

Ускоренные методы. Heavy Ball, Нестеров,
FISTA

Даня Меркулов

ФКН ВШЭ

Мотивация: почему GD медленный?

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} \|x_0 - x^*\|^2$$

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Пример: $\kappa = 100$.

k	$r_{\text{GD}}^k \approx 0.980^k$
100	0.135
500	4.1×10^{-5}
1000	1.7×10^{-9}

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Пример: $\kappa = 100$.

k	$r_{\text{GD}}^k \approx 0.980^k$
100	0.135
500	4.1×10^{-5}
1000	1.7×10^{-9}

Вопрос: можно ли добиться скорости $O(1/\sqrt{\kappa})$ вместо $O(1/\kappa)$?

Ответ: да — методы с «памятью» (momentum).

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента,
«забываем» прошлое.

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Параметры: - $\beta = 0$: обычный GD - $\beta \in (0, 1)$: Heavy Ball (Поляк, 1964) - β с особым выбором: метод Нестерова

Метод тяжёлого шара (Heavy Ball)

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для квадратичных функций $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Скорость сходимости:

$$\|x_k - x^*\| \leq C \cdot \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Скорость сходимости:

$$\|x_k - x^*\| \leq C \cdot \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

Скорость $r_{\text{HB}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \approx 1 - \frac{2}{\sqrt{\kappa}}$ — в $\sqrt{\kappa}$ раз лучше GD!

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

Анализ Heavy Ball для квадрати

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Анализ Heavy Ball для квадрати

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Характеристический многочлен:

$$t^2 - (1 + \beta - \alpha\lambda)t + \beta = 0$$

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Характеристический многочлен:

$$t^2 - (1 + \beta - \alpha\lambda)t + \beta = 0$$

Идея: хотим $|t_{1,2}| \leq r < 1$ для всех $\lambda \in [\mu, L]$.

Оптимальный выбор — **двойной корень** $t = \sqrt{\beta}$ при $\lambda = \sqrt{L\mu}$ (среднегеометрическое):

$$\sqrt{\beta^*} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$, $k = 100$!

Недостаток: оптимальные α^*, β^* требуют знания μ и L .

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$, $k = 100$!

Недостаток: оптимальные α^*, β^* требуют знания μ и L .

Важно: Heavy Ball **не ускоряет** для общих выпуклых функций (не квадратик).

Лессар, Recht, Packard, 2016: HB расходится для некоторых выпуклых функций!

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Метод Нестерова (AGD)

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned}y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)\end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned} y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k) \end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

Ключевое отличие от GD: шаг градиента делается из x_k (не из y_k !), а x_k — «ускоренная» точка с моментом.

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned} y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k) \end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

Ключевое отличие от GD: шаг градиента делается из x_k (не из y_k !), а x_k — «ускоренная» точка с моментом.

Два вектора: y_k — «приближение к минимуму», x_k — «точка шага».

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1$ $\boxtimes$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \boxtimes$$

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1$ $\boxtimes$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \quad \boxtimes$$

Следствие: $t_k^2 \geq \frac{(k+1)^2}{4}$.

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1 \quad \square$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \quad \square$$

Следствие: $t_k^2 \geq \frac{(k+1)^2}{4}$.

Другая запись: коэффициент момента $\frac{t_k - 1}{t_{k+1}} \rightarrow 1^-$ при $k \rightarrow \infty$.

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Лемма убывания ($\Phi_k \leq \Phi_{k-1}$): вытекает из L -гладкости (descent lemma) + рекуррентности t_k .

Начальное значение: $\Phi_0 = \frac{L}{2}\|x_0 - x^*\|^2$.

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Лемма убывания ($\Phi_k \leq \Phi_{k-1}$): вытекает из L -гладкости (descent lemma) + рекуррентности t_k .

Начальное значение: $\Phi_0 = \frac{L}{2}\|x_0 - x^*\|^2$.

Из $t_k \geq (k+1)/2$:

$$f(y_k) - f^* \leq \frac{\Phi_0}{t_k^2} \leq \frac{L/2 \cdot \|x_0 - x^*\|^2}{(k+1)^2/4} = \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

□

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD в 20 раз быстрее ($\approx \sqrt{\kappa}$).

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

AGD в 20 раз быстрее ($\approx \sqrt{\kappa}$).

Вывод: при $\kappa \gg 1$ ускорение огромно. При $\kappa = 2$: ускорение $\approx \sqrt{2}$ — незначительно.

FISTA: ускорение для негладких задач

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Скорость ISTA: $O(1/k)$ — как GD для гладкого случая.

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Скорость ISTA: $O(1/k)$ — как GD для гладкого случая.

Вопрос: можно ли применить ускорение Нестерова к ISTA? Да!

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned}y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)\end{aligned}$$

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

Скорость FISTA:

$$F(y_k) - F^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}, \quad F = f + g$$

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

Скорость FISTA:

$$F(y_k) - F^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}, \quad F = f + g$$

Отличие от ISTA: ISTA делает прокс-шаг из y_k (предыдущего приближения), FISTA — из x_k (ускоренной точки).

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$\nabla f(x) = A^\top (Ax - b)$, $L = \lambda_{\max}(A^\top A)$.

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$\nabla f(x) = A^\top (Ax - b)$, $L = \lambda_{\max}(A^\top A)$.

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$$\nabla f(x) = A^\top (Ax - b), \quad L = \lambda_{\max}(A^\top A).$$

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso:

$$u_k = x_k - \frac{1}{L} A^\top (Ax_k - b), \quad y_{k+1} = \mathcal{S}_{\lambda/L}(u_k), \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$$\nabla f(x) = A^\top (Ax - b), \quad L = \lambda_{\max}(A^\top A).$$

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso:

$$u_k = x_k - \frac{1}{L} A^\top (Ax_k - b), \quad y_{k+1} = \mathcal{S}_{\lambda/L}(u_k), \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

Итоговая стоимость: одно умножение Ax + один мягкий порог за итерацию.

Нижние оценки и оптимальность

Оракульная модель

Класс задач: $\mathcal{F}_L = \{f : f \text{ выпуклая, } L\text{-гладкая}\}$.

Алгоритм первого порядка: на шаге k использует только:

$$x_k \in x_0 + \text{span}\{\nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_{k-1})\}$$

Оракульная модель

Класс задач: $\mathcal{F}_L = \{f : f \text{ выпуклая, } L\text{-гладкая}\}$.

Алгоритм первого порядка: на шаге k использует только:

$$x_k \in x_0 + \text{span}\{\nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_{k-1})\}$$

Вопрос: насколько быстро любой такой алгоритм может минимизировать $f \in \mathcal{F}_L$?

Оракульная модель

Класс задач: $\mathcal{F}_L = \{f : f \text{ выпуклая, } L\text{-гладкая}\}$.

Алгоритм первого порядка: на шаге k использует только:

$$x_k \in x_0 + \text{span}\{\nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_{k-1})\}$$

Вопрос: насколько быстро любой такой алгоритм может минимизировать $f \in \mathcal{F}_L$?

Ответ: Нестеров доказал **нижнюю оценку**.

Нижняя оценка (Нестеров, 1983)

Теорема. Для любого алгоритма первого порядка и любого $k \geq 1$ существует $f \in \mathcal{F}_L$ такая, что:

$$f(x_{k-1}) - f^* \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}$$

Нижняя оценка (Нестеров, 1983)

Теорема. Для любого алгоритма первого порядка и любого $k \geq 1$ существует $f \in \mathcal{F}_L$ такая, что:

$$f(x_{k-1}) - f^* \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}$$

Конструкция («лестничная функция»): специальная квадратичная форма, которую алгоритм первого порядка не может «разгадать» раньше k -й итерации:

$$f_d(x) = \frac{L}{8} (\|x\|^2 - e_1^\top x) \quad \text{на } \mathbb{R}^d$$

При $d \geq k$: $x_k \in \text{span}\{e_1, \dots, e_k\}$ — не хватает компонент для точного решения.

Нижняя оценка (Нестеров, 1983)

Теорема. Для любого алгоритма первого порядка и любого $k \geq 1$ существует $f \in \mathcal{F}_L$ такая, что:

$$f(x_{k-1}) - f^* \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}$$

Конструкция («лестничная функция»): специальная квадратичная форма, которую алгоритм первого порядка не может «разгадать» раньше k -й итерации:

$$f_d(x) = \frac{L}{8} (\|x\|^2 - e_1^\top x) \quad \text{на } \mathbb{R}^d$$

При $d \geq k$: $x_k \in \text{span}\{e_1, \dots, e_k\}$ — не хватает компонент для точного решения.

Следствие: нижняя оценка $\Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$.

Оптимальность AGD

Верхняя оценка (AGD): $f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$.

Нижняя оценка: $\Omega\left(\frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}\right)$.

Оптимальность AGD

Верхняя оценка (AGD): $f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$.

Нижняя оценка: $\Omega\left(\frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}\right)$.

Вывод: обе оценки $O(1/k^2)$ с теми же параметрами (с точностью до константы).

Оптимальность AGD

Верхняя оценка (AGD): $f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$.

Нижняя оценка: $\Omega\left(\frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}\right)$.

Вывод: обе оценки $O(1/k^2)$ с теми же параметрами (с точностью до константы).

AGD является оптимальным в классе алгоритмов первого порядка

Оптимальность AGD

Верхняя оценка (AGD): $f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$.

Нижняя оценка: $\Omega\left(\frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}\right)$.

Вывод: обе оценки $O(1/k^2)$ с теми же параметрами (с точностью до константы).

AGD является оптимальным в классе алгоритмов первого порядка

Это результат фундаментальный: улучшить скорость $O(1/k^2)$ без дополнительных предположений невозможно.

Оптимальность AGD

Верхняя оценка (AGD): $f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$.

Нижняя оценка: $\Omega\left(\frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}\right)$.

Вывод: обе оценки $O(1/k^2)$ с теми же параметрами (с точностью до константы).

AGD является оптимальным в классе алгоритмов первого порядка

Это результат фундаментальный: улучшить скорость $O(1/k^2)$ без дополнительных предположений невозможно.

Что даёт дополнительное предположение (μ -сильная выпуклость)? $O(e^{-k/\sqrt{\kappa}})$.

Сводная таблица скоростей

Метод	Класс	Скорость
GD	L -гладкая выпуклая	$O\left(\frac{L\ x_0\ ^2}{k}\right)$
AGD (Нестеров)	L -гладкая выпуклая	$O\left(\frac{L\ x_0\ ^2}{k^2}\right) \boxtimes$
GD	μ -с.в., L -гладкая	$O\left(e^{-2k/(\kappa+1)}\right)$
Heavy Ball	квадратичная	$O\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k\right)$
AGD (restart)	μ -с.в., L -гладкая	$O\left(e^{-k/\sqrt{\kappa}}\right) \boxtimes$
ISTA	$f + g$ составная	$O\left(\frac{1}{k}\right)$
FISTA	$f + g$ составная	$O\left(\frac{1}{k^2}\right) \boxtimes$

$\boxtimes$ = оптимальный в своём классе

Ускорение в стохастическом случае

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L} g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Суммируя: накапливается дисперсия $\sim k\sigma^2/L^2$.

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Суммируя: накапливается дисперсия $\sim k\sigma^2/L^2$.

Итог:
$$\mathbb{E}[f(y_k) - f^*] \leq \frac{2L\|x_0\|^2}{k^2} + \frac{C\sigma^2 k}{L}$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Нижняя оценка (Agarwal et al., 2012): для стохастических алгоритмов первого порядка:

$$\mathbb{E}[f(x_k) - f^*] \geq \Omega\left(\frac{L\|x_0\|^2}{k^2} + \frac{\sigma\|x_0\|}{\sqrt{k}}\right)$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Нижняя оценка (Agarwal et al., 2012): для стохастических алгоритмов первого порядка:

$$\mathbb{E}[f(x_k) - f^*] \geq \Omega\left(\frac{L\|x_0\|^2}{k^2} + \frac{\sigma\|x_0\|}{\sqrt{k}}\right)$$

SGD достигает $O(1/\sqrt{k})$ — это **оптимально** в стохастическом случае!

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Дисперсия моментного градиента:

$$\text{Var}[m_k] \approx \frac{(1 - \beta)}{2(1 - \beta)} \sigma^2 = \frac{\sigma^2}{1 - \beta}$$

При $\beta \rightarrow 1$: дисперсия растёт как $O(1/(1 - \beta))$ — шум усиливается.

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Дисперсия моментного градиента:

$$\text{Var}[m_k] \approx \frac{(1 - \beta)}{2(1 - \beta)} \sigma^2 = \frac{\sigma^2}{1 - \beta}$$

При $\beta \rightarrow 1$: дисперсия растёт как $O(1/(1 - \beta))$ — шум **усиливается**.

Вывод: для SGD оптимален **убывающий шаг** $\alpha_k \sim 1/\sqrt{k}$ **без** тяжёлого момента.

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Дисперсия моментного градиента:

$$\text{Var}[m_k] \approx \frac{(1 - \beta)}{2(1 - \beta)} \sigma^2 = \frac{\sigma^2}{1 - \beta}$$

При $\beta \rightarrow 1$: дисперсия растёт как $O(1/(1 - \beta))$ — шум **усиливается**.

Вывод: для SGD оптимален **убывающий шаг** $\alpha_k \sim 1/\sqrt{k}$ **без** тяжёлого момента.

Практика: $\beta = 0.9$ в CV (умеренный момент, сглаживает шум, не «ломает» сходимость). Adam — адаптивный момент, отдельная история.

Итог

Ключевые идеи лекции

1. Heavy Ball (Поляк, 1964): - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций

Ключевые идеи лекции

- 1. Heavy Ball (Поляк, 1964):** - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
- 2. Нестеров AGD (1983):** - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка

Ключевые идеи лекции

- 1. Heavy Ball (Поляк, 1964):** - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
- 2. Нестеров AGD (1983):** - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка
- 3. FISTA (Beck–Teboulle, 2009):** - AGD + проксимальный шаг вместо градиентного - $O(1/k^2)$ для составных задач $(f + g)$

Ключевые идеи лекции

- 1. Heavy Ball (Поляк, 1964):** - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик: $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
- 2. Нестеров AGD (1983):** - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка
- 3. FISTA (Beck–Teboulle, 2009):** - AGD + проксимальный шаг вместо градиентного - $O(1/k^2)$ для составных задач $(f + g)$
- 4. Стохастика:** - Момент Нестерова **не ускоряет** SGD при ненулевом шуме - SGD-оптимум: $O(1/\sqrt{k})$ при убывающем шаге

Ключевые формулы

Объект	Формула
Heavy Ball	$x_{k+1} = x_k - \alpha^* \nabla f(x_k) + \beta^* (x_k - x_{k-1})$
Оптимальные параметры НВ	$\alpha^* = 4/(\sqrt{L} + \sqrt{\mu})^2, \beta^* = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$
Скорость НВ (квадратика)	$\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$
AGD скорость (выпуклая)	$2L\ x_0 - x^*\ ^2/(k+1)^2$
AGD скорость (с.в.)	$e^{-k/\sqrt{\kappa}}$ с перезапуском
FISTA скорость	$2L\ x_0 - x^*\ ^2/k^2$
Нижняя оценка (выпуклая)	$3L\ x_0 - x^*\ ^2/[32(k+1)^2]$

Ключевые формулы

Объект	Формула
Heavy Ball	$x_{k+1} = x_k - \alpha^* \nabla f(x_k) + \beta^* (x_k - x_{k-1})$
Оптимальные параметры HB	$\alpha^* = 4/(\sqrt{L} + \sqrt{\mu})^2, \beta^* = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$
Скорость HB (квадратика)	$\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$
AGD скорость (выпуклая)	$2L\ x_0 - x^*\ ^2/(k+1)^2$
AGD скорость (с.в.)	$e^{-k/\sqrt{\kappa}}$ с перезапуском
FISTA скорость	$2L\ x_0 - x^*\ ^2/k^2$
Нижняя оценка (выпуклая)	$3L\ x_0 - x^*\ ^2/[32(k+1)^2]$

Связи с курсом: - Л6 (двойственность): сопряжённые функции $\rightarrow$ прокс-оператор $\rightarrow$ FISTA - Л7 (субградиент/ISTA): FISTA = ISTA + момент - Л9 (SGD): ускорение ломается из-за стохастики $\rightarrow$ Variance Reduction (Л10)

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций HB нужно для точности 10^{-6} ? Сравните с GD.

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций HB нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций HB нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Домашнее задание

Тест Лекции 8 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций HB нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Следующая лекция: SGD. Шумовой пол, Mini-batch, расписания шагов. Почему ускорение «ломается» при стохастике.