



Ускоренные методы. Heavy Ball, Нестеров,
FISTA

Даня Меркулов

ФКН ВШЭ

Мотивация: почему GD медленный?

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} \|x_0 - x^*\|^2$$

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Пример: $\kappa = 100$.

k	$r_{\text{GD}}^k \approx 0.980^k$
100	0.135
500	4.1×10^{-5}
1000	1.7×10^{-9}

Напоминание: скорость GD

Задача: $\min_x f(x)$, f — μ -сильно выпуклая, L -гладкая, $\kappa = L/\mu$.

GD с оптимальным шагом $\alpha = 2/(L + \mu)$:

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2$$

Скорость $r_{\text{GD}} = \frac{\kappa - 1}{\kappa + 1} = 1 - \frac{2}{\kappa + 1} \approx 1 - \frac{2}{\kappa}$ при большом κ .

Пример: $\kappa = 100$.

k	$r_{\text{GD}}^k \approx 0.980^k$
100	0.135
500	4.1×10^{-5}
1000	1.7×10^{-9}

Вопрос: можно ли добиться скорости $O(1/\sqrt{\kappa})$ вместо $O(1/\kappa)$?

Ответ: да — методы с «памятью» (momentum).

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента,
«забываем» прошлое.

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Интуиция: момент и инерция

GD: выбираем направление только из текущего градиента, «забываем» прошлое.

Проблема: в плохо обусловленных задачах GD «петляет» — делает шаги, которые частично отменяют друг друга.

Идея момента: добавить «инерцию» — помнить направление предыдущего шага.

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \underbrace{\beta(x_k - x_{k-1})}_{\text{момент}}$$

Физическая аналогия: шарик катится к минимуму.

- GD = шарик с бесконечным трением (каждый раз останавливается)
- Момент = шарик с инерцией (набирает скорость вниз по склону)

Параметры: - $\beta = 0$: обычный GD - $\beta \in (0, 1)$: Heavy Ball (Поляк, 1964) - β с особым выбором: метод Нестерова

Нижние оценки

Таблица нижних оценок

выпуклая (негладкая)	гладкая (невыпуклая) ¹	гладкая и выпуклая ²	гладкая и сильно выпуклая (или PL)
$\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$	$\mathcal{O}\left(\frac{1}{k^2}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$	$\mathcal{O}\left(\frac{1}{k^2}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$	$\mathcal{O}\left(\left(1 - \sqrt{\frac{\mu}{L}}\right)^k\right)$ $k_\varepsilon \sim \mathcal{O}\left(\sqrt{n} \log \frac{1}{\varepsilon}\right)$

¹Carmon, Duchi, Hinder, Sidford, 2017

²Немировский, Юдин, 1979

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка:

$$\begin{aligned}x^{k+1} &\in x^0 + \operatorname{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \operatorname{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка:

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

Для построения нижней оценки нужно найти функцию f из соответствующего класса такую, что любой метод из семейства 1 будет работать не быстрее нижней оценки.

Гладкий случай

Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

Гладкий случай

i Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся f , для которой скорость ограничена снизу как $\Omega\left(\frac{1}{k^2}\right)$.

Гладкий случай

i Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся f , для которой скорость ограничена снизу как $\Omega\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .

Гладкий случай

i Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся f , для которой скорость ограничена снизу как $\Omega\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Эта оценка $\Omega\left(\frac{1}{k^2}\right)$ **не совпадает** со скоростью GD $O\left(\frac{1}{k}\right)$. Два варианта:

Гладкий случай

i Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся f , для которой скорость ограничена снизу как $\Omega\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Эта оценка $\Omega\left(\frac{1}{k^2}\right)$ **не совпадает** со скоростью GD $O\left(\frac{1}{k}\right)$. Два варианта:
 - а. Нижняя оценка неточна.

Гладкий случай

i Theorem

Существует функция f , L -гладкая и выпуклая, такая что любой метод 1 удовлетворяет для $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся f , для которой скорость ограничена снизу как $\Omega\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Эта оценка $\Omega\left(\frac{1}{k^2}\right)$ **не совпадает** со скоростью GD $O\left(\frac{1}{k}\right)$. Два варианта:
 - a. Нижняя оценка неточна.
 - b. **Градиентный метод неоптимален для данной задачи.**

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Заметим:

$$x^T Ax = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно, $x^T Ax \geq 0$ и $0 \preceq A \preceq 4I$.

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Заметим:

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно, $x^T A x \geq 0$ и $0 \preceq A \preceq 4I$.

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Заметим:

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно, $x^T A x \geq 0$ и $0 \preceq A \preceq 4I$.

Пример при $n = 3$:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Заметим:

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно, $x^T A x \geq 0$ и $0 \preceq A \preceq 4I$.

Пример при $n = 3$:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Худшая функция Нестерова

- Пусть $n = 2k + 1$ и $A \in \mathbb{R}^{n \times n}$:

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Заметим:

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно, $x^T A x \geq 0$ и $0 \preceq A \preceq 4I$.

Пример при $n = 3$:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка:

$$\begin{aligned} x^T A x &\leq 4(x_1^2 + x_2^2 + x_3^2) \\ 0 &\leq x_1^2 + (x_1 + x_2)^2 + (x_2 + x_3)^2 + x_3^2 \end{aligned}$$

Худшая функция Нестерова

- Определим L -гладкую выпуклую функцию: $f(x) = \frac{L}{4} \left(\frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$.

Худшая функция Нестерова

- Определим L -гладкую выпуклую функцию: $f(x) = \frac{L}{4} \left(\frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$.
- Оптимум x^* удовлетворяет $Ax^* = e_1$. Решение:

$$x_i^* = 1 - \frac{i}{n+1},$$

Худшая функция Нестерова

- Определим L -гладкую выпуклую функцию: $f(x) = \frac{L}{4} \left(\frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$.
- Оптимум x^* удовлетворяет $Ax^* = e_1$. Решение:

$$x_i^* = 1 - \frac{i}{n+1},$$

- Значение в оптимуме:

$$f(x^*) = -\frac{L}{8} \langle x^*, e_1 \rangle = -\frac{L}{8} \left(1 - \frac{1}{n+1} \right).$$

Доказательство нижней оценки (гладкий случай)

- Стартуем из $x^0 = 0$. Оракул даёт $g_0 = -e_1$.
Тогда $x^1 \in \text{span}\{e_1\}$:

$$x^1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Доказательство нижней оценки (гладкий случай)

- Стартуем из $x^0 = 0$. Оракул даёт $g_0 = -e_1$. Тогда $x^1 \in \text{span}\{e_1\}$:

$$x^1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за **трёхдиагональной структуры** A , по индукции: после k итераций последние $n - k$ компонент x^k равны нулю.

Доказательство нижней оценки (гладкий случай)

- Стартуем из $x^0 = 0$. Оракул даёт $g_0 = -e_1$. Тогда $x^1 \in \text{span}\{e_1\}$:

$$x^1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за **трёхдиагональной структуры** A , по индукции: после k итераций последние $n - k$ компонент x^k равны нулю.

Доказательство нижней оценки (гладкий случай)

- Стартуем из $x^0 = 0$. Оракул даёт $g_0 = -e_1$. Тогда $x^1 \in \text{span}\{e_1\}$:
- Каждый итерат x^k лежит в $S_k = \text{span}\{e_1, \dots, e_k\}$ и не может «дотянуться» до x^* .

$$x^1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за **трёхдиагональной структуры** A , по индукции: после k итераций последние $n - k$ компонент x^k равны нулю.

Доказательство нижней оценки (гладкий случай)

- Стартуем из $x^0 = 0$. Оракул даёт $g_0 = -e_1$. Тогда $x^1 \in \text{span}\{e_1\}$:

$$x^1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за **трёхдиагональной структуры** A , по индукции: после k итераций последние $n - k$ компонент x^k равны нулю.

- Каждый итерат x^k лежит в $S_k = \text{span}\{e_1, \dots, e_k\}$ и не может «дотянуться» до x^* .
- Даже лучшее приближение из S_k :

$$\tilde{x}^k = \arg \min_{x \in S_k} f(x)$$

даёт $f(\tilde{x}^k) > f(x^*)$.

Доказательство (продолжение)

- Имеем $\tilde{x}_i^k = 1 - \frac{i}{k+1}$ и $f(\tilde{x}^k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$. Тогда:

$$\begin{aligned} f(x^k) - f(x^*) &\geq f(\tilde{x}^k) - f(x^*) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1} \right) \stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \tag{2}$$

Доказательство (продолжение)

- Имеем $\tilde{x}_i^k = 1 - \frac{i}{k+1}$ и $f(\tilde{x}^k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$. Тогда:

$$\begin{aligned} f(x^k) - f(x^*) &\geq f(\tilde{x}^k) - f(x^*) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1} \right) \stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \tag{2}$$

Доказательство (продолжение)

- Имеем $\tilde{x}_i^k = 1 - \frac{i}{k+1}$ и $f(\tilde{x}^k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$. Тогда:

$$\begin{aligned} f(x^k) - f(x^*) &\geq f(\tilde{x}^k) - f(x^*) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1} \right) \stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \quad (2)$$

- Оценим $R = \|x^0 - x^*\|_2$:

$$\|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \leq \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3} \Rightarrow k+1 \geq \frac{3}{2} R^2 \quad (3)$$

Доказательство (продолжение)

- Имеем $\tilde{x}_i^k = 1 - \frac{i}{k+1}$ и $f(\tilde{x}^k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$. Тогда:

$$\begin{aligned} f(x^k) - f(x^*) &\geq f(\tilde{x}^k) - f(x^*) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1} \right) \stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \quad (2)$$

- Оценим $R = \|x^0 - x^*\|_2$:

$$\|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \leq \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3} \Rightarrow k+1 \geq \frac{3}{2} R^2 \quad (3)$$

Доказательство (продолжение)

- Имеем $\tilde{x}_i^k = 1 - \frac{i}{k+1}$ и $f(\tilde{x}^k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$. Тогда:

$$\begin{aligned} f(x^k) - f(x^*) &\geq f(\tilde{x}^k) - f(x^*) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1} \right) \stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \quad (2)$$

- Оценим $R = \|x^0 - x^*\|_2$:

$$\|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \leq \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3} \Rightarrow k+1 \geq \frac{3}{2} R^2 \quad (3)$$

- Объединяя (2) и (3):

$$f(x^k) - f(x^*) \geq \frac{L}{16(k+1)} \geq \frac{3LR^2}{32(k+1)^2}$$

Что завершает доказательство с оценкой $\Omega\left(\frac{1}{k^2}\right)$.

Теоремы нижних оценок

i Гладкий выпуклый случай

Существует L -гладкая выпуклая f такая, что для любого метода 1 и $k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

i Гладкий сильно выпуклый случай

Для любого x^0 и $\mu > 0$, $\kappa = \frac{L}{\mu} > 1$ существует L -гладкая μ -сильно выпуклая f такая, что:

$$\begin{aligned}\|x^k - x^*\|_2 &\geq \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x^0 - x^*\|_2 \\ f(x^k) - f^* &\geq \frac{\mu}{2} \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2k} \|x^0 - x^*\|_2^2\end{aligned}$$

Ускорение для квадратик: полиномы Чебышёва

Сходимость GD для квадратик

Рассмотрим сильно выпуклую квадратичную функцию:

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

i Theorem


GD с шагом $\alpha_k = \frac{2}{\mu+L}$ сходится:

$$\|x^{k+1} - x^*\|_2 = \left(\frac{\kappa - 1}{\kappa + 1}\right)^k \|x^0 - x^*\|_2$$


где $\kappa = L/\mu$ — число обусловленности.

Число обусловленности κ

$\kappa = 1.0$



$\kappa = 100.0$



Сходимость из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть x^* — решение $Ax = b$, $e_k = x_k - x^*$. Тогда:

$$e_{k+1} = (I - \alpha_k A)e_k.$$

Полиномы

Получаем $e_k = p_k(A)e_0$, где p_k — полином:

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

Оценка нормы ошибки:

$$\|e_k\| \leq \|p_k(A)\| \cdot \|e_0\|.$$

Сходимость из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть x^* — решение $Ax = b$, $e_k = x_k - x^*$. Тогда:

$$e_{k+1} = (I - \alpha_k A)e_k.$$

Полиномы

Получаем $e_k = p_k(A)e_0$, где p_k — полином:

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

Оценка нормы ошибки:

$$\|e_k\| \leq \|p_k(A)\| \cdot \|e_0\|.$$

Для симметричной A с собственными значениями в $[\mu, L]$:

$$\|p_k(A)\| \leq \max_{\mu \leq a \leq L} |p_k(a)|.$$

Задача: среди всех полиномов $p_k(0) = 1$ найти тот, чья амплитуда на $[\mu, L]$ минимальна.


Наивный полином (постоянный шаг)

Выбор $\alpha_k = \frac{2}{\mu+L}$ даёт $|p_k(\mu)| = |p_k(L)|$:

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|$$

Это в точности скорость GD для гладких сильно выпуклых функций.

Можно ли лучше? **Да** — полиномы Чебышёва.




Наивный полином (постоянный шаг)

Выбор $\alpha_k = \frac{2}{\mu+L}$ даёт $|p_k(\mu)| = |p_k(L)|$:

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|$$

Это в точности скорость GD для гладких сильно выпуклых функций.

Можно ли лучше? **Да** — полиномы Чебышёва.




Наивный полином (постоянный шаг)

Выбор $\alpha_k = \frac{2}{\mu+L}$ даёт $|p_k(\mu)| = |p_k(L)|$:

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|$$

Это в точности скорость GD для гладких сильно выпуклых функций.

Можно ли лучше? **Да** — полиномы Чебышёва.




Наивный полином (постоянный шаг)

Выбор $\alpha_k = \frac{2}{\mu+L}$ даёт $|p_k(\mu)| = |p_k(L)|$:

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|$$

Это в точности скорость GD для гладких сильно выпуклых функций.

Можно ли лучше? **Да** — полиномы Чебышёва.




Наивный полином (постоянный шаг)

Выбор $\alpha_k = \frac{2}{\mu+L}$ даёт $|p_k(\mu)| = |p_k(L)|$:

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|$$

Это в точности скорость GD для гладких сильно выпуклых функций.

Можно ли лучше? **Да** — полиномы Чебышёва.



Полиномы Чебышёва


Полиномы Чебышёва дают оптимальный ответ: при подходящем масштабировании они минимизируют амплитуду на $[\mu, L]$ при условии $p_k(0) = 1$.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Стандартные полиномы Чебышёва (без масштабирования):



Полиномы Чебышёва


Полиномы Чебышёва дают оптимальный ответ: при подходящем масштабировании они минимизируют амплитуду на $[\mu, L]$ при условии $p_k(0) = 1$.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Стандартные полиномы Чебышёва (без масштабирования):



Полиномы Чебышёва


Полиномы Чебышёва дают оптимальный ответ: при подходящем масштабировании они минимизируют амплитуду на $[\mu, L]$ при условии $p_k(0) = 1$.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Стандартные полиномы Чебышёва (без масштабирования):



Полиномы Чебышёва


Полиномы Чебышёва дают оптимальный ответ: при подходящем масштабировании они минимизируют амплитуду на $[\mu, L]$ при условии $p_k(0) = 1$.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Стандартные полиномы Чебышёва (без масштабирования):



Полиномы Чебышёва


Полиномы Чебышёва дают оптимальный ответ: при подходящем масштабировании они минимизируют амплитуду на $[\mu, L]$ при условии $p_k(0) = 1$.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Стандартные полиномы Чебышёва (без масштабирования):



Масштабированные полиномы Чебышёва

Исходные полиномы Чебышёва определены на $[-1, 1]$. Для наших целей нужно масштабирование на $[\mu, L]$.

Масштабированные полиномы Чебышёва

Исходные полиномы Чебышёва определены на $[-1, 1]$. Для наших целей нужно масштабирование на $[\mu, L]$.
Аффинное преобразование:

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$

$$\begin{aligned} \text{При этом } x = 1 &\leftrightarrow a = \mu, \quad x = -1 \leftrightarrow a = L, \\ x = 0 &\leftrightarrow a = \frac{\mu + L}{2}. \end{aligned}$$

Масштабированные полиномы Чебышёва

Исходные полиномы Чебышёва определены на $[-1, 1]$. Для наших целей нужно масштабирование на $[\mu, L]$.

Аффинное преобразование:


При этом $x = 1 \leftrightarrow a = \mu$, $x = -1 \leftrightarrow a = L$,
 $x = 0 \leftrightarrow a = \frac{\mu+L}{2}$.

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$


Нормализованный полином (с условием $P_k(0) = 1$):

$$P_k(a) = T_k\left(\frac{L + \mu - 2a}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$


Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва




Масштабированные полиномы Чебышёва



Масштабированные полиномы Чебышёва



Масштабированные полиномы Чебышёва



Верхняя оценка через Чебышёва

Максимум $|P_k|$ на $[\mu, L]$ достигается в $a = \mu$:

$$\|P_k(A)\|_2 \leq T_k \left(\frac{\varkappa + 1}{\varkappa - 1} \right)^{-1} = T_k (1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\varkappa - 1}.$$

Верхняя оценка через Чебышёва

Максимум $|P_k|$ на $[\mu, L]$ достигается в $a = \mu$:

$$\|P_k(A)\|_2 \leq T_k \left(\frac{\varkappa + 1}{\varkappa - 1} \right)^{-1} = T_k (1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\varkappa - 1}.$$

Для оценки $T_k(1 + \epsilon)$ снизу:

1. $T_k(x) = \cosh(k \operatorname{arccosh}(x))$ при $x \geq 1$.

Верхняя оценка через Чебышёва

Максимум $|P_k|$ на $[\mu, L]$ достигается в $a = \mu$:

$$\|P_k(A)\|_2 \leq T_k \left(\frac{\varkappa + 1}{\varkappa - 1} \right)^{-1} = T_k (1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\varkappa - 1}.$$

Для оценки $T_k(1 + \epsilon)$ снизу:

1. $T_k(x) = \cosh(k \operatorname{arccosh}(x))$ при $x \geq 1$.
2. $e^{\operatorname{arccosh}(1+\epsilon)} = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}$.

Верхняя оценка через Чебышёва

Максимум $|P_k|$ на $[\mu, L]$ достигается в $a = \mu$:

$$\|P_k(A)\|_2 \leq T_k \left(\frac{\varkappa + 1}{\varkappa - 1} \right)^{-1} = T_k (1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\varkappa - 1}.$$

Для оценки $T_k(1 + \epsilon)$ снизу:

1. $T_k(x) = \cosh(k \operatorname{arccosh}(x))$ при $x \geq 1$.
2. $e^{\operatorname{arccosh}(1+\epsilon)} = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}$.

3. Следовательно:

$$T_k(1 + \epsilon) \geq \frac{(1 + \sqrt{\epsilon})^k}{2}$$

Верхняя оценка через Чебышёва

Максимум $|P_k|$ на $[\mu, L]$ достигается в $a = \mu$:

$$\|P_k(A)\|_2 \leq T_k \left(\frac{\varkappa + 1}{\varkappa - 1} \right)^{-1} = T_k (1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\varkappa - 1}.$$

Для оценки $T_k(1 + \epsilon)$ снизу:

1. $T_k(x) = \cosh(k \operatorname{arccosh}(x))$ при $x \geq 1$.
2. $e^{\operatorname{arccosh}(1+\epsilon)} = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}$.

3. Следовательно:

$$T_k(1 + \epsilon) \geq \frac{(1 + \sqrt{\epsilon})^k}{2}$$

4. Итого:

$$\|e_k\| \leq 2 \exp \left(-\sqrt{\frac{2}{\varkappa - 1}} k \right) \|e_0\|$$

Ускоренный метод из рекурсии Чебышёва

Из рекуррентного соотношения $T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$ можно вывести итерационную схему:

$$P_{k+1}(a) = (1 - \alpha_k a)P_k(a) + \beta_k (P_k(a) - P_{k-1}(a))$$

Ускоренный метод из рекурсии Чебышёва

Из рекуррентного соотношения $T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$ можно вывести итерационную схему:

$$P_{k+1}(a) = (1 - \alpha_k a)P_k(a) + \beta_k (P_k(a) - P_{k-1}(a))$$

Поскольку $e_{k+1} = P_{k+1}(A)e_0$ и $\nabla f(x_k) = Ax_k$ для квадратичной задачи:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Ускоренный метод из рекурсии Чебышёва

Из рекуррентного соотношения $T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$ можно вывести итерационную схему:

$$P_{k+1}(a) = (1 - \alpha_k a)P_k(a) + \beta_k (P_k(a) - P_{k-1}(a))$$


Поскольку $e_{k+1} = P_{k+1}(A)e_0$ и $\nabla f(x_k) = Ax_k$ для квадратичной задачи:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$


Это в точности метод тяжёлого шара — он оптимален для квадратик как следствие оптимальности полиномов Чебышёва!

Ускорение из первых принципов

$\kappa = 1.0$



$\kappa = 100.0$



Метод тяжёлого шара (Heavy Ball)

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для квадратичных функций $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Скорость сходимости:

$$\|x_k - x^*\| \leq C \cdot \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

Heavy Ball: алгоритм

Метод тяжёлого шара (Поляк, 1964):

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Ключевое: для **квадратичных функций** $f(x) = \frac{1}{2}x^\top Ax - b^\top x$ оптимальные параметры известны явно.

Для $A \succ 0$ со спектром $[\mu, L]$ и $\kappa = L/\mu$:

$$\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^2$$

Скорость сходимости:

$$\|x_k - x^*\| \leq C \cdot \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k$$

Скорость $r_{\text{HB}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \approx 1 - \frac{2}{\sqrt{\kappa}}$ — в $\sqrt{\kappa}$ раз лучше GD!

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Анализ Heavy Ball для квадрати́к

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Характеристический многочлен:

$$t^2 - (1 + \beta - \alpha\lambda)t + \beta = 0$$

Анализ Heavy Ball для квадратик

Доказательство скорости: введём $e_k = x_k - x^*$.

Итерация в терминах ошибки ($Ax^* = b$):

$$e_{k+1} = (1 + \beta - \alpha A)e_k - \beta e_{k-1}$$

В собственном базисе A (eigenvalue λ):

$$(e_{k+1})_\lambda = (1 + \beta - \alpha\lambda)(e_k)_\lambda - \beta(e_{k-1})_\lambda$$

Характеристический многочлен:

$$t^2 - (1 + \beta - \alpha\lambda)t + \beta = 0$$

Идея: хотим $|t_{1,2}| \leq r < 1$ для всех $\lambda \in [\mu, L]$.

Оптимальный выбор — **двойной корень** $t = \sqrt{\beta}$ при $\lambda = \sqrt{L\mu}$ (среднегеометрическое):

$$\sqrt{\beta^*} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$,
 $k = 100$!

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$, $k = 100$!

Недостаток: оптимальные α^*, β^* требуют знания μ и L .

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Сравнение скоростей: GD vs Heavy Ball

κ	r_{GD}	r_{HB}	Ускорение
4	0.600	0.333	$1.8\times$
10	0.818	0.520	$2.6\times$
100	0.980	0.818	$\approx \sqrt{10}\times$
1000	0.998	0.939	$\approx \sqrt{10}\times$
κ	$1 - 2/\kappa$	$1 - 2/\sqrt{\kappa}$	$\approx \sqrt{\kappa}\times$

Heavy Ball быстрее GD в 10^7 раз при $\kappa = 100$, $k = 100$!

Недостаток: оптимальные α^*, β^* требуют знания μ и L .

Важно: Heavy Ball **не ускоряет** для общих выпуклых функций (не квадратик).

Лессар, Recht, Packard, 2016: HB расходится для некоторых выпуклых функций!

Для $\kappa = 100$, $k = 100$:

- GD: $0.980^{100} \approx 0.135$
- HB: $0.818^{100} \approx 7 \times 10^{-9}$

Метод Нестерова (AGD)

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned}y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)\end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned}y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)\end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

Ключевое отличие от GD: шаг градиента делается из x_k (не из y_k !), а x_k — «ускоренная» точка с моментом.

AGD: алгоритм

Метод Нестерова (1983) — ускоренный градиентный спуск:

Для L -гладкой выпуклой f :

$$\begin{aligned} y_{k+1} &= x_k - \frac{1}{L} \nabla f(x_k) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k) \end{aligned}$$

$$\text{где } t_1 = 1, \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.$$

Ключевое отличие от GD: шаг градиента делается из x_k (не из y_k !), а x_k — «ускоренная» точка с моментом.

Два вектора: y_k — «приближение к минимуму», x_k — «точка шага».

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1$ $\boxtimes$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \boxtimes$$

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1$ $\boxtimes$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \quad \boxtimes$$

Следствие: $t_k^2 \geq \frac{(k+1)^2}{4}$.

Последовательность t_k

Рекуррентность $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$:

k	t_k	$\frac{k+1}{2}$
1	1.000	1.000
2	1.618	1.500
3	2.193	2.000
4	2.749	2.500
10	≈ 5.7	5.5

Ключевое неравенство: $t_k \geq \frac{k+1}{2}$.

Доказательство по индукции: - $t_1 = 1 \geq 1 \quad \square$ -

$$t_{k+1} \geq \frac{1 + \sqrt{(k+1)^2}}{2} = \frac{k+2}{2} \quad \square$$

Следствие: $t_k^2 \geq \frac{(k+1)^2}{4}$.

Другая запись: коэффициент момента $\frac{t_k - 1}{t_{k+1}} \rightarrow 1^-$ при $k \rightarrow \infty$.

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Лемма убывания ($\Phi_k \leq \Phi_{k-1}$): вытекает из L -гладкости (descent lemma) + рекуррентности t_k .

Начальное значение: $\Phi_0 = \frac{L}{2}\|x_0 - x^*\|^2$.

Сходимость AGD: $O(1/k^2)$

Теорема (Нестеров, 1983). Для L -гладкой выпуклой f :

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

Доказательство (идея): функция Ляпунова:

$$\Phi_k = t_k^2(f(y_k) - f^*) + \frac{L}{2}\|v_k\|^2, \quad v_k = t_k y_k - (t_k - 1)y_{k-1} - x^*$$

Лемма убывания ($\Phi_k \leq \Phi_{k-1}$): вытекает из L -гладкости (descent lemma) + рекуррентности t_k .

Начальное значение: $\Phi_0 = \frac{L}{2}\|x_0 - x^*\|^2$.

Из $t_k \geq (k+1)/2$:

$$f(y_k) - f^* \leq \frac{\Phi_0}{t_k^2} \leq \frac{L/2 \cdot \|x_0 - x^*\|^2}{(k+1)^2/4} = \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$$

□

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD в 20 раз быстрее ($\approx \sqrt{\kappa}$).

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

GD vs AGD: числовой пример

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + 100x_2^2), \mu = 1, L = 100, \kappa = 100.$$

Нужно $\|x_k - x^*\| \leq 10^{-4} \|x_0 - x^*\|$.

GD ($\alpha = 1/L$):

$$r = 1 - 1/\kappa = 0.99$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.99)} \approx 916$$

AGD (с.в. случай, $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$):

$$r = \frac{9}{11} \approx 0.818$$

$$r^k \leq 10^{-4} \Rightarrow k \geq \frac{4 \ln 10}{\ln(1/0.818)} \approx 46$$

AGD в 20 раз быстрее ($\approx \sqrt{\kappa}$).

Вывод: при $\kappa \gg 1$ ускорение огромно. При $\kappa = 2$: ускорение $\approx \sqrt{2}$ — незначительно.

FISTA: ускорение для негладких задач

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Скорость ISTA: $O(1/k)$ — как GD для гладкого случая.

Задача и ISTA

Составная задача:

$$\min_x \underbrace{f(x)}_{\text{гладкая}} + \underbrace{g(x)}_{\text{негладкая/проксимальная}}$$

ISTA (Iterative Shrinkage-Thresholding Algorithm):

$$x_{k+1} = \text{prox}_{hg}(x_k - h\nabla f(x_k)), \quad h = 1/L$$

Напоминание: проксимальный оператор — $\text{prox}_{hg}(u) = \arg \min_x \{g(x) + \frac{1}{2h}\|x - u\|^2\}$.

Скорость ISTA: $O(1/k)$ — как GD для гладкого случая.

Вопрос: можно ли применить ускорение Нестерова к ISTA? Да!

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned}y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)\end{aligned}$$

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

Скорость FISTA:

$$F(y_k) - F^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}, \quad F = f + g$$

FISTA: алгоритм

FISTA (Fast ISTA, Beck–Teboulle, 2009):

$$\begin{aligned} y_{k+1} &= \text{prox}_{hg}(x_k - h\nabla f(x_k)) \\ x_{k+1} &= y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k) \end{aligned}$$

Та же рекуррентность t_k , шаг $h = 1/L$.

Скорость FISTA:

$$F(y_k) - F^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}, \quad F = f + g$$

Отличие от ISTA: ISTA делает прокс-шаг из y_k (предыдущего приближения), FISTA — из x_k (ускоренной точки).

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$\nabla f(x) = A^\top (Ax - b)$, $L = \lambda_{\max}(A^\top A)$.

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$$\nabla f(x) = A^\top (Ax - b), \quad L = \lambda_{\max}(A^\top A).$$

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$$\nabla f(x) = A^\top (Ax - b), \quad L = \lambda_{\max}(A^\top A).$$

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso:

$$u_k = x_k - \frac{1}{L} A^\top (Ax_k - b), \quad y_{k+1} = \mathcal{S}_{\lambda/L}(u_k), \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

FISTA для Lasso

Lasso: $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$, где $f(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$.

$$\nabla f(x) = A^\top (Ax - b), \quad L = \lambda_{\max}(A^\top A).$$

Прокс-оператор для L_1 — мягкое пороговое (soft thresholding):

$$\text{prox}_{h\lambda\|\cdot\|_1}(u) = \mathcal{S}_{h\lambda}(u), \quad [\mathcal{S}_\tau(u)]_i = \text{sign}(u_i) \max(|u_i| - \tau, 0)$$

FISTA для Lasso:

$$u_k = x_k - \frac{1}{L} A^\top (Ax_k - b), \quad y_{k+1} = \mathcal{S}_{\lambda/L}(u_k), \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

Итоговая стоимость: одно умножение Ax + один мягкий порог за итерацию.

Ускорение в стохастическом случае

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L} g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}} (y_{k+1} - y_k)$$

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Суммируя: накапливается дисперсия $\sim k\sigma^2/L^2$.

Почему ускорение «ломается» при шуме?

Попытка: применить момент Нестерова к SGD.

$$y_{k+1} = x_k - \frac{1}{L}g_k, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k)$$

Проблема: функция Ляпунова Φ_k требует **монотонного убывания**. В детерминированном случае $\Delta\Phi_k \leq 0$ гарантируется descent lemma. При $g_k = \nabla f(x_k) + \xi_k$:

$$\Delta\Phi_k \leq -(\text{хороший член}) + O(t_k \cdot \|\xi_k\|)$$

Суммируя: накапливается дисперсия $\sim k\sigma^2/L^2$.

Итог:
$$\mathbb{E}[f(y_k) - f^*] \leq \frac{2L\|x_0\|^2}{k^2} + \frac{C\sigma^2 k}{L}$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Нижняя оценка (Agarwal et al., 2012): для стохастических алгоритмов первого порядка:

$$\mathbb{E}[f(x_k) - f^*] \geq \Omega\left(\frac{L\|x_0\|^2}{k^2} + \frac{\sigma\|x_0\|}{\sqrt{k}}\right)$$

Оптимальная стохастическая скорость

Два слагаемых:

$$\underbrace{\frac{2L\|x_0\|^2}{k^2}}_{\text{«детерминированный» член}} + \underbrace{\frac{C\sigma^2 k}{L}}_{\text{«шумовой» член}}$$

При малом k : доминирует первое (ускорение работает).

При большом k : доминирует второе (шум разрушает ускорение).

Нижняя оценка (Agarwal et al., 2012): для стохастических алгоритмов первого порядка:

$$\mathbb{E}[f(x_k) - f^*] \geq \Omega\left(\frac{L\|x_0\|^2}{k^2} + \frac{\sigma\|x_0\|}{\sqrt{k}}\right)$$

SGD достигает $O(1/\sqrt{k})$ — это **оптимально** в стохастическом случае!

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Эффективный шаг SGD с моментом:

$$\alpha_{\text{eff}} = \frac{\alpha}{1 - \beta} \xrightarrow{\beta \rightarrow 1} \infty$$

Шумовой пол пропорционален $\alpha_{\text{eff}} \cdot \sigma \sim \frac{\sigma}{1 - \beta}$.

При $\beta \rightarrow 1$: шумовой пол растёт как $O(1/(1 - \beta))$ — шум **усиливается**.

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Эффективный шаг SGD с моментом:

$$\alpha_{\text{eff}} = \frac{\alpha}{1 - \beta} \xrightarrow{\beta \rightarrow 1} \infty$$

Шумовой пол пропорционален $\alpha_{\text{eff}} \cdot \sigma \sim \frac{\sigma}{1 - \beta}$.

При $\beta \rightarrow 1$: шумовой пол растёт как $O(1/(1 - \beta))$ — шум **усиливается**.

Вывод: для SGD оптимален **убывающий шаг** $\alpha_k \sim 1/\sqrt{k}$ **без** тяжёлого момента.

Катастрофа момента в SGD

Что происходит, если добавить большой момент к SGD?

SGD+Momentum с $\beta \approx 1$:

$$m_{k+1} = \beta m_k + (1 - \beta)g_k, \quad x_{k+1} = x_k - \alpha m_{k+1}$$

Эффективный шаг SGD с моментом:

$$\alpha_{\text{eff}} = \frac{\alpha}{1 - \beta} \xrightarrow{\beta \rightarrow 1} \infty$$

Шумовой пол пропорционален $\alpha_{\text{eff}} \cdot \sigma \sim \frac{\sigma}{1 - \beta}$.

При $\beta \rightarrow 1$: шумовой пол растёт как $O(1/(1 - \beta))$ — шум **усиливается**.

Вывод: для SGD оптимален **убывающий шаг** $\alpha_k \sim 1/\sqrt{k}$ **без** тяжёлого момента.

Практика: $\beta = 0.9$ в CV (умеренный момент, сглаживает шум, не «ломает» сходимость). Adam — адаптивный момент, отдельная история.

Итог

Ключевые идеи лекции

1. Heavy Ball (Поляк, 1964): - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций

Ключевые идеи лекции

1. **Heavy Ball (Поляк, 1964)**: - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
2. **Нестеров AGD (1983)**: - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка

Ключевые идеи лекции

- 1. Heavy Ball (Поляк, 1964):** - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик:
 $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
- 2. Нестеров AGD (1983):** - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка
- 3. FISTA (Beck–Teboulle, 2009):** - AGD + проксимальный шаг вместо градиентного - $O(1/k^2)$ для составных задач $(f + g)$

Ключевые идеи лекции

- 1. Heavy Ball (Поляк, 1964):** - $x_{k+1} = x_k - \alpha \nabla f + \beta(x_k - x_{k-1})$ - Оптимальная скорость для квадратик: $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ - Не гарантирует ускорение для общих выпуклых функций
- 2. Нестеров AGD (1983):** - Два вектора y_k, x_k ; момент из t_k -последовательности - $O(1/k^2)$ для гладких выпуклых функций - **Оптимален** в классе первого порядка
- 3. FISTA (Beck–Teboulle, 2009):** - AGD + проксимальный шаг вместо градиентного - $O(1/k^2)$ для составных задач $(f + g)$
- 4. Стохастика:** - Момент Нестерова **не ускоряет** SGD при ненулевом шуме - SGD-оптимум: $O(1/\sqrt{k})$ при убывающем шаге

Ключевые формулы

Объект	Формула
Heavy Ball	$x_{k+1} = x_k - \alpha^* \nabla f(x_k) + \beta^* (x_k - x_{k-1})$
Оптимальные параметры НВ	$\alpha^* = 4/(\sqrt{L} + \sqrt{\mu})^2, \beta^* = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$
Скорость НВ (квадратика)	$\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$
AGD скорость (выпуклая)	$2L\ x_0 - x^*\ ^2/(k+1)^2$
AGD скорость (с.в.)	$e^{-k/\sqrt{\kappa}}$ с перезапуском
FISTA скорость	$2L\ x_0 - x^*\ ^2/k^2$
Нижняя оценка (выпуклая)	$3L\ x_0 - x^*\ ^2/[32(k+1)^2]$

Ключевые формулы

Объект	Формула
Heavy Ball	$x_{k+1} = x_k - \alpha^* \nabla f(x_k) + \beta^* (x_k - x_{k-1})$
Оптимальные параметры НВ	$\alpha^* = 4/(\sqrt{L} + \sqrt{\mu})^2, \beta^* = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$
Скорость НВ (квадратика)	$\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$
AGD скорость (выпуклая)	$2L\ x_0 - x^*\ ^2/(k+1)^2$
AGD скорость (с.в.)	$e^{-k/\sqrt{\kappa}}$ с перезапуском
FISTA скорость	$2L\ x_0 - x^*\ ^2/k^2$
Нижняя оценка (выпуклая)	$3L\ x_0 - x^*\ ^2/[32(k+1)^2]$

Связи с курсом: - Лб (двойственность): сопряжённые функции → прокс-оператор → FISTA - Л8
(градиентный спуск): верхние оценки → ускорение через момент - Л10 (метод сопряжённых градиентов):
другой подход к ускорению

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций НВ нужно для точности 10^{-6} ? Сравните с GD.

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций НВ нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций НВ нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Домашнее задание

Тест Лекции 9 (8 задач): `hse26.fmin.xyz`

Задача для размышления: рассмотрим квадратичную $f(x) = \frac{1}{2}x^\top Ax$ с $\kappa = 25$.

1. Вычислите оптимальные α^*, β^* для Heavy Ball.
2. Сколько итераций НВ нужно для точности 10^{-6} ? Сравните с GD.
3. Почему Heavy Ball с этими параметрами **не работает** для $f(x) = \max(x^2, (x-1)^2)$?

Следующая лекция: Метод сопряжённых градиентов.