




**Нижние оценки и ускоренные градиентные  
методы. Метод тяжёлого шарика.  
Ускоренный градиентный метод Нестерова**

**Даня Меркулов**

ФКН ВШЭ

## Краткий обзор основных результатов лекции

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:  $\min_{x \in \mathbb{R}^n} f(x)$   $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$   $\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$

| выпуклая (негладкая)                                                                                                             | гладкая (невыпуклая)                                                                                                                                         | гладкая & выпуклая                                                                                                      | гладкая & сильно выпуклая                                                                                                                                   |
|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ | $\ x_k - x^*\ ^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$<br>$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$ |

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:  $\min_{x \in \mathbb{R}^n} f(x)$   $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$   $\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$

| выпуклая (негладкая)                                                                                                             | гладкая (невыпуклая)                                                                                                                                         | гладкая & выпуклая                                                                                                      | гладкая & сильно выпуклая                                                                                                                                   |
|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ | $\ x_k - x^*\ ^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$<br>$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$ |

Для гладких сильно выпуклых функций имеем:

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

Заметим, что для любого  $x$ , вследствие того, что  $e^{-x}$  выпукла и  $1 - x$  - его касательная в точке  $x = 0$ , имеем:

$$1 - x \leq e^{-x}$$

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

$$\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$$

| выпуклая (негладкая)                                                                                                             | гладкая (невыпуклая)                                                                                                                                         | гладкая & выпуклая                                                                                                      | гладкая & сильно выпуклая                                                                                                                                   |
|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ | $\ x_k - x^*\ ^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$<br>$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$ |

Для гладких сильно выпуклых функций имеем:

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

Заметим, что для любого  $x$ , вследствие того, что  $e^{-x}$  выпукла и  $1 - x$  - его касательная в точке  $x = 0$ , имеем:

$$1 - x \leq e^{-x}$$

В конечном итоге имеем:

$$\varepsilon = f(x^{k_\varepsilon}) - f^* \leq \left(1 - \frac{\mu}{L}\right)^{k_\varepsilon} (f(x^0) - f^*)$$

$$\leq \exp\left(-k_\varepsilon \frac{\mu}{L}\right) (f(x^0) - f^*)$$

$$k_\varepsilon \geq \kappa \log \frac{f(x^0) - f^*}{\varepsilon} = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$$

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

$$\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$$

| выпуклая (негладкая)                                                                                                             | гладкая (невыпуклая)                                                                                                                                         | гладкая & выпуклая                                                                                                      | гладкая & сильно выпуклая                                                                                                                                   |
|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ | $\ x_k - x^*\ ^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$<br>$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$ |

Для гладких сильно выпуклых функций имеем:

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

Заметим, что для любого  $x$ , вследствие того, что  $e^{-x}$  выпукла и  $1 - x$  - его касательная в точке  $x = 0$ , имеем:

$$1 - x \leq e^{-x}$$

В конечном итоге имеем:

$$\varepsilon = f(x^{k_\varepsilon}) - f^* \leq \left(1 - \frac{\mu}{L}\right)^{k_\varepsilon} (f(x^0) - f^*)$$

$$\leq \exp\left(-k_\varepsilon \frac{\mu}{L}\right) (f(x^0) - f^*)$$

$$k_\varepsilon \geq \kappa \log \frac{f(x^0) - f^*}{\varepsilon} = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$$

**Question:** Можно ли быстрее, используя лишь информацию первого порядка (градиенты)?

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

$$\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$$

выпуклая (негладкая)

гладкая (невыпуклая)

гладкая & выпуклая

гладкая & сильно выпуклая

$$f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$

$$\min_{0 \leq i \leq k} \|\nabla f(x_i)\| = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$

$$f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$$

$$\|x_k - x^*\|^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$$

$$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

$$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

$$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

$$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$$

Для гладких сильно выпуклых функций имеем:

$$f(x^k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x^0) - f^*).$$

Заметим, что для любого  $x$ , вследствие того, что  $e^{-x}$  выпукла и  $1 - x$  - его касательная в точке  $x = 0$ , имеем:

$$1 - x \leq e^{-x}$$

В конечном итоге имеем:

$$\varepsilon = f(x^{k_\varepsilon}) - f^* \leq \left(1 - \frac{\mu}{L}\right)^{k_\varepsilon} (f(x^0) - f^*)$$

$$\leq \exp\left(-k_\varepsilon \frac{\mu}{L}\right) (f(x^0) - f^*)$$

$$k_\varepsilon \geq \kappa \log \frac{f(x^0) - f^*}{\varepsilon} = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$$

**Question:** Можно ли быстрее, используя лишь информацию первого порядка (градиенты)? **Да, можно.**

# Колебания и ускорение


$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$




# Колебания и ускорение

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Gradient Descent



Heavy Ball



## Нижние оценки для градиентных методов

# Нижние оценки для произвольных методов I порядка на классе гладких функций

Произвольный метод I порядка:  $\min_{x \in \mathbb{R}^n} f(x)$   $x_{k+1} = x_k - \sum_{i=0}^k \alpha_i \nabla f(x_i)$   $\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$

| выпуклая (негладкая)                                                                                                   | гладкая (невыпуклая) <sup>1</sup>                                                                                                                  | гладкая & выпуклая <sup>2</sup>                                                                                        | гладкая & сильно выпуклая                                                                                                                                                      |
|------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \Omega\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \Omega\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \Omega\left(\frac{1}{k^2}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\sqrt{\varepsilon}}\right)$ | $f(x_k) - f^* = \Omega\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^{2k}\right)$<br>$k_\varepsilon = \Omega\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$ |

<sup>1</sup>Carmon, Duchi, Hinder, Sidford, 2017

<sup>2</sup>Nemirovski, Yudin, 1979

# Чёрный ящик

Итерация градиентного спуска:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

# Чёрный ящик

Итерация градиентного спуска:

$$\begin{aligned}x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\ &= x_{k-1} - \alpha_{k-1} \nabla f(x_{k-1}) - \alpha_k \nabla f(x_k)\end{aligned}$$

# Чёрный ящик

Итерация градиентного спуска:

$$\begin{aligned}x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\ &= x_{k-1} - \alpha_{k-1} \nabla f(x_{k-1}) - \alpha_k \nabla f(x_k) \\ &\vdots\end{aligned}$$

# Чёрный ящик

Итерация градиентного спуска:

$$\begin{aligned}x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\&= x_{k-1} - \alpha_{k-1} \nabla f(x_{k-1}) - \alpha_k \nabla f(x_k) \\&\vdots \\&= x_0 - \sum_{i=0}^k \alpha_{k-i} \nabla f(x_{k-i})\end{aligned}$$

# Чёрный ящик

Итерация градиентного спуска:

$$\begin{aligned}x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\&= x_{k-1} - \alpha_{k-1} \nabla f(x_{k-1}) - \alpha_k \nabla f(x_k) \\&\vdots \\&= x_0 - \sum_{i=0}^k \alpha_{k-i} \nabla f(x_{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x_{k+1} &\in x_0 + \text{Lin} \{ \nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_k) \} & f &\text{— гладкая} \\x_{k+1} &\in x_0 + \text{Lin} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x_i) & f &\text{— негладкая}\end{aligned} \tag{1}$$



# Чёрный ящик

Итерация градиентного спуска:

$$\begin{aligned}x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\&= x_{k-1} - \alpha_{k-1} \nabla f(x_{k-1}) - \alpha_k \nabla f(x_k) \\&\vdots \\&= x_0 - \sum_{i=0}^k \alpha_{k-i} \nabla f(x_{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x_{k+1} &\in x_0 + \text{Lin} \{ \nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_k) \} & f &\text{— гладкая} \\x_{k+1} &\in x_0 + \text{Lin} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x_i) & f &\text{— негладкая}\end{aligned} \tag{1}$$

Чтобы построить нижнюю оценку, нам нужно найти функцию  $f$  из соответствующего класса, такую, что любой метод из семейства (1) будет работать не быстрее этой нижней оценки.

## Гладкий случай

### Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

## Гладкий случай

### i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .

## Гладкий случай

### i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключом к доказательству является явное построение специальной функции  $f$ .

## Гладкий случай

### i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключом к доказательству является явное построение специальной функции  $f$ .
- Обратите внимание, что эта граница  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не соответствует скорости градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Два возможных варианта:

# Гладкий случай

## i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключом к доказательству является явное построение специальной функции  $f$ .
- Обратите внимание, что эта граница  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не соответствует скорости градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Два возможных варианта:
  - a. Нижняя оценка не является точной.

# Гладкий случай

## i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключом к доказательству является явное построение специальной функции  $f$ .
- Обратите внимание, что эта граница  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не соответствует скорости градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Два возможных варианта:
  - a. Нижняя оценка не является точной.
  - b. Метод градиентного спуска не является оптимальным для этой задачи.

# Гладкий случай

## i Theorem

Существует  $L$ -гладкая и выпуклая функция  $f$ , такая, что любой метод (1) для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

- Какой бы метод из семейства методов первого порядка вы ни использовали, найдётся функция  $f$ , на которой скорость сходимости не лучше  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключом к доказательству является явное построение специальной функции  $f$ .
- Обратите внимание, что эта граница  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не соответствует скорости градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Два возможных варианта:
  - a. Нижняя оценка не является точной.
  - b. Метод градиентного спуска не является оптимальным для этой задачи.



## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка

$$x^T A x = 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &\leq 4(x_1^2 + x_2^2 + x_3^2) \end{aligned}$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &\leq 4(x_1^2 + x_2^2 + x_3^2) \\ 0 &\leq 2x_1^2 + 2x_2^2 + 2x_3^2 + 2x_1x_2 + 2x_2x_3 \end{aligned}$$



## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &\leq 4(x_1^2 + x_2^2 + x_3^2) \\ 0 &\leq 2x_1^2 + 2x_2^2 + 2x_3^2 + 2x_1x_2 + 2x_2x_3 \\ 0 &\leq x_1^2 + x_1^2 + 2x_1x_2 + x_2^2 + x_2^2 + 2x_2x_3 + x_3^2 + x_3^2 \end{aligned}$$

## Наихудшая функция Нестерова

- Пусть  $n = 2k + 1$  и  $A \in \mathbb{R}^{n \times n}$ .

$$A = \begin{bmatrix} 2 & -1 & 0 & 0 & \dots & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 \end{bmatrix}$$

- Обратите внимание, что

$$x^T A x = x_1^2 + x_n^2 + \sum_{i=1}^{n-1} (x_i - x_{i+1})^2,$$

Следовательно,  $x^T A x \geq 0$ . Также легко увидеть, что  $0 \preceq A \preceq 4I$ .

Пример, когда  $n = 3$ :

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Нижняя оценка:

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &= x_1^2 + x_1^2 - 2x_1x_2 + x_2^2 + x_2^2 - 2x_2x_3 + x_3^2 + x_3^2 \\ &= x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 \geq 0 \end{aligned}$$

Верхняя оценка

$$\begin{aligned} x^T A x &= 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 \\ &\leq 4(x_1^2 + x_2^2 + x_3^2) \\ 0 &\leq 2x_1^2 + 2x_2^2 + 2x_3^2 + 2x_1x_2 + 2x_2x_3 \\ 0 &\leq x_1^2 + x_1^2 + 2x_1x_2 + x_2^2 + x_2^2 + 2x_2x_3 + x_3^2 + x_3^2 \\ 0 &\leq x_1^2 + (x_1 + x_2)^2 + (x_2 + x_3)^2 + x_3^2 \end{aligned}$$

## Наихудшая функция Нестерова

- Определим следующую  $L$ -гладкую выпуклую функцию:  $f(x) = \frac{L}{4} \left( \frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$ .

## Наихудшая функция Нестерова

- Определим следующую  $L$ -гладкую выпуклую функцию:  $f(x) = \frac{L}{4} \left( \frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$ .
- Оптимальное решение  $x^*$  удовлетворяет  $Ax^* = e_1$ , и решение этой системы уравнений дает:

$$\begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} x_1^* \\ x_2^* \\ x_3^* \\ \vdots \\ x_n^* \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad \begin{cases} 2x_1^* - x_2^* = 1 \\ -x_{i-1}^* + 2x_i^* - x_{i+1}^* = 0, \quad i = 2, \dots, n-1 \\ -x_{n-1}^* + 2x_n^* = 0 \end{cases}$$

## Наихудшая функция Нестерова

- Определим следующую  $L$ -гладкую выпуклую функцию:  $f(x) = \frac{L}{4} \left( \frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$ .
- Оптимальное решение  $x^*$  удовлетворяет  $Ax^* = e_1$ , и решение этой системы уравнений дает:

$$\begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} x_1^* \\ x_2^* \\ x_3^* \\ \vdots \\ x_n^* \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad \begin{cases} 2x_1^* - x_2^* = 1 \\ -x_{i-1}^* + 2x_i^* - x_{i+1}^* = 0, \quad i = 2, \dots, n-1 \\ -x_{n-1}^* + 2x_n^* = 0 \end{cases}$$

- Гипотеза:  $x_i^* = a + bi$  (вдохновлённая физикой). Проверьте, что выполнено второе уравнение, в то время как  $a$  и  $b$  вычисляются из первого и последнего уравнений.

## Наихудшая функция Нестерова

- Определим следующую  $L$ -гладкую выпуклую функцию:  $f(x) = \frac{L}{4} \left( \frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$ .
- Оптимальное решение  $x^*$  удовлетворяет  $Ax^* = e_1$ , и решение этой системы уравнений дает:

$$\begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} x_1^* \\ x_2^* \\ x_3^* \\ \vdots \\ x_n^* \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad \begin{cases} 2x_1^* - x_2^* = 1 \\ -x_{i-1}^* + 2x_i^* - x_{i+1}^* = 0, \quad i = 2, \dots, n-1 \\ -x_{n-1}^* + 2x_n^* = 0 \end{cases}$$

- Гипотеза:  $x_i^* = a + bi$  (вдохновлённая физикой). Проверьте, что выполнено второе уравнение, в то время как  $a$  и  $b$  вычисляются из первого и последнего уравнений.
- Решение:

$$x_i^* = 1 - \frac{i}{n+1},$$

## Наихудшая функция Нестерова

- Определим следующую  $L$ -гладкую выпуклую функцию:  $f(x) = \frac{L}{4} \left( \frac{1}{2} x^T A x - e_1^T x \right) = \frac{L}{8} x^T A x - \frac{L}{4} e_1^T x$ .
- Оптимальное решение  $x^*$  удовлетворяет  $Ax^* = e_1$ , и решение этой системы уравнений дает:

$$\begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ 0 & 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} x_1^* \\ x_2^* \\ x_3^* \\ \vdots \\ x_n^* \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad \begin{cases} 2x_1^* - x_2^* = 1 \\ -x_{i-1}^* + 2x_i^* - x_{i+1}^* = 0, \quad i = 2, \dots, n-1 \\ -x_{n-1}^* + 2x_n^* = 0 \end{cases}$$

- Гипотеза:  $x_i^* = a + bi$  (вдохновлённая физикой). Проверьте, что выполнено второе уравнение, в то время как  $a$  и  $b$  вычисляются из первого и последнего уравнений.
- Решение:

$$x_i^* = 1 - \frac{i}{n+1},$$

- И значение функции равно

$$f(x^*) = \frac{L}{8} x^{*T} A x^* - \frac{L}{4} \langle x^*, e_1 \rangle = -\frac{L}{8} \langle x^*, e_1 \rangle = -\frac{L}{8} \left( 1 - \frac{1}{n+1} \right).$$

## Гладкий случай (доказательство)

- Предположим, что мы начинаем с  $x_0 = 0$ .

Запросив у оракула градиент, мы получаем

$g_0 = -\frac{L}{4}e_1$ . Тогда,  $x_1$  должен лежать на линии, генерируемой  $e_1$ . В этой точке все компоненты  $x_1$  равны нулю, кроме первой, поэтому

$$x_1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$



## Гладкий случай (доказательство)

- Предположим, что мы начинаем с  $x_0 = 0$ .

Запросив у оракула градиент, мы получаем

$g_0 = -\frac{L}{4}e_1$ . Тогда,  $x_1$  должен лежать на линии, генерируемой  $e_1$ . В этой точке все компоненты  $x_1$  равны нулю, кроме первой, поэтому

$$x_1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- На второй итерации оракул возвращает градиент  $g_1 = \frac{L}{4}(Ax_1 - e_1)$ . Тогда,  $x_2$  должен лежать на линии, генерируемой  $e_1$  и  $Ax_1 - e_1$ . Все компоненты  $x_2$  равны нулю, кроме первых двух, поэтому

$$\begin{bmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix} \Rightarrow x_2 = \begin{bmatrix} \bullet \\ \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

## Гладкий случай (доказательство)

- Предположим, что мы начинаем с  $x_0 = 0$ . Запросив у оракула градиент, мы получаем  $g_0 = -\frac{L}{4}e_1$ . Тогда,  $x_1$  должен лежать на линии, генерируемой  $e_1$ . В этой точке все компоненты  $x_1$  равны нулю, кроме первой, поэтому

$$x_1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- На второй итерации оракул возвращает градиент  $g_1 = \frac{L}{4}(Ax_1 - e_1)$ . Тогда,  $x_2$  должен лежать на линии, генерируемой  $e_1$  и  $Ax_1 - e_1$ . Все компоненты  $x_2$  равны нулю, кроме первых двух, поэтому

$$\begin{bmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix} \Rightarrow x_2 = \begin{bmatrix} \bullet \\ \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за структуры матрицы  $A$  можно показать, что после  $k$  итераций все последние  $n - k$  компоненты  $x_k$  равны нулю.

$$x_k = \begin{bmatrix} \bullet \\ \bullet \\ \vdots \\ \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix} \begin{matrix} 1 \\ 2 \\ \vdots \\ k \\ k+1 \\ \vdots \\ n \end{matrix}$$

## Гладкий случай (доказательство)

- Предположим, что мы начинаем с  $x_0 = 0$ . Запросив у оракула градиент, мы получаем  $g_0 = -\frac{L}{4}e_1$ . Тогда,  $x_1$  должен лежать на линии, генерируемой  $e_1$ . В этой точке все компоненты  $x_1$  равны нулю, кроме первой, поэтому

$$x_1 = \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- На второй итерации оракул возвращает градиент  $g_1 = \frac{L}{4}(Ax_1 - e_1)$ . Тогда,  $x_2$  должен лежать на линии, генерируемой  $e_1$  и  $Ax_1 - e_1$ . Все компоненты  $x_2$  равны нулю, кроме первых двух, поэтому

$$\begin{bmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 2 \end{bmatrix} \begin{bmatrix} \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix} \Rightarrow x_2 = \begin{bmatrix} \bullet \\ \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

- Из-за структуры матрицы  $A$  можно показать, что после  $k$  итераций все последние  $n - k$  компоненты  $x_k$  равны нулю.

$$x_k = \begin{bmatrix} \bullet \\ \bullet \\ \vdots \\ \bullet \\ 0 \\ \vdots \\ 0 \end{bmatrix} \begin{matrix} 1 \\ 2 \\ \vdots \\ k \\ k+1 \\ \vdots \\ n \end{matrix}$$

- Однако, поскольку каждая итерация  $x_k$ , произведенная нашим методом, лежит в  $S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  (т.е. имеет нули в координатах  $k+1, \dots, n$ ), она не может “достичь” полного оптимального вектора  $x^*$ . Другими словами, даже если бы мы выбрали лучший возможный вектор из  $S_k$ , обозначаемый

$$\tilde{x}_k = \arg \min_{x \in S_k} f(x),$$

значение функции в нём  $f(\tilde{x}_k)$  будет выше, чем  $f(x^*)$ .

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

- Аналогично, для оптимума исходной функции, мы имеем  $\tilde{x}_{k(i)} = 1 - \frac{i}{k+1}$  и  $f(\tilde{x}_k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$ .

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

- Аналогично, для оптимума исходной функции, мы имеем  $\tilde{x}_{k(i)} = 1 - \frac{i}{k+1}$  и  $f(\tilde{x}_k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$ .
- Теперь мы имеем:

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*)$$

(2)

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

- Аналогично, для оптимума исходной функции, мы имеем  $\tilde{x}_{k(i)} = 1 - \frac{i}{k+1}$  и  $f(\tilde{x}_k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$ .
- Теперь мы имеем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq f(\tilde{x}_k) - f(x^*) \\ &= -\frac{L}{8} \left(1 - \frac{1}{k+1}\right) - \left(-\frac{L}{8} \left(1 - \frac{1}{n+1}\right)\right) \end{aligned}$$

(2)



## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

- Аналогично, для оптимума исходной функции, мы имеем  $\tilde{x}_{k(i)} = 1 - \frac{i}{k+1}$  и  $f(\tilde{x}_k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$ .
- Теперь мы имеем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq f(\tilde{x}_k) - f(x^*) \\ &= -\frac{L}{8} \left(1 - \frac{1}{k+1}\right) - \left(-\frac{L}{8} \left(1 - \frac{1}{n+1}\right)\right) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1}\right) = \frac{L}{8} \left(\frac{n-k}{(k+1)(n+1)}\right) \end{aligned} \tag{2}$$

## Гладкий случай (доказательство)

- Поскольку  $x_k \in S_k = \text{Lin}\{e_1, e_2, \dots, e_k\}$  и  $\tilde{x}_k$  является лучшим возможным приближением к  $x^*$  в  $S_k$ , мы имеем

$$f(x_k) \geq f(\tilde{x}_k).$$

- Следовательно,

$$f(x_k) - f(x^*) \geq f(\tilde{x}_k) - f(x^*).$$

- Аналогично, для оптимума исходной функции, мы имеем  $\tilde{x}_{k(i)} = 1 - \frac{i}{k+1}$  и  $f(\tilde{x}_k) = -\frac{L}{8} \left(1 - \frac{1}{k+1}\right)$ .
- Теперь мы имеем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq f(\tilde{x}_k) - f(x^*) \\ &= -\frac{L}{8} \left(1 - \frac{1}{k+1}\right) - \left(-\frac{L}{8} \left(1 - \frac{1}{n+1}\right)\right) \\ &= \frac{L}{8} \left(\frac{1}{k+1} - \frac{1}{n+1}\right) = \frac{L}{8} \left(\frac{n-k}{(k+1)(n+1)}\right) \\ &\stackrel{n=2k+1}{=} \frac{L}{16(k+1)} \end{aligned} \tag{2}$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\|x_0 - x^*\|_2^2 = \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\ &= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2\end{aligned}$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\ &= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2 \\ &\leq n - \frac{2}{n+1} \cdot \frac{n(n+1)}{2} + \frac{1}{(n+1)^2} \cdot \frac{(n+1)^3}{3}\end{aligned}$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\&= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2 \\&\leq n - \frac{2}{n+1} \cdot \frac{n(n+1)}{2} + \frac{1}{(n+1)^2} \cdot \frac{(n+1)^3}{3} \\&= \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3}.\end{aligned}$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\&= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2 \\&\leq n - \frac{2}{n+1} \cdot \frac{n(n+1)}{2} + \frac{1}{(n+1)^2} \cdot \frac{(n+1)^3}{3} \\&= \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3}.\end{aligned}$$

- Следовательно,

$$k+1 \geq \frac{3}{2} \|x_0 - x^*\|_2^2 = \frac{3}{2} R^2 \quad (3)$$

## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\&= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2 \\&\leq n - \frac{2}{n+1} \cdot \frac{n(n+1)}{2} + \frac{1}{(n+1)^2} \cdot \frac{(n+1)^3}{3} \\&= \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3}.\end{aligned}$$

- Следовательно,

$$k+1 \geq \frac{3}{2} \|x_0 - x^*\|_2^2 = \frac{3}{2} R^2 \quad (3)$$



## Гладкий случай (доказательство)

- Теперь мы ограничиваем  $R = \|x_0 - x^*\|_2$ :

$$\begin{aligned}\|x_0 - x^*\|_2^2 &= \|0 - x^*\|_2^2 = \|x^*\|_2^2 = \sum_{i=1}^n \left(1 - \frac{i}{n+1}\right)^2 \\&= n - \frac{2}{n+1} \sum_{i=1}^n i + \frac{1}{(n+1)^2} \sum_{i=1}^n i^2 \\&\leq n - \frac{2}{n+1} \cdot \frac{n(n+1)}{2} + \frac{1}{(n+1)^2} \cdot \frac{(n+1)^3}{3} \\&= \frac{n+1}{3} \stackrel{n=2k+1}{=} \frac{2(k+1)}{3}.\end{aligned}$$

- Следовательно,

$$k+1 \geq \frac{3}{2} \|x_0 - x^*\|_2^2 = \frac{3}{2} R^2 \quad (3)$$

Заметим, что

$$\begin{aligned}\sum_{i=1}^n i &= \frac{n(n+1)}{2} \\ \sum_{i=1}^n i^2 &= \frac{n(n+1)(2n+1)}{6} \\ &\leq \frac{(n+1)^3}{3}\end{aligned}$$

## Гладкий случай (доказательство)

Наконец, используя (2) и (3), мы получаем:

$$f(x_k) - f(x^*) \geq \frac{L}{16(k+1)} = \frac{L(k+1)}{16(k+1)^2}$$

## Гладкий случай (доказательство)

Наконец, используя (2) и (3), мы получаем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq \frac{L}{16(k+1)} = \frac{L(k+1)}{16(k+1)^2} \\ &\geq \frac{L}{16(k+1)^2} \frac{3}{2} R^2 \end{aligned}$$

## Гладкий случай (доказательство)

Наконец, используя (2) и (3), мы получаем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq \frac{L}{16(k+1)} = \frac{L(k+1)}{16(k+1)^2} \\ &\geq \frac{L}{16(k+1)^2} \frac{3}{2} R^2 \\ &= \frac{3LR^2}{32(k+1)^2} \end{aligned}$$

## Гладкий случай (доказательство)

Наконец, используя (2) и (3), мы получаем:

$$\begin{aligned} f(x_k) - f(x^*) &\geq \frac{L}{16(k+1)} = \frac{L(k+1)}{16(k+1)^2} \\ &\geq \frac{L}{16(k+1)^2} \frac{3}{2} R^2 \\ &= \frac{3LR^2}{32(k+1)^2} \end{aligned}$$

Это завершает доказательство с желаемой скоростью  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .

## Нижние оценки для гладкого случая

### i Гладкий выпуклый случай

Существует  $L$ -гладкая выпуклая функция  $f$ , такая, что любой метод в форме 1 для всех  $k$ ,  $1 \leq k \leq \frac{n-1}{2}$ , удовлетворяет:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$$

### i Гладкий сильно выпуклый случай

Для любого  $x_0$  и любого  $\mu > 0$ ,  $\kappa = \frac{L}{\mu} > 1$ , существует  $L$ -гладкая и  $\mu$ -сильно выпуклая функция  $f$ , такая, что для любого метода в форме 1 выполняются неравенства:

$$\begin{aligned}\|x_k - x^*\|_2 &\geq \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x_0 - x^*\|_2 \\ f(x_k) - f^* &\geq \frac{\mu}{2} \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2k} \|x_0 - x^*\|_2^2\end{aligned}$$

# Ускорение для квадратичных функций

## Результат сходимости для квадратичных функций

Предположим, что мы решаем задачу минимизации сильно выпуклой квадратичной функции, с помощью метода градиентного спуска:

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$



## Результат сходимости для квадратичных функций

Предположим, что мы решаем задачу минимизации сильно выпуклой квадратичной функции, с помощью метода градиентного спуска:

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

### i Theorem


Градиентный спуск с шагом  $\alpha_k = \frac{2}{\mu+L}$  сходится к оптимальному решению  $x^*$  со следующей гарантией:

$$\|x_{k+1} - x^*\|_2 \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^k \|x_0 - x^*\|_2 \quad f(x_{k+1}) - f(x^*) \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^{2k} (f(x_0) - f(x^*))$$


где  $\varkappa = \frac{L}{\mu}$  является числом обусловленности  $A$ .

# Число обусловленности $\kappa$

$\kappa = 1.0$



$\kappa = 100.0$



## Ускорение из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть  $x^*$  будет единственным решением системы линейных уравнений  $Ax = b$  и пусть  $e_k = x_k - x^*$ , где  $x_{k+1} = x_k - \alpha_k(Ax_k - b)$  определяется рекурсивно, начиная с некоторого  $x_0$ , а  $\alpha_k$  — шаг, который мы определим позже.

$$e_{k+1} = (I - \alpha_k A)e_k.$$

## Ускорение из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть  $x^*$  будет единственным решением системы линейных уравнений  $Ax = b$  и пусть  $e_k = x_k - x^*$ , где  $x_{k+1} = x_k - \alpha_k (Ax_k - b)$  определяется рекурсивно, начиная с некоторого  $x_0$ , а  $\alpha_k$  — шаг, который мы определим позже.

$$e_{k+1} = (I - \alpha_k A)e_k.$$

## Полиномы

Вышеуказанный расчет дает нам  $e_k = p_k(A)e_0$ ,  
где  $p_k$  является полиномом

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

## Ускорение из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть  $x^*$  будет единственным решением системы линейных уравнений  $Ax = b$  и пусть  $e_k = x_k - x^*$ , где  $x_{k+1} = x_k - \alpha_k (Ax_k - b)$  определяется рекурсивно, начиная с некоторого  $x_0$ , а  $\alpha_k$  — шаг, который мы определим позже.

$$e_{k+1} = (I - \alpha_k A)e_k.$$

## Полиномы

Вышеуказанный расчет дает нам  $e_k = p_k(A)e_0$ ,  
где  $p_k$  является полиномом

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

Мы можем ограничить норму ошибки как

$$\|e_k\| \leq \|p_k(A)\| \cdot \|e_0\|.$$

## Ускорение из первых принципов

$$f(x) = \frac{1}{2}x^T Ax - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Пусть  $x^*$  будет единственным решением системы линейных уравнений  $Ax = b$  и пусть  $e_k = x_k - x^*$ , где  $x_{k+1} = x_k - \alpha_k (Ax_k - b)$  определяется рекурсивно, начиная с некоторого  $x_0$ , а  $\alpha_k$  — шаг, который мы определим позже.

$$e_{k+1} = (I - \alpha_k A)e_k.$$

## Полиномы

Вышеуказанный расчет дает нам  $e_k = p_k(A)e_0$ , где  $p_k$  является полиномом

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

Мы можем ограничить норму ошибки как

$$\|e_k\| \leq \|p_k(A)\| \cdot \|e_0\|.$$

Поскольку  $A$  является симметричной матрицей с собственными значениями в  $[\mu, L]$ :

$$\|p_k(A)\| \leq \max_{\mu \leq a \leq L} |p_k(a)|.$$

Это приводит к интересной постановке задачи: среди всех полиномов, удовлетворяющих  $p_k(0) = 1$ , мы ищем полином, значение которого как можно меньше отклоняется от нуля на интервале  $[\mu, L]$ .

## Наивное полиномиальное решение


Наивное решение состоит в том, чтобы выбрать равномерный шаг  $\alpha_k = \frac{2}{\mu+L}$ . Благодаря этому  $|p_k(\mu)| = |p_k(L)|$ .

$$\|e_k\| \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^k \|e_0\|$$

Это точно та же скорость, которую мы доказали в предыдущей лекции для любой гладкой и сильно выпуклой функции.

Давайте посмотрим на этот полином поближе. На правом рисунке мы выбираем  $\mu = 1$  и  $L = 10$  так, что  $\varkappa = 10$ . Следовательно, соответствующий интервал равен  $[1, 10]$ .

Можем ли мы сделать лучше? Ответ — да.



## Наивное полиномиальное решение


Наивное решение состоит в том, чтобы выбрать равномерный шаг  $\alpha_k = \frac{2}{\mu+L}$ . Благодаря этому  $|p_k(\mu)| = |p_k(L)|$ .

$$\|e_k\| \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^k \|e_0\|$$

Это точно та же скорость, которую мы доказали в предыдущей лекции для любой гладкой и сильно выпуклой функции.

Давайте посмотрим на этот полином поближе. На правом рисунке мы выбираем  $\mu = 1$  и  $L = 10$  так, что  $\varkappa = 10$ . Следовательно, соответствующий интервал равен  $[1, 10]$ .

Можем ли мы сделать лучше? Ответ — да.





## Наивное полиномиальное решение


Наивное решение состоит в том, чтобы выбрать равномерный шаг  $\alpha_k = \frac{2}{\mu+L}$ . Благодаря этому  $|p_k(\mu)| = |p_k(L)|$ .

$$\|e_k\| \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^k \|e_0\|$$

Это точно та же скорость, которую мы доказали в предыдущей лекции для любой гладкой и сильно выпуклой функции.

Давайте посмотрим на этот полином поближе. На правом рисунке мы выбираем  $\mu = 1$  и  $L = 10$  так, что  $\varkappa = 10$ . Следовательно, соответствующий интервал равен  $[1, 10]$ .

Можем ли мы сделать лучше? Ответ — да.



## Наивное полиномиальное решение


Наивное решение состоит в том, чтобы выбрать равномерный шаг  $\alpha_k = \frac{2}{\mu+L}$ . Благодаря этому  $|p_k(\mu)| = |p_k(L)|$ .

$$\|e_k\| \leq \left(\frac{\varkappa - 1}{\varkappa + 1}\right)^k \|e_0\|$$

Это точно та же скорость, которую мы доказали в предыдущей лекции для любой гладкой и сильно выпуклой функции.

Давайте посмотрим на этот полином поближе. На правом рисунке мы выбираем  $\mu = 1$  и  $L = 10$  так, что  $\varkappa = 10$ . Следовательно, соответствующий интервал равен  $[1, 10]$ .

Можем ли мы сделать лучше? Ответ — да.



## Наивное полиномиальное решение


Наивное решение состоит в том, чтобы выбрать равномерный шаг  $\alpha_k = \frac{2}{\mu+L}$ . Благодаря этому  $|p_k(\mu)| = |p_k(L)|$ .

$$\|e_k\| \leq \left( \frac{\varkappa - 1}{\varkappa + 1} \right)^k \|e_0\|$$

Это точно та же скорость, которую мы доказали в предыдущей лекции для любой гладкой и сильно выпуклой функции.

Давайте посмотрим на этот полином поближе. На правом рисунке мы выбираем  $\mu = 1$  и  $L = 10$  так, что  $\varkappa = 10$ . Следовательно, соответствующий интервал равен  $[1, 10]$ .

Можем ли мы сделать лучше? Ответ — да.



## Полиномы Чебышева


Полиномы Чебышёва дают оптимальный ответ на поставленный вопрос. При соответствующем шкалировании они минимизируют абсолютное значение на заданном интервале  $[\mu, L]$ , одновременно удовлетворяя нормировочному условию  $p(0) = 1$ .

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Давайте построим стандартные полиномы Чебышёва (без масштабирования):



## Полиномы Чебышева


Полиномы Чебышёва дают оптимальный ответ на поставленный вопрос. При соответствующем шкалировании они минимизируют абсолютное значение на заданном интервале  $[\mu, L]$ , одновременно удовлетворяя нормировочному условию  $p(0) = 1$ .

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Давайте построим стандартные полиномы Чебышёва (без масштабирования):



## Полиномы Чебышева


Полиномы Чебышёва дают оптимальный ответ на поставленный вопрос. При соответствующем шкалировании они минимизируют абсолютное значение на заданном интервале  $[\mu, L]$ , одновременно удовлетворяя нормировочному условию  $p(0) = 1$ .

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Давайте построим стандартные полиномы Чебышёва (без масштабирования):



## Полиномы Чебышева


Полиномы Чебышёва дают оптимальный ответ на поставленный вопрос. При соответствующем шкалировании они минимизируют абсолютное значение на заданном интервале  $[\mu, L]$ , одновременно удовлетворяя нормировочному условию  $p(0) = 1$ .

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Давайте построим стандартные полиномы Чебышёва (без масштабирования):



## Полиномы Чебышева


Полиномы Чебышёва дают оптимальный ответ на поставленный вопрос. При соответствующем шкалировании они минимизируют абсолютное значение на заданном интервале  $[\mu, L]$ , одновременно удовлетворяя нормировочному условию  $p(0) = 1$ .

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Давайте построим стандартные полиномы Чебышёва (без масштабирования):





## Отшкалированные полиномы Чебышёва

Оригинальные полиномы Чебышёва определены на интервале  $[-1, 1]$ . Чтобы использовать их для наших целей, мы должны отшкалировать их на интервал  $[\mu, L]$ .

## Отшкалированные полиномы Чебышёва

Оригинальные полиномы Чебышёва определены на интервале  $[-1, 1]$ . Чтобы использовать их для наших целей, мы должны отшкалировать их на интервал  $[\mu, L]$ .

Мы будем использовать следующее аффинное преобразование:

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$

Обратите внимание, что  $x = 1$  соответствует  $a = \mu$ ,  $x = -1$  соответствует  $a = L$  и  $x = 0$  соответствует  $a = \frac{\mu+L}{2}$ . Это преобразование гарантирует, что поведение полинома Чебышёва на интервале  $[-1, 1]$  транслируется на интервал  $[\mu, L]$ .

## Отшкалированные полиномы Чебышёва

Оригинальные полиномы Чебышёва определены на интервале  $[-1, 1]$ . Чтобы использовать их для наших целей, мы должны отшкалировать их на интервал  $[\mu, L]$ .

Мы будем использовать следующее аффинное преобразование:

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$

Обратите внимание, что  $x = 1$  соответствует  $a = \mu$ ,  $x = -1$  соответствует  $a = L$  и  $x = 0$  соответствует  $a = \frac{\mu+L}{2}$ . Это преобразование гарантирует, что поведение полинома Чебышёва на интервале  $[-1, 1]$  транслируется на интервал  $[\mu, L]$ .

В нашем анализе ошибок мы требуем, чтобы полином был равен 1 в 0 (т.е.  $p_k(0) = 1$ ). После применения преобразования значение  $T_k$  в точке, соответствующей  $a = 0$ , может не быть 1. Следовательно, мы умножаем на обратную величину  $T_k$  в точке

$$\frac{L + \mu}{L - \mu}, \quad \text{что обеспечивает} \quad P_k(0) = T_k\left(\frac{L + \mu - 0}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = 1.$$

## Отшкалированные полиномы Чебышёва

Оригинальные полиномы Чебышёва определены на интервале  $[-1, 1]$ . Чтобы использовать их для наших целей, мы должны отшкалировать их на интервал  $[\mu, L]$ .

Мы будем использовать следующее аффинное преобразование:

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$

Обратите внимание, что  $x = 1$  соответствует  $a = \mu$ ,  $x = -1$  соответствует  $a = L$  и  $x = 0$  соответствует  $a = \frac{\mu+L}{2}$ . Это преобразование гарантирует, что поведение полинома Чебышёва на интервале  $[-1, 1]$  транслируется на интервал  $[\mu, L]$ .

В нашем анализе ошибок мы требуем, чтобы полином был равен 1 в 0 (т.е.  $p_k(0) = 1$ ). После применения преобразования значение  $T_k$  в точке, соответствующей  $a = 0$ , может не быть 1. Следовательно, мы умножаем на обратную величину  $T_k$  в точке

$$\frac{L + \mu}{L - \mu}, \quad \text{что обеспечивает} \quad P_k(0) = T_k\left(\frac{L + \mu - 0}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = 1.$$


Построим отшкалированные полиномы Чебышёва

$$P_k(a) = T_k\left(\frac{L + \mu - 2a}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

и увидим, что они больше подходят для нашей задачи, чем наивные полиномы на интервале  $[\mu, L]$ .


# Отшкалированные полиномы Чебышёва

Полиномы степени 1




# Отшкалированные полиномы Чебышёва

Полиномы степени 2




# Отшкалированные полиномы Чебышёва

Полиномы степени 3



# Отшкалированные полиномы Чебышёва


Полиномы степени 4






# Отшкалированные полиномы Чебышёва

Полиномы степени 5




# Отшкалированные полиномы Чебышёва

Полиномы степени 6




# Отшкалированные полиномы Чебышёва

Полиномы степени 7




# Отшкалированные полиномы Чебышёва

Полиномы степени 8




# Отшкалированные полиномы Чебышёва

Полиномы степени 9



# Отшкалированные полиномы Чебышёва

Полиномы степени 10



## Верхняя оценка для полиномов Чебышёва

Мы можем видеть, что максимальное значение полинома Чебышёва на интервале  $[\mu, L]$  достигается на концах отрезка в точках  $a = \mu$  и  $a = L$ . Следовательно, мы можем использовать следующую верхнюю оценку:

$$\|P_k(A)\|_2 \leq P_k(\mu) = T_k\left(\frac{L + \mu - 2\mu}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k(1) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

## Верхняя оценка для полиномов Чебышёва

Мы можем видеть, что максимальное значение полинома Чебышёва на интервале  $[\mu, L]$  достигается на концах отрезка в точках  $a = \mu$  и  $a = L$ . Следовательно, мы можем использовать следующую верхнюю оценку:

$$\|P_k(A)\|_2 \leq P_k(\mu) = T_k\left(\frac{L + \mu - 2\mu}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k(1) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

Используя определение числа обусловленности  $\kappa = \frac{L}{\mu}$ , мы получаем:

$$\|P_k(A)\|_2 \leq T_k\left(\frac{\kappa + 1}{\kappa - 1}\right)^{-1} = T_k\left(1 + \frac{2}{\kappa - 1}\right)^{-1} = T_k(1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\kappa - 1}.$$



## Верхняя оценка для полиномов Чебышёва

Мы можем видеть, что максимальное значение полинома Чебышёва на интервале  $[\mu, L]$  достигается на концах отрезка в точках  $a = \mu$  и  $a = L$ . Следовательно, мы можем использовать следующую верхнюю оценку:

$$\|P_k(A)\|_2 \leq P_k(\mu) = T_k\left(\frac{L + \mu - 2\mu}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k(1) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

Используя определение числа обусловленности  $\kappa = \frac{L}{\mu}$ , мы получаем:

$$\|P_k(A)\|_2 \leq T_k\left(\frac{\kappa + 1}{\kappa - 1}\right)^{-1} = T_k\left(1 + \frac{2}{\kappa - 1}\right)^{-1} = T_k(1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\kappa - 1}.$$

Именно в этот момент явно возникнет ускорение. Мы ограничим значение  $\|P_k(A)\|_2$  сверху величиной  $\left(\frac{1}{1 + \sqrt{\epsilon}}\right)^k$ . Для этого детально изучим величину  $|T_k(1 + \epsilon)|$ .

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

1. Для любого  $x \geq 1$ , полиномы Чебышёва первого рода могут быть записаны как

$$\begin{aligned}T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)).\end{aligned}$$

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

1. Для любого  $x \geq 1$ , полиномы Чебышёва первого рода могут быть записаны как

$$\begin{aligned}T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)).\end{aligned}$$

2. Помните, что:

$$\cosh(x) = \frac{e^x + e^{-x}}{2} \quad \operatorname{arccosh}(x) = \ln(x + \sqrt{x^2 - 1}).$$

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

1. Для любого  $x \geq 1$ , полиномы Чебышёва первого рода могут быть записаны как

$$\begin{aligned}T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)).\end{aligned}$$

2. Помните, что:

$$\cosh(x) = \frac{e^x + e^{-x}}{2} \quad \operatorname{arccosh}(x) = \ln(x + \sqrt{x^2 - 1}).$$

3. Теперь, пусть  $\phi = \operatorname{arccosh}(1 + \epsilon)$ ,

$$e^\phi = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}.$$

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

1. Для любого  $x \geq 1$ , полиномы Чебышёва первого рода могут быть записаны как
4. Следовательно,

$$\begin{aligned}T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)).\end{aligned}$$

2. Помните, что:

$$\cosh(x) = \frac{e^x + e^{-x}}{2} \quad \operatorname{arccosh}(x) = \ln(x + \sqrt{x^2 - 1}).$$

3. Теперь, пусть  $\phi = \operatorname{arccosh}(1 + \epsilon)$ ,

$$e^\phi = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}.$$

$$\begin{aligned}T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)) \\&= \cosh(k\phi) \\&= \frac{e^{k\phi} + e^{-k\phi}}{2} \geq \frac{e^{k\phi}}{2} \\&= \frac{(1 + \sqrt{\epsilon})^k}{2}.\end{aligned}$$

## Верхняя оценка для полиномов Чебышёва

Чтобы ограничить  $|P_k|$  сверху, мы должны ограничить  $|T_k(1 + \epsilon)|$  снизу.

1. Для любого  $x \geq 1$ , полиномы Чебышёва первого рода могут быть записаны как
4. Следовательно,

$$\begin{aligned}T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)).\end{aligned}$$

2. Помните, что:

$$\cosh(x) = \frac{e^x + e^{-x}}{2} \quad \operatorname{arccosh}(x) = \ln(x + \sqrt{x^2 - 1}).$$

3. Теперь, пусть  $\phi = \operatorname{arccosh}(1 + \epsilon)$ ,

$$e^\phi = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}.$$

$$\begin{aligned}T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)) \\&= \cosh(k\phi) \\&= \frac{e^{k\phi} + e^{-k\phi}}{2} \geq \frac{e^{k\phi}}{2} \\&= \frac{(1 + \sqrt{\epsilon})^k}{2}.\end{aligned}$$

5. Наконец, мы получаем:

$$\begin{aligned}\|e_k\| &\leq \|P_k(A)\| \|e_0\| \leq \frac{2}{(1 + \sqrt{\epsilon})^k} \|e_0\| \\&\leq 2 \left(1 + \sqrt{\frac{2}{n-1}}\right)^{-k} \|e_0\| \\&\leq 2 \exp\left(-\sqrt{\frac{2}{n-1}} k\right) \|e_0\|\end{aligned}$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$



## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

$$T_k\left(\frac{L+\mu-2a}{L-\mu}\right) = P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right)$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

$$T_k\left(\frac{L+\mu-2a}{L-\mu}\right) = P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k-1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k-1}(a) T_{k-1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k+1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k+1}(a) T_{k+1}\left(\frac{L+\mu}{L-\mu}\right)$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

$$T_k\left(\frac{L+\mu-2a}{L-\mu}\right) = P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k-1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k-1}(a) T_{k-1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k+1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k+1}(a) T_{k+1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$P_{k+1}(a)t_{k+1} = 2\frac{L+\mu-2a}{L-\mu}P_k(a)t_k - P_{k-1}(a)t_{k-1}, \text{ где } t_k = T_k\left(\frac{L+\mu}{L-\mu}\right)$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

$$T_k\left(\frac{L+\mu-2a}{L-\mu}\right) = P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k-1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k-1}(a) T_{k-1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k+1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k+1}(a) T_{k+1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$P_{k+1}(a)t_{k+1} = 2\frac{L+\mu-2a}{L-\mu}P_k(a)t_k - P_{k-1}(a)t_{k-1}, \text{ где } t_k = T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$P_{k+1}(a) = 2\frac{L+\mu-2a}{L-\mu}P_k(a)\frac{t_k}{t_{k+1}} - P_{k-1}(a)\frac{t_{k-1}}{t_{k+1}}$$

## Ускоренный метод [1/2]

Из-за рекурсивного определения полиномов Чебышёва мы непосредственно получаем итерационную схему ускоренного алгоритма. Переформулируя рекурсию в терминах наших отшкалированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Принимая во внимание, что  $x = \frac{L+\mu-2a}{L-\mu}$ , и:

$$P_k(a) = T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1}$$

$$T_k\left(\frac{L+\mu-2a}{L-\mu}\right) = P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k-1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k-1}(a) T_{k-1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$T_{k+1}\left(\frac{L+\mu-2a}{L-\mu}\right) = P_{k+1}(a) T_{k+1}\left(\frac{L+\mu}{L-\mu}\right)$$

$$P_{k+1}(a) t_{k+1} = 2 \frac{L+\mu-2a}{L-\mu} P_k(a) t_k - P_{k-1}(a) t_{k-1}, \text{ где } t_k = T_k\left(\frac{L+\mu}{L-\mu}\right)$$

$$P_{k+1}(a) = 2 \frac{L+\mu-2a}{L-\mu} P_k(a) \frac{t_k}{t_{k+1}} - P_{k-1}(a) \frac{t_{k-1}}{t_{k+1}}$$

Поскольку мы имеем  $P_{k+1}(0) = P_k(0) = P_{k-1}(0) = 1$ , получаем рекуррентную формулу вида:

$$P_{k+1}(a) = (1 - \alpha_k a) P_k(a) + \beta_k (P_k(a) - P_{k-1}(a)).$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$
$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$



## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$\begin{aligned}P_{k+1}(a) &= (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a), \\P_{k+1}(a) &= 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)\end{aligned}$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

Мы почти закончили :) Помним, что  $e_{k+1} = P_{k+1}(A)e_0$ . Также обратим внимание, что мы работаем с квадратичной задачей, поэтому мы можем предположить  $x^* = 0$  без ограничения общности. В этом случае  $e_0 = x_0$  и  $e_{k+1} = x_{k+1}$ .

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

Мы почти закончили :) Помним, что  $e_{k+1} = P_{k+1}(A)e_0$ . Также обратим внимание, что мы работаем с квадратичной задачей, поэтому мы можем предположить  $x^* = 0$  без ограничения общности. В этом случае  $e_0 = x_0$  и  $e_{k+1} = x_{k+1}$ .

$$x_{k+1} = P_{k+1}(A)x_0$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

Мы почти закончили :) Помним, что  $e_{k+1} = P_{k+1}(A)e_0$ . Также обратим внимание, что мы работаем с квадратичной задачей, поэтому мы можем предположить  $x^* = 0$  без ограничения общности. В этом случае  $e_0 = x_0$  и  $e_{k+1} = x_{k+1}$ .

$$x_{k+1} = P_{k+1}(A)x_0 = (I - \alpha_k A)P_k(A)x_0 + \beta_k (P_k(A) - P_{k-1}(A))x_0$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

Мы почти закончили :) Помним, что  $e_{k+1} = P_{k+1}(A)e_0$ . Также обратим внимание, что мы работаем с квадратичной задачей, поэтому мы можем предположить  $x^* = 0$  без ограничения общности. В этом случае  $e_0 = x_0$  и  $e_{k+1} = x_{k+1}$ .

$$\begin{aligned} x_{k+1} &= P_{k+1}(A)x_0 = (I - \alpha_k A)P_k(A)x_0 + \beta_k (P_k(A) - P_{k-1}(A))x_0 \\ &= (I - \alpha_k A)x_k + \beta_k (x_k - x_{k-1}) \end{aligned}$$

## Ускоренный метод [2/2]

Перегруппируя члены, мы получаем:

$$P_{k+1}(a) = (1 + \beta_k)P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a),$$

$$P_{k+1}(a) = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L - \mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a)$$

$$\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L - \mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L + \mu}{L - \mu} \frac{t_k}{t_{k+1}} \end{cases}$$

Мы почти закончили :) Помним, что  $e_{k+1} = P_{k+1}(A)e_0$ . Также обратим внимание, что мы работаем с квадратичной задачей, поэтому мы можем предположить  $x^* = 0$  без ограничения общности. В этом случае  $e_0 = x_0$  и  $e_{k+1} = x_{k+1}$ .


$$\begin{aligned} x_{k+1} &= P_{k+1}(A)x_0 = (I - \alpha_k A)P_k(A)x_0 + \beta_k (P_k(A) - P_{k-1}(A))x_0 \\ &= (I - \alpha_k A)x_k + \beta_k (x_k - x_{k-1}) \end{aligned}$$

Для квадратичной задачи мы имеем  $\nabla f(x_k) = Ax_k$ , поэтому мы можем переписать обновление как:


$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

# Ускорение из первых принципов

$\kappa = 1.0$



$\kappa = 100.0$





## Метод тяжёлого шарика



# Метод тяжёлого шарика Поляка

Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$





# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :



# Метод тяжёлого шарика Поляка





Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

# Метод тяжёлого шарика Поляка





Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \end{aligned}$$

# Метод тяжёлого шарика Поляка





Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}), \text{ а так же отметим, что } x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}):$$

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}), \text{ а так же отметим, что } x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}):$$

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$



Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}), \text{ а так же отметим, что } x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}):$$

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2}) + \dots + \beta^k \nabla f(x_0)] \end{aligned}$$



# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2}) + \dots + \beta^k \nabla f(x_0)] \end{aligned}$$

Таким образом, метод тяжёлого шарика учитывает все предыдущие градиенты с тем меньшим весом, чем старше итерация ( $0 \leq \beta < 1$ ).

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta (x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

Давайте введем следующее обозначение:  $\hat{z}_k = \begin{bmatrix} \hat{x}_{k+1} \\ \hat{x}_k \end{bmatrix}$ . Следовательно,  $\hat{z}_{k+1} = M \hat{z}_k$ , где матрица итерации  $M$  имеет вид:

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

Давайте введем следующее обозначение:  $\hat{z}_k = \begin{bmatrix} \hat{x}_{k+1} \\ \hat{x}_k \end{bmatrix}$ . Следовательно,  $\hat{z}_{k+1} = M \hat{z}_k$ , где матрица итерации  $M$  имеет вид:

$$M = \begin{bmatrix} I - \alpha \Lambda + \beta I & -\beta I \\ I & 0_d \end{bmatrix}.$$

## Сведение к скалярному случаю

Обратим внимание, что  $M$  является матрицей  $2d \times 2d$  с четырьмя блочно-диагональными матрицами размера  $d \times d$  внутри. Это означает, что мы можем изменить порядок координат, чтобы сделать  $M$  блочно-диагональной. Обратите внимание, что в уравнении ниже матрица  $M$  обозначает то же самое, что и в обозначении выше, за исключением описанной перестановки строк и столбцов. Мы используем эту небольшую перегрузку обозначений для простоты.

## Сведение к скалярному случаю

Обратим внимание, что  $M$  является матрицей  $2d \times 2d$  с четырьмя блочно-диагональными матрицами размера  $d \times d$  внутри. Это означает, что мы можем изменить порядок координат, чтобы сделать  $M$  блочно-диагональной. Обратите внимание, что в уравнении ниже матрица  $M$  обозначает то же самое, что и в обозначении выше, за исключением описанной перестановки строк и столбцов. Мы используем эту небольшую перегрузку обозначений для простоты.




Figure 1: Иллюстрация перестановки матрицы  $M$

где  $\hat{x}_k^{(i)}$  является  $i$ -й координатой вектора  $\hat{x}_k \in \mathbb{R}^d$  и  $M_i$  обозначает матрицу размера  $2 \times 2$ . Переупорядочение позволяет нам исследовать динамику метода независимо от размерности. Асимптотическая скорость сходимости последовательности векторов  $\hat{z}_k$  размерности  $2d$  определяется наихудшей скоростью сходимости среди его блока координат. Следовательно, достаточно исследовать оптимизацию в одномерном случае.

## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$



## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

Метод будет сходиться, если  $\rho(M) < 1$ , и оптимальные параметры могут быть вычислены путем оптимизации спектрального радиуса

$$\alpha^*, \beta^* = \arg \min_{\alpha, \beta} \max_i \rho(M_i), \quad \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

Метод будет сходиться, если  $\rho(M) < 1$ , и оптимальные параметры могут быть вычислены путем оптимизации спектрального радиуса

$$\alpha^*, \beta^* = \arg \min_{\alpha, \beta} \max_i \rho(M_i), \quad \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

Можно показать, что для таких параметров матрица  $M$  имеет комплексные собственные значения, которые образуют комплексно-сопряжённую пару, поэтому расстояние до оптимума (в этом случае  $\|z_k\|$ ) обычно не убывает монотонно.

# Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

Пусть  $z_1, z_2$  — корни этого уравнения. По теореме Виета:

$$z_1 z_2 = \beta, \quad z_1 + z_2 = 1 - \alpha\lambda_i + \beta$$

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

Пусть  $z_1, z_2$  — корни этого уравнения. По теореме Виета:

$$z_1 z_2 = \beta, \quad z_1 + z_2 = 1 - \alpha\lambda_i + \beta$$

Спектральный радиус  $\rho(M_i) = \max(|z_1|, |z_2|)$ . Для сходимости необходимо  $\rho(M_i) < 1$ , что подразумевает  $\beta < 1$  (так как  $z_1 z_2 = \beta$ ).

## Анализ дискриминанта: Вещественные корни

Дискриминант квадратного уравнения  $z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$ :

$$D = (1 - \alpha\lambda_i + \beta)^2 - 4\beta$$

Рассмотрим случай **вещественных корней** ( $D \geq 0$ ). Корни вещественны и  $z_1, z_2 = \frac{1 - \alpha\lambda_i + \beta \pm \sqrt{D}}{2}$ . Так как  $z_1 z_2 = \beta$ , то если корни различны, один из них по модулю должен быть больше  $\sqrt{\beta}$  (если только они не равны  $\pm\sqrt{\beta}$ ). Более того, если  $D > 0$ , то  $\max(|z_1|, |z_2|) > \sqrt{\beta}$ . Это означает, что скорость сходимости будет хуже, чем  $\sqrt{\beta}$ .

## Анализ дискриминанта: Комплексные корни

Рассмотрим случай **комплексных корней** ( $D < 0$ ). Корни комплексно-сопряженные:

$$z_{1,2} = \frac{1 - \alpha\lambda_i + \beta \pm i\sqrt{4\beta - (1 - \alpha\lambda_i + \beta)^2}}{2}$$

Вычислим квадрат модуля корней:

$$\begin{aligned} |z_{1,2}|^2 &= \left( \frac{1 - \alpha\lambda_i + \beta}{2} \right)^2 + \left( \frac{\sqrt{4\beta - (1 - \alpha\lambda_i + \beta)^2}}{2} \right)^2 \\ &= \frac{(1 - \alpha\lambda_i + \beta)^2 + 4\beta - (1 - \alpha\lambda_i + \beta)^2}{4} = \frac{4\beta}{4} = \beta \end{aligned}$$

Следовательно,  $|z_1| = |z_2| = \sqrt{\beta}$ .



# Вывод по дискриминанту

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и не зависит от  $\lambda_i$ .

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

**Стратегия:** Мы хотим минимизировать худший спектральный радиус по всем  $\lambda_i$ . Наилучшая ситуация достигается, когда для всех  $\lambda_i$  корни комплексные (или на границе  $D = 0$ ), и мы минимизируем  $\sqrt{\beta}$ . Поэтому мы требуем выполнения условия  $D \leq 0$  для всех  $\lambda_i \in [\mu, L]$ .

## Постановка задачи оптимизации

Мы ищем  $\alpha > 0, \beta \geq 0$ , минимизирующие спектральный радиус  $\rho(\alpha, \beta) = \max_{\lambda \in [\mu, L]} \max(|z_1(\lambda)|, |z_2(\lambda)|)$ .  
Радиус корней для фиксированного  $\lambda$ :

$$r(\lambda) = \begin{cases} \frac{1}{2} \left( |1 + \beta - \alpha\lambda| + \sqrt{(1 + \beta - \alpha\lambda)^2 - 4\beta} \right), & \text{если } D > 0 \\ \sqrt{\beta}, & \text{если } D \leq 0 \end{cases}$$

## Постановка задачи оптимизации

Мы ищем  $\alpha > 0, \beta \geq 0$ , минимизирующие спектральный радиус  $\rho(\alpha, \beta) = \max_{\lambda \in [\mu, L]} \max(|z_1(\lambda)|, |z_2(\lambda)|)$ . Радиус корней для фиксированного  $\lambda$ :

$$r(\lambda) = \begin{cases} \frac{1}{2} \left( |1 + \beta - \alpha\lambda| + \sqrt{(1 + \beta - \alpha\lambda)^2 - 4\beta} \right), & \text{если } D > 0 \\ \sqrt{\beta}, & \text{если } D \leq 0 \end{cases}$$

Обозначим  $\alpha_{opt} = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2$ . Заметим, что  $D \leq 0 \iff \beta \geq (1 - \sqrt{\alpha\bar{\lambda}})^2$ . Также  $|1 - \sqrt{\alpha\mu}| < |1 - \sqrt{\alpha L}| \iff \alpha > \alpha_{opt}$ .

## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .



## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .
2.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta < (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho \geq r(\mu) > 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . (Здесь  $r(\mu)$  убывает по  $\beta$ ).

## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .
4.  $\alpha > \alpha_{opt}$  и  $\beta < (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho \geq r(L) > \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . (Здесь  $r(L)$  убывает по  $\beta$ ).

## Оптимальные параметры

Во всех случаях  $\rho(\alpha, \beta) \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . Равенство достигается только в первом случае на границе:

$$\alpha^* = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

## Оптимальные параметры

Во всех случаях  $\rho(\alpha, \beta) \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . Равенство достигается только в первом случае на границе:

$$\alpha^* = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

При этом оптимальная скорость сходимости:

$$\rho_{opt} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

Это соответствует сложности  $O(\sqrt{\kappa} \log \frac{1}{\varepsilon})$ .

# Сходимость метода тяжёлого шарика для квадратичной функции

## i Theorem

Предположим, что  $f$  является  $\mu$ -сильно выпуклой и  $L$ -гладкой квадратичной функцией. Тогда метод тяжёлого шарика с параметрами

$$\alpha = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \beta = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

сходится линейно:

$$\|x_k - x^*\|_2 \leq \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x_0 - x^*\|$$



# Глобальная сходимость метода тяжёлого шарика<sup>3</sup>

## i Theorem

Предположим, что  $f$  является гладкой и выпуклой и что

$$\beta \in [0, 1), \quad \alpha \in \left(0, \frac{2(1-\beta)}{L}\right).$$

Тогда последовательность  $\{x_k\}$ , генерируемая итерациями тяжёлого шарика, удовлетворяет

$$f(\bar{x}_T) - f^* \leq \begin{cases} \frac{\|x_0 - x^*\|^2}{2(T+1)} \left( \frac{L\beta}{1-\beta} + \frac{1-\beta}{\alpha} \right), & \text{if } \alpha \in \left(0, \frac{1-\beta}{L}\right], \\ \frac{\|x_0 - x^*\|^2}{2(T+1)(2(1-\beta) - \alpha L)} \left( L\beta + \frac{(1-\beta)^2}{\alpha} \right), & \text{if } \alpha \in \left[\frac{1-\beta}{L}, \frac{2(1-\beta)}{L}\right), \end{cases}$$

где  $\bar{x}_T$  среднее Чезаро последовательности итераций, т.е.

$$\bar{x}_T = \frac{1}{T+1} \sum_{k=0}^T x_k.$$

<sup>3</sup>Глобальная сходимость метода тяжёлого шарика для выпуклой оптимизации, Euhanna Ghadimi et al.

# Глобальная сходимость метода тяжёлого шарика<sup>4</sup>

## i Theorem

Предположим, что  $f$  является гладкой и сильно выпуклой и что

$$\alpha \in \left(0, \frac{2}{L}\right), \quad 0 \leq \beta < \frac{1}{2} \left( \frac{\mu\alpha}{2} + \sqrt{\frac{\mu^2\alpha^2}{4} + 4\left(1 - \frac{\alpha L}{2}\right)} \right).$$

Тогда последовательность  $\{x_k\}$ , генерируемая итерациями метода тяжёлого шарика, сходится линейно к единственному оптимальному решению  $x^*$ . В частности,

$$f(x_k) - f^* \leq q^k (f(x_0) - f^*),$$

где  $q \in [0, 1)$ .

<sup>4</sup>Глобальная сходимость метода тяжёлого шарика для выпуклой оптимизации, Euhanna Ghadimi et al.

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.
- Метод не был чрезвычайно популярен до ML-бума.

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

# Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.
- Метод не был чрезвычайно популярен до ML-бума.
- Сейчас он фактически является стандартом для практического ускорения методов градиентного спуска, в том числе для невыпуклых задач (обучение нейронных сетей).

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

## Ускоренный градиентный метод Нестерова



## Концепция ускоренного градиентного метода Нестерова

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \quad x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \quad \begin{cases} y_{k+1} = x_k + \beta(x_k - x_{k-1}) \\ x_{k+1} = y_{k+1} - \alpha \nabla f(y_{k+1}) \end{cases}$$

# Концепция ускоренного градиентного метода Нестерова

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \quad x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Давайте определим следующие обозначения

$$x^+ = x - \alpha \nabla f(x) \quad \text{Градиентный шаг}$$

$$d_k = \beta_k(x_k - x_{k-1}) \quad \text{Импульс}$$

Тогда мы можем записать:


$$x_{k+1} = x_k^+ \quad \text{Градиентный спуск}$$

$$x_{k+1} = x_k^+ + d_k \quad \text{Метод тяжёлого шарика}$$


$$x_{k+1} = (x_k + d_k)^+ \quad \text{Ускоренный градиентный метод Нестерова}$$

$$\begin{cases} y_{k+1} = x_k + \beta(x_k - x_{k-1}) \\ x_{k+1} = y_{k+1} - \alpha \nabla f(y_{k+1}) \end{cases}$$

Polyak momentum



Nesterov momentum



# Сходимость для выпуклых функций

## i Theorem

Предположим, что  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является выпуклой и  $L$ -гладкой. Ускоренный градиентный метод Нестерова (NAG) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Обновление градиента:** 
$$x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$$

**Вес экстраполяции:** 
$$\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$$

$$\gamma_k = \frac{\lambda_k - 1}{\lambda_{k+1}}$$

**Экстраполяция:** 
$$y_{k+1} = x_{k+1} + \gamma_k (x_{k+1} - x_k)$$

Последовательность  $\{f(x_k)\}_{k \in \mathbb{N}}$ , генерируемая алгоритмом, сходится к оптимальному значению  $f^*$  со скоростью  $\mathcal{O}\left(\frac{1}{k^2}\right)$ , в частности:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}$$

# Ускоренная сходимость для сильно выпуклых функций

## i Theorem

Предположим, что  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является  $\mu$ -сильно выпуклой и  $L$ -гладкой. Ускоренный градиентный метод Нестерова (NAG) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Обновление градиента:** 
$$x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$$

**Экстраполяция:** 
$$y_{k+1} = x_{k+1} - \gamma (x_{k+1} - x_k)$$

**Вес экстраполяции:** 
$$\gamma = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$$


Последовательность  $\{f(x_k)\}_{k \in \mathbb{N}}$ , генерируемая алгоритмом, сходится к оптимальному значению  $f^*$  линейно:

$$f(x_k) - f^* \leq \frac{\mu + L}{2} \|x_0 - x^*\|_2^2 \exp\left(-\frac{k}{\sqrt{\kappa}}\right)$$

## Выбор параметров для квадратичной функции


# Диаграмм сходимости метода тяжёлого шарика для сильно выпуклой квадратичной функции

Convergence Rate of Heavy Ball Method.  $d = 2, \mu = 0.5, L = 1$



# Диаграмм сходимости ускоренного градиентного метода Нестерова для сильно выпуклой квадратичной функции

Convergence Rate of Nesterov Accelerated Gradient.  $d = 2, \mu = 0.5, L = 1$




## Численные эксперименты



# Выпуклая квадратичная задача (линейная регрессия)


Convex quadratics:  $n=60$ , random matrix,  $\mu=0$ ,  $L=10$




# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)

Strongly convex quadratics:  $n=60$ , random matrix,  $\mu=1$ ,  $L=10$


Function Gap



Domain Gap




Gradient Norm



— Gradient Descent.  $\alpha=1.67\text{e-}01$     - - - Heavy Ball.  $\alpha=2.15\text{e-}01$ ,  $\beta=2.88\text{e-}01$     ..... NAG.  $\alpha=9.09\text{e-}02$ ,  $\beta=5.37\text{e-}01$

# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)


Strongly convex quadratics:  $n=60$ , random matrix,  $\mu=1$ ,  $L=1000$




# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)

Strongly convex quadratics:  $n=1000$ , random matrix,  $\mu=1$ ,  $L=1000$


Function Gap



Domain Gap




Gradient Norm



— Gradient Descent.  $\alpha=2.00\text{e-}03$     - - - Heavy Ball.  $\alpha=3.75\text{e-}03$ ,  $\beta=8.81\text{e-}01$     ····· NAG.  $\alpha=9.99\text{e-}04$ ,  $\beta=9.39\text{e-}01$


# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .



# Выпуклая бинарная логистическая регрессия


Convex binary logistic regression.  $\mu=0$ .






# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .



# Сильно выпуклая бинарная логистическая регрессия


Strongly convex binary logistic regression.  $\mu=1$ .






# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .



# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .



# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .

