



Стохастический градиентный спуск. SGD,  
Mini-batch. Расписания шагов

Даня Меркулов

ФКН ВШЭ

# Мотивация

# Проблема больших данных

**Задача ERM (Empirical Risk Minimization):**

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,  
 $n = 10^6$  (ImageNet).

# Проблема больших данных

**Задача ERM (Empirical Risk Minimization):**

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,  
 $n = 10^6$  (ImageNet).

**Стоимость одной итерации GD:**

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$  нужно  $n$  вычислений  $\nabla f_i$  за шаг  $\Rightarrow O(n)$  на итерацию.

# Проблема больших данных

**Задача ERM (Empirical Risk Minimization):**

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,  
 $n = 10^6$  (ImageNet).

**Стоимость одной итерации GD:**

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$  нужно  $n$  вычислений  $\nabla f_i$  за шаг  $\Rightarrow O(n)$  на итерацию.

При  $n = 10^6$  и  $K = 1000$  итераций:  $10^9$  **вычислений градиента**.

# Проблема больших данных

**Задача ERM (Empirical Risk Minimization):**

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,  
 $n = 10^6$  (ImageNet).

**Стоимость одной итерации GD:**

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$  нужно  $n$  вычислений  $\nabla f_i$  за шаг  $\Rightarrow O(n)$  на итерацию.

При  $n = 10^6$  и  $K = 1000$  итераций:  $10^9$  вычислений градиента.

**Идея SGD:** вместо точного градиента — случайная **несмещённая оценка** по одному или нескольким объектам:

$$g_k \approx \nabla f(w_k), \quad \mathbb{E}[g_k \mid w_k] = \nabla f(w_k)$$

# Проблема больших данных

**Задача ERM (Empirical Risk Minimization):**

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,  $n = 10^6$  (ImageNet).

**Стоимость одной итерации GD:**

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$  нужно  $n$  вычислений  $\nabla f_i$  за шаг  $\Rightarrow O(n)$  на итерацию.

При  $n = 10^6$  и  $K = 1000$  итераций:  $10^9$  вычислений градиента.

**Идея SGD:** вместо точного градиента — случайная **несмещённая оценка** по одному или нескольким объектам:

$$g_k \approx \nabla f(w_k), \quad \mathbb{E}[g_k \mid w_k] = \nabla f(w_k)$$

**Стоимость:**  $O(1)$  или  $O(b)$  на шаг — при  $b \ll n$  огромная экономия.

## Когда GD неэффективен?

| Сценарий                | $n$      | $d$    | GD итерация       | Проблема       |
|-------------------------|----------|--------|-------------------|----------------|
| Линейная регрессия      | $10^3$   | $10^2$ | быстро            | ок             |
| Логистическая регрессия | $10^6$   | $10^3$ | <b>медленно</b>   | $O(n)$         |
| Нейронная сеть          | $10^6$   | $10^8$ | <b>невозможно</b> | $O(n \cdot d)$ |
| Онлайн-обучение         | $\infty$ | —      | <b>невозможно</b> | данных нет     |



## Когда GD неэффективен?

| Сценарий                | $n$      | $d$    | GD итерация       | Проблема       |
|-------------------------|----------|--------|-------------------|----------------|
| Линейная регрессия      | $10^3$   | $10^2$ | быстро            | ок             |
| Логистическая регрессия | $10^6$   | $10^3$ | <b>медленно</b>   | $O(n)$         |
| Нейронная сеть          | $10^6$   | $10^8$ | <b>невозможно</b> | $O(n \cdot d)$ |
| Онлайн-обучение         | $\infty$ | —      | <b>невозможно</b> | данных нет     |

**Вывод:** при больших  $n$  нужен метод с сублинейной стоимостью итерации.

## Алгоритм SGD

# SGD: алгоритм

**SGD с одним образцом:**

Выбираем  $i_k \sim \text{Uniform}\{1, \dots, n\}$  независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

# SGD: алгоритм

## SGD с одним образцом:

Выбираем  $i_k \sim \text{Uniform}\{1, \dots, n\}$  независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

## Несмещённость оценки:

$$\mathbb{E}_{i_k} [\nabla f_{i_k}(w_k) \mid w_k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(w_k) = \nabla f(w_k) \checkmark$$

# SGD: алгоритм

## SGD с одним образцом:

Выбираем  $i_k \sim \text{Uniform}\{1, \dots, n\}$  независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

## Несмещённость оценки:

$$\mathbb{E}_{i_k} [\nabla f_{i_k}(w_k) \mid w_k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(w_k) = \nabla f(w_k) \checkmark$$

## Дисперсия (ограниченный второй момент):

$$\mathbb{E} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$$

# Mini-batch SGD

**Mini-batch:** выбираем подмножество  $\mathcal{B}_k \subset \{1, \dots, n\}$  размера  $b$ :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

# Mini-batch SGD

**Mini-batch:** выбираем подмножество  $\mathcal{B}_k \subset \{1, \dots, n\}$  размера  $b$ :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

**Дисперсия mini-batch** уменьшается с ростом  $b$ :

$$\mathbb{E} \left\| \frac{1}{b} \sum_{i \in \mathcal{B}} \nabla f_i(w) - \nabla f(w) \right\|^2 = \frac{\sigma^2}{b}, \quad \sigma^2 = \frac{1}{n} \sum_i \|\nabla f_i(w) - \nabla f(w)\|^2$$

## Mini-batch SGD

**Mini-batch:** выбираем подмножество  $\mathcal{B}_k \subset \{1, \dots, n\}$  размера  $b$ :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

**Дисперсия mini-batch** уменьшается с ростом  $b$ :

$$\mathbb{E} \left\| \frac{1}{b} \sum_{i \in \mathcal{B}} \nabla f_i(w) - \nabla f(w) \right\|^2 = \frac{\sigma^2}{b}, \quad \sigma^2 = \frac{1}{n} \sum_i \|\nabla f_i(w) - \nabla f(w)\|^2$$

**Стоимость:**  $O(b)$  вместо  $O(n)$   $\rightarrow$  при  $b \ll n$  огромная экономия. **Компромисс:** большой  $b \rightarrow$  меньше шума  $\rightarrow$  можно брать больший  $\alpha$ , но стоимость итерации растёт.



## Анализ сходимости

# Базовое неравенство SGD

**Предположения:**  $f$  — выпуклая,  $L$ -гладкая;  $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$ .

**Лемма (базовое неравенство).** Для любого  $w^*$ :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

# Базовое неравенство SGD

**Предположения:**  $f$  — выпуклая,  $L$ -гладкая;  $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$ .

**Лемма (базовое неравенство).** Для любого  $w^*$ :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

**Доказательство:**

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём  $\mathbb{E}_{i_k}[\cdot \mid w_k]$ :

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$  (выпуклость)

# Базовое неравенство SGD

**Предположения:**  $f$  — выпуклая,  $L$ -гладкая;  $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$ .

**Лемма (базовое неравенство).** Для любого  $w^*$ :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

**Доказательство:**

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём  $\mathbb{E}_{i_k}[\cdot \mid w_k]$ :

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$  (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$ .  $\square$

# Базовое неравенство SGD

**Предположения:**  $f$  — выпуклая,  $L$ -гладкая;  $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$ .

**Лемма (базовое неравенство).** Для любого  $w^*$ :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

**Доказательство:**

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём  $\mathbb{E}_{i_k}[\cdot \mid w_k]$ :

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$  (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$ .  $\square$

# Базовое неравенство SGD

**Предположения:**  $f$  — выпуклая,  $L$ -гладкая;  $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$ .

**Лемма (базовое неравенство).** Для любого  $w^*$ :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

**Доказательство:**

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём  $\mathbb{E}_{i_k}[\cdot \mid w_k]$ :

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$  (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$ .  $\square$

**Связь с субградиентным методом:** та же формула! SGD = стохастический субградиентный метод.

## Сходимость: убывающий шаг (выпуклый случай)

**Теорема.** Для выпуклой  $f$  при  $\alpha_k = \frac{\alpha}{\sqrt{k+1}}$ :

$$\mathbb{E} \left[ \frac{1}{K} \sum_{k=0}^{K-1} f(w_k) \right] - f^* \leq \frac{R^2 + \alpha^2 G^2 \ln K}{2\alpha\sqrt{K}} = O\left(\frac{RG}{\sqrt{K}}\right)$$

при оптимальном  $\alpha = R/G$ , где  $R = \|w_0 - w^*\|$ .

## Сходимость: убывающий шаг (выпуклый случай)

**Теорема.** Для выпуклой  $f$  при  $\alpha_k = \frac{\alpha}{\sqrt{k+1}}$ :

$$\mathbb{E} \left[ \frac{1}{K} \sum_{k=0}^{K-1} f(w_k) \right] - f^* \leq \frac{R^2 + \alpha^2 G^2 \ln K}{2\alpha\sqrt{K}} = O\left(\frac{RG}{\sqrt{K}}\right)$$

при оптимальном  $\alpha = R/G$ , где  $R = \|w_0 - w^*\|$ .

**Доказательство** (телескоп базового неравенства):

Суммируем по  $k = 0, \dots, K-1$ , делим на  $K$ , применяем выпуклость:

$$f\left(\frac{1}{K} \sum_k w_k\right) - f^* \leq \frac{1}{K} \sum_k (f(w_k) - f^*) \leq \frac{R^2}{2\alpha K} \sum_k \frac{1}{\sqrt{k+1}} + \frac{\alpha G^2}{2K} \sum_k \frac{1}{\sqrt{k+1}}$$

используя  $\sum_{k=0}^{K-1} \frac{1}{\sqrt{k+1}} \leq 2\sqrt{K}$ .  $\square$



## Шумовой пол: постоянный шаг

При  $\alpha_k = \alpha = \text{const}$  телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

## Шумовой пол: постоянный шаг

При  $\alpha_k = \alpha = \text{const}$  телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

При  $K \rightarrow \infty$ :

$$\boxed{\lim_{K \rightarrow \infty} \mathbb{E}[f(w_K) - f^*] \leq \frac{\alpha G^2}{2}}$$

**Это шумовой пол** (noise floor): SGD с постоянным шагом **не сходится к  $x^*$** , а колеблется в окрестности радиуса  $\sim \alpha G$ .

## Шумовой пол: постоянный шаг

При  $\alpha_k = \alpha = \text{const}$  телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

При  $K \rightarrow \infty$ :

$$\lim_{K \rightarrow \infty} \mathbb{E}[f(w_K) - f^*] \leq \frac{\alpha G^2}{2}$$

**Это шумовой пол** (noise floor): SGD с постоянным шагом **не сходится к  $x^*$** , а колеблется в окрестности радиуса  $\sim \alpha G$ .

**Убывающий шаг:**  $\alpha_k \rightarrow 0 \rightarrow$  сходимость к  $x^*$ , но медленнее в начале.

**Постоянный шаг:** быстрый прогресс в начале  $\rightarrow$  пол  $O(\alpha)$ . Популярен в ML (пол пропорционален «шуму данных»).

## Сходимость: сильно выпуклый случай

**Теорема.** Для  $\mu$ -сильно выпуклой  $f$  при  $\alpha_k = \frac{2}{\mu(k+1)}$ :

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где  $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$  — взвешенное среднее.

## Сходимость: сильно выпуклый случай

**Теорема.** Для  $\mu$ -сильно выпуклой  $f$  при  $\alpha_k = \frac{2}{\mu(k+1)}$ :

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где  $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$  — взвешенное среднее.

**Сравнение:** GD для сильно выпуклой даёт **линейную** сходимость  $O(e^{-\mu k/L})$ .

SGD даёт  $O(1/K)$  — субмарковскую. **Разрыв!**

## Сходимость: сильно выпуклый случай

**Теорема.** Для  $\mu$ -сильно выпуклой  $f$  при  $\alpha_k = \frac{2}{\mu(k+1)}$ :

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где  $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$  — взвешенное среднее.

**Сравнение:** GD для сильно выпуклой даёт **линейную** сходимость  $O(e^{-\mu k/L})$ .

SGD даёт  $O(1/K)$  — субмарковскую. **Разрыв!**

**Причина разрыва:** неустранимый шум  $\sigma^2 > 0$  — мы не используем прошлые градиенты. Решение: **Variance Reduction** (Лекция 10: SVRG, SAG, SARAH).

## Расписания шагов и батч

## Расписания шагов на практике

**Step decay:** уменьшать  $\alpha$  в  $10\times$  каждые  $T$  эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.



# Расписания шагов на практике

**Step decay:** уменьшать  $\alpha$  в  $10\times$  каждые  $T$  эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

**Cosine annealing** (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left( 1 + \cos \frac{\pi k}{K} \right)$$

# Расписания шагов на практике

**Step decay:** уменьшать  $\alpha$  в  $10\times$  каждые  $T$  эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

**Cosine annealing** (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left( 1 + \cos \frac{\pi k}{K} \right)$$

**Warmup:** первые  $T_{\text{warm}}$  шагов  $\alpha$  **растёт** от 0 до  $\alpha_{\max}$ .

Обязателен для трансформеров: большой батч + случайная инициализация  $\rightarrow$  нестабильные ранние градиенты.

# Расписания шагов на практике

**Step decay:** уменьшать  $\alpha$  в  $10\times$  каждые  $T$  эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

**Cosine annealing** (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left( 1 + \cos \frac{\pi k}{K} \right)$$

**Warmup:** первые  $T_{\text{warm}}$  шагов  $\alpha$  **растёт** от 0 до  $\alpha_{\max}$ .

Обязателен для трансформеров: большой батч + случайная инициализация  $\rightarrow$  нестабильные ранние градиенты.

**Практика:** шаги подбираются под  $b$ , архитектуру и датасет. Нет универсального рецепта.

# Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

## Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При  $b > b_{\text{crit}}$  прирост шума мал, увеличение  $\alpha$  не помогает.

# Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При  $b > b_{\text{crit}}$  прирост шума мал, увеличение  $\alpha$  не помогает.

**Gradient noise scale** (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный  $b \approx \mathcal{N}$  для баланса параллелизм/обновления.

Типичные значения:

| Задача      | $b$                        |
|-------------|----------------------------|
| CV (ResNet) | 256–4096                   |
| NLP (BERT)  | 256–2048                   |
| LLM (GPT-3) | $\sim 3,2\text{M}$ токенов |

# Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При  $b > b_{\text{crit}}$  прирост шума мал, увеличение  $\alpha$  не помогает.

**Gradient noise scale** (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный  $b \approx \mathcal{N}$  для баланса параллелизм/обновления.

Типичные значения:

| Задача      | $b$                        |
|-------------|----------------------------|
| CV (ResNet) | 256–4096                   |
| NLP (BERT)  | 256–2048                   |
| LLM (GPT-3) | $\sim 3,2\text{M}$ токенов |

Очень большие батчи требуют:

- linear scaling rule

# Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При  $b > b_{\text{crit}}$  прирост шума мал, увеличение  $\alpha$  не помогает.

**Gradient noise scale** (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный  $b \approx \mathcal{N}$  для баланса параллелизм/обновления.

Типичные значения:

| Задача      | $b$                        |
|-------------|----------------------------|
| CV (ResNet) | 256–4096                   |
| NLP (BERT)  | 256–2048                   |
| LLM (GPT-3) | $\sim 3,2\text{M}$ токенов |

Очень большие батчи требуют:

- linear scaling rule
- warmup (обязателен!)



# Эффект размера батча

Дисперсия:  $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$ .

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При  $b > b_{\text{crit}}$  прирост шума мал, увеличение  $\alpha$  не помогает.

**Gradient noise scale** (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный  $b \approx \mathcal{N}$  для баланса параллелизм/обновления.

Типичные значения:

| Задача      | $b$                        |
|-------------|----------------------------|
| CV (ResNet) | 256–4096                   |
| NLP (BERT)  | 256–2048                   |
| LLM (GPT-3) | $\sim 3,2\text{M}$ токенов |

Очень большие батчи требуют:

- linear scaling rule
- warmup (обязателен!)
- cosine annealing

## SGD с моментом

**SGD+Momentum** (Heavy Ball для стохастического случая):

$$m_{k+1} = \beta m_k + (1 - \beta) \nabla f_{i_k}(w_k), \quad w_{k+1} = w_k - \alpha m_{k+1}$$

## SGD с моментом

**SGD+Momentum** (Heavy Ball для стохастического случая):

$$m_{k+1} = \beta m_k + (1 - \beta) \nabla f_{i_k}(w_k), \quad w_{k+1} = w_k - \alpha m_{k+1}$$

Эквивалентно:  $w_{k+1} = w_k - \alpha_{\text{eff}} g_k$ , где  $\alpha_{\text{eff}} = \alpha / (1 - \beta)$  при  $\beta \rightarrow 1$ .

## SGD с моментом

**SGD+Momentum** (Heavy Ball для стохастического случая):

$$m_{k+1} = \beta m_k + (1 - \beta) \nabla f_{i_k}(w_k), \quad w_{k+1} = w_k - \alpha m_{k+1}$$

Эквивалентно:  $w_{k+1} = w_k - \alpha_{\text{eff}} g_k$ , где  $\alpha_{\text{eff}} = \alpha / (1 - \beta)$  при  $\beta \rightarrow 1$ .

**Почему момент не ускоряет SGD теоретически:** момент Нестерова накапливает шум  $\rightarrow$  ускорение  $O(1/k^2) \rightarrow O(1/\sqrt{k})$  пропадает при  $\sigma^2 > 0$ .

## SGD с моментом

**SGD+Momentum** (Heavy Ball для стохастического случая):

$$m_{k+1} = \beta m_k + (1 - \beta) \nabla f_{i_k}(w_k), \quad w_{k+1} = w_k - \alpha m_{k+1}$$

Эквивалентно:  $w_{k+1} = w_k - \alpha_{\text{eff}} g_k$ , где  $\alpha_{\text{eff}} = \alpha / (1 - \beta)$  при  $\beta \rightarrow 1$ .

**Почему момент не ускоряет SGD теоретически:** момент Нестерова накапливает шум  $\rightarrow$  ускорение  $O(1/k^2) \rightarrow O(1/\sqrt{k})$  пропадает при  $\sigma^2 > 0$ .

**Практически:**  $\beta = 0.9$  — стандарт в CV. Помогает «проходить» плохо обусловленные участки, сглаживает шум.

**Adam** = SGD+Momentum с адаптивными по координатным шагами  $\rightarrow$  отдельная тема.

Итог

## Сравнительная таблица методов

| Метод | Скорость (выпуклая) | Скорость (с.в.)           | Итерационная стоимость |
|-------|---------------------|---------------------------|------------------------|
| GD    | $O(1/k)$            | $O(e^{-\mu k/L})$         | $O(n)$                 |
| AGD   | $O(1/k^2)$          | $O(e^{-k/\sqrt{\kappa}})$ | $O(n)$                 |
| SGD   | $O(1/\sqrt{k})$     | $O(1/(\mu k))$            | $O(1)$                 |
| SVRG  | $O(1/\sqrt{k})^*$   | $O(e^{-\mu k/L})$         | $O(1)^{**}$            |

\*В выпуклом случае SVRG не улучшает SGD. \*\*Амортизированно.

## Сравнительная таблица методов

| Метод | Скорость (выпуклая) | Скорость (с.в.)           | Итерационная стоимость |
|-------|---------------------|---------------------------|------------------------|
| GD    | $O(1/k)$            | $O(e^{-\mu k/L})$         | $O(n)$                 |
| AGD   | $O(1/k^2)$          | $O(e^{-k/\sqrt{\kappa}})$ | $O(n)$                 |
| SGD   | $O(1/\sqrt{k})$     | $O(1/(\mu k))$            | $O(1)$                 |
| SVRG  | $O(1/\sqrt{k})^*$   | $O(e^{-\mu k/L})$         | $O(1)^{**}$            |

\*В выпуклом случае SVRG не улучшает SGD. \*\*Амортизированно.

**Ключевой вывод:** SGD выгоден когда  $n \gg 1/\varepsilon$  (много данных, умеренная точность). Линейной сходимости SGD не даёт из-за шума  $\rightarrow$  нужен **Variance Reduction** (Лекция 10).