

Стохастический градиентный спуск. SGD,
Mini-batch. Расписания шагов

Даня Меркулов

ФКН ВШЭ

Мотивация

Проблема больших данных

Задача ERM (Empirical Risk Minimization):

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,
 $n = 10^6$ (ImageNet).

Проблема больших данных

Задача ERM (Empirical Risk Minimization):

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,
 $n = 10^6$ (ImageNet).

Стоимость одной итерации GD:

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$ нужно n вычислений ∇f_i за шаг $\Rightarrow O(n)$ на итерацию.

Проблема больших данных

Задача ERM (Empirical Risk Minimization):

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,
 $n = 10^6$ (ImageNet).

Стоимость одной итерации GD:

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$ нужно n вычислений ∇f_i за шаг $\Rightarrow O(n)$ на итерацию.

При $n = 10^6$ и $K = 1000$ итераций: 10^9 вычислений градиента.

Проблема больших данных

Задача ERM (Empirical Risk Minimization):

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети,
 $n = 10^6$ (ImageNet).

Стоимость одной итерации GD:

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$ нужно n вычислений ∇f_i за шаг $\Rightarrow O(n)$ на итерацию.

При $n = 10^6$ и $K = 1000$ итераций: 10^9 вычислений градиента.

Идея SGD: вместо точного градиента — случайная **несмещённая оценка** по одному или нескольким объектам:

$$g_k \approx \nabla f(w_k), \quad \mathbb{E}[g_k \mid w_k] = \nabla f(w_k)$$

Проблема больших данных

Задача ERM (Empirical Risk Minimization):

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$$

Примеры: логистическая регрессия, нейронные сети, $n = 10^6$ (ImageNet).

Стоимость одной итерации GD:

$$w_{k+1} = w_k - \alpha \nabla f(w_k) = w_k - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(w_k)$$

$\Rightarrow$ нужно n вычислений ∇f_i за шаг $\Rightarrow O(n)$ на итерацию.

При $n = 10^6$ и $K = 1000$ итераций: 10^9 вычислений градиента.

Идея SGD: вместо точного градиента — случайная **несмещённая оценка** по одному или нескольким объектам:

$$g_k \approx \nabla f(w_k), \quad \mathbb{E}[g_k \mid w_k] = \nabla f(w_k)$$

Стоимость: $O(1)$ или $O(b)$ на шаг — при $b \ll n$ огромная экономия.

Когда GD неэффективен?

Сценарий	n	d	GD итерация	Проблема
Линейная регрессия	10^3	10^2	быстро	ок
Логистическая регрессия	10^6	10^3	медленно	$O(n)$
Нейронная сеть	10^6	10^8	невозможно	$O(n \cdot d)$
Онлайн-обучение	∞	—	невозможно	данных нет

Когда GD неэффективен?

Сценарий	n	d	GD итерация	Проблема
Линейная регрессия	10^3	10^2	быстро	ок
Логистическая регрессия	10^6	10^3	медленно	$O(n)$
Нейронная сеть	10^6	10^8	невозможно	$O(n \cdot d)$
Онлайн-обучение	∞	—	невозможно	данных нет

Вывод: при больших n нужен метод с сублинейной стоимостью итерации.

Алгоритм SGD

SGD: алгоритм

SGD с одним образцом:

Выбираем $i_k \sim \text{Uniform}\{1, \dots, n\}$ независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

SGD: алгоритм

SGD с одним образцом:

Выбираем $i_k \sim \text{Uniform}\{1, \dots, n\}$ независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

Несмещённость оценки:

$$\mathbb{E}_{i_k} [\nabla f_{i_k}(w_k) \mid w_k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(w_k) = \nabla f(w_k) \checkmark$$

SGD: алгоритм

SGD с одним образцом:

Выбираем $i_k \sim \text{Uniform}\{1, \dots, n\}$ независимо, задаём:

$$w_{k+1} = w_k - \alpha_k \nabla f_{i_k}(w_k)$$

Несмещённость оценки:

$$\mathbb{E}_{i_k} [\nabla f_{i_k}(w_k) \mid w_k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(w_k) = \nabla f(w_k) \checkmark$$

Дисперсия (ограниченный второй момент):

$$\mathbb{E} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$$

Mini-batch SGD

Mini-batch: выбираем подмножество $\mathcal{B}_k \subset \{1, \dots, n\}$ размера b :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

Mini-batch SGD

Mini-batch: выбираем подмножество $\mathcal{B}_k \subset \{1, \dots, n\}$ размера b :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

Дисперсия mini-batch уменьшается с ростом b :

$$\mathbb{E} \left\| \frac{1}{b} \sum_{i \in \mathcal{B}} \nabla f_i(w) - \nabla f(w) \right\|^2 = \frac{\sigma^2}{b}, \quad \sigma^2 = \frac{1}{n} \sum_i \|\nabla f_i(w) - \nabla f(w)\|^2$$

Mini-batch SGD

Mini-batch: выбираем подмножество $\mathcal{B}_k \subset \{1, \dots, n\}$ размера b :

$$w_{k+1} = w_k - \alpha_k \cdot \frac{1}{b} \sum_{i \in \mathcal{B}_k} \nabla f_i(w_k)$$

Дисперсия mini-batch уменьшается с ростом b :

$$\mathbb{E} \left\| \frac{1}{b} \sum_{i \in \mathcal{B}} \nabla f_i(w) - \nabla f(w) \right\|^2 = \frac{\sigma^2}{b}, \quad \sigma^2 = \frac{1}{n} \sum_i \|\nabla f_i(w) - \nabla f(w)\|^2$$

Стоимость: $O(b)$ вместо $O(n)$ $\rightarrow$ при $b \ll n$ огромная экономия. **Компромисс:** большой $b \rightarrow$ меньше шума $\rightarrow$ можно брать больший α , но стоимость итерации растёт.

Анализ сходимости

Базовое неравенство SGD

Предположения: f — выпуклая, L -гладкая; $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$.

Лемма (базовое неравенство). Для любого w^* :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

Базовое неравенство SGD

Предположения: f — выпуклая, L -гладкая; $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$.

Лемма (базовое неравенство). Для любого w^* :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

Доказательство:

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём $\mathbb{E}_{i_k}[\cdot \mid w_k]$:

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$ (выпуклость)

Базовое неравенство SGD

Предположения: f — выпуклая, L -гладкая; $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$.

Лемма (базовое неравенство). Для любого w^* :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

Доказательство:

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём $\mathbb{E}_{i_k}[\cdot \mid w_k]$:

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$ (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$. $\square$

Базовое неравенство SGD

Предположения: f — выпуклая, L -гладкая; $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$.

Лемма (базовое неравенство). Для любого w^* :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

Доказательство:

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём $\mathbb{E}_{i_k}[\cdot \mid w_k]$:

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$ (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$. $\square$

Базовое неравенство SGD

Предположения: f — выпуклая, L -гладкая; $\mathbb{E}_{i_k} \|\nabla f_{i_k}(w_k)\|^2 \leq G^2$.

Лемма (базовое неравенство). Для любого w^* :

$$\mathbb{E} \|w_{k+1} - w^*\|^2 \leq \|w_k - w^*\|^2 - 2\alpha_k(f(w_k) - f^*) + \alpha_k^2 G^2$$

Доказательство:

$$\|w_{k+1} - w^*\|^2 = \|w_k - \alpha_k g_k - w^*\|^2 = \|w_k - w^*\|^2 - 2\alpha_k \langle g_k, w_k - w^* \rangle + \alpha_k^2 \|g_k\|^2$$

Берём $\mathbb{E}_{i_k}[\cdot \mid w_k]$:

- $\mathbb{E} \langle g_k, w_k - w^* \rangle = \langle \nabla f(w_k), w_k - w^* \rangle \geq f(w_k) - f^*$ (выпуклость)
- $\mathbb{E} \|g_k\|^2 \leq G^2$. $\square$

Связь с субградиентным методом: та же формула! SGD = стохастический субградиентный метод.

Сходимость: убывающий шаг (выпуклый случай)

Теорема. Для выпуклой f при $\alpha_k = \frac{\alpha}{\sqrt{k+1}}$:

$$\mathbb{E} \left[\frac{1}{K} \sum_{k=0}^{K-1} f(w_k) \right] - f^* \leq \frac{R^2 + \alpha^2 G^2 \ln K}{2\alpha\sqrt{K}} = O\left(\frac{RG}{\sqrt{K}}\right)$$

при оптимальном $\alpha = R/G$, где $R = \|w_0 - w^*\|$.

Сходимость: убывающий шаг (выпуклый случай)

Теорема. Для выпуклой f при $\alpha_k = \frac{\alpha}{\sqrt{k+1}}$:

$$\mathbb{E} \left[\frac{1}{K} \sum_{k=0}^{K-1} f(w_k) \right] - f^* \leq \frac{R^2 + \alpha^2 G^2 \ln K}{2\alpha\sqrt{K}} = O\left(\frac{RG}{\sqrt{K}}\right)$$

при оптимальном $\alpha = R/G$, где $R = \|w_0 - w^*\|$.

Доказательство (телескоп базового неравенства):

Суммируем по $k = 0, \dots, K-1$, делим на K , применяем выпуклость:

$$f\left(\frac{1}{K} \sum_k w_k\right) - f^* \leq \frac{1}{K} \sum_k (f(w_k) - f^*) \leq \frac{R^2}{2\alpha K} \sum_k \frac{1}{\sqrt{k+1}} + \frac{\alpha G^2}{2K} \sum_k \frac{1}{\sqrt{k+1}}$$

используя $\sum_{k=0}^{K-1} \frac{1}{\sqrt{k+1}} \leq 2\sqrt{K}$. $\square$

Шумовой пол: постоянный шаг

При $\alpha_k = \alpha = \text{const}$ телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

Шумовой пол: постоянный шаг

При $\alpha_k = \alpha = \text{const}$ телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

При $K \rightarrow \infty$:

$$\boxed{\lim_{K \rightarrow \infty} \mathbb{E}[f(w_K) - f^*] \leq \frac{\alpha G^2}{2}}$$

Это шумовой пол (noise floor): SGD с постоянным шагом **не сходится к x^*** , а колеблется в окрестности радиуса $\sim \alpha G$.

Шумовой пол: постоянный шаг

При $\alpha_k = \alpha = \text{const}$ телескоп даёт:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(w_k) - f^*] \leq \frac{R^2}{2\alpha K} + \frac{\alpha G^2}{2}$$

При $K \rightarrow \infty$:

$$\lim_{K \rightarrow \infty} \mathbb{E}[f(w_K) - f^*] \leq \frac{\alpha G^2}{2}$$

Это шумовой пол (noise floor): SGD с постоянным шагом **не сходится к x^*** , а колеблется в окрестности радиуса $\sim \alpha G$.

Убывающий шаг: $\alpha_k \rightarrow 0 \rightarrow$ сходимость к x^* , но медленнее в начале.

Постоянный шаг: быстрый прогресс в начале $\rightarrow$ пол $O(\alpha)$. Популярен в ML (пол пропорционален «шуму данных»).

Сходимость: сильно выпуклый случай

Теорема. Для μ -сильно выпуклой f при $\alpha_k = \frac{2}{\mu(k+1)}$:

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$ — взвешенное среднее.

Сходимость: сильно выпуклый случай

Теорема. Для μ -сильно выпуклой f при $\alpha_k = \frac{2}{\mu(k+1)}$:

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$ — взвешенное среднее.

Сравнение: GD для сильно выпуклой даёт **линейную** сходимость $O(e^{-\mu k/L})$.

SGD даёт $O(1/K)$ — субмарковскую. **Разрыв!**

Сходимость: сильно выпуклый случай

Теорема. Для μ -сильно выпуклой f при $\alpha_k = \frac{2}{\mu(k+1)}$:

$$\mathbb{E}[f(\bar{w}_K) - f^*] \leq \frac{2LG^2}{\mu^2 K}$$

где $\bar{w}_K = \frac{2}{K(K+1)} \sum_{k=0}^{K-1} (k+1)w_k$ — взвешенное среднее.

Сравнение: GD для сильно выпуклой даёт **линейную** сходимость $O(e^{-\mu k/L})$.

SGD даёт $O(1/K)$ — субмарковскую. **Разрыв!**

Причина разрыва: неустранимый шум $\sigma^2 > 0$ — мы не используем прошлые градиенты. Решение: **Variance Reduction** (Лекция 10: SVRG, SAG, SARAH).

Расписания шагов и батч

Расписания шагов на практике

Step decay: уменьшать α в $10\times$ каждые T эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

Расписания шагов на практике

Step decay: уменьшать α в $10\times$ каждые T эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

Cosine annealing (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left(1 + \cos \frac{\pi k}{K} \right)$$

Расписания шагов на практике

Step decay: уменьшать α в $10\times$ каждые T эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

Cosine annealing (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left(1 + \cos \frac{\pi k}{K} \right)$$

Warmup: первые T_{warm} шагов α **растёт** от 0 до $\alpha_{\max}$.

Обязателен для трансформеров: большой батч + случайная инициализация $\rightarrow$ нестабильные ранние градиенты.

Расписания шагов на практике

Step decay: уменьшать α в $10\times$ каждые T эпох.

$$\alpha_k = \alpha_0 \cdot \gamma^{\lfloor k/T \rfloor}, \quad \gamma = 0.1$$

Стандарт для ResNet/ImageNet.

Cosine annealing (популярно в NLP/LLM):

$$\alpha_k = \alpha_{\min} + \frac{\alpha_{\max} - \alpha_{\min}}{2} \left(1 + \cos \frac{\pi k}{K} \right)$$

Warmup: первые T_{warm} шагов α **растёт** от 0 до $\alpha_{\max}$.

Обязателен для трансформеров: большой батч + случайная инициализация $\rightarrow$ нестабильные ранние градиенты.

Практика: шаги подбираются под b , архитектуру и датасет. Нет универсального рецепта.

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При $b > b_{\text{crit}}$ прирост шума мал, увеличение α не помогает.

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При $b > b_{\text{crit}}$ прирост шума мал, увеличение α не помогает.

Gradient noise scale (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный $b \approx \mathcal{N}$ для баланса параллелизм/обновления.

Типичные значения:

Задача	b
CV (ResNet)	256–4096
NLP (BERT)	256–2048
LLM (GPT-3)	$\sim 3,2\text{M}$ токенов

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При $b > b_{\text{crit}}$ прирост шума мал, увеличение α не помогает.

Gradient noise scale (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный $b \approx \mathcal{N}$ для баланса параллелизм/обновления.

Типичные значения:

Задача	b
CV (ResNet)	256–4096
NLP (BERT)	256–2048
LLM (GPT-3)	$\sim 3,2\text{M}$ токенов

Очень большие батчи требуют:

- linear scaling rule

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При $b > b_{\text{crit}}$ прирост шума мал, увеличение α не помогает.

Gradient noise scale (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный $b \approx \mathcal{N}$ для баланса параллелизм/обновления.

Типичные значения:

Задача	b
CV (ResNet)	256–4096
NLP (BERT)	256–2048
LLM (GPT-3)	$\sim 3,2\text{M}$ токенов

Очень большие батчи требуют:

- linear scaling rule
- warmup (обязателен!)

Эффект размера батча

Дисперсия: $\mathbb{E}\|g_{\mathcal{B}} - \nabla f\|^2 = \sigma^2/b$.

Линейное масштабирование шага (Facebook AI, 2017):

$$b \rightarrow kb \quad \Rightarrow \quad \alpha \rightarrow k\alpha$$

Работает до **критического размера батча**:

$$b_{\text{crit}} \sim \frac{\sigma^2}{\|\nabla f\|^2}$$

При $b > b_{\text{crit}}$ прирост шума мал, увеличение α не помогает.

Gradient noise scale (McCandlish et al., 2018):

$$\mathcal{N} = \frac{\text{tr}(\Sigma)}{\|\nabla f\|^2}$$

Оптимальный $b \approx \mathcal{N}$ для баланса параллелизм/обновления.

Типичные значения:

Задача	b
CV (ResNet)	256–4096
NLP (BERT)	256–2048
LLM (GPT-3)	$\sim 3,2\text{M}$ токенов

Очень большие батчи требуют:

- linear scaling rule
- warmup (обязателен!)
- cosine annealing