



Снижение дисперсии. SVRG, SAG, SAGA,
SARAH

Даня Меркулов

ФКН ВШЭ

Проблема SGD: шумовой пол

Напоминание: SGD не сходится линейно

Задача: $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$, f — μ -сильно выпуклая, L -гладкая.

Напоминание: SGD не сходится линейно

Задача: $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$, f — μ -сильно выпуклая, L -гладкая.

GD: $O(e^{-\mu k/L})$ — **линейная** сходимость. Требуется $O(n)$ на итерацию.

SGD с убывающим шагом $\alpha_k = 2/(\mu(k+1))$:

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

Напоминание: SGD не сходится линейно

Задача: $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$, f — μ -сильно выпуклая, L -гладкая.

GD: $O(e^{-\mu k/L})$ — **линейная** сходимость. Требуется $O(n)$ на итерацию.

SGD с убывающим шагом $\alpha_k = 2/(\mu(k+1))$:

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

Шумовой пол SGD с постоянным шагом $\alpha = \text{const}$:

$$\lim_{k \rightarrow \infty} \mathbb{E}[f(w_k) - f^*] \leq \frac{\alpha G^2}{2}$$

Напоминание: SGD не сходится линейно

Задача: $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$, f — μ -сильно выпуклая, L -гладкая.

GD: $O(e^{-\mu k/L})$ — **линейная** сходимость. Требуется $O(n)$ на итерацию.

SGD с убывающим шагом $\alpha_k = 2/(\mu(k+1))$:

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

Шумовой пол SGD с постоянным шагом $\alpha = \text{const}$:

$$\lim_{k \rightarrow \infty} \mathbb{E}[f(w_k) - f^*] \leq \frac{\alpha G^2}{2}$$

Проблема: даже в минимуме w^* стохастический градиент имеет ненулевую дисперсию:

$$\mathbb{E}_{i_k} \left\| \nabla f_{i_k}(w^*) \right\|^2 = \sigma^2 > 0$$

Вопрос: можно ли добиться линейной сходимости с ценой $O(1)$ на итерацию?

Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо $g_k = \nabla f_{i_k}(w_k)$ использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где $\tilde{w}$ — «эталонная» точка, $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$.

Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо $g_k = \nabla f_{i_k}(w_k)$ использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где $\tilde{w}$ — «эталонная» точка, $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$.

Несмещённость: $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k) - \nabla f(\tilde{w}) + \nabla f(\tilde{w}) = \nabla f(w_k) \boxtimes$

Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо $g_k = \nabla f_{i_k}(w_k)$ использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где $\tilde{w}$ — «эталонная» точка, $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$.

Несмещённость: $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k) - \nabla f(\tilde{w}) + \nabla f(\tilde{w}) = \nabla f(w_k) \quad \boxtimes$

Дисперсия убывает! Когда $w_k \rightarrow w^*$ и $\tilde{w} \rightarrow w^*$:

$$\nabla f_{i_k}(w_k) \approx \nabla f_{i_k}(\tilde{w}) \quad \Rightarrow \quad \hat{g}_k \approx 0$$

В оптимуме $w_k = \tilde{w} = w^*$: $\hat{g}_k = 0$ — **нулевая дисперсия!**

SVRG: Stochastic Variance Reduced Gradient

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)
3. **Внутренний цикл** ($k = 1, \dots, m$):

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ вычислений)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$
 - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ вычислений)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$
 - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
 - $w_k = w_{k-1} - \alpha \hat{g}_k$

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$
 - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
 - $w_k = w_{k-1} - \alpha \hat{g}_k$
4. $w_0^{(s+1)} \leftarrow w_m$ (или среднее по внутреннему циклу)

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$
 - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
 - $w_k = w_{k-1} - \alpha \hat{g}_k$
4. $w_0^{(s+1)} \leftarrow w_m$ (или среднее по внутреннему циклу)

Алгоритм SVRG

SVRG (Johnson & Zhang, NeurIPS 2013):

Внешний цикл (эпоха $s = 1, 2, \dots$):

1. $\tilde{w} \leftarrow w_0^{(s)}$ — эталонная точка
2. $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$ — полный градиент ($O(n)$ **вычислений**)
3. **Внутренний цикл** ($k = 1, \dots, m$):
 - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$
 - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
 - $w_k = w_{k-1} - \alpha \hat{g}_k$
4. $w_0^{(s+1)} \leftarrow w_m$ (или среднее по внутреннему циклу)

Параметры: внутренний цикл $m = O(n/\kappa)$, шаг $\alpha = O(1/L)$.

Стоимость эпохи: $O(n)$ (полный градиент) + $O(m)$ (внутр. цикл) = $O(n)$ — как одна итерация GD.

Сходимость SVRG

Теорема (Johnson & Zhang, 2013). Для μ -сильно выпуклой L -гладкой f ,
при $m = 20L/\mu$ и $\alpha = 1/(10L)$:

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

Сходимость SVRG

Теорема (Johnson & Zhang, 2013). Для μ -сильно выпуклой L -гладкой f ,
при $m = 20L/\mu$ и $\alpha = 1/(10L)$:

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

Геометрическая сходимость за эпоху (коэффициент $\rho = 0.5$)!

Сходимость SVRG

Теорема (Johnson & Zhang, 2013). Для μ -сильно выпуклой L -гладкой f ,
при $m = 20L/\mu$ и $\alpha = 1/(10L)$:

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

Геометрическая сходимость за эпоху (коэффициент $\rho = 0.5$)!

Суммарное число вычислений ∇f_i до ε -точности:

$$T = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right) = O((n + \kappa) \log \frac{1}{\varepsilon})$$

Сходимость SVRG

Теорема (Johnson & Zhang, 2013). Для μ -сильно выпуклой L -гладкой f , при $m = 20L/\mu$ и $\alpha = 1/(10L)$:

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

Геометрическая сходимость за эпоху (коэффициент $\rho = 0.5$)!

Суммарное число вычислений ∇f_i до ε -точности:

$$T = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right) = O((n + \kappa) \log \frac{1}{\varepsilon})$$

Сравнение:

Метод	T до ε -точности
GD	$O(n\kappa \log(1/\varepsilon))$
SGD	$O(\kappa^2/\varepsilon)$ — нелинейный!
SVRG	$O((n + \kappa) \log(1/\varepsilon))$ ☒

Почему SVRG работает: ключевая лемма

Лемма (убывание дисперсии). Для L -гладкой f_i :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

Почему SVRG работает: ключевая лемма

Лемма (убывание дисперсии). Для L -гладкой f_i :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

Доказательство (идея):

Из несмещённости: $\|\hat{g}_k\|^2 \leq 2\|\nabla f_{i_k}(w_k) - \nabla f_{i_k}(w^*)\|^2 + 2\|\nabla f_{i_k}(\tilde{w}) - \nabla f_{i_k}(w^*)\|^2$.

Из L -гладкости каждого f_i (координатное неравенство):

$$\mathbb{E}_i \|\nabla f_i(w) - \nabla f_i(w^*)\|^2 \leq 2L(f(w) - f^*)$$

Складывая: $\mathbb{E} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$. $\square$

Почему SVRG работает: ключевая лемма

Лемма (убывание дисперсии). Для L -гладкой f_i :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

Доказательство (идея):

Из несмещённости: $\|\hat{g}_k\|^2 \leq 2\|\nabla f_{i_k}(w_k) - \nabla f_{i_k}(w^*)\|^2 + 2\|\nabla f_{i_k}(\tilde{w}) - \nabla f_{i_k}(w^*)\|^2$.

Из L -гладкости каждого f_i (координатное неравенство):

$$\mathbb{E}_i \|\nabla f_i(w) - \nabla f_i(w^*)\|^2 \leq 2L(f(w) - f^*)$$

Складываем: $\mathbb{E}\|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$. $\square$

Интерпретация: когда w_{k-1} и $\tilde{w}$ близки к w^* , дисперсия мала $\rightarrow$ SVRG сходится линейно.

SVRG vs GD: когда выгоднее?

Обе имеют стоимость $O(n)$ за эпоху. Разница в числе эпох:

- GD: $O(\kappa \log(1/\varepsilon))$ эпох

SVRG vs GD: когда выгоднее?

Обе имеют стоимость $O(n)$ за эпоху. Разница в числе эпох:

- GD: $O(\kappa \log(1/\varepsilon))$ эпох
- SVRG: $O((1 + \kappa/n) \log(1/\varepsilon))$ эпох

SVRG vs GD: когда выгоднее?

Обе имеют стоимость $O(n)$ за эпоху. Разница в числе эпох:

- GD: $O(\kappa \log(1/\varepsilon))$ эпох
- SVRG: $O((1 + \kappa/n) \log(1/\varepsilon))$ эпох

SVRG vs GD: когда выгоднее?

Обе имеют стоимость $O(n)$ за эпоху. Разница в числе эпох:

- GD: $O(\kappa \log(1/\varepsilon))$ эпох
- SVRG: $O((1 + \kappa/n) \log(1/\varepsilon))$ эпох

SVRG лучше GD когда $\kappa \ll n$:

При $n = 10^6$, $\kappa = 10^3$: SVRG в 10^3 раз быстрее GD!

Типичный случай ML: данных много ($n \gg 1$),
обусловленность умеренная ($\kappa \sim 10^2$ - 10^3).

SVRG не лучше GD когда $\kappa \gg n$:

При $n = 10^2$, $\kappa = 10^4$: $n + \kappa \approx \kappa \rightarrow O(\kappa \log(1/\varepsilon))$ — как GD.

Нейросети: n может быть малым при κ огромном.

SVRG vs GD: когда выгоднее?

Обе имеют стоимость $O(n)$ за эпоху. Разница в числе эпох:

- GD: $O(\kappa \log(1/\varepsilon))$ эпох
- SVRG: $O((1 + \kappa/n) \log(1/\varepsilon))$ эпох

SVRG лучше GD когда $\kappa \ll n$:

При $n = 10^6$, $\kappa = 10^3$: SVRG в 10^3 раз быстрее GD!

Типичный случай ML: данных много ($n \gg 1$),
обусловленность умеренная ($\kappa \sim 10^2$ - 10^3).

Правило золотого сечения: SVRG оптимален когда $n \approx \kappa$.

SVRG не лучше GD когда $\kappa \gg n$:

При $n = 10^2$, $\kappa = 10^4$: $n + \kappa \approx \kappa \rightarrow O(\kappa \log(1/\varepsilon))$ — как GD.

Нейросети: n может быть малым при κ огромном.

SAG и SAGA: память vs несмещённость

SAG: Stochastic Average Gradient

SAG (Le Roux, Schmidt, Bach, JMLR 2012).

Идея: хранить таблицу последних градиентов $y_i = \nabla f_i(w_i^{\text{last}})$ для всех i .

SAG: Stochastic Average Gradient

SAG (Le Roux, Schmidt, Bach, JMLR 2012).

Идея: хранить таблицу последних градиентов $y_i = \nabla f_i(w_i^{\text{last}})$ для всех i .

Алгоритм: 1. Инициализация: $y_i^{(0)} = 0$ для всех i , $g^{(0)} = 0$ 2. Для $k = 1, 2, \dots$: - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$ - $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$ (обновить один) - $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$ (обновить среднее) - $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

SAG: Stochastic Average Gradient

SAG (Le Roux, Schmidt, Bach, JMLR 2012).

Идея: хранить таблицу последних градиентов $y_i = \nabla f_i(w_i^{\text{last}})$ для всех i .

Алгоритм: 1. Инициализация: $y_i^{(0)} = 0$ для всех i , $g^{(0)} = 0$ 2. Для $k = 1, 2, \dots$: - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$ - $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$ (обновить один) - $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$ (обновить среднее) - $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

Смещённость: $\mathbb{E}[g^{(k)}] \neq \nabla f(w_k)$ (используются устаревшие y_j для $j \neq i_k$).

Тем не менее: SAG сходится линейно! (Используется «запас» между итерациями.)

SAG: Stochastic Average Gradient

SAG (Le Roux, Schmidt, Bach, JMLR 2012).

Идея: хранить таблицу последних градиентов $y_i = \nabla f_i(w_i^{\text{last}})$ для всех i .

Алгоритм: 1. Инициализация: $y_i^{(0)} = 0$ для всех i , $g^{(0)} = 0$ 2. Для $k = 1, 2, \dots$: - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$ - $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$ (обновить один) - $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$ (обновить среднее) - $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

Смещённость: $\mathbb{E}[g^{(k)}] \neq \nabla f(w_k)$ (используются устаревшие y_j для $j \neq i_k$).

Тем не менее: SAG сходится линейно! (Используется «запас» между итерациями.)

Недостаток: память $O(nd)$ — для нейросетей с $d = 10^8$ неприемлемо.

SAGA: несмещённый SAG

SAGA (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

Исправление смещения: вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

SAGA: несмещённый SAG

SAGA (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

Исправление смещения: вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

Несмещённость:

$$\mathbb{E}_{i_k}[g_k \mid w_k] = \nabla f(w_k) - \mathbb{E}[\phi_{i_k}] + \frac{1}{n} \sum_j \phi_j = \nabla f(w_k) \checkmark$$

SAGA: несмещённый SAG

SAGA (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

Исправление смещения: вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

Несмещённость:

$$\mathbb{E}_{i_k}[g_k \mid w_k] = \nabla f(w_k) - \mathbb{E}[\phi_{i_k}] + \frac{1}{n} \sum_j \phi_j = \nabla f(w_k) \checkmark$$

После обновления: $\phi_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$.

Преимущества перед SAG: - Несмещённость → **поддерживает проксимальные шаги** (SAGA + prox для Lasso!) - Лучшие константы в теоремах - Практически: чуть более стабильная сходимость

Память: $O(nd)$ — та же проблема.

SAG vs SAGA vs SVRG: сравнение

Свойство	SAG	SAGA	SVRG
Несмещённость	☒	☒	☒
Прокс-совместимость	☒	☒	☒
Память	$O(nd)$	$O(nd)$	$O(d)$
Скорость (с.в.)	$O((n + \kappa) \log(1/\varepsilon))$	то же	то же
Внешний цикл	нет	нет	есть ($O(n)$)
Реализация	просто	просто	сложнее

SAG vs SAGA vs SVRG: сравнение

Свойство	SAG	SAGA	SVRG
Несмещённость	☒	☒	☒
Прокс-совместимость	☒	☒	☒
Память	$O(nd)$	$O(nd)$	$O(d)$
Скорость (с.в.)	$O((n + \kappa) \log(1/\varepsilon))$	то же	то же
Внешний цикл	нет	нет	есть ($O(n)$)
Реализация	просто	просто	сложнее

SVRG: лучшая память, требует полный градиент раз в m шагов.

SAGA: проще, несмещённость, плохая память при больших d .

SAG: смещённый, плохая память — устарел (SAGA строго лучше).

SARAH: рекурсивный вариант

SARAH: Stochastic Recursive Gradient

SARAH (Nguyen et al., ICML 2017).

SARAH: Stochastic Recursive Gradient

SARAH (Nguyen et al., ICML 2017).

Идея: рекурсивно отслеживать изменение градиента вместо хранения таблицы.

Внешний цикл (эпоха): 1. $\tilde{w} \leftarrow w_0$ (эталон) 2. $v_0 \leftarrow \nabla f(\tilde{w})$ (**полный** градиент, $O(n)$) 3. $w_1 \leftarrow \tilde{w} - \alpha v_0$

Внутренний цикл ($k = 1, \dots, m$): - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$ - $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$ (**рекурсивно!**) - $w_{k+1} = w_k - \alpha v_k$

SARAH: Stochastic Recursive Gradient

SARAH (Nguyen et al., ICML 2017).

Идея: рекурсивно отслеживать изменение градиента вместо хранения таблицы.

Внешний цикл (эпоха): 1. $\tilde{w} \leftarrow w_0$ (эталон) 2. $v_0 \leftarrow \nabla f(\tilde{w})$ (**полный** градиент, $O(n)$) 3. $w_1 \leftarrow \tilde{w} - \alpha v_0$

Внутренний цикл ($k = 1, \dots, m$): - Выбрать $i_k \sim \text{Uniform}\{1, \dots, n\}$ - $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$ (**рекурсивно!**) - $w_{k+1} = w_k - \alpha v_k$

Ключевое: v_k обновляется рекурсивно — не нужно хранить n градиентов.

Память: $O(d)$ — как SVRG.

SVRG vs SARAH: разница в оценке

SVRG: якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ($\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$) - Дисперсия убывает по ходу внешних эпох

SARAH: якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ($\mathbb{E}[v_k] \neq \nabla f(w_k)$) - Но дисперсия убывает **внутри эпохи**

SVRG vs SARAH: разница в оценке

SVRG: якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ($\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$) - Дисперсия убывает по ходу внешних эпох

SARAH: якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ($\mathbb{E}[v_k] \neq \nabla f(w_k)$) - Но дисперсия убывает **внутри эпохи**

Интересное свойство SARAH:

$$\mathbb{E}\|v_k - \nabla f(w_k)\|^2 \leq L^2 \sum_{j=0}^{k-1} \mathbb{E}\|w_{j+1} - w_j\|^2$$

По мере схождения $w_k \rightarrow w^*$: шаги $\|w_{j+1} - w_j\| \rightarrow 0 \rightarrow$ смещение убывает!

SVRG vs SARAH: разница в оценке

SVRG: якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ($\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$) - Дисперсия убывает по ходу внешних эпох

SARAH: якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ($\mathbb{E}[v_k] \neq \nabla f(w_k)$) - Но дисперсия убывает **внутри эпохи**

Интересное свойство SARAH:

$$\mathbb{E}\|v_k - \nabla f(w_k)\|^2 \leq L^2 \sum_{j=0}^{k-1} \mathbb{E}\|w_{j+1} - w_j\|^2$$

По мере схождения $w_k \rightarrow w^*$: шаги $\|w_{j+1} - w_j\| \rightarrow 0 \rightarrow$ смещение убывает!

Практика: SARAH немного лучше SVRG в некоторых задачах (меньше вариация), но анализ сложнее.

Итог: когда что использовать

Большая сравнительная таблица

Метод	Скорость	Стоимость итер.	Память	Прокс
GD	$O(e^{-\mu k/L})$	$O(n)$	$O(d)$	☒
AGD	$O(e^{-k/\sqrt{\kappa}})$	$O(n)$	$O(d)$	☒
SGD	$O(1/(\mu K)) \leftarrow$ нелин.	$O(1)$	$O(d)$	☒
SAG	$O(e^{-k/(8\max(n,\kappa))})$	$O(1)$ амортиз.	$O(nd)$	☒
SAGA	то же	$O(1)$ амортиз.	$O(nd)$	☒
SVRG	$O((1/2)^{\text{эпоха}})$	$O(1)$ амортиз.	$O(d)$	☒
SARAH	аналог SVRG	$O(1)$ амортиз.	$O(d)$	☒

Большая сравнительная таблица

Метод	Скорость	Стоимость итер.	Память	Прокс
GD	$O(e^{-\mu k/L})$	$O(n)$	$O(d)$	☒
AGD	$O(e^{-k/\sqrt{\kappa}})$	$O(n)$	$O(d)$	☒
SGD	$O(1/(\mu K)) \leftarrow$ нелин.	$O(1)$	$O(d)$	☒
SAG	$O(e^{-k/(8\max(n,\kappa))})$	$O(1)$ амортиз.	$O(nd)$	☒
SAGA	то же	$O(1)$ амортиз.	$O(nd)$	☒
SVRG	$O((1/2)^{\text{эпоха}})$	$O(1)$ амортиз.	$O(d)$	☒
SARAH	аналог SVRG	$O(1)$ амортиз.	$O(d)$	☒

Амортизированно: $O(1)$ на итерацию при $m = O(n)$.

Практические рекомендации

Почему VR редко используют в DL?

Ситуация	Рекомендация
$n \leq \kappa$ (мало данных)	GD или AGD
$n \gg \kappa$ (много данных)	SGD с большим батчем
$n \approx \kappa$	SVRG или SARAH
Lasso/Group Lasso	SAGA + prox
Нейросети $d = 10^9$	SVRG (не SAGA!)
Deep learning вообще	Adam / SGD (VR не прижился)

Практические рекомендации

Ситуация	Рекомендация
$n \leq \kappa$ (мало данных)	GD или AGD
$n \gg \kappa$ (много данных)	SGD с большим батчем
$n \approx \kappa$	SVRG или SARAH
Lasso/Group Lasso	SAGA + prox
Нейросети $d = 10^9$	SVRG (не SAGA!)
Deep learning вообще	Adam / SGD (VR не прижился)

Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных $\rightarrow$ f меняется каждую эпоху

Практические рекомендации

Ситуация	Рекомендация
$n \leq \kappa$ (мало данных)	GD или AGD
$n \gg \kappa$ (много данных)	SGD с большим батчем
$n \approx \kappa$	SVRG или SARAH
Lasso/Group Lasso	SAGA + prox
Нейросети $d = 10^9$	SVRG (не SAGA!)
Deep learning вообще	Adam / SGD (VR не прижился)

Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных $\rightarrow f$ меняется каждую эпоху
2. **Стоимость хранения:** $O(nd)$ неприемлемо

Практические рекомендации

Ситуация	Рекомендация
$n \leq \kappa$ (мало данных)	GD или AGD
$n \gg \kappa$ (много данных)	SGD с большим батчем
$n \approx \kappa$	SVRG или SARAH
Lasso/Group Lasso	SAGA + prox
Нейросети $d = 10^9$	SVRG (не SAGA!)
Deep learning вообще	Adam / SGD (VR не прижился)

Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных $\rightarrow f$ меняется каждую эпоху
2. **Стоимость хранения:** $O(nd)$ неприемлемо
3. **Нелинейность:** большие нейросети не ведут себя как «хорошие» μ -с.в. функции

Практические рекомендации

Ситуация	Рекомендация
$n \leq \kappa$ (мало данных)	GD или AGD
$n \gg \kappa$ (много данных)	SGD с большим батчем
$n \approx \kappa$	SVRG или SARAH
Lasso/Group Lasso	SAGA + prox
Нейросети $d = 10^9$	SVRG (не SAGA!)
Deep learning вообще	Adam / SGD (VR не прижился)

Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных $\rightarrow f$ меняется каждую эпоху
2. **Стоимость хранения:** $O(nd)$ неприемлемо
3. **Нелинейность:** большие нейросети не ведут себя как «хорошие» μ -с.в. функции
4. **Adam работает лучше** на практике

Ключевые формулы

Объект	Формула
SVRG градиент	$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
Несмещённость	$\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$
Дисперсия SVRG	$\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$
Стоимость SVRG	$O((n + \kappa) \log(1/\varepsilon))$
SAGA градиент	$g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$
SARAH рекурсия	$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$

Ключевые формулы

Объект	Формула
SVRG градиент	$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
Несмещённость	$\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$
Дисперсия SVRG	$\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$
Стоимость SVRG	$O((n + \kappa) \log(1/\varepsilon))$
SAGA градиент	$g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$
SARAH рекурсия	$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$

Связи с курсом:

- Л9 (SGD): шумовой пол $\rightarrow$ VR устраняет

Ключевые формулы

Объект	Формула
SVRG градиент	$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
Несмещённость	$\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$
Дисперсия SVRG	$\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$
Стоимость SVRG	$O((n + \kappa) \log(1/\varepsilon))$
SAGA градиент	$g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$
SARAH рекурсия	$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$

Связи с курсом:

- Л9 (SGD): шумовой пол $\rightarrow$ VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR

Ключевые формулы

Объект	Формула
SVRG градиент	$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
Несмещённость	$\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$
Дисперсия SVRG	$\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$
Стоимость SVRG	$O((n + \kappa) \log(1/\varepsilon))$
SAGA градиент	$g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$
SARAH рекурсия	$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$

Связи с курсом:

- Л9 (SGD): шумовой пол $\rightarrow$ VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR
- Л8 (FISTA): Katyusha = SVRG + момент Нестерова $\rightarrow O((n + \sqrt{n\kappa}) \log(1/\varepsilon))$

Ключевые формулы

Объект	Формула
SVRG градиент	$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
Несмещённость	$\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$
Дисперсия SVRG	$\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$
Стоимость SVRG	$O((n + \kappa) \log(1/\varepsilon))$
SAGA градиент	$g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$
SARAH рекурсия	$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$

Связи с курсом:

- Л9 (SGD): шумовой пол $\rightarrow$ VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR
- Л8 (FISTA): Katyusha = SVRG + момент Нестерова $\rightarrow O((n + \sqrt{n\kappa}) \log(1/\varepsilon))$
- PhD: VR $\boxtimes$ Ли-Троттер для стохастических операторов!

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): hse26.fmin.xyz

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: рассмотрим Lasso: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите итерацию SAGA+прох для этой задачи (прокс-оператор для $\lambda \|\cdot\|_1$?).

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: рассмотрим Lasso: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для $\lambda \|\cdot\|_1$?).
2. При $n = 10^4$, $d = 10^3$, $\kappa = 10^2$: сколько итераций SAGA vs GD до $\varepsilon = 10^{-6}$?

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: рассмотрим Lasso: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для $\lambda \|\cdot\|_1$?).
2. При $n = 10^4$, $d = 10^3$, $\kappa = 10^2$: сколько итераций SAGA vs GD до $\varepsilon = 10^{-6}$?
3. Почему хранить таблицу $\phi_i \in \mathbb{R}^d$ затруднительно при $n = 10^6$, $d = 10^3$?

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: рассмотрим Lasso: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для $\lambda \|\cdot\|_1$?).
2. При $n = 10^4$, $d = 10^3$, $\kappa = 10^2$: сколько итераций SAGA vs GD до $\varepsilon = 10^{-6}$?
3. Почему хранить таблицу $\phi_i \in \mathbb{R}^d$ затруднительно при $n = 10^6$, $d = 10^3$?

Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: рассмотрим Lasso: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для $\lambda \|\cdot\|_1$?).
2. При $n = 10^4$, $d = 10^3$, $\kappa = 10^2$: сколько итераций SAGA vs GD до $\varepsilon = 10^{-6}$?
3. Почему хранить таблицу $\phi_i \in \mathbb{R}^d$ затруднительно при $n = 10^6$, $d = 10^3$?

Следующая лекция: Координатный спуск (RCD), ADMM, проксимальное расщепление.