



Снижение дисперсии. SVRG, SAG, SAGA,  
SARAH

Даня Меркулов

ФКН ВШЭ

## Проблема SGD: шумовой пол

## Напоминание: SGD не сходится линейно

**Задача:**  $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$ ,  $f$  —  $\mu$ -сильно выпуклая,  $L$ -гладкая.

## Напоминание: SGD не сходится линейно

**Задача:**  $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$ ,  $f$  —  $\mu$ -сильно выпуклая,  $L$ -гладкая.

**GD:**  $O(e^{-\mu k/L})$  — **линейная** сходимость. Требуется  $O(n)$  на итерацию.

**SGD с убывающим шагом**  $\alpha_k = 2/(\mu(k+1))$ :

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

## Напоминание: SGD не сходится линейно

**Задача:**  $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$ ,  $f$  —  $\mu$ -сильно выпуклая,  $L$ -гладкая.

**GD:**  $O(e^{-\mu k/L})$  — **линейная** сходимость. Требуется  $O(n)$  на итерацию.

**SGD с убывающим шагом**  $\alpha_k = 2/(\mu(k+1))$ :

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

**Шумовой пол SGD с постоянным шагом**  $\alpha = \text{const}$ :

$$\lim_{k \rightarrow \infty} \mathbb{E}[f(w_k) - f^*] \leq \frac{\alpha G^2}{2}$$

## Напоминание: SGD не сходится линейно

**Задача:**  $\min_w f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$ ,  $f$  —  $\mu$ -сильно выпуклая,  $L$ -гладкая.

**GD:**  $O(e^{-\mu k/L})$  — **линейная** сходимость. Требуется  $O(n)$  на итерацию.

**SGD с убывающим шагом**  $\alpha_k = 2/(\mu(k+1))$ :

$$\mathbb{E}[f(w_K) - f^*] \leq \frac{2LG^2}{\mu^2 K} = O\left(\frac{1}{\mu K}\right)$$

**Шумовой пол SGD с постоянным шагом**  $\alpha = \text{const}$ :

$$\lim_{k \rightarrow \infty} \mathbb{E}[f(w_k) - f^*] \leq \frac{\alpha G^2}{2}$$

**Проблема:** даже в минимуме  $w^*$  стохастический градиент имеет ненулевую дисперсию:

$$\mathbb{E}_{i_k} \left\| \nabla f_{i_k}(w^*) \right\|^2 = \sigma^2 > 0$$

**Вопрос:** можно ли добиться линейной сходимости с ценой  $O(1)$  на итерацию?

## Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

## Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо  $g_k = \nabla f_{i_k}(w_k)$  использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где  $\tilde{w}$  — «эталонная» точка,  $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$ .

## Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо  $g_k = \nabla f_{i_k}(w_k)$  использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где  $\tilde{w}$  — «эталонная» точка,  $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$ .

Несмещённость:  $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k) - \nabla f(\tilde{w}) + \nabla f(\tilde{w}) = \nabla f(w_k) \boxtimes$

## Ключевая идея: контрольные переменные

Ответ — **Variance Reduction** (снижение дисперсии).

Идея: вместо  $g_k = \nabla f_{i_k}(w_k)$  использовать **скорректированный** градиент:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \underbrace{\nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f}_{\text{поправка}}$$

где  $\tilde{w}$  — «эталонная» точка,  $\tilde{\nabla} f = \nabla f(\tilde{w}) = \frac{1}{n} \sum_i \nabla f_i(\tilde{w})$ .

Несмещённость:  $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k) - \nabla f(\tilde{w}) + \nabla f(\tilde{w}) = \nabla f(w_k) \quad \boxtimes$

Дисперсия убывает! Когда  $w_k \rightarrow w^*$  и  $\tilde{w} \rightarrow w^*$ :

$$\nabla f_{i_k}(w_k) \approx \nabla f_{i_k}(\tilde{w}) \quad \Rightarrow \quad \hat{g}_k \approx 0$$

В оптимуме  $w_k = \tilde{w} = w^*$ :  $\hat{g}_k = 0$  — **нулевая дисперсия!**

## SVRG: Stochastic Variance Reduced Gradient

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  вычислений)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$
  - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  вычислений)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$
  - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
  - $w_k = w_{k-1} - \alpha \hat{g}_k$

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$
  - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
  - $w_k = w_{k-1} - \alpha \hat{g}_k$
4.  $w_0^{(s+1)} \leftarrow w_m$  (или среднее по внутреннему циклу)

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$
  - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
  - $w_k = w_{k-1} - \alpha \hat{g}_k$
4.  $w_0^{(s+1)} \leftarrow w_m$  (или среднее по внутреннему циклу)

# Алгоритм SVRG

**SVRG** (Johnson & Zhang, NeurIPS 2013):

**Внешний цикл** (эпоха  $s = 1, 2, \dots$ ):

1.  $\tilde{w} \leftarrow w_0^{(s)}$  — эталонная точка
2.  $\tilde{\nabla} f \leftarrow \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{w})$  — полный градиент ( $O(n)$  **вычислений**)
3. **Внутренний цикл** ( $k = 1, \dots, m$ ):
  - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$
  - $\hat{g}_k = \nabla f_{i_k}(w_{k-1}) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$
  - $w_k = w_{k-1} - \alpha \hat{g}_k$
4.  $w_0^{(s+1)} \leftarrow w_m$  (или среднее по внутреннему циклу)

**Параметры:** внутренний цикл  $m = O(n/\kappa)$ , шаг  $\alpha = O(1/L)$ .

**Стоимость эпохи:**  $O(n)$  (полный градиент) +  $O(m)$  (внутр. цикл) =  $O(n)$  — как одна итерация GD.

## Сходимость SVRG

**Теорема** (Johnson & Zhang, 2013). Для  $\mu$ -сильно выпуклой  $L$ -гладкой  $f$ ,  
при  $m = 20L/\mu$  и  $\alpha = 1/(10L)$ :

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

## Сходимость SVRG

**Теорема** (Johnson & Zhang, 2013). Для  $\mu$ -сильно выпуклой  $L$ -гладкой  $f$ ,  
при  $m = 20L/\mu$  и  $\alpha = 1/(10L)$ :

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

**Геометрическая сходимость** за эпоху (коэффициент  $\rho = 0.5$ )!

## Сходимость SVRG

**Теорема** (Johnson & Zhang, 2013). Для  $\mu$ -сильно выпуклой  $L$ -гладкой  $f$ ,  
при  $m = 20L/\mu$  и  $\alpha = 1/(10L)$ :

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

**Геометрическая сходимость** за эпоху (коэффициент  $\rho = 0.5$ )!

Суммарное число вычислений  $\nabla f_i$  до  $\varepsilon$ -точности:

$$T = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right) = O((n + \kappa) \log \frac{1}{\varepsilon})$$

## Сходимость SVRG

**Теорема** (Johnson & Zhang, 2013). Для  $\mu$ -сильно выпуклой  $L$ -гладкой  $f$ , при  $m = 20L/\mu$  и  $\alpha = 1/(10L)$ :

$$\mathbb{E}[f(w_0^{(s+1)}) - f^*] \leq \frac{1}{2}(f(w_0^{(s)}) - f^*)$$

**Геометрическая сходимость** за эпоху (коэффициент  $\rho = 0.5$ )!

Суммарное число вычислений  $\nabla f_i$  до  $\varepsilon$ -точности:

$$T = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right) = O((n + \kappa) \log \frac{1}{\varepsilon})$$

**Сравнение:**

| Метод       | $T$ до $\varepsilon$ -точности          |
|-------------|-----------------------------------------|
| GD          | $O(n\kappa \log(1/\varepsilon))$        |
| SGD         | $O(\kappa^2/\varepsilon)$ — нелинейный! |
| <b>SVRG</b> | $O((n + \kappa) \log(1/\varepsilon))$ ☒ |

## Почему SVRG работает: ключевая лемма

**Лемма** (убывание дисперсии). Для  $L$ -гладкой  $f_i$ :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

## Почему SVRG работает: ключевая лемма

**Лемма** (убывание дисперсии). Для  $L$ -гладкой  $f_i$ :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

**Доказательство** (идея):

Из несмещённости:  $\|\hat{g}_k\|^2 \leq 2\|\nabla f_{i_k}(w_k) - \nabla f_{i_k}(w^*)\|^2 + 2\|\nabla f_{i_k}(\tilde{w}) - \nabla f_{i_k}(w^*)\|^2$ .

Из  $L$ -гладкости каждого  $f_i$  (координатное неравенство):

$$\mathbb{E}_i \|\nabla f_i(w) - \nabla f_i(w^*)\|^2 \leq 2L(f(w) - f^*)$$

Складывая:  $\mathbb{E} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$ .  $\square$

## Почему SVRG работает: ключевая лемма

**Лемма** (убывание дисперсии). Для  $L$ -гладкой  $f_i$ :

$$\mathbb{E}_{i_k} \|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$$

**Доказательство** (идея):

Из несмещённости:  $\|\hat{g}_k\|^2 \leq 2\|\nabla f_{i_k}(w_k) - \nabla f_{i_k}(w^*)\|^2 + 2\|\nabla f_{i_k}(\tilde{w}) - \nabla f_{i_k}(w^*)\|^2$ .

Из  $L$ -гладкости каждого  $f_i$  (координатное неравенство):

$$\mathbb{E}_i \|\nabla f_i(w) - \nabla f_i(w^*)\|^2 \leq 2L(f(w) - f^*)$$

Складываем:  $\mathbb{E}\|\hat{g}_k\|^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$ .  $\square$

**Интерпретация:** когда  $w_{k-1}$  и  $\tilde{w}$  близки к  $w^*$ , дисперсия мала  $\rightarrow$  SVRG сходится линейно.

## SVRG vs GD: когда выгоднее?

Обе имеют стоимость  $O(n)$  за эпоху. Разница в числе эпох:

- GD:  $O(\kappa \log(1/\varepsilon))$  эпох

## SVRG vs GD: когда выгоднее?

Обе имеют стоимость  $O(n)$  за эпоху. Разница в числе эпох:

- GD:  $O(\kappa \log(1/\varepsilon))$  эпох
- SVRG:  $O((1 + \kappa/n) \log(1/\varepsilon))$  эпох

## SVRG vs GD: когда выгоднее?

Обе имеют стоимость  $O(n)$  за эпоху. Разница в числе эпох:

- GD:  $O(\kappa \log(1/\varepsilon))$  эпох
- SVRG:  $O((1 + \kappa/n) \log(1/\varepsilon))$  эпох

## SVRG vs GD: когда выгоднее?

Обе имеют стоимость  $O(n)$  за эпоху. Разница в числе эпох:

- GD:  $O(\kappa \log(1/\varepsilon))$  эпох
- SVRG:  $O((1 + \kappa/n) \log(1/\varepsilon))$  эпох

**SVRG лучше GD** когда  $\kappa \ll n$ :

При  $n = 10^6$ ,  $\kappa = 10^3$ : SVRG в  $10^3$  раз быстрее GD!

*Типичный случай ML*: данных много ( $n \gg 1$ ),  
обусловленность умеренная ( $\kappa \sim 10^2$ - $10^3$ ).

**SVRG не лучше GD** когда  $\kappa \gg n$ :

При  $n = 10^2$ ,  $\kappa = 10^4$ :  $n + \kappa \approx \kappa \rightarrow O(\kappa \log(1/\varepsilon))$  — как GD.

*Нейросети*:  $n$  может быть малым при  $\kappa$  огромном.

## SVRG vs GD: когда выгоднее?

Обе имеют стоимость  $O(n)$  за эпоху. Разница в числе эпох:

- GD:  $O(\kappa \log(1/\varepsilon))$  эпох
- SVRG:  $O((1 + \kappa/n) \log(1/\varepsilon))$  эпох

**SVRG лучше GD** когда  $\kappa \ll n$ :

При  $n = 10^6$ ,  $\kappa = 10^3$ : SVRG в  $10^3$  раз быстрее GD!

*Типичный случай ML*: данных много ( $n \gg 1$ ),  
обусловленность умеренная ( $\kappa \sim 10^2$ - $10^3$ ).

**Правило золотого сечения**: SVRG оптимален когда  $n \approx \kappa$ .

**SVRG не лучше GD** когда  $\kappa \gg n$ :

При  $n = 10^2$ ,  $\kappa = 10^4$ :  $n + \kappa \approx \kappa \rightarrow O(\kappa \log(1/\varepsilon))$  — как GD.

*Нейросети*:  $n$  может быть малым при  $\kappa$  огромном.

## SAG и SAGA: память vs несмещённость

# SAG: Stochastic Average Gradient

**SAG** (Le Roux, Schmidt, Bach, JMLR 2012).

**Идея:** хранить таблицу последних градиентов  $y_i = \nabla f_i(w_i^{\text{last}})$  для всех  $i$ .

# SAG: Stochastic Average Gradient

**SAG** (Le Roux, Schmidt, Bach, JMLR 2012).

**Идея:** хранить таблицу последних градиентов  $y_i = \nabla f_i(w_i^{\text{last}})$  для всех  $i$ .

**Алгоритм:** 1. Инициализация:  $y_i^{(0)} = 0$  для всех  $i$ ,  $g^{(0)} = 0$  2. Для  $k = 1, 2, \dots$ : - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$  -  $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$  (обновить один) -  $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$  (обновить среднее) -  $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

# SAG: Stochastic Average Gradient

**SAG** (Le Roux, Schmidt, Bach, JMLR 2012).

**Идея:** хранить таблицу последних градиентов  $y_i = \nabla f_i(w_i^{\text{last}})$  для всех  $i$ .

**Алгоритм:** 1. Инициализация:  $y_i^{(0)} = 0$  для всех  $i$ ,  $g^{(0)} = 0$  2. Для  $k = 1, 2, \dots$ : - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$  -  $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$  (обновить один) -  $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$  (обновить среднее) -  $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

**Смещённость:**  $\mathbb{E}[g^{(k)}] \neq \nabla f(w_k)$  (используются устаревшие  $y_j$  для  $j \neq i_k$ ).

**Тем не менее:** SAG сходится линейно! (Используется «запас» между итерациями.)

# SAG: Stochastic Average Gradient

**SAG** (Le Roux, Schmidt, Bach, JMLR 2012).

**Идея:** хранить таблицу последних градиентов  $y_i = \nabla f_i(w_i^{\text{last}})$  для всех  $i$ .

**Алгоритм:** 1. Инициализация:  $y_i^{(0)} = 0$  для всех  $i$ ,  $g^{(0)} = 0$  2. Для  $k = 1, 2, \dots$ : - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$  -  $y_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$  (обновить один) -  $g^{(k)} \leftarrow g^{(k-1)} + \frac{1}{n}(y_{i_k}^{(k)} - y_{i_k}^{(k-1)})$  (обновить среднее) -  $w_{k+1} \leftarrow w_k - \alpha g^{(k)}$

**Смещённость:**  $\mathbb{E}[g^{(k)}] \neq \nabla f(w_k)$  (используются устаревшие  $y_j$  для  $j \neq i_k$ ).

**Тем не менее:** SAG сходится линейно! (Используется «запас» между итерациями.)

**Недостаток:** память  $O(nd)$  — для нейросетей с  $d = 10^8$  неприемлемо.

## SAGA: несмещённый SAG

**SAGA** (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

**Исправление смещения:** вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

# SAGA: несмещённый SAG

**SAGA** (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

**Исправление смещения:** вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

**Несмещённость:**

$$\mathbb{E}_{i_k}[g_k \mid w_k] = \nabla f(w_k) - \mathbb{E}[\phi_{i_k}] + \frac{1}{n} \sum_j \phi_j = \nabla f(w_k) \checkmark$$

# SAGA: несмещённый SAG

**SAGA** (Defazio, Bach, Lacoste-Julien, NeurIPS 2014).

**Исправление смещения:** вместо просто среднего — несмещённая поправка:

$$g_k = \underbrace{\nabla f_{i_k}(w_k) - \phi_{i_k}^{(k-1)}}_{\text{обновление}} + \underbrace{\frac{1}{n} \sum_{j=1}^n \phi_j^{(k-1)}}_{\text{старое среднее}}$$

**Несмещённость:**

$$\mathbb{E}_{i_k}[g_k \mid w_k] = \nabla f(w_k) - \mathbb{E}[\phi_{i_k}] + \frac{1}{n} \sum_j \phi_j = \nabla f(w_k) \checkmark$$

После обновления:  $\phi_{i_k}^{(k)} \leftarrow \nabla f_{i_k}(w_k)$ .

**Преимущества перед SAG:** - Несмещённость → **поддерживает проксимальные шаги** (SAGA + prox для Lasso!) - Лучшие константы в теоремах - Практически: чуть более стабильная сходимость

**Память:**  $O(nd)$  — та же проблема.

## SAG vs SAGA vs SVRG: сравнение

| Свойство            | SAG                                   | SAGA    | SVRG            |
|---------------------|---------------------------------------|---------|-----------------|
| Несмещённость       | ☒                                     | ☒       | ☒               |
| Прокс-совместимость | ☒                                     | ☒       | ☒               |
| Память              | $O(nd)$                               | $O(nd)$ | $O(d)$          |
| Скорость (с.в.)     | $O((n + \kappa) \log(1/\varepsilon))$ | то же   | то же           |
| Внешний цикл        | нет                                   | нет     | есть ( $O(n)$ ) |
| Реализация          | просто                                | просто  | сложнее         |

## SAG vs SAGA vs SVRG: сравнение

| Свойство            | SAG                                   | SAGA    | SVRG            |
|---------------------|---------------------------------------|---------|-----------------|
| Несмещённость       | ☒                                     | ☒       | ☒               |
| Прокс-совместимость | ☒                                     | ☒       | ☒               |
| Память              | $O(nd)$                               | $O(nd)$ | $O(d)$          |
| Скорость (с.в.)     | $O((n + \kappa) \log(1/\varepsilon))$ | то же   | то же           |
| Внешний цикл        | нет                                   | нет     | есть ( $O(n)$ ) |
| Реализация          | просто                                | просто  | сложнее         |

**SVRG:** лучшая память, требует полный градиент раз в  $m$  шагов.

**SAGA:** проще, несмещённость, плохая память при больших  $d$ .

**SAG:** смещённый, плохая память — устарел (SAGA строго лучше).

## SARAH: рекурсивный вариант

# SARAH: Stochastic Recursive Gradient

**SARAH** (Nguyen et al., ICML 2017).

# SARAH: Stochastic Recursive Gradient

**SARAH** (Nguyen et al., ICML 2017).

**Идея:** рекурсивно отслеживать изменение градиента вместо хранения таблицы.

**Внешний цикл** (эпоха): 1.  $\tilde{w} \leftarrow w_0$  (эталон) 2.  $v_0 \leftarrow \nabla f(\tilde{w})$  (**полный** градиент,  $O(n)$ ) 3.  $w_1 \leftarrow \tilde{w} - \alpha v_0$

**Внутренний цикл** ( $k = 1, \dots, m$ ): - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$  -  $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$  (**рекурсивно!**) -  $w_{k+1} = w_k - \alpha v_k$

# SARAH: Stochastic Recursive Gradient

**SARAH** (Nguyen et al., ICML 2017).

**Идея:** рекурсивно отслеживать изменение градиента вместо хранения таблицы.

**Внешний цикл** (эпоха): 1.  $\tilde{w} \leftarrow w_0$  (эталон) 2.  $v_0 \leftarrow \nabla f(\tilde{w})$  (**полный** градиент,  $O(n)$ ) 3.  $w_1 \leftarrow \tilde{w} - \alpha v_0$

**Внутренний цикл** ( $k = 1, \dots, m$ ): - Выбрать  $i_k \sim \text{Uniform}\{1, \dots, n\}$  -  $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$  (**рекурсивно!**) -  $w_{k+1} = w_k - \alpha v_k$

**Ключевое:**  $v_k$  обновляется рекурсивно — не нужно хранить  $n$  градиентов.

**Память:**  $O(d)$  — как SVRG.

## SVRG vs SARAH: разница в оценке

**SVRG:** якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ( $\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$ ) - Дисперсия убывает по ходу внешних эпох

**SARAH:** якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ( $\mathbb{E}[v_k] \neq \nabla f(w_k)$ ) - Но дисперсия убывает **внутри эпохи**

## SVRG vs SARAH: разница в оценке

**SVRG:** якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ( $\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$ ) - Дисперсия убывает по ходу внешних эпох

**SARAH:** якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ( $\mathbb{E}[v_k] \neq \nabla f(w_k)$ ) - Но дисперсия убывает **внутри эпохи**

**Интересное свойство SARAH:**

$$\mathbb{E}\|v_k - \nabla f(w_k)\|^2 \leq L^2 \sum_{j=0}^{k-1} \mathbb{E}\|w_{j+1} - w_j\|^2$$

По мере схождения  $w_k \rightarrow w^*$ : шаги  $\|w_{j+1} - w_j\| \rightarrow 0 \rightarrow$  смещение убывает!

## SVRG vs SARAH: разница в оценке

**SVRG:** якорь фиксирован:

$$\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$$

- Несмещённый ( $\mathbb{E}[\hat{g}_k] = \nabla f(w_k)$ ) - Дисперсия убывает по ходу внешних эпох

**SARAH:** якорь «ползёт»:

$$v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$$

- **Смещённый** ( $\mathbb{E}[v_k] \neq \nabla f(w_k)$ ) - Но дисперсия убывает **внутри эпохи**

**Интересное свойство SARAH:**

$$\mathbb{E}\|v_k - \nabla f(w_k)\|^2 \leq L^2 \sum_{j=0}^{k-1} \mathbb{E}\|w_{j+1} - w_j\|^2$$

По мере схождения  $w_k \rightarrow w^*$ : шаги  $\|w_{j+1} - w_j\| \rightarrow 0 \rightarrow$  смещение убывает!

**Практика:** SARAH немного лучше SVRG в некоторых задачах (меньше вариация), но анализ сложнее.

Итог: когда что использовать

## Большая сравнительная таблица

| Метод | Скорость                         | Стоимость итер. | Память  | Прокс |
|-------|----------------------------------|-----------------|---------|-------|
| GD    | $O(e^{-\mu k/L})$                | $O(n)$          | $O(d)$  | ☒     |
| AGD   | $O(e^{-k/\sqrt{\kappa}})$        | $O(n)$          | $O(d)$  | ☒     |
| SGD   | $O(1/(\mu K)) \leftarrow$ нелин. | $O(1)$          | $O(d)$  | ☒     |
| SAG   | $O(e^{-k/(8\max(n,\kappa))})$    | $O(1)$ амортиз. | $O(nd)$ | ☒     |
| SAGA  | то же                            | $O(1)$ амортиз. | $O(nd)$ | ☒     |
| SVRG  | $O((1/2)^{\text{эпоха}})$        | $O(1)$ амортиз. | $O(d)$  | ☒     |
| SARAH | аналог SVRG                      | $O(1)$ амортиз. | $O(d)$  | ☒     |

## Большая сравнительная таблица

| Метод | Скорость                         | Стоимость итер. | Память  | Прокс |
|-------|----------------------------------|-----------------|---------|-------|
| GD    | $O(e^{-\mu k/L})$                | $O(n)$          | $O(d)$  | ☒     |
| AGD   | $O(e^{-k/\sqrt{\kappa}})$        | $O(n)$          | $O(d)$  | ☒     |
| SGD   | $O(1/(\mu K)) \leftarrow$ нелин. | $O(1)$          | $O(d)$  | ☒     |
| SAG   | $O(e^{-k/(8\max(n,\kappa))})$    | $O(1)$ амортиз. | $O(nd)$ | ☒     |
| SAGA  | то же                            | $O(1)$ амортиз. | $O(nd)$ | ☒     |
| SVRG  | $O((1/2)^{\text{эпоха}})$        | $O(1)$ амортиз. | $O(d)$  | ☒     |
| SARAH | аналог SVRG                      | $O(1)$ амортиз. | $O(d)$  | ☒     |

Амортизированно:  $O(1)$  на итерацию при  $m = O(n)$ .

## Практические рекомендации

Почему VR редко используют в DL?

| Ситуация                      | Рекомендация                |
|-------------------------------|-----------------------------|
| $n \leq \kappa$ (мало данных) | GD или AGD                  |
| $n \gg \kappa$ (много данных) | SGD с большим батчем        |
| $n \approx \kappa$            | <b>SVRG</b> или SARAH       |
| Lasso/Group Lasso             | <b>SAGA</b> + <b>prox</b>   |
| Нейросети $d = 10^9$          | SVRG (не SAGA!)             |
| Deep learning вообще          | Adam / SGD (VR не прижился) |

## Практические рекомендации

| Ситуация                      | Рекомендация                |
|-------------------------------|-----------------------------|
| $n \leq \kappa$ (мало данных) | GD или AGD                  |
| $n \gg \kappa$ (много данных) | SGD с большим батчем        |
| $n \approx \kappa$            | <b>SVRG</b> или SARAH       |
| Lasso/Group Lasso             | <b>SAGA</b> + <b>prox</b>   |
| Нейросети $d = 10^9$          | SVRG (не SAGA!)             |
| Deep learning вообще          | Adam / SGD (VR не прижился) |

### Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных  $\rightarrow$   $f$  меняется каждую эпоху

## Практические рекомендации

| Ситуация                      | Рекомендация                |
|-------------------------------|-----------------------------|
| $n \leq \kappa$ (мало данных) | GD или AGD                  |
| $n \gg \kappa$ (много данных) | SGD с большим батчем        |
| $n \approx \kappa$            | <b>SVRG</b> или SARAH       |
| Lasso/Group Lasso             | <b>SAGA + prox</b>          |
| Нейросети $d = 10^9$          | SVRG (не SAGA!)             |
| Deep learning вообще          | Adam / SGD (VR не прижился) |

### Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных  $\rightarrow f$  меняется каждую эпоху
2. **Стоимость хранения:**  $O(nd)$  неприемлемо

## Практические рекомендации

| Ситуация                      | Рекомендация                |
|-------------------------------|-----------------------------|
| $n \leq \kappa$ (мало данных) | GD или AGD                  |
| $n \gg \kappa$ (много данных) | SGD с большим батчем        |
| $n \approx \kappa$            | <b>SVRG</b> или SARAH       |
| Lasso/Group Lasso             | <b>SAGA</b> + <b>prox</b>   |
| Нейросети $d = 10^9$          | SVRG (не SAGA!)             |
| Deep learning вообще          | Adam / SGD (VR не прижился) |

### Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных  $\rightarrow f$  меняется каждую эпоху
2. **Стоимость хранения:**  $O(nd)$  неприемлемо
3. **Нелинейность:** большие нейросети не ведут себя как «хорошие»  $\mu$ -с.в. функции

## Практические рекомендации

| Ситуация                      | Рекомендация                |
|-------------------------------|-----------------------------|
| $n \leq \kappa$ (мало данных) | GD или AGD                  |
| $n \gg \kappa$ (много данных) | SGD с большим батчем        |
| $n \approx \kappa$            | <b>SVRG</b> или SARAH       |
| Lasso/Group Lasso             | <b>SAGA + prox</b>          |
| Нейросети $d = 10^9$          | SVRG (не SAGA!)             |
| Deep learning вообще          | Adam / SGD (VR не прижился) |

### Почему VR редко используют в DL?

1. **Нестационарность:** аугментация данных  $\rightarrow f$  меняется каждую эпоху
2. **Стоимость хранения:**  $O(nd)$  неприемлемо
3. **Нелинейность:** большие нейросети не ведут себя как «хорошие»  $\mu$ -с.в. функции
4. **Adam работает лучше** на практике

# Ключевые формулы

| Объект         | Формула                                                                          |
|----------------|----------------------------------------------------------------------------------|
| SVRG градиент  | $\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$ |
| Несмещённость  | $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$                                    |
| Дисперсия SVRG | $\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$   |
| Стоимость SVRG | $O((n + \kappa) \log(1/\varepsilon))$                                            |
| SAGA градиент  | $g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$             |
| SARAH рекурсия | $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$                  |

# Ключевые формулы

| Объект         | Формула                                                                          |
|----------------|----------------------------------------------------------------------------------|
| SVRG градиент  | $\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$ |
| Несмещённость  | $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$                                    |
| Дисперсия SVRG | $\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$   |
| Стоимость SVRG | $O((n + \kappa) \log(1/\varepsilon))$                                            |
| SAGA градиент  | $g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$             |
| SARAH рекурсия | $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$                  |

## Связи с курсом:

- Л9 (SGD): шумовой пол  $\rightarrow$  VR устраняет

# Ключевые формулы

| Объект         | Формула                                                                          |
|----------------|----------------------------------------------------------------------------------|
| SVRG градиент  | $\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$ |
| Несмещённость  | $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$                                    |
| Дисперсия SVRG | $\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$   |
| Стоимость SVRG | $O((n + \kappa) \log(1/\varepsilon))$                                            |
| SAGA градиент  | $g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$             |
| SARAH рекурсия | $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$                  |

## Связи с курсом:

- Л9 (SGD): шумовой пол  $\rightarrow$  VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR

# Ключевые формулы

| Объект         | Формула                                                                          |
|----------------|----------------------------------------------------------------------------------|
| SVRG градиент  | $\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$ |
| Несмещённость  | $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$                                    |
| Дисперсия SVRG | $\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$   |
| Стоимость SVRG | $O((n + \kappa) \log(1/\varepsilon))$                                            |
| SAGA градиент  | $g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$             |
| SARAH рекурсия | $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$                  |

## Связи с курсом:

- Л9 (SGD): шумовой пол  $\rightarrow$  VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR
- Л8 (FISTA): Katyusha = SVRG + момент Нестерова  $\rightarrow O((n + \sqrt{n\kappa}) \log(1/\varepsilon))$

# Ключевые формулы

| Объект         | Формула                                                                          |
|----------------|----------------------------------------------------------------------------------|
| SVRG градиент  | $\hat{g}_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(\tilde{w}) + \tilde{\nabla} f$ |
| Несмещённость  | $\mathbb{E}_{i_k}[\hat{g}_k] = \nabla f(w_k)$                                    |
| Дисперсия SVRG | $\mathbb{E}\ \hat{g}_k\ ^2 \leq 4L(f(w_{k-1}) - f^*) + 4L(f(\tilde{w}) - f^*)$   |
| Стоимость SVRG | $O((n + \kappa) \log(1/\varepsilon))$                                            |
| SAGA градиент  | $g_k = \nabla f_{i_k}(w_k) - \phi_{i_k} + \frac{1}{n} \sum_j \phi_j$             |
| SARAH рекурсия | $v_k = \nabla f_{i_k}(w_k) - \nabla f_{i_k}(w_{k-1}) + v_{k-1}$                  |

## Связи с курсом:

- Л9 (SGD): шумовой пол  $\rightarrow$  VR устраняет
- Л7 (ISTA): SAGA+prox = ISTA с VR
- Л8 (FISTA): Katyusha = SVRG + момент Нестерова  $\rightarrow O((n + \sqrt{n\kappa}) \log(1/\varepsilon))$
- PhD: VR  $\boxtimes$  Ли-Троттер для стохастических операторов!

# Домашнее задание

Тест Лекции 10 (7 задач, 35 баллов, 60 мин): [hse26.fmin.xyz](https://hse26.fmin.xyz)

## Домашнее задание

**Тест Лекции 10** (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** рассмотрим Lasso:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите итерацию SAGA+прох для этой задачи (прокс-оператор для  $\lambda \|\cdot\|_1$ ?).

## Домашнее задание

**Тест Лекции 10** (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** рассмотрим Lasso:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для  $\lambda \|\cdot\|_1$ ?).
2. При  $n = 10^4$ ,  $d = 10^3$ ,  $\kappa = 10^2$ : сколько итераций SAGA vs GD до  $\varepsilon = 10^{-6}$ ?

## Домашнее задание

**Тест Лекции 10** (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** рассмотрим Lasso:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для  $\lambda \|\cdot\|_1$ ?).
2. При  $n = 10^4$ ,  $d = 10^3$ ,  $\kappa = 10^2$ : сколько итераций SAGA vs GD до  $\varepsilon = 10^{-6}$ ?
3. Почему хранить таблицу  $\phi_i \in \mathbb{R}^d$  затруднительно при  $n = 10^6$ ,  $d = 10^3$ ?

## Домашнее задание

**Тест Лекции 10** (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** рассмотрим Lasso:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для  $\lambda \|\cdot\|_1$ ?).
2. При  $n = 10^4$ ,  $d = 10^3$ ,  $\kappa = 10^2$ : сколько итераций SAGA vs GD до  $\varepsilon = 10^{-6}$ ?
3. Почему хранить таблицу  $\phi_i \in \mathbb{R}^d$  затруднительно при  $n = 10^6$ ,  $d = 10^3$ ?

## Домашнее задание

**Тест Лекции 10** (7 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** рассмотрим Lasso:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите итерацию SAGA+prox для этой задачи (прокс-оператор для  $\lambda \|\cdot\|_1$ ?).
2. При  $n = 10^4$ ,  $d = 10^3$ ,  $\kappa = 10^2$ : сколько итераций SAGA vs GD до  $\varepsilon = 10^{-6}$ ?
3. Почему хранить таблицу  $\phi_i \in \mathbb{R}^d$  затруднительно при  $n = 10^6$ ,  $d = 10^3$ ?

**Следующая лекция:** Координатный спуск (RCD), ADMM, проксимальное расщепление.