




Координатный спуск

Даня Меркулов

ФКН ВШЭ

Мотивация: зачем обновлять одну координату?

Проблема высоких размерностей

Задача: $\min_{w \in \mathbb{R}^d} f(w)$

Проблема высоких размерностей

Задача: $\min_{w \in \mathbb{R}^d} f(w)$

Полный градиент $\nabla f(w) \in \mathbb{R}^d$ требует $O(nd)$ операций за шаг.

Проблема высоких размерностей

Задача: $\min_{w \in \mathbb{R}^d} f(w)$

Полный градиент $\nabla f(w) \in \mathbb{R}^d$ требует $O(nd)$ операций за шаг.

Идея координатного спуска: обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

Проблема высоких размерностей

Задача: $\min_{w \in \mathbb{R}^d} f(w)$

Полный градиент $\nabla f(w) \in \mathbb{R}^d$ требует $O(nd)$ операций за шаг.

Идея координатного спуска: обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

Стоимость одного шага: $O(n)$ или даже $O(1)$ при разреженных данных!

Проблема высоких размерностей

Задача: $\min_{w \in \mathbb{R}^d} f(w)$

Полный градиент $\nabla f(w) \in \mathbb{R}^d$ требует $O(nd)$ операций за шаг.

Идея координатного спуска: обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

Стоимость одного шага: $O(n)$ или даже $O(1)$ при разреженных данных!

Когда это работает: задачи вида

$$\min_w f(w) = g(w) + \sum_{j=1}^d h_j(w_j)$$

с **разделяемой** регуляризацией h_j .

Практические примеры

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — точное обновление по каждому w_j !

Практические примеры

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — точное обновление по каждому w_j !

Ridge: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$ — аналитически.

Практические примеры

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — точное обновление по каждому w_j !

Ridge: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$ — аналитически.

word2vec: обновляет embedding одного слова за итерацию.

Практические примеры

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — точное обновление по каждому w_j !

Ridge: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$ — аналитически.

word2vec: обновляет embedding одного слова за итерацию.

SVM (dual): координатный спуск = SMO (Sequential Minimal Optimization).

Практические примеры

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — точное обновление по каждому w_j !

Ridge: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$ — аналитически.

word2vec: обновляет embedding одного слова за итерацию.

SVM (dual): координатный спуск = SMO (Sequential Minimal Optimization).

Линейные модели с L^1 : sklearn LASSO использует CD по умолчанию.

Random Coordinate Descent (RCD)

Алгоритм RCD

Нестеров 2012: f — L -гладкая по каждой координате (L -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

Алгоритм RCD

Нестеров 2012: f — L -гладкая по каждой координате (L -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

Алгоритм RCD

1. Выбрать $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить: $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

Алгоритм RCD

Нестеров 2012: f — L -гладкая по каждой координате (L -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

Алгоритм RCD

1. Выбрать $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить: $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

$\nabla_j f(w) = \frac{\partial f}{\partial w_j}$ — скалярное число, не вектор!

Алгоритм RCD

Нестеров 2012: f — L -гладкая по каждой координате (L -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

Алгоритм RCD

1. Выбрать $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить: $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

$\nabla_j f(w) = \frac{\partial f}{\partial w_j}$ — скалярное число, не вектор!

Связь с GD: при равных $L_j = L$ это GD с «выбором» одной координаты случайно.

Теорема сходимости RCD

Теорема (Нестеров 2012)

Пусть f — L -гладкая и μ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

Теорема сходимости RCD

Теорема (Нестеров 2012)

Пусть f — L -гладкая и μ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

Стоимость до ε -точности: $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$ координатных обновлений.

Теорема сходимости RCD

Теорема (Нестеров 2012)

Пусть f — L -гладкая и μ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

Стоимость до ε -точности: $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$ координатных обновлений.

Метод	Шагов	Стоимость шага	Итого
GD	$O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$	$O(nd)$	$O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$
RCD	$O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$	$O(n)$	$O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$

Теорема сходимости RCD

Теорема (Нестеров 2012)

Пусть f — L -гладкая и μ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

Стоимость до ε -точности: $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$ координатных обновлений.

Метод	Шагов	Стоимость шага	Итого
GD	$O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$	$O(nd)$	$O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$
RCD	$O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$	$O(n)$	$O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$

Вывод: одинаковая суммарная стоимость, но RCD лучше при разреженных данных: $O(s)$ vs $O(nd)$.

Доказательство: лемма убывания

Шаг доказательства 1: из L_{j_k} -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

Доказательство: лемма убывания

Шаг доказательства 1: из L_{j_k} -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство: $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$; берём $\mathbb{E}_{j_k}$; используем $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$.)

Доказательство: лемма убывания

Шаг доказательства 1: из L_{j_k} -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство: $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$; берём $\mathbb{E}_{j_k}$; используем $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$.)

Шаг 2: из μ -сильной выпуклости: $\|\nabla f(w)\|^2 \geq 2\mu(f(w) - f^*)$:

$$\mathbb{E}[f(w_{k+1}) - f^*] \leq \left(1 - \frac{\mu}{dL}\right) (f(w_k) - f^*)$$

Доказательство: лемма убывания

Шаг доказательства 1: из L_{j_k} -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство: $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$; берём $\mathbb{E}_{j_k}$; используем $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$.)

Шаг 2: из μ -сильной выпуклости: $\|\nabla f(w)\|^2 \geq 2\mu(f(w) - f^*)$:

$$\mathbb{E}[f(w_{k+1}) - f^*] \leq \left(1 - \frac{\mu}{dL}\right) (f(w_k) - f^*)$$

Шаг 3: Применяя рекурсивно k раз — теорема доказана. $\square$

Координатный спуск для LASSO

Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

Остаток без j -й переменной: $r_j = y - X_{-j}w_{-j}$

Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

Остаток без j -й переменной: $r_j = y - X_{-j}w_{-j}$

Задача по w_j при фиксированных остальных:

$$\min_{w_j} \frac{1}{2n} \|X_j w_j - r_j\|^2 + \lambda |w_j|$$

Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

Остаток без j -й переменной: $r_j = y - X_{-j}w_{-j}$

Задача по w_j при фиксированных остальных:

$$\min_{w_j} \frac{1}{2n} \|X_j w_j - r_j\|^2 + \lambda |w_j|$$

Аналитическое решение — мягкое пороговое обрезание

$$w_j^* = \mathcal{S}_\tau(c_j), \quad c_j = \frac{X_j^\top r_j}{\|X_j\|^2}, \quad \tau = \frac{\lambda n}{\|X_j\|^2}$$
$$\mathcal{S}_\tau(c) = \text{sign}(c) \max(|c| - \tau, 0)$$

LASSO CD vs. ISTA: связь

Алгоритм: перебираем $j = 1, \dots, d$, применяем мягкое пороговое обрезание.

LASSO CD vs. ISTA: связь

Алгоритм: перебираем $j = 1, \dots, d$, применяем мягкое пороговое обрезание.

	ISTA	LASSO CD
Шаг	Глобальный: $w - \frac{1}{L} \nabla g(w)$	Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$
Прокс	$\mathcal{S}_{\lambda/L}$ по всем координатам	$\mathcal{S}_{\lambda/L_j}$ по одной
Шаг	$\alpha = 1/L$ (глобальный)	$\alpha_j = 1/L_j$ (адаптивный!)

LASSO CD vs. ISTA: связь

Алгоритм: перебираем $j = 1, \dots, d$, применяем мягкое пороговое обрезание.

	ISTA	LASSO CD
Шаг	Глобальный: $w - \frac{1}{L} \nabla g(w)$	Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$
Прокс	$\mathcal{S}_{\lambda/L}$ по всем координатам	$\mathcal{S}_{\lambda/L_j}$ по одной
Шаг	$\alpha = 1/L$ (глобальный)	$\alpha_j = 1/L_j$ (адаптивный!)

Преимущество CD: адаптивный шаг $L_j = \|X_j\|^2/n$ — дешевле, чем $L = \|X\|^2/n$.

LASSO CD vs. ISTA: связь

Алгоритм: перебираем $j = 1, \dots, d$, применяем мягкое пороговое обрезание.

	ISTA	LASSO CD
Шаг	Глобальный: $w - \frac{1}{L} \nabla g(w)$	Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$
Прокс	$\mathcal{S}_{\lambda/L}$ по всем координатам	$\mathcal{S}_{\lambda/L_j}$ по одной
Шаг	$\alpha = 1/L$ (глобальный)	$\alpha_j = 1/L_j$ (адаптивный!)

Преимущество CD: адаптивный шаг $L_j = \|X_j\|^2/n$ — дешевле, чем $L = \|X\|^2/n$.

Sklearn использует именно этот алгоритм (Coordinate Descent с warm restarts).

Циклический vs. случайный CD

Сравнение порядков обновления

	Gauss-Seidel (циклический)	RCD (случайный)
Порядок	$j = 1, 2, \dots, d, 1, 2, \dots$	$j_k \sim \text{Uniform}\{1, \dots, d\}$
Теория	Нет гарантий для общего невыпуклого	Сходимость доказана
Практика	Часто быстрее на гладких задачах	Устойчивее к «плохим» данным

Сравнение порядков обновления

	Gauss-Seidel (циклический)	RCD (случайный)
Порядок	$j = 1, 2, \dots, d, 1, 2, \dots$	$j_k \sim \text{Uniform}\{1, \dots, d\}$
Теория	Нет гарантий для общего невыпуклого	Сходимость доказана
Практика	Часто быстрее на гладких задачах	Устойчивее к «плохим» данным

Важное замечание: для LASSO циклический CD (sklearn) часто быстрее RCD на практике!

Сравнение порядков обновления

	Gauss-Seidel (циклический)	RCD (случайный)
Порядок	$j = 1, 2, \dots, d, 1, 2, \dots$	$j_k \sim \text{Uniform}\{1, \dots, d\}$
Теория	Нет гарантий для общего невыпуклого	Сходимость доказана
Практика	Часто быстрее на гладких задачах	Устойчивее к «плохим» данным

Важное замечание: для LASSO **циклический CD** (sklearn) часто быстрее RCD на практике!

Причина: «тёплый старт» — w_j изменяется мало от итерации к итерации → хорошее начальное приближение для следующего прохода.

Сравнение порядков обновления

	Gauss-Seidel (циклический)	RCD (случайный)
Порядок	$j = 1, 2, \dots, d, 1, 2, \dots$	$j_k \sim \text{Uniform}\{1, \dots, d\}$
Теория	Нет гарантий для общего невыпуклого	Сходимость доказана
Практика	Часто быстрее на гладких задачах	Устойчивее к «плохим» данным

Важное замечание: для LASSO **циклический CD** (sklearn) часто быстрее RCD на практике!

Причина: «тёплый старт» — w_j изменяется мало от итерации к итерации $\rightarrow$ хорошее начальное приближение для следующего прохода.

Когда RCD лучше: разреженные данные с сильно варьирующимися L_j .

Блочный координатный спуск

Обобщение: обновляем **блок** $B_s \subseteq \{1, \dots, d\}$ координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

Блочный координатный спуск

Обобщение: обновляем **блок** $B_s \subseteq \{1, \dots, d\}$ координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

Мотивация: группы **коррелированных** признаков лучше обновлять совместно.

Блочный координатный спуск

Обобщение: обновляем **блок** $B_s \subseteq \{1, \dots, d\}$ координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

Мотивация: группы **коррелированных** признаков лучше обновлять совместно.

Условие: разделяемая регуляризация по блокам — прокс-шаг вычислим точно.

Блочный координатный спуск

Обобщение: обновляем **блок** $B_s \subseteq \{1, \dots, d\}$ координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

Мотивация: группы **коррелированных** признаков лучше обновлять совместно.

Условие: разделяемая регуляризация по блокам — прокс-шаг вычислим точно.

Пример: group LASSO — $\sum_g \lambda_g \|w_{B_g}\|_2$:

$$\text{prox}_{\lambda_g \|\cdot\|_2}(v) = v \cdot \max\left(1 - \frac{\lambda_g}{\|v\|}, 0\right)$$

Итоговая таблица и связи

Сравнительная таблица методов

Метод	Сходимость (выпуклая)	μ -сильно выпуклая	Стоимость шага
GD	$O(L/k)$	$O(e^{-\mu k/L})$	$O(nd)$
SGD	$O(1/\sqrt{k})$	$O(1/(\mu k))$	$O(n)$
RCD	$O(dL/k)$	$O(e^{-\mu k/(dL)})$	$O(n)$ или $O(1)$
SVRG	—	$O(e^{-\mu k/((n+2m)L)})$	$O(n)$

Сравнительная таблица методов

Метод	Сходимость (выпуклая)	μ -сильно выпуклая	Стоимость шага
GD	$O(L/k)$	$O(e^{-\mu k/L})$	$O(nd)$
SGD	$O(1/\sqrt{k})$	$O(1/(\mu k))$	$O(n)$
RCD	$O(dL/k)$	$O(e^{-\mu k/(dL)})$	$O(n)$ или $O(1)$
SVRG	—	$O(e^{-\mu k/((n+2m)L)})$	$O(n)$

Вывод: RCD ☒ GD по суммарной стоимости, но **выигрывает при разреженных данных**.

Сравнительная таблица методов

Метод	Сходимость (выпуклая)	μ -сильно выпуклая	Стоимость шага
GD	$O(L/k)$	$O(e^{-\mu k/L})$	$O(nd)$
SGD	$O(1/\sqrt{k})$	$O(1/(\mu k))$	$O(n)$
RCD	$O(dL/k)$	$O(e^{-\mu k/(dL)})$	$O(n)$ или $O(1)$
SVRG	—	$O(e^{-\mu k/((n+2m)L)})$	$O(n)$

Вывод: RCD $\boxtimes$ GD по суммарной стоимости, но **выигрывает при разреженных данных**.

Для LASSO: CD с точным прокс-шагом $\approx$ ISTA с адаптивным шагом — обычно быстрее!

Связь с PhD и следующей лекцией

Связь с расщеплением: координатный спуск — частный случай оператора расщепления!

Связь с PhD и следующей лекцией

Связь с расщеплением: координатный спуск — частный случай оператора расщепления!

Обновление j -й координаты = шаг оператора **проекции** на координатное подпространство.

Связь с PhD и следующей лекцией

Связь с расщеплением: координатный спуск — частный случай оператора расщепления!

Обновление j -й координаты = шаг оператора **проекции** на координатное подпространство.

Параллельный блочный CD = асинхронная версия расщепления Ли-Троттера.

Связь с PhD и следующей лекцией

Связь с расщеплением: координатный спуск — частный случай оператора расщепления!

Обновление j -й координаты = шаг оператора **проекции** на координатное подпространство.

Параллельный блочный CD = асинхронная версия расщепления Ли-Троттера.

Следующая лекция (#12): ADMM и проксимальное расщепление.

Следующая лекция (#12): ADMM и проксимальное расщепление.

Координатный спуск решает $g(w) + h(w)$ при **разделяемом** h . Что если разделяемости нет?

→ **ADMM**: разбиваем через переменные связи. Глубокая связь с двойственностью Лагранжа.

Следующая лекция (#12): ADMM и проксимальное расщепление.

Координатный спуск решает $g(w) + h(w)$ при **разделяемом** h . Что если разделяемости нет?

→ **ADMM**: разбиваем через переменные связи. Глубокая связь с двойственностью Лагранжа.

→ ADMM = DRS (Douglas-Rachford splitting) + аугментированный лагранжиан.