




Координатный спуск

Даня Меркулов

ФКН ВШЭ

Мотивация: зачем обновлять одну координату?

# Проблема высоких размерностей

**Задача:**  $\min_{w \in \mathbb{R}^d} f(w)$

# Проблема высоких размерностей

**Задача:**  $\min_{w \in \mathbb{R}^d} f(w)$

**Полный градиент**  $\nabla f(w) \in \mathbb{R}^d$  требует  $O(nd)$  операций за шаг.

# Проблема высоких размерностей

**Задача:**  $\min_{w \in \mathbb{R}^d} f(w)$

**Полный градиент**  $\nabla f(w) \in \mathbb{R}^d$  требует  $O(nd)$  операций за шаг.

**Идея координатного спуска:** обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

# Проблема высоких размерностей

**Задача:**  $\min_{w \in \mathbb{R}^d} f(w)$

**Полный градиент**  $\nabla f(w) \in \mathbb{R}^d$  требует  $O(nd)$  операций за шаг.

**Идея координатного спуска:** обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

Стоимость одного шага:  $O(n)$  или даже  $O(1)$  при разреженных данных!

# Проблема высоких размерностей

**Задача:**  $\min_{w \in \mathbb{R}^d} f(w)$

**Полный градиент**  $\nabla f(w) \in \mathbb{R}^d$  требует  $O(nd)$  операций за шаг.

**Идея координатного спуска:** обновлять только **одну координату** за шаг:

$$w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$$

Стоимость одного шага:  $O(n)$  или даже  $O(1)$  при разреженных данных!

**Когда это работает:** задачи вида

$$\min_w f(w) = g(w) + \sum_{j=1}^d h_j(w_j)$$

с **разделяемой** регуляризацией  $h_j$ .

## Практические примеры

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — точное обновление по каждому  $w_j$ !

## Практические примеры

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — точное обновление по каждому  $w_j$ !

**Ridge:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$  — аналитически.

## Практические примеры

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — точное обновление по каждому  $w_j$ !

**Ridge:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$  — аналитически.

**word2vec:** обновляет embedding одного слова за итерацию.

## Практические примеры

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — точное обновление по каждому  $w_j$ !

**Ridge:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$  — аналитически.

**word2vec:** обновляет embedding одного слова за итерацию.

**SVM (dual):** координатный спуск = SMO (Sequential Minimal Optimization).

## Практические примеры

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — точное обновление по каждому  $w_j$ !

**Ridge:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2$  — аналитически.

**word2vec:** обновляет embedding одного слова за итерацию.

**SVM (dual):** координатный спуск = SMO (Sequential Minimal Optimization).

**Линейные модели с  $L^1$ :** sklearn LASSO использует CD по умолчанию.

## Random Coordinate Descent (RCD)

# Алгоритм RCD

**Нестеров 2012:**  $f$  —  $L$ -гладкая по каждой координате ( $L$ -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

## Алгоритм RCD

**Нестеров 2012:**  $f$  —  $L$ -гладкая по каждой координате ( $L$ -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

## Алгоритм RCD

1. Выбрать  $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить:  $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

## Алгоритм RCD

**Нестеров 2012:**  $f$  —  $L$ -гладкая по каждой координате ( $L$ -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

## Алгоритм RCD

1. Выбрать  $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить:  $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

$\nabla_j f(w) = \frac{\partial f}{\partial w_j}$  — скалярное число, не вектор!

## Алгоритм RCD

**Нестеров 2012:**  $f$  —  $L$ -гладкая по каждой координате ( $L$ -гладкость по координатам):

$$f(w + \alpha e_j) \leq f(w) + \alpha \nabla_j f(w) + \frac{L_j}{2} \alpha^2$$

## Алгоритм RCD

1. Выбрать  $j_k \sim \text{Uniform}\{1, \dots, d\}$
2. Обновить:  $w_{k+1} = w_k - \frac{1}{L_{j_k}} \nabla_{j_k} f(w_k) \cdot e_{j_k}$

$\nabla_j f(w) = \frac{\partial f}{\partial w_j}$  — скалярное число, не вектор!

**Связь с GD:** при равных  $L_j = L$  это GD с «выбором» одной координаты случайно.

# Теорема сходимости RCD

## Теорема (Нестеров 2012)

Пусть  $f$  —  $L$ -гладкая и  $\mu$ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

# Теорема сходимости RCD

## Теорема (Нестеров 2012)

Пусть  $f$  —  $L$ -гладкая и  $\mu$ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

**Стоимость до  $\varepsilon$ -точности:**  $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$  координатных обновлений.

# Теорема сходимости RCD

## Теорема (Нестеров 2012)

Пусть  $f$  —  $L$ -гладкая и  $\mu$ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

**Стоимость до  $\varepsilon$ -точности:**  $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$  координатных обновлений.

| Метод | Шагов                                                     | Стоимость шага | Итого                                                      |
|-------|-----------------------------------------------------------|----------------|------------------------------------------------------------|
| GD    | $O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$  | $O(nd)$        | $O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$ |
| RCD   | $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$ | $O(n)$         | $O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$ |

# Теорема сходимости RCD

## Теорема (Нестеров 2012)

Пусть  $f$  —  $L$ -гладкая и  $\mu$ -сильно выпуклая. Тогда:

$$\mathbb{E}[f(w_k) - f^*] \leq \left(1 - \frac{\mu}{dL}\right)^k (f(w_0) - f^*)$$

**Стоимость до  $\varepsilon$ -точности:**  $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$  координатных обновлений.

| Метод | Шагов                                                     | Стоимость шага | Итого                                                      |
|-------|-----------------------------------------------------------|----------------|------------------------------------------------------------|
| GD    | $O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$  | $O(nd)$        | $O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$ |
| RCD   | $O\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right)$ | $O(n)$         | $O\left(\frac{ndL}{\mu} \log \frac{1}{\varepsilon}\right)$ |

**Вывод:** одинаковая суммарная стоимость, но RCD **лучше при разреженных данных:**  $O(s)$  vs  $O(nd)$ .

## Доказательство: лемма убывания

**Шаг доказательства 1:** из  $L_{j_k}$ -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

## Доказательство: лемма убывания

**Шаг доказательства 1:** из  $L_{j_k}$ -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство:  $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$ ; берём  $\mathbb{E}_{j_k}$ ; используем  $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$ .)

## Доказательство: лемма убывания

**Шаг доказательства 1:** из  $L_{j_k}$ -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство:  $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$ ; берём  $\mathbb{E}_{j_k}$ ; используем  $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$ .)

**Шаг 2:** из  $\mu$ -сильной выпуклости:  $\|\nabla f(w)\|^2 \geq 2\mu(f(w) - f^*)$ :

$$\mathbb{E}[f(w_{k+1}) - f^*] \leq \left(1 - \frac{\mu}{dL}\right) (f(w_k) - f^*)$$

## Доказательство: лемма убывания

**Шаг доказательства 1:** из  $L_{j_k}$ -гладкости по координатам и оптимального шага:

$$\mathbb{E}_{j_k}[f(w_{k+1})] \leq f(w_k) - \frac{1}{2dL} \|\nabla f(w_k)\|^2$$

(Доказательство:  $f(w_{k+1}) \leq f(w_k) - \frac{(\nabla_{j_k} f)^2}{2L_{j_k}}$ ; берём  $\mathbb{E}_{j_k}$ ; используем  $\mathbb{E}[(\nabla_j f)^2] = \frac{1}{d} \|\nabla f\|^2$ .)

**Шаг 2:** из  $\mu$ -сильной выпуклости:  $\|\nabla f(w)\|^2 \geq 2\mu(f(w) - f^*)$ :

$$\mathbb{E}[f(w_{k+1}) - f^*] \leq \left(1 - \frac{\mu}{dL}\right) (f(w_k) - f^*)$$

**Шаг 3:** Применяя рекурсивно  $k$  раз — теорема доказана.  $\square$

## Координатный спуск для LASSO

# Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

# Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

Остаток без  $j$ -й переменной:  $r_j = y - X_{-j}w_{-j}$

# Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

**Остаток** без  $j$ -й переменной:  $r_j = y - X_{-j}w_{-j}$

Задача по  $w_j$  при фиксированных остальных:

$$\min_{w_j} \frac{1}{2n} \|X_j w_j - r_j\|^2 + \lambda |w_j|$$

## Точное решение по одной координате

Задача LASSO:

$$\min_w \underbrace{\frac{1}{2n} \|Xw - y\|^2}_{g(w)} + \lambda \underbrace{\|w\|_1}_{=\sum_j |w_j|}$$

**Остаток** без  $j$ -й переменной:  $r_j = y - X_{-j}w_{-j}$

Задача по  $w_j$  при фиксированных остальных:

$$\min_{w_j} \frac{1}{2n} \|X_j w_j - r_j\|^2 + \lambda |w_j|$$

Аналитическое решение — мягкое пороговое обрезание

$$w_j^* = \mathcal{S}_\tau(c_j), \quad c_j = \frac{X_j^\top r_j}{\|X_j\|^2}, \quad \tau = \frac{\lambda n}{\|X_j\|^2}$$
$$\mathcal{S}_\tau(c) = \text{sign}(c) \max(|c| - \tau, 0)$$

## LASSO CD vs. ISTA: связь

**Алгоритм:** перебираем  $j = 1, \dots, d$ , применяем мягкое пороговое обрезание.

## LASSO CD vs. ISTA: связь

**Алгоритм:** перебираем  $j = 1, \dots, d$ , применяем мягкое пороговое обрезание.

|       | ISTA                                          | LASSO CD                                       |
|-------|-----------------------------------------------|------------------------------------------------|
| Шаг   | Глобальный: $w - \frac{1}{L} \nabla g(w)$     | Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$ |
| Прокс | $\mathcal{S}_{\lambda/L}$ по всем координатам | $\mathcal{S}_{\lambda/L_j}$ по одной           |
| Шаг   | $\alpha = 1/L$ (глобальный)                   | $\alpha_j = 1/L_j$ (адаптивный!)               |

## LASSO CD vs. ISTA: связь

**Алгоритм:** перебираем  $j = 1, \dots, d$ , применяем мягкое пороговое обрезание.

|       | ISTA                                          | LASSO CD                                       |
|-------|-----------------------------------------------|------------------------------------------------|
| Шаг   | Глобальный: $w - \frac{1}{L} \nabla g(w)$     | Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$ |
| Прокс | $\mathcal{S}_{\lambda/L}$ по всем координатам | $\mathcal{S}_{\lambda/L_j}$ по одной           |
| Шаг   | $\alpha = 1/L$ (глобальный)                   | $\alpha_j = 1/L_j$ (адаптивный!)               |

**Преимущество CD:** адаптивный шаг  $L_j = \|X_j\|^2/n$  — дешевле, чем  $L = \|X\|^2/n$ .

## LASSO CD vs. ISTA: связь

**Алгоритм:** перебираем  $j = 1, \dots, d$ , применяем мягкое пороговое обрезание.

|       | ISTA                                          | LASSO CD                                       |
|-------|-----------------------------------------------|------------------------------------------------|
| Шаг   | Глобальный: $w - \frac{1}{L} \nabla g(w)$     | Локальный: $w_j - \frac{1}{L_j} \nabla_j g(w)$ |
| Прокс | $\mathcal{S}_{\lambda/L}$ по всем координатам | $\mathcal{S}_{\lambda/L_j}$ по одной           |
| Шаг   | $\alpha = 1/L$ (глобальный)                   | $\alpha_j = 1/L_j$ (адаптивный!)               |

**Преимущество CD:** адаптивный шаг  $L_j = \|X_j\|^2/n$  — дешевле, чем  $L = \|X\|^2/n$ .

**Sklearn** использует именно этот алгоритм (Coordinate Descent с warm restarts).

## Циклический vs. случайный CD

## Сравнение порядков обновления

|          | Gauss-Seidel (циклический)          | RCD (случайный)                          |
|----------|-------------------------------------|------------------------------------------|
| Порядок  | $j = 1, 2, \dots, d, 1, 2, \dots$   | $j_k \sim \text{Uniform}\{1, \dots, d\}$ |
| Теория   | Нет гарантий для общего невыпуклого | Сходимость доказана                      |
| Практика | Часто быстрее на гладких задачах    | Устойчивее к «плохим» данным             |

## Сравнение порядков обновления

|          | Gauss-Seidel (циклический)          | RCD (случайный)                          |
|----------|-------------------------------------|------------------------------------------|
| Порядок  | $j = 1, 2, \dots, d, 1, 2, \dots$   | $j_k \sim \text{Uniform}\{1, \dots, d\}$ |
| Теория   | Нет гарантий для общего невыпуклого | Сходимость доказана                      |
| Практика | Часто быстрее на гладких задачах    | Устойчивее к «плохим» данным             |

**Важное замечание:** для LASSO циклический CD (sklearn) часто быстрее RCD на практике!

## Сравнение порядков обновления

|          | Gauss-Seidel (циклический)          | RCD (случайный)                          |
|----------|-------------------------------------|------------------------------------------|
| Порядок  | $j = 1, 2, \dots, d, 1, 2, \dots$   | $j_k \sim \text{Uniform}\{1, \dots, d\}$ |
| Теория   | Нет гарантий для общего невыпуклого | Сходимость доказана                      |
| Практика | Часто быстрее на гладких задачах    | Устойчивее к «плохим» данным             |

**Важное замечание:** для LASSO **циклический CD** (sklearn) часто быстрее RCD на практике!

**Причина:** «тёплый старт» —  $w_j$  изменяется мало от итерации к итерации → хорошее начальное приближение для следующего прохода.

## Сравнение порядков обновления

|          | Gauss-Seidel (циклический)          | RCD (случайный)                          |
|----------|-------------------------------------|------------------------------------------|
| Порядок  | $j = 1, 2, \dots, d, 1, 2, \dots$   | $j_k \sim \text{Uniform}\{1, \dots, d\}$ |
| Теория   | Нет гарантий для общего невыпуклого | Сходимость доказана                      |
| Практика | Часто быстрее на гладких задачах    | Устойчивее к «плохим» данным             |

**Важное замечание:** для LASSO **циклический CD** (sklearn) часто быстрее RCD на практике!

**Причина:** «тёплый старт» —  $w_j$  изменяется мало от итерации к итерации  $\rightarrow$  хорошее начальное приближение для следующего прохода.

**Когда RCD лучше:** разреженные данные с сильно варьирующимися  $L_j$ .

# Блочный координатный спуск

**Обобщение:** обновляем **блок**  $B_s \subseteq \{1, \dots, d\}$  координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

# Блочный координатный спуск

**Обобщение:** обновляем **блок**  $B_s \subseteq \{1, \dots, d\}$  координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

**Мотивация:** группы **коррелированных** признаков лучше обновлять совместно.

## Блочный координатный спуск

**Обобщение:** обновляем **блок**  $B_s \subseteq \{1, \dots, d\}$  координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

**Мотивация:** группы **коррелированных** признаков лучше обновлять совместно.

**Условие:** разделяемая регуляризация по блокам — прокс-шаг вычислим точно.

## Блочный координатный спуск

**Обобщение:** обновляем **блок**  $B_s \subseteq \{1, \dots, d\}$  координат совместно:

$$w_{k+1}^{B_s} = w_k^{B_s} - \frac{1}{L_{B_s}} \nabla_{B_s} f(w_k)$$

**Мотивация:** группы **коррелированных** признаков лучше обновлять совместно.

**Условие:** разделяемая регуляризация по блокам — прокс-шаг вычислим точно.

**Пример:** group LASSO —  $\sum_g \lambda_g \|w_{B_g}\|_2$ :

$$\text{prox}_{\lambda_g \|\cdot\|_2}(v) = v \cdot \max\left(1 - \frac{\lambda_g}{\|v\|}, 0\right)$$

## Итоговая таблица и связи

## Сравнительная таблица методов

| Метод      | Сходимость (выпуклая) | $\mu$ -сильно выпуклая    | Стоимость шага    |
|------------|-----------------------|---------------------------|-------------------|
| GD         | $O(L/k)$              | $O(e^{-\mu k/L})$         | $O(nd)$           |
| SGD        | $O(1/\sqrt{k})$       | $O(1/(\mu k))$            | $O(n)$            |
| <b>RCD</b> | $O(dL/k)$             | $O(e^{-\mu k/(dL)})$      | $O(n)$ или $O(1)$ |
| SVRG       | —                     | $O(e^{-\mu k/((n+2m)L)})$ | $O(n)$            |

## Сравнительная таблица методов

| Метод      | Сходимость (выпуклая) | $\mu$ -сильно выпуклая    | Стоимость шага    |
|------------|-----------------------|---------------------------|-------------------|
| GD         | $O(L/k)$              | $O(e^{-\mu k/L})$         | $O(nd)$           |
| SGD        | $O(1/\sqrt{k})$       | $O(1/(\mu k))$            | $O(n)$            |
| <b>RCD</b> | $O(dL/k)$             | $O(e^{-\mu k/(dL)})$      | $O(n)$ или $O(1)$ |
| SVRG       | —                     | $O(e^{-\mu k/((n+2m)L)})$ | $O(n)$            |

**Вывод:** RCD ☒ GD по суммарной стоимости, но **выигрывает при разреженных данных**.

## Сравнительная таблица методов

| Метод      | Сходимость (выпуклая) | $\mu$ -сильно выпуклая    | Стоимость шага    |
|------------|-----------------------|---------------------------|-------------------|
| GD         | $O(L/k)$              | $O(e^{-\mu k/L})$         | $O(nd)$           |
| SGD        | $O(1/\sqrt{k})$       | $O(1/(\mu k))$            | $O(n)$            |
| <b>RCD</b> | $O(dL/k)$             | $O(e^{-\mu k/(dL)})$      | $O(n)$ или $O(1)$ |
| SVRG       | —                     | $O(e^{-\mu k/((n+2m)L)})$ | $O(n)$            |

**Вывод:** RCD  $\boxtimes$  GD по суммарной стоимости, но **выигрывает при разреженных данных**.

Для LASSO: CD с точным прокс-шагом  $\approx$  ISTA с адаптивным шагом — обычно быстрее!

## Связь с PhD и следующей лекцией

**Связь с расщеплением:** координатный спуск — частный случай оператора расщепления!

## Связь с PhD и следующей лекцией

**Связь с расщеплением:** координатный спуск — частный случай оператора расщепления!

Обновление  $j$ -й координаты = шаг оператора **проекции** на координатное подпространство.

## Связь с PhD и следующей лекцией

**Связь с расщеплением:** координатный спуск — частный случай оператора расщепления!

Обновление  $j$ -й координаты = шаг оператора **проекции** на координатное подпространство.

**Параллельный блочный CD** = асинхронная версия расщепления Ли-Троттера.

## Связь с PhD и следующей лекцией

**Связь с расщеплением:** координатный спуск — частный случай оператора расщепления!

Обновление  $j$ -й координаты = шаг оператора **проекции** на координатное подпространство.

**Параллельный блочный CD** = асинхронная версия расщепления Ли-Троттера.

Следующая лекция (#12): ADMM и проксимальное расщепление.

Следующая лекция (#12): ADMM и проксимальное расщепление.

Координатный спуск решает  $g(w) + h(w)$  при **разделяемом**  $h$ . Что если разделяемости нет?

→ **ADMM**: разбиваем через переменные связи. Глубокая связь с двойственностью Лагранжа.

**Следующая лекция (#12):** ADMM и проксимальное расщепление.

Координатный спуск решает  $g(w) + h(w)$  при **разделяемом**  $h$ . Что если разделяемости нет?

→ **ADMM**: разбиваем через переменные связи. Глубокая связь с двойственностью Лагранжа.

→ ADMM = DRS (Douglas-Rachford splitting) + аугментированный лагранжиан.