



Градиентные методы для задач с ограничениями. Метод проекции градиента. Метод Франк-Вульфа. Метод зеркального спуска

Даня Меркулов

ФКН ВШЭ

## Методы с ограничениями

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$



# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

**Да.** Для этого нужно использовать проекции, чтобы обеспечить допустимость на каждой итерации.

## Пример: adversarial white-box attacks




Figure 1: Источник

- Математически нейронная сеть — это функция  $f(w; x)$

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

## Пример: adversarial white-box attacks




Figure 1: Источник

- Математически нейронная сеть — это функция  $f(w; x)$
- Обычно вход  $x$  задан, а веса сети  $w$  оптимизируются

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

## Пример: adversarial white-box attacks




Figure 1: Источник

- Математически нейронная сеть — это функция  $f(w; x)$
- Обычно вход  $x$  задан, а веса сети  $w$  оптимизируются
- Но можно зафиксировать веса  $w$  и оптимизировать  $x$ !

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

## Идея метода проекции градиента




Figure 2: Предположим, мы стартуем из точки  $x_k$ .

## Идея метода проекции градиента




Figure 3: И движемся в направлении  $-\nabla f(x_k)$ .

## Идея метода проекции градиента




Figure 4: Иногда мы можем оказаться за пределами допустимого множества.



## Идея метода проекции градиента




Figure 5: Решим эту маленькую проблему с помощью проекции!

## Идея метода проекции градиента

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Figure 6: Иллюстрация метода проекции градиента

# Проекция

# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $y \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(y) \in S$ :

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $y \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(y) \in S$ :

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.

# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $y \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(y) \in S$ :

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.

# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $y \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(y) \in S$ :

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.



# Проекция

Расстояние  $d$  от точки  $y \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $y \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(y) \in S$ :

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.
- Если точка принадлежит множеству, то её проекция — это она сама.

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## i Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$$




Figure 7: Угол должен быть тупым или прямым для любой точки  $x \in S$



## Оператор проекции - нестягивающий

- Функция  $f$  называется нестягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

---

<sup>1</sup>Нестягивающая функция становится сжимающей при  $L < 1$ .

## Оператор проекции - нестягивающий

- Функция  $f$  называется нестягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

---

<sup>1</sup>Нестягивающая функция становится сжимающей при  $L < 1$ .

# Оператор проекции - нестягивающий

- Функция  $f$  называется нестягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

- Далее покажем, что из неравенства Бурбаки-Чейни-Гольдштейна следует свойство нестягиваемости, а именно:

$$\langle y - \text{proj}(y), x - \text{proj}(y) \rangle \leq 0 \quad \forall x \in S \quad \Rightarrow \quad \|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

---

<sup>1</sup>Нестягивающая функция становится сжимающей при  $L < 1$ .

# Оператор проекции - нестягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

## Оператор проекции - нестягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

## Оператор проекции - нестягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменяем  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$



## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

По неравенству КБШ левая часть ограничена сверху величиной

$\|y - x\|_2 \|\pi(y) - \pi(x)\|_2$ , откуда следует  $\|y - x\|_2 \|\pi(y) - \pi(x)\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$ . Сокращая на  $\|\pi(x) - \pi(y)\|_2$ , завершаем доказательство.

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T (x - \pi) \geq 0$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

$$\begin{aligned} & \left( x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left( x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left( \frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left( \frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left( (y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left( \frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:  
 $(\pi - y)^T(x - \pi) \geq 0$

Первый множитель отрицателен по выбору точки  $y$ . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} & \left( x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left( x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left( \frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left( \frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left( (y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left( \frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$


Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:  
 $(\pi - y)^T(x - \pi) \geq 0$

$$\begin{aligned} \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|}\right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|}\right) &= \\ \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|}\right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|}\right) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\|\right) &= \\ (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R\right) \end{aligned}$$

Первый множитель отрицателен по выбору точки  $y$ . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} (y - x_0)^T(x - x_0) &\leq \|y - x_0\|\|x - x_0\| \\ \frac{(y - x_0)^T(x - x_0)}{\|y - x_0\|} - R &\leq \frac{\|y - x_0\|\|x - x_0\|}{\|y - x_0\|} - R \end{aligned}$$





## Пример: проекция на полупространство

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:

## Пример: проекция на полупространство

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:




Figure 9: Гиперплоскость

## Пример: проекция на полупространство

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:




Figure 9: Гиперплоскость

$$\begin{aligned}c^T(y + \alpha c) &= b \\c^T y + \alpha c^T c &= b \\c^T y &= b - \alpha c^T c\end{aligned}$$

Проверим неравенство для замкнутого выпуклого множества:  $(\pi - y)^T(x - \pi) \geq 0$

$$\begin{aligned}(y + \alpha c - y)^T(x - y - \alpha c) &= \\ \alpha c^T(x - y - \alpha c) &= \\ \alpha(c^T x) - \alpha(c^T y) - \alpha^2(c^T c) &= \\ \alpha b - \alpha(b - \alpha c^T c) - \alpha^2 c^T c &= \\ \alpha b - \alpha b + \alpha^2 c^T c - \alpha^2 c^T c &= 0 \geq 0\end{aligned}$$

## Метод проекции градиента (PGD)

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Figure 10: Иллюстрация алгоритма метода проекции градиента



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$





## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x := y, y := y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$
$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем  $x$  и  $y$

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$



## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем  $x$  и  $y$

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

## Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем  $x$  и  $y$

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Лемма доказана. На первый взгляд она не имеет очевидной геометрической интерпретации, но мы будем использовать её как удобный инструмент для оценки разности градиентов.



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая функция на  $\mathbb{R}^n$ . Тогда функция  $f$  является  $\mu$ -сильно выпуклой тогда и только тогда, когда для любых  $x, y \in \mathbb{R}^d$  выполняется:

$$\text{Сильно выпуклый случай } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Выпуклый случай } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

## Доказательство

1. Приведём доказательство только для сильно выпуклого случая; выпуклый следует из него при  $\mu = 0$ . Начнём с необходимости. Для сильно выпуклой функции

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$\text{сумма} \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

$$\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt \quad \quad = \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \end{aligned}$$
$$\begin{aligned} &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &= \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \end{aligned}$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt \end{aligned}$$



## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt \end{aligned}$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

## Инструменты для доказательства сходимости

2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

$$\text{меняем } x \text{ и } y \quad - \langle \nabla f(x), x - y \rangle \leq - \left( f(x) - f(y) + \frac{\mu}{2} \|x - y\|_2^2 \right)$$

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :



# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

Гладкость: 
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

Гладкость: 
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод: 
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

Гладкость: 
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод: 
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов: 
$$= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

Гладкость: 
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод: 
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов: 
$$\begin{aligned} &= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2 \\ &= f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2 + \frac{L}{2}\|y_k - x_{k+1}\|^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$
$$\|y_k - x^*\|^2 \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$
$$\|y_k - x^*\|^2 \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

4. Теперь, используя выпуклость и предыдущую часть:

## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$
$$\|y_k - x^*\|^2 \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$



## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$
$$\|y_k - x^*\|^2 \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$
$$\leq \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)$$

## Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$\begin{aligned}f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)\end{aligned}$$

$$\text{Сумма для } i = 0, k-1 \quad \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \frac{1}{2L} \|\nabla f(x_i)\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2$$

## Скорость сходимости для гладкого выпуклого случая

- Оценим градиенты с помощью неравенства достаточного убывания 7:

## Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2$$

## Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2\end{aligned}$$

# Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{k-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=1}^k [f(x_i) - f^*] &\leq \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$



## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (\*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

## Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (\*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Таким образом,

$$f(x_{k+1}) \leq f(x_k) \quad \text{для каждого } k,$$

то есть  $\{f(x_k)\}$  — монотонно невозрастающая последовательность.

# Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

# Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$



# Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку  $f(x_i)$  убывает по  $i$ , в частности  $f(x_k) \leq f(x_i)$  для всех  $i \leq k$ . Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

# Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку  $f(x_i)$  убывает по  $i$ , в частности  $f(x_k) \leq f(x_i)$  для всех  $i \leq k$ . Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

откуда немедленно получаем

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}.$$

Это завершает доказательство скорости сходимости  $\mathcal{O}(\frac{1}{k})$  для выпуклой  $L$ -гладкой функции  $f$  в условной задаче оптимизации.

# Скорость сходимости для гладкого сильно выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  —  $\mu$ -сильно выпуклая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\alpha \leq \frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

## Доказательство

1. Сначала докажем свойство стационарной точки:  $\text{proj}_S(x^* - \alpha \nabla f(x^*)) = x^*$ .

Это следует из критерия проекции и условия оптимальности первого порядка для  $x^*$ . Пусть  $y = x^* - \alpha \nabla f(x^*)$ . Нужно показать, что  $\langle y - x^*, x - x^* \rangle \leq 0$  для всех  $x \in S$ .

$$\langle (x^* - \alpha \nabla f(x^*)) - x^*, x - x^* \rangle = -\alpha \langle \nabla f(x^*), x - x^* \rangle \leq 0$$

Неравенство выполняется, так как  $\alpha > 0$  и  $\langle \nabla f(x^*), x - x^* \rangle \geq 0$  — условие оптимальности для  $x^*$ .

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

$$\text{свойство стационарной точки} = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$$

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2\end{aligned}$$

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$



# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

# Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\begin{aligned}\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 &\leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ \text{сильная выпуклость} \quad -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle &\leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle\end{aligned}$$

# Скорость сходимости для гладкого сильно выпуклого случая

3. Подставим:



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

4. В силу выпуклости  $f$ :  $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$ . Следовательно, при  $\alpha \leq \frac{1}{L}$ :

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что означает линейную сходимость метода со скоростью  $1 - \frac{\mu}{L}$ .

## Метод Франк-Вульфа





Figure 11: Маргарит Страус Франк (1927-2024)



Figure 12: Филип Вульф (1927-2016)




Figure 13: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 14: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 15: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 16: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 17: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 18: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Figure 19: Иллюстрация алгоритма Франк-Вульфа (условного градиента)



$$y_k = \arg \min_{x \in S} f^I_{x_k}(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$

$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$




Figure 20: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм Франк-Вульфа с размером шага  $\gamma_k = \frac{k-1}{k+1}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где  $R = \max_{x,y \in S} \|x - y\|$  — диаметр множества  $S$ .

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм Франк-Вульфа с размером шага  $\gamma_k = \frac{k-1}{k+1}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где  $R = \max_{x, y \in S} \|x - y\|$  — диаметр множества  $S$ .

1. Из  $L$ -гладкости  $f$  имеем:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

## Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

## Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

5. Перегруппируем слагаемые:

$$f(x_{k+1}) - f(x^*) \leq \gamma_k (f(x_k) - f(x^*)) + (1 - \gamma_k)^2 \frac{LR^2}{2}$$

## Скорость сходимости для гладкого выпуклого случая

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$



## Скорость сходимости для гладкого выпуклого случая

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

- База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

- База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим  $\delta_k \leq \frac{2}{k+1}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

- База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим  $\delta_k \leq \frac{2}{k+1}$
- Тогда  $\delta_{k+1} \leq \frac{k-1}{k+1} \cdot \frac{2}{k+1} + \frac{2}{(k+1)^2} = \frac{2k}{k^2+2k+1} < \frac{2}{k+2}$  

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Нижняя оценка для метода Франк-Вульфа <sup>2</sup>

### Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству  $S \subseteq \mathbb{R}^n$  только через оракул линейной минимизации (LMO). Пусть диаметр множества  $S$  равен  $R$ . Существует  $L$ -гладкая сильно выпуклая функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , для которой этому алгоритму потребуется не менее

$$\min \left( \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку  $\hat{x} \in S$  с  $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$ . Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

<sup>2</sup>  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

## Нижняя оценка для метода Франк-Вульфа <sup>2</sup>

### Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству  $S \subseteq \mathbb{R}^n$  только через оракул линейной минимизации (LMO). Пусть диаметр множества  $S$  равен  $R$ . Существует  $L$ -гладкая сильно выпуклая функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , для которой этому алгоритму потребуется не менее

$$\min \left( \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку  $\hat{x} \in S$  с  $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$ . Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

**Набросок доказательства.** Рассмотрим следующую задачу оптимизации:

$$\min_{x \in S} f(x) = \min_{x \in S} \frac{1}{2} \|x\|_2^2$$

$$S = \left\{ x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = 1 \right\}$$

Заметим, что:

- $f$  является 1-гладкой;
- диаметр  $S$  равен  $R = 2$ ;
- $f$  сильно выпукла.

<sup>2</sup>  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

## Нижняя оценка для метода Франк-Вульфа <sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

## Нижняя оценка для метода Франк-Вульфа <sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$



## Нижняя оценка для метода Франк-Вульфа <sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке  $\hat{x}$ , получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left( \frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

## Нижняя оценка для метода Франк-Вульфа<sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке  $\hat{x}$ , получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left( \frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

4. Чтобы обеспечить  $f(\hat{x}) - f(x^*) \leq \varepsilon$ , необходимо (полное доказательство приведено в статье):

$$k \geq \min \left\{ \frac{n}{2}, \frac{1}{4\varepsilon} \right\} = \min \left\{ \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right\}.$$

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными

# Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  ( статья)

# Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  (📄 статья)
- Если допустить шаги удаления, сходимость становится линейной (📄 статья) в сильно выпуклом случае

# Итоги метода Франк-Вульфа


- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  ( статья)
- Если допустить шаги удаления, сходимость становится линейной ( статья) в сильно выпуклом случае
- В недавних работах показано обобщение на негладкий случай ( статья) со скоростью сходимости  $O\left(\frac{1}{\sqrt{k}}\right)$



## Численные эксперименты


## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 0




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 1




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 2




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 3




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 4




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 5



## Двумерный пример. Метод Франк-Вульфа


Frank-Wolfe Method: Iteration 6





## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 7



# Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента  $g$  имеет вид  $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$ .

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained convex quadratic problem:  $n=80, \mu=0, L=10$



— Projected Gradient Descent    - - - Frank-Wolfe

# Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента  $g$  имеет вид  $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$ .

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained strongly Convex quadratic problem:  $n=80, \mu=1, L=10$



— Projected Gradient Descent    - - - Frank-Wolfe

# Квадратичная функция. Симплексные ограничения (удачная задача с диагональной матрицей)

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$





$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$

| Метод | Время шага, мс | Время LMO/проекции, мс |
|-------|----------------|------------------------|
| PGD   | 0.0069         | 0.0167                 |
| FW    | 0.0070         | 0.0066                 |

Проекция на единичный симплекс  $\pi_S(x)$  выполняется за  $\mathcal{O}(n \log n)$  или за ожидаемое  $\mathcal{O}(n)$  время.<sup>4</sup>  
 LMO для заданного градиента  $g$  имеет вид  $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$ . Решение соответствует вершине симплекса:

$$y = e_j \quad \text{где} \quad j = \operatorname{argmin}_i g_i.$$

<sup>4</sup> Efficient Projections onto the  $\ell_1$ -Ball for Learning in High Dimensions



--- Frank-Wolfe    — Projected Gradient Descent





# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$

| Метод | Время шага, мс | Время LMO/проекции, мс |
|-------|----------------|------------------------|
| PGD   | 0.0069         | 0.0420                 |
| FW    | 0.0069         | 0.0066                 |



--- Frank-Wolfe    — Projected Gradient Descent





# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

| Метод | Время шага, мс | Время LMO/проекции, мс |
|-------|----------------|------------------------|
| PGD   | 0.0068         | 0.0761                 |
| FW    | 0.0069         | 0.0070                 |



--- Frank-Wolfe    — Projected Gradient Descent





# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [1; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

| Метод | Время шага, мс | Время LMO/проекции, мс |
|-------|----------------|------------------------|
| PGD   | 0.0068         | 0.0752                 |
| FW    | 0.0067         | 0.0068                 |



--- Frank-Wolfe    — Projected Gradient Descent

## PGD и метод Франк-Вульфа

Ключевое различие между PGD и FW состоит в том, что PGD требует проекции, тогда как FW — лишь оракул линейной минимизации (LMO).

В недавней статье авторы представили следующую сравнительную таблицу сложностей линейной минимизации и проекций на некоторые выпуклые множества с точностью до аддитивной ошибки  $\epsilon$  в евклидовой норме.

| Множество                                                                                                    | Линейная минимизация                                                           | Проекция                                                                  |
|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|---------------------------------------------------------------------------|
| $n$ -мерный $\ell_p$ -шар, $p \neq 1, 2, \infty$                                                             | $\mathcal{O}(n)$                                                               | $\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$                               |
| Шар ядерной нормы для $n \times m$ матриц                                                                    | $\mathcal{O}\left(\nu \ln(m+n) \frac{\sqrt{\sigma_1}}{\sqrt{\epsilon}}\right)$ | $\mathcal{O}(mn \min\{m, n\})$                                            |
| Потоковый многогранник на графе с $m$ вершинами и $n$ рёбрами (ограничение пропускной способности на рёбрах) | $\mathcal{O}\left((n \log m)(n + m \log m)\right)$                             | $\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$ или $\mathcal{O}(n^4 \log n)$ |
| Многогранник Биркгофа ( $n \times n$ дважды стохастические матрицы)                                          | $\mathcal{O}(n^3)$                                                             | $\tilde{\mathcal{O}}(\frac{n^2}{\epsilon^2})$                             |

Когда  $\epsilon$  отсутствует, аддитивной ошибки нет. Обозначение  $\tilde{\mathcal{O}}$  скрывает полилогарифмические множители по размерности и полиномиальные множители в константах, связанных с расстоянием до оптимума. Для шара ядерной нормы (спектраэдра)  $\nu$  обозначает число ненулевых элементов, а  $\sigma_1$  — наибольшее сингулярное

число проецируемой матрицы.



## Дополнительные численные эксперименты

## Траектории PGD и FW на $\ell_2$ -шаре


$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^\top A x - b^\top x, \quad \|x\|_2 \leq 1$$

PGD: проекция  $\rightarrow$  кратчайший путь к границе, затем движение вдоль неё к оптимуму.

FW: каждый шаг — выпуклая комбинация текущей точки и **антиградиентной точки на границе**. Характерный зигзаг вдоль множества.

Оба метода стартуют из  $x_0 = (-0.5, -0.5)$ .


Траектории PGD и FW,  $\ell_2$ -шар



## Траектории PGD и FW на 2-симплексе

$$\min_{\substack{x \in \mathbb{R}^3 \\ x \geq 0, \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$

FW на каждом шаге выбирает одну из вершин симплекса  $(e_1, e_2, e_3)$ , движется к ней  $\rightarrow$  траектория проходит через рёбра. PGD: проекция на симплекс допускает движение в любом направлении  $\rightarrow$  более прямой путь к оптимуму.





## $\ell_2$ -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





## $\ell_2$ -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция:  $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$  —  $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





## $\ell_2$ -шар. Проекция и LMO одинаково дешёвы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция:  $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$  —  $\mathcal{O}(n)$
- LMO:  $y = -R \frac{g}{\|g\|}$  —  $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





# Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация  $x_k$  есть **выпуклая комбинация  $k$  вершин**  $\Rightarrow$  не более  $k$  ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает  $\sim 400$

Это важно, когда нужно получить разреженное решение.





# Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация  $x_k$  есть **выпуклая комбинация  $k$  вершин**  $\Rightarrow$  не более  $k$  ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает  $\sim 400$
- FW: число ненулевых растёт **линейно** с итерациями

Это важно, когда нужно получить разреженное решение.





## Сильная выпуклость: PGD ускоряется, FW — нет

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$



- $n = 200, \mu = 5, L = 100, \kappa = 20$

PGD с шагом  $\frac{1}{L}$ : **линейная сходимость**

$(1 - \mu/L)^k$ , ведь проекция на выпуклое множество — нестягивающий оператор.

FW: остаётся  $\mathcal{O}(1/k)$  — сильная выпуклость **не помогает** со стандартным шагом

$$\gamma_k = \frac{2}{k+2}.$$





# Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \preceq x \preceq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель:  $\mu \approx 0$  — оба метода  $\mathcal{O}(1/k)$ , но PGD быстрее по константе

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.





# Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель:  $\mu \approx 0$  — оба метода  $\mathcal{O}(1/k)$ , но PGD быстрее по константе
- Правая панель:  $\mu = 2$  — PGD получает **экспоненциальную** скорость, FW остаётся сублинейным

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.



## Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка +  $O(n)$  — всего  $O(n \log n)$

При  $n = 10000$  проекция дороже LMO на **порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)



## Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка +  $O(n)$  — всего  $\mathcal{O}(n \log n)$
- LMO (argmin): один проход —  $\mathcal{O}(n)$

При  $n = 10000$  проекция дороже LMO **на порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)





## Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD  $\mathcal{O}(n^3)$  на каждой итерации

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при  $n = 800$  полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера  $10^4 \times 10^4$  и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.





# Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD  $\mathcal{O}(n^3)$  на каждой итерации
- FW: rank-1 SVD (power iteration)  $\mathcal{O}(n^2)$

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при  $n = 800$  полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера  $10^4 \times 10^4$  и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.



# Ядерная норма: определение и свойства

## **i** Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$



# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

**Приложения:** matrix completion (рекомендательные системы), robust PCA, low-rank matrix recovery, сжатие нейронных сетей.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$



# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  
 $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  
 $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  
 $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$
3.  $S_k = R \cdot u_1 v_1^\top$  — ранг-1 матрица

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
  2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$
  3.  $S_k = R \cdot u_1 v_1^\top$  — ранг-1 матрица
  4.  $X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$
- Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  **разрежен** (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$

FW компенсирует медленную сходимость  $\mathcal{O}(1/k)$  огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени





# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  **разрежен** (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы  $Y$ :  $\mathcal{O}(n^3)$

FW компенсирует медленную сходимость  $\mathcal{O}(1/k)$  огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  **разрежен** (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы  $Y$ :  $\mathcal{O}(n^3)$
- При  $n = 2500$ ,  $|\Omega| = 3\% \cdot n^2$ :  
отношение  $\approx 900\times$

FW компенсирует медленную сходимость  $\mathcal{O}(1/k)$  огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — невыпуклое

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга



# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях <sup>5</sup>

---

<sup>5</sup>  Candès, Recht. Exact Matrix Completion via Convex Optimization.

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях <sup>5</sup>

---

<sup>5</sup>  Candès, Recht. Exact Matrix Completion via Convex Optimization.

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Дана матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях <sup>5</sup>

**Пример из практики:** Netflix Prize — предсказание оценок пользователей для фильмов. Матрица  $\sim 500\text{K} \times 17\text{K}$ , известно  $\sim 1\%$  записей. Ядерная норма + FW позволяют эффективно решать эту задачу.

<sup>5</sup> Candès, Recht. Exact Matrix Completion via Convex Optimization.

## Метод зеркального спуска

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S (x_k - \alpha_k \nabla f(x_k))$$

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$



## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

**Проблема:** PGD с евклидовой проекцией может давать оценку  $\mathcal{O}\left(\frac{L_2 R_2^2}{k}\right)$ , но  $L_2$  и  $R_2$  могут **зависеть от размерности**  $n$ , что делает оценку бессмысленной для задач большой размерности.

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$



## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

**Выигрыш:**  $\frac{n}{\ln n}$  — экспоненциальный по размерности!

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для  $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

# Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для  $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение**  $\nabla\omega$ :

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.



# Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для  $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Функция  $\omega$  называется **прокс-функцией** (distance-generating function). Она задаёт геометрию через дивергенцию Брэгмана.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение**  $\nabla\omega$ :

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_{\omega}(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_{\omega}(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$ .

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_{\omega}(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_{\omega}(x, y) \neq V_{\omega}(y, x)$ .

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_{\omega}(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_{\omega}(x, y) \neq V_{\omega}(y, x)$ .
- **Не удовлетворяет** неравенству треугольника.

# Дивергенция Брэгмана

## i Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_{\omega}(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_{\omega}(x, y) \neq V_{\omega}(y, x)$ .
- **Не удовлетворяет** неравенству треугольника.
- Геометрически:  $V_{\omega}(x, y)$  — разность между  $\omega(x)$  и значением касательной к  $\omega$  в точке  $y$ , вычисленным в точке  $x$ .

# Примеры дивергенций Брэгмана

## Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.



# Примеры дивергенций Брэгмана

## Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

## Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

# Примеры дивергенций Брэгмана

## Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

## Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

## Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left( \frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

# Примеры дивергенций Брэгмана

## Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

## Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

## Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left( \frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

## Дивергенция Махаланобиса

$$\omega(x) = \frac{1}{2}x^\top Qx, \text{ где } Q \succ 0$$

$$V_\omega(x, y) = \frac{1}{2}(x - y)^\top Q(x - y)$$

Обобщённая евклидова геометрия.

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .

# Сильная выпуклость относительно нормы

## i Definition

Функция  $\omega$  называется  $\sigma$ -**сильно выпуклой относительно нормы**  $\|\cdot\|$ , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
  - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

# Сильная выпуклость относительно нормы

## i Definition

Функция  $\omega$  называется  $\sigma$ -**сильно выпуклой относительно нормы**  $\|\cdot\|$ , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
  - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.



# Сильная выпуклость относительно нормы

## i Definition

Функция  $\omega$  называется  $\sigma$ -**сильно выпуклой относительно нормы**  $\|\cdot\|$ , если для всех  $x, y$  из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
- Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Именно  $\sigma$ -сильная выпуклость прокс-функции  $\omega$  относительно нормы  $\|\cdot\|$  позволяет дивергенции Брэгмана «измерять расстояния» в геометрии, задаваемой нормой  $\|\cdot\|$ .

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### i Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### i Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### i Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### i Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

**Интерпретация:** на каждом шаге минимизируем линейное приближение  $f$  с регуляризацией дивергенцией Брэгмана вместо  $\frac{1}{2\alpha} \|x - x_k\|_2^2$ .

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### i Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

**Интерпретация:** на каждом шаге минимизируем линейное приближение  $f$  с регуляризацией дивергенцией Брэгмана вместо  $\frac{1}{2\alpha} \|x - x_k\|_2^2$ .

**Частный случай:** при  $\omega(x) = \frac{1}{2} \|x\|_2^2$  получаем  $V_\omega(x, y) = \frac{1}{2} \|x - y\|_2^2$ , и итерация принимает вид:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle \nabla f(x_k), x \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right\} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

то есть стандартный PGD.

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:



# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

## 3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

## 3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

В евклидовом случае ( $\omega = \frac{1}{2} \| \cdot \|^2$ ) проекция Брэгмана совпадает с евклидовой проекцией.

# Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

# Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

# Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

# Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

**Вывод.** Из условия оптимальности:  $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$ , где  $\lambda$  — множитель Лагранжа для ограничения  $\sum_i x_i = 1$ . Тогда  $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$ , и нормировка даёт формулу выше.



# Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

**Вывод.** Из условия оптимальности:  $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$ , где  $\lambda$  — множитель Лагранжа для ограничения  $\sum_i x_i = 1$ . Тогда  $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$ , и нормировка даёт формулу выше.

**Стоимость:**  $\mathcal{O}(n)$  — **не требуется** сортировка (в отличие от евклидовой проекции на симплекс, которая стоит  $\mathcal{O}(n \log n)$ ).



## i Theorem

Пусть  $f : S \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом относительно нормы  $\|\cdot\|$ :

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция  $\omega$  является  $\sigma$ -сильно выпуклой относительно  $\|\cdot\|$ , и  $R^2 = \max_{x \in S} V_\omega(x, x_0)$ . Тогда зеркальный спуск с шагом  $\alpha_k = \frac{1}{L/\sigma}$  обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

# Скорость сходимости зеркального спуска

## Theorem

Пусть  $f : S \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом относительно нормы  $\|\cdot\|$ :

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция  $\omega$  является  $\sigma$ -сильно выпуклой относительно  $\|\cdot\|$ , и  $R^2 = \max_{x \in S} V_\omega(x, x_0)$ . Тогда зеркальный спуск с шагом  $\alpha_k = \frac{1}{L/\sigma}$  обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

## Сравнение с PGD:

|           | PGD                     | Зеркальный спуск           |
|-----------|-------------------------|----------------------------|
| Норма     | $\ \cdot\ _2$           | $\ \cdot\ $ (произвольная) |
| Гладкость | $L_2$                   | $L$ (отн. $\ \cdot\ $ )    |
| «Радиус»  | $R_2 = \ x_0 - x^*\ _2$ | $R^2 = V_\omega(x^*, x_0)$ |
| Оценка    | $\frac{L_2 R_2^2}{k}$   | $\frac{LR^2}{\sigma k}$    |

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$



## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Это **лемма трёх точек** (three-point identity) для дивергенции Брэгмана:

$$V_\omega(x, x_k) - V_\omega(x, x_{k+1}) = \langle \nabla \omega(x_{k+1}) - \nabla \omega(x_k), x - x_{k+1} \rangle + V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K - 1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K - 1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K-1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

6. Используя шаг 2 для оценки каждого слагаемого и монотонность  $f(x_k)$ :

$$K \cdot (f(x_K) - f^*) \leq \frac{L}{\sigma} V_\omega(x^*, x_0) = \frac{LR^2}{\sigma}$$

откуда  $f(x_K) - f^* \leq \frac{LR^2}{\sigma K}$ , что и требовалось доказать.

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг



## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$

| Параметр  | PGD                              | MD (EG)                                |
|-----------|----------------------------------|----------------------------------------|
| Гладкость | $L_2 = \ A^\top A\ _{\text{op}}$ | $L_\infty = \max_{ij}  A^\top A _{ij}$ |
| «Радиус»  | $R_2^2 \leq 2$                   | $R^2 \leq \ln n$                       |
| Оценка    | $\frac{L_2}{k}$                  | $\frac{L_\infty \ln n}{k}$             |

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

| Параметр  | PGD                              | MD (EG)                                |
|-----------|----------------------------------|----------------------------------------|
| Гладкость | $L_2 = \ A^\top A\ _{\text{op}}$ | $L_\infty = \max_{ij}  A^\top A _{ij}$ |
| «Радиус»  | $R_2^2 \leq 2$                   | $R^2 \leq \ln n$                       |
| Оценка    | $\frac{L_2}{k}$                  | $\frac{L_\infty \ln n}{k}$             |

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

| Параметр  | PGD                              | MD (EG)                                |
|-----------|----------------------------------|----------------------------------------|
| Гладкость | $L_2 = \ A^\top A\ _{\text{op}}$ | $L_\infty = \max_{ij}  A^\top A _{ij}$ |
| «Радиус»  | $R_2^2 \leq 2$                   | $R^2 \leq \ln n$                       |
| Оценка    | $\frac{L_2}{k}$                  | $\frac{L_\infty \ln n}{k}$             |

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

**Выигрыш:**  $\frac{n}{\ln n}$  раз!

| Параметр  | PGD                              | MD (EG)                                |
|-----------|----------------------------------|----------------------------------------|
| Гладкость | $L_2 = \ A^\top A\ _{\text{op}}$ | $L_\infty = \max_{ij}  A^\top A _{ij}$ |
| «Радиус»  | $R_2^2 \leq 2$                   | $R^2 \leq \ln n$                       |
| Оценка    | $\frac{L_2}{k}$                  | $\frac{L_\infty \ln n}{k}$             |

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

**Выигрыш:**  $\frac{n}{\ln n}$  раз!

Для  $n = 1000$ : выигрыш  $\approx 145$  раз.

Для  $n = 10^6$ : выигрыш  $\approx 72\,400$  раз.


| Параметр  | PGD                              | MD (EG)                                |
|-----------|----------------------------------|----------------------------------------|
| Гладкость | $L_2 = \ A^\top A\ _{\text{op}}$ | $L_\infty = \max_{ij}  A^\top A _{ij}$ |
| «Радиус»  | $R_2^2 \leq 2$                   | $R^2 \leq \ln n$                       |
| Оценка    | $\frac{L_2}{k}$                  | $\frac{L_\infty \ln n}{k}$             |

# Негладкая задача: MD побеждает по итерациям


**Задача Бека:**  $\min_{x \in \Delta_n} \|Ax - b\|_1$  — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$  на  $\Delta_n$ : по итерациям с теорией


$n = 100, m = 50$   
 $\|g\|_2 / \|g\|_\infty = 3.3$



$n = 500, m = 200$   
 $\|g\|_2 / \|g\|_\infty = 4.6$



$n = 2000, m = 500$   
 $\|g\|_2 / \|g\|_\infty = 5.1$



- Субградиент  $g = A^\top \text{sign}(Ax - b)$ :  $\|g\|_2$  растёт с  $\sqrt{n}$ , а  $\|g\|_\infty$  остаётся ограниченным




# Негладкая задача: MD побеждает по итерациям


**Задача Бека:**  $\min_{x \in \Delta_n} \|Ax - b\|_1$  — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$  на  $\Delta_n$ : по итерациям с теорией


$n = 100, m = 50$   
 $\|g\|_2 / \|g\|_\infty = 3.3$



$n = 500, m = 200$   
 $\|g\|_2 / \|g\|_\infty = 4.6$






$n = 2000, m = 500$   
 $\|g\|_2 / \|g\|_\infty = 5.1$



- Субградиент  $g = A^\top \text{sign}(Ax - b)$ :  $\|g\|_2$  растёт с  $\sqrt{n}$ , а  $\|g\|_\infty$  остаётся ограниченным
- **Зеркальный спуск** использует  $\ell_\infty$ -геометрию и побеждает в  $\sim \sqrt{n / \ln n}$  раз!

# Негладкая задача: честное сравнение по времени




$\min \|Ax - b\|_1$  на  $\Delta_n$ : по времени



- MD побеждает **и по времени**: стоимость итерации сравнима ( $O(n)$  vs  $O(n \log n)$ ), но MD сходится существенно быстрее



# Негладкая задача: честное сравнение по времени

$\min \|Ax - b\|_1$  на  $\Delta_n$ : по времени





- MD побеждает **и по времени**: стоимость итерации сравнима ( $O(n)$  vs  $O(n \log n)$ ), но MD сходится существенно быстрее
- Преимущество растёт с размерностью: для  $n = 2000$  субградиентный метод за то же время далеко от оптимума

# Масштабирование преимущества MD





- При росте  $n$  невязка субградиентного метода растёт, а MD остаётся малой

# Масштабирование преимущества MD




- При росте  $n$  невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до  $\varepsilon$ -точности: MD требует меньше при любом  $n$

# Масштабирование преимущества MD




- При росте  $n$  невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до  $\varepsilon$ -точности: MD требует меньше при любом  $n$

# Масштабирование преимущества MD




- При росте  $n$  невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до  $\varepsilon$ -точности: MD требует меньше при любом  $n$



- Стоимость шага MD —  $\mathcal{O}(n)$ , дешевле PGD —  $\mathcal{O}(n \log n)$

# Масштабирование преимущества MD






- При росте  $n$  невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до  $\varepsilon$ -точности: MD требует меньше при любом  $n$
- Стоимость шага MD —  $\mathcal{O}(n)$ , дешевле PGD —  $\mathcal{O}(n \log n)$
- MD и FW имеют одинаковую асимптотику  $\mathcal{O}(n)$



## KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$  на  $\Delta_n$  — задача с неограниченной  $L_2$ -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$  на  $\Delta_n$ : относительная гладкость






- Константа  $L_h = \max_k \sum_{i,j} (A_i)_{jk}$  вычислима из данных задачи; MD шаг  $\eta = 1/L_h$  — теория гарантирует  $O(1/k)$

## KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$  на  $\Delta_n$  — задача с неограниченной  $L_2$ -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$  на  $\Delta_n$ : относительная гладкость






- Константа  $L_h = \max_k \sum_{i,j} (A_i)_{jk}$  вычислима из данных задачи; MD шаг  $\eta = 1/L_h$  — теория гарантирует  $O(1/k)$
- $L_2$  константа Липшица в **175 раз** больше  $L_h \rightarrow$  шаг PGD  $\alpha = 1/L_2$  сверхконсервативен; Armijo — медленнее по времени

## KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$  на  $\Delta_n$  — задача с неограниченной  $L_2$ -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$$f(x) = \sum \text{KL}(A_i x \| b_i) \text{ на } \Delta_n: \text{относительная гладкость}$$



- Константа  $L_h = \max_k \sum_{i,j} (A_i)_{jk}$  вычислима из данных задачи; MD шаг  $\eta = 1/L_h$  — теория гарантирует  $O(1/k)$
- $L_2$  константа Липшица в **175 раз** больше  $L_h \rightarrow$  шаг PGD  $\alpha = 1/L_2$  сверхконсервативен; Armijo — медленнее по времени
- Правый график:  $L_h$  vs  $L_2(x_k)$  — **почему** неевклидова геометрия выигрывает

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
  - **Негладкие задачи на симплексе:**  $\min \|Ax - b\|_1$  — выигрыш в  $\sim \sqrt{n/\ln n}$  раз (и по итерациям, и по времени!)

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
  - **Негладкие** задачи на симплексе:  $\min \|Ax - b\|_1$  — выигрыш в  $\sim \sqrt{n/\ln n}$  раз (и по итерациям, и по времени!)
  - **KL-дивергенция** и задачи с **относительной гладкостью**:  $L_2$  неограничена, но MD сходится с фиксированным шагом



## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
  - **Негладкие** задачи на симплексе:  $\min \|Ax - b\|_1$  — выигрыш в  $\sim \sqrt{n/\ln n}$  раз (и по итерациям, и по времени!)
  - **KL-дивергенция** и задачи с **относительной гладкостью**:  $L_2$  неограничена, но MD сходится с фиксированным шагом
  - Задачи, где  $\|g\|_2 \gg \|g\|_\infty$ ; высокоразмерные задачи, где  $\ell_2$ -оценки зависят от  $n$

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
  - **Негладкие задачи на симплексе:**  $\min \|Ax - b\|_1$  — выигрыш в  $\sim \sqrt{n/\ln n}$  раз (и по итерациям, и по времени!)
  - **KL-дивергенция** и задачи с **относительной гладкостью:**  $L_2$  неограничена, но MD сходится с фиксированным шагом
  - Задачи, где  $\|g\|_2 \gg \|g\|_\infty$ ; высокоразмерные задачи, где  $\ell_2$ -оценки зависят от  $n$
- **Ключевой результат на симплексе:** с прокс-функцией  $\omega(x) = \sum_i x_i \ln x_i$  зеркальный спуск даёт оценку  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$  вместо  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$  у PGD — экспоненциальный выигрыш по размерности.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
  - **Негладкие задачи на симплексе:**  $\min \|Ax - b\|_1$  — выигрыш в  $\sim \sqrt{n/\ln n}$  раз (и по итерациям, и по времени!)
  - **KL-дивергенция** и задачи с **относительной гладкостью:**  $L_2$  неограничена, но MD сходится с фиксированным шагом
  - Задачи, где  $\|g\|_2 \gg \|g\|_\infty$ ; высокоразмерные задачи, где  $\ell_2$ -оценки зависят от  $n$
- **Ключевой результат на симплексе:** с прокс-функцией  $\omega(x) = \sum_i x_i \ln x_i$  зеркальный спуск даёт оценку  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$  вместо  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$  у PGD — экспоненциальный выигрыш по размерности.
- Выбор прокс-функции  $\omega$  — ключевое решение при применении метода. Общее правило:  $\omega$  должна быть сильно выпуклой относительно нормы, в которой  $f$  является гладкой.