




ADMM и проксимальное расщепление

Даня Меркулов

ФКН ВШЭ

Мотивация: когда прокс-шаг не разделяется

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Примеры “сложных” задач:

- **LASSO с ограничениями:** $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — связь f и g через w

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Примеры “сложных” задач:

- **LASSO с ограничениями:** $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — связь f и g через w
- **Распределённая оптимизация:** $f_i(w_i)$ на каждом узле, но нужно $w_i = w_j$

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Примеры “сложных” задач:

- **LASSO с ограничениями:** $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — связь f и g через w
- **Распределённая оптимизация:** $f_i(w_i)$ на каждом узле, но нужно $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Примеры “сложных” задач:

- **LASSO с ограничениями:** $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — связь f и g через w
- **Распределённая оптимизация:** $f_i(w_i)$ на каждом узле, но нужно $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения

Ограничение ISTA и координатного спуска

ISTA/FISTA: решает $\min_w f(w) + g(w)$ когда g имеет **вычислимый прокс-оператор**.

Координатный спуск: решает $\min_w f(w) + \sum_j h_j(w_j)$ когда g **разделяется по координатам**.

Что если ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Примеры “сложных” задач:

- **LASSO с ограничениями:** $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ — связь f и g через w
- **Распределённая оптимизация:** $f_i(w_i)$ на каждом узле, но нужно $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения

Идея ADMM: разделим переменные x и z , свяжем их ограничением и будем **чередовать** шаги.

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Зачем аугментация?

- Квадратичный штраф улучшает **обусловленность** задачи

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Зачем аугментация?

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых f, g

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Зачем аугментация?

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых f, g
- Позволяет разделить минимизацию по x и z

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Зачем аугментация?

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых f, g
- Позволяет разделить минимизацию по x и z

Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан: $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

Проблема обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Зачем аугментация?

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых f, g
- Позволяет разделить минимизацию по x и z

Параметр $\rho > 0$ — «штрафной параметр», определяет жёсткость ограничения.

ADMM: Метод множителей переменного направления

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь $u = \lambda/\rho$ — нормированная двойственная переменная (scaled dual variable).

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь $u = \lambda/\rho$ — нормированная двойственная переменная (scaled dual variable).

Три шага:

- **x-шаг:** минимизация по x с фиксированным z_k (проксимальная задача для f)

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь $u = \lambda/\rho$ — нормированная двойственная переменная (scaled dual variable).

Три шага:

- **х-шаг:** минимизация по x с фиксированным z_k (проксимальная задача для f)
- **z-шаг:** минимизация по z с фиксированным x_{k+1} (проксимальная задача для g)

Алгоритм ADMM

ADMM (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь $u = \lambda/\rho$ — нормированная двойственная переменная (scaled dual variable).

Три шага:

- **x-шаг:** минимизация по x с фиксированным z_k (проксимальная задача для f)
- **z-шаг:** минимизация по z с фиксированным x_{k+1} (проксимальная задача для g)
- **dual update:** обновление нарушения ограничения (как субградиентный шаг по u)

Consensus ADMM = DRS

Простейший случай: $\min_w f(w) + g(w)$

Consensus ADMM = DRS

Простейший случай: $\min_w f(w) + g(w)$

Запишем как consensus: $\min_{x=z} f(x) + g(z)$, то есть $A = I$, $B = -I$, $c = 0$.

Consensus ADMM = DRS

Простейший случай: $\min_w f(w) + g(w)$

Запишем как consensus: $\min_{x=z} f(x) + g(z)$, то есть $A = I$, $B = -I$, $c = 0$.

ADMM итерации:

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

Consensus ADMM = DRS

Простейший случай: $\min_w f(w) + g(w)$

Запишем как consensus: $\min_{x=z} f(x) + g(z)$, то есть $A = I$, $B = -I$, $c = 0$.

ADMM итерации:

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

Узнаёте? Это — расщепление Дугласа-Рэкфорда (DRS)!

Consensus ADMM = DRS

Простейший случай: $\min_w f(w) + g(w)$

Запишем как consensus: $\min_{x=z} f(x) + g(z)$, то есть $A = I$, $B = -I$, $c = 0$.

ADMM итерации:

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

Узнаёте? Это — расщепление Дугласа-Рэкфорда (DRS)!

Связь	Формула
DRS	$y_{k+1} = y_k + T_f(2T_g(y_k) - y_k) - T_g(y_k)$
Consensus ADMM	Эквивалентно при $T_f = \text{prox}_{f/\rho}$, $T_g = \text{prox}_{g/\rho}$

Сходимость ADMM

Теорема (Boyd et al. 2011)

Пусть f и g — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility: $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual: $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение: $f(x_k) + g(z_k) \rightarrow f^* + g^*$

Сходимость ADMM

Теорема (Boyd et al. 2011)

Пусть f и g — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility: $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual: $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение: $f(x_k) + g(z_k) \rightarrow f^* + g^*$

Линейная сходимость при μ -сильно выпуклой f :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho\|A\|^2}\right)^k$$

Сходимость ADMM

Теорема (Boyd et al. 2011)

Пусть f и g — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility: $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual: $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение: $f(x_k) + g(z_k) \rightarrow f^* + g^*$

Линейная сходимость при μ -сильно выпуклой f :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

Выбор ρ : оптимальный $\rho^* = \sqrt{\mu_f \cdot L_g}$ (геометрическое среднее).

Сходимость ADMM

Теорема (Boyd et al. 2011)

Пусть f и g — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility: $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual: $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение: $f(x_k) + g(z_k) \rightarrow f^* + g^*$

Линейная сходимость при μ -сильно выпуклой f :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

Выбор ρ : оптимальный $\rho^* = \sqrt{\mu_f \cdot L_g}$ (геометрическое среднее).

Критерии останова (Boyd et al.):

- Primal residual: $r^{\text{prim}} = Ax + Bz - c < \varepsilon^{\text{prim}}$

Сходимость ADMM

Теорема (Boyd et al. 2011)

Пусть f и g — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility: $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual: $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение: $f(x_k) + g(z_k) \rightarrow f^* + g^*$

Линейная сходимость при μ -сильно выпуклой f :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

Выбор ρ : оптимальный $\rho^* = \sqrt{\mu_f \cdot L_g}$ (геометрическое среднее).

Критерии останова (Boyd et al.):

- Primal residual: $r^{\text{prim}} = Ax + Bz - c < \varepsilon^{\text{prim}}$
- Dual residual: $r^{\text{dual}} = \rho A^\top B(z_k - z_{k-1}) < \varepsilon^{\text{dual}}$

ADMM для LASSO

x-шаг и z-шаг

Задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

x-шаг и z-шаг

Задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление: $x = w$, $z = w$, ограничение $x = z$.

х-шаг и z-шаг

Задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление: $x = w$, $z = w$, ограничение $x = z$.

х-шаг (гладкая часть f):

$$x_{k+1} = \arg \min_x \left[\frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

x-шаг и z-шаг

Задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление: $x = w$, $z = w$, ограничение $x = z$.

x-шаг (гладкая часть f):

$$x_{k+1} = \arg \min_x \left[\frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

Это ridge regression! **Аналитическое решение:**

$$x_{k+1} = \left(\frac{X^\top X}{n} + \rho I \right)^{-1} \left(\frac{X^\top y}{n} + \rho(z_k - u_k) \right)$$

Стоимость: $O(d^3)$ один раз (LU-разложение), $O(d^2)$ за итерацию.

х-шаг и z-шаг

Задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление: $x = w$, $z = w$, ограничение $x = z$.

х-шаг (гладкая часть f):

$$x_{k+1} = \arg \min_x \left[\frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

Это ridge regression! **Аналитическое решение:**

$$x_{k+1} = \left(\frac{X^\top X}{n} + \rho I \right)^{-1} \left(\frac{X^\top y}{n} + \rho(z_k - u_k) \right)$$

Стоимость: $O(d^3)$ один раз (LU-разложение), $O(d^2)$ за итерацию.

z-шаг (негладкая часть g):

$$z_{k+1} = \text{prox}_{\lambda/\rho}(x_{k+1} + u_k) = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$$

Это мягкое пороговое обрезание: $\mathcal{S}_\tau(v)_j = \text{sign}(v_j) \max(|v_j| - \tau, 0)$.

ADMM vs ISTA для LASSO

Критерий	ISTA	ADMM
x-шаг	$w - \frac{1}{L} \nabla f(w)$ (гр. шаг)	ridge regression (точно)
z-шаг	$\mathcal{S}_{\lambda/L}$ по всем	$\mathcal{S}_{\lambda/\rho}$ (параметр ρ)
Стоимость шага	$O(nd)$	$O(nd) + O(d^3)$ первый раз
Сходимость	$O(1/k)$	Линейная (при f с.в.)
Параллелизация	Сложная	Естественная

ADMM vs ISTA для LASSO

Критерий	ISTA	ADMM
x-шаг	$w - \frac{1}{L} \nabla f(w)$ (гр. шаг)	ridge regression (точно)
z-шаг	$\mathcal{S}_{\lambda/L}$ по всем	$\mathcal{S}_{\lambda/\rho}$ (параметр ρ)
Стоимость шага	$O(nd)$	$O(nd) + O(d^3)$ первый раз
Сходимость	$O(1/k)$	Линейная (при f с.в.)
Параллелизация	Сложная	Естественная

Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не $O(1/k)$)

ADMM vs ISTA для LASSO

Критерий	ISTA	ADMM
x-шаг	$w - \frac{1}{L} \nabla f(w)$ (гр. шаг)	ridge regression (точно)
z-шаг	$\mathcal{S}_{\lambda/L}$ по всем	$\mathcal{S}_{\lambda/\rho}$ (параметр ρ)
Стоимость шага	$O(nd)$	$O(nd) + O(d^3)$ первый раз
Сходимость	$O(1/k)$	Линейная (при f с.в.)
Параллелизация	Сложная	Естественная

Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не $O(1/k)$)
- Задача легко расщепляется на «гладкую» и «негладкую» части

ADMM vs ISTA для LASSO

Критерий	ISTA	ADMM
x-шаг	$w - \frac{1}{L} \nabla f(w)$ (гр. шаг)	ridge regression (точно)
z-шаг	$\mathcal{S}_{\lambda/L}$ по всем	$\mathcal{S}_{\lambda/\rho}$ (параметр ρ)
Стоимость шага	$O(nd)$	$O(nd) + O(d^3)$ первый раз
Сходимость	$O(1/k)$	Линейная (при f с.в.)
Параллелизация	Сложная	Естественная

Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не $O(1/k)$)
- Задача легко расщепляется на «гладкую» и «негладкую» части
- Требуется параллельное/распределённое решение

Distributed ADMM

Consensus ADMM для N агентов

Задача: N агентов, у каждого своя $f_i(w)$:

$$\min_w \sum_{i=1}^N f_i(w)$$

Consensus ADMM для N агентов

Задача: N агентов, у каждого своя $f_i(w)$:

$$\min_w \sum_{i=1}^N f_i(w)$$

Consensus form: каждый агент i имеет x_i , глобальная переменная z :

$$\min_{\{x_i\}, z} \sum_{i=1}^N f_i(x_i) \quad \text{s.t.} \quad x_i = z, \quad \forall i$$

Consensus ADMM для N агентов

Задача: N агентов, у каждого своя $f_i(w)$:

$$\min_w \sum_{i=1}^N f_i(w)$$

Consensus form: каждый агент i имеет x_i , глобальная переменная z :

$$\min_{\{x_i\}, z} \sum_{i=1}^N f_i(x_i) \quad \text{s.t.} \quad x_i = z, \forall i$$

Итерации (полностью параллельные):

$$x_i^{k+1} = \arg \min_{x_i} \left[f_i(x_i) + \frac{\rho}{2} \|x_i - z^k + u_i^k\|^2 \right] \quad (\text{параллельно!})$$

$$z^{k+1} = \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + u_i^k) \quad (\text{усреднение})$$

$$u_i^{k+1} = u_i^k + x_i^{k+1} - z^{k+1} \quad (\text{параллельно})$$

Ключевые свойства distributed ADMM

Параллелизм: x-шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Связь с Federated Learning:

- **FedAvg:** локальные шаги SGD $\rightarrow$ усреднение весов. Неточное усреднение.

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Связь с Federated Learning:

- **FedAvg:** локальные шаги SGD $\rightarrow$ усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными u_i .

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Связь с Federated Learning:

- **FedAvg:** локальные шаги SGD $\rightarrow$ усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными u_i .
- FedAvg $\approx$ consensus ADMM без dual update (поэтому страдает при non-IID данных!).

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Связь с Federated Learning:

- **FedAvg:** локальные шаги SGD $\rightarrow$ усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными u_i .
- FedAvg $\approx$ consensus ADMM без dual update (поэтому страдает при non-IID данных!).

Ключевые свойства distributed ADMM

Параллелизм: x -шаги независимы $\rightarrow$ каждый агент решает свою задачу локально.

Коммуникация: только усреднение z — AllReduce операция ($O(d)$ данных).

Конфиденциальность: агент передаёт x_i , не исходные данные f_i .

Связь с Federated Learning:

- **FedAvg:** локальные шаги SGD $\rightarrow$ усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными u_i .
- FedAvg $\approx$ consensus ADMM без dual update (поэтому страдает при non-IID данных!).

Связь с PhD: distributed ADMM = operator splitting для составных операторов на N множествах!

Итоговое сравнение

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- Ли-Троттер: $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:** $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок
- **Стренг:** $e^{Ah/2}e^{Bh}e^{Ah/2}$ — явный, второй порядок

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:** $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок
- **Стренг:** $e^{Ah/2}e^{Bh}e^{Ah/2}$ — явный, второй порядок
- **DRS/ADMM:** $x = \text{prox}_{f/\rho}(\cdot)$, $z = \text{prox}_{g/\rho}(\cdot)$ — **неявный**, нет ограничения шага

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:** $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок
- **Стренг:** $e^{Ah/2}e^{Bh}e^{Ah/2}$ — явный, второй порядок
- **DRS/ADMM:** $x = \text{prox}_{f/\rho}(\cdot)$, $z = \text{prox}_{g/\rho}(\cdot)$ — **неявный**, нет ограничения шага

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:** $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок
- **Стренг:** $e^{Ah/2}e^{Bh}e^{Ah/2}$ — явный, второй порядок
- **DRS/ADMM:** $x = \text{prox}_{f/\rho}(\cdot)$, $z = \text{prox}_{g/\rho}(\cdot)$ — **неявный**, нет ограничения шага

Преимущество неявного (ADMM/DRS): сходится без ограничения на ρ (в отличие от явных методов, где $h < 2/L$).

Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:** $e^{(A+B)h} \approx e^{Ah}e^{Bh}$ — явный, первый порядок
- **Стренг:** $e^{Ah/2}e^{Bh}e^{Ah/2}$ — явный, второй порядок
- **DRS/ADMM:** $x = \text{prox}_{f/\rho}(\cdot)$, $z = \text{prox}_{g/\rho}(\cdot)$ — **неявный**, нет ограничения шага

Преимущество неявного (ADMM/DRS): сходится без ограничения на ρ (в отличие от явных методов, где $h < 2/L$).

DRS сходится для монотонных операторов — строже чем просто выпуклость. Это центральный результат современной теории расщепления.

Большая таблица: когда что использовать

Задача	Лучший метод	Почему
Гладкая выпуклая f $f + \lambda \ w\ _1$ (малая d)	GD или AGD ISTA/FISTA	$O(1/k^2)$, просто Прокс + ускорение Нестерова
$f + \lambda \ w\ _1$ (разреженная X)	Coord. CD	Адаптивный шаг по координатам
Составная $f(x) + g(z)$, $Ax = Bz$	ADMM	Нет глобального прокс-шага
Распределённая $\sum f_i(w)$	Consensus ADMM	Параллелизм + коммуникация $O(d)$
Нейросети	Adam/SGD	Нелинейность, большой d

Большая таблица: когда что использовать

Задача	Лучший метод	Почему
Гладкая выпуклая f $f + \lambda \ w\ _1$ (малая d)	GD или AGD ISTA/FISTA	$O(1/k^2)$, просто Прокс + ускорение Нестерова
$f + \lambda \ w\ _1$ (разреженная X)	Coord. CD	Адаптивный шаг по координатам
Составная $f(x) + g(z)$, $Ax = Bz$	ADMM	Нет глобального прокс-шага
Распределённая $\sum f_i(w)$	Consensus ADMM	Параллелизм + коммуникация $O(d)$
Нейросети	Adam/SGD	Нелинейность, большой d

Вывод: ADMM — самый гибкий метод, работает когда другие не применимы.

Ключевые формулы

Объект	Формула
Аугм. лагранжиан	$\mathcal{L}_\rho = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \ Ax + Bz - c\ ^2$
x-шаг	$x_{k+1} = \arg \min_x [f(x) + \frac{\rho}{2} \ Ax + Bz_k - c + u_k\ ^2]$
z-шаг	$z_{k+1} = \text{prox}_{g/\rho}(Ax_{k+1} + u_k - c)$
dual update	$u_{k+1} = u_k + Ax_{k+1} + Bz_{k+1} - c$
LASSO x-шаг	$x_{k+1} = (\frac{X^\top X}{n} + \rho I)^{-1} (\frac{X^\top y}{n} + \rho(z_k - u_k))$
LASSO z-шаг	$z_{k+1} = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$
Consensus ADMM	$z = \frac{1}{N} \sum_i (x_i + u_i)$

Ключевые формулы

Объект	Формула
Аугм. лагранжиан	$\mathcal{L}_\rho = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \ Ax + Bz - c\ ^2$
x-шаг	$x_{k+1} = \arg \min_x [f(x) + \frac{\rho}{2} \ Ax + Bz_k - c + u_k\ ^2]$
z-шаг	$z_{k+1} = \text{prox}_{g/\rho}(Ax_{k+1} + u_k - c)$
dual update	$u_{k+1} = u_k + Ax_{k+1} + Bz_{k+1} - c$
LASSO x-шаг	$x_{k+1} = (\frac{X^\top X}{n} + \rho I)^{-1} (\frac{X^\top y}{n} + \rho(z_k - u_k))$
LASSO z-шаг	$z_{k+1} = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$
Consensus ADMM	$z = \frac{1}{N} \sum_i (x_i + u_i)$

Связи с курсом: Л7 (ISTA) $\leftarrow$ z-шаг ADMM | Л11 (CD) $\leftarrow$ x-шаг специальный случай | Л17 (FL) $\leftarrow$ consensus ADMM

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если $n \gg d$ vs $n \ll d$? (hint: Woodbury identity)

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если $n \gg d$ vs $n \ll d$? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ($N = 2$) с $f_1 = f_2 = f/2$ эквивалентен ADMM для одного агента с $f + g$ при $g = 0$.

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если $n \gg d$ vs $n \ll d$? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ($N = 2$) с $f_1 = f_2 = f/2$ эквивалентен ADMM для одного агента с $f + g$ при $g = 0$.

Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$.

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если $n \gg d$ vs $n \ll d$? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ($N = 2$) с $f_1 = f_2 = f/2$ эквивалентен ADMM для одного агента с $f + g$ при $g = 0$.

Следующая лекция (#13): Прямо-двойственные методы (Chambolle-Pock, TV denoising, PDHG).