




**ADMM и проксимальное расщепление**

**Даня Меркулов**

ФКН ВШЭ

Мотивация: когда прокс-шаг не разделяется

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Примеры “сложных” задач:**

- **LASSO с ограничениями:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — связь  $f$  и  $g$  через  $w$

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Примеры “сложных” задач:**

- **LASSO с ограничениями:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — связь  $f$  и  $g$  через  $w$
- **Распределённая оптимизация:**  $f_i(w_i)$  на каждом узле, но нужно  $w_i = w_j$

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Примеры “сложных” задач:**

- **LASSO с ограничениями:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — связь  $f$  и  $g$  через  $w$
- **Распределённая оптимизация:**  $f_i(w_i)$  на каждом узле, но нужно  $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения



# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Примеры “сложных” задач:**

- **LASSO с ограничениями:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — связь  $f$  и  $g$  через  $w$
- **Распределённая оптимизация:**  $f_i(w_i)$  на каждом узле, но нужно  $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения

# Ограничение ISTA и координатного спуска

**ISTA/FISTA:** решает  $\min_w f(w) + g(w)$  когда  $g$  имеет **вычислимый прокс-оператор**.

**Координатный спуск:** решает  $\min_w f(w) + \sum_j h_j(w_j)$  когда  $g$  **разделяется по координатам**.

**Что если** ни одно из этих условий не выполнено?

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Примеры “сложных” задач:**

- **LASSO с ограничениями:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$  — связь  $f$  и  $g$  через  $w$
- **Распределённая оптимизация:**  $f_i(w_i)$  на каждом узле, но нужно  $w_i = w_j$
- **SVM:** квадратичная цель + линейные ограничения

**Идея ADMM:** разделим переменные  $x$  и  $z$ , свяжем их ограничением и будем **чередовать** шаги.

# Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

# Аугментированный лагранжиан

Задача (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

Лагранжиан:  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

**Зачем аугментация?**

- Квадратичный штраф улучшает **обусловленность** задачи

# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

**Зачем аугментация?**

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых  $f, g$

# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

**Зачем аугментация?**

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых  $f, g$
- Позволяет разделить минимизацию по  $x$  и  $z$



# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

**Зачем аугментация?**

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых  $f, g$
- Позволяет разделить минимизацию по  $x$  и  $z$

# Аугментированный лагранжиан

**Задача** (общая форма):

$$\min_{x,z} f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

**Лагранжиан:**  $\mathcal{L}(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c)$

**Проблема** обычного метода множителей: может не сходиться без выпуклости. **Решение** — добавить квадратичный штраф:

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

**Зачем аугментация?**

- Квадратичный штраф улучшает **обусловленность** задачи
- Обеспечивает сходимость при невыпуклых  $f, g$
- Позволяет разделить минимизацию по  $x$  и  $z$

**Параметр**  $\rho > 0$  — «штрафной параметр», определяет жёсткость ограничения.

## ADMM: Метод множителей переменного направления

# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь  $u = \lambda/\rho$  — нормированная двойственная переменная (scaled dual variable).

# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь  $u = \lambda/\rho$  — нормированная двойственная переменная (scaled dual variable).

**Три шага:**

- **x-шаг:** минимизация по  $x$  с фиксированным  $z_k$  (проксимальная задача для  $f$ )

# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь  $u = \lambda/\rho$  — нормированная двойственная переменная (scaled dual variable).

**Три шага:**

- **x-шаг:** минимизация по  $x$  с фиксированным  $z_k$  (проксимальная задача для  $f$ )
- **z-шаг:** минимизация по  $z$  с фиксированным  $x_{k+1}$  (проксимальная задача для  $g$ )



# Алгоритм ADMM

**ADMM** (Alternating Direction Method of Multipliers), Boyd et al. 2011:

Итерации ADMM (scaled form)

$$\begin{aligned}x_{k+1} &= \arg \min_x \left[ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|^2 \right] \\z_{k+1} &= \arg \min_z \left[ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|^2 \right] \\u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c\end{aligned}$$

Здесь  $u = \lambda/\rho$  — нормированная двойственная переменная (scaled dual variable).

**Три шага:**

- **x-шаг:** минимизация по  $x$  с фиксированным  $z_k$  (проксимальная задача для  $f$ )
- **z-шаг:** минимизация по  $z$  с фиксированным  $x_{k+1}$  (проксимальная задача для  $g$ )
- **dual update:** обновление нарушения ограничения (как субградиентный шаг по  $u$ )

# Consensus ADMM = DRS

Простейший случай:  $\min_w f(w) + g(w)$

## Consensus ADMM = DRS

Простейший случай:  $\min_w f(w) + g(w)$

Запишем как consensus:  $\min_{x=z} f(x) + g(z)$ , то есть  $A = I$ ,  $B = -I$ ,  $c = 0$ .

# Consensus ADMM = DRS

**Простейший случай:**  $\min_w f(w) + g(w)$

Запишем как consensus:  $\min_{x=z} f(x) + g(z)$ , то есть  $A = I$ ,  $B = -I$ ,  $c = 0$ .

**ADMM итерации:**

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

# Consensus ADMM = DRS

**Простейший случай:**  $\min_w f(w) + g(w)$

Запишем как consensus:  $\min_{x=z} f(x) + g(z)$ , то есть  $A = I$ ,  $B = -I$ ,  $c = 0$ .

**ADMM итерации:**

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

**Узнаёте? Это — расщепление Дугласа-Рэкфорда (DRS)!**

# Consensus ADMM = DRS

**Простейший случай:**  $\min_w f(w) + g(w)$

Запишем как consensus:  $\min_{x=z} f(x) + g(z)$ , то есть  $A = I$ ,  $B = -I$ ,  $c = 0$ .

**ADMM итерации:**

$$x_{k+1} = \text{prox}_{f/\rho}(z_k - u_k)$$

$$z_{k+1} = \text{prox}_{g/\rho}(x_{k+1} + u_k)$$

$$u_{k+1} = u_k + x_{k+1} - z_{k+1}$$

**Узнаёте? Это — расщепление Дугласа-Рэкфорда (DRS)!**

---

Связь

Формула

---

DRS

$$y_{k+1} = y_k + T_f(2T_g(y_k) - y_k) - T_g(y_k)$$

Consensus ADMM

$$\text{Эквивалентно при } T_f = \text{prox}_{f/\rho}, T_g = \text{prox}_{g/\rho}$$

---

# Сходимость ADMM

## Теорема (Boyd et al. 2011)

Пусть  $f$  и  $g$  — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility:  $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual:  $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение:  $f(x_k) + g(z_k) \rightarrow f^* + g^*$

# Сходимость ADMM

## Теорема (Boyd et al. 2011)

Пусть  $f$  и  $g$  — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility:  $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual:  $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение:  $f(x_k) + g(z_k) \rightarrow f^* + g^*$

**Линейная сходимость** при  $\mu$ -сильно выпуклой  $f$ :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho\|A\|^2}\right)^k$$



# Сходимость ADMM

## Теорема (Boyd et al. 2011)

Пусть  $f$  и  $g$  — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility:  $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual:  $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение:  $f(x_k) + g(z_k) \rightarrow f^* + g^*$

**Линейная сходимость** при  $\mu$ -сильно выпуклой  $f$ :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

**Выбор  $\rho$ :** оптимальный  $\rho^* = \sqrt{\mu_f \cdot L_g}$  (геометрическое среднее).

# Сходимость ADMM

## Теорема (Boyd et al. 2011)

Пусть  $f$  и  $g$  — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility:  $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual:  $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение:  $f(x_k) + g(z_k) \rightarrow f^* + g^*$

**Линейная сходимость** при  $\mu$ -сильно выпуклой  $f$ :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

**Выбор  $\rho$ :** оптимальный  $\rho^* = \sqrt{\mu_f \cdot L_g}$  (геометрическое среднее).

**Критерии останова** (Boyd et al.):

- Primal residual:  $r^{\text{prim}} = Ax + Bz - c < \varepsilon^{\text{prim}}$

# Сходимость ADMM

## Теорема (Boyd et al. 2011)

Пусть  $f$  и  $g$  — замкнутые выпуклые функции, задача имеет решение. Тогда:

- Feasibility:  $\|Ax_k + Bz_k - c\| \rightarrow 0$
- Dual:  $\rho A^\top B(z_k - z_{k-1}) \rightarrow 0$
- Значение:  $f(x_k) + g(z_k) \rightarrow f^* + g^*$

**Линейная сходимость** при  $\mu$ -сильно выпуклой  $f$ :

$$\|r_k\|^2 \leq C \left(1 - \frac{\mu}{\mu + \rho \|A\|^2}\right)^k$$

**Выбор  $\rho$ :** оптимальный  $\rho^* = \sqrt{\mu_f \cdot L_g}$  (геометрическое среднее).

**Критерии останова** (Boyd et al.):

- Primal residual:  $r^{\text{prim}} = Ax + Bz - c < \varepsilon^{\text{prim}}$
- Dual residual:  $r^{\text{dual}} = \rho A^\top B(z_k - z_{k-1}) < \varepsilon^{\text{dual}}$

## ADMM для LASSO

## x-шаг и z-шаг

Задача **LASSO**:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

## x-шаг и z-шаг

Задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление:  $x = w$ ,  $z = w$ , ограничение  $x = z$ .

## х-шаг и z-шаг

Задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Consensus расщепление:  $x = w$ ,  $z = w$ , ограничение  $x = z$ .

х-шаг (гладкая часть  $f$ ):

$$x_{k+1} = \arg \min_x \left[ \frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

## x-шаг и z-шаг

**Задача LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Consensus расщепление:**  $x = w$ ,  $z = w$ , ограничение  $x = z$ .

**x-шаг** (гладкая часть  $f$ ):

$$x_{k+1} = \arg \min_x \left[ \frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

Это ridge regression! **Аналитическое решение:**

$$x_{k+1} = \left( \frac{X^\top X}{n} + \rho I \right)^{-1} \left( \frac{X^\top y}{n} + \rho(z_k - u_k) \right)$$

Стоимость:  $O(d^3)$  один раз (LU-разложение),  $O(d^2)$  за итерацию.



## х-шаг и z-шаг

**Задача LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Consensus расщепление:**  $x = w$ ,  $z = w$ , ограничение  $x = z$ .

**х-шаг** (гладкая часть  $f$ ):

$$x_{k+1} = \arg \min_x \left[ \frac{1}{2n} \|Xx - y\|^2 + \frac{\rho}{2} \|x - z_k + u_k\|^2 \right]$$

Это ridge regression! **Аналитическое решение:**

$$x_{k+1} = \left( \frac{X^\top X}{n} + \rho I \right)^{-1} \left( \frac{X^\top y}{n} + \rho(z_k - u_k) \right)$$

Стоимость:  $O(d^3)$  один раз (LU-разложение),  $O(d^2)$  за итерацию.

**z-шаг** (негладкая часть  $g$ ):

$$z_{k+1} = \text{prox}_{\lambda/\rho}(x_{k+1} + u_k) = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$$

Это мягкое пороговое обрезание:  $\mathcal{S}_\tau(v)_j = \text{sign}(v_j) \max(|v_j| - \tau, 0)$ .

# ADMM vs ISTA для LASSO

| Критерий       | ISTA                                    | ADMM                                            |
|----------------|-----------------------------------------|-------------------------------------------------|
| x-шаг          | $w - \frac{1}{L} \nabla f(w)$ (гр. шаг) | ridge regression (точно)                        |
| z-шаг          | $\mathcal{S}_{\lambda/L}$ по всем       | $\mathcal{S}_{\lambda/\rho}$ (параметр $\rho$ ) |
| Стоимость шага | $O(nd)$                                 | $O(nd) + O(d^3)$ первый раз                     |
| Сходимость     | $O(1/k)$                                | Линейная (при $f$ с.в.)                         |
| Параллелизация | Сложная                                 | Естественная                                    |

# ADMM vs ISTA для LASSO

| Критерий       | ISTA                                    | ADMM                                            |
|----------------|-----------------------------------------|-------------------------------------------------|
| x-шаг          | $w - \frac{1}{L} \nabla f(w)$ (гр. шаг) | ridge regression (точно)                        |
| z-шаг          | $\mathcal{S}_{\lambda/L}$ по всем       | $\mathcal{S}_{\lambda/\rho}$ (параметр $\rho$ ) |
| Стоимость шага | $O(nd)$                                 | $O(nd) + O(d^3)$ первый раз                     |
| Сходимость     | $O(1/k)$                                | Линейная (при $f$ с.в.)                         |
| Параллелизация | Сложная                                 | Естественная                                    |

## Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не  $O(1/k)$ )

# ADMM vs ISTA для LASSO

| Критерий       | ISTA                                    | ADMM                                            |
|----------------|-----------------------------------------|-------------------------------------------------|
| x-шаг          | $w - \frac{1}{L} \nabla f(w)$ (гр. шаг) | ridge regression (точно)                        |
| z-шаг          | $\mathcal{S}_{\lambda/L}$ по всем       | $\mathcal{S}_{\lambda/\rho}$ (параметр $\rho$ ) |
| Стоимость шага | $O(nd)$                                 | $O(nd) + O(d^3)$ первый раз                     |
| Сходимость     | $O(1/k)$                                | Линейная (при $f$ с.в.)                         |
| Параллелизация | Сложная                                 | Естественная                                    |

## Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не  $O(1/k)$ )
- Задача легко расщепляется на «гладкую» и «негладкую» части

# ADMM vs ISTA для LASSO

| Критерий       | ISTA                                    | ADMM                                            |
|----------------|-----------------------------------------|-------------------------------------------------|
| x-шаг          | $w - \frac{1}{L} \nabla f(w)$ (гр. шаг) | ridge regression (точно)                        |
| z-шаг          | $\mathcal{S}_{\lambda/L}$ по всем       | $\mathcal{S}_{\lambda/\rho}$ (параметр $\rho$ ) |
| Стоимость шага | $O(nd)$                                 | $O(nd) + O(d^3)$ первый раз                     |
| Сходимость     | $O(1/k)$                                | Линейная (при $f$ с.в.)                         |
| Параллелизация | Сложная                                 | Естественная                                    |

## Когда ADMM лучше ISTA?

- Нужна линейная сходимость (не  $O(1/k)$ )
- Задача легко расщепляется на «гладкую» и «негладкую» части
- Требуется параллельное/распределённое решение

## Distributed ADMM

## Consensus ADMM для $N$ агентов

**Задача:**  $N$  агентов, у каждого своя  $f_i(w)$ :

$$\min_w \sum_{i=1}^N f_i(w)$$

## Consensus ADMM для $N$ агентов

**Задача:**  $N$  агентов, у каждого своя  $f_i(w)$ :

$$\min_w \sum_{i=1}^N f_i(w)$$

**Consensus form:** каждый агент  $i$  имеет  $x_i$ , глобальная переменная  $z$ :

$$\min_{\{x_i\}, z} \sum_{i=1}^N f_i(x_i) \quad \text{s.t.} \quad x_i = z, \quad \forall i$$



## Consensus ADMM для $N$ агентов

**Задача:**  $N$  агентов, у каждого своя  $f_i(w)$ :

$$\min_w \sum_{i=1}^N f_i(w)$$

**Consensus form:** каждый агент  $i$  имеет  $x_i$ , глобальная переменная  $z$ :

$$\min_{\{x_i\}, z} \sum_{i=1}^N f_i(x_i) \quad \text{s.t.} \quad x_i = z, \forall i$$

**Итерации** (полностью параллельные):

$$x_i^{k+1} = \arg \min_{x_i} \left[ f_i(x_i) + \frac{\rho}{2} \|x_i - z^k + u_i^k\|^2 \right] \quad (\text{параллельно!})$$

$$z^{k+1} = \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + u_i^k) \quad (\text{усреднение})$$

$$u_i^{k+1} = u_i^k + x_i^{k+1} - z^{k+1} \quad (\text{параллельно})$$

# Ключевые свойства distributed ADMM

**Параллелизм:** x-шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

**Связь с Federated Learning:**

- **FedAvg:** локальные шаги SGD  $\rightarrow$  усреднение весов. Неточное усреднение.

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

**Связь с Federated Learning:**

- **FedAvg:** локальные шаги SGD  $\rightarrow$  усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными  $u_i$ .

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

**Связь с Federated Learning:**

- **FedAvg:** локальные шаги SGD  $\rightarrow$  усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными  $u_i$ .
- FedAvg  $\approx$  consensus ADMM без dual update (поэтому страдает при non-IID данных!).

# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

**Связь с Federated Learning:**

- **FedAvg:** локальные шаги SGD  $\rightarrow$  усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными  $u_i$ .
- FedAvg  $\approx$  consensus ADMM без dual update (поэтому страдает при non-IID данных!).



# Ключевые свойства distributed ADMM

**Параллелизм:**  $x$ -шаги независимы  $\rightarrow$  каждый агент решает свою задачу локально.

**Коммуникация:** только усреднение  $z$  — AllReduce операция ( $O(d)$  данных).

**Конфиденциальность:** агент передаёт  $x_i$ , не исходные данные  $f_i$ .

**Связь с Federated Learning:**

- **FedAvg:** локальные шаги SGD  $\rightarrow$  усреднение весов. Неточное усреднение.
- **Consensus ADMM:** точное усреднение с двойственными переменными  $u_i$ .
- FedAvg  $\approx$  consensus ADMM без dual update (поэтому страдает при non-IID данных!).

**Связь с PhD:** distributed ADMM = operator splitting для составных операторов на  $N$  множествах!

## Итоговое сравнение

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- Ли-Троттер:  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:**  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок
- **Стренг:**  $e^{Ah/2}e^{Bh}e^{Ah/2}$  — явный, второй порядок

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:**  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок
- **Стренг:**  $e^{Ah/2}e^{Bh}e^{Ah/2}$  — явный, второй порядок
- **DRS/ADMM:**  $x = \text{prox}_{f/\rho}(\cdot)$ ,  $z = \text{prox}_{g/\rho}(\cdot)$  — **неявный**, нет ограничения шага

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:**  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок
- **Стренг:**  $e^{Ah/2}e^{Bh}e^{Ah/2}$  — явный, второй порядок
- **DRS/ADMM:**  $x = \text{prox}_{f/\rho}(\cdot)$ ,  $z = \text{prox}_{g/\rho}(\cdot)$  — **неявный**, нет ограничения шага

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:**  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок
- **Стренг:**  $e^{Ah/2}e^{Bh}e^{Ah/2}$  — явный, второй порядок
- **DRS/ADMM:**  $x = \text{prox}_{f/\rho}(\cdot)$ ,  $z = \text{prox}_{g/\rho}(\cdot)$  — **неявный**, нет ограничения шага

**Преимущество неявного (ADMM/DRS):** сходится без ограничения на  $\rho$  (в отличие от явных методов, где  $h < 2/L$ ).

# Связь ADMM с расщеплением операторов

Оператор расщепления (PhD hook):

- **Ли-Троттер:**  $e^{(A+B)h} \approx e^{Ah}e^{Bh}$  — явный, первый порядок
- **Стренг:**  $e^{Ah/2}e^{Bh}e^{Ah/2}$  — явный, второй порядок
- **DRS/ADMM:**  $x = \text{prox}_{f/\rho}(\cdot)$ ,  $z = \text{prox}_{g/\rho}(\cdot)$  — **неявный**, нет ограничения шага

**Преимущество неявного (ADMM/DRS):** сходится без ограничения на  $\rho$  (в отличие от явных методов, где  $h < 2/L$ ).

**DRS сходится для монотонных операторов** — строже чем просто выпуклость. Это центральный результат современной теории расщепления.



## Большая таблица: когда что использовать

| Задача                                                     | Лучший метод             | Почему                                                |
|------------------------------------------------------------|--------------------------|-------------------------------------------------------|
| Гладкая выпуклая $f$<br>$f + \lambda \ w\ _1$ (малая $d$ ) | GD или AGD<br>ISTA/FISTA | $O(1/k^2)$ , просто<br>Прокс + ускорение<br>Нестерова |
| $f + \lambda \ w\ _1$ (разреженная $X$ )                   | Coord. CD                | Адаптивный шаг по<br>координатам                      |
| Составная $f(x) + g(z)$ ,<br>$Ax = Bz$                     | <b>ADMM</b>              | Нет глобального прокс-шага                            |
| Распределённая $\sum f_i(w)$                               | <b>Consensus ADMM</b>    | Параллелизм +<br>коммуникация $O(d)$                  |
| Нейросети                                                  | Adam/SGD                 | Нелинейность, большой $d$                             |

## Большая таблица: когда что использовать

| Задача                                                     | Лучший метод             | Почему                                                |
|------------------------------------------------------------|--------------------------|-------------------------------------------------------|
| Гладкая выпуклая $f$<br>$f + \lambda \ w\ _1$ (малая $d$ ) | GD или AGD<br>ISTA/FISTA | $O(1/k^2)$ , просто<br>Прокс + ускорение<br>Нестерова |
| $f + \lambda \ w\ _1$ (разреженная $X$ )                   | Coord. CD                | Адаптивный шаг по<br>координатам                      |
| Составная $f(x) + g(z)$ ,<br>$Ax = Bz$                     | <b>ADMM</b>              | Нет глобального прокс-шага                            |
| Распределённая $\sum f_i(w)$                               | <b>Consensus ADMM</b>    | Параллелизм +<br>коммуникация $O(d)$                  |
| Нейросети                                                  | Adam/SGD                 | Нелинейность, большой $d$                             |

**Вывод:** ADMM — самый гибкий метод, работает когда другие не применимы.

# Ключевые формулы

| Объект           | Формула                                                                                    |
|------------------|--------------------------------------------------------------------------------------------|
| Аугм. лагранжиан | $\mathcal{L}_\rho = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \ Ax + Bz - c\ ^2$ |
| x-шаг            | $x_{k+1} = \arg \min_x [f(x) + \frac{\rho}{2} \ Ax + Bz_k - c + u_k\ ^2]$                  |
| z-шаг            | $z_{k+1} = \text{prox}_{g/\rho}(Ax_{k+1} + u_k - c)$                                       |
| dual update      | $u_{k+1} = u_k + Ax_{k+1} + Bz_{k+1} - c$                                                  |
| LASSO x-шаг      | $x_{k+1} = (\frac{X^\top X}{n} + \rho I)^{-1} (\frac{X^\top y}{n} + \rho(z_k - u_k))$      |
| LASSO z-шаг      | $z_{k+1} = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$                                      |
| Consensus ADMM   | $z = \frac{1}{N} \sum_i (x_i + u_i)$                                                       |

# Ключевые формулы

| Объект           | Формула                                                                                    |
|------------------|--------------------------------------------------------------------------------------------|
| Аугм. лагранжиан | $\mathcal{L}_\rho = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \ Ax + Bz - c\ ^2$ |
| х-шаг            | $x_{k+1} = \arg \min_x [f(x) + \frac{\rho}{2} \ Ax + Bz_k - c + u_k\ ^2]$                  |
| z-шаг            | $z_{k+1} = \text{prox}_{g/\rho}(Ax_{k+1} + u_k - c)$                                       |
| dual update      | $u_{k+1} = u_k + Ax_{k+1} + Bz_{k+1} - c$                                                  |
| LASSO х-шаг      | $x_{k+1} = (\frac{X^\top X}{n} + \rho I)^{-1} (\frac{X^\top y}{n} + \rho(z_k - u_k))$      |
| LASSO z-шаг      | $z_{k+1} = \mathcal{S}_{\lambda/\rho}(x_{k+1} + u_k)$                                      |
| Consensus ADMM   | $z = \frac{1}{N} \sum_i (x_i + u_i)$                                                       |

**Связи с курсом:** Л7 (ISTA)  $\leftarrow$  z-шаг ADMM | Л11 (CD)  $\leftarrow$  х-шаг специальный случай | Л17 (FL)  $\leftarrow$  consensus ADMM

## Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

## Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).

## Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если  $n \gg d$  vs  $n \ll d$ ? (hint: Woodbury identity)

## Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если  $n \gg d$  vs  $n \ll d$ ? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ( $N = 2$ ) с  $f_1 = f_2 = f/2$  эквивалентен ADMM для одного агента с  $f + g$  при  $g = 0$ .



## Домашнее задание

Тест Лекции 12 (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

Задача для размышления: дана задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если  $n \gg d$  vs  $n \ll d$ ? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ( $N = 2$ ) с  $f_1 = f_2 = f/2$  эквивалентен ADMM для одного агента с  $f + g$  при  $g = 0$ .

## Домашнее задание

**Тест Лекции 12** (6 задач, 35 баллов, 60 мин): `hse26.fmin.xyz`

**Задача для размышления:** дана задача LASSO:  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$ .

1. Запишите полные итерации ADMM (x-шаг, z-шаг, dual update).
2. Что происходит с x-шагом если  $n \gg d$  vs  $n \ll d$ ? (hint: Woodbury identity)
3. Покажите что consensus ADMM для двух агентов ( $N = 2$ ) с  $f_1 = f_2 = f/2$  эквивалентен ADMM для одного агента с  $f + g$  при  $g = 0$ .

**Следующая лекция (#13):** Прямо-двойственные методы (Chambolle-Pock, TV denoising, PDHG).