




Прямо-двойственные методы. PDHG

Даня Меркулов

ФКН ВШЭ

Мотивация: когда прокс-шаг не разделяется

# Ограничение ISTA и ADMM

**ISTA/FISTA:** решает  $\min_x f(x) + g(x)$  — прокс  $g$  вычислим напрямую.

# Ограничение ISTA и ADMM

**ISTA/FISTA:** решает  $\min_x f(x) + g(x)$  — прокс  $g$  вычислим напрямую.

**ADMM:** решает  $\min f(x) + g(z)$  при  $Ax + Bz = c$  — разделяет переменные.

# Ограничение ISTA и ADMM

**ISTA/FISTA:** решает  $\min_x f(x) + g(x)$  — прокс  $g$  вычислим напрямую.

**ADMM:** решает  $\min f(x) + g(z)$  при  $Ax + Bz = c$  — разделяет переменные.

**Новая проблема:** что делать с  $\min_x f(x) + g(Kx)$ ?

$$\min_{x \in \mathbb{R}^d} f(x) + g(Kx), \quad K \in \mathbb{R}^{m \times d}$$

# Ограничение ISTA и ADMM

**ISTA/FISTA:** решает  $\min_x f(x) + g(x)$  — прокс  $g$  вычислим напрямую.

**ADMM:** решает  $\min f(x) + g(z)$  при  $Ax + Bz = c$  — разделяет переменные.

**Новая проблема:** что делать с  $\min_x f(x) + g(Kx)$ ?

$$\min_{x \in \mathbb{R}^d} f(x) + g(Kx), \quad K \in \mathbb{R}^{m \times d}$$

**Проблема:**  $\text{prox}_{\tau g(K \cdot)}(v)$  не вычисляется в замкнутой форме — нет формулы для  $\text{prox}_{g \circ K}$ !

## Примеры составных задач

**TV-денойзинг:** восстановить изображение из зашумлённого  $f$ :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь  $K = \nabla$  (дискретный градиент),  $g(z) = \lambda \|z\|_{1,2}$ .

## Примеры составных задач

**TV-денойзинг:** восстановить изображение из зашумлённого  $f$ :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь  $K = \nabla$  (дискретный градиент),  $g(z) = \lambda \|z\|_{1,2}$ .

**Томография:**  $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$ , где  $A$  — оператор Радона.



## Примеры составных задач

**TV-денойзинг:** восстановить изображение из зашумлённого  $f$ :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь  $K = \nabla$  (дискретный градиент),  $g(z) = \lambda \|z\|_{1,2}$ .

**Томография:**  $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$ , где  $A$  — оператор Радона.

**Обобщённый LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$ , где  $D$  — матрица разностей.

## Примеры составных задач

**TV-денойзинг:** восстановить изображение из зашумлённого  $f$ :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь  $K = \nabla$  (дискретный градиент),  $g(z) = \lambda \|z\|_{1,2}$ .

**Томография:**  $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$ , где  $A$  — оператор Радона.

**Обобщённый LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$ , где  $D$  — матрица разностей.

### Общий вопрос

Как решить  $\min_x f(x) + g(Kx)$  без вычисления  $\text{prox}_{g(K\cdot)}$ ?

## Сопряжённые функции

# Преобразование Лежандра-Фенхеля

## Определение

Сопряжённая функция  $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ :

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

# Преобразование Лежандра-Фенхеля

## Определение

Сопряжённая функция  $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ :

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{ \langle z, y \rangle - g(z) \}$$

**Геометрический смысл:**  $g^*(y)$  — максимальный «зазор» между прямой  $\langle z, y \rangle$  и графиком  $g$ .

# Преобразование Лежандра-Фенхеля

## Определение

Сопряжённая функция  $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ :

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

**Геометрический смысл:**  $g^*(y)$  — максимальный «зазор» между прямой  $\langle z, y \rangle$  и графиком  $g$ .

**Свойства:**

- $g^*$  всегда выпукла и полунепрерывна снизу (как  $\sup$  линейных функций)

# Преобразование Лежандра-Фенхеля

## Определение

Сопряжённая функция  $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ :

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

**Геометрический смысл:**  $g^*(y)$  — максимальный «зазор» между прямой  $\langle z, y \rangle$  и графиком  $g$ .

**Свойства:**

- $g^*$  всегда выпукла и полунепрерывна снизу (как  $\sup$  линейных функций)
- **Двойственность Фенхеля:**  $(g^*)^* = g$  для выпуклой замкнутой  $g$

# Преобразование Лежандра-Фенхеля

## Определение

Сопряжённая функция  $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ :

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

**Геометрический смысл:**  $g^*(y)$  — максимальный «зазор» между прямой  $\langle z, y \rangle$  и графиком  $g$ .

**Свойства:**

- $g^*$  всегда выпукла и полунепрерывна снизу (как  $\sup$  линейных функций)
- **Двойственность Фенхеля:**  $(g^*)^* = g$  для выпуклой замкнутой  $g$
- Неравенство Юнга:  $\langle z, y \rangle \leq g(z) + g^*(y)$  для всех  $z, y$



# Примеры сопряжённых функций

| $g(z)$                      | $g^*(y)$                                                         |
|-----------------------------|------------------------------------------------------------------|
| $\lambda \ z\ _1$           | $\delta_{\ y\ _\infty \leq \lambda}$                             |
| $\frac{1}{2} \ z\ ^2$       | $\frac{1}{2} \ y\ ^2$                                            |
| $\ z\ _2$                   | $\delta_{\ y\ _2 \leq 1}$                                        |
| $\delta_{z \geq 0}$         | $\delta_{y \leq 0}$                                              |
| $\frac{1}{2n} \ Az - b\ ^2$ | $\frac{n}{2} \ y\ ^2 + b^\top y + \frac{1}{2n} \ Ay\ ^2 - \dots$ |

## Примеры сопряжённых функций

| $g(z)$                      | $g^*(y)$                                                         |
|-----------------------------|------------------------------------------------------------------|
| $\lambda \ z\ _1$           | $\delta_{\ y\ _\infty \leq \lambda}$                             |
| $\frac{1}{2} \ z\ ^2$       | $\frac{1}{2} \ y\ ^2$                                            |
| $\ z\ _2$                   | $\delta_{\ y\ _2 \leq 1}$                                        |
| $\delta_{z \geq 0}$         | $\delta_{y \leq 0}$                                              |
| $\frac{1}{2n} \ Az - b\ ^2$ | $\frac{n}{2} \ y\ ^2 + b^\top y + \frac{1}{2n} \ Ay\ ^2 - \dots$ |

**Упражнение:** убедитесь что  $(\lambda \|z\|_1)^* = \delta_{\|y\|_\infty \leq \lambda}$ .

*Подсказка:*  $\sup_z \{\langle z, y \rangle - \lambda \|z\|_1\} = 0$  если  $\|y\|_\infty \leq \lambda$ , иначе  $+\infty$ .

# Тождество Мора (Moreau Identity)

## Теорема (Moreau, 1962)

Для любой выпуклой  $g$  и  $\sigma > 0$ :

$$v = \operatorname{prox}_{\sigma g}(v) + \sigma \operatorname{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\operatorname{prox}_{\sigma g^*}(v) = v - \sigma \operatorname{prox}_{g/\sigma}(v/\sigma)$$

# Тождество Мора (Moreau Identity)

## Теорема (Moreau, 1962)

Для любой выпуклой  $g$  и  $\sigma > 0$ :

$$v = \text{prox}_{\sigma g}(v) + \sigma \text{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma)$$

**Значение:** если умеем вычислять  $\text{prox}_g$  — автоматически умеем  $\text{prox}_{g^*}$ !

# Тождество Мора (Moreau Identity)

## Теорема (Moreau, 1962)

Для любой выпуклой  $g$  и  $\sigma > 0$ :

$$v = \operatorname{prox}_{\sigma g}(v) + \sigma \operatorname{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\operatorname{prox}_{\sigma g^*}(v) = v - \sigma \operatorname{prox}_{g/\sigma}(v/\sigma)$$

**Значение:** если умеем вычислять  $\operatorname{prox}_g$  — автоматически умеем  $\operatorname{prox}_{g^*}$ !

**Пример:**  $g(z) = \lambda \|z\|_1$ , нужен  $\operatorname{prox}_{\sigma g^*}(v)$ .

$$\begin{aligned}\operatorname{prox}_{\sigma g^*}(v) &= v - \sigma \operatorname{prox}_{\lambda \|\cdot\|_1/\sigma}(v/\sigma) \\ &= v - \sigma \cdot \operatorname{clip}\left(\frac{v}{\sigma}, -\frac{\lambda}{\sigma}, \frac{\lambda}{\sigma}\right) \\ &= \operatorname{clip}(v, -\lambda, \lambda) \quad \leftarrow \text{проекция на } \ell^\infty\text{-шар!}\end{aligned}$$

## Седловая задача и PDHG

# Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

# Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача  $\min_x f(x) + g(Kx)$  переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$



# Двойственная формулировка задачи

**Ключевое тождество** (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

**Задача**  $\min_x f(x) + g(Kx)$  переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

**Решение**  $(x^*, y^*)$  — прямо-двойственная пара:

- $x^*$  — решение прямой задачи (оптимальные параметры)

# Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача  $\min_x f(x) + g(Kx)$  переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение  $(x^*, y^*)$  — прямо-двойственная пара:

- $x^*$  — решение прямой задачи (оптимальные параметры)
- $y^*$  — оптимальный двойственный вектор (множители)

# Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача  $\min_x f(x) + g(Kx)$  переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение  $(x^*, y^*)$  — прямо-двойственная пара:

- $x^*$  — решение прямой задачи (оптимальные параметры)
- $y^*$  — оптимальный двойственный вектор (множители)

# Двойственная формулировка задачи

**Ключевое тождество** (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

**Задача**  $\min_x f(x) + g(Kx)$  переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

**Решение**  $(x^*, y^*)$  — прямо-двойственная пара:

- $x^*$  — решение прямой задачи (оптимальные параметры)
- $y^*$  — оптимальный двойственный вектор (множители)

**Условия оптимальности** (КТТ для седловой точки):

$$0 \in \partial f(x^*) + K^\top y^*, \quad Kx^* \in \partial g^*(y^*)$$

# Алгоритм Chambolle-Pock (PDHG)

**Идея:** чередовать прималь-шаг и дуаль-шаг с экстраполяцией.

PDHG (Chambolle & Pock, 2011)

Параметры:  $\tau > 0$  (прималь-шаг),  $\sigma > 0$  (дуаль-шаг),  $\theta \in [0, 1]$ .

Инициализация:  $x_0 \in \mathbb{R}^d$ ,  $y_0 \in \mathbb{R}^m$ ,  $\bar{x}_0 = x_0$ .

На каждом шаге  $k = 0, 1, 2, \dots$ :

$$y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K \bar{x}_k)$$

$$x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^\top y_{k+1})$$

$$\bar{x}_{k+1} = x_{k+1} + \theta(x_{k+1} - x_k)$$

# Алгоритм Chambolle-Pock (PDHG)

**Идея:** чередовать прималь-шаг и дуаль-шаг с экстраполяцией.

PDHG (Chambolle & Pock, 2011)

Параметры:  $\tau > 0$  (прималь-шаг),  $\sigma > 0$  (дуаль-шаг),  $\theta \in [0, 1]$ .

Инициализация:  $x_0 \in \mathbb{R}^d$ ,  $y_0 \in \mathbb{R}^m$ ,  $\bar{x}_0 = x_0$ .

На каждом шаге  $k = 0, 1, 2, \dots$ :

$$y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K \bar{x}_k)$$

$$x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^\top y_{k+1})$$

$$\bar{x}_{k+1} = x_{k+1} + \theta(x_{k+1} - x_k)$$

**Экстраполяция**  $\bar{x}$  «смотрит вперед» — ускоряет сходимость по  $y$ .

## Условие сходимости и выбор шагов

**Теорема (Chambolle-Rock, 2011):** пусть  $f, g$  выпуклы,  $\tau\sigma\|K\|^2 \leq 1$ ,  $\theta = 1$ . Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где  $f^* = \min_x [f(x) + g(Kx)]$  и  $C$  зависит от начальной точки.

## Условие сходимости и выбор шагов

**Теорема (Chambolle-Rock, 2011):** пусть  $f, g$  выпуклы,  $\tau\sigma\|K\|^2 \leq 1$ ,  $\theta = 1$ . Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где  $f^* = \min_x [f(x) + g(Kx)]$  и  $C$  зависит от начальной точки.

**Выбор шагов:** практически берут  $\tau = \sigma = 1/\|K\|$  (равенство  $\tau\sigma\|K\|^2 = 1$ ).



## Условие сходимости и выбор шагов

**Теорема (Chambolle-Rock, 2011):** пусть  $f, g$  выпуклы,  $\tau\sigma\|K\|^2 \leq 1$ ,  $\theta = 1$ . Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где  $f^* = \min_x [f(x) + g(Kx)]$  и  $C$  зависит от начальной точки.

**Выбор шагов:** практически берут  $\tau = \sigma = 1/\|K\|$  (равенство  $\tau\sigma\|K\|^2 = 1$ ).

**Как вычислить  $\|K\|$ ?**

Степенной метод (power iteration):  $v \leftarrow K^\top K v / \|K^\top K v\|$ , несколько итераций.

Стоимость:  $O(md)$  за итерацию, 10–30 итераций обычно достаточно.

## Условие сходимости и выбор шагов

**Теорема (Chambolle-Rock, 2011):** пусть  $f, g$  выпуклы,  $\tau\sigma\|K\|^2 \leq 1$ ,  $\theta = 1$ . Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где  $f^* = \min_x [f(x) + g(Kx)]$  и  $C$  зависит от начальной точки.

**Выбор шагов:** практически берут  $\tau = \sigma = 1/\|K\|$  (равенство  $\tau\sigma\|K\|^2 = 1$ ).

**Как вычислить  $\|K\|$ ?**

Степенной метод (power iteration):  $v \leftarrow K^\top K v / \|K^\top K v\|$ , несколько итераций.

Стоимость:  $O(md)$  за итерацию, 10–30 итераций обычно достаточно.

**Ускоренный случай:** если  $f$  сильно выпукла с параметром  $\mu$  — адаптировать  $\tau_k, \sigma_k, \theta_k \rightarrow O(e^{-k\sqrt{\mu}})$ .

## Приложения

**Задача:** восстановить  $u$  из  $f = u_{\text{true}} + \xi$ :

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где  $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$  — дискретный градиент.

**Задача:** восстановить  $u$  из  $f = u_{\text{true}} + \xi$ :

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где  $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$  — дискретный градиент.

**Формат PDHG:**  $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$ ,  $f(u) = \frac{1}{2} \|u - f\|^2$ ,  $g(z) = \lambda \|z\|_{1,2}$ .

**Задача:** восстановить  $u$  из  $f = u_{\text{true}} + \xi$ :

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где  $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$  — дискретный градиент.

**Формат PDHG:**  $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$ ,  $f(u) = \frac{1}{2} \|u - f\|^2$ ,  $g(z) = \lambda \|z\|_{1,2}$ .

**Прокс-операторы:**

- $\text{prox}_{\tau f}(v) = \frac{v + \tau f}{1 + \tau}$  — среднее с данными

**Задача:** восстановить  $u$  из  $f = u_{\text{true}} + \xi$ :

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где  $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$  — дискретный градиент.

**Формат PDHG:**  $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$ ,  $f(u) = \frac{1}{2} \|u - f\|^2$ ,  $g(z) = \lambda \|z\|_{1,2}$ .

**Прокс-операторы:**

- $\text{prox}_{\tau f}(v) = \frac{v + \tau f}{1 + \tau}$  — среднее с данными
- $g^*(y) = \delta_{\|y_{ij}\|_2 \leq \lambda}$ ,  $\text{prox}_{\sigma g^*}(y) = \frac{y_{ij}}{\max(1, \|y_{ij}\|_2 / \lambda)}$  — проекция на шары

# PDHG для TV-денойзинга: итерации

Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$



# PDHG для TV-денойзинга: итерации

Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$

Стоимость одной итерации:  $O(n^2)$  — линейна по числу пикселей!

# PDHG для TV-денойзинга: итерации

## Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$

**Стоимость одной итерации:**  $O(n^2)$  — линейна по числу пикселей!

**Результат:** TV-денойзинг сохраняет **края** (sharp edges), в отличие от гауссова сглаживания. Именно поэтому TV используется в медицинской визуализации (МРТ, КТ).

# LASSO через прямо-двойственный метод

$$\text{LASSO: } \min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$$

# LASSO через прямо-двойственный метод

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Способ 1 (прямой):** ISTA/FISTA с мягким обрезанием — работает хорошо,  $K = I$ .

# LASSO через прямо-двойственный метод

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Способ 1 (прямой):** ISTA/FISTA с мягким обрезанием — работает хорошо,  $K = I$ .

**Способ 2 (PDHG):**  $f(w) = \frac{1}{2n} \|Xw - y\|^2$ ,  $K = I$ ,  $g(z) = \lambda \|z\|_1$ .

- Шаг по  $y$ :  $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$

# LASSO через прямо-двойственный метод

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Способ 1 (прямой):** ISTA/FISTA с мягким обрезанием — работает хорошо,  $K = I$ .

**Способ 2 (PDHG):**  $f(w) = \frac{1}{2n} \|Xw - y\|^2$ ,  $K = I$ ,  $g(z) = \lambda \|z\|_1$ .

- Шаг по  $y$ :  $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по  $w$ :  $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$  — ridge regression!

# LASSO через прямо-двойственный метод

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Способ 1 (прямой):** ISTA/FISTA с мягким обрезанием — работает хорошо,  $K = I$ .

**Способ 2 (PDHG):**  $f(w) = \frac{1}{2n} \|Xw - y\|^2$ ,  $K = I$ ,  $g(z) = \lambda \|z\|_1$ .

- Шаг по  $y$ :  $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по  $w$ :  $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$  — ridge regression!

# LASSO через прямо-двойственный метод

**LASSO:**  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

**Способ 1 (прямой):** ISTA/FISTA с мягким обрезанием — работает хорошо,  $K = I$ .

**Способ 2 (PDHG):**  $f(w) = \frac{1}{2n} \|Xw - y\|^2$ ,  $K = I$ ,  $g(z) = \lambda \|z\|_1$ .

- Шаг по  $y$ :  $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по  $w$ :  $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$  — ridge regression!

**Обобщённый LASSO** ( $K \neq I$ ):  $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$ .

ISTA не работает (нет  $\text{prox}_{\lambda \|D\cdot\|_1}$ ), PDHG — работает!



## Связь с другими методами

## PDHG и ADMM: одна задача, разные алгоритмы

**Факт:** PDHG и ADMM для задачи  $\min f(x) + g(Kx)$  эквивалентны при правильном выборе параметров.

## PDHG и ADMM: одна задача, разные алгоритмы

**Факт:** PDHG и ADMM для задачи  $\min f(x) + g(Kx)$  эквивалентны при правильном выборе параметров.

**ADMM** (с разделением  $Kx = z$ ):

$$\begin{aligned}x_{k+1} &= \operatorname{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \operatorname{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

## PDHG и ADMM: одна задача, разные алгоритмы

**Факт:** PDHG и ADMM для задачи  $\min f(x) + g(Kx)$  эквивалентны при правильном выборе параметров.

**ADMM** (с разделением  $Kx = z$ ):

$$\begin{aligned}x_{k+1} &= \text{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \text{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

При  $\tau = 1/\rho$ ,  $\sigma = \rho/\|K\|^2$ ,  $\theta = 1 \rightarrow \text{PDHG} = \text{ADMM}$ .

## PDHG и ADMM: одна задача, разные алгоритмы

**Факт:** PDHG и ADMM для задачи  $\min f(x) + g(Kx)$  эквивалентны при правильном выборе параметров.

**ADMM** (с разделением  $Kx = z$ ):

$$\begin{aligned}x_{k+1} &= \text{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \text{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

При  $\tau = 1/\rho$ ,  $\sigma = \rho/\|K\|^2$ ,  $\theta = 1 \rightarrow \text{PDHG} = \text{ADMM}$ .

**Разница на практике:**

|             | PDHG                             | ADMM                               |
|-------------|----------------------------------|------------------------------------|
| $x$ -шаг    | дешёвый $\text{prox}_{\tau f}$   | дорогой $(I + \tau K^\top K)^{-1}$ |
| Дуаль-шаг   | явный $\text{prox}_{\sigma g^*}$ | через $z$ и $u$                    |
| Параллелизм | хорош                            | хорош                              |

## Большая картина: когда что использовать

| Задача                                                                               | Лучший метод                                                 | Почему                                                         |
|--------------------------------------------------------------------------------------|--------------------------------------------------------------|----------------------------------------------------------------|
| $f(x) + g(x)$ , прокс $g$ прост<br>$f(x) + g(Kx)$ , $K$<br>прямоугольный             | <b>ISTA/FISTA</b><br><b>PDHG</b>                             | Один шаг, быстро<br>Нет прох <sub><math>g(K\cdot)</math></sub> |
| $f(x) + g(z)$ , $Ax + Bz = c$<br>$f$ сильно выпукла<br>Распределённая<br>оптимизация | <b>ADMM</b><br><b>ускоренный PDHG</b><br><b>ADMM / EXTRA</b> | Разделяет переменные<br>$O(e^{-k\sqrt{\mu}})$<br>Параллелизм   |

## Большая картина: когда что использовать

| Задача                                                                   | Лучший метод                          | Почему                                            |
|--------------------------------------------------------------------------|---------------------------------------|---------------------------------------------------|
| $f(x) + g(x)$ , прокс $g$ прост<br>$f(x) + g(Kx)$ , $K$<br>прямоугольный | <b>ISTA/FISTA</b><br><b>PDHG</b>      | Один шаг, быстро<br>Нет $\text{prox}_{g(K\cdot)}$ |
| $f(x) + g(z)$ , $Ax + Bz = c$<br>$f$ сильно выпукла                      | <b>ADMM</b><br><b>ускоренный PDHG</b> | Разделяет переменные<br>$O(e^{-k\sqrt{\mu}})$     |
| Распределённая<br>оптимизация                                            | <b>ADMM / EXTRA</b>                   | Параллелизм                                       |

## Итоговое сообщение

Прямо-двойственные методы = инструмент для задач  $f(x) + g(Kx)$ , где  $K$  нетривиально. Седловая формулировка + тождество Мора = мощная техника.

## Резюме



## Что мы узнали сегодня

1. Сопряжённая функция  $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$ :  $\rightarrow$  всегда выпукла, двойственность Фенхеля:  $(g^*)^* = g$

## Что мы узнали сегодня

1. **Сопряжённая функция**  $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$ :  $\rightarrow$  всегда выпукла, двойственность Фенхеля:  $(g^*)^* = g$
2. **Тождество Мора**:  $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$  знаем  $\text{prox}_g \rightarrow$  знаем  $\text{prox}_{g^*}$ !

## Что мы узнали сегодня

1. **Сопряжённая функция**  $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$ :  $\rightarrow$  всегда выпукла, двойственность Фенхеля:  $(g^*)^* = g$
2. **Тождество Мора**:  $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$  знаем  $\text{prox}_g \rightarrow$  знаем  $\text{prox}_{g^*}$ !
3. **Седловая задача**:  $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$

## Что мы узнали сегодня

1. **Сопряжённая функция**  $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$ :  $\rightarrow$  всегда выпукла, двойственность Фенхеля:  $(g^*)^* = g$
2. **Тождество Мора**:  $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$  знаем  $\text{prox}_g \rightarrow$  знаем  $\text{prox}_{g^*}$ !
3. **Седловая задача**:  $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$
4. **PDHG**: чередуем дуаль-шаг ( $\text{prox}_{\sigma g^*}$ ) и прималь-шаг ( $\text{prox}_{\tau f}$ ) + экстраполяция. Условие:  $\tau\sigma\|K\|^2 \leq 1$ . Скорость:  $O(1/k)$ .

## Что мы узнали сегодня

1. **Сопряжённая функция**  $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$ :  $\rightarrow$  всегда выпукла, двойственность Фенхеля:  $(g^*)^* = g$
2. **Тождество Мора**:  $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$  знаем  $\text{prox}_g \rightarrow$  знаем  $\text{prox}_{g^*}$ !
3. **Седловая задача**:  $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$
4. **PDHG**: чередуем дуаль-шаг ( $\text{prox}_{\sigma g^*}$ ) и прималь-шаг ( $\text{prox}_{\tau f}$ ) + экстраполяция. Условие:  $\tau\sigma\|K\|^2 \leq 1$ . Скорость:  $O(1/k)$ .
5. **Приложения**: TV-денойзинг, обобщённый LASSO, томография.

## Задачи для практики

1. Вычислите  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.

## Задачи для практики

1. Вычислите  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.

## Задачи для практики

1. **Вычислите**  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.
2. **Выведите** условие  $\tau\sigma\|K\|^2 \leq 1$  из требования монотонности оператора шага PDHG.



## Задачи для практики

1. **Вычислите**  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.
2. **Выведите** условие  $\tau\sigma\|K\|^2 \leq 1$  из требования монотонности оператора шага PDHG.

## Задачи для практики

1. **Вычислите**  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.
2. **Выведите** условие  $\tau \sigma \|K\|^2 \leq 1$  из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое  $32 \times 32$  изображение с шумом  $\sigma = 0.1$ ,  $\lambda = 0.05$ ). Сравните с гауссовым фильтром.

## Задачи для практики

1. **Вычислите**  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.
2. **Выведите** условие  $\tau \sigma \|K\|^2 \leq 1$  из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое  $32 \times 32$  изображение с шумом  $\sigma = 0.1$ ,  $\lambda = 0.05$ ). Сравните с гауссовым фильтром.

## Задачи для практики

1. **Вычислите**  $g^*(y)$  для  $g(z) = \lambda \|z\|_2$  (групповая норма). Найдите  $\text{prox}_{\sigma g^*}(v)$  через тождество Мора.
2. **Выведите** условие  $\tau \sigma \|K\|^2 \leq 1$  из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое  $32 \times 32$  изображение с шумом  $\sigma = 0.1$ ,  $\lambda = 0.05$ ). Сравните с гауссовым фильтром.
4. **Покажите:** для задачи LASSO при  $K = I$ ,  $\theta = 0$  — PDHG совпадает с ISTA.

*hse26.fmin.xyz* | Оптимизация в ML | ФКН ВШЭ 2026