




Прямо-двойственные методы. PDHG

Даня Меркулов

ФКН ВШЭ

Мотивация: когда прокс-шаг не разделяется

Ограничение ISTA и ADMM

ISTA/FISTA: решает $\min_x f(x) + g(x)$ — прокс g вычислим напрямую.

Ограничение ISTA и ADMM

ISTA/FISTA: решает $\min_x f(x) + g(x)$ — прокс g вычислим напрямую.

ADMM: решает $\min f(x) + g(z)$ при $Ax + Bz = c$ — разделяет переменные.

Ограничение ISTA и ADMM

ISTA/FISTA: решает $\min_x f(x) + g(x)$ — прокс g вычислим напрямую.

ADMM: решает $\min f(x) + g(z)$ при $Ax + Bz = c$ — разделяет переменные.

Новая проблема: что делать с $\min_x f(x) + g(Kx)$?

$$\min_{x \in \mathbb{R}^d} f(x) + g(Kx), \quad K \in \mathbb{R}^{m \times d}$$

Ограничение ISTA и ADMM

ISTA/FISTA: решает $\min_x f(x) + g(x)$ — прокс g вычислим напрямую.

ADMM: решает $\min f(x) + g(z)$ при $Ax + Bz = c$ — разделяет переменные.

Новая проблема: что делать с $\min_x f(x) + g(Kx)$?

$$\min_{x \in \mathbb{R}^d} f(x) + g(Kx), \quad K \in \mathbb{R}^{m \times d}$$

Проблема: $\text{prox}_{\tau g(K \cdot)}(v)$ не вычисляется в замкнутой форме — нет формулы для $\text{prox}_{g \circ K}$!

Примеры составных задач

TV-денойзинг: восстановить изображение из зашумлённого f :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь $K = \nabla$ (дискретный градиент), $g(z) = \lambda \|z\|_{1,2}$.

Примеры составных задач

TV-денойзинг: восстановить изображение из зашумлённого f :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь $K = \nabla$ (дискретный градиент), $g(z) = \lambda \|z\|_{1,2}$.

Томография: $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$, где A — оператор Радона.

Примеры составных задач

TV-денойзинг: восстановить изображение из зашумлённого f :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь $K = \nabla$ (дискретный градиент), $g(z) = \lambda \|z\|_{1,2}$.

Томография: $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$, где A — оператор Радона.

Обобщённый LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$, где D — матрица разностей.

Примеры составных задач

TV-денойзинг: восстановить изображение из зашумлённого f :

$$\min_u \frac{1}{2} \|u - f\|^2 + \lambda \|\nabla u\|_{1,2}$$

Здесь $K = \nabla$ (дискретный градиент), $g(z) = \lambda \|z\|_{1,2}$.

Томография: $\min_u \|Au - b\|^2 + \lambda \text{TV}(u)$, где A — оператор Радона.

Обобщённый LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$, где D — матрица разностей.

Общий вопрос

Как решить $\min_x f(x) + g(Kx)$ без вычисления $\text{prox}_{g(K\cdot)}$?

Сопряжённые функции

Преобразование Лежандра-Фенхеля

Определение

Сопряжённая функция $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$:

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

Преобразование Лежандра-Фенхеля

Определение

Сопряжённая функция $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$:

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

Геометрический смысл: $g^*(y)$ — максимальный «зазор» между прямой $\langle z, y \rangle$ и графиком g .

Преобразование Лежандра-Фенхеля

Определение

Сопряжённая функция $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$:

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

Геометрический смысл: $g^*(y)$ — максимальный «зазор» между прямой $\langle z, y \rangle$ и графиком g .

Свойства:

- g^* всегда выпукла и полунепрерывна снизу (как $\sup$ линейных функций)

Преобразование Лежандра-Фенхеля

Определение

Сопряжённая функция $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$:

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{ \langle z, y \rangle - g(z) \}$$

Геометрический смысл: $g^*(y)$ — максимальный «зазор» между прямой $\langle z, y \rangle$ и графиком g .

Свойства:

- g^* всегда выпукла и полунепрерывна снизу (как $\sup$ линейных функций)
- **Двойственность Фенхеля:** $(g^*)^* = g$ для выпуклой замкнутой g

Преобразование Лежандра-Фенхеля

Определение

Сопряжённая функция $g^* : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$:

$$g^*(y) = \sup_{z \in \mathbb{R}^m} \{\langle z, y \rangle - g(z)\}$$

Геометрический смысл: $g^*(y)$ — максимальный «зазор» между прямой $\langle z, y \rangle$ и графиком g .

Свойства:

- g^* всегда выпукла и полунепрерывна снизу (как $\sup$ линейных функций)
- **Двойственность Фенхеля:** $(g^*)^* = g$ для выпуклой замкнутой g
- Неравенство Юнга: $\langle z, y \rangle \leq g(z) + g^*(y)$ для всех z, y

Примеры сопряжённых функций

$g(z)$	$g^*(y)$
$\lambda \ z\ _1$	$\delta_{\ y\ _\infty \leq \lambda}$
$\frac{1}{2} \ z\ ^2$	$\frac{1}{2} \ y\ ^2$
$\ z\ _2$	$\delta_{\ y\ _2 \leq 1}$
$\delta_{z \geq 0}$	$\delta_{y \leq 0}$
$\frac{1}{2n} \ Az - b\ ^2$	$\frac{n}{2} \ y\ ^2 + b^\top y + \frac{1}{2n} \ Ay\ ^2 - \dots$

Примеры сопряжённых функций

$g(z)$	$g^*(y)$
$\lambda \ z\ _1$	$\delta_{\ y\ _\infty \leq \lambda}$
$\frac{1}{2} \ z\ ^2$	$\frac{1}{2} \ y\ ^2$
$\ z\ _2$	$\delta_{\ y\ _2 \leq 1}$
$\delta_{z \geq 0}$	$\delta_{y \leq 0}$
$\frac{1}{2n} \ Az - b\ ^2$	$\frac{n}{2} \ y\ ^2 + b^\top y + \frac{1}{2n} \ Ay\ ^2 - \dots$

Упражнение: убедитесь что $(\lambda \|z\|_1)^* = \delta_{\|y\|_\infty \leq \lambda}$.

Подсказка: $\sup_z \{\langle z, y \rangle - \lambda \|z\|_1\} = 0$ если $\|y\|_\infty \leq \lambda$, иначе $+\infty$.

Тождество Мора (Moreau Identity)

Теорема (Moreau, 1962)

Для любой выпуклой g и $\sigma > 0$:

$$v = \text{prox}_{\sigma g}(v) + \sigma \text{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma)$$

Тождество Мора (Moreau Identity)

Теорема (Moreau, 1962)

Для любой выпуклой g и $\sigma > 0$:

$$v = \text{prox}_{\sigma g}(v) + \sigma \text{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma)$$

Значение: если умеем вычислять prox_g — автоматически умеем prox_{g^*} !

Тождество Мора (Moreau Identity)

Теорема (Moreau, 1962)

Для любой выпуклой g и $\sigma > 0$:

$$v = \operatorname{prox}_{\sigma g}(v) + \sigma \operatorname{prox}_{g^*/\sigma}(v/\sigma)$$

Или эквивалентно:

$$\operatorname{prox}_{\sigma g^*}(v) = v - \sigma \operatorname{prox}_{g/\sigma}(v/\sigma)$$

Значение: если умеем вычислять prox_g — автоматически умеем $\operatorname{prox}_{g^*}$!

Пример: $g(z) = \lambda \|z\|_1$, нужен $\operatorname{prox}_{\sigma g^*}(v)$.

$$\begin{aligned}\operatorname{prox}_{\sigma g^*}(v) &= v - \sigma \operatorname{prox}_{\lambda \|\cdot\|_1/\sigma}(v/\sigma) \\ &= v - \sigma \cdot \operatorname{clip}\left(\frac{v}{\sigma}, -\frac{\lambda}{\sigma}, \frac{\lambda}{\sigma}\right) \\ &= \operatorname{clip}(v, -\lambda, \lambda) \quad \leftarrow \text{проекция на } \ell^\infty\text{-шар!}\end{aligned}$$

Седловая задача и PDHG

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача $\min_x f(x) + g(Kx)$ переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача $\min_x f(x) + g(Kx)$ переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение (x^*, y^*) — прямо-двойственная пара:

- x^* — решение прямой задачи (оптимальные параметры)

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача $\min_x f(x) + g(Kx)$ переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение (x^*, y^*) — прямо-двойственная пара:

- x^* — решение прямой задачи (оптимальные параметры)
- y^* — оптимальный двойственный вектор (множители)

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача $\min_x f(x) + g(Kx)$ переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение (x^*, y^*) — прямо-двойственная пара:

- x^* — решение прямой задачи (оптимальные параметры)
- y^* — оптимальный двойственный вектор (множители)

Двойственная формулировка задачи

Ключевое тождество (из двойственности Фенхеля):

$$g(Kx) = \max_{y \in \mathbb{R}^m} \{ \langle Kx, y \rangle - g^*(y) \}$$

Задача $\min_x f(x) + g(Kx)$ переписывается как:

Седловая (min-max) задача

$$\min_{x \in \mathbb{R}^d} \max_{y \in \mathbb{R}^m} \{ f(x) + \langle Kx, y \rangle - g^*(y) \}$$

Решение (x^*, y^*) — прямо-двойственная пара:

- x^* — решение прямой задачи (оптимальные параметры)
- y^* — оптимальный двойственный вектор (множители)

Условия оптимальности (КТТ для седловой точки):

$$0 \in \partial f(x^*) + K^\top y^*, \quad Kx^* \in \partial g^*(y^*)$$

Алгоритм Chambolle-Pock (PDHG)

Идея: чередовать прималь-шаг и дуаль-шаг с экстраполяцией.

PDHG (Chambolle & Pock, 2011)

Параметры: $\tau > 0$ (прималь-шаг), $\sigma > 0$ (дуаль-шаг), $\theta \in [0, 1]$.

Инициализация: $x_0 \in \mathbb{R}^d$, $y_0 \in \mathbb{R}^m$, $\bar{x}_0 = x_0$.

На каждом шаге $k = 0, 1, 2, \dots$:

$$y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K \bar{x}_k)$$

$$x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^\top y_{k+1})$$

$$\bar{x}_{k+1} = x_{k+1} + \theta(x_{k+1} - x_k)$$

Алгоритм Chambolle-Pock (PDHG)

Идея: чередовать прималь-шаг и дуаль-шаг с экстраполяцией.

PDHG (Chambolle & Pock, 2011)

Параметры: $\tau > 0$ (прималь-шаг), $\sigma > 0$ (дуаль-шаг), $\theta \in [0, 1]$.

Инициализация: $x_0 \in \mathbb{R}^d$, $y_0 \in \mathbb{R}^m$, $\bar{x}_0 = x_0$.

На каждом шаге $k = 0, 1, 2, \dots$:

$$y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K \bar{x}_k)$$

$$x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^\top y_{k+1})$$

$$\bar{x}_{k+1} = x_{k+1} + \theta(x_{k+1} - x_k)$$

Экстраполяция $\bar{x}$ «смотрит вперёд» — ускоряет сходимость по y .

Условие сходимости и выбор шагов

Теорема (Chambolle-Rock, 2011): пусть f, g выпуклы, $\tau\sigma\|K\|^2 \leq 1$, $\theta = 1$. Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где $f^* = \min_x [f(x) + g(Kx)]$ и C зависит от начальной точки.

Условие сходимости и выбор шагов

Теорема (Chambolle-Rock, 2011): пусть f, g выпуклы, $\tau\sigma\|K\|^2 \leq 1$, $\theta = 1$. Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где $f^* = \min_x [f(x) + g(Kx)]$ и C зависит от начальной точки.

Выбор шагов: практически берут $\tau = \sigma = 1/\|K\|$ (равенство $\tau\sigma\|K\|^2 = 1$).

Условие сходимости и выбор шагов

Теорема (Chambolle-Rock, 2011): пусть f, g выпуклы, $\tau\sigma\|K\|^2 \leq 1$, $\theta = 1$. Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где $f^* = \min_x [f(x) + g(Kx)]$ и C зависит от начальной точки.

Выбор шагов: практически берут $\tau = \sigma = 1/\|K\|$ (равенство $\tau\sigma\|K\|^2 = 1$).

Как вычислить $\|K\|$?

Степенной метод (power iteration): $v \leftarrow K^\top K v / \|K^\top K v\|$, несколько итераций.

Стоимость: $O(md)$ за итерацию, 10–30 итераций обычно достаточно.

Условие сходимости и выбор шагов

Теорема (Chambolle-Rock, 2011): пусть f, g выпуклы, $\tau\sigma\|K\|^2 \leq 1$, $\theta = 1$. Тогда:

$$f(x_k) + g(Kx_k) - f^* \leq \frac{C}{k}$$

где $f^* = \min_x [f(x) + g(Kx)]$ и C зависит от начальной точки.

Выбор шагов: практически берут $\tau = \sigma = 1/\|K\|$ (равенство $\tau\sigma\|K\|^2 = 1$).

Как вычислить $\|K\|$?

Степенной метод (power iteration): $v \leftarrow K^\top K v / \|K^\top K v\|$, несколько итераций.

Стоимость: $O(md)$ за итерацию, 10–30 итераций обычно достаточно.

Ускоренный случай: если f сильно выпукла с параметром μ — адаптировать $\tau_k, \sigma_k, \theta_k \rightarrow O(e^{-k\sqrt{\mu}})$.

Приложения

Задача: восстановить u из $f = u_{\text{true}} + \xi$:

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$ — дискретный градиент.

Задача: восстановить u из $f = u_{\text{true}} + \xi$:

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$ — дискретный градиент.

Формат PDHG: $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$, $f(u) = \frac{1}{2} \|u - f\|^2$, $g(z) = \lambda \|z\|_{1,2}$.

Задача: восстановить u из $f = u_{\text{true}} + \xi$:

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$ — дискретный градиент.

Формат PDHG: $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$, $f(u) = \frac{1}{2} \|u - f\|^2$, $g(z) = \lambda \|z\|_{1,2}$.

Прокс-операторы:

- $\text{prox}_{\tau f}(v) = \frac{v + \tau f}{1 + \tau}$ — среднее с данными

Задача: восстановить u из $f = u_{\text{true}} + \xi$:

$$\min_{u \in \mathbb{R}^{n^2}} \frac{1}{2} \|u - f\|^2 + \lambda \sum_{i,j} \|\nabla u_{ij}\|_2$$

где $\nabla u_{ij} = (u_{i+1,j} - u_{ij}, u_{i,j+1} - u_{ij})$ — дискретный градиент.

Формат PDHG: $K = \nabla \in \mathbb{R}^{2n^2 \times n^2}$, $f(u) = \frac{1}{2} \|u - f\|^2$, $g(z) = \lambda \|z\|_{1,2}$.

Прокс-операторы:

- $\text{prox}_{\tau f}(v) = \frac{v + \tau f}{1 + \tau}$ — среднее с данными
- $g^*(y) = \delta_{\|y_{ij}\|_2 \leq \lambda}$, $\text{prox}_{\sigma g^*}(y) = \frac{y_{ij}}{\max(1, \|y_{ij}\|_2 / \lambda)}$ — проекция на шары

PDHG для TV-денойзинга: итерации

Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$

PDHG для TV-денойзинга: итерации

Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$

Стоимость одной итерации: $O(n^2)$ — линейна по числу пикселей!

PDHG для TV-денойзинга: итерации

Итерации (явная форма)

$$y_{k+1}^{ij} = \frac{y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}}{\max(1, \|y_k^{ij} + \sigma \nabla \bar{u}_k^{ij}\|_2 / \lambda)}$$

$$u_{k+1} = \frac{u_k - \tau \nabla^\top y_{k+1} + \tau f}{1 + \tau}$$

$$\bar{u}_{k+1} = u_{k+1} + (u_{k+1} - u_k)$$

Стоимость одной итерации: $O(n^2)$ — линейна по числу пикселей!

Результат: TV-денойзинг сохраняет **края** (sharp edges), в отличие от гауссова сглаживания. Именно поэтому TV используется в медицинской визуализации (МРТ, КТ).

LASSO через прямо-двойственный метод

$$\text{LASSO: } \min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$$

LASSO через прямо-двойственный метод

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Способ 1 (прямой): ISTA/FISTA с мягким обрезанием — работает хорошо, $K = I$.

LASSO через прямо-двойственный метод

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Способ 1 (прямой): ISTA/FISTA с мягким обрезанием — работает хорошо, $K = I$.

Способ 2 (PDHG): $f(w) = \frac{1}{2n} \|Xw - y\|^2$, $K = I$, $g(z) = \lambda \|z\|_1$.

- Шаг по y : $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$

LASSO через прямо-двойственный метод

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Способ 1 (прямой): ISTA/FISTA с мягким обрезанием — работает хорошо, $K = I$.

Способ 2 (PDHG): $f(w) = \frac{1}{2n} \|Xw - y\|^2$, $K = I$, $g(z) = \lambda \|z\|_1$.

- Шаг по y : $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по w : $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$ — ridge regression!

LASSO через прямо-двойственный метод

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Способ 1 (прямой): ISTA/FISTA с мягким обрезанием — работает хорошо, $K = I$.

Способ 2 (PDHG): $f(w) = \frac{1}{2n} \|Xw - y\|^2$, $K = I$, $g(z) = \lambda \|z\|_1$.

- Шаг по y : $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по w : $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$ — ridge regression!

LASSO через прямо-двойственный метод

LASSO: $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1$

Способ 1 (прямой): ISTA/FISTA с мягким обрезанием — работает хорошо, $K = I$.

Способ 2 (PDHG): $f(w) = \frac{1}{2n} \|Xw - y\|^2$, $K = I$, $g(z) = \lambda \|z\|_1$.

- Шаг по y : $y_{k+1} = \text{clip}(y_k + \sigma \bar{w}_k, -\lambda, \lambda)$
- Шаг по w : $w_{k+1} = \text{prox}_{\tau f}(w_k - \tau y_{k+1})$ — ridge regression!

Обобщённый LASSO ($K \neq I$): $\min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|Dw\|_1$.

ISTA не работает (нет $\text{prox}_{\lambda \|D\cdot\|_1}$), PDHG — работает!

Связь с другими методами

PDHG и ADMM: одна задача, разные алгоритмы

Факт: PDHG и ADMM для задачи $\min f(x) + g(Kx)$ эквивалентны при правильном выборе параметров.

PDHG и ADMM: одна задача, разные алгоритмы

Факт: PDHG и ADMM для задачи $\min f(x) + g(Kx)$ эквивалентны при правильном выборе параметров.

ADMM (с разделением $Kx = z$):

$$\begin{aligned}x_{k+1} &= \operatorname{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \operatorname{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

PDHG и ADMM: одна задача, разные алгоритмы

Факт: PDHG и ADMM для задачи $\min f(x) + g(Kx)$ эквивалентны при правильном выборе параметров.

ADMM (с разделением $Kx = z$):

$$\begin{aligned}x_{k+1} &= \text{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \text{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

При $\tau = 1/\rho$, $\sigma = \rho/\|K\|^2$, $\theta = 1 \rightarrow \text{PDHG} = \text{ADMM}$.

PDHG и ADMM: одна задача, разные алгоритмы

Факт: PDHG и ADMM для задачи $\min f(x) + g(Kx)$ эквивалентны при правильном выборе параметров.

ADMM (с разделением $Kx = z$):

$$\begin{aligned}x_{k+1} &= \text{prox}_{f/\rho}(K^\top(z_k - u_k)) \\z_{k+1} &= \text{prox}_{g/\rho}(Kx_{k+1} + u_k), \quad u_{k+1} = u_k + Kx_{k+1} - z_{k+1}\end{aligned}$$

При $\tau = 1/\rho$, $\sigma = \rho/\|K\|^2$, $\theta = 1 \rightarrow \text{PDHG} = \text{ADMM}$.

Разница на практике:

	PDHG	ADMM
x -шаг	дешёвый $\text{prox}_{\tau f}$	дорогой $(I + \tau K^\top K)^{-1}$
Дуаль-шаг	явный $\text{prox}_{\sigma g^*}$	через z и u
Параллелизм	хорош	хорош

Большая картина: когда что использовать

Задача	Лучший метод	Почему
$f(x) + g(x)$, прокс g прост $f(x) + g(Kx)$, K прямоугольный	ISTA/FISTA PDHG	Один шаг, быстро Нет прох $_{g(K\cdot)}$
$f(x) + g(z)$, $Ax + Bz = c$ f сильно выпукла Распределённая оптимизация	ADMM ускоренный PDHG ADMM / EXTRA	Разделяет переменные $O(e^{-k\sqrt{\mu}})$ Параллелизм

Большая картина: когда что использовать

Задача	Лучший метод	Почему
$f(x) + g(x)$, прокс g прост $f(x) + g(Kx)$, K прямоугольный	ISTA/FISTA PDHG	Один шаг, быстро Нет $\text{prox}_{g(K\cdot)}$
$f(x) + g(z)$, $Ax + Bz = c$ f сильно выпукла Распределённая оптимизация	ADMM ускоренный PDHG ADMM / EXTRA	Разделяет переменные $O(e^{-k\sqrt{\mu}})$ Параллелизм

Итоговое сообщение

Прямо-двойственные методы = инструмент для задач $f(x) + g(Kx)$, где K нетривиально. Седловая формулировка + тождество Мора = мощная техника.

Резюме

Что мы узнали сегодня

1. Сопряжённая функция $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$: $\rightarrow$ всегда выпукла, двойственность Фенхеля: $(g^*)^* = g$

Что мы узнали сегодня

1. **Сопряжённая функция** $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$: $\rightarrow$ всегда выпукла, двойственность Фенхеля: $(g^*)^* = g$
2. **Тождество Мора**: $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$ знаем $\text{prox}_g \rightarrow$ знаем prox_{g^*} !

Что мы узнали сегодня

1. **Сопряжённая функция** $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$: $\rightarrow$ всегда выпукла, двойственность Фенхеля: $(g^*)^* = g$
2. **Тождество Мора**: $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$ знаем $\text{prox}_g \rightarrow$ знаем prox_{g^*} !
3. **Седловая задача**: $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$

Что мы узнали сегодня

1. **Сопряжённая функция** $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$: $\rightarrow$ всегда выпукла, двойственность Фенхеля: $(g^*)^* = g$
2. **Тождество Мора**: $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$ знаем $\text{prox}_g \rightarrow$ знаем prox_{g^*} !
3. **Седловая задача**: $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$
4. **PDHG**: чередуем дуаль-шаг ($\text{prox}_{\sigma g^*}$) и прималь-шаг ($\text{prox}_{\tau f}$) + экстраполяция. Условие: $\tau\sigma\|K\|^2 \leq 1$. Скорость: $O(1/k)$.

Что мы узнали сегодня

1. **Сопряжённая функция** $g^*(y) = \sup_z \{\langle z, y \rangle - g(z)\}$: $\rightarrow$ всегда выпукла, двойственность Фенхеля: $(g^*)^* = g$
2. **Тождество Мора**: $\text{prox}_{\sigma g^*}(v) = v - \sigma \text{prox}_{g/\sigma}(v/\sigma) \rightarrow$ знаем $\text{prox}_g \rightarrow$ знаем prox_{g^*} !
3. **Седловая задача**: $\min_x f(x) + g(Kx) \equiv \min_x \max_y \{f(x) + \langle Kx, y \rangle - g^*(y)\}$
4. **PDHG**: чередуем дуаль-шаг ($\text{prox}_{\sigma g^*}$) и прималь-шаг ($\text{prox}_{\tau f}$) + экстраполяция. Условие: $\tau\sigma\|K\|^2 \leq 1$. Скорость: $O(1/k)$.
5. **Приложения**: TV-денойзинг, обобщённый LASSO, томография.

Задачи для практики

1. Вычислите $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.

Задачи для практики

1. Вычислите $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.

Задачи для практики

1. **Вычислите** $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.
2. **Выведите** условие $\tau\sigma\|K\|^2 \leq 1$ из требования монотонности оператора шага PDHG.

Задачи для практики

1. **Вычислите** $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.
2. **Выведите** условие $\tau\sigma\|K\|^2 \leq 1$ из требования монотонности оператора шага PDHG.

Задачи для практики

1. **Вычислите** $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.
2. **Выведите** условие $\tau \sigma \|K\|^2 \leq 1$ из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое 32×32 изображение с шумом $\sigma = 0.1$, $\lambda = 0.05$). Сравните с гауссовым фильтром.

Задачи для практики

1. **Вычислите** $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.
2. **Выведите** условие $\tau \sigma \|K\|^2 \leq 1$ из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое 32×32 изображение с шумом $\sigma = 0.1$, $\lambda = 0.05$). Сравните с гауссовым фильтром.

Задачи для практики

1. **Вычислите** $g^*(y)$ для $g(z) = \lambda \|z\|_2$ (групповая норма). Найдите $\text{prox}_{\sigma g^*}(v)$ через тождество Мора.
2. **Выведите** условие $\tau \sigma \|K\|^2 \leq 1$ из требования монотонности оператора шага PDHG.
3. **Реализуйте** PDHG для TV-денойзинга на Python (синтетическое 32×32 изображение с шумом $\sigma = 0.1$, $\lambda = 0.05$). Сравните с гауссовым фильтром.
4. **Покажите:** для задачи LASSO при $K = I$, $\theta = 0$ — PDHG совпадает с ISTA.

hse26.fmin.xyz | Оптимизация в ML | ФКН ВШЭ 2026