




## Метод Франк-Вульфа (Условный градиент)

Даня Меркулов

ФКН ВШЭ

Мотивация: когда проекция дорога

# Ограниченная оптимизация и проекция

**Задача:**  $\min_{x \in C} f(x)$ , где  $C$  — замкнутое выпуклое множество.

# Ограниченная оптимизация и проекция

**Задача:**  $\min_{x \in C} f(x)$ , где  $C$  — замкнутое выпуклое множество.

**Проксимальный градиентный спуск (PGD):**

$$x_{k+1} = \Pi_C(x_k - t \nabla f(x_k))$$

# Ограниченная оптимизация и проекция

**Задача:**  $\min_{x \in C} f(x)$ , где  $C$  — замкнутое выпуклое множество.

**Проксимальный градиентный спуск (PGD):**

$$x_{k+1} = \Pi_C(x_k - t \nabla f(x_k))$$

**Проблема:** проекция  $\Pi_C$  может быть дорогой или аналитически невозможной!

## Примеры дорогих проекций

| Множество $C$                       | Проекция $\Pi_C(v)$          | Стоимость                |
|-------------------------------------|------------------------------|--------------------------|
| $\ell_1$ -шар $\ x\ _1 \leq R$      | Нетривиальная (waterfilling) | $O(d \log d)$            |
| Ядерно-нормный шар $\ X\ _* \leq R$ | SVD + обрезание              | $O(\min(m, n) \cdot mn)$ |
| Полигон (LP feasible set)           | Решение LP                   | Труднее                  |

## Примеры дорогих проекций

| Множество $C$                       | Проекция $\Pi_C(v)$          | Стоимость                |
|-------------------------------------|------------------------------|--------------------------|
| $\ell_1$ -шар $\ x\ _1 \leq R$      | Нетривиальная (waterfilling) | $O(d \log d)$            |
| Ядерно-нормный шар $\ X\ _* \leq R$ | SVD + обрезание              | $O(\min(m, n) \cdot mn)$ |
| Полигон (LP feasible set)           | Решение LP                   | Труднее                  |

### Идея Франк-Вульфа (1956)

Вместо проекции решаем **линейную программу** (LP oracle) над  $C$ !

## Алгоритм Франк-Вульфа



# Идея: линеаризация целевой функции

**Мотивация:** если  $f$  гладкая, то вблизи  $x_k$ :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

# Идея: линеаризация целевой функции

**Мотивация:** если  $f$  гладкая, то вблизи  $x_k$ :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации  $f(x)$  по  $C$  (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

# Идея: линеаризация целевой функции

**Мотивация:** если  $f$  гладкая, то вблизи  $x_k$ :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации  $f(x)$  по  $C$  (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над  $C$ . Часто очень дешёва!

# Идея: линеаризация целевой функции

**Мотивация:** если  $f$  гладкая, то вблизи  $x_k$ :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации  $f(x)$  по  $C$  (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над  $C$ . Часто очень дешёва!

**Шаг FW:** двигаемся от  $x_k$  к  $s_k$  с шагом  $\gamma_k \in [0, 1]$ :

$$x_{k+1} = (1 - \gamma_k)x_k + \gamma_k s_k$$

# Идея: линеаризация целевой функции

**Мотивация:** если  $f$  гладкая, то вблизи  $x_k$ :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации  $f(x)$  по  $C$  (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над  $C$ . Часто очень дешёва!

**Шаг FW:** двигаемся от  $x_k$  к  $s_k$  с шагом  $\gamma_k \in [0, 1]$ :

$$x_{k+1} = (1 - \gamma_k)x_k + \gamma_k s_k$$

**Ключевое свойство**

$x_{k+1} \in C$  **автоматически** (выпуклость  $C$ ). Никакой проекции!

## Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

# Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. Точный линейный поиск:  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$

# Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. Точный линейный поиск:  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. Открытый шаг:  $\gamma_k = \frac{2}{k + 2}$  — простой и теоретически обоснованный



# Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. **Точный линейный поиск:**  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:**  $\gamma_k = \frac{2}{k + 2}$  — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению  $s_k - x_k$

# Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. **Точный линейный поиск:**  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:**  $\gamma_k = \frac{2}{k + 2}$  — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению  $s_k - x_k$

## Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. **Точный линейный поиск:**  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:**  $\gamma_k = \frac{2}{k + 2}$  — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению  $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

## Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. **Точный линейный поиск**:  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг**:  $\gamma_k = \frac{2}{k+2}$  — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению  $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

**Лемма**:  $g_k \geq f(x_k) - f^*$

**Доказательство**: из выпуклости  $f(x^*) \geq f(x_k) + \langle \nabla f(x_k), x^* - x_k \rangle$ , значит

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle \leq g_k$$

## Выбор шага и FW-зазор

Выбор шага  $\gamma_k \in [0, 1]$ :

1. **Точный линейный поиск:**  $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:**  $\gamma_k = \frac{2}{k + 2}$  — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению  $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

**Лемма:**  $g_k \geq f(x_k) - f^*$

**Доказательство:** из выпуклости  $f(x^*) \geq f(x_k) + \langle \nabla f(x_k), x^* - x_k \rangle$ , значит

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle \leq g_k$$

**Останов:** при  $g_k \leq \varepsilon$  гарантировано  $f(x_k) - f^* \leq \varepsilon$ .

## Анализ сходимости

**Теорема:** пусть  $f$   $L$ -гладкая,  $C$  ограниченное ( $\text{diam}(C) = D$ ). Тогда при  $\gamma_k = 2/(k+2)$ :

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

## Анализ сходимости

**Теорема:** пусть  $f$   $L$ -гладкая,  $C$  ограниченное ( $\text{diam}(C) = D$ ). Тогда при  $\gamma_k = 2/(k+2)$ :

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

*Доказательство (ключевые шаги):*

**Шаг 1** (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

## Анализ сходимости

**Теорема:** пусть  $f$   $L$ -гладкая,  $C$  ограниченное ( $\text{diam}(C) = D$ ). Тогда при  $\gamma_k = 2/(k+2)$ :

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

*Доказательство (ключевые шаги):*

**Шаг 1** (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

**Шаг 2** (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$



## Анализ сходимости

**Теорема:** пусть  $f$   $L$ -гладкая,  $C$  ограниченное ( $\text{diam}(C) = D$ ). Тогда при  $\gamma_k = 2/(k+2)$ :

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

*Доказательство (ключевые шаги):*

**Шаг 1** (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

**Шаг 2** (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$

**Шаг 3** (подставим  $\Delta_k = f(x_k) - f^*$ ,  $\gamma_k = 2/(k+2)$ ,  $\|s_k - x_k\|^2 \leq D^2$ ):

$$\Delta_{k+1} \leq (1 - \gamma_k) \Delta_k + \frac{\gamma_k^2 LD^2}{2}$$

## Анализ сходимости

**Теорема:** пусть  $f$   $L$ -гладкая,  $C$  ограниченное ( $\text{diam}(C) = D$ ). Тогда при  $\gamma_k = 2/(k+2)$ :

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

*Доказательство (ключевые шаги):*

**Шаг 1** (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

**Шаг 2** (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$

**Шаг 3** (подставим  $\Delta_k = f(x_k) - f^*$ ,  $\gamma_k = 2/(k+2)$ ,  $\|s_k - x_k\|^2 \leq D^2$ ):

$$\Delta_{k+1} \leq (1 - \gamma_k) \Delta_k + \frac{\gamma_k^2 LD^2}{2}$$

**Шаг 4:** по индукции  $\Delta_k \leq \frac{2LD^2}{k+2}$ .  $\square$

## Сравнение методов

| Метод              | Скорость        | Проекция?  | Итер. стоимость |
|--------------------|-----------------|------------|-----------------|
| PGD                | $O(1/k)$        | Да         | $O(\Pi_C + nd)$ |
| FISTA              | $O(1/k^2)$      | Да         | $O(\Pi_C + nd)$ |
| <b>Frank-Wolfe</b> | $O(1/k)$        | <b>Нет</b> | $O(LP + nd)$    |
| FW with away-steps | $O(e^{-\mu k})$ | Нет        | $O(LP + nd)$    |

## Сравнение методов

| Метод              | Скорость        | Проекция?  | Итер. стоимость |
|--------------------|-----------------|------------|-----------------|
| PGD                | $O(1/k)$        | Да         | $O(\Pi_C + nd)$ |
| FISTA              | $O(1/k^2)$      | Да         | $O(\Pi_C + nd)$ |
| <b>Frank-Wolfe</b> | $O(1/k)$        | <b>Нет</b> | $O(LP + nd)$    |
| FW with away-steps | $O(e^{-\mu k})$ | Нет        | $O(LP + nd)$    |

**FW на  $O(1/k)$  медленнее FISTA? Да, но:**

## Сравнение методов

| Метод              | Скорость        | Проекция?  | Итер. стоимость |
|--------------------|-----------------|------------|-----------------|
| PGD                | $O(1/k)$        | Да         | $O(\Pi_C + nd)$ |
| FISTA              | $O(1/k^2)$      | Да         | $O(\Pi_C + nd)$ |
| <b>Frank-Wolfe</b> | $O(1/k)$        | <b>Нет</b> | $O(LP + nd)$    |
| FW with away-steps | $O(e^{-\mu k})$ | Нет        | $O(LP + nd)$    |

**FW на  $O(1/k)$  медленнее FISTA? Да, но:**

- **Нет проекции** — экономия на дорогом шаге

## Сравнение методов

| Метод              | Скорость        | Проекция?  | Итер. стоимость |
|--------------------|-----------------|------------|-----------------|
| PGD                | $O(1/k)$        | Да         | $O(\Pi_C + nd)$ |
| FISTA              | $O(1/k^2)$      | Да         | $O(\Pi_C + nd)$ |
| <b>Frank-Wolfe</b> | $O(1/k)$        | <b>Нет</b> | $O(LP + nd)$    |
| FW with away-steps | $O(e^{-\mu k})$ | Нет        | $O(LP + nd)$    |

**FW на  $O(1/k)$  медленнее FISTA? Да, но:**

- **Нет проекции** — экономия на дорогом шаге
- **Разрежённость** — решения имеют малое количество ненулевых элементов

## Сравнение методов

| Метод              | Скорость        | Проекция?  | Итер. стоимость |
|--------------------|-----------------|------------|-----------------|
| PGD                | $O(1/k)$        | Да         | $O(\Pi_C + nd)$ |
| FISTA              | $O(1/k^2)$      | Да         | $O(\Pi_C + nd)$ |
| <b>Frank-Wolfe</b> | $O(1/k)$        | <b>Нет</b> | $O(LP + nd)$    |
| FW with away-steps | $O(e^{-\mu k})$ | Нет        | $O(LP + nd)$    |

**FW на  $O(1/k)$  медленнее FISTA? Да, но:**

- **Нет проекции** — экономия на дорогом шаге
- **Разрежённость** — решения имеют малое количество ненулевых элементов
- **Афинная инвариантность** — не зависит от масштабирования

## Приложения



# LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

# LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для  $\ell_1$ -шара:  $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

# LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для  $\ell_1$ -шара:  $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

Стоимость:  $O(nd)$  для градиента +  $O(d)$  для LP oracle =  $O(nd)$  всего.

# LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для  $\ell_1$ -шара:  $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

Стоимость:  $O(nd)$  для градиента +  $O(d)$  для LP oracle =  $O(nd)$  всего.

## Автоматическая разрежённость

Каждый шаг FW добавляет **один** новый ненулевой элемент в  $w_k$ .

После  $k$  шагов:  $\text{nnz}(w_k) \leq k$ .

## Матричное дополнение (Nuclear Norm Ball)

**Задача:** восстановить матрицу  $M \in \mathbb{R}^{m \times n}$  из наблюдений на  $\Omega$ .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

# Матричное дополнение (Nuclear Norm Ball)

**Задача:** восстановить матрицу  $M \in \mathbb{R}^{m \times n}$  из наблюдений на  $\Omega$ .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

**LP oracle** для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где  $u_1, v_1$  — первые сингулярные векторы  $G_k = \nabla f(X_k)$ .

# Матричное дополнение (Nuclear Norm Ball)

**Задача:** восстановить матрицу  $M \in \mathbb{R}^{m \times n}$  из наблюдений на  $\Omega$ .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

**LP oracle** для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где  $u_1, v_1$  — первые сингулярные векторы  $G_k = \nabla f(X_k)$ .

**Стоимость:** только **top-1 SVD** =  $O(mn)$  (степенной метод).

# Матричное дополнение (Nuclear Norm Ball)

**Задача:** восстановить матрицу  $M \in \mathbb{R}^{m \times n}$  из наблюдений на  $\Omega$ .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

**LP oracle** для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где  $u_1, v_1$  — первые сингулярные векторы  $G_k = \nabla f(X_k)$ .

**Стоимость:** только **top-1 SVD** =  $O(mn)$  (степенной метод).

**PGD** требует полную SVD  $O(m^2n)$  для проекции — FW значительно быстрее!



## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

**Away-step FW** (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:**  $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$  (как обычно)

## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

**Away-step FW** (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:**  $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$  (как обычно)
2. **Away step:**  $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$  — движемся **от**  $v_k$

## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

**Away-step FW** (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:**  $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$  (как обычно)
2. **Away step:**  $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$  — движемся **от**  $v_k$

## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

**Away-step FW** (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:**  $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$  (как обычно)
2. **Away step:**  $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$  — движемся **от**  $v_k$

Выбираем тот шаг, который больше уменьшает  $f$ .

## FW с away-steps (линейная сходимость)

**Проблема:** стандартный FW на политопе сходится медленно из-за **zig-zagging**.

**Away-step FW** (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:**  $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$  (как обычно)
2. **Away step:**  $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$  — движемся **от**  $v_k$

Выбираем тот шаг, который больше уменьшает  $f$ .

### Теорема (линейная сходимость)

При  $f$   $\mu$ -сильно выпуклой и  $C$  политоп:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{2LD^2}\right)^k (f(x_0) - f^*)$$

## Итоги и связь с курсом

# Когда использовать Frank-Wolfe

Используйте FW когда:



# Когда использовать Frank-Wolfe

Используйте FW когда:

☒  $C$  —  $\ell_1$ -шар, ядерно-нормный шар, политоп (LP oracle дешёв)

# Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒  $C$  —  $\ell_1$ -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)

# Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒  $C$  —  $\ell_1$ -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на  $C$  дорога или аналитически недоступна

# Когда использовать Frank-Wolfe

**Используйте FW когда:**

- ☒  $C$  —  $\ell_1$ -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на  $C$  дорога или аналитически недоступна

**Не используйте FW когда:**

# Когда использовать Frank-Wolfe

**Используйте FW когда:**

- ☒  $C$  —  $\ell_1$ -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на  $C$  дорога или аналитически недоступна

**Не используйте FW когда:**

- ☒  $C$  —  $\ell_2$ -шар (проекция  $O(d)$  — дешевле LP oracle)
- ☒ Нужна высокая точность (FW медленнее FISTA на порядок)
- ☒  $f$  негладкая (теоремы не применимы)

## Связь с ранее изученными методами

Ландшафт алгоритмов курса (ограниченная оптимизация):

| Метод              | Тип шага          | Структура $C$ | Сходимость        |
|--------------------|-------------------|---------------|-------------------|
| PGD                | Прокс-шаг         | Любое         | $O(1/k)$          |
| FISTA              | Прокс + ускорение | Любое         | $O(1/k^2)$        |
| ADMM               | Двойственная      | Разделимая    | Линейная          |
| <b>Frank-Wolfe</b> | LP oracle         | Политоп/шар   | $O(1/k)$ или лин. |

## Связь с ранее изученными методами

Ландшафт алгоритмов курса (ограниченная оптимизация):

| Метод              | Тип шага          | Структура $C$ | Сходимость        |
|--------------------|-------------------|---------------|-------------------|
| PGD                | Прокс-шаг         | Любое         | $O(1/k)$          |
| FISTA              | Прокс + ускорение | Любое         | $O(1/k^2)$        |
| ADMM               | Двойственная      | Разделимая    | Линейная          |
| <b>Frank-Wolfe</b> | LP oracle         | Политоп/шар   | $O(1/k)$ или лин. |

## Связь с оператором расщепления (PhD Даниила)

FW разделяет задачу: «**вычислить градиент**» + «**решить LP**».

Это форма оператора расщепления в пространстве допустимых направлений!

# Резюме лекции

Сегодня изучили:



# Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дороги  $\rightarrow$  нужен альтернативный подход

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$

# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle  $O(d)$  + автоматическая разрежённость

# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle  $O(d)$  + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD

# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle  $O(d)$  + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах

# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle  $O(d)$  + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах



# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** проекция дорога  $\rightarrow$  нужен альтернативный подход
2. **LP oracle:** линеаризация  $f$  + оптимизация линейной функции по  $C$
3. **FW-зазор:**  $g_k \geq f(x_k) - f^*$  — гарантированный сертификат субоптимальности
4. **Сходимость:**  $O(LD^2/k)$  для  $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle  $O(d)$  + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах

Следующая лекция (#15): Методы второго порядка — Ньютон, квази-Ньютон, L-BFGS.