




Метод Франк-Вульфа (Условный градиент)

Даня Меркулов

ФКН ВШЭ

Мотивация: когда проекция дорога

Ограниченная оптимизация и проекция

Задача: $\min_{x \in C} f(x)$, где C — замкнутое выпуклое множество.

Ограниченная оптимизация и проекция

Задача: $\min_{x \in C} f(x)$, где C — замкнутое выпуклое множество.

Проксимальный градиентный спуск (PGD):

$$x_{k+1} = \Pi_C(x_k - t \nabla f(x_k))$$

Ограниченная оптимизация и проекция

Задача: $\min_{x \in C} f(x)$, где C — замкнутое выпуклое множество.

Проксимальный градиентный спуск (PGD):

$$x_{k+1} = \Pi_C(x_k - t \nabla f(x_k))$$

Проблема: проекция Π_C может быть дорогой или аналитически невозможной!

Примеры дорогих проекций

Множество C	Проекция $\Pi_C(v)$	Стоимость
ℓ_1 -шар $\ x\ _1 \leq R$	Нетривиальная (waterfilling)	$O(d \log d)$
Ядерно-нормный шар $\ X\ _* \leq R$	SVD + обрезание	$O(\min(m, n) \cdot mn)$
Полигон (LP feasible set)	Решение LP	Труднее

Примеры дорогих проекций

Множество C	Проекция $\Pi_C(v)$	Стоимость
ℓ_1 -шар $\ x\ _1 \leq R$	Нетривиальная (waterfilling)	$O(d \log d)$
Ядерно-нормный шар $\ X\ _* \leq R$	SVD + обрезание	$O(\min(m, n) \cdot mn)$
Полигон (LP feasible set)	Решение LP	Труднее

Идея Франк-Вульфа (1956)

Вместо проекции решаем **линейную программу** (LP oracle) над C !

Алгоритм Франк-Вульфа

Идея: линеаризация целевой функции

Мотивация: если f гладкая, то вблизи x_k :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Идея: линеаризация целевой функции

Мотивация: если f гладкая, то вблизи x_k :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации $f(x)$ по C (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Идея: линеаризация целевой функции

Мотивация: если f гладкая, то вблизи x_k :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации $f(x)$ по C (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над C . Часто очень дешёва!

Идея: линеаризация целевой функции

Мотивация: если f гладкая, то вблизи x_k :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации $f(x)$ по C (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над C . Часто очень дешёва!

Шаг FW: двигаемся от x_k к s_k с шагом $\gamma_k \in [0, 1]$:

$$x_{k+1} = (1 - \gamma_k)x_k + \gamma_k s_k$$

Идея: линеаризация целевой функции

Мотивация: если f гладкая, то вблизи x_k :

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Вместо минимизации $f(x)$ по C (сложно), минимизируем линейное приближение:

$$s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$$

Это **LP oracle** — линейная программа над C . Часто очень дешёва!

Шаг FW: двигаемся от x_k к s_k с шагом $\gamma_k \in [0, 1]$:

$$x_{k+1} = (1 - \gamma_k)x_k + \gamma_k s_k$$

Ключевое свойство

$x_{k+1} \in C$ **автоматически** (выпуклость C). Никакой проекции!

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. Точный линейный поиск: $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. Точный линейный поиск: $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. Открытый шаг: $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. **Точный линейный поиск:** $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:** $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению $s_k - x_k$

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. **Точный линейный поиск:** $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:** $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению $s_k - x_k$

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. **Точный линейный поиск:** $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:** $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. **Точный линейный поиск:** $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:** $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

Лемма: $g_k \geq f(x_k) - f^*$

Доказательство: из выпуклости $f(x^*) \geq f(x_k) + \langle \nabla f(x_k), x^* - x_k \rangle$, значит

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle \leq g_k$$

Выбор шага и FW-зазор

Выбор шага $\gamma_k \in [0, 1]$:

1. **Точный линейный поиск:** $\gamma_k = \arg \min_{\gamma \in [0, 1]} f((1 - \gamma)x_k + \gamma s_k)$
2. **Открытый шаг:** $\gamma_k = \frac{2}{k + 2}$ — простой и теоретически обоснованный
3. **Armijo backtracking** по направлению $s_k - x_k$

FW-зазор (сертификат субоптимальности):

$$g_k = \langle \nabla f(x_k), x_k - s_k \rangle \geq 0$$

Лемма: $g_k \geq f(x_k) - f^*$

Доказательство: из выпуклости $f(x^*) \geq f(x_k) + \langle \nabla f(x_k), x^* - x_k \rangle$, значит

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle \leq g_k$$

Останов: при $g_k \leq \varepsilon$ гарантировано $f(x_k) - f^* \leq \varepsilon$.

Анализ сходимости

Теорема: пусть f L -гладкая, C ограниченное ($\text{diam}(C) = D$). Тогда при $\gamma_k = 2/(k+2)$:

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

Анализ сходимости

Теорема: пусть f L -гладкая, C ограниченное ($\text{diam}(C) = D$). Тогда при $\gamma_k = 2/(k+2)$:

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

Доказательство (ключевые шаги):

Шаг 1 (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

Анализ сходимости

Теорема: пусть f L -гладкая, C ограниченное ($\text{diam}(C) = D$). Тогда при $\gamma_k = 2/(k+2)$:

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

Доказательство (ключевые шаги):

Шаг 1 (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

Шаг 2 (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$

Анализ сходимости

Теорема: пусть f L -гладкая, C ограниченное ($\text{diam}(C) = D$). Тогда при $\gamma_k = 2/(k+2)$:

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

Доказательство (ключевые шаги):

Шаг 1 (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

Шаг 2 (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$

Шаг 3 (подставим $\Delta_k = f(x_k) - f^*$, $\gamma_k = 2/(k+2)$, $\|s_k - x_k\|^2 \leq D^2$):

$$\Delta_{k+1} \leq (1 - \gamma_k) \Delta_k + \frac{\gamma_k^2 LD^2}{2}$$

Анализ сходимости

Теорема: пусть f L -гладкая, C ограниченное ($\text{diam}(C) = D$). Тогда при $\gamma_k = 2/(k+2)$:

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}$$

Доказательство (ключевые шаги):

Шаг 1 (квадратичное неравенство гладкой функции):

$$f(x_{k+1}) \leq f(x_k) + \gamma_k \langle \nabla f(x_k), s_k - x_k \rangle + \frac{\gamma_k^2 L}{2} \|s_k - x_k\|^2$$

Шаг 2 (LP oracle даёт наименьший линейный шаг):

$$\langle \nabla f(x_k), s_k - x_k \rangle \leq f^* - f(x_k)$$

Шаг 3 (подставим $\Delta_k = f(x_k) - f^*$, $\gamma_k = 2/(k+2)$, $\|s_k - x_k\|^2 \leq D^2$):

$$\Delta_{k+1} \leq (1 - \gamma_k) \Delta_k + \frac{\gamma_k^2 LD^2}{2}$$

Шаг 4: по индукции $\Delta_k \leq \frac{2LD^2}{k+2}$. $\square$

Сравнение методов

Метод	Скорость	Проекция?	Итер. стоимость
PGD	$O(1/k)$	Да	$O(\Pi_C + nd)$
FISTA	$O(1/k^2)$	Да	$O(\Pi_C + nd)$
Frank-Wolfe	$O(1/k)$	Нет	$O(LP + nd)$
FW with away-steps	$O(e^{-\mu k})$	Нет	$O(LP + nd)$

Сравнение методов

Метод	Скорость	Проекция?	Итер. стоимость
PGD	$O(1/k)$	Да	$O(\Pi_C + nd)$
FISTA	$O(1/k^2)$	Да	$O(\Pi_C + nd)$
Frank-Wolfe	$O(1/k)$	Нет	$O(LP + nd)$
FW with away-steps	$O(e^{-\mu k})$	Нет	$O(LP + nd)$

FW на $O(1/k)$ медленнее FISTA? Да, но:

Сравнение методов

Метод	Скорость	Проекция?	Итер. стоимость
PGD	$O(1/k)$	Да	$O(\Pi_C + nd)$
FISTA	$O(1/k^2)$	Да	$O(\Pi_C + nd)$
Frank-Wolfe	$O(1/k)$	Нет	$O(LP + nd)$
FW with away-steps	$O(e^{-\mu k})$	Нет	$O(LP + nd)$

FW на $O(1/k)$ медленнее FISTA? Да, но:

- **Нет проекции** — экономия на дорогом шаге

Сравнение методов

Метод	Скорость	Проекция?	Итер. стоимость
PGD	$O(1/k)$	Да	$O(\Pi_C + nd)$
FISTA	$O(1/k^2)$	Да	$O(\Pi_C + nd)$
Frank-Wolfe	$O(1/k)$	Нет	$O(LP + nd)$
FW with away-steps	$O(e^{-\mu k})$	Нет	$O(LP + nd)$

FW на $O(1/k)$ медленнее FISTA? Да, но:

- **Нет проекции** — экономия на дорогом шаге
- **Разрежённость** — решения имеют малое количество ненулевых элементов

Сравнение методов

Метод	Скорость	Проекция?	Итер. стоимость
PGD	$O(1/k)$	Да	$O(\Pi_C + nd)$
FISTA	$O(1/k^2)$	Да	$O(\Pi_C + nd)$
Frank-Wolfe	$O(1/k)$	Нет	$O(LP + nd)$
FW with away-steps	$O(e^{-\mu k})$	Нет	$O(LP + nd)$

FW на $O(1/k)$ медленнее FISTA? Да, но:

- **Нет проекции** — экономия на дорогом шаге
- **Разрежённость** — решения имеют малое количество ненулевых элементов
- **Афинная инвариантность** — не зависит от масштабирования

Приложения

LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для ℓ_1 -шара: $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для ℓ_1 -шара: $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

Стоимость: $O(nd)$ для градиента + $O(d)$ для LP oracle = $O(nd)$ всего.

LASSO через Frank-Wolfe

Ограниченный LASSO (Tibshirani 1996):

$$\min_w \frac{1}{2n} \|Xw - y\|^2 \quad \text{s.t.} \quad \|w\|_1 \leq R$$

LP oracle для ℓ_1 -шара: $s_k = \arg \min_{\|s\|_1 \leq R} \langle \nabla f(w_k), s \rangle$

$$s_k = -R \cdot e_{j^*} \cdot \text{sign}([\nabla f]_{j^*}), \quad j^* = \arg \max_j |[\nabla f(w_k)]_j|$$

Стоимость: $O(nd)$ для градиента + $O(d)$ для LP oracle = $O(nd)$ всего.

Автоматическая разрежённость

Каждый шаг FW добавляет **один** новый ненулевой элемент в w_k .

После k шагов: $\text{nnz}(w_k) \leq k$.

Матричное дополнение (Nuclear Norm Ball)

Задача: восстановить матрицу $M \in \mathbb{R}^{m \times n}$ из наблюдений на Ω .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

Матричное дополнение (Nuclear Norm Ball)

Задача: восстановить матрицу $M \in \mathbb{R}^{m \times n}$ из наблюдений на Ω .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

LP oracle для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где u_1, v_1 — первые сингулярные векторы $G_k = \nabla f(X_k)$.

Матричное дополнение (Nuclear Norm Ball)

Задача: восстановить матрицу $M \in \mathbb{R}^{m \times n}$ из наблюдений на Ω .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

LP oracle для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где u_1, v_1 — первые сингулярные векторы $G_k = \nabla f(X_k)$.

Стоимость: только **top-1 SVD** = $O(mn)$ (степенной метод).

Матричное дополнение (Nuclear Norm Ball)

Задача: восстановить матрицу $M \in \mathbb{R}^{m \times n}$ из наблюдений на Ω .

$$\min_{X: \|X\|_* \leq R} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$$

LP oracle для ядерно-нормного шара:

$$S_k = \arg \min_{\|S\|_* \leq R} \langle G_k, S \rangle = -R \cdot u_1 v_1^T$$

где u_1, v_1 — первые сингулярные векторы $G_k = \nabla f(X_k)$.

Стоимость: только **top-1 SVD** = $O(mn)$ (степенной метод).

PGD требует полную SVD $O(m^2n)$ для проекции — FW значительно быстрее!

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

Away-step FW (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:** $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$ (как обычно)

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

Away-step FW (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:** $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$ (как обычно)
2. **Away step:** $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$ — движемся **от** v_k

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

Away-step FW (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:** $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$ (как обычно)
2. **Away step:** $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$ — движемся **от** v_k

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

Away-step FW (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:** $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$ (как обычно)
2. **Away step:** $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$ — движемся **от** v_k

Выбираем тот шаг, который больше уменьшает f .

FW с away-steps (линейная сходимость)

Проблема: стандартный FW на политопе сходится медленно из-за **zig-zagging**.

Away-step FW (Wolfe 1970): на каждом шаге выбираем из двух вариантов:

1. **FW step:** $s_k = \arg \min_{s \in C} \langle \nabla f(x_k), s \rangle$ (как обычно)
2. **Away step:** $v_k = \arg \max_{v \in \text{supp}(x_k)} \langle \nabla f(x_k), v \rangle$ — движемся **от** v_k

Выбираем тот шаг, который больше уменьшает f .

Теорема (линейная сходимость)

При f μ -сильно выпуклой и C политоп:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{2LD^2}\right)^k (f(x_0) - f^*)$$

Итоги и связь с курсом

Когда использовать Frank-Wolfe

Используйте FW когда:

Когда использовать Frank-Wolfe

Используйте FW когда:

☒ C — ℓ_1 -шар, ядерно-нормный шар, политоп (LP oracle дешёв)

Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒ C — ℓ_1 -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)

Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒ C — ℓ_1 -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на C дорога или аналитически недоступна

Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒ C — ℓ_1 -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на C дорога или аналитически недоступна

Не используйте FW когда:

Когда использовать Frank-Wolfe

Используйте FW когда:

- ☒ C — ℓ_1 -шар, ядерно-нормный шар, политоп (LP oracle дешёв)
- ☒ Нужны разрежённые решения (малоранговая матрица, разрежённый вектор)
- ☒ Проекция на C дорога или аналитически недоступна

Не используйте FW когда:

- ☒ C — ℓ_2 -шар (проекция $O(d)$ — дешевле LP oracle)
- ☒ Нужна высокая точность (FW медленнее FISTA на порядок)
- ☒ f негладкая (теоремы не применимы)

Связь с ранее изученными методами

Ландшафт алгоритмов курса (ограниченная оптимизация):

Метод	Тип шага	Структура C	Сходимость
PGD	Прокс-шаг	Любое	$O(1/k)$
FISTA	Прокс + ускорение	Любое	$O(1/k^2)$
ADMM	Двойственная	Разделимая	Линейная
Frank-Wolfe	LP oracle	Политоп/шар	$O(1/k)$ или лин.

Связь с ранее изученными методами

Ландшафт алгоритмов курса (ограниченная оптимизация):

Метод	Тип шага	Структура C	Сходимость
PGD	Прокс-шаг	Любое	$O(1/k)$
FISTA	Прокс + ускорение	Любое	$O(1/k^2)$
ADMM	Двойственная	Разделимая	Линейная
Frank-Wolfe	LP oracle	Политоп/шар	$O(1/k)$ или лин.

Связь с оператором расщепления (PhD Даниила)

FW разделяет задачу: «**вычислить градиент**» + «**решить LP**».

Это форма оператора расщепления в пространстве допустимых направлений!

Резюме лекции

Сегодня изучили:

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дороги $\rightarrow$ нужен альтернативный подход

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle $O(d)$ + автоматическая разрежённость

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle $O(d)$ + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle $O(d)$ + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle $O(d)$ + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах

Резюме лекции

Сегодня изучили:

1. **Мотивация:** проекция дорога $\rightarrow$ нужен альтернативный подход
2. **LP oracle:** линеаризация f + оптимизация линейной функции по C
3. **FW-зазор:** $g_k \geq f(x_k) - f^*$ — гарантированный сертификат субоптимальности
4. **Сходимость:** $O(LD^2/k)$ для $\gamma_k = 2/(k+2)$
5. **LASSO:** LP oracle $O(d)$ + автоматическая разрежённость
6. **Ядерная норма:** top-1 SVD вместо полной SVD
7. **Away-steps:** линейная сходимость на политопах

Следующая лекция (#15): Негладкая оптимизация — субградиент, субдифференциал, субградиентный спуск.