




Методы второго порядка

Даня Меркулов

ФКН ВШЭ

Мотивация: скорость важна

Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

Общая черта: используют только $\nabla f(x)$ — информацию о **наклоне** функции.

Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

Общая черта: используют только $\nabla f(x)$ — информацию о **наклоне** функции.

Метод	Скорость	Зависимость от $\kappa = L/\mu$
GD	$O((1 - 1/\kappa)^k)$	Линейная, плохо при большом κ
AGD	$O(e^{-k/\sqrt{\kappa}})$	Ускорение, но всё равно зависит от κ
SGD	$O(1/\sqrt{k})$	Шумовой пол — никогда не достигает точного минимума

Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

Общая черта: используют только $\nabla f(x)$ — информацию о **наклоне** функции.

Метод	Скорость	Зависимость от $\kappa = L/\mu$
GD	$O((1 - 1/\kappa)^k)$	Линейная, плохо при большом κ
AGD	$O(e^{-k/\sqrt{\kappa}})$	Ускорение, но всё равно зависит от κ
SGD	$O(1/\sqrt{k})$	Шумовой пол — никогда не достигает точного минимума

Вопрос: что если использовать **кривизну** функции (вторые производные)?

Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

Общая черта: используют только $\nabla f(x)$ — информацию о **наклоне** функции.

Метод	Скорость	Зависимость от $\kappa = L/\mu$
GD	$O((1 - 1/\kappa)^k)$	Линейная, плохо при большом κ
AGD	$O(e^{-k/\sqrt{\kappa}})$	Ускорение, но всё равно зависит от κ
SGD	$O(1/\sqrt{k})$	Шумовой пол — никогда не достигает точного минимума

Вопрос: что если использовать **кривизну** функции (вторые производные)?

Метод Ньютона

$O(\log \log(1/\varepsilon))$ итераций — квадратичная сходимость!

Количество верных цифр **удваивается** на каждой итерации.

Интуиция: аппроксимация второго порядка

GD: линейная аппроксимация $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

Интуиция: аппроксимация второго порядка

GD: линейная аппроксимация $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

Интуиция: аппроксимация второго порядка

GD: линейная аппроксимация $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

Newton: квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Интуиция: аппроксимация второго порядка

GD: линейная аппроксимация $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

Newton: квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Минимизируем квадратичную аппроксимацию аналитически:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

Интуиция: аппроксимация второго порядка

GD: линейная аппроксимация $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

Newton: квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Минимизируем квадратичную аппроксимацию аналитически:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

Геометрическая интерпретация

Шаг Ньютона $d_k = -H_k^{-1} g_k$ — кратчайший спуск в **метрике гессiana**:
 $\|d_k\|_{H_k}^2 = d_k^T H_k d_k = g_k^T H_k^{-1} g_k$

Метод Ньютона

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:  
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление  
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо  
    x_{k+1} = x_k + α_k d_k  
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$ (верхняя оценка субоптимальности)

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$ (верхняя оценка субоптимальности)

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$ (верхняя оценка субоптимальности)
- **Аффинная инвариантность:** $\lambda(x)$ не меняется при замене $y = Ax$

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$ (верхняя оценка субоптимальности)
- **Аффинная инвариантность:** $\lambda(x)$ не меняется при замене $y = Ax$

Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$ (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$ (верхняя оценка субоптимальности)
- **Аффинная инвариантность:** $\lambda(x)$ не меняется при замене $y = Ax$

Два режима сходимости

Демпфированная фаза: x далеко от x^* — используем backtracking line search.

Квадратичная фаза: x близко к x^* — полный шаг $\alpha = 1$.

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей: $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$.

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей: $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$.

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей: $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$.

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

Что это значит: обозначим $e_k = \|x_k - x^*\|$.

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей: $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$.

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

Что это значит: обозначим $e_k = \|x_k - x^*\|$.

$$e_{k+1} \leq C e_k^2 \implies e_k \leq \frac{1}{C} (C e_0)^{2^k}$$

Квадратичная сходимость

Теорема (локальная квадратичная сходимость): если f сильно выпуклая, $\nabla^2 f$ M -липшицев, и x_k достаточно близко к x^* , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

Доказательство (набросок):

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей: $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$.

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

Что это значит: обозначим $e_k = \|x_k - x^*\|$.

$$e_{k+1} \leq C e_k^2 \implies e_k \leq \frac{1}{C} (C e_0)^{2^k}$$

Удвоение точных цифр

От $e_0 = 10^{-2}$ до $e_4 \approx 10^{-32}$ за 4 итерации!

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

При $d = 10^6$ (типичная нейросеть):

- Гессиан: 10^{12} элементов $\rightarrow$ **4 ТБ** памяти только для хранения!

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

При $d = 10^6$ (типичная нейросеть):

- Гессиан: 10^{12} элементов $\rightarrow$ **4 ТБ** памяти только для хранения!
- Инверсия: 10^{18} операций $\rightarrow$ при 10^{12} FLOP/s = **1 000 000 секунд**

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

При $d = 10^6$ (типичная нейросеть):

- Гессиан: 10^{12} элементов $\rightarrow$ **4 ТБ** памяти только для хранения!
- Инверсия: 10^{18} операций $\rightarrow$ при 10^{12} FLOP/s = **1 000 000 секунд**

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

При $d = 10^6$ (типичная нейросеть):

- Гессиан: 10^{12} элементов $\rightarrow$ **4 ТБ** памяти только для хранения!
- Инверсия: 10^{18} операций $\rightarrow$ при 10^{12} FLOP/s = **1 000 000 секунд**

Вывод: Ньютон непрактичен для DL

Метод Ньютона применим только при $d \leq 10^3$ – 10^4 (малые модели, физика, химия).

Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

Шаг	Операция	Стоимость
Градиент	$\nabla f(x_k)$	$O(nd)$
Гессиан	$\nabla^2 f(x_k)$	$O(nd^2)$
Решение СЛАУ	$H_k d_k = -g_k$	$O(d^3)$
Итого		$O(nd^2 + d^3)$

При $d = 10^6$ (типичная нейросеть):

- Гессиан: 10^{12} элементов $\rightarrow$ **4 ТБ** памяти только для хранения!
- Инверсия: 10^{18} операций $\rightarrow$ при 10^{12} FLOP/s = **1 000 000 секунд**

Вывод: Ньютон непрактичен для DL

Метод Ньютона применим только при $d \leq 10^3$ – 10^4 (малые модели, физика, химия).

Компромисс: квази-ньютоновские методы — аппроксимируем H^{-1} без явного вычисления.

Квази-Ньютоновские методы

Идея: аппроксимация гессиана

Ключевой вопрос: можем ли мы строить хорошую аппроксимацию H_k^{-1} , используя только градиенты?

Идея: аппроксимация гессиана

Ключевой вопрос: можем ли мы строить хорошую аппроксимацию H_k^{-1} , используя только градиенты?

Секантное условие: из $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$ следует:

$$B_{k+1}s_k = y_k$$

где $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$, B_{k+1} — аппроксимация $\nabla^2 f$.

Идея: аппроксимация гессиана

Ключевой вопрос: можем ли мы строить хорошую аппроксимацию H_k^{-1} , используя только градиенты?

Секантное условие: из $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$ следует:

$$B_{k+1}s_k = y_k$$

где $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$, B_{k+1} — аппроксимация $\nabla^2 f$.

Идея ранг-2 обновлений: обновлять матрицу $C_k = B_k^{-1}$ малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$

Идея: аппроксимация гессиана

Ключевой вопрос: можем ли мы строить хорошую аппроксимацию H_k^{-1} , используя только градиенты?

Секантное условие: из $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$ следует:

$$B_{k+1} s_k = y_k$$

где $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$, B_{k+1} — аппроксимация $\nabla^2 f$.

Идея ранг-2 обновлений: обновлять матрицу $C_k = B_k^{-1}$ малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$

BFGS-обновление (Broyden–Fletcher–Goldfarb–Shanno, 1970):

$$C_{k+1} = (I - \rho_k s_k y_k^T) C_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

где $\rho_k = \frac{1}{y_k^T s_k}$.

Идея: аппроксимация гессиана

Ключевой вопрос: можем ли мы строить хорошую аппроксимацию H_k^{-1} , используя только градиенты?

Секантное условие: из $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$ следует:

$$B_{k+1} s_k = y_k$$

где $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$, B_{k+1} — аппроксимация $\nabla^2 f$.

Идея ранг-2 обновлений: обновлять матрицу $C_k = B_k^{-1}$ малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$

BFGS-обновление (Broyden–Fletcher–Goldfarb–Shanno, 1970):

$$C_{k+1} = (I - \rho_k s_k y_k^T) C_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

где $\rho_k = \frac{1}{y_k^T s_k}$.

Условие корректности

Необходимо $y_k^T s_k > 0$ — обеспечивается **условием Вольфа** в line search.

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. Достаточное убывание (Армихо): $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. Достаточное убывание (Армихо): $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. **Достаточное убывание (Армихо):** $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:** $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. **Достаточное убывание (Армихо):** $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:** $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. **Достаточное убывание (Армихо):** $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:** $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$. $\boxtimes$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. **Достаточное убывание (Армихо)**: $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны**: $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$. $\boxtimes$

Теорема (суперлинейная сходимость BFGS): если x_0 достаточно близко к x^* , f сильно выпуклая с Липшицевым гессианом, то:

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0 \quad (k \rightarrow \infty)$$

Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага α_k):

1. **Достаточное убывание (Армихо):** $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:** $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$. $\boxtimes$

Теорема (суперлинейная сходимость BFGS): если x_0 достаточно близко к x^* , f сильно выпуклая с Липшицевым гессианом, то:

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0 \quad (k \rightarrow \infty)$$

Интерпретация

Суперлинейная — это больше линейной, но меньше квадратичной.

На практике: BFGS сходится быстрее GD и почти так же быстро, как Newton!

Стоимость BFGS

Анализ стоимости BFGS:

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Сравнение с Ньютоном:

- Ньютон: $O(d^3)$ за итерацию (инверсия гессиана)

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Сравнение с Ньютоном:

- Ньютон: $O(d^3)$ за итерацию (инверсия гессиана)
- BFGS: $O(d^2)$ за итерацию — **на порядок быстрее!**

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Сравнение с Ньютоном:

- Ньютон: $O(d^3)$ за итерацию (инверсия гессиана)
- BFGS: $O(d^2)$ за итерацию — **на порядок быстрее!**

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Сравнение с Ньютоном:

- Ньютон: $O(d^3)$ за итерацию (инверсия гессиана)
- BFGS: $O(d^2)$ за итерацию — **на порядок быстрее!**

Но при $d = 10^5$: хранение $C_k = 10^{10}$ элементов = **80 ГБ** — всё ещё слишком много.

Стоимость BFGS

Анализ стоимости BFGS:

Шаг	Стоимость
Градиент g_{k+1}	$O(nd)$
Обновление C_{k+1} (ранг-2)	$O(d^2)$
Умножение $C_{k+1}g_{k+1}$	$O(d^2)$
Хранение C_k	$O(d^2)$

Сравнение с Ньютоном:

- Ньютон: $O(d^3)$ за итерацию (инверсия гессиана)
- BFGS: $O(d^2)$ за итерацию — **на порядок быстрее!**

Но при $d = 10^5$: хранение $C_k = 10^{10}$ элементов = **80 ГБ** — всё ещё слишком много.

Ограничение BFGS

BFGS практичен при $d \leq 10^4$. Для больших задач нужен **L-BFGS**.

L-BFGS

L-BFGS: Limited Memory BFGS

Ключевая идея: не хранить всю матрицу $C_k \in \mathbb{R}^{d \times d}$, а только последние m пар (s_j, y_j) .

L-BFGS: Limited Memory BFGS

Ключевая идея: не хранить всю матрицу $C_k \in \mathbb{R}^{d \times d}$, а только последние m пар (s_j, y_j) .

L-BFGS (Liu & Nocedal, 1989): - Хранить: m пар $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$ - Типичное m : 5–20 (независимо от d !) - Память: $O(md)$ вместо $O(d^2)$

L-BFGS: Limited Memory BFGS

Ключевая идея: не хранить всю матрицу $C_k \in \mathbb{R}^{d \times d}$, а только последние m пар (s_j, y_j) .

L-BFGS (Liu & Nocedal, 1989): - Хранить: m пар $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$ - Типичное m : 5–20 (независимо от d !) - Память: $O(md)$ вместо $O(d^2)$

Вычисление $C_k g_k$ без явной матрицы — через двухпетлевую рекуррентность:

Вход: g_k , пары $\{(s_j, y_j)\}$, скаляры $\rho_j = 1/(y_j^T s_j)$

```
q = g_k
for i = k-1, k-2, ..., k-m:           # Первая петля (назад)
     $\alpha_i = \rho_i * s_i^T q$ 
     $q = q - \alpha_i * y_i$ 

r = H_0 * q                           # Начальное приближение (диагональ)

for i = k-m, k-m+1, ..., k-1:       # Вторая петля (вперёд)
     $\beta_i = \rho_i * y_i^T r$ 
     $r = r + (\alpha_i - \beta_i) * s_i$ 

return r    ← это H_k g_k
```

L-BFGS: Limited Memory BFGS

Ключевая идея: не хранить всю матрицу $C_k \in \mathbb{R}^{d \times d}$, а только последние m пар (s_j, y_j) .

L-BFGS (Liu & Nocedal, 1989): - Хранить: m пар $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$ - Типичное m : 5–20 (независимо от d !) - Память: $O(md)$ вместо $O(d^2)$

Вычисление $C_k g_k$ без явной матрицы — через двухпетлевую рекуррентность:

Вход: g_k , пары $\{(s_j, y_j)\}$, скаляры $\rho_j = 1/(y_j^T s_j)$

```
q = g_k
for i = k-1, k-2, ..., k-m:          # Первая петля (назад)
     $\alpha_i = \rho_i * s_i^T q$ 
     $q = q - \alpha_i * y_i$ 

r = H_0 * q                          # Начальное приближение (диагональ)

for i = k-m, k-m+1, ..., k-1:      # Вторая петля (вперёд)
     $\beta_i = \rho_i * y_i^T r$ 
     $r = r + (\alpha_i - \beta_i) * s_i$ 

return r    ← это H_k g_k
```

Стоимость: $O(md)$ — не зависит от d^2 !

Детали L-BFGS

Начальное приближение H_0 :

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом $y_k^T s_k$):

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом $y_k^T s_k$):

Если $\rho_k = 1/(y_k^T s_k)$ слишком велико — пропускаем пару (s_k, y_k) .

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом $y_k^T s_k$):

Если $\rho_k = 1/(y_k^T s_k)$ слишком велико — пропускаем пару (s_k, y_k) .

Сходимость L-BFGS: линейная (хуже суперлинейной для полного BFGS):

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{c}{m}\right) (f(x_k) - f^*)$$

Детали L-BFGS

Начальное приближение H_0 :

Обычно берут $H_0 = \gamma_k I$, где $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ — масштаб последнего обновления.

Выбор m :

- $m = 5$: быстро, хватает для большинства задач
- $m = 20$: лучше аппроксимация, чуть медленнее
- $m = d$: эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом $y_k^T s_k$):

Если $\rho_k = 1/(y_k^T s_k)$ слишком велико — пропускаем пару (s_k, y_k) .

Сходимость L-BFGS: линейная (хуже суперлинейной для полного BFGS):

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{c}{m}\right) (f(x_k) - f^*)$$

Практическое использование

PyTorch: `torch.optim.LBFGS`. Scikit-learn: `solver='lbfgs'` для LogReg, MLP.

Сравнение и применение

Полная таблица методов оптимизации

Метод	Стоимость/итер	Сходимость	Память	Применение
GD	$O(nd)$	Линейная	$O(d)$	Большой n , простые задачи
AGD	$O(nd)$	$O(e^{-k/\sqrt{\kappa}})$	$O(d)$	Выпуклая, нет шума
SGD	$O(d)$	$O(1/\sqrt{k})$	$O(d)$	DL, $n \rightarrow \infty$
SVRG	$O((n + \kappa)d)$	Линейная	$O(d)$	Конечные суммы
ADMM	$O(\text{subprob})$	Линейная	$O(d)$	Разделимая структура
FW	$O(nd + \text{LP})$	$O(1/k)$	$O(d)$	Полигон/шар
Newton	$O(nd^2 + d^3)$	Квадратичная	$O(d^2)$	$d \leq 10^3$
BFGS	$O(nd + d^2)$	Суперлинейная	$O(d^2)$	$d \leq 10^4$
L-BFGS	$O((n + m)d)$	Линейная	$O(md)$	$d \leq 10^6$, пакетный
Adam	$O(nd)$	Адаптивная (эмпир.)	$O(d)$	DL, sparse gradients

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

☒ Физика/химия (моделирование молекул, МКЭ)

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

L-BFGS: $10^4 \leq d \leq 10^6$

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

L-BFGS: $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

L-BFGS: $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

L-BFGS: $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)
- ☒ Физика+ML: neural operators, PINNs

Когда использовать методы второго порядка

Newton: $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до 10^{-15})

BFGS: $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при $d \leq 10^4$

L-BFGS: $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)
- ☒ Физика+ML: neural operators, PINNs
- ☒ **Не используйте методы 2-го порядка для:** SGD-режима (стохастический шум ломает аппроксимацию гессиана), очень больших нейросетей ($d > 10^8$).

Связь с современными методами (K-FAC, Shampoo, Muon)

Практическая проблема: Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

Связь с современными методами (K-FAC, Shampoo, Muon)

Практическая проблема: Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

Ответ: Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через m пар).

Связь с современными методами (K-FAC, Shampoo, Muon)

Практическая проблема: Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

Ответ: Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через m пар).

Современные «second-order» методы для DL:

Связь с современными методами (K-FAC, Shampoo, Muon)

Практическая проблема: Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

Ответ: Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через m пар).

Современные «second-order» методы для DL:

Метод	Идея	Применение
K-FAC	Кронекерова факторизация гессиана	CNN, Transformer
Shampoo	Предобусловливание по Кронекерову произведению	Google TPU
Muon	Momentum + ортогонализация (☒ Ньютон)	GPT-2, Gemma
Sophia	Scalable second-order	LLM pretraining

Связь с современными методами (K-FAC, Shampoo, Muon)

Практическая проблема: Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

Ответ: Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через m пар).

Современные «second-order» методы для DL:

Метод	Идея	Применение
K-FAC	Кронекерова факторизация гессiana	CNN, Transformer
Shampoo	Предобусловливание по Кронекерову произведению	Google TPU
Muon	Momentum + ортогонализация (☒ Ньютон)	GPT-2, Gemma
Sophia	Scalable second-order	LLM pretraining

Связь с PhD Даниила

BFGS аппроксимирует гессиан через секантные пары (s_k, y_k) — форма **накопленного расщепления** информации о кривизне.

IMEX-RK методы занимают промежуточное место между явным (GD) и неявным (Newton).

Итоги

Резюме лекции

Сегодня изучили:

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$
6. **L-BFGS:** m пар + двухпетлевая рекуррентность $\rightarrow O(md)$, применимо до $d = 10^6$

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$
6. **L-BFGS:** m пар + двухпетлевая рекуррентность $\rightarrow O(md)$, применимо до $d = 10^6$

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$
6. **L-BFGS:** m пар + двухпетлевая рекуррентность $\rightarrow O(md)$, применимо до $d = 10^6$
7. **Таблица методов:** выбор зависит от d , структуры задачи, нужной точности

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$
6. **L-BFGS:** m пар + двухпетлевая рекуррентность $\rightarrow O(md)$, применимо до $d = 10^6$
7. **Таблица методов:** выбор зависит от d , структуры задачи, нужной точности

Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от κ — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация $\rightarrow O(\log \log(1/\varepsilon))$ итераций, но $O(d^3)$ дорого
3. **Ньютоновский декремент** $\lambda(x)$: аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:** $e_{k+1} \leq \frac{M}{2\mu} e_k^2$ — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление $\rightarrow$ суперлинейная сходимость при $O(d^2)$
6. **L-BFGS:** m пар + двухпетлевая рекуррентность $\rightarrow O(md)$, применимо до $d = 10^6$
7. **Таблица методов:** выбор зависит от d , структуры задачи, нужной точности

Следующая лекция (#16): Невыпуклая оптимизация — как методы работают за пределами выпуклого случая, седловые точки, PL-условие.