




Методы второго порядка

Даня Меркулов

ФКН ВШЭ

Мотивация: скорость важна

# Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

# Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

**Общая черта:** используют только  $\nabla f(x)$  — информацию о **наклоне** функции.

## Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

**Общая черта:** используют только  $\nabla f(x)$  — информацию о **наклоне** функции.

| Метод | Скорость                  | Зависимость от $\kappa = L/\mu$                     |
|-------|---------------------------|-----------------------------------------------------|
| GD    | $O((1 - 1/\kappa)^k)$     | Линейная, плохо при большом $\kappa$                |
| AGD   | $O(e^{-k/\sqrt{\kappa}})$ | Ускорение, но всё равно зависит от $\kappa$         |
| SGD   | $O(1/\sqrt{k})$           | Шумовой пол — никогда не достигает точного минимума |

## Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

**Общая черта:** используют только  $\nabla f(x)$  — информацию о **наклоне** функции.

| Метод | Скорость                  | Зависимость от $\kappa = L/\mu$                     |
|-------|---------------------------|-----------------------------------------------------|
| GD    | $O((1 - 1/\kappa)^k)$     | Линейная, плохо при большом $\kappa$                |
| AGD   | $O(e^{-k/\sqrt{\kappa}})$ | Ускорение, но всё равно зависит от $\kappa$         |
| SGD   | $O(1/\sqrt{k})$           | Шумовой пол — никогда не достигает точного минимума |

**Вопрос:** что если использовать **кривизну** функции (вторые производные)?

# Ограничения методов первого порядка

Что мы изучили: GD, AGD, SGD, ProxGD, ADMM, Frank-Wolfe — всё это **методы первого порядка**.

**Общая черта:** используют только  $\nabla f(x)$  — информацию о **наклоне** функции.

| Метод | Скорость                  | Зависимость от $\kappa = L/\mu$                     |
|-------|---------------------------|-----------------------------------------------------|
| GD    | $O((1 - 1/\kappa)^k)$     | Линейная, плохо при большом $\kappa$                |
| AGD   | $O(e^{-k/\sqrt{\kappa}})$ | Ускорение, но всё равно зависит от $\kappa$         |
| SGD   | $O(1/\sqrt{k})$           | Шумовой пол — никогда не достигает точного минимума |

**Вопрос:** что если использовать **кривизну** функции (вторые производные)?

## Метод Ньютона

$O(\log \log(1/\varepsilon))$  итераций — квадратичная сходимость!

Количество верных цифр **удваивается** на каждой итерации.

## Интуиция: аппроксимация второго порядка

**GD:** линейная аппроксимация  $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$



## Интуиция: аппроксимация второго порядка

**GD:** линейная аппроксимация  $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

## Интуиция: аппроксимация второго порядка

**GD:** линейная аппроксимация  $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

**Newton:** квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

## Интуиция: аппроксимация второго порядка

**GD:** линейная аппроксимация  $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

**Newton:** квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Минимизируем квадратичную аппроксимацию аналитически:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

## Интуиция: аппроксимация второго порядка

**GD:** линейная аппроксимация  $f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$

$$x_{k+1} = x_k - t \nabla f(x_k) \quad \leftarrow \text{шаг в направлении антиградиента}$$

**Newton:** квадратичная аппроксимация:

$$f(x) \approx f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Минимизируем квадратичную аппроксимацию аналитически:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

## Геометрическая интерпретация

Шаг Ньютона  $d_k = -H_k^{-1} g_k$  — кратчайший спуск в **метрике гессiana**:  
 $\|d_k\|_{H_k}^2 = d_k^T H_k d_k = g_k^T H_k^{-1} g_k$

# Метод Ньютона

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:  
    d_k = -[∇2f(x_k)]-1 ∇f(x_k)      # Ньютоновское направление  
    α_k = backtracking(x_k, d_k)        # Шаг по Армихо  
    x_{k+1} = x_k + α_k d_k  
    if λ(x_k)2/2 ≤ ε: break            # Критерий остановки
```

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)



# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$  (верхняя оценка субоптимальности)

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$  (верхняя оценка субоптимальности)

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$  (верхняя оценка субоптимальности)
- **Аффинная инвариантность:**  $\lambda(x)$  не меняется при замене  $y = Ax$

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$  (верхняя оценка субоптимальности)
- **Аффинная инвариантность:**  $\lambda(x)$  не меняется при замене  $y = Ax$

# Алгоритм и ньютоновский декремент

Демпфированный метод Ньютона:

```
for k = 0, 1, 2, ...:
    d_k = -[∇²f(x_k)]⁻¹ ∇f(x_k)      # Ньютоновское направление
    α_k = backtracking(x_k, d_k)      # Шаг по Армихо
    x_{k+1} = x_k + α_k d_k
    if λ(x_k)²/2 ≤ ε: break          # Критерий остановки
```

Ньютоновский декремент:

$$\lambda(x) = \sqrt{g^T H^{-1} g} = \|d\|_H$$

Свойства декремента:

- $\lambda(x) = 0 \Leftrightarrow x = x^*$  (критерий оптимальности)
- $f(x) - f(x^*) \leq \frac{\lambda(x)^2}{2}$  (верхняя оценка субоптимальности)
- **Аффинная инвариантность:**  $\lambda(x)$  не меняется при замене  $y = Ax$

Два режима сходимости

**Демпфированная фаза:**  $x$  далеко от  $x^*$  — используем backtracking line search.

**Квадратичная фаза:**  $x$  близко к  $x^*$  — полный шаг  $\alpha = 1$ .

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$



## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей:  $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$ .

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей:  $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$ .

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей:  $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$ .

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

**Что это значит:** обозначим  $e_k = \|x_k - x^*\|$ .

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей:  $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$ .

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

**Что это значит:** обозначим  $e_k = \|x_k - x^*\|$ .

$$e_{k+1} \leq C e_k^2 \implies e_k \leq \frac{1}{C} (C e_0)^{2^k}$$

## Квадратичная сходимость

**Теорема (локальная квадратичная сходимость):** если  $f$  сильно выпуклая,  $\nabla^2 f$   $M$ -липшицев, и  $x_k$  достаточно близко к  $x^*$ , то:

$$\|x_{k+1} - x^*\| \leq \frac{M}{2\mu} \|x_k - x^*\|^2$$

*Доказательство (набросок):*

$$x_{k+1} - x^* = x_k - H_k^{-1} g_k - x^* = H_k^{-1} [H_k(x_k - x^*) - g_k]$$

Из формулы конечных разностей:  $g_k = \int_0^1 H(x^* + t(x_k - x^*)) dt \cdot (x_k - x^*)$ .

$$\|x_{k+1} - x^*\| \leq \|H_k^{-1}\| \cdot \frac{M}{2} \|x_k - x^*\|^2 \leq \frac{M}{2\mu} \|x_k - x^*\|^2 \quad \square$$

**Что это значит:** обозначим  $e_k = \|x_k - x^*\|$ .

$$e_{k+1} \leq C e_k^2 \implies e_k \leq \frac{1}{C} (C e_0)^{2^k}$$

**Удвоение точных цифр**

От  $e_0 = 10^{-2}$  до  $e_4 \approx 10^{-32}$  за 4 итерации!

# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

При  $d = 10^6$  (типичная нейросеть):

- Гессиан:  $10^{12}$  элементов  $\rightarrow$  **4 ТБ** памяти только для хранения!



# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

При  $d = 10^6$  (типичная нейросеть):

- Гессиан:  $10^{12}$  элементов  $\rightarrow$  **4 ТБ** памяти только для хранения!
- Инверсия:  $10^{18}$  операций  $\rightarrow$  при  $10^{12}$  FLOP/s = **1 000 000 секунд**

# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

При  $d = 10^6$  (типичная нейросеть):

- Гессиан:  $10^{12}$  элементов  $\rightarrow$  **4 ТБ** памяти только для хранения!
- Инверсия:  $10^{18}$  операций  $\rightarrow$  при  $10^{12}$  FLOP/s = **1 000 000 секунд**

## Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

При  $d = 10^6$  (типичная нейросеть):

- Гессиан:  $10^{12}$  элементов  $\rightarrow$  **4 ТБ** памяти только для хранения!
- Инверсия:  $10^{18}$  операций  $\rightarrow$  при  $10^{12}$  FLOP/s = **1 000 000 секунд**

**Вывод: Ньютон непрактичен для DL**

Метод Ньютона применим только при  $d \leq 10^3$ – $10^4$  (малые модели, физика, химия).

# Стоимость и ограничения

Стоимость одной итерации метода Ньютона:

| Шаг          | Операция          | Стоимость       |
|--------------|-------------------|-----------------|
| Градиент     | $\nabla f(x_k)$   | $O(nd)$         |
| Гессиан      | $\nabla^2 f(x_k)$ | $O(nd^2)$       |
| Решение СЛАУ | $H_k d_k = -g_k$  | $O(d^3)$        |
| <b>Итого</b> |                   | $O(nd^2 + d^3)$ |

При  $d = 10^6$  (типичная нейросеть):

- Гессиан:  $10^{12}$  элементов  $\rightarrow$  **4 ТБ** памяти только для хранения!
- Инверсия:  $10^{18}$  операций  $\rightarrow$  при  $10^{12}$  FLOP/s = **1 000 000 секунд**

**Вывод: Ньютон непрактичен для DL**

Метод Ньютона применим только при  $d \leq 10^3$ – $10^4$  (малые модели, физика, химия).

**Компромисс: квази-ньютоновские методы** — аппроксимируем  $H^{-1}$  без явного вычисления.

## Квази-Ньютоновские методы

## Идея: аппроксимация гессиана

**Ключевой вопрос:** можем ли мы строить хорошую аппроксимацию  $H_k^{-1}$ , используя только градиенты?

## Идея: аппроксимация гессиана

**Ключевой вопрос:** можем ли мы строить хорошую аппроксимацию  $H_k^{-1}$ , используя только градиенты?

**Секантное условие:** из  $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$  следует:

$$B_{k+1}s_k = y_k$$

где  $s_k = x_{k+1} - x_k$ ,  $y_k = g_{k+1} - g_k$ ,  $B_{k+1}$  — аппроксимация  $\nabla^2 f$ .

## Идея: аппроксимация гессиана

**Ключевой вопрос:** можем ли мы строить хорошую аппроксимацию  $H_k^{-1}$ , используя только градиенты?

**Секантное условие:** из  $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$  следует:

$$B_{k+1}s_k = y_k$$

где  $s_k = x_{k+1} - x_k$ ,  $y_k = g_{k+1} - g_k$ ,  $B_{k+1}$  — аппроксимация  $\nabla^2 f$ .

**Идея ранг-2 обновлений:** обновлять матрицу  $C_k = B_k^{-1}$  малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$



## Идея: аппроксимация гессиана

**Ключевой вопрос:** можем ли мы строить хорошую аппроксимацию  $H_k^{-1}$ , используя только градиенты?

**Секантное условие:** из  $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$  следует:

$$B_{k+1} s_k = y_k$$

где  $s_k = x_{k+1} - x_k$ ,  $y_k = g_{k+1} - g_k$ ,  $B_{k+1}$  — аппроксимация  $\nabla^2 f$ .

**Идея ранг-2 обновлений:** обновлять матрицу  $C_k = B_k^{-1}$  малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$

**BFGS-обновление** (Broyden–Fletcher–Goldfarb–Shanno, 1970):

$$C_{k+1} = (I - \rho_k s_k y_k^T) C_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

где  $\rho_k = \frac{1}{y_k^T s_k}$ .

## Идея: аппроксимация гессиана

**Ключевой вопрос:** можем ли мы строить хорошую аппроксимацию  $H_k^{-1}$ , используя только градиенты?

**Секантное условие:** из  $g(x_{k+1}) - g(x_k) \approx H(x_{k+1} - x_k)$  следует:

$$B_{k+1} s_k = y_k$$

где  $s_k = x_{k+1} - x_k$ ,  $y_k = g_{k+1} - g_k$ ,  $B_{k+1}$  — аппроксимация  $\nabla^2 f$ .

**Идея ранг-2 обновлений:** обновлять матрицу  $C_k = B_k^{-1}$  малоранговой добавкой:

$$C_{k+1} = C_k + \text{ранг-2 коррекция}(s_k, y_k)$$

**BFGS-обновление** (Broyden–Fletcher–Goldfarb–Shanno, 1970):

$$C_{k+1} = (I - \rho_k s_k y_k^T) C_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

где  $\rho_k = \frac{1}{y_k^T s_k}$ .

**Условие корректности**

Необходимо  $y_k^T s_k > 0$  — обеспечивается **условием Вольфа** в line search.

# Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага  $\alpha_k$ ):

# Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага  $\alpha_k$ ):

1. Достаточное убывание (Армихо):  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$

# Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага  $\alpha_k$ ):

1. Достаточное убывание (Армихо):  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$

# Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага  $\alpha_k$ ):

1. **Достаточное убывание (Армихо):**  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:**  $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

# Условие Вольфа и сходимость BFGS

Условие Вольфа (для выбора шага  $\alpha_k$ ):

1. **Достаточное убывание (Армихо):**  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:**  $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

# Условие Вольфа и сходимость BFGS

**Условие Вольфа** (для выбора шага  $\alpha_k$ ):

1. **Достаточное убывание (Армихо):**  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:**  $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует  $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$ .  $\boxtimes$



# Условие Вольфа и сходимость BFGS

**Условие Вольфа** (для выбора шага  $\alpha_k$ ):

1. **Достаточное убывание (Армихо):**  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:**  $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует  $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$ .  $\boxtimes$

**Теорема (суперлинейная сходимость BFGS):** если  $x_0$  достаточно близко к  $x^*$ ,  $f$  сильно выпуклая с Липшицевым гессианом, то:

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0 \quad (k \rightarrow \infty)$$

# Условие Вольфа и сходимость BFGS

**Условие Вольфа** (для выбора шага  $\alpha_k$ ):

1. **Достаточное убывание (Армихо):**  $f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \langle g_k, d_k \rangle$
2. **Условие кривизны:**  $\langle g(x_k + \alpha_k d_k), d_k \rangle \geq c_2 \langle g_k, d_k \rangle$

Из условия кривизны следует  $y_k^T s_k = (g_{k+1} - g_k)^T \alpha_k d_k \geq (c_2 - 1) \alpha_k \|g_k\|^2 > 0$ .  $\boxtimes$

**Теорема (суперлинейная сходимость BFGS):** если  $x_0$  достаточно близко к  $x^*$ ,  $f$  сильно выпуклая с Липшицевым гессианом, то:

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0 \quad (k \rightarrow \infty)$$

## Интерпретация

Суперлинейная — это больше линейной, но меньше квадратичной.

На практике: BFGS сходится быстрее GD и почти так же быстро, как Newton!

# Стоимость BFGS

Анализ стоимости BFGS:

# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

## Сравнение с Ньютоном:

- Ньютон:  $O(d^3)$  за итерацию (инверсия гессиана)

# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

## Сравнение с Ньютоном:

- Ньютон:  $O(d^3)$  за итерацию (инверсия гессиана)
- BFGS:  $O(d^2)$  за итерацию — **на порядок быстрее!**

# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

## Сравнение с Ньютоном:

- Ньютон:  $O(d^3)$  за итерацию (инверсия гессиана)
- BFGS:  $O(d^2)$  за итерацию — **на порядок быстрее!**

# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

## Сравнение с Ньютоном:

- Ньютон:  $O(d^3)$  за итерацию (инверсия гессиана)
- BFGS:  $O(d^2)$  за итерацию — **на порядок быстрее!**

Но при  $d = 10^5$ : хранение  $C_k = 10^{10}$  элементов = **80 ГБ** — всё ещё слишком много.



# Стоимость BFGS

## Анализ стоимости BFGS:

| Шаг                           | Стоимость |
|-------------------------------|-----------|
| Градиент $g_{k+1}$            | $O(nd)$   |
| Обновление $C_{k+1}$ (ранг-2) | $O(d^2)$  |
| Умножение $C_{k+1}g_{k+1}$    | $O(d^2)$  |
| Хранение $C_k$                | $O(d^2)$  |

## Сравнение с Ньютоном:

- Ньютон:  $O(d^3)$  за итерацию (инверсия гессиана)
- BFGS:  $O(d^2)$  за итерацию — **на порядок быстрее!**

Но при  $d = 10^5$ : хранение  $C_k = 10^{10}$  элементов = **80 ГБ** — всё ещё слишком много.

## Ограничение BFGS

BFGS практичен при  $d \leq 10^4$ . Для больших задач нужен **L-BFGS**.

## L-BFGS

## L-BFGS: Limited Memory BFGS

**Ключевая идея:** не хранить всю матрицу  $C_k \in \mathbb{R}^{d \times d}$ , а только последние  $m$  пар  $(s_j, y_j)$ .

## L-BFGS: Limited Memory BFGS

**Ключевая идея:** не хранить всю матрицу  $C_k \in \mathbb{R}^{d \times d}$ , а только последние  $m$  пар  $(s_j, y_j)$ .

**L-BFGS** (Liu & Nocedal, 1989): - Хранить:  $m$  пар  $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$  - Типичное  $m$ : 5–20 (независимо от  $d$ !) - Память:  $O(md)$  вместо  $O(d^2)$

## L-BFGS: Limited Memory BFGS

**Ключевая идея:** не хранить всю матрицу  $C_k \in \mathbb{R}^{d \times d}$ , а только последние  $m$  пар  $(s_j, y_j)$ .

**L-BFGS** (Liu & Nocedal, 1989): - Хранить:  $m$  пар  $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$  - Типичное  $m$ : 5–20 (независимо от  $d$ !) - Память:  $O(md)$  вместо  $O(d^2)$

**Вычисление  $C_k g_k$  без явной матрицы** — через двухпетлевую рекуррентность:

Вход:  $g_k$ , пары  $\{(s_j, y_j)\}$ , скаляры  $\rho_j = 1/(y_j^T s_j)$

```
q = g_k
for i = k-1, k-2, ..., k-m:           # Первая петля (назад)
     $\alpha_i = \rho_i * s_i^T q$ 
     $q = q - \alpha_i * y_i$ 

r = H_0 * q                           # Начальное приближение (диагональ)

for i = k-m, k-m+1, ..., k-1:         # Вторая петля (вперёд)
     $\beta_i = \rho_i * y_i^T r$ 
     $r = r + (\alpha_i - \beta_i) * s_i$ 

return r    ← это H_k g_k
```

## L-BFGS: Limited Memory BFGS

**Ключевая идея:** не хранить всю матрицу  $C_k \in \mathbb{R}^{d \times d}$ , а только последние  $m$  пар  $(s_j, y_j)$ .

**L-BFGS** (Liu & Nocedal, 1989): - Хранить:  $m$  пар  $\{(s_{k-m}, y_{k-m}), \dots, (s_{k-1}, y_{k-1})\}$  - Типичное  $m$ : 5–20 (независимо от  $d$ !) - Память:  $O(md)$  вместо  $O(d^2)$

**Вычисление  $C_k g_k$  без явной матрицы** — через двухпетлевую рекуррентность:

Вход:  $g_k$ , пары  $\{(s_j, y_j)\}$ , скаляры  $\rho_j = 1/(y_j^T s_j)$

```
q = g_k
for i = k-1, k-2, ..., k-m:          # Первая петля (назад)
     $\alpha_i = \rho_i * s_i^T q$ 
     $q = q - \alpha_i * y_i$ 

r = H_0 * q                          # Начальное приближение (диагональ)

for i = k-m, k-m+1, ..., k-1:      # Вторая петля (вперёд)
     $\beta_i = \rho_i * y_i^T r$ 
     $r = r + (\alpha_i - \beta_i) * s_i$ 

return r    ← это H_k g_k
```

**Стоимость:**  $O(md)$  — не зависит от  $d^2$ !

# Детали L-BFGS

Начальное приближение  $H_0$ :

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.



## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом  $y_k^T s_k$ ):

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом  $y_k^T s_k$ ):

Если  $\rho_k = 1/(y_k^T s_k)$  слишком велико — пропускаем пару  $(s_k, y_k)$ .

## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом  $y_k^T s_k$ ):

Если  $\rho_k = 1/(y_k^T s_k)$  слишком велико — пропускаем пару  $(s_k, y_k)$ .

Сходимость L-BFGS: линейная (хуже суперлинейной для полного BFGS):

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{c}{m}\right) (f(x_k) - f^*)$$



## Детали L-BFGS

Начальное приближение  $H_0$ :

Обычно берут  $H_0 = \gamma_k I$ , где  $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$  — масштаб последнего обновления.

Выбор  $m$ :

- $m = 5$ : быстро, хватает для большинства задач
- $m = 20$ : лучше аппроксимация, чуть медленнее
- $m = d$ : эквивалентно BFGS (но тогда теряем смысл)

Граничные случаи (обновление при малом  $y_k^T s_k$ ):

Если  $\rho_k = 1/(y_k^T s_k)$  слишком велико — пропускаем пару  $(s_k, y_k)$ .

Сходимость L-BFGS: линейная (хуже суперлинейной для полного BFGS):

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{c}{m}\right) (f(x_k) - f^*)$$

## Практическое использование

PyTorch: `torch.optim.LBFGS`. Scikit-learn: `solver='lbfgs'` для LogReg, MLP.

## Сравнение и применение

# Полная таблица методов оптимизации

| Метод         | Стоимость/итер      | Сходимость                | Память   | Применение                   |
|---------------|---------------------|---------------------------|----------|------------------------------|
| GD            | $O(nd)$             | Линейная                  | $O(d)$   | Большой $n$ , простые задачи |
| AGD           | $O(nd)$             | $O(e^{-k/\sqrt{\kappa}})$ | $O(d)$   | Выпуклая, нет шума           |
| SGD           | $O(d)$              | $O(1/\sqrt{k})$           | $O(d)$   | DL, $n \rightarrow \infty$   |
| SVRG          | $O((n + \kappa)d)$  | Линейная                  | $O(d)$   | Конечные суммы               |
| ADMM          | $O(\text{subprob})$ | Линейная                  | $O(d)$   | Разделимая структура         |
| FW            | $O(nd + \text{LP})$ | $O(1/k)$                  | $O(d)$   | Полигон/шар                  |
| <b>Newton</b> | $O(nd^2 + d^3)$     | <b>Квадратичная</b>       | $O(d^2)$ | $d \leq 10^3$                |
| <b>BFGS</b>   | $O(nd + d^2)$       | <b>Суперлинейная</b>      | $O(d^2)$ | $d \leq 10^4$                |
| <b>L-BFGS</b> | $O((n + m)d)$       | Линейная                  | $O(md)$  | $d \leq 10^6$ , пакетный     |
| Adam          | $O(nd)$             | Адаптивная<br>(эмпир.)    | $O(d)$   | DL, sparse gradients         |

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

☒ Физика/химия (моделирование молекул, МКЭ)

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$



## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

**L-BFGS:**  $10^4 \leq d \leq 10^6$

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

**L-BFGS:**  $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

**L-BFGS:**  $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

**L-BFGS:**  $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)
- ☒ Физика+ML: neural operators, PINNs

## Когда использовать методы второго порядка

**Newton:**  $d \leq 10^3$

- ☒ Физика/химия (моделирование молекул, МКЭ)
- ☒ Малые нейросети (логистическая регрессия, SVM)
- ☒ Когда нужна квадратичная точность (счёт до  $10^{-15}$ )

**BFGS:**  $10^3 \leq d \leq 10^4$

- ☒ Нелинейные МНК, оптимизация в физике
- ☒ Scikit-learn: solver='lbfgs' для LogReg при  $d \leq 10^4$

**L-BFGS:**  $10^4 \leq d \leq 10^6$

- ☒ `torch.optim.LBFGS` — точная настройка нейросетей (fine-tuning)
- ☒ Языковые модели малого размера (GPT-small)
- ☒ Физика+ML: neural operators, PINNs
- ☒ **Не используйте методы 2-го порядка для:** SGD-режима (стохастический шум ломает аппроксимацию гессиана), очень больших нейросетей ( $d > 10^8$ ).

## Связь с современными методами (K-FAC, Shampoo, Muon)

**Практическая проблема:** Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?



## Связь с современными методами (K-FAC, Shampoo, Muon)

**Практическая проблема:** Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

**Ответ:** Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через  $m$  пар).

## Связь с современными методами (K-FAC, Shampoo, Muon)

**Практическая проблема:** Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

**Ответ:** Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через  $m$  пар).

**Современные «second-order» методы для DL:**

## Связь с современными методами (K-FAC, Shampoo, Muon)

**Практическая проблема:** Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

**Ответ:** Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через  $m$  пар).

**Современные «second-order» методы для DL:**

| Метод   | Идея                                           | Применение       |
|---------|------------------------------------------------|------------------|
| K-FAC   | Кронекерова факторизация гессиана              | CNN, Transformer |
| Shampoo | Предобусловливание по Кронекерову произведению | Google TPU       |
| Muon    | Momentum + ортогонализация (☒ Ньютон)          | GPT-2, Gemma     |
| Sophia  | Scalable second-order                          | LLM pretraining  |

## Связь с современными методами (K-FAC, Shampoo, Muon)

**Практическая проблема:** Adam работает хорошо, но зачем L-BFGS, если Adam тоже «адаптивный»?

**Ответ:** Adam адаптирует только **диагональ** (покоординатно), L-BFGS — **полную матрицу** (через  $m$  пар).

**Современные «second-order» методы для DL:**

| Метод   | Идея                                           | Применение       |
|---------|------------------------------------------------|------------------|
| K-FAC   | Кронекерова факторизация гессiana              | CNN, Transformer |
| Shampoo | Предобусловливание по Кронекерову произведению | Google TPU       |
| Muon    | Momentum + ортогонализация (☒ Ньютон)          | GPT-2, Gemma     |
| Sophia  | Scalable second-order                          | LLM pretraining  |

## Связь с PhD Даниила

BFGS аппроксимирует гессиан через секантные пары  $(s_k, y_k)$  — форма **накопленного расщепления** информации о кривизне.

IMEX-RK методы занимают промежуточное место между явным (GD) и неявным (Newton).

Итоги

# Резюме лекции

Сегодня изучили:

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?



# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$



# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$
6. **L-BFGS:**  $m$  пар + двухпетлевая рекуррентность  $\rightarrow O(md)$ , применимо до  $d = 10^6$

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$
6. **L-BFGS:**  $m$  пар + двухпетлевая рекуррентность  $\rightarrow O(md)$ , применимо до  $d = 10^6$

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$
6. **L-BFGS:**  $m$  пар + двухпетлевая рекуррентность  $\rightarrow O(md)$ , применимо до  $d = 10^6$
7. **Таблица методов:** выбор зависит от  $d$ , структуры задачи, нужной точности

# Резюме лекции

Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$
6. **L-BFGS:**  $m$  пар + двухпетлевая рекуррентность  $\rightarrow O(md)$ , применимо до  $d = 10^6$
7. **Таблица методов:** выбор зависит от  $d$ , структуры задачи, нужной точности

# Резюме лекции

## Сегодня изучили:

1. **Мотивация:** методы 1-го порядка зависят от  $\kappa$  — можем ли сделать лучше?
2. **Метод Ньютона:** квадратичная аппроксимация  $\rightarrow O(\log \log(1/\varepsilon))$  итераций, но  $O(d^3)$  дорого
3. **Ньютоновский декремент**  $\lambda(x)$ : аффинно-инвариантный критерий остановки и оценка субоптимальности
4. **Квадратичная сходимость:**  $e_{k+1} \leq \frac{M}{2\mu} e_k^2$  — удвоение верных цифр
5. **BFGS:** секантное условие + ранг-2 обновление  $\rightarrow$  суперлинейная сходимость при  $O(d^2)$
6. **L-BFGS:**  $m$  пар + двухпетлевая рекуррентность  $\rightarrow O(md)$ , применимо до  $d = 10^6$
7. **Таблица методов:** выбор зависит от  $d$ , структуры задачи, нужной точности

**Следующая лекция (#16):** Невыпуклая оптимизация — как методы работают за пределами выпуклого случая, седловые точки, PL-условие.