




Методы редукции дисперсии: SAG, SVRG,
SAGA. Адаптивные стохастические
градиентные методы.

Даня Меркулов

ФКН ВШЭ

Итог: что мы изучили

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

Три ключевых вопроса:

1. **Существование:** есть ли решение?

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

Три ключевых вопроса:

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

Три ключевых вопроса:

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

Три ключевых вопроса:

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

18 лекций — один курс

Цель курса: научиться решать задачи вида $\min_{x \in \mathcal{X}} f(x)$ для задач ML.

Три ключевых вопроса:

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

Главная идея курса

Правильный алгоритм = правильное использование структуры задачи.

Структура курса одним слайдом

Блок	Лекции	Тема
Основы	1–4	Линал, выпуклость, условия оптимальности, GD
Ускорение	5–8	Конъюгатные градиенты, AGD, Нестеров, FISTA
Стохастика	9–10	SGD, мини-батч, variance reduction
Специализация	11–14	CD, ADMM, PDHG, Frank-Wolfe
Второй порядок	15	Newton, BFGS, L-BFGS
Расширения	16–17	Невыпуклость, PL, FedAvg, FL
Синтез	18	Дерево выбора, frontier

Таксономия задач

Три измерения любой задачи оптимизации

Измерение 1 — Структура f :

Свойство	Параметр	Что даёт
L -гладкость	L	Шаг $t \leq 1/L$, GD работает
μ -сил. выпуклость	μ	Линейная сходимость
Сильно выпуклая + гладкая	$\kappa = L/\mu$	Скорость $(1 - 1/\kappa)^k$
Стохастический градиент	σ^2	Шумовой пол $O(\sigma^2/k)$

Три измерения любой задачи оптимизации

Измерение 1 — Структура f :

Свойство	Параметр	Что даёт
L -гладкость	L	Шаг $t \leq 1/L$, GD работает
μ -сил. выпуклость	μ	Линейная сходимость
Сильно выпуклая + гладкая	$\kappa = L/\mu$	Скорость $(1 - 1/\kappa)^k$
Стохастический градиент	σ^2	Шумовой пол $O(\sigma^2/k)$

Измерение 2 — Ограничения: нет / $x \in C$ (проекция) / $Ax = b$ / составная $f + g$

Измерение 3 — Масштаб: размер n , размерность d , агентов N

Как выбрать алгоритм: дерево решений

Задача $\min f(x)$:

- f негладкая? → субградиент / ISTA (если есть прокс)
- f гладкая →
 - Составная $f + g(Kx)$? → PDHG / ADMM [Л12-13]
 - Ограниченная C , LP дешёв? → Frank-Wolfe [Л14]
 - Маленький d (≤ 10)? → L-BFGS / Newton [Л15]
 - Большой n , стохастика →
 - Памяти много → SVRG / SAGA [Л10]
 - Памяти мало → SGD + cosine [Л9]
 - Распределённая →
 - IID → FedAvg [Л17]
 - non-IID → SCAFFOLD [Л17]
 - Приватность → DP-SGD [Л17]
 - Невыпуклая →
 - PL-условие → GD (линейная сходимость!) [Л16]
 - Сёдла → Perturbed GD [Л16]

Мегатаблица методов

Все алгоритмы курса — часть I

Задача	Алгоритм	Скорость
$\min f$, выпуклая, L -гл.	GD	$O(1/k)$
$\min f$, с.в., L -гл.	GD	$O(e^{-k/\kappa})$
$\min f$, с.в., L -гл.	AGD (Нестеров)	$O(e^{-k/\sqrt{\kappa}})$
$\min f + g$, прокс g	ISTA	$O(1/k)$
$\min f + g$, прокс g , с.в.	FISTA	$O(1/k^2)$
Стохастический ∇f	SGD	$O(\sigma/\sqrt{k})$
Большой n , с.в.	SVRG / SAGA	$O(e^{-k(1-1/n\kappa)})$

Все алгоритмы курса — часть II

Задача	Алгоритм	Скорость
Разрежённый x	RCD	$O(e^{-\mu k/dL})$
$\min f + g(Kx)$	PDHG	$O(1/k)$ при $\tau\sigma\ K\ ^2 \leq 1$
$\min f + g$ (двойст.)	ADMM	$O(1/k)$
$x \in C$, LP oracle	Frank-Wolfe	$O(LD^2/k)$
Мал. d , второй порядок	Newton	Квадратичная
Мал. d , памяти нет	L-BFGS	Суперлинейная
Невыпуклая	GD	$O(1/\sqrt{k})$ нормы ∇f
PL-условие	GD	$O(e^{-\mu k/L})$ к глоб. оптим.
Распред., IID	FedAvg	$O(1/\sqrt{NK\tau})$

Нижние оценки: быстрее нельзя

Теорема Немировского-Юдина (1983): для гладкой выпуклой f любой алгоритм, использующий k градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

Нижние оценки: быстрее нельзя

Теорема Немировского-Юдина (1983): для гладкой выпуклой f любой алгоритм, использующий k градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

AGD = оптимален: скорость $O(1/k^2)$ достигается!

Нижние оценки: быстрее нельзя

Теорема Немировского-Юдина (1983): для гладкой выпуклой f любой алгоритм, использующий k градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

AGD = оптимален: скорость $O(1/k^2)$ достигается!

Класс задач	Нижняя оценка	Достигается
Выпуклая, L -гл.	$\Omega(1/k^2)$	AGD ☒
С.в. μ , L -гл.	$\Omega(e^{-k/\sqrt{\kappa}})$	AGD ☒
Стохастическая	$\Omega(\sigma/\sqrt{k})$	SGD ☒
Конечная сумма	$\Omega(e^{-k\mu/(L+n\mu)})$	SVRG ☒

Связь всего со всем

Оператор расщепления — единый взгляд

Ключевая идея: большинство методов — это **численная дискретизация ODE** через оператор расщепления.

Оператор расщепления — единый взгляд

Ключевая идея: большинство методов — это **численная дискретизация ODE** через оператор расщепления.

Метод	Расщепление
GD	Ли-Троттер: $e^{(A_f+A_R)h} \approx e^{A_f h} e^{A_R h}$
ISTA	Ли-Троттер: $\text{prox}_g \boxtimes \text{implicit } A_R + \nabla f \boxtimes \text{explicit } A_f$
AGD	Двойная ODE: Heavy Ball + Нестеровский момент
ADMM / DRS	Douglas-Rachford в двойственном пространстве
PDHG	Прямо-двойственное расщепление
FedAvg	ADMM consensus = расщепление по агентам

Оператор расщепления — единый взгляд

Ключевая идея: большинство методов — это **численная дискретизация ODE** через оператор расщепления.

Метод	Расщепление
GD	Ли-Троттер: $e^{(A_f+A_R)h} \approx e^{A_f h} e^{A_R h}$
ISTA	Ли-Троттер: $\text{prox}_g \boxtimes \text{implicit } A_R + \nabla f \boxtimes \text{explicit } A_f$
AGD	Двойная ODE: Heavy Ball + Нестеровский момент
ADMM / DRS	Douglas-Rachford в двойственном пространстве
PDHG	Прямо-двойственное расщепление
FedAvg	ADMM consensus = расщепление по агентам

Тема диссертации Даниила

Strang splitting (2-й порядок) для ISTA/Ridge регрессии: сходится в $\sqrt{\kappa}$ раз быстрее Ли-Троттера. Подано в ЖВММФ.

Связи между методами

ADMM = DRS (Douglas-Rachford Splitting):

ADMM для $\min f(x) + g(z), Ax + Bz = c \iff$ DRS в двойственном пространстве

Связи между методами

ADMM = DRS (Douglas-Rachford Splitting):

ADMM для $\min f(x) + g(z), Ax + Bz = c \iff$ DRS в двойственном пространстве

FISTA = AGD + Proximal:

$$x_{k+1} = \text{prox}_{tg}(y_k - t\nabla f(y_k)), \quad y_{k+1} = x_{k+1} + \frac{k-1}{k+2}(x_{k+1} - x_k)$$

Связи между методами

ADMM = DRS (Douglas-Rachford Splitting):

ADMM для $\min f(x) + g(z), Ax + Bz = c \iff$ DRS в двойственном пространстве

FISTA = AGD + Proximal:

$$x_{k+1} = \text{prox}_{tg}(y_k - t\nabla f(y_k)), \quad y_{k+1} = x_{k+1} + \frac{k-1}{k+2}(x_{k+1} - x_k)$$

FedAvg $\boxtimes$ **local SGD** $\boxtimes$ **ADMM consensus:**

$$\min \frac{1}{N} \sum_{i=1}^N f_i(w) \iff \min \sum_i f_i(w_i) \text{ s.t. } w_i = w$$

Современные направления

Frontier: стохастические методы второго порядка

Проблема: Hessian $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$ память, $O(d^3)$ инверсия. Недопустимо для LLM ($d \sim 10^9$).

Frontier: стохастические методы второго порядка

Проблема: Hessian $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$ память, $O(d^3)$ инверсия. Недопустимо для LLM ($d \sim 10^9$).

Решения:

Метод	Идея	Стоимость
L-BFGS	m последних градиентов	$O(md)$
K-FAC	$H \approx A \otimes G$ (блочная)	$O(d^{1.5})$
Shampoo	Блочный L-BFGS для тензоров	$O(d^{1.5})$
SOAP	Shampoo + Adam в одном	$O(d^{1.5})$
Muon	Nesterov + матричная форма	$O(d \log d)$

Frontier: стохастические методы второго порядка

Проблема: Hessian $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$ память, $O(d^3)$ инверсия. Недопустимо для LLM ($d \sim 10^9$).

Решения:

Метод	Идея	Стоимость
L-BFGS	m последних градиентов	$O(md)$
K-FAC	$H \approx A \otimes G$ (блочная)	$O(d^{1.5})$
Shampoo	Блочный L-BFGS для тензоров	$O(d^{1.5})$
SOAP	Shampoo + Adam в одном	$O(d^{1.5})$
Muon	Nesterov + матричная форма	$O(d \log d)$

Shampoo и K-FAC используются в продакшене (Google, Meta).

Frontier: Adam и трансформеры

Adam не имеет строгой теоремы для невыпуклых стохастических задач (открытая проблема!).

Frontier: Adam и трансформеры

Adam не имеет строгой теоремы для невыпуклых стохастических задач (открытая проблема!).

Что известно: - Adam с gradient clipping сходится (Zhang et al., 2020) - «Implicit bias» Adam $\neq$ implicit bias GD
→ разная генерализация - AdamW = Adam + weight decay (без decay на LayerNorm и biases)

Frontier: Adam и трансформеры

Adam не имеет строгой теоремы для невыпуклых стохастических задач (открытая проблема!).

Что известно: - Adam с gradient clipping сходится (Zhang et al., 2020) - «Implicit bias» Adam $\neq$ implicit bias GD
→ разная генерализация - AdamW = Adam + weight decay (без decay на LayerNorm и biases)

Muon (Kosson & Brendan, 2025) — state-of-art для трансформеров:

$$G_t = \text{Nesterov}(\nabla \mathcal{L}_t), \quad \Delta W = \frac{G_t}{\|G_t\|_F}$$

Нормировка по фробениусовой норме = implicit matrix conditioning.

Frontier: генеративные модели и оптимизация

Diffusion models = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

Frontier: генеративные модели и оптимизация

Diffusion models = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

RLHF = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика π . Внутренняя: reward model r_ϕ .

Frontier: генеративные модели и оптимизация

Diffusion models = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

RLHF = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика π . Внутренняя: reward model r_ϕ .

GAN = min-max (седловая задача):

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

Frontier: генеративные модели и оптимизация

Diffusion models = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

RLHF = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика π . Внутренняя: reward model r_ϕ .

GAN = min-max (седловая задача):

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

Открытые вопросы: сходимость GAN (нет гарантий!), оптимальный schedule для RLHF, масштабирование Diffusion.

Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.

Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)

Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?

Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?
4. **Невыпуклость + PL:** когда PL выполняется для NN на практике? Связь с NTK?

Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?
4. **Невыпуклость + PL:** когда PL выполняется для NN на практике? Связь с NTK?
5. **Privacy-utility-communication trilemma:** нет единого оптимального решения для FL.

Подготовка к экзамену

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):** $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):** $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:** $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):** $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:** $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL $\rightarrow$ линейная сходимость:** $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):** $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:** $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL $\rightarrow$ линейная сходимость:** $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$
6. **Frank-Wolfe:** $f(x_k) - f^* \leq \frac{2LD^2}{k+2}$, где $D = \text{diam}(\mathcal{X})$

7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:** $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:** $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):** $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:** $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL $\rightarrow$ линейная сходимость:** $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$
6. **Frank-Wolfe:** $f(x_k) - f^* \leq \frac{2LD^2}{k+2}$, где $D = \text{diam}(\mathcal{X})$
7. **PDHG:** сходится при $\tau\sigma\|K\|^2 \leq 1$

Типичные экзаменационные задачи

Тип 1 — Доказательство: - Докажите нижнюю оценку $\Omega(1/k^2)$ для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

Типичные экзаменационные задачи

Тип 1 — Доказательство: - Докажите нижнюю оценку $\Omega(1/k^2)$ для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

Тип 2 — Вычисление: - Запишите двойственную задачу для LASSO / SVM - Вычислите $\text{prox}_{\lambda\|x\|_1}(v)$ и $\text{prox}_{\lambda\|x\|_2}(v)$ - Найдите оптимальный шаг для Ridge regression

Типичные экзаменационные задачи

Тип 1 — Доказательство: - Докажите нижнюю оценку $\Omega(1/k^2)$ для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

Тип 2 — Вычисление: - Запишите двойственную задачу для LASSO / SVM - Вычислите $\text{prox}_{\lambda\|x\|_1}(v)$ и $\text{prox}_{\lambda\|x\|_2}(v)$ - Найдите оптимальный шаг для Ridge regression

Тип 3 — Выбор алгоритма: - «Дана задача X с параметрами Y — какой метод, какая скорость?» - «Сравните SGD и SVRG для задачи с $n = 10^6$, $\kappa = 100$ »

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

Советы к экзамену

Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:** ℓ_1 , ℓ_2 , индикатор C , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

Главный совет

Найдите ****условия**** теорем, не только результаты. Экзаменатор проверит именно их.

Заключение

Что дальше после курса

Для практиков (ML-инженеры): - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

Что дальше после курса

Для практиков (ML-инженеры): - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

Для исследователей: - Нижние оценки (Nesterov lower bound framework) - Operator splitting для составных задач - Stochastic variance reduction (SVRG, SARAH, SPIDER)

Что дальше после курса

Для практиков (ML-инженеры): - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

Для исследователей: - Нижние оценки (Nesterov lower bound framework) - Operator splitting для составных задач - Stochastic variance reduction (SVRG, SARAH, SPIDER)

Для теоретиков: - Convergence Adam — открытая задача - Non-convex optimization за пределами PL - Optimal FL communication complexity

Оптимизация как профессия

Журналы: JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

Оптимизация как профессия

Журналы: JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

Конференции: NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

Оптимизация как профессия

Журналы: JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

Конференции: NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

Ключевые исследовательские группы: Nesterov (Louvain), Jordan (Berkeley), Sra (MIT), Richtárik (KAUST), Dvurechensky (Berlin), Меркулов (AI4Science Сбеа)

Оптимизация как профессия

Журналы: JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖБММФ (БАК)

Конференции: NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

Ключевые исследовательские группы: Nesterov (Louvain), Jordan (Berkeley), Sra (MIT), Richtárik (KAUST), Dvurechensky (Berlin), Меркулов (AI4Science Сбера)

Курс закончен — оптимизация продолжается!

Оптимизация = фундамент современного ML. Всё, что обучается, оптимизируется. Всё, что оптимизируется — требует теории.

Спасибо за курс!

Удачи на экзамене!

Материалы курса: `hse26.fmin.xyz`

Вопросы после экзамена: Telegram @bratishk

«An algorithm must be seen to be believed.»

— Donald Knuth