



Методы редукции дисперсии: SAG, SVRG,
SAGA. Адаптивные стохастические
градиентные методы.

Даня Меркулов

ФКН ВШЭ

Напоминание: задача минимизации конечной суммы

От градиентного спуска к стохастическому

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x_k) \quad (\text{GD})$$

- Стоимость итерации линейна по n .

От градиентного спуска к стохастическому

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x_k) \quad (\text{GD})$$

- Стоимость итерации линейна по n .

От градиентного спуска к стохастическому

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x_k) \quad (\text{GD})$$

- Стоимость итерации линейна по n .

Стохастический градиентный спуск — несмещённая оценка градиента по случайному индексу $i_k \sim \text{U}\{1, \dots, n\}$:

$$x_{k+1} = x_k - \alpha_k \nabla f_{i_k}(x_k), \quad \mathbb{E}[\nabla f_{i_k}(x)] = \nabla f(x) \quad (\text{SGD})$$

Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.

Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.
- Сублинейная скорость даже в сильно выпуклом случае.

Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.
- Сублинейная скорость даже в сильно выпуклом случае.
- Оценки неулучшаемы при стандартных предположениях.

Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.
- Сублинейная скорость даже в сильно выпуклом случае.
- Оценки неулучшаемы при стандартных предположениях.

Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.
- Сублинейная скорость даже в сильно выпуклом случае.
- Оценки неулучшаемы при стандартных предположениях.
- Методы с моментом и квазиньютоновские методы **не улучшают скорость** в стохастическом случае — узким местом становится дисперсия, а не число обусловленности.


Сравнение GD и SGD: что мы знаем

Если ∇f — L -липшицев, то:

Предположение	Градиентный спуск	Стохастический ГС
PL	$O(\log(1/\varepsilon))$	$O(1/\varepsilon)$
Выпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$
Невыпуклая	$O(1/\varepsilon)$	$O(1/\varepsilon^2)$

- **SGD** — дешёвая итерация $O(1)$, но медленная сублинейная сходимость.
- Сублинейная скорость даже в сильно выпуклом случае.
- Оценки неулучшаемы при стандартных предположениях.
- Методы с моментом и квазиньютоновские методы **не улучшают скорость** в стохастическом случае — узким местом становится дисперсия, а не число обусловленности.
- **Вопрос лекции:** можно ли получить **линейную** скорость, как у GD, при стоимости итерации, как у SGD?


SGD с постоянным шагом не сходится



Основная проблема SGD

$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{n} \sum_{i=1}^n \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^p}$$

Strongly convex binary logistic regression. $m=200$, $n=10$, $\mu=1$.



Методы редукции дисперсии

Дисперсия мини-батч градиента: с возвращением

Обозначим $\sigma^2 = \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x_k) - \nabla f(x_k)\|^2$ — дисперсия индивидуальных градиентов.

Схема с возвращением (sampling with replacement): индексы $i_1, \dots, i_B$ выбираются независимо и равномерно из $\{1, \dots, n\}$ (могут повторяться).

$$g^k = \frac{1}{B} \sum_{j=1}^B \nabla f_{i_j}(x_k)$$

Дисперсия мини-батч градиента: с возвращением

Обозначим $\sigma^2 = \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x_k) - \nabla f(x_k)\|^2$ — дисперсия индивидуальных градиентов.

Схема с возвращением (sampling with replacement): индексы $i_1, \dots, i_B$ выбираются независимо и равномерно из $\{1, \dots, n\}$ (могут повторяться).

$$g^k = \frac{1}{B} \sum_{j=1}^B \nabla f_{i_j}(x_k)$$

Поскольку индексы i_j независимы и одинаково распределены, слагаемые $\nabla f_{i_j}(x_k)$ — также независимые одинаково распределённые случайные величины. Дисперсия среднего из B независимых величин:

$$\mathbb{E} \left[\|g^k - \nabla f(x_k)\|^2 \right] = \frac{1}{B^2} \sum_{j=1}^B \mathbb{E} \left[\|\nabla f_{i_j}(x_k) - \nabla f(x_k)\|^2 \right] = \frac{\sigma^2}{B}$$

Дисперсия мини-батч градиента: без возвращения (постановка)

Схема без возвращения (sampling without replacement): батч $\mathcal{B}_k$ — равномерно случайное подмножество размера B из $\{1, \dots, n\}$ (без повторов).

$$g^k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k)$$

Дисперсия мини-батч градиента: без возвращения (постановка)

Схема без возвращения (sampling without replacement): батч $\mathcal{B}_k$ — равномерно случайное подмножество размера B из $\{1, \dots, n\}$ (без повторов).

$$g^k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k)$$

Слагаемые теперь **зависимы**: если знаем, что некоторый индекс уже попал в батч, вероятности для остальных меняются.

Дисперсия мини-батч градиента: без возвращения (постановка)

Схема без возвращения (sampling without replacement): батч $\mathcal{B}_k$ — равномерно случайное подмножество размера B из $\{1, \dots, n\}$ (без повторов).

$$g^k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k)$$

Слагаемые теперь **зависимы**: если знаем, что некоторый индекс уже попал в батч, вероятности для остальных меняются.

Введём индикаторы $I_i = [i \in \mathcal{B}_k]$. Тогда:

- $\mathbb{E}[I_i] = \frac{B}{n},$

Отсюда $\text{Cov}(I_i, I_j) = -\frac{B(n-B)}{n^2(n-1)}$ — отрицательная ковариация, которая и даёт уменьшение дисперсии по сравнению со схемой с возвращением.

Дисперсия мини-батч градиента: без возвращения (постановка)

Схема без возвращения (sampling without replacement): батч $\mathcal{B}_k$ — равномерно случайное подмножество размера B из $\{1, \dots, n\}$ (без повторов).

$$g^k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k)$$

Слагаемые теперь **зависимы**: если знаем, что некоторый индекс уже попал в батч, вероятности для остальных меняются.

Введём индикаторы $I_i = [i \in \mathcal{B}_k]$. Тогда:

- $\mathbb{E}[I_i] = \frac{B}{n},$
- $\mathbb{E}[I_i^2] = \frac{B}{n},$

Отсюда $\text{Cov}(I_i, I_j) = -\frac{B(n-B)}{n^2(n-1)}$ — отрицательная ковариация, которая и даёт уменьшение дисперсии по сравнению со схемой с возвращением.

Дисперсия мини-батч градиента: без возвращения (постановка)

Схема без возвращения (sampling without replacement): батч $\mathcal{B}_k$ — равномерно случайное подмножество размера B из $\{1, \dots, n\}$ (без повторов).

$$g^k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla f_i(x_k)$$

Слагаемые теперь **зависимы**: если знаем, что некоторый индекс уже попал в батч, вероятности для остальных меняются.

Введём индикаторы $I_i = [i \in \mathcal{B}_k]$. Тогда:

- $\mathbb{E}[I_i] = \frac{B}{n}$,
- $\mathbb{E}[I_i^2] = \frac{B}{n}$,
- $\mathbb{E}[I_i I_j] = \frac{B(B-1)}{n(n-1)}$ для $i \neq j$.

Отсюда $\text{Cov}(I_i, I_j) = -\frac{B(n-B)}{n^2(n-1)}$ — отрицательная ковариация, которая и даёт уменьшение дисперсии по сравнению со схемой с возвращением.

Дисперсия мини-батч градиента: без возвращения (вывод)

Обозначим $d_i = \nabla f_i(x_k) - \nabla f(x_k)$. Тогда $\sum_i d_i = 0$ и $\sigma^2 = \frac{1}{n} \sum_i \|d_i\|^2$.

Дисперсия мини-батч градиента: без возвращения (вывод)

Обозначим $d_i = \nabla f_i(x_k) - \nabla f(x_k)$. Тогда $\sum_i d_i = 0$ и $\sigma^2 = \frac{1}{n} \sum_i \|d_i\|^2$.

Перепишем $g^k - \nabla f(x_k)$ через индикаторы I_i , пользуясь тем, что $\sum_i I_i = B$:

$$g^k - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i \nabla f_i(x_k) - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i d_i.$$

Дисперсия мини-батч градиента: без возвращения (вывод)

Обозначим $d_i = \nabla f_i(x_k) - \nabla f(x_k)$. Тогда $\sum_i d_i = 0$ и $\sigma^2 = \frac{1}{n} \sum_i \|d_i\|^2$.

Перепишем $g^k - \nabla f(x_k)$ через индикаторы I_i , пользуясь тем, что $\sum_i I_i = B$:

$$g^k - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i \nabla f_i(x_k) - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i d_i.$$

Берём квадрат нормы и матожидание:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \sum_{i,j} \mathbb{E}[I_i I_j] \langle d_i, d_j \rangle.$$

Дисперсия мини-батч градиента: без возвращения (вывод)

Обозначим $d_i = \nabla f_i(x_k) - \nabla f(x_k)$. Тогда $\sum_i d_i = 0$ и $\sigma^2 = \frac{1}{n} \sum_i \|d_i\|^2$.

Перепишем $g^k - \nabla f(x_k)$ через индикаторы I_i , пользуясь тем, что $\sum_i I_i = B$:

$$g^k - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i \nabla f_i(x_k) - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i d_i.$$

Берём квадрат нормы и матожидание:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \sum_{i,j} \mathbb{E}[I_i I_j] \langle d_i, d_j \rangle.$$

Подставим моменты индикаторов:

$$= \frac{1}{B^2} \left[\frac{B}{n} \sum_i \|d_i\|^2 + \frac{B(B-1)}{n(n-1)} \sum_{i \neq j} \langle d_i, d_j \rangle \right].$$

Дисперсия мини-батч градиента: без возвращения (вывод)

Обозначим $d_i = \nabla f_i(x_k) - \nabla f(x_k)$. Тогда $\sum_i d_i = 0$ и $\sigma^2 = \frac{1}{n} \sum_i \|d_i\|^2$.

Перепишем $g^k - \nabla f(x_k)$ через индикаторы I_i , пользуясь тем, что $\sum_i I_i = B$:

$$g^k - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i \nabla f_i(x_k) - \nabla f(x_k) = \frac{1}{B} \sum_{i=1}^n I_i d_i.$$

Берём квадрат нормы и матожидание:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \sum_{i,j} \mathbb{E}[I_i I_j] \langle d_i, d_j \rangle.$$

Подставим моменты индикаторов:

$$= \frac{1}{B^2} \left[\frac{B}{n} \sum_i \|d_i\|^2 + \frac{B(B-1)}{n(n-1)} \sum_{i \neq j} \langle d_i, d_j \rangle \right].$$

Из $\sum_i d_i = 0$ следует $\sum_{i \neq j} \langle d_i, d_j \rangle = -\sum_i \|d_i\|^2 = -n\sigma^2$.

Дисперсия мини-батч градиента: без возвращения (результат)

Сворачиваем выражение, помня, что $\sum_i \|d_i\|^2 = n\sigma^2$:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \left[\frac{B}{n} \cdot n\sigma^2 - \frac{B(B-1)}{n(n-1)} \cdot n\sigma^2 \right] = \frac{\sigma^2}{B} \left[1 - \frac{B-1}{n-1} \right].$$

Окончательно:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}.$$

Дисперсия мини-батч градиента: без возвращения (результат)

Сворачиваем выражение, помня, что $\sum_i \|d_i\|^2 = n\sigma^2$:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \left[\frac{B}{n} \cdot n\sigma^2 - \frac{B(B-1)}{n(n-1)} \cdot n\sigma^2 \right] = \frac{\sigma^2}{B} \left[1 - \frac{B-1}{n-1} \right].$$

Окончательно:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}.$$

Множитель $\frac{n-B}{n-1}$ — **поправка на конечность генеральной совокупности** (finite population correction).

Дисперсия мини-батч градиента: без возвращения (результат)

Сворачиваем выражение, помня, что $\sum_i \|d_i\|^2 = n\sigma^2$:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \left[\frac{B}{n} \cdot n\sigma^2 - \frac{B(B-1)}{n(n-1)} \cdot n\sigma^2 \right] = \frac{\sigma^2}{B} \left[1 - \frac{B-1}{n-1} \right].$$

Окончательно:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}.$$

Множитель $\frac{n-B}{n-1}$ — **поправка на конечность генеральной совокупности** (finite population correction).

Что отсюда видно:

- при $B = 1$ — поправка равна 1, обе схемы совпадают (один элемент — нет разницы, с повтором или без);

В частности, для одинакового B схема без возвращения **всегда не хуже** схемы с возвращением.

Дисперсия мини-батч градиента: без возвращения (результат)

Сворачиваем выражение, помня, что $\sum_i \|d_i\|^2 = n\sigma^2$:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \left[\frac{B}{n} \cdot n\sigma^2 - \frac{B(B-1)}{n(n-1)} \cdot n\sigma^2 \right] = \frac{\sigma^2}{B} \left[1 - \frac{B-1}{n-1} \right].$$

Окончательно:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}.$$

Множитель $\frac{n-B}{n-1}$ — **поправка на конечность генеральной совокупности** (finite population correction).

Что отсюда видно:

- при $B = 1$ — поправка равна 1, обе схемы совпадают (один элемент — нет разницы, с повтором или без);
- при $B \ll n$ — поправка ≈ 1 , обе схемы дают почти одинаковую дисперсию σ^2/B ;

В частности, для одинакового B схема без возвращения **всегда не хуже** схемы с возвращением.

Дисперсия мини-батч градиента: без возвращения (результат)

Сворачиваем выражение, помня, что $\sum_i \|d_i\|^2 = n\sigma^2$:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{1}{B^2} \left[\frac{B}{n} \cdot n\sigma^2 - \frac{B(B-1)}{n(n-1)} \cdot n\sigma^2 \right] = \frac{\sigma^2}{B} \left[1 - \frac{B-1}{n-1} \right].$$

Окончательно:

$$\mathbb{E}[\|g^k - \nabla f(x_k)\|^2] = \frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}.$$

Множитель $\frac{n-B}{n-1}$ — **поправка на конечность генеральной совокупности** (finite population correction).

Что отсюда видно:

- при $B = 1$ — поправка равна 1, обе схемы совпадают (один элемент — нет разницы, с повтором или без);
- при $B \ll n$ — поправка ≈ 1 , обе схемы дают почти одинаковую дисперсию σ^2/B ;
- при $B = n$ — поправка 0: батч равен всей выборке, и оценка совпадает с точным градиентом, дисперсия 0.

В частности, для одинакового B схема без возвращения **всегда не хуже** схемы с возвращением.

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.
- Дисперсия с возвращением **не зависит** от n и **точно** равна σ^2/B — независимо от B относительно n .

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.
- Дисперсия с возвращением **не зависит** от n и **точно** равна σ^2/B — независимо от B относительно n .
- Дисперсия убывает как $1/B$: удвоение батча снижает дисперсию вдвое.

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.
- Дисперсия с возвращением **не зависит** от n и **точно** равна σ^2/B — независимо от B относительно n .
- Дисперсия убывает как $1/B$: удвоение батча снижает дисперсию вдвое.
- Но стоимость итерации растёт линейно по B .

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.
- Дисперсия с возвращением **не зависит** от n и **точно** равна σ^2/B — независимо от B относительно n .
- Дисперсия убывает как $1/B$: удвоение батча снижает дисперсию вдвое.
- Но стоимость итерации растёт линейно по B .
- **Дилемма**: маленький батч — дешёвые, но шумные шаги; большой батч — точные, но дорогие.

Сравнение двух схем сэмплирования

	С возвращением	Без возвращения
Дисперсия	$\frac{\sigma^2}{B}$	$\frac{\sigma^2}{B} \cdot \frac{n-B}{n-1}$
$B \ll n$	$\frac{\sigma^2}{B}$	$\approx \frac{\sigma^2}{B}$
$B = n$	$\frac{\sigma^2}{n} > 0$	0 (точный градиент)

- Схема без возвращения **всегда не хуже**: $\frac{n-B}{n-1} \leq 1$.
- Дисперсия с возвращением **не зависит** от n и **точно** равна σ^2/B — независимо от B относительно n .
- Дисперсия убывает как $1/B$: удвоение батча снижает дисперсию вдвое.
- Но стоимость итерации растёт линейно по B .
- **Дилемма**: маленький батч — дешёвые, но шумные шаги; большой батч — точные, но дорогие.
- **Вопрос**: можно ли снизить дисперсию, не увеличивая батч?

Ключевая идея редукции дисперсии: метод контрольной переменной

Идея: снизить дисперсию случайной величины X с помощью другой, **вспомогательной** случайной величины Y , у которой математическое ожидание известно точно. В англоязычной литературе этот приём называют *control variate*; в русской — **метод контрольной переменной**. Рассмотрим новую случайную величину Z_α :

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$

Ключевая идея редукции дисперсии: метод контрольной переменной

Идея: снизить дисперсию случайной величины X с помощью другой, **вспомогательной** случайной величины Y , у которой математическое ожидание известно точно. В англоязычной литературе этот приём называют *control variate*; в русской — **метод контрольной переменной**. Рассмотрим новую случайную величину Z_α :

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2 \text{cov}(X, Y))$

Ключевая идея редукции дисперсии: метод контрольной переменной

Идея: снизить дисперсию случайной величины X с помощью другой, **вспомогательной** случайной величины Y , у которой математическое ожидание известно точно. В англоязычной литературе этот приём называют *control variate*; в русской — **метод контрольной переменной**. Рассмотрим новую случайную величину Z_α :

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: без смещения, $\mathbb{E}[Z_1] = \mathbb{E}[X]$.

Ключевая идея редукции дисперсии: метод контрольной переменной

Идея: снизить дисперсию случайной величины X с помощью другой, **вспомогательной** случайной величины Y , у которой математическое ожидание известно точно. В англоязычной литературе этот приём называют *control variate*; в русской — **метод контрольной переменной**. Рассмотрим новую случайную величину Z_α :

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: без смещения, $\mathbb{E}[Z_1] = \mathbb{E}[X]$.
 - Если $\alpha < 1$: возможно смещение (но меньше дисперсия).

Ключевая идея редукции дисперсии: метод контрольной переменной

Идея: снизить дисперсию случайной величины X с помощью другой, **вспомогательной** случайной величины Y , у которой математическое ожидание известно точно. В англоязычной литературе этот приём называют *control variate*; в русской — **метод контрольной переменной**. Рассмотрим новую случайную величину Z_α :

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: без смещения, $\mathbb{E}[Z_1] = \mathbb{E}[X]$.
 - Если $\alpha < 1$: возможно смещение (но меньше дисперсия).
- Полезно, если Y положительно коррелирована с X : тогда $\text{cov}(X, Y) > 0$ и $\text{var}(Z_\alpha) < \alpha^2\text{var}(X)$.

Интуиция: «якорь + малая поправка»

Если $Y \approx X$, то $X - Y \approx 0$ — разность почти детерминирована, и дисперсия мала. При этом $\mathbb{E}[Y]$ нам известно точно, поэтому мы «якоримся» к точному значению и корректируем на маленькую стохастическую добавку:

$$\underbrace{Z_1}_{\text{наша оценка}} = \underbrace{\mathbb{E}[Y]}_{\text{точный якорь}} + \underbrace{(X - Y)}_{\approx 0, \text{ малая дисперсия}}$$

Интуиция: «якорь + малая поправка»

Если $Y \approx X$, то $X - Y \approx 0$ — разность почти детерминирована, и дисперсия мала. При этом $\mathbb{E}[Y]$ нам известно точно, поэтому мы «якоримся» к точному значению и корректируем на маленькую стохастическую добавку:

$$\underbrace{Z_1}_{\text{наша оценка}} = \underbrace{\mathbb{E}[Y]}_{\text{точный якорь}} + \underbrace{(X - Y)}_{\approx 0, \text{ малая дисперсия}}$$

Применение к оценке градиента. Пусть $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, где $\tilde{x}$ — некоторая «опорная» точка, в которой однажды вычислен полный градиент. Тогда

$$g^k = \underbrace{\nabla f(\tilde{x})}_{\text{якорь}} + \underbrace{\nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})}_{\text{стохастическая коррекция}}$$

- Коррекция мала, когда $x^{(k-1)} \approx \tilde{x}$.

Интуиция: «якорь + малая поправка»

Если $Y \approx X$, то $X - Y \approx 0$ — разность почти детерминирована, и дисперсия мала. При этом $\mathbb{E}[Y]$ нам известно точно, поэтому мы «якоримся» к точному значению и корректируем на маленькую стохастическую добавку:

$$\underbrace{Z_1}_{\text{наша оценка}} = \underbrace{\mathbb{E}[Y]}_{\text{точный якорь}} + \underbrace{(X - Y)}_{\approx 0, \text{ малая дисперсия}}$$

Применение к оценке градиента. Пусть $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, где $\tilde{x}$ — некоторая «опорная» точка, в которой однажды вычислен полный градиент. Тогда

$$g^k = \underbrace{\nabla f(\tilde{x})}_{\text{якорь}} + \underbrace{\nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})}_{\text{стохастическая коррекция}}$$

- Коррекция мала, когда $x^{(k-1)} \approx \tilde{x}$.
- Дисперсия $\rightarrow 0$ при $x^{(k-1)} \rightarrow x^*$ (если $\tilde{x}$ тоже близка к x^*) — в отличие от SGD.

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$.

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$.
- На шаге $k = 1, 2, 3, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{свежий градиент } f_{i_k}),$$

остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, — не меняются.

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$.
- На шаге $k = 1, 2, 3, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{свежий градиент } f_{i_k}),$$

остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, — не меняются.

- Обновление:

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$.
- На шаге $k = 1, 2, 3, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{свежий градиент } f_{i_k}),$$

остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, — не меняются.

- Обновление:

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **смещённые** (на каждой итерации $\mathbb{E}[g^{(k)}] \neq \nabla f(x^{(k-1)})$), но с сильно сниженной дисперсией.

SAG (Stochastic Average Gradient) ¹

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$.
- На шаге $k = 1, 2, 3, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{свежий градиент } f_{i_k}),$$

остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, — не меняются.

- Обновление:

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **смещённые** (на каждой итерации $\mathbb{E}[g^{(k)}] \neq \nabla f(x^{(k-1)})$), но с сильно сниженной дисперсией.
- Дёшево обновлять среднее: один член меняется в сумме, остальные $n - 1$ — нет:

$$x^{(k)} = x^{(k-1)} - \alpha_k \underbrace{\left(\frac{1}{n} g_{i_k}^{(k)} - \frac{1}{n} g_{i_k}^{(k-1)} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее}} \right)}_{\text{новое среднее}}$$

¹  Schmidt, Le Roux, Bach (2013). Minimizing Finite Sums with the Stochastic Average Gradient.

Сходимость SAG

Предположим $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, каждая f_i дифференцируема, ∇f_i — липшицев с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднее итераций после $k - 1$ шагов.

i Теорема (SAG, выпуклый случай)

SAG с фиксированным шагом $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2.$$

- Скорость $\mathcal{O}(1/k)$ для SAG — как у GD, но при стоимости итерации $O(1)$.

Сходимость SAG

Предположим $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, каждая f_i дифференцируема, ∇f_i — липшицев с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднее итераций после $k - 1$ шагов.

i Теорема (SAG, выпуклый случай)

SAG с фиксированным шагом $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2.$$

- Скорость $\mathcal{O}(1/k)$ для SAG — как у GD, но при стоимости итерации $\mathcal{O}(1)$.
- Первый член содержит множитель n ; авторы рекомендуют разумную инициализацию (например, n шагов SGD).

Сходимость SAG: сильно выпуклый случай

Дополнительно: каждая f_i сильно выпукла с параметром μ .

i Теорема (SAG, сильно выпуклый случай)

SAG с шагом $\alpha = \frac{1}{16L}$ и той же инициализацией:

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2} (f(x^{(0)}) - f^*) + \frac{4L}{n} \|x^{(0)} - x^*\|^2\right).$$

- **Линейная** скорость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и лишь $\mathcal{O}(1/k)$ для SGD.

Сходимость SAG: сильно выпуклый случай

Дополнительно: каждая f_i сильно выпукла с параметром μ .

i Теорема (SAG, сильно выпуклый случай)

SAG с шагом $\alpha = \frac{1}{16L}$ и той же инициализацией:

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right).$$

- **Линейная** скорость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и лишь $\mathcal{O}(1/k)$ для SGD.
- Как и GD, SAG адаптивен к сильной выпуклости.

Сходимость SAG: сильно выпуклый случай

Дополнительно: каждая f_i сильно выпукла с параметром μ .

i Теорема (SAG, сильно выпуклый случай)

SAG с шагом $\alpha = \frac{1}{16L}$ и той же инициализацией:

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right).$$

- **Линейная** скорость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и лишь $\mathcal{O}(1/k)$ для SGD.
- Как и GD, SAG адаптивен к сильной выпуклости.
- Доказательство непростое: около 15 страниц, часть выкладок выполняется с помощью компьютера.

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:
 - выбираем начальное L_0 ;

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:
 - выбираем начальное L_0 ;
 - увеличиваем L , пока не выполнится

$$f_{i_k}(x^{k+1}) \leq f_{i_k}(x^k) + \langle \nabla f_{i_k}(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2;$$

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:
 - выбираем начальное L_0 ;
 - увеличиваем L , пока не выполнится

$$f_{i_k}(x^{k+1}) \leq f_{i_k}(x^k) + \langle \nabla f_{i_k}(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2;$$

- между итерациями L можно уменьшать.

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:
 - выбираем начальное L_0 ;
 - увеличиваем L , пока не выполнится

$$f_{i_k}(x^{k+1}) \leq f_{i_k}(x^k) + \langle \nabla f_{i_k}(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2;$$

- между итерациями L можно уменьшать.
- По мере сходимости $x^k \rightarrow x^*$ дисперсия оценки $g(x^k)$ уменьшается и значение оценки сходится к истинному градиенту $\nabla f(x^k)$, поэтому норму $\|g(x^k)\|$ можно использовать как критерий остановки (в SGD это бесполезно, так как дисперсия не убывает).

Замечания к SAG

- В исходной формулировке требует $\mathcal{O}(np)$ памяти — не применим к большим нейросетям.
- На практике константу Липшица L можно подбирать по ходу — линейным поиском с дроблением шага:
 - выбираем начальное L_0 ;
 - увеличиваем L , пока не выполнится

$$f_{i_k}(x^{k+1}) \leq f_{i_k}(x^k) + \langle \nabla f_{i_k}(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2;$$

- между итерациями L можно уменьшать.
- По мере сходимости $x^k \rightarrow x^*$ дисперсия оценки $g(x^k)$ уменьшается и значение оценки сходится к истинному градиенту $\nabla f(x^k)$, поэтому норму $\|g(x^k)\|$ можно использовать как критерий остановки (в SGD это бесполезно, так как дисперсия не убывает).
- Для обобщённых линейных моделей (LogReg, МНК) достаточно $\mathcal{O}(n)$ памяти вместо $\mathcal{O}(np)$:

$$f_i(w) = \varphi(w^T x_i) \quad \Rightarrow \quad \nabla f_i(w) = \varphi'(w^T x_i) x_i.$$

SAG: неравномерный выбор индекса

- Скорость определяется $L = \max_i L_i$, где L_i — константа Липшица для f_i .

SAG: неравномерный выбор индекса

- Скорость определяется $L = \max_i L_i$, где L_i — константа Липшица для f_i .
- Если индекс i выбирать с вероятностью, пропорциональной L_i , эффективная константа Липшица становится $\bar{L} = \frac{1}{n} \sum_i L_i$ — обычно существенно меньше $\max_i L_i$.

SAG: неравномерный выбор индекса

- Скорость определяется $L = \max_i L_i$, где L_i — константа Липшица для f_i .
- Если индекс i выбирать с вероятностью, пропорциональной L_i , эффективная константа Липшица становится $\bar{L} = \frac{1}{n} \sum_i L_i$ — обычно существенно меньше $\max_i L_i$.

SAG: неравномерный выбор индекса

- Скорость определяется $L = \max_i L_i$, где L_i — константа Липшица для f_i .
- Если индекс i выбирать с вероятностью, пропорциональной L_i , эффективная константа Липшица становится $\bar{L} = \frac{1}{n} \sum_i L_i$ — обычно существенно меньше $\max_i L_i$.
- Для гарантии сходимости берут смешанное распределение: с вероятностью $\frac{1}{2}$ — равномерный выбор, с вероятностью $\frac{1}{2}$ — выбор с весами $L_i / \sum_j L_j$.

SAG: неравномерный выбор индекса

- Скорость определяется $L = \max_i L_i$, где L_i — константа Липшица для f_i .
- Если индекс i выбирать с вероятностью, пропорциональной L_i , эффективная константа Липшица становится $\bar{L} = \frac{1}{n} \sum_i L_i$ — обычно существенно меньше $\max_i L_i$.
- Для гарантии сходимости берут смешанное распределение: с вероятностью $\frac{1}{2}$ — равномерный выбор, с вероятностью $\frac{1}{2}$ — выбор с весами $L_i / \sum_j L_j$.
- Реализация такой выборки возможна за $O(\log n)$ на одну итерацию.

SVRG (Stochastic Variance Reduced Gradient) ²

- Инициализация: $\tilde{x} \in \mathbb{R}^p$.

SVRG (Stochastic Variance Reduced Gradient) ²

- Инициализация: $\tilde{x} \in \mathbb{R}^p$.
- Для $s = 1, 2, \dots$ (внешний цикл — эпохи):

SVRG (Stochastic Variance Reduced Gradient) ²

- Инициализация: $\tilde{x} \in \mathbb{R}^p$.
- Для $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.

SVRG (Stochastic Variance Reduced Gradient) ²

- Инициализация: $\tilde{x} \in \mathbb{R}^p$.
- Для $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - Для $t = 1, \dots, m$ (внутренний цикл):

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

SVRG (Stochastic Variance Reduced Gradient) ²

- Инициализация: $\tilde{x} \in \mathbb{R}^p$.
- Для $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - Для $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

Замечания:

- Два вычисления градиента на внутреннем шаге.

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

Замечания:

- Два вычисления градиента на внутреннем шаге.
- Только два параметра: длина эпохи m и шаг α .

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

Замечания:

- Два вычисления градиента на внутреннем шаге.
- Только два параметра: длина эпохи m и шаг α .
- Память $O(p)$ — в n раз меньше, чем у SAG.

SVRG (Stochastic Variance Reduced Gradient) ²

- **Инициализация:** $\tilde{x} \in \mathbb{R}^p$.
- **Для** $s = 1, 2, \dots$ (внешний цикл — эпохи):
 - Вычисляем все градиенты $\nabla f_i(\tilde{x})$ и сохраняем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$.
 - Инициализируем $x_0 = \tilde{x}$.
 - **Для** $t = 1, \dots, m$ (внутренний цикл):
 - выбираем $i_t \in \{1, \dots, n\}$ равномерно;
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$.
 - Обновляем $\tilde{x} = x_m$.

Замечания:

- Два вычисления градиента на внутреннем шаге.
- Только два параметра: длина эпохи m и шаг α .
- Память $O(p)$ — в n раз меньше, чем у SAG.
- Линейная скорость сходимости в сильно выпуклом случае, доказательство гораздо короче.

²  Johnson, Zhang (2013). Accelerating SGD using Predictive Variance Reduction.

SAGA ³

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.

SAGA ³

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$.

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$.
- На шаге $k = 1, 2, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$, обновляем только одну запись:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}), \quad g_i^{(k)} = g_i^{(k-1)} \text{ для } i \neq i_k.$$

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$.
- На шаге $k = 1, 2, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$, обновляем только одну запись:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}), \quad g_i^{(k)} = g_i^{(k-1)} \text{ для } i \neq i_k.$$

- Обновление параметра:

$$x^{(k)} = x^{(k-1)} - \alpha \left[\underbrace{g_{i_k}^{(k)} - g_{i_k}^{(k-1)}}_{\text{свежая поправка}} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее}} \right].$$

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$.
- На шаге $k = 1, 2, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$, обновляем только одну запись:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}), \quad g_i^{(k)} = g_i^{(k-1)} \text{ для } i \neq i_k.$$

- Обновление параметра:

$$x^{(k)} = x^{(k-1)} - \alpha \left[\underbrace{g_{i_k}^{(k)} - g_{i_k}^{(k-1)}}_{\text{свежая поправка}} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее}} \right].$$

³ Defazio, Bach, Lacoste-Julien (2014). SAGA: A Fast Incremental Gradient Method.

SAGA — прямое развитие SAG. Структура та же, отличается **одна** деталь в обновлении.

- Поддерживаем таблицу градиентов g_i функции f_i , $i = 1, \dots, n$.
- Инициализируем $x^{(0)}$ и $g_i^{(0)} = \nabla f_i(x^{(0)})$.
- На шаге $k = 1, 2, \dots$ выбираем случайный $i_k \in \{1, \dots, n\}$, обновляем только одну запись:

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}), \quad g_i^{(k)} = g_i^{(k-1)} \text{ для } i \neq i_k.$$

- Обновление параметра:

$$x^{(k)} = x^{(k-1)} - \alpha \left[\underbrace{g_{i_k}^{(k)} - g_{i_k}^{(k-1)}}_{\text{свежая поправка}} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее}} \right].$$

Сравнение оценок: $g_{\text{SAGA}}^{(k)} = g_{i_k}^{(k)} - g_{i_k}^{(k-1)} + \frac{1}{n} \sum_i g_i^{(k-1)}$ — отличается от SAG только **отсутствием множителя** $\frac{1}{n}$ у поправки.

³  Defazio, Bach, Lacoste-Julien (2014). SAGA: A Fast Incremental Gradient Method.

SAG vs SAGA: смещённость через контрольную переменную

Вернёмся к семейству оценок $\theta_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$ для оценивания $\mathbb{E}[X]$, где X, Y — коррелированы:

$$\mathbb{E}[\theta_\alpha] = \alpha \mathbb{E}[X] + (1 - \alpha) \mathbb{E}[Y], \quad \text{Var}(\theta_\alpha) = \alpha^2 (\text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)).$$

SAG vs SAGA: смещённость через контрольную переменную

Вернёмся к семейству оценок $\theta_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$ для оценивания $\mathbb{E}[X]$, где X, Y — коррелированы:

$$\mathbb{E}[\theta_\alpha] = \alpha \mathbb{E}[X] + (1 - \alpha) \mathbb{E}[Y], \quad \text{Var}(\theta_\alpha) = \alpha^2 (\text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)).$$

Для оценок градиента возьмём $X = g_{i_k}^{(k)}$ (свежий), $Y = g_{i_k}^{(k-1)}$ (старый), $\mathbb{E}[Y] = \frac{1}{n} \sum_i g_i^{(k-1)}$.

- **SAGA** использует $\alpha = 1 \Rightarrow$ оценка **несмещённая**: $\mathbb{E}[g_{\text{SAGA}}^{(k)}] = \nabla f(x^{(k-1)})$.

SAG vs SAGA: смещённость через контрольную переменную

Вернёмся к семейству оценок $\theta_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$ для оценивания $\mathbb{E}[X]$, где X, Y — коррелированы:

$$\mathbb{E}[\theta_\alpha] = \alpha \mathbb{E}[X] + (1 - \alpha) \mathbb{E}[Y], \quad \text{Var}(\theta_\alpha) = \alpha^2 (\text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)).$$

Для оценок градиента возьмём $X = g_{i_k}^{(k)}$ (свежий), $Y = g_{i_k}^{(k-1)}$ (старый), $\mathbb{E}[Y] = \frac{1}{n} \sum_i g_i^{(k-1)}$.

- **SAGA** использует $\alpha = 1 \Rightarrow$ оценка **несмещённая**: $\mathbb{E}[g_{\text{SAGA}}^{(k)}] = \nabla f(x^{(k-1)})$.
- **SAG** использует $\alpha = 1/n \Rightarrow$ оценка **смещённая**, но дисперсия в n^2 раз меньше.

SAG vs SAGA: смещённость через контрольную переменную

Вернёмся к семейству оценок $\theta_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$ для оценивания $\mathbb{E}[X]$, где X, Y — коррелированы:

$$\mathbb{E}[\theta_\alpha] = \alpha \mathbb{E}[X] + (1 - \alpha) \mathbb{E}[Y], \quad \text{Var}(\theta_\alpha) = \alpha^2 (\text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)).$$

Для оценок градиента возьмём $X = g_{i_k}^{(k)}$ (свежий), $Y = g_{i_k}^{(k-1)}$ (старый), $\mathbb{E}[Y] = \frac{1}{n} \sum_i g_i^{(k-1)}$.

- **SAGA** использует $\alpha = 1 \Rightarrow$ оценка **несмещённая**: $\mathbb{E}[g_{\text{SAGA}}^{(k)}] = \nabla f(x^{(k-1)})$.
- **SAG** использует $\alpha = 1/n \Rightarrow$ оценка **смещённая**, но дисперсия в n^2 раз меньше.

SAG vs SAGA: смещённость через контрольную переменную

Вернёмся к семейству оценок $\theta_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$ для оценивания $\mathbb{E}[X]$, где X, Y — коррелированы:

$$\mathbb{E}[\theta_\alpha] = \alpha \mathbb{E}[X] + (1 - \alpha) \mathbb{E}[Y], \quad \text{Var}(\theta_\alpha) = \alpha^2 (\text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)).$$

Для оценок градиента возьмём $X = g_{i_k}^{(k)}$ (свежий), $Y = g_{i_k}^{(k-1)}$ (старый), $\mathbb{E}[Y] = \frac{1}{n} \sum_i g_i^{(k-1)}$.

- **SAGA** использует $\alpha = 1 \Rightarrow$ оценка **несмещённая**: $\mathbb{E}[g_{\text{SAGA}}^{(k)}] = \nabla f(x^{(k-1)})$.
- **SAG** использует $\alpha = 1/n \Rightarrow$ оценка **смещённая**, но дисперсия в n^2 раз меньше.

Замечательный факт: SAGA достигает **тех же скоростей сходимости**, что и SAG, при значительно более простом доказательстве (несмещённость убирает кучу хитростей).

Сходимость SAGA

Те же предположения: каждая f_i выпукла, дифференцируема, ∇f_i — L -липшицев.

i Теорема (SAGA, выпуклый случай)

SAGA с шагом $\alpha = \frac{1}{3L}$ и инициализацией $g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)})$:

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{4n}{k} [f(x^{(0)}) - f^*] + \frac{8L}{k} \|x^{(0)} - x^*\|^2.$$

- В сильно выпуклом случае ($\mu > 0$): шаг $\alpha = \frac{1}{2(\mu n + L)}$, линейная скорость с коэффициентом сжатия $1 - \frac{\mu}{2(\mu n + L)}$.

Сходимость SAGA

Те же предположения: каждая f_i выпукла, дифференцируема, ∇f_i — L -липшицев.

i Теорема (SAGA, выпуклый случай)

SAGA с шагом $\alpha = \frac{1}{3L}$ и инициализацией $g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)})$:

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{4n}{k} [f(x^{(0)}) - f^*] + \frac{8L}{k} \|x^{(0)} - x^*\|^2.$$

- В сильно выпуклом случае ($\mu > 0$): шаг $\alpha = \frac{1}{2(\mu n + L)}$, линейная скорость с коэффициентом сжатия $1 - \frac{\mu}{2(\mu n + L)}$.
- SAGA естественно расширяется на комбинированные задачи $\min f(x) + h(x)$ через проксимальный оператор от h .

Сравнение методов

Метод	Стоимость итерации	Сходимость (сильно выпуклый)	Память	Несмещён?
GD	$O(n)$	Линейная	$O(p)$	—
SGD	$O(1)$	Сублинейная $O(1/k)$	$O(p)$	да
SAG	$O(1)$	Линейная	$O(np)$	нет
SVRG	$O(1)$	Линейная	$O(p)$	да
SAGA	$O(1)$	Линейная	$O(np)$	да


Сравнение методов

Метод	Стоимость итерации	Сходимость (сильно выпуклый)	Память	Несмещён?
GD	$O(n)$	Линейная	$O(p)$	—
SGD	$O(1)$	Сублинейная $O(1/k)$	$O(p)$	да
SAG	$O(1)$	Линейная	$O(np)$	нет
SVRG	$O(1)$	Линейная	$O(p)$	да
SAGA	$O(1)$	Линейная	$O(np)$	да

Главное достижение: VR-методы достигают **линейной** сходимости при стоимости итерации $O(1)$ — то, чего нет у обычного SGD.


Численный эксперимент: SGD vs SAG vs SAGA

Логистическая регрессия с ℓ_2 -регуляризацией, $n = 800$, $d = 100$. Шаги: $\alpha_{\text{SAG}} = \alpha_{\text{SGD}} = \frac{1}{16L}$, $\alpha_{\text{SAGA}} = \frac{1}{3L}$. По 15 запусков с разными случайными перестановками.




Численный эксперимент: SGD vs SAG vs SAGA

Логистическая регрессия с ℓ_2 -регуляризацией, $n = 800$, $d = 100$. Шаги: $\alpha_{\text{SAG}} = \alpha_{\text{SGD}} = \frac{1}{16L}$, $\alpha_{\text{SAGA}} = \frac{1}{3L}$. По 15 запусков с разными случайными перестановками.



Численный эксперимент: SGD vs SAG vs SAGA

Логистическая регрессия с ℓ_2 -регуляризацией, $n = 800$, $d = 100$. Шаги: $\alpha_{\text{SAG}} = \alpha_{\text{SGD}} = \frac{1}{16L}$, $\alpha_{\text{SAGA}} = \frac{1}{3L}$. По 15 запусков с разными случайными перестановками.



Можно ли быстрее? Нижние оценки и ускорение

Для выпуклой задачи с конечной суммой (n компонент, μ -сильно выпуклых, L -гладких) известны **точные нижние оценки**.

Можно ли быстрее? Нижние оценки и ускорение

Для выпуклой задачи с конечной суммой (n компонент, μ -сильно выпуклых, L -гладких) известны **точные нижние оценки**.

Верхняя оценка для SAG / SAGA / SVRG (и им подобных):

$$\# \text{ итераций} = \mathcal{O}\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right).$$

⁴Lan, Zhou (2015). *An optimal randomized incremental gradient method.*; Woodworth, Srebro (2016).

Можно ли быстрее? Нижние оценки и ускорение

Для выпуклой задачи с конечной суммой (n компонент, μ -сильно выпуклых, L -гладких) известны **точные нижние оценки**.

Верхняя оценка для SAG / SAGA / SVRG (и им подобных):

$$\# \text{ итераций} = \mathcal{O}\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right).$$

Нижняя оценка ⁴:

$$\# \text{ итераций} = \Omega\left(\left(n + \sqrt{\frac{nL}{\mu}}\right) \log \frac{1}{\varepsilon}\right).$$

Между ними есть **зазор**: на плохо обусловленных задачах ($L/\mu \gg n$) можно ускориться в $\sqrt{n}$ раз.

⁴Lan, Zhou (2015). *An optimal randomized incremental gradient method.*; Woodworth, Srebro (2016).

Можно ли быстрее? Нижние оценки и ускорение

Для выпуклой задачи с конечной суммой (n компонент, μ -сильно выпуклых, L -гладких) известны **точные нижние оценки**.

Верхняя оценка для SAG / SAGA / SVRG (и им подобных):

$$\# \text{ итераций} = \mathcal{O}\left(\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}\right).$$

Нижняя оценка⁴:

$$\# \text{ итераций} = \Omega\left(\left(n + \sqrt{\frac{nL}{\mu}}\right) \log \frac{1}{\varepsilon}\right).$$

Между ними есть **зазор**: на плохо обусловленных задачах ($L/\mu \gg n$) можно ускориться в $\sqrt{n}$ раз.

Ускоренные VR-методы (Catalyst, Lan-Zhou, Allen-Zhu Katyusha) этот зазор закрывают:

$$\# \text{ итераций} = \mathcal{O}\left(\left(n + \sqrt{\frac{nL}{\mu}}\right) \log \frac{1}{\varepsilon}\right) - \text{оптимально.}$$

⁴Lan, Zhou (2015). *An optimal randomized incremental gradient method.*; Woodworth, Srebro (2016).

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.
- **Невыпуклый случай** — история сильно сложнее. Ускорение в стиле Нестерова используется реже; вместо него — **момент** (Polyak 1964, предшествует ускорению почти на 20 лет):

$$x^{k+1} = x^k + \beta (x^k - x^{k-1}) - \alpha \nabla f_{i_k}(x^k).$$

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.
- **Невыпуклый случай** — история сильно сложнее. Ускорение в стиле Нестерова используется реже; вместо него — **момент** (Polyak 1964, предшествует ускорению почти на 20 лет):

$$x^{k+1} = x^k + \beta (x^k - x^{k-1}) - \alpha \nabla f_{i_k}(x^k).$$

- На практике моментум работает очень хорошо, но менее устойчив.

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.
- **Невыпуклый случай** — история сильно сложнее. Ускорение в стиле Нестерова используется реже; вместо него — **момент** (Polyak 1964, предшествует ускорению почти на 20 лет):

$$x^{k+1} = x^k + \beta (x^k - x^{k-1}) - \alpha \nabla f_{i_k}(x^k).$$

- На практике моментум работает очень хорошо, но менее устойчив.
- Ускорение Нестерова отличается **корректирующим градиентным членом**, и сама корректировка устроена по-разному в выпуклом и сильно выпуклом случае.

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Моментум, ускорение и невыпуклый случай

- **Выпуклая задача с конечной суммой** — закрыта: VR + ускорение дают оптимальную скорость.
- **Общий выпуклый стохастический случай** (без конечной суммы): SGD оптимален, улучшить нельзя ⁵.
- **Невыпуклый случай** — история сильно сложнее. Ускорение в стиле Нестерова используется реже; вместо него — **момент** (Polyak 1964, предшествует ускорению почти на 20 лет):

$$x^{k+1} = x^k + \beta (x^k - x^{k-1}) - \alpha \nabla f_{i_k}(x^k).$$

- На практике моментум работает очень хорошо, но менее устойчив.
- Ускорение Нестерова отличается **корректирующим градиентным членом**, и сама корректировка устроена по-разному в выпуклом и сильно выпуклом случае.
- **Открытая задача**: когда и почему всё это работает в невыпуклом случае?

⁵Nemirovski, Juditsky, Lan, Shapiro (2009)

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:
 - данные не фиксированы — на каждой эпохе работают аугментации и dropout;

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:
 - данные не фиксированы — на каждой эпохе работают аугментации и dropout;
 - траектория обучения долго остаётся вдали от окрестности оптимума x^* ;

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:
 - данные не фиксированы — на каждой эпохе работают аугментации и dropout;
 - траектория обучения долго остаётся вдали от окрестности оптимума x^* ;
 - задача невыпуклая и нелинейная.

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:
 - данные не фиксированы — на каждой эпохе работают аугментации и dropout;
 - траектория обучения долго остаётся вдали от окрестности оптимума x^* ;
 - задача невыпуклая и нелинейная.
- Авторы рассматривают SVRG (наиболее экономный по памяти) и получают **либо ухудшение качества, либо расходимость** на CIFAR и ImageNet.

Работают ли VR-методы для нейросетей? ⁶

- Обучение нейросетей нарушает большинство предположений, на которых строятся VR-методы:
 - данные не фиксированы — на каждой эпохе работают аугментации и dropout;
 - траектория обучения долго остаётся вдали от окрестности оптимума x^* ;
 - задача невыпуклая и нелинейная.
- Авторы рассматривают SVRG (наиболее экономный по памяти) и получают **либо ухудшение качества, либо расходимость** на CIFAR и ImageNet.
- В конце они предлагают комбинировать редукцию дисперсии с адаптивными методами (AdaGrad, Adam, ...). Это естественный мостик к следующей части лекции.

⁶  Defazio, Bottou (2019). On the Ineffectiveness of Variance Reduced Optimization for Deep Learning.

Адаптивные стохастические методы

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях, отдельные параметры в глубоких сетях;

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях, отдельные параметры в глубоких сетях;
 - слой эмбедингов для редких слов обновляется намного реже, чем плотные слои.

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях, отдельные параметры в глубоких сетях;
 - слой эмбедингов для редких слов обновляется намного реже, чем плотные слои.
- Идея адаптивных методов — **подобрать свой эффективный шаг каждой координате**, опираясь на накопленную историю градиентов.

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях, отдельные параметры в глубоких сетях;
 - слой эмбедингов для редких слов обновляется намного реже, чем плотные слои.
- Идея адаптивных методов — **подобрать свой эффективный шаг каждой координате**, опираясь на накопленную историю градиентов.
- Содержательно это можно трактовать как грубое приближение диагонали гессиана (или информационной матрицы Фишера).

Adagrad ⁷

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.

Adagrad ⁷

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.
- Заметно улучшает SGD в разреженных задачах (NLP, рекомендательные системы).

Adagrad ⁷

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.
- Заметно улучшает SGD в разреженных задачах (NLP, рекомендательные системы).
- Главная слабость — **монотонное** накопление в знаменателе: эффективный шаг $\rightarrow 0$ слишком рано, и обучение «затухает».

⁷  Duchi, Hazan, Singer (2010). Adaptive Subgradient Methods for Online Learning and Stochastic Optimization.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) \left(g_j^{(k)} \right)^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — корень из скользящего среднего квадратов градиентов: грубая оценка корня из среднеквадратичной величины градиента по каждой координате.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) \left(g_j^{(k)} \right)^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — корень из скользящего среднего квадратов градиентов: грубая оценка корня из среднеквадратичной величины градиента по каждой координате.
- Более гибкая настройка, чем у AdaGrad, подходит для нестационарных задач.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — корень из скользящего среднего квадратов градиентов: грубая оценка корня из среднеквадратичной величины градиента по каждой координате.
- Более гибкая настройка, чем у AdaGrad, подходит для нестационарных задач.
- Долгое время был выбором по умолчанию при обучении рекуррентных сетей.

⁸  Tieleman, Hinton (2012). Coursera Lecture 6.

Развитие RMSProp: вообще **не требует** глобального шага α . Вместо этого использует «единицы измерения» обновлений:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$\tilde{g}_j^{(k)} = \frac{\sqrt{\Delta x_j^{(k-1)} + \varepsilon}}{\sqrt{v_j^{(k)} + \varepsilon}} g_j^{(k)}$$

$$x_j^{(k)} = x_j^{(k-1)} - \tilde{g}_j^{(k)}, \quad \Delta x_j^{(k)} = \rho \Delta x_j^{(k-1)} + (1 - \rho) (\tilde{g}_j^{(k)})^2$$

Замечания:

- Шаг автоматически масштабируется так, чтобы иметь те же единицы, что и параметр.

Развитие RMSProp: вообще **не требует** глобального шага α . Вместо этого использует «единицы измерения» обновлений:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$\tilde{g}_j^{(k)} = \frac{\sqrt{\Delta x_j^{(k-1)} + \varepsilon}}{\sqrt{v_j^{(k)} + \varepsilon}} g_j^{(k)}$$

$$x_j^{(k)} = x_j^{(k-1)} - \tilde{g}_j^{(k)}, \quad \Delta x_j^{(k)} = \rho \Delta x_j^{(k-1)} + (1 - \rho) (\tilde{g}_j^{(k)})^2$$

Замечания:

- Шаг автоматически масштабируется так, чтобы иметь те же единицы, что и параметр.
- Полезен, когда масштабы параметров между слоями существенно различаются.

⁹  Zeiler (2012). ADADELTA: An Adaptive Learning Rate Method.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.
- Не сходится для некоторых простых задач (даже выпуклых).

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.
- Не сходится для некоторых простых задач (даже выпуклых).
- Гораздо лучше работает для языковых моделей, чем для задач компьютерного зрения — открытый вопрос «почему».

¹⁰  Kingma, Ba (2014). Adam: A Method for Stochastic Optimization.

¹¹  Reddi, Kale, Kumar (2018). On the Convergence of Adam and Beyond.

Решает проблему ℓ_2 -регуляризации в адаптивных оптимизаторах. Стандартная ℓ_2 -регуляризация добавляет $\lambda\|x\|^2$ к целевой функции, порождая градиентный член λx . В Adam этот член делится на $(\sqrt{\hat{v}_j} + \varepsilon)$ — то есть сила регуляризации оказывается связана с величинами градиентов, что нежелательно.

AdamW **разделяет** weight decay и адаптацию градиентов:

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon} + \lambda x_j^{(k-1)} \right)$$

Замечания:

- Член weight decay $\lambda x_j^{(k-1)}$ добавляется *после* адаптивного градиентного шага и не масштабируется на $\sqrt{\hat{v}_j}$.

Решает проблему ℓ_2 -регуляризации в адаптивных оптимизаторах. Стандартная ℓ_2 -регуляризация добавляет $\lambda\|x\|^2$ к целевой функции, порождая градиентный член λx . В Adam этот член делится на $(\sqrt{\hat{v}_j} + \varepsilon)$ — то есть сила регуляризации оказывается связана с величинами градиентов, что нежелательно.

AdamW **разделяет** weight decay и адаптацию градиентов:

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon} + \lambda x_j^{(k-1)} \right)$$

Замечания:

- Член weight decay $\lambda x_j^{(k-1)}$ добавляется *после* адаптивного градиентного шага и не масштабируется на $\sqrt{\hat{v}_j}$.
- Широко используется при обучении трансформеров и больших моделей; выбор по умолчанию в HuggingFace Trainer.

¹²  Loshchilov, Hutter (2017). Decoupled Weight Decay Regularization.

Adam не сходится: постановка¹³

Рассмотрим **простейшую** возможную задачу — выпуклую, гладкую, сильно выпуклую, с единственным глобальным минимумом в нуле:

$$L(w) = w^2, \quad \nabla L(w) = 2w, \quad w \in \mathbb{R}.$$

Обновление Adam (одномерный случай, без коррекции смещения и для упрощения $\varepsilon = 0$):

$$\begin{aligned} g_t &= 2w_{t-1}, \\ m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ w_t &= w_{t-1} - \eta \frac{m_t}{\sqrt{v_t}}. \end{aligned}$$

¹³  Reddi et al. (2018). On the Convergence of Adam and Beyond.

Adam не сходится: постановка¹³

Рассмотрим **простейшую** возможную задачу — выпуклую, гладкую, сильно выпуклую, с единственным глобальным минимумом в нуле:

$$L(w) = w^2, \quad \nabla L(w) = 2w, \quad w \in \mathbb{R}.$$

Обновление Adam (одномерный случай, без коррекции смещения и для упрощения $\varepsilon = 0$):

$$\begin{aligned} g_t &= 2w_{t-1}, \\ m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ w_t &= w_{t-1} - \eta \frac{m_t}{\sqrt{v_t}}. \end{aligned}$$

Чего мы **ждём** от любого приличного метода: $w_t \rightarrow 0$ и шаг $|w_t - w_{t-1}| \rightarrow 0$ по мере приближения к оптимуму. У GD с шагом $\eta < 1/2$ это так: $w_t = (1 - 2\eta)w_{t-1}$, экспоненциальная сходимость.

Покажем, что у Adam **этого не происходит**.

¹³  Reddi et al. (2018). On the Convergence of Adam and Beyond.

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

v_t — **квадратичен по w** . Сумма прошлых $g_\tau^2 = 4w_{\tau-1}^2$, каждый член квадратичен:

$$v_t = (1 - \beta_2) \sum_{\tau \leq t} \beta_2^{t-\tau} 4w_{\tau-1}^2 \propto w^2.$$

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

v_t — **квадратичен по w** . Сумма прошлых $g_\tau^2 = 4w_{\tau-1}^2$, каждый член квадратичен:

$$v_t = (1 - \beta_2) \sum_{\tau \leq t} \beta_2^{t-\tau} 4w_{\tau-1}^2 \propto w^2.$$

Следовательно:

$$\sqrt{v_t} \propto |w| \quad \Rightarrow \quad \frac{m_t}{\sqrt{v_t}} \approx \text{sign}(w) = \pm 1$$

Это отношение **не зависит** от $|w|$: какой бы маленькой ни стала итерация, нормированный градиент остаётся порядка единицы.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Получаем **предельный цикл**:

$$w_t \in \{-\eta/2, +\eta/2\}, \quad t \rightarrow \infty.$$

Метод **не сходится** ни к точке, ни даже к нулю по среднему.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Получаем **предельный цикл**:

$$w_t \in \{-\eta/2, +\eta/2\}, \quad t \rightarrow \infty.$$

Метод **не сходится** ни к точке, ни даже к нулю по среднему.

Сравнение с SGD. Для $L(w) = w^2$ обновление SGD:

$$w_t = w_{t-1} - \eta \cdot 2w_{t-1} = (1 - 2\eta)w_{t-1}.$$

Шаг **пропорционален** w , обнуляется в пределе $\Rightarrow$ сходимость.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Получаем **предельный цикл**:

$$w_t \in \{-\eta/2, +\eta/2\}, \quad t \rightarrow \infty.$$

Метод **не сходится** ни к точке, ни даже к нулю по среднему.

Сравнение с SGD. Для $L(w) = w^2$ обновление SGD:

$$w_t = w_{t-1} - \eta \cdot 2w_{t-1} = (1 - 2\eta)w_{t-1}.$$

Шаг **пропорционален** w , обнуляется в пределе $\Rightarrow$ сходимость.

Мораль. Адаптивная нормировка $\frac{m_t}{\sqrt{v_t}}$ убивает информацию о масштабе — даже на самой простой выпуклой задаче.

Adam не сходится: иллюстрация





Figure 2: Adam (с разными η) на $L(w) = w^2$. Виден переход от линейного убывания к предельному циклу амплитуды $\sim \eta/2$.

Много оптимизаторов — как сравнивать?

Rosenbrock Function.
Adaptive stochastic gradient algorithms.
Learning rate 0.003



AlgoPerf benchmark ¹⁴

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:

AlgoPerf benchmark ¹⁴

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);


- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).
- **Оценка** агрегируется через профили производительности; финальный балл — нормализованная площадь под профилем (1.0 = быстрееший на всех задачах).

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).
- **Оценка** агрегируется через профили производительности; финальный балл — нормализованная площадь под профилем (1.0 = быстрееший на всех задачах).
- **Стоимость** оценки: $\sim 49\,240$ часов работы на 8 NVIDIA V100 GPU.

¹⁴  Dahl et al. (2023). Benchmarking Neural Network Training Algorithms.

AlgoPerf benchmark: результаты



Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.
- На практике VR-методы плохо переносятся на современное глубокое обучение из-за нарушения предположений (аугментации, dropout, невыпуклость).

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.
- На практике VR-методы плохо переносятся на современное глубокое обучение из-за нарушения предположений (аугментации, dropout, невыпуклость).
- **Адаптивные методы** (AdaGrad, RMSProp, Adadelta, Adam, AdamW) задают **свой** эффективный шаг каждой координате через статистики градиентов.

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.
- На практике VR-методы плохо переносятся на современное глубокое обучение из-за нарушения предположений (аугментации, dropout, невыпуклость).
- **Адаптивные методы** (AdaGrad, RMSProp, Adadelta, Adam, AdamW) задают **свой** эффективный шаг каждой координате через статистики градиентов.
- Adam — де-факто стандарт для обучения LLM, но не сходится даже на простейших выпуклых примерах. AdamW — улучшение, корректно учитывающее регуляризацию.

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.
- На практике VR-методы плохо переносятся на современное глубокое обучение из-за нарушения предположений (аугментации, dropout, невыпуклость).
- **Адаптивные методы** (AdaGrad, RMSProp, Adadelta, Adam, AdamW) задают **свой** эффективный шаг каждой координате через статистики градиентов.
- Adam — де-факто стандарт для обучения LLM, но не сходится даже на простейших выпуклых примерах. AdamW — улучшение, корректно учитывающее регуляризацию.

Итоги лекции

- **VR-методы** (SAG, SVRG, SAGA) достигают **линейной** сходимости при цене итерации $O(1)$ для выпуклой задачи минимизации конечной суммы:
 - SAG — смещённый, минимальная дисперсия, $O(np)$ памяти;
 - SVRG — несмещённый, $O(p)$ памяти, двойное вычисление градиента и полный проход раз в эпоху;
 - SAGA — несмещённый, $O(np)$ памяти, простой анализ, расширяется на композитные задачи.
- **Ускоренные VR-методы** (Katyusha, Catalyst) закрывают зазор между верхними и нижними оценками и оптимальны для выпуклой конечной суммы.
- На практике VR-методы плохо переносятся на современное глубокое обучение из-за нарушения предположений (аугментации, dropout, невыпуклость).
- **Адаптивные методы** (AdaGrad, RMSProp, Adadelta, Adam, AdamW) задают **свой** эффективный шаг каждой координате через статистики градиентов.
- Adam — де-факто стандарт для обучения LLM, но не сходится даже на простейших выпуклых примерах. AdamW — улучшение, корректно учитывающее регуляризацию.

Дальше: оптимизация для **матричных** параметров — спектральная норма, ортогонализация градиента, Muon и Neon.