




Невыпуклая оптимизация

Даня Меркулов

ФКН ВШЭ

Мотивация: реальность ML

Весь курс был о выпуклых задачах

Выпуклые задачи: f выпуклая $\Rightarrow$ любой локальный минимум = глобальный.

Весь курс был о выпуклых задачах

Выпуклые задачи: f выпуклая $\Rightarrow$ любой локальный минимум = глобальный.

Гарантии: GD — $O(1/k)$, AGD — $O(1/k^2)$, сильно выпуклая — $O(e^{-k})$.

Весь курс был о выпуклых задачах

Выпуклые задачи: f выпуклая $\Rightarrow$ любой локальный минимум = глобальный.

Гарантии: GD — $O(1/k)$, AGD — $O(1/k^2)$, сильно выпуклая — $O(e^{-k})$.

Реальность ML: функция потерь нейронной сети $\mathcal{L}(\theta)$ — невыпуклая.

Весь курс был о выпуклых задачах

Выпуклые задачи: f выпуклая $\Rightarrow$ любой локальный минимум = глобальный.

Гарантии: GD — $O(1/k)$, AGD — $O(1/k^2)$, сильно выпуклая — $O(e^{-k})$.

Реальность ML: функция потерь нейронной сети $\mathcal{L}(\theta)$ — невыпуклая.

Вопрос

Почему GD и Adam вообще работают для нейронных сетей?

Три ключевых факта о невыпуклой оптимизации

Факт 1: для L -гладкой невыпуклой f GD сходится к ε -стационарной точке за $O(1/\varepsilon^2)$ итераций.

Три ключевых факта о невыпуклой оптимизации

Факт 1: для L -гладкой невыпуклой f GD сходится к ε -стационарной точке за $O(1/\varepsilon^2)$ итераций.

Факт 2: условие Поляка-Łojasiewicz (PL) гарантирует линейную сходимость **без выпуклости**.

Три ключевых факта о невыпуклой оптимизации

Факт 1: для L -гладкой невыпуклой f GD сходится к ε -стационарной точке за $O(1/\varepsilon^2)$ итераций.

Факт 2: условие Поляка-Łojasiewicz (PL) гарантирует линейную сходимость **без выпуклости**.

Факт 3: при избыточной параметризации нейронные сети имеют «доброкачественный» ландшафт.

Три ключевых факта о невыпуклой оптимизации

Факт 1: для L -гладкой невыпуклой f GD сходится к ε -стационарной точке за $O(1/\varepsilon^2)$ итераций.

Факт 2: условие Поляка-Łojasiewicz (PL) гарантирует линейную сходимость **без выпуклости**.

Факт 3: при избыточной параметризации нейронные сети имеют «доброкачественный» ландшафт.

Условие	Скорость GD	Гарантия
Выпуклая, L -гладкая	$O(1/k)$	Глобальный оптимум
Сильно выпуклая	$O(e^{-\mu k/L})$	Глобальный оптимум
Невыпуклая, L -гладкая	$O(1/\sqrt{k})$ (норма ∇f)	ε -стационарная точка
PL + L -гладкая	$O(e^{-\mu k/L})$	Глобальный (без выпуклости!)

Критические точки и классификация

Критические точки

Определение: x^* — критическая точка, если $\nabla f(x^*) = 0$.

Критические точки

Определение: x^* — критическая точка, если $\nabla f(x^*) = 0$.

Классификация по гессиану $H = \nabla^2 f(x^*)$:

Тип	H	Пример
Глобальный минимум	PSD, все $\lambda \geq 0$	$f = \ x\ ^2$
Локальный минимум	PD, все $\lambda > 0$	чаша
Седловая точка	Indefinite (есть $\lambda < 0$)	$f = x^2 - y^2$
Локальный максимум	ND, все $\lambda < 0$	редко в ML

Критические точки

Определение: x^* — критическая точка, если $\nabla f(x^*) = 0$.

Классификация по гессиану $H = \nabla^2 f(x^*)$:

Тип	H	Пример
Глобальный минимум	PSD, все $\lambda \geq 0$	$f = \ x\ ^2$
Локальный минимум	PD, все $\lambda > 0$	чаша
Седловая точка	Indefinite (есть $\lambda < 0$)	$f = x^2 - y^2$
Локальный максимум	ND, все $\lambda < 0$	редко в ML

Критических точек много: у нейросети с $d = 10^7$ параметров — экспоненциально много. Но большинство — сёдла, а не локальные минимумы!

Пример: седловая точка $f(x, y) = x^2 - y^2$

Критическая точка $(0, 0)$: $\nabla f = (2x, -2y)|_{(0,0)} = (0, 0)$.

Пример: седловая точка $f(x, y) = x^2 - y^2$

Критическая точка $(0, 0)$: $\nabla f = (2x, -2y)|_{(0,0)} = (0, 0)$.

Гессиан: $H = \text{diag}(2, -2)$ — одно собственное значение > 0 , одно < 0 .

Пример: седловая точка $f(x, y) = x^2 - y^2$

Критическая точка $(0, 0)$: $\nabla f = (2x, -2y)|_{(0,0)} = (0, 0)$.

Гессиан: $H = \text{diag}(2, -2)$ — одно собственное значение > 0 , одно < 0 .

Поведение GD: вдоль x — движется к 0 (убыль), вдоль y — уходит от 0 (рост).

Пример: седловая точка $f(x, y) = x^2 - y^2$

Критическая точка $(0, 0)$: $\nabla f = (2x, -2y)|_{(0,0)} = (0, 0)$.

Гессиан: $H = \text{diag}(2, -2)$ — одно собственное значение > 0 , одно < 0 .

Поведение GD: вдоль x — движется к 0 (убыль), вдоль y — уходит от 0 (рост).

Ключевое наблюдение

В $\mathbb{R}^d$ при d большом: у локального минимума **все** d собственных значений H должны быть > 0 — событие маловероятное! Большинство критических точек — сёдла.

Сходимость GD для невыпуклых функций

Теорема: $O(1/\varepsilon^2)$ итераций

Теорема (сходимость GD к ε -стационарной точке):

Пусть f L -гладкая и ограничена снизу: $f^* > -\infty$. Тогда GD с шагом $\alpha = 1/L$:

$$\min_{k=0,\dots,K-1} \|\nabla f(x_k)\|^2 \leq \frac{2L(f(x_0) - f^*)}{K}$$

Теорема: $O(1/\varepsilon^2)$ итераций

Теорема (сходимость GD к ε -стационарной точке):

Пусть f L -гладкая и ограничена снизу: $f^* > -\infty$. Тогда GD с шагом $\alpha = 1/L$:

$$\min_{k=0,\dots,K-1} \|\nabla f(x_k)\|^2 \leq \frac{2L(f(x_0) - f^*)}{K}$$

Доказательство: из L -гладкости:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$$

Суммируем по $k = 0, \dots, K-1$, используем телескопирование:

$$\sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 \leq 2L(f(x_0) - f(x_K)) \leq 2L(f(x_0) - f^*)$$

Минимум $\leq$ среднее. $\square$

Теорема: $O(1/\varepsilon^2)$ итераций

Теорема (сходимость GD к ε -стационарной точке):

Пусть f L -гладкая и ограничена снизу: $f^* > -\infty$. Тогда GD с шагом $\alpha = 1/L$:

$$\min_{k=0, \dots, K-1} \|\nabla f(x_k)\|^2 \leq \frac{2L(f(x_0) - f^*)}{K}$$

Доказательство: из L -гладкости:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$$

Суммируем по $k = 0, \dots, K-1$, используем телескопирование:

$$\sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 \leq 2L(f(x_0) - f(x_K)) \leq 2L(f(x_0) - f^*)$$

Минимум $\leq$ среднее. $\square$

Следствие: для $\|\nabla f\| \leq \varepsilon$ нужно $K = O(L(f(x_0) - f^*)/\varepsilon^2)$ итераций.

Сравнение скоростей

Класс задачи	Скорость	Мера сходимости
Сильно выпуклая ($\mu > 0$)	$O(e^{-k\mu/L})$	$f(x_k) - f^*$
Выпуклая ($\mu = 0$)	$O(1/k)$	$f(x_k) - f^*$
Невыпуклая	$O(1/\sqrt{k})$	$\min_k \ \nabla f(x_k)\ $

Сравнение скоростей

Класс задачи	Скорость	Мера сходимости
Сильно выпуклая ($\mu > 0$)	$O(e^{-k\mu/L})$	$f(x_k) - f^*$
Выпуклая ($\mu = 0$)	$O(1/k)$	$f(x_k) - f^*$
Невыпуклая	$O(1/\sqrt{k})$	$\min_k \ \nabla f(x_k)\ $

Нижняя оценка: $\Omega(1/\varepsilon^2)$ — оптимально для невыпуклых задач (нет метода лучше по градиентам).

Сравнение скоростей

Класс задачи	Скорость	Мера сходимости
Сильно выпуклая ($\mu > 0$)	$O(e^{-k\mu/L})$	$f(x_k) - f^*$
Выпуклая ($\mu = 0$)	$O(1/k)$	$f(x_k) - f^*$
Невыпуклая	$O(1/\sqrt{k})$	$\min_k \ \nabla f(x_k)\ $

Нижняя оценка: $\Omega(1/\varepsilon^2)$ — оптимально для невыпуклых задач (нет метода лучше по градиентам).

Практическая интерпретация

GD гарантирует нахождение точки с **малым градиентом** — возможно, локальный минимум или седло. Для нейросетей на практике этого достаточно!

Условие Поляка-Łojasiewicz (PL)

Определение условия PL

Условие PL (Polyak, 1963; Łojasiewicz, 1963):

$$\|\nabla f(x)\|^2 \geq 2\mu (f(x) - f^*) \quad \forall x$$

Определение условия PL

Условие PL (Polyak, 1963; Łojasiewicz, 1963):

$$\|\nabla f(x)\|^2 \geq 2\mu (f(x) - f^*) \quad \forall x$$

Интуиция: «далеко от минимума — большой градиент». Это **не выпуклость!**

Определение условия PL

Условие PL (Polyak, 1963; Łojasiewicz, 1963):

$$\|\nabla f(x)\|^2 \geq 2\mu (f(x) - f^*) \quad \forall x$$

Интуиция: «далеко от минимума — большой градиент». Это **не выпуклость!**

Иерархия условий:

Сильная выпуклость $\Rightarrow$ PL $\Rightarrow$ квазивыпуклость

Но: PL $\nRightarrow$ выпуклость!

Определение условия PL

Условие PL (Polyak, 1963; Łojasiewicz, 1963):

$$\|\nabla f(x)\|^2 \geq 2\mu (f(x) - f^*) \quad \forall x$$

Интуиция: «далеко от минимума — большой градиент». Это **не выпуклость!**

Иерархия условий:

Сильная выпуклость $\Rightarrow$ PL $\Rightarrow$ квазивыпуклость

Но: PL $\nRightarrow$ выпуклость!

PL допускает множество минимумов — в отличие от сильной выпуклости.

Примеры функций, удовлетворяющих PL

1. **Линейная регрессия:** $f(x) = \|Ax - b\|^2$ при A полного ранга — PL с $\mu = 2\sigma_{\min}^2(A)$.

Примеры функций, удовлетворяющих PL

1. **Линейная регрессия:** $f(x) = \|Ax - b\|^2$ при A полного ранга — PL с $\mu = 2\sigma_{\min}^2(A)$.
2. **Невыпуклая функция:** $f(x) = \frac{1}{2}\|x\|^2 \cdot \|x - 1\|^2$ — невыпуклая (два минимума $x = 0, x = 1$), но PL!

Примеры функций, удовлетворяющих PL

1. **Линейная регрессия:** $f(x) = \|Ax - b\|^2$ при A полного ранга — PL с $\mu = 2\sigma_{\min}^2(A)$.
2. **Невыпуклая функция:** $f(x) = \frac{1}{2}\|x\|^2 \cdot \|x - 1\|^2$ — невыпуклая (два минимума $x = 0, x = 1$), но PL!
3. **Нейронные сети при избыточной параметризации** (Du et al., 2019): при достаточной ширине GD сходится к нулевой потере.

Примеры функций, удовлетворяющих PL

1. **Линейная регрессия:** $f(x) = \|Ax - b\|^2$ при A полного ранга — PL с $\mu = 2\sigma_{\min}^2(A)$.
2. **Невыпуклая функция:** $f(x) = \frac{1}{2}\|x\|^2 \cdot \|x - 1\|^2$ — невыпуклая (два минимума $x = 0, x = 1$), но PL!
3. **Нейронные сети при избыточной параметризации** (Du et al., 2019): при достаточной ширине GD сходится к нулевой потере.
4. **НТК-режим:** при ширине $\rightarrow \infty$ сеть ведёт себя как линейная модель $\Rightarrow$ выпуклость $\Rightarrow$ PL.

Теорема: линейная сходимость при PL

Теорема: если f L -гладкая и выполнено PL с $\mu > 0$, то GD с $\alpha = 1/L$:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*)$$

Теорема: линейная сходимость при PL

Теорема: если f L -гладкая и выполнено PL с $\mu > 0$, то GD с $\alpha = 1/L$:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*)$$

Доказательство (элегантное):

Из L -гладкости: $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$.

Из PL: $\|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$.

Подставляем:

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{\mu}{L}\right) (f(x_k) - f^*). \quad \square$$

Теорема: линейная сходимость при PL

Теорема: если f L -гладкая и выполнено PL с $\mu > 0$, то GD с $\alpha = 1/L$:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*)$$

Доказательство (элегантное):

Из L -гладкости: $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$.

Из PL: $\|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$.

Подставляем:

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{\mu}{L}\right) (f(x_k) - f^*). \quad \square$$

Ключевой результат

При PL-условии GD сходится **линейно к глобальному минимуму без выпуклости!** Скорость та же, что для сильно выпуклых задач.

Седловые точки и их преодоление

Застревает ли GD на сёдлах?

Вопрос: если GD находит точку с $\nabla f = 0$ — это седло или минимум?

Застревает ли GD на сёдлах?

Вопрос: если GD находит точку с $\nabla f = 0$ — это седло или минимум?

Факт 1: если x_0 точно на седле, $\nabla f(x_0) = 0$ — GD не движется.

Застревает ли GD на сёдлах?

Вопрос: если GD находит точку с $\nabla f = 0$ — это седло или минимум?

Факт 1: если x_0 точно на седле, $\nabla f(x_0) = 0$ — GD не движется.

Факт 2 (теорема Ли и др., 2016): GD из **случайной** инициализации сходится к локальному минимуму **почти наверное** — седла нестабильны.

Застревает ли GD на сёдлах?

Вопрос: если GD находит точку с $\nabla f = 0$ — это седло или минимум?

Факт 1: если x_0 точно на седле, $\nabla f(x_0) = 0$ — GD не движется.

Факт 2 (теорема Ли и др., 2016): GD из **случайной** инициализации сходится к локальному минимуму **почти наверное** — седла нестабильны.

SGD и шум: стохастический градиент $\tilde{g}_k = \nabla f_{i_k}(x_k)$ имеет шум. Этот шум помогает **вырваться** из сёдел.

Perturbed GD: явное добавление шума

Алгоритм (Ge et al., 2015):

if $\| \nabla f(x_k) \| \geq \rho$:

$$x_k = x_k + \xi_k \quad (\xi_k \sim N(0, \sigma^2 I), \sigma \text{ мало})$$

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

Perturbed GD: явное добавление шума

Алгоритм (Ge et al., 2015):

if $\| \nabla f(x_k) \| \geq \rho$:

$$x_k = x_k + \xi_k \quad (\xi \sim N(0, \sigma^2 I), \sigma \text{ мало})$$

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

Гарантия: сходимость к ε -second-order critical point:

$$\| \nabla f(x) \| \leq \varepsilon \quad \text{и} \quad \lambda_{\min}(\nabla^2 f(x)) \geq -\sqrt{\varepsilon}$$

Perturbed GD: явное добавление шума

Алгоритм (Ge et al., 2015):

```
if  $\|\nabla f(x_k)\| \geq \rho$ :  
     $x_k = x_k + \xi_k$  ( $\xi \sim N(0, \sigma^2 I)$ ,  $\sigma$  мало)  
 $x_{k+1} = x_k - \alpha \nabla f(x_k)$ 
```

Гарантия: сходимость к ε -second-order critical point:

$$\|\nabla f(x)\| \leq \varepsilon \quad \text{и} \quad \lambda_{\min}(\nabla^2 f(x)) \geq -\sqrt{\varepsilon}$$

Интуиция: если мы близко к седлу ($\|\nabla f\|$ мало), добавляем шум. Шум «скатывает» с седла по направлению наименьшего собственного значения гессиана.

Кубическая регуляризация (Nesterov-Polyak, 2006)

Идея: вместо квадратичной аппроксимации — кубическая:

$$x_{k+1} = \arg \min_d \left[f(x_k) + \nabla f_k^T d + \frac{1}{2} d^T H_k d + \frac{M}{6} \|d\|^3 \right]$$

Кубическая регуляризация (Nesterov-Polyak, 2006)

Идея: вместо квадратичной аппроксимации — кубическая:

$$x_{k+1} = \arg \min_d \left[f(x_k) + \nabla f_k^T d + \frac{1}{2} d^T H_k d + \frac{M}{6} \|d\|^3 \right]$$

Преимущества:

Метод	Итераций до ε -stationarity	Порядок
GD	$O(L/\varepsilon^2)$	1st-order
Perturbed GD	$O((L/\varepsilon)^{1.75})$	1st-order
Cubic Newton	$O(L/\varepsilon^{1.5})$	2nd-order

Кубическая регуляризация (Nesterov-Polyak, 2006)

Идея: вместо квадратичной аппроксимации — кубическая:

$$x_{k+1} = \arg \min_d \left[f(x_k) + \nabla f_k^T d + \frac{1}{2} d^T H_k d + \frac{M}{6} \|d\|^3 \right]$$

Преимущества:

Метод	Итераций до ε -stationarity	Порядок
GD	$O(L/\varepsilon^2)$	1st-order
Perturbed GD	$O((L/\varepsilon)^{1.75})$	1st-order
Cubic Newton	$O(L/\varepsilon^{1.5})$	2nd-order

Компромисс: кубическая подзадача дороже ($\approx$ одна итерация Ньютона), но сходимость быстрее к second-order critical point.

Ландшафт нейронных сетей

Эмпирические наблюдения

Observation 1: у глубоких сетей почти все локальные минимумы имеют **схожее качество** с глобальным минимумом.

Эмпирические наблюдения

Observation 1: у глубоких сетей почти все локальные минимумы имеют **схожее качество** с глобальным минимумом.

Observation 2: при избыточной параметризации ландшафт потерь **гладкий** — SGD не застревает.

Эмпирические наблюдения

Observation 1: у глубоких сетей почти все локальные минимумы имеют **схожее качество** с глобальным минимумом.

Observation 2: при избыточной параметризации ландшафт потерь **гладкий** — SGD не застревает.

Observation 3: мода хорошей нейросети — это **многомерное плато** (flat minimum), а не острый колодец. Flat minima обобщают лучше!

Эмпирические наблюдения

Observation 1: у глубоких сетей почти все локальные минимумы имеют **схожее качество** с глобальным минимумом.

Observation 2: при избыточной параметризации ландшафт потерь **гладкий** — SGD не застревает.

Observation 3: мода хорошей нейросети — это **многомерное плато** (flat minimum), а не острый колодец. Flat minima обобщают лучше!

Loss Surface Visualization

Goldstein et al. 2018: ResNet-56 (без skip-connections) — хаотичный ландшафт; с skip-connections — гладкий.

Теоретические результаты

1. Линейные сети (Du & Lee, 2018): $\mathcal{L}(\theta) = \|W_L \cdots W_1 X - Y\|^2$ при полном ранге. PL выполнено вблизи оптимума — GD сходится.

Теоретические результаты

1. **Линейные сети** (Du & Lee, 2018): $\mathcal{L}(\theta) = \|W_L \cdots W_1 X - Y\|^2$ при полном ранге. PL выполнено вблизи оптимума — GD сходится.
2. **Overparameterized ReLU сети** (Du et al., 2019): при ширине $m \geq \Omega(n^6/\lambda_0^4)$ (параметров $\gg$ данных):

$$f(x_k) \leq e^{-\eta\lambda_0 k/2} f(x_0)$$

GD с random initialization сходится к **нулевой** потере.

Теоретические результаты

1. **Линейные сети** (Du & Lee, 2018): $\mathcal{L}(\theta) = \|W_L \cdots W_1 X - Y\|^2$ при полном ранге. PL выполнено вблизи оптимума — GD сходится.

2. **Overparameterized ReLU сети** (Du et al., 2019): при ширине $m \geq \Omega(n^6/\lambda_0^4)$ (параметров $\gg$ данных):

$$f(x_k) \leq e^{-\eta\lambda_0 k/2} f(x_0)$$

GD с random initialization сходится к **нулевой** потере.

3. **Neural Tangent Kernel (Jacot et al., 2018)**: при ширине $\rightarrow \infty$ сеть «замораживается» у инициализации — ведёт себя как **линейная модель** с ядром NTK. Задача становится выпуклой!

Batch Normalization и геометрия

BatchNorm (Ioffe & Szegedy, 2015) не только стабилизирует обучение — он **улучшает геометрию** потерь!

Batch Normalization и геометрия

BatchNorm (Ioffe & Szegedy, 2015) не только стабилизирует обучение — он **улучшает геометрию** потерь!

Santurkar et al., 2018: BatchNorm делает ландшафт потерь: - Более гладким (L уменьшается эффективно) - β -гладким (гессиан устойчивее) - PL-условие выполняется чаще

Batch Normalization и геометрия

BatchNorm (Ioffe & Szegedy, 2015) не только стабилизирует обучение — он **улучшает геометрию** потерь!

Santurkar et al., 2018: BatchNorm делает ландшафт потерь: - Более гладким (L уменьшается эффективно) - β -гладким (гессииан устойчивее) - PL-условие выполняется чаще

Практический вывод: большинство трюков в обучении нейросетей (BatchNorm, residual connections, skip-connections) неявно улучшают геометрию оптимизационной задачи.

Итоговая таблица: невыпуклая оптимизация

Условие	Метод	Скорость	Гарантия
L -гладкая	GD	$O(1/\sqrt{k})$	ε -stationarity
L -гладкая	SGD	$O(1/\sqrt{k})$	ε -stationarity
L -гладкая	Perturbed GD	$O(L/\varepsilon^{1.75})$	2nd-order stationarity
L -гладкая	Cubic Newton	$O(L/\varepsilon^{1.5})$	2nd-order stationarity
L -гладкая + PL	GD	$O(e^{-\mu k/L})$	Глобальный минимум!
Overparameterized NN	GD	Линейная (эмпирически)	$f = 0$ (интерполяция)

Итоговая таблица: невыпуклая оптимизация

Условие	Метод	Скорость	Гарантия
L -гладкая	GD	$O(1/\sqrt{k})$	ε -stationarity
L -гладкая	SGD	$O(1/\sqrt{k})$	ε -stationarity
L -гладкая	Perturbed GD	$O(L/\varepsilon^{1.75})$	2nd-order stationarity
L -гладкая	Cubic Newton	$O(L/\varepsilon^{1.5})$	2nd-order stationarity
L -гладкая + PL	GD	$O(e^{-\mu k/L})$	Глобальный минимум!
Overparameterized NN	GD	Линейная (эмпирически)	$f = 0$ (интерполяция)

Главный вывод

Невыпуклость нейросетей «доброкачественная»: избыточная параметризация + SGD + правильная архитектура $\rightarrow$ PL-подобные свойства $\rightarrow$ линейная сходимость на практике.

Практика и примеры

Adam и невыпуклые задачи

Почему Adam работает лучше GD на невыпуклых задачах?

Adam и невыпуклые задачи

Почему Adam работает лучше GD на невыпуклых задачах?

Adaptive learning rates: разные параметры получают разные эффективные шаги.

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) \nabla f(x_k)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) (\nabla f(x_k))^2$$

$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{v_k} + \varepsilon} \cdot m_k$$

Adam и невыпуклые задачи

Почему Adam работает лучше GD на невыпуклых задачах?

Adaptive learning rates: разные параметры получают разные эффективные шаги.

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) \nabla f(x_k)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) (\nabla f(x_k))^2$$

$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{v_k} + \varepsilon} \cdot m_k$$

Интерпретация: $\sqrt{v_k}$ $\boxtimes$ вторая производная (curvature) $\rightarrow$ Adam автоматически уменьшает шаг в «крутых» направлениях.

Adam и невыпуклые задачи

Почему Adam работает лучше GD на невыпуклых задачах?

Adaptive learning rates: разные параметры получают разные эффективные шаги.

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) \nabla f(x_k)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) (\nabla f(x_k))^2$$

$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{v_k} + \varepsilon} \cdot m_k$$

Интерпретация: $\sqrt{v_k}$ $\boxtimes$ вторая производная (curvature) $\rightarrow$ Adam автоматически уменьшает шаг в «крутых» направлениях.

Теоретический статус: сходимость Adam для невыпуклых задач — открытый вопрос. На практике Adam часто лучше GD по скорости, но GD даёт лучшее обобщение (flat minima hypothesis).

Практические рекомендации

Выбор метода для невыпуклой задачи (ML):

Практические рекомендации

Выбор метода для невыпуклой задачи (ML):

Adam / AdamW: стартовый выбор для большинства задач (NLP, vision, RL). Быстрая сходимость. $lr=1e-3$, $weight_decay=0.01$.

Практические рекомендации

Выбор метода для невыпуклой задачи (ML):

Adam / AdamW: стартовый выбор для большинства задач (NLP, vision, RL). Быстрая сходимость. $lr=1e-3$, $weight_decay=0.01$.

SGD + momentum: часто лучше Adam по конечной точности (обобщению) при правильном расписании шагов. $lr=0.1 \rightarrow 0.001$.

Практические рекомендации

Выбор метода для невыпуклой задачи (ML):

Adam / AdamW: стартовый выбор для большинства задач (NLP, vision, RL). Быстрая сходимость. $lr=1e-3$, $weight_decay=0.01$.

SGD + momentum: часто лучше Adam по конечной точности (обобщению) при правильном расписании шагов. $lr=0.1 \rightarrow 0.001$.

Learning rate schedule: cosine annealing / linear warmup $\rightarrow$ cosine — стандарт для LLM.

Практические рекомендации

Выбор метода для невыпуклой задачи (ML):

Adam / AdamW: стартовый выбор для большинства задач (NLP, vision, RL). Быстрая сходимость. $lr=1e-3$, $weight_decay=0.01$.

SGD + momentum: часто лучше Adam по конечной точности (обобщению) при правильном расписании шагов. $lr=0.1 \rightarrow 0.001$.

Learning rate schedule: cosine annealing / linear warmup $\rightarrow$ cosine — стандарт для LLM.

Эмпирическое правило

Adam для быстрого старта. SGD + cosine schedule — для наилучшего конечного качества.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.
3. Сёдла нестабильны: GD из случайной инициализации обходит их почти наверное. SGD-шум ускоряет escape.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.
3. Сёдла нестабильны: GD из случайной инициализации обходит их почти наверное. SGD-шум ускоряет escape.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.
3. Сёдла нестабильны: GD из случайной инициализации обходит их почти наверное. SGD-шум ускоряет escape.
4. Нейросети при избыточной параметризации имеют «добрый» ландшафт: PL-условие, flat minima, NTK.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.
3. Сёдла нестабильны: GD из случайной инициализации обходит их почти наверное. SGD-шум ускоряет escape.
4. Нейросети при избыточной параметризации имеют «добрый» ландшафт: PL-условие, flat minima, NTK.

Резюме лекции

Ключевые идеи:

1. Для L -гладкой невыпуклой функции GD находит ε -стационарную точку за $O(1/\varepsilon^2)$ итераций.
2. Условие PL (без выпуклости!) гарантирует линейную сходимость GD к **глобальному минимуму**.
3. Сёдла нестабильны: GD из случайной инициализации обходит их почти наверное. SGD-шум ускоряет escape.
4. Нейросети при избыточной параметризации имеют «добрый» ландшафт: PL-условие, flat minima, NTK.
5. BatchNorm / residual connections улучшают геометрию — не только стабилизируют, но и ускоряют сходимость.