



**Адаптивные методы. Методы матричной
оптимизации на основе ортогонализации.
Shampoo, Muon.**

Даня Меркулов

ФКН ВШЭ

Адаптивные стохастические методы

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях;

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях;
 - в embedding-слое строка редкого слова получает ненулевой градиент только когда это слово попало в батч — в отличие от плотных слоёв, где все параметры обновляются на каждом шаге.

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях;
 - в embedding-слое строка редкого слова получает ненулевой градиент только когда это слово попало в батч — в отличие от плотных слоёв, где все параметры обновляются на каждом шаге.
- Идея адаптивных методов — **подобрать свой эффективный шаг каждой координате**, опираясь на накопленную историю градиентов.

Почему нужна адаптивность

- Единый скаляр α — плохой выбор, когда **разные координаты** имеют существенно разные масштабы:
 - редкие признаки в логистической регрессии и NLP-моделях;
 - в embedding-слое строка редкого слова получает ненулевой градиент только когда это слово попало в батч — в отличие от плотных слоёв, где все параметры обновляются на каждом шаге.
- Идея адаптивных методов — **подобрать свой эффективный шаг каждой координате**, опираясь на накопленную историю градиентов.
- Содержательно это можно трактовать как грубое приближение диагонали гессиана (или информационной матрицы Фишера).

Adagrad ¹

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.

Adagrad ¹

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.

Adagrad ¹

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.
- Заметно улучшает SGD в разреженных задачах (NLP, рекомендательные системы).

Adagrad ¹

Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$. Обновление для каждой координаты $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- Не требует тонкой настройки α — эффективный шаг убывает автоматически по каждой координате.
- Для редких, но информативных признаков шаг убывает медленно — алгоритм даёт им «работать» дольше.
- Заметно улучшает SGD в разреженных задачах (NLP, рекомендательные системы).
- Главная слабость — **монотонное** накопление в знаменателе: эффективный шаг $\rightarrow 0$ слишком рано, и обучение «затухает».

¹  Duchi, Hazan, Singer (2010). Adaptive Subgradient Methods for Online Learning and Stochastic Optimization.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — скользящее среднее квадратов градиентов (RMS): «забывает» старые градиенты, в отличие от монотонного накопления в AdaGrad.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) \left(g_j^{(k)}\right)^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — скользящее среднее квадратов градиентов (RMS): «забывает» старые градиенты, в отличие от монотонного накопления в AdaGrad.
- Эффективный шаг может как убывать, так и возрасть — подходит для нестационарных задач.

Решает проблему монотонно убывающей скорости обучения. Использует экспоненциально затухающее среднее квадратов градиентов:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Замечания:

- В знаменателе — скользящее среднее квадратов градиентов (RMS): «забывает» старые градиенты, в отличие от монотонного накопления в AdaGrad.
- Эффективный шаг может как убывать, так и возрасть — подходит для нестационарных задач.
- Долгое время был выбором по умолчанию при обучении рекуррентных сетей.

²  Tieleman, Hinton (2012). Coursera Lecture 6.

Развитие RMSProp: вообще **не требует** глобального шага α . Вместо него масштабирует шаг через накопленные обновления параметров:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) \left(g_j^{(k)}\right)^2$$

$$\tilde{g}_j^{(k)} = \frac{\sqrt{\Delta x_j^{(k-1)} + \varepsilon}}{\sqrt{v_j^{(k)} + \varepsilon}} g_j^{(k)}$$

$$x_j^{(k)} = x_j^{(k-1)} - \tilde{g}_j^{(k)}, \quad \Delta x_j^{(k)} = \rho \Delta x_j^{(k-1)} + (1 - \rho) \left(\tilde{g}_j^{(k)}\right)^2$$

Замечания:

- Числитель $\sqrt{\Delta x_j^{(k-1)} + \varepsilon}$ имеет те же единицы, что и параметр — шаг автоматически согласован по масштабу.

Развитие RMSProp: вообще **не требует** глобального шага α . Вместо него масштабирует шаг через накопленные обновления параметров:

$$v_j^{(k)} = \gamma v_j^{(k-1)} + (1 - \gamma) (g_j^{(k)})^2$$

$$\tilde{g}_j^{(k)} = \frac{\sqrt{\Delta x_j^{(k-1)} + \varepsilon}}{\sqrt{v_j^{(k)} + \varepsilon}} g_j^{(k)}$$

$$x_j^{(k)} = x_j^{(k-1)} - \tilde{g}_j^{(k)}, \quad \Delta x_j^{(k)} = \rho \Delta x_j^{(k-1)} + (1 - \rho) (\tilde{g}_j^{(k)})^2$$

Замечания:

- Числитель $\sqrt{\Delta x_j^{(k-1)} + \varepsilon}$ имеет те же единицы, что и параметр — шаг автоматически согласован по масштабу.
- Полезен, когда масштабы параметров между слоями существенно различаются.

³  Zeiler (2012). ADADELTA: An Adaptive Learning Rate Method.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.
- Не сходится для некоторых простых задач (даже выпуклых).

Комбинирует элементы AdaGrad и RMSProp. Экспоненциально затухающее среднее градиентов и квадратов градиентов:

EMA:
$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$
$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

Коррекция:
$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$$
$$\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

Обновление:
$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon}$$

Замечания:

- Корректирует смещение моментов к нулю на старте.
- Одна из самых цитируемых работ в области ML.
- Не сходится для некоторых простых задач (даже выпуклых).
- Гораздо лучше работает для языковых моделей, чем для задач компьютерного зрения — открытый вопрос «почему».

⁴  Kingma, Ba (2014). Adam: A Method for Stochastic Optimization.

⁵  Reddi, Kale, Kumar (2018). On the Convergence of Adam and Beyond.

Решает проблему ℓ_2 -регуляризации в адаптивных оптимизаторах. При стандартном подходе ℓ_2 -регуляризация добавляет $\lambda\|x\|^2$ к функции потерь, порождая градиентный член λx . В Adam этот член делится на $(\sqrt{\hat{v}_j} + \varepsilon)$ — сила регуляризации оказывается зависимой от магнитуд градиентов, что нежелательно.

AdamW **разделяет** weight decay и адаптацию градиентов:

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon} + \lambda x_j^{(k-1)} \right)$$

Замечания:

- Член weight decay $\lambda x_j^{(k-1)}$ добавляется *после* адаптивного градиентного шага и не масштабируется на $\sqrt{\hat{v}_j}$.

Решает проблему ℓ_2 -регуляризации в адаптивных оптимизаторах. При стандартном подходе ℓ_2 -регуляризация добавляет $\lambda\|x\|^2$ к функции потерь, порождая градиентный член λx . В Adam этот член делится на $(\sqrt{\hat{v}_j} + \varepsilon)$ — сила регуляризации оказывается зависимой от магнитуд градиентов, что нежелательно.

AdamW **разделяет** weight decay и адаптацию градиентов:

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \varepsilon} + \lambda x_j^{(k-1)} \right)$$

Замечания:

- Член weight decay $\lambda x_j^{(k-1)}$ добавляется *после* адаптивного градиентного шага и не масштабируется на $\sqrt{\hat{v}_j}$.
- Широко используется при обучении трансформеров и больших моделей; выбор по умолчанию в HuggingFace Trainer.

⁶  Loshchilov, Hutter (2017). Decoupled Weight Decay Regularization.

Adam не сходится: постановка ⁷

Рассмотрим **простейшую** возможную задачу — выпуклую, гладкую, сильно выпуклую, с единственным глобальным минимумом в нуле:

$$L(w) = w^2, \quad \nabla L(w) = 2w, \quad w \in \mathbb{R}.$$

Обновление Adam (одномерный случай, без коррекции смещения и для упрощения $\varepsilon = 0$):

$$\begin{aligned} g_t &= 2w_{t-1}, \\ m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ w_t &= w_{t-1} - \eta \frac{m_t}{\sqrt{v_t}}. \end{aligned}$$

⁷  Reddi et al. (2018). On the Convergence of Adam and Beyond.

Adam не сходится: постановка ⁷

Рассмотрим **простейшую** возможную задачу — выпуклую, гладкую, сильно выпуклую, с единственным глобальным минимумом в нуле:

$$L(w) = w^2, \quad \nabla L(w) = 2w, \quad w \in \mathbb{R}.$$

Обновление Adam (одномерный случай, без коррекции смещения и для упрощения $\varepsilon = 0$):

$$\begin{aligned} g_t &= 2w_{t-1}, \\ m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ w_t &= w_{t-1} - \eta \frac{m_t}{\sqrt{v_t}}. \end{aligned}$$

Чего мы **ждём** от корректного метода: $w_t \rightarrow 0$ и длина шага $|w_t - w_{t-1}| \rightarrow 0$ по мере приближения к оптимуму. У GD с $\eta < 1/2$ это так: $w_t = (1 - 2\eta)w_{t-1}$, экспоненциальная сходимость.

Покажем, что у Adam **этого не происходит**.

⁷  Reddi et al. (2018). On the Convergence of Adam and Beyond.

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

v_t — **квадратичен по w** . Сумма прошлых $g_\tau^2 = 4w_{\tau-1}^2$, каждый член квадратичен:

$$v_t = (1 - \beta_2) \sum_{\tau \leq t} \beta_2^{t-\tau} 4w_{\tau-1}^2 \propto w^2.$$

Adam не сходится: анализ масштаба при малых $|w|$

Предположим, что итерации находятся в окрестности нуля и величина $|w_t|$ ведёт себя как масштаб $|w| \rightarrow 0$.
Что происходит с m_t и v_t ?

m_t — **линеен по w** . Это сумма (взвешенная) прошлых градиентов $g_\tau = 2w_{\tau-1}$, каждый из которых линеен по w :

$$m_t = (1 - \beta_1) \sum_{\tau \leq t} \beta_1^{t-\tau} 2w_{\tau-1} \propto w.$$

v_t — **квадратичен по w** . Сумма прошлых $g_\tau^2 = 4w_{\tau-1}^2$, каждый член квадратичен:

$$v_t = (1 - \beta_2) \sum_{\tau \leq t} \beta_2^{t-\tau} 4w_{\tau-1}^2 \propto w^2.$$

Следовательно:

$$\sqrt{v_t} \propto |w| \quad \Rightarrow \quad \frac{m_t}{\sqrt{v_t}} \approx \text{sign}(w) = \pm 1$$

Это отношение **не зависит** от $|w|$: какой бы маленькой ни стала итерация, нормированный градиент остаётся порядка единицы.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Получаем **предельный цикл**:

$$w_t \in \{-\eta/2, +\eta/2\}, \quad t \rightarrow \infty.$$

Метод **не сходится** ни к точке, ни даже к нулю по среднему.

Adam не сходится: предельный цикл

Из предыдущего шага: шаг Adam в окрестности нуля имеет постоянную **по модулю** длину

$$|w_t - w_{t-1}| = \eta \left| \frac{m_t}{\sqrt{v_t}} \right| \approx \eta,$$

независимо от того, насколько w близко к оптимуму.

Что это означает. Если $|w_{t-1}| < \eta/2$, то шаг $\pm\eta$ «перепрыгивает» через ноль и оказывается с противоположной стороны на расстоянии $\approx \eta/2$. На следующем шаге — обратно.

Получаем **предельный цикл**:

$$w_t \in \{-\eta/2, +\eta/2\}, \quad t \rightarrow \infty.$$

Метод **не сходится** ни к точке, ни даже к нулю по среднему.

Сравнение с SGD. Для $L(w) = w^2$ обновление SGD:

$$w_t = w_{t-1} - \eta \cdot 2w_{t-1} = (1 - 2\eta)w_{t-1}.$$

Шаг **пропорционален** w , обнуляется в пределе $\Rightarrow$ сходимость.

Adam не сходится: иллюстрация





Figure 1: GD сходится к нулю, Adam выходит на предельный цикл амплитуды $\sim \alpha/2$.

Как сравнивать оптимизаторы в задачах машинного обучения

Много оптимизаторов — как сравнивать?

Rosenbrock Function.
Adaptive stochastic gradient algorithms.
Learning rate 0.003



AlgoPerf benchmark ⁸

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:

AlgoPerf benchmark ⁸

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);

AlgoPerf benchmark ⁸

- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).


- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).
- **Оценка** агрегируется через профили производительности; финальный балл — нормализованная площадь под профилем (1.0 = быстрееший на всех задачах).

AlgoPerf benchmark ⁸


- **AlgoPerf** — стандартизированный бенчмарк для сравнения алгоритмов обучения нейросетей по двум регламентам:
 - **External Tuning** — подбор гиперпараметров с ограниченными ресурсами (5 попыток);
 - **Self-Tuning** — автоматическая настройка на одной машине (3× бюджет).
- **Оценка** агрегируется через профили производительности; финальный балл — нормализованная площадь под профилем (1.0 = быстрееший на всех задачах).
- **Стоимость** оценки: $\sim 49\,240$ часов работы на 8 NVIDIA V100 GPU.

⁸  Dahl et al. (2023). Benchmarking Neural Network Training Algorithms.

AlgoPerf benchmark: результаты



NanoGPT speedrun ⁹



⁹ Источник

Работают ли трюки, если увеличить размер модели?

Scaling up the NanoGPT (124M) speedrun




Figure 2:  Источник

Сравнение оптимизаторов на NanoGPT speedrun




Figure 3: По числу токенов






Figure 4: По wallclock time (8×H100)

Муон (фиолетовый) — лучший по обоим метрикам: быстрая сходимость по токенам и самый дешёвый по времени (142 ms/step).

Muon

Новый подход к оптимизации ¹⁰



Модели, отмеченные звёздочкой, были обучены методом Muon, остальные модели были обучены другими алгоритмами оптимизации.

$$\min_{x \in \mathbb{R}^p} f(x)$$

$$f(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \mathcal{O}(\|x - x_k\|_2^2).$$

Функция потерь

$$\min_{x \in \mathbb{R}^p} f(x)$$


$$f(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \mathcal{O}(\|x - x_k\|_2^2).$$

$$\min_{x \in \mathbb{R}^p} f(x)$$

Функция потерь



$$f(x) = \underbrace{f(x_k) + \langle \nabla f(x_k), x - x_k \rangle}_{\text{Линейная аппроксимация}} + \mathcal{O}(\|x - x_k\|_2^2).$$

Линейная
аппроксимация



Функция потерь

$$\min_{x \in \mathbb{R}^p} f(x)$$

$$f(x) = \underbrace{f(x_k) + \langle \nabla f(x_k), x - x_k \rangle}_{\text{Линейная аппроксимация}} + \mathcal{O}(\|x - x_k\|_2^2).$$

Линейная
аппроксимация

Хорошее приближение
в окрестности x_k

Интуиция за методом Muon. Градиентный спуск

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right)$$

Интуиция за методом Муон. Градиентный спуск

$$\begin{aligned}x_{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right) \\ &= x_k - \alpha \nabla f(x_k)\end{aligned}$$

Интуиция за методом Муон. Градиентный спуск

Штраф за
дальность от x_k

$$\begin{aligned}x_{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right) \\ &= x_k - \alpha \nabla f(x_k)\end{aligned}$$


Интуиция за методом Muon. Градиентный спуск

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right)$$

$$= x_k - \alpha \nabla f(x_k)$$

Шаг обучения /
коэффициент регуляризации

Штраф за
дальность от x_k



Интуиция за методом Muon. Нормированный градиентный спуск

$$x_{k+1} = \operatorname{argmin}_{\|x - x_k\|_2 = \alpha} (f(x_k) + \langle \nabla f(x_k), x - x_k \rangle)$$

Интуиция за методом Муон. Нормированный градиентный спуск

$$\begin{aligned}x_{k+1} &= \operatorname{argmin}_{\|x - x_k\|_2 = \alpha} (f(x_k) + \langle \nabla f(x_k), x - x_k \rangle) \\&= x_k - \alpha \frac{\nabla f(x_k)}{\|\nabla f(x_k)\|_2}\end{aligned}$$

Интуиция за методом Муон. Нормированный градиентный спуск

$$\begin{aligned}x_{k+1} &= \operatorname{argmin}_{\|x - x_k\|_2 = \alpha} (f(x_k) + \langle \nabla f(x_k), x - x_k \rangle) \\ &= x_k - \alpha \frac{\nabla f(x_k)}{\|\nabla f(x_k)\|_2}\end{aligned}$$



Ограничение на длину шага

Интуиция за методом Muon. Нормированный градиентный спуск

$$\begin{aligned}x_{k+1} &= \operatorname{argmin}_{\|x - x_k\|_2 = \alpha} (f(x_k) + \langle \nabla f(x_k), x - x_k \rangle) \\&= x_k - \alpha \frac{\nabla f(x_k)}{\|\nabla f(x_k)\|_2}\end{aligned}$$

Ограничение на длину шага

Параметр ограничения / шаг обучения



Что насчёт других норм?




Figure 5: Примеры шаров в разных нормах

Для неевклидовых норм нужно ввести несколько определений

- Сопряжённая норма:

$$\|g\|^* = \sup_{\|x\|=1} \langle g, x \rangle$$

Для неевклидовых норм нужно ввести несколько определений

- Сопряжённая норма:

$$\|g\|^* = \sup_{\|x\|=1} \langle g, x \rangle$$

- Linear Minimization Oracle:

$$\text{LMO}_{\|\cdot\|}(g) = \underset{\|x\|=1}{\operatorname{argmin}} \langle g, x \rangle$$

Для неевклидовых норм нужно ввести несколько определений

- Сопряжённая норма:

$$\|g\|^* = \sup_{\|x\|=1} \langle g, x \rangle$$

- Linear Minimization Oracle:

$$\text{LMO}_{\|\cdot\|}(g) = \underset{\|x\|=1}{\operatorname{argmin}} \langle g, x \rangle$$

- Важное свойство, связывающее эти два понятия:

$$\langle g, \text{LMO}_{\|\cdot\|}(g) \rangle = -\|g\|^*$$

! Неевклидов градиентный спуск

Для вектора градиента $g = \nabla f(x_k)$ и шага $\alpha > 0$:

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle g, x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|^2 \right) = x_k + \alpha \|g\|^* \operatorname{LMO}_{\|\cdot\|}(g)$$

! Неевклидов градиентный спуск

Для вектора градиента $g = \nabla f(x_k)$ и шага $\alpha > 0$:

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^p} \left(f(x_k) + \langle g, x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|^2 \right) = x_k + \alpha \|g\|^* \operatorname{LMO}_{\|\cdot\|}(g)$$

! Неевклидов нормированный градиентный спуск

Для вектора градиента $g = \nabla f(x_k)$ и шага $\alpha > 0$:

$$x_{k+1} = \operatorname{argmin}_{\|x - x_k\| = \alpha} (f(x_k) + \langle g, x - x_k \rangle) = x_k + \alpha \operatorname{LMO}_{\|\cdot\|}(g)$$

Вывод: неевклидов градиентный спуск

$$\min_{d \in \mathbb{R}^p} \left(\langle g, d \rangle + \frac{1}{2\alpha} \|d\|^2 \right)$$

Вывод: неевклидов градиентный спуск

$$\min_{d \in \mathbb{R}^p} \left(\langle g, d \rangle + \frac{1}{2\alpha} \|d\|^2 \right)$$

Подставим $d = r \cdot u$, где $\|u\| = 1$, $r \geq 0$:

$$\min_{r \geq 0, \|u\|=1} \left(r \langle g, u \rangle + \frac{r^2}{2\alpha} \right)$$

Вывод: неевклидов градиентный спуск

$$\min_{d \in \mathbb{R}^p} \left(\langle g, d \rangle + \frac{1}{2\alpha} \|d\|^2 \right)$$

Подставим $d = r \cdot u$, где $\|u\| = 1$, $r \geq 0$:

$$\min_{r \geq 0, \|u\|=1} \left(r \langle g, u \rangle + \frac{r^2}{2\alpha} \right)$$

При фиксированном u оптимальное $r^* = -\alpha \langle g, u \rangle$ (при $\langle g, u \rangle < 0$). Подставляя:

$$-\frac{\alpha}{2} \langle g, u \rangle^2 \rightarrow \min_{\|u\|=1}$$

Вывод: неевклидов градиентный спуск

$$\min_{d \in \mathbb{R}^p} \left(\langle g, d \rangle + \frac{1}{2\alpha} \|d\|^2 \right)$$

Подставим $d = r \cdot u$, где $\|u\| = 1$, $r \geq 0$:

$$\min_{r \geq 0, \|u\|=1} \left(r \langle g, u \rangle + \frac{r^2}{2\alpha} \right)$$

При фиксированном u оптимальное $r^* = -\alpha \langle g, u \rangle$ (при $\langle g, u \rangle < 0$). Подставляя:

$$-\frac{\alpha}{2} \langle g, u \rangle^2 \rightarrow \min_{\|u\|=1}$$

Максимум $\langle g, u \rangle^2$ при $\|u\| = 1$ достигается на $u^* = \text{LMO}_{\|\cdot\|}(g)$, где $\langle g, u^* \rangle = -\|g\|^*$:

$$d^* = \alpha \|g\|^* \cdot \text{LMO}_{\|\cdot\|}(g) \implies x_{k+1} = x_k + \alpha \|g\|^* \text{LMO}_{\|\cdot\|}(g)$$

Вывод: неевклидов нормированный градиентный спуск

$$\min_{\|d\|=\alpha} \langle g, d \rangle$$

Вывод: неевклидов нормированный градиентный спуск

$$\min_{\|d\|=\alpha} \langle g, d \rangle$$

Подставим $d = \alpha u$, где $\|u\| = 1$:

$$\min_{\|u\|=1} \alpha \langle g, u \rangle = \alpha \cdot \min_{\|u\|=1} \langle g, u \rangle$$

Вывод: неевклидов нормированный градиентный спуск

$$\min_{\|d\|=\alpha} \langle g, d \rangle$$

Подставим $d = \alpha u$, где $\|u\| = 1$:

$$\min_{\|u\|=1} \alpha \langle g, u \rangle = \alpha \cdot \min_{\|u\|=1} \langle g, u \rangle$$

По определению $\text{LMO}_{\|\cdot\|}(g) = \operatorname{argmin}_{\|u\|=1} \langle g, u \rangle$:

$$d^* = \alpha \cdot \text{LMO}_{\|\cdot\|}(g) \implies x_{k+1} = x_k + \alpha \text{LMO}_{\|\cdot\|}(g)$$

Вывод: неевклидов нормированный градиентный спуск

$$\min_{\|d\|=\alpha} \langle g, d \rangle$$

Подставим $d = \alpha u$, где $\|u\| = 1$:

$$\min_{\|u\|=1} \alpha \langle g, u \rangle = \alpha \cdot \min_{\|u\|=1} \langle g, u \rangle$$

По определению $\text{LMO}_{\|\cdot\|}(g) = \operatorname{argmin}_{\|u\|=1} \langle g, u \rangle$:

$$d^* = \alpha \cdot \text{LMO}_{\|\cdot\|}(g) \implies x_{k+1} = x_k + \alpha \text{LMO}_{\|\cdot\|}(g)$$

Сравнение: градиентный спуск масштабирует шаг на $\|g\|^*$ (зависит от величины градиента), нормированный — нет (фиксированная длина шага α).

В нейросетях параметры — матрицы

- В линейных слоях, attention, embedding-слоях параметр — матрица весов

$$W \in \mathbb{R}^{d \times n}, \quad G_k = \nabla_W f(W_k) \in \mathbb{R}^{d \times n}.$$

В нейросетях параметры — матрицы

- В линейных слоях, attention, embedding-слоях параметр — матрица весов

$$W \in \mathbb{R}^{d \times n}, \quad G_k = \nabla_W f(W_k) \in \mathbb{R}^{d \times n}.$$

- Естественно использовать **матричные нормы**: операторную $\|\cdot\|_{\text{op}}$, ядерную $\|\cdot\|_{\text{нuc}}$, Фробениуса $\|\cdot\|_F$ и т.п.

В нейросетях параметры — матрицы

- В линейных слоях, attention, embedding-слоях параметр — матрица весов

$$W \in \mathbb{R}^{d \times n}, \quad G_k = \nabla_W f(W_k) \in \mathbb{R}^{d \times n}.$$

- Естественно использовать **матричные нормы**: операторную $\|\cdot\|_{\text{op}}$, ядерную $\|\cdot\|_{\text{нuc}}$, Фробениуса $\|\cdot\|_F$ и т.п.
- Вся логика переносится: вместо вектора ищем «лучшее направление спуска» среди матриц заданной нормы.

В нейросетях параметры — матрицы

- В линейных слоях, attention, embedding-слоях параметр — матрица весов

$$W \in \mathbb{R}^{d \times n}, \quad G_k = \nabla_W f(W_k) \in \mathbb{R}^{d \times n}.$$

- Естественно использовать **матричные нормы**: операторную $\|\cdot\|_{\text{op}}$, ядерную $\|\cdot\|_{\text{нuc}}$, Фробениуса $\|\cdot\|_F$ и т.п.
- Вся логика переносится: вместо вектора ищем «лучшее направление спуска» среди матриц заданной нормы.
- Скалярное произведение:

$$\langle A, B \rangle := \text{tr}(A^\top B) = \sum_{ij} A_{ij} B_{ij}.$$

Неевклидов нормированный спуск для матриц

Пусть заданы матричная норма $\|\cdot\|$ и шаг $\lambda > 0$. Тогда нормированный шаг по матрице W :

$$W_{k+1} = \operatorname{argmin}_{\|W - W_k\| = \lambda} \left(f(W_k) + \langle G_k, W - W_k \rangle \right)$$

Неевклидов нормированный спуск для матриц

Пусть заданы матричная норма $\|\cdot\|$ и шаг $\lambda > 0$. Тогда нормированный шаг по матрице W :

$$W_{k+1} = \operatorname{argmin}_{\|W - W_k\| = \lambda} \left(f(W_k) + \langle G_k, W - W_k \rangle \right)$$

Подставим $D = W - W_k$, $\|D\| = \lambda$, $D = \lambda U$, $\|U\| = 1$:

$$\min_{\|U\|=1} \lambda \langle G_k, U \rangle = \lambda \langle G_k, \operatorname{LMO}_{\|\cdot\|}(G_k) \rangle$$

Неевклидов нормированный спуск для матриц

Пусть заданы матричная норма $\|\cdot\|$ и шаг $\lambda > 0$. Тогда нормированный шаг по матрице W :

$$W_{k+1} = \operatorname{argmin}_{\|W - W_k\| = \lambda} \left(f(W_k) + \langle G_k, W - W_k \rangle \right)$$

Подставим $D = W - W_k$, $\|D\| = \lambda$, $D = \lambda U$, $\|U\| = 1$:

$$\min_{\|U\|=1} \lambda \langle G_k, U \rangle = \lambda \langle G_k, \operatorname{LMO}_{\|\cdot\|}(G_k) \rangle$$

$$W_{k+1} = W_k + \lambda \operatorname{LMO}_{\|\cdot\|}(G_k)$$

Неевклидов нормированный спуск для матриц

Пусть заданы матричная норма $\|\cdot\|$ и шаг $\lambda > 0$. Тогда нормированный шаг по матрице W :

$$W_{k+1} = \operatorname{argmin}_{\|W - W_k\| = \lambda} \left(f(W_k) + \langle G_k, W - W_k \rangle \right)$$

Подставим $D = W - W_k$, $\|D\| = \lambda$, $D = \lambda U$, $\|U\| = 1$:

$$\min_{\|U\|=1} \lambda \langle G_k, U \rangle = \lambda \langle G_k, \operatorname{LMO}_{\|\cdot\|}(G_k) \rangle$$

$$W_{k+1} = W_k + \lambda \operatorname{LMO}_{\|\cdot\|}(G_k)$$

где

$$\operatorname{LMO}_{\|\cdot\|}(G) = \operatorname{argmin}_{\|W\|=1} \langle G, W \rangle$$

— тот же самый LMO, только теперь он ищет **матрицу** единичной нормы, дающую наибольшее убывание линейного приближения.

Операторная норма и быстрый расчёт (UV^T)

Рассмотрим операторную (спектральную) норму $\|\cdot\|_{\text{op}}$. Пусть

$$G_k = U\Sigma V^T$$

— редуцированное SVD градиента. Тогда

- LMO по операторной норме:

$$\text{LMO}_{\|\cdot\|}(G) = -UV^T,$$

то есть оптимальное направление — **полярный фактор** матрицы G_k (ортогональная часть полярного разложения $G = UP$).

Операторная норма и быстрый расчёт ($UV^\top$)

Рассмотрим операторную (спектральную) норму $\|\cdot\|_{\text{op}}$. Пусть

$$G_k = U\Sigma V^\top$$

— редуцированное SVD градиента. Тогда

- LMO по операторной норме:

$$\text{LMO}_{\|\cdot\|}(G) = -UV^\top,$$

то есть оптимальное направление — **полярный фактор** матрицы G_k (ортогональная часть полярного разложения $G = UP$).

- Проблема: полное SVD стоит $O(d^3)$ на каждом шаге. Но нам нужен только произведение $UV^\top$, а не сами U , Σ , V по отдельности.

Операторная норма и быстрый расчёт ($UV^\top$)

Рассмотрим операторную (спектральную) норму $\|\cdot\|_{\text{op}}$. Пусть

$$G_k = U\Sigma V^\top$$

— редуцированное SVD градиента. Тогда

- LMO по операторной норме:

$$\text{LMO}_{\|\cdot\|}(G) = -UV^\top,$$

то есть оптимальное направление — **полярный фактор** матрицы G_k (ортогональная часть полярного разложения $G = UP$).

- Проблема: полное SVD стоит $O(d^3)$ на каждом шаге. Но нам нужен только произведение $UV^\top$, а не сами U , Σ , V по отдельности.
- Итерации **Newton–Schulz** используют только матричные умножения и дают приближение $UV^\top$ за 5–10 шагов — снимают вычислительное узкое место Muon.

Муон: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

Муон: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

- **SGD** (норма Фробениуса): $D^* = -G/\|G\|_F$ — направление $\propto$ градиенту

Муон: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

- **SGD** (норма Фробениуса): $D^* = -G/\|G\|_F$ — направление $\propto$ градиенту
- **SignGD** (ℓ_∞ -норма): $D^* = -\text{sign}(G)$ — знак каждого элемента

Muon: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

- **SGD** (норма Фробениуса): $D^* = -G/\|G\|_F$ — направление $\propto$ градиенту
- **SignGD** (ℓ_∞ -норма): $D^* = -\text{sign}(G)$ — знак каждого элемента
- **Muon** (спектральная норма): $D^* = -UV^\top$ — полярный фактор градиента

Муон: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

- **SGD** (норма Фробениуса): $D^* = -G/\|G\|_F$ — направление $\propto$ градиенту
- **SignGD** (ℓ_∞ -норма): $D^* = -\text{sign}(G)$ — знак каждого элемента
- **Муон** (спектральная норма): $D^* = -UV^\top$ — полярный фактор градиента

¹³  J. Bernstein “Deriving Muon”. 2025.

¹⁴  Kovalev, D. (2025). Understanding Gradient Orthogonalization.

Муон: вывод через наискорейший спуск в спектральной норме ^{13 14}

Задача наискорейшего спуска для матричного параметра W :

$$D^* = \arg \min_{\|D\|_\sigma \leq 1} \text{tr} [\nabla L(W)^\top D]$$

где $\|\cdot\|_\sigma$ — спектральная норма (максимальное сингулярное число).

- **SGD** (норма Фробениуса): $D^* = -G/\|G\|_F$ — направление $\propto$ градиенту
- **SignGD** (ℓ_∞ -норма): $D^* = -\text{sign}(G)$ — знак каждого элемента
- **Muon** (спектральная норма): $D^* = -UV^\top$ — полярный фактор градиента

Двойственная норма к спектральной — **ядерная** (сумма сингулярных чисел):

$$\|G\|_* = \sum_i \sigma_i(G), \quad \arg \min_{\|D\|_\sigma \leq 1} \langle G, D \rangle = -UV^\top$$

¹³  J. Bernstein “Deriving Muon”. 2025.

¹⁴  Kovalev, D. (2025). Understanding Gradient Orthogonalization.

Вывод: SGD как наискорейший спуск в норме Фробениуса

$$D^* = \operatorname{argmin}_{\|D\|_F \leq 1} \langle G, D \rangle$$

Вывод: SGD как наискорейший спуск в норме Фробениуса

$$D^* = \operatorname{argmin}_{\|D\|_F \leq 1} \langle G, D \rangle$$

Двойственная норма к $\|\cdot\|_F$ — это $\|\cdot\|_F$ (норма Фробениуса самосопряжена):

$$\|G\|_F^* = \sup_{\|D\|_F=1} \langle G, D \rangle = \|G\|_F$$

Вывод: SGD как наискорейший спуск в норме Фробениуса

$$D^* = \operatorname{argmin}_{\|D\|_F \leq 1} \langle G, D \rangle$$

Двойственная норма к $\|\cdot\|_F$ — это $\|\cdot\|_F$ (норма Фробениуса самосопряжена):

$$\|G\|_F^* = \sup_{\|D\|_F=1} \langle G, D \rangle = \|G\|_F$$

$\text{LMO}_{\|\cdot\|_F}(G)$: ищем $\|D\|_F = 1$, минимизирующую $\langle G, D \rangle$. Решение по Коши–Шварцу:

$$D^* = -\frac{G}{\|G\|_F}$$

Вывод: SGD как наискорейший спуск в норме Фробениуса

$$D^* = \operatorname{argmin}_{\|D\|_F \leq 1} \langle G, D \rangle$$

Двойственная норма к $\|\cdot\|_F$ — это $\|\cdot\|_F$ (норма Фробениуса самосопряжена):

$$\|G\|_F^* = \sup_{\|D\|_F=1} \langle G, D \rangle = \|G\|_F$$

$\operatorname{LMO}_{\|\cdot\|_F}(G)$: ищем $\|D\|_F = 1$, минимизирующую $\langle G, D \rangle$. Решение по Коши–Шварцу:

$$D^* = -\frac{G}{\|G\|_F}$$

$$W_{k+1} = W_k - \alpha \frac{G_k}{\|G_k\|_F} = \text{нормированный SGD}$$

Вывод: SignGD как наискорейший спуск в ℓ_∞ -норме

$$D^* = \operatorname{argmin}_{\|D\|_\infty \leq 1} \langle G, D \rangle = \operatorname{argmin}_{\max_{ij} |D_{ij}| \leq 1} \sum_{ij} G_{ij} D_{ij}$$

Вывод: SignGD как наискорейший спуск в ℓ_∞ -норме

$$D^* = \operatorname{argmin}_{\|D\|_\infty \leq 1} \langle G, D \rangle = \operatorname{argmin}_{\max_{ij} |D_{ij}| \leq 1} \sum_{ij} G_{ij} D_{ij}$$

Каждый элемент D_{ij} независимо ограничен $|D_{ij}| \leq 1$. Минимум $G_{ij} D_{ij}$ достигается при:

$$D_{ij}^* = -\operatorname{sign}(G_{ij})$$

Вывод: SignGD как наискорейший спуск в ℓ_∞ -норме

$$D^* = \operatorname{argmin}_{\|D\|_\infty \leq 1} \langle G, D \rangle = \operatorname{argmin}_{\max_{ij} |D_{ij}| \leq 1} \sum_{ij} G_{ij} D_{ij}$$

Каждый элемент D_{ij} независимо ограничен $|D_{ij}| \leq 1$. Минимум $G_{ij} D_{ij}$ достигается при:

$$D_{ij}^* = -\operatorname{sign}(G_{ij})$$

Двойственная норма: $\|G\|_\infty^* = \|G\|_1 = \sum_{ij} |G_{ij}|$

Вывод: SignGD как наискорейший спуск в ℓ_∞ -норме

$$D^* = \operatorname{argmin}_{\|D\|_\infty \leq 1} \langle G, D \rangle = \operatorname{argmin}_{\max_{ij} |D_{ij}| \leq 1} \sum_{ij} G_{ij} D_{ij}$$

Каждый элемент D_{ij} независимо ограничен $|D_{ij}| \leq 1$. Минимум $G_{ij} D_{ij}$ достигается при:

$$D_{ij}^* = -\operatorname{sign}(G_{ij})$$

Двойственная норма: $\|G\|_\infty^* = \|G\|_1 = \sum_{ij} |G_{ij}|$

$$W_{k+1} = W_k - \alpha \operatorname{sign}(G_k) = \text{SignGD}$$

Вывод: Муон как наискорейший спуск в спектральной норме

$$D^* = \operatorname{argmin}_{\|D\|_\sigma \leq 1} \langle G, D \rangle, \quad G = U\Sigma V^\top \text{ (SVD)}$$

Вывод: Муон как наискорейший спуск в спектральной норме

$$D^* = \operatorname{argmin}_{\|D\|_\sigma \leq 1} \langle G, D \rangle, \quad G = U \Sigma V^\top \text{ (SVD)}$$

Двойственная норма к спектральной — **ядерная**: $\|G\|_\sigma^* = \|G\|_* = \sum_i \sigma_i(G)$

Вывод: Муон как наискорейший спуск в спектральной норме

$$D^* = \operatorname{argmin}_{\|D\|_\sigma \leq 1} \langle G, D \rangle, \quad G = U \Sigma V^\top \text{ (SVD)}$$

Двойственная норма к спектральной — **ядерная**: $\|G\|_\sigma^* = \|G\|_* = \sum_i \sigma_i(G)$

$\text{LMO}_{\|\cdot\|_\sigma}(G)$: ищем $\|D\|_\sigma = 1$ (т.е. $\sigma_{\max}(D) = 1$), минимизирующую $\langle G, D \rangle = \operatorname{tr}(G^\top D)$.

По неравенству фон Неймана: $\operatorname{tr}(G^\top D) \geq -\sum_i \sigma_i(G) \sigma_i(D) \geq -\sum_i \sigma_i(G)$

Вывод: Муон как наискорейший спуск в спектральной норме

$$D^* = \operatorname{argmin}_{\|D\|_\sigma \leq 1} \langle G, D \rangle, \quad G = U \Sigma V^\top \text{ (SVD)}$$

Двойственная норма к спектральной — **ядерная**: $\|G\|_\sigma^* = \|G\|_* = \sum_i \sigma_i(G)$

$\text{LMO}_{\|\cdot\|_\sigma}(G)$: ищем $\|D\|_\sigma = 1$ (т.е. $\sigma_{\max}(D) = 1$), минимизирующую $\langle G, D \rangle = \operatorname{tr}(G^\top D)$.

По неравенству фон Неймана: $\operatorname{tr}(G^\top D) \geq -\sum_i \sigma_i(G) \sigma_i(D) \geq -\sum_i \sigma_i(G)$


Равенство при $D^* = -UV^\top$ (все сингулярные числа D равны 1):

$$W_{k+1} = W_k - \alpha UV^\top = \text{Муон}$$


Три нормы — три оптимизатора: эксперимент

Наискорейший спуск в трёх нормах: $\|\cdot\|_F$ (SGD), $\|\cdot\|_\infty$ (SignGD), $\|\cdot\|_\sigma$ (Muon)


Сходимость



Спектр обновления (iter 0)



Спектр обновления (iter 50)



$f(W) = \frac{1}{2}\|\Sigma W\|_F^2$, $W \in \mathbb{R}^{8 \times 8}$, $\kappa(\Sigma) = 20$. **Слева:** сходимость трёх методов. **Справа:** спектр обновления ΔW . SGD концентрирует энергию на 1–2 сингулярных направлениях, Muon — распределяет равномерно.

Откуда берётся итерация Newton–Schulz

Задача: вычислить $1/a$ без деления — только сложениями и умножениями.

Откуда берётся итерация Newton–Schulz

Задача: вычислить $1/a$ без деления — только сложениями и умножениями.

Применим метод Ньютона к $f(x) = 1/x - a = 0$:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = x_k - \frac{1/x_k - a}{-1/x_k^2} = x_k(2 - ax_k).$$

Откуда берётся итерация Newton–Schulz

Задача: вычислить $1/a$ без деления — только сложениями и умножениями.

Применим метод Ньютона к $f(x) = 1/x - a = 0$:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = x_k - \frac{1/x_k - a}{-1/x_k^2} = x_k(2 - ax_k).$$

Невязка $u_k = 1 - ax_k$ удовлетворяет $u_{k+1} = u_k^2$ — **квадратичная сходимость** при $|u_0| < 1$.

Откуда берётся итерация Newton–Schulz

Задача: вычислить $1/a$ без деления — только сложениями и умножениями.

Применим метод Ньютона к $f(x) = 1/x - a = 0$:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = x_k - \frac{1/x_k - a}{-1/x_k^2} = x_k(2 - ax_k).$$

Невязка $u_k = 1 - ax_k$ удовлетворяет $u_{k+1} = u_k^2$ — **квадратичная сходимость** при $|u_0| < 1$.

Заменяем скаляры на матрицы: $x_k \rightarrow X_k$, $a \rightarrow A$:

$$X_{k+1} = X_k(2I - AX_k) \rightarrow A^{-1}$$

Ни одного обращения матрицы — только умножения.

От обращения матрицы к полярному фактору

Теперь **другая задача**: вычислить $1/\sqrt{a}$. Метод Ньютона к $f(x) = 1/x^2 - a = 0$:

$$x_{k+1} = x_k - \frac{1/x_k^2 - a}{-2/x_k^3} = \frac{1}{2}x_k(3 - ax_k^2).$$

От обращения матрицы к полярному фактору

Теперь **другая задача**: вычислить $1/\sqrt{a}$. Метод Ньютона к $f(x) = 1/x^2 - a = 0$:

$$x_{k+1} = x_k - \frac{1/x_k^2 - a}{-2/x_k^3} = \frac{1}{2}x_k(3 - ax_k^2).$$

Заменяем скаляры на матрицы: $x_k \rightarrow X_k$, $a \rightarrow X_k^\top X_k$:

$$X_{k+1} = \frac{1}{2}X_k(3I - X_k^\top X_k)$$

От обращения матрицы к полярному фактору

Теперь **другая задача**: вычислить $1/\sqrt{a}$. Метод Ньютона к $f(x) = 1/x^2 - a = 0$:

$$x_{k+1} = x_k - \frac{1/x_k^2 - a}{-2/x_k^3} = \frac{1}{2}x_k(3 - ax_k^2).$$

Заменяем скаляры на матрицы: $x_k \rightarrow X_k$, $a \rightarrow X_k^\top X_k$:

$$X_{k+1} = \frac{1}{2}X_k(3I - X_k^\top X_k)$$

Ключевой трюк: инициализируем $X_0 = G/\|G\|_F$. Итерация сохраняет сингулярные векторы U , V и действует на каждое сингулярное число как $\sigma \mapsto \frac{1}{2}\sigma(3 - \sigma^2)$.

От обращения матрицы к полярному фактору

Теперь **другая задача**: вычислить $1/\sqrt{a}$. Метод Ньютона к $f(x) = 1/x^2 - a = 0$:

$$x_{k+1} = x_k - \frac{1/x_k^2 - a}{-2/x_k^3} = \frac{1}{2}x_k(3 - ax_k^2).$$

Заменяем скаляры на матрицы: $x_k \rightarrow X_k$, $a \rightarrow X_k^\top X_k$:

$$X_{k+1} = \frac{1}{2}X_k(3I - X_k^\top X_k)$$

Ключевой трюк: инициализируем $X_0 = G/\|G\|_F$. Итерация сохраняет сингулярные векторы U , V и действует на каждое сингулярное число как $\sigma \mapsto \frac{1}{2}\sigma(3 - \sigma^2)$.

Неподвижная точка: $\sigma = 1 \Rightarrow \sigma_i(X_k) \rightarrow 1 \Rightarrow X_k \rightarrow UV^\top$. Множитель G «вшит» в X_0 ; итерация лишь выравнивает спектр, не трогая направления.

Algorithm 1 Proposed optimizer

Require: Learning rate η , momentum μ , weight decay λ

- 1: Initialize $B_0 \leftarrow 0$
 - 2: **for** $t = 1, \dots$ **do**
 - 3: Compute gradient $G_t \leftarrow \nabla_{\theta} \mathcal{L}_t(\theta_{t-1})$
 - 4: $B_t \leftarrow \mu B_{t-1} + G_t$
 - 5: $G_t \leftarrow \mu B_t + G_t$
 - 6: $O_t \leftarrow \text{NewtonSchulz5}(G_t)$
 - 7: Update parameters $\theta_t \leftarrow \theta_{t-1} - \eta(O_t + \lambda \theta_{t-1})$
 - 8: **end for**
 - 9: **return** θ_t
-

Newton-Schulz вместо SVD для вычисления $UV^{\top}$:

$$X_0 = G / \|G\|_F$$

$$X_{k+1} = aX_k + bX_kX_k^{\top}X_k + c(X_kX_k^{\top})^2X_k$$

с коэффициентами $a=3.4445$, $b=-4.7750$,
 $c=2.0315$.

- **5 итераций** достаточно на практике

Algorithm 1 Proposed optimizer

Require: Learning rate η , momentum μ , weight decay λ

- 1: Initialize $B_0 \leftarrow 0$
 - 2: **for** $t = 1, \dots$ **do**
 - 3: Compute gradient $G_t \leftarrow \nabla_{\theta} \mathcal{L}_t(\theta_{t-1})$
 - 4: $B_t \leftarrow \mu B_{t-1} + G_t$
 - 5: $G_t \leftarrow \mu B_t + G_t$
 - 6: $O_t \leftarrow \text{NewtonSchulz5}(G_t)$
 - 7: Update parameters $\theta_t \leftarrow \theta_{t-1} - \eta(O_t + \lambda \theta_{t-1})$
 - 8: **end for**
 - 9: **return** θ_t
-

Newton-Schulz вместо SVD для вычисления $UV^{\top}$:

$$X_0 = G / \|G\|_F$$

$$X_{k+1} = aX_k + bX_kX_k^{\top}X_k + c(X_kX_k^{\top})^2X_k$$

с коэффициентами $a=3.4445$, $b=-4.7750$,
 $c=2.0315$.

- **5 итераций** достаточно на практике
- Только матричные умножения — эффективно на GPU

Algorithm 1 Proposed optimizer

Require: Learning rate η , momentum μ , weight decay λ

- 1: Initialize $B_0 \leftarrow 0$
 - 2: **for** $t = 1, \dots$ **do**
 - 3: Compute gradient $G_t \leftarrow \nabla_{\theta} \mathcal{L}_t(\theta_{t-1})$
 - 4: $B_t \leftarrow \mu B_{t-1} + G_t$
 - 5: $G_t \leftarrow \mu B_t + G_t$
 - 6: $O_t \leftarrow \text{NewtonSchulz5}(G_t)$
 - 7: Update parameters $\theta_t \leftarrow \theta_{t-1} - \eta(O_t + \lambda \theta_{t-1})$
 - 8: **end for**
 - 9: **return** θ_t
-

Newton-Schulz вместо SVD для вычисления $UV^{\top}$:

$$X_0 = G / \|G\|_F$$

$$X_{k+1} = aX_k + bX_kX_k^{\top}X_k + c(X_kX_k^{\top})^2X_k$$

с коэффициентами $a=3.4445$, $b=-4.7750$,
 $c=2.0315$.

- **5 итераций** достаточно на практике
- Только матричные умножения — эффективно на GPU
- Кубическая сходимость к полярному фактору

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.
- **Muon**¹⁵: $p(x) = 3.4445x - 4.7750x^3 + 2.0315x^5$ — **эвристический** градиентный поиск. Не сходится к $UV^\top$ (ошибка ≈ 0.3), но на практике достаточно для обучения.

¹⁵  К. Jordan, блог-пост (2024)

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.
- **Muon**¹⁵: $p(x) = 3.4445x - 4.7750x^3 + 2.0315x^5$ — **эвристический** градиентный поиск. Не сходится к $UV^\top$ (ошибка ≈ 0.3), но на практике достаточно для обучения.

¹⁵  К. Jordan, блог-пост (2024)

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.
- **Muon**¹⁵: $p(x) = 3.4445x - 4.7750x^3 + 2.0315x^5$ — **эвристический** градиентный поиск. Не сходится к $UV^\top$ (ошибка ≈ 0.3), но на практике достаточно для обучения.
- **Polar Express**¹⁶: **адаптивный** полином на каждой итерации, жадный минимакс $\rightarrow$ доказанная оптимальность.

¹⁵  К. Jordan, блог-пост (2024)

¹⁶  Amsel et al. (2025)

Откуда берутся коэффициенты?

Полином $p(\sigma) \rightarrow 1$ действует на сингулярные числа. Задача — **минимаксная аппроксимация единицы** нечётным полиномом:

$$p^* = \operatorname{argmin}_{p \in \mathbb{P}_d^{\text{odd}}} \max_{x \in [\ell, u]} |1 - p(x)|$$

- **Классический NS** (Schulz, 1933): $p(x) = \frac{3}{2}x - \frac{1}{2}x^3$. Нечётный кубический полином имеет вид $p(x) = ax - bx^3$. Условия $p(1) = 1$ и $p'(1) = 0$ (неподвижная точка с нулевой производной для квадратичной сходимости) дают систему $a - b = 1$, $a - 3b = 0$, откуда $a = 3/2$, $b = 1/2$. Медленный начальный этап.
- **Muon**¹⁵: $p(x) = 3.4445x - 4.7750x^3 + 2.0315x^5$ — **эвристический** градиентный поиск. Не сходится к $UV^\top$ (ошибка ≈ 0.3), но на практике достаточно для обучения.
- **Polar Express**¹⁶: **адаптивный** полином на каждой итерации, жадный минимакс $\rightarrow$ доказанная оптимальность.
- **CANS**¹⁷: оптимальные полиномы через **равноосцилляцию Чебышёва**. Явные формулы для степени 3, алгоритм Ремеза для $d > 3$.


¹⁵  К. Jordan, блог-пост (2024)

¹⁶  Amsel et al. (2025)

¹⁷  Grishina et al. (2025)

Newton-Schulz: эллипс $\rightarrow$ окружность

Newton-Schulz: эллипс $\rightarrow$ окружность (ортогонализация)




Пусть $G = U\Sigma V^T$, $X_0 = G/\|G\|_F$. Итерация $X_{k+1} = \frac{1}{2}X_k(3I - X_k^T X_k)$ сохраняет сингулярные векторы U, V и применяет к каждому сингулярному числу отображение $\sigma \mapsto \frac{1}{2}\sigma(3 - \sigma^2)$. Неподвижная точка: $\sigma = 1$. Сходимость: $\sigma_i(X_k) \rightarrow 1 \Rightarrow X_k \rightarrow UV^T$.


Результаты и эксперименты

Муон: геометрия ортогонализации


Сингулярные числа
градиента и Муон



Энергия обновления
по направлениям




Число обусловленности





Вывод: SGD концентрирует обновление на доминирующих сингулярных направлениях (разница $500\times$). Муон нормализует все направления к единице — **равномерный прогресс** во всех направлениях пространства параметров.

Эксперимент: классификация спиралей

Классификация спиралей (mini-batch): SGD, Nesterov, AdamW, Muon




Классификация спиралей: после HP tuning (Optuna)



500 trials $\times$ 1000 steps. SGD/Nesterov: **lr доминирует** (>70%). Muon: **weight decay** и **lr равнозначны** — ортогонализация снижает чувствительность к шагу.

 Интерактивная визуализация и детали



Муон на квадратичных задачах ¹⁸



Простейшая задача: $L(W) = \frac{1}{2}\|W\|_F^2$, точная ортогонализация (без Newton-Schulz), без момента.

- Обновление Муон: $W_{k+1} = W_k - \alpha UV^\top$, где $W_k = U\Sigma V^\top$. Каждое сингулярное число обновляется независимо:
 $\sigma_{k+1} = \sigma_k - \alpha \text{sign}(\sigma_k)$


Муон на квадратичных задачах ¹⁸



Простейшая задача: $L(W) = \frac{1}{2}\|W\|_F^2$, точная ортогонализация (без Newton-Schulz), без момента.

- Обновление Муон: $W_{k+1} = W_k - \alpha UV^\top$, где $W_k = U\Sigma V^\top$. Каждое сингулярное число обновляется независимо:
 $\sigma_{k+1} = \sigma_k - \alpha \text{sign}(\sigma_k)$
- Шаг **фиксирован** по модулю (α) и не зависит от $|\sigma_k|$ — аналог предельного цикла Adam, но для каждого сингулярного числа


Муон на квадратичных задачах ¹⁸



Простейшая задача: $L(W) = \frac{1}{2}\|W\|_F^2$, точная ортогонализация (без Newton-Schulz), без момента.

- Обновление Муон: $W_{k+1} = W_k - \alpha UV^\top$, где $W_k = U\Sigma V^\top$. Каждое сингулярное число обновляется независимо:
 $\sigma_{k+1} = \sigma_k - \alpha \text{sign}(\sigma_k)$
- Шаг **фиксирован** по модулю (α) и не зависит от $|\sigma_k|$ — аналог предельного цикла Adam, но для каждого сингулярного числа
- Итог: **2-цикл** около нуля, loss не опускается ниже $\Theta(\alpha^2)$. Скорость $O(1/\sqrt{\epsilon})$ шагов против $O(\log(1/\epsilon))$ у GD

Муон: стабильность по спектру задачи ¹⁹




$$L(W) = \frac{1}{2} \langle W, AW \rangle + \langle B, W \rangle + c, \quad A = QSQ^\top,$$

$$n = 100.$$

7 спектров S , все с $(s_{\min}, s_{\max}) = (10^{-3}, 10)$, $\kappa = 10^4$,

$$T = 500.$$

Муон: стабильность по спектру задачи ¹⁹




$$L(W) = \frac{1}{2} \langle W, AW \rangle + \langle B, W \rangle + c, \quad A = QSQ^\top, \\ n = 100.$$

7 спектров S , все с $(s_{\min}, s_{\max}) = (10^{-3}, 10)$, $\kappa = 10^4$, $T = 500$.

Почему Муон стабилен: обновление $-UV^\top$ имеет все сингулярные числа $= 1 \rightarrow$ одинаковый прогресс по **всем** направлениям, независимо от кривизны.

Муон: стабильность по спектру задачи ¹⁹



$$L(W) = \frac{1}{2} \langle W, AW \rangle + \langle B, W \rangle + c, \quad A = QSQ^\top, \\ n = 100.$$

7 спектров S , все с $(s_{\min}, s_{\max}) = (10^{-3}, 10)$, $\kappa = 10^4$, $T = 500$.

Почему Muon стабилен: обновление $-UV^\top$ имеет все сингулярные числа $= 1 \rightarrow$ одинаковый прогресс по **всем** направлениям, независимо от кривизны.

Почему GD нестабилен: обновление $\propto \nabla L = AW \rightarrow$ прогресс пропорционален собственному числу s_i . Если большинство $s_i \approx s_{\min}$ (min_spiked) — GD медленный. Если $s_i \approx s_{\max}$ (max_spiked) — быстрый. При одном κ , но разной форме спектра, ранжирование Muon vs GD **переворачивается**.

Мagma: случайное маскирование обновлений ²⁰

Идея: случайное пропускание обновлений параметров во время обучения LLM **улучшает** результат!

SkipUpdate: на каждом шаге блокируем обновление блока параметров с вероятностью $1 - p$, масштабируя оставшиеся на $1/p$.

Мagma: случайное маскирование обновлений ²⁰

Идея: случайное пропускание обновлений параметров во время обучения LLM **улучшает** результат!

SkipUpdate: на каждом шаге блокируем обновление блока параметров с вероятностью $1 - p$, масштабируя оставшиеся на $1/p$.

Мagma (Momentum-Aligned Gradient Masking): модулирует маскирование через выравнивание с моментумом:

$$\tilde{s}_t^{(b)} = \text{sigmoid} \left(\frac{\cos(\mu_t^{(b)}, g_t^{(b)})}{\tau} \right)$$

²⁰  Joo, T. et al. (2026). On Surprising Effectiveness of Masking Updates in Adaptive Optimizers.

Magma: случайное маскирование обновлений ²⁰

Идея: случайное пропускание обновлений параметров во время обучения LLM **улучшает** результат!

SkipUpdate: на каждом шаге блокируем обновление блока параметров с вероятностью $1 - p$, масштабируя оставшиеся на $1/p$.

Magma (Momentum-Aligned Gradient Masking): модулирует маскирование через выравнивание с моментумом:

$$\tilde{s}_t^{(b)} = \text{sigmoid} \left(\frac{\cos(\mu_t^{(b)}, g_t^{(b)})}{\tau} \right)$$


Теоретический инсайт: маскирование индуцирует геометрическую регуляризацию, зависящую от кривизны:

$$\mathcal{R}_t^{(b)} = \frac{1-p}{2p} \cdot (\Delta_t^{(b)})^\top H_{bb}(\theta_t) \Delta_t^{(b)}$$

Штрафует обновления вдоль направлений с большой кривизной — оптимизация смещается к более плоским минимумам.

²⁰  Joo, T. et al. (2026). On Surprising Effectiveness of Masking Updates in Adaptive Optimizers.

Магма: масштабирование до 1B параметров ²¹



Магма превосходит Adam, Muon, Adafactor, GaLore на всех масштабах. На 1B: perplexity **13.8** vs 16.3 (Adam).

²¹  Joo et al. (2026)

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).
- Ключевой инсайт: ортогонализация $(UV^\top)$ устраняет зависимость от числа обусловленности — **равномерный прогресс** по всем сингулярным направлениям.

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).
- Ключевой инсайт: ортогонализация $(UV^\top)$ устраняет зависимость от числа обусловленности — **равномерный прогресс** по всем сингулярным направлениям.
- Newton-Schulz позволяет эффективно вычислять полярный фактор: 5 итераций матричных умножений вместо полного SVD.

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).
- Ключевой инсайт: ортогонализация $(UV^\top)$ устраняет зависимость от числа обусловленности — **равномерный прогресс** по всем сингулярным направлениям.
- Newton-Schulz позволяет эффективно вычислять полярный фактор: 5 итераций матричных умножений вместо полного SVD.

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).
- Ключевой инсайт: ортогонализация $(UV^\top)$ устраняет зависимость от числа обусловленности — **равномерный прогресс** по всем сингулярным направлениям.
- Newton-Schulz позволяет эффективно вычислять полярный фактор: 5 итераций матричных умножений вместо полного SVD.
- **На практике:** Muon — лучший по NanoGPT speedrun; используется в моделях масштаба 1T (Kimi K2).

Итоги лекции

- **Muon** — метод ортогонализации градиента, делающий **наискорейший спуск в спектральной норме** для матричных параметров.
- Shampoo приближает полноматричный предобусловитель AdaGrad через произведения Кронекера; Muon — его предельный случай (один градиент).
- Ключевой инсайт: ортогонализация (UV^T) устраняет зависимость от числа обусловленности — **равномерный прогресс** по всем сингулярным направлениям.
- Newton-Schulz позволяет эффективно вычислять полярный фактор: 5 итераций матричных умножений вместо полного SVD.
- **На практике:** Muon — лучший по NanoGPT speedrun; используется в моделях масштаба 1T (Kimi K2).
- **Magma** — регуляризация через маскирование, смещающая обучение к плоским минимумам.

Дополнительные материалы

-  J. Bernstein "Deriving Muon"

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"
-  Gonon et al. "Insights on Muon from Simple Quadratics" (2026)

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"
-  Gonon et al. "Insights on Muon from Simple Quadratics" (2026)
-  Joo et al. "On Surprising Effectiveness of Masking Updates" (2026)

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"
-  Gonon et al. "Insights on Muon from Simple Quadratics" (2026)
-  Joo et al. "On Surprising Effectiveness of Masking Updates" (2026)
-  Amsel et al. "The Polar Express: Optimal Matrix Sign Methods" (2025)

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"
-  Gonon et al. "Insights on Muon from Simple Quadratics" (2026)
-  Joo et al. "On Surprising Effectiveness of Masking Updates" (2026)
-  Amsel et al. "The Polar Express: Optimal Matrix Sign Methods" (2025)
-  Grishina et al. "Accelerating Newton-Schulz via Chebyshev-type Polynomials" (2025)

Дополнительные материалы

-  J. Bernstein "Deriving Muon"
-  K. Jordan "Muon: An optimizer for hidden layers"
-  Gonon et al. "Insights on Muon from Simple Quadratics" (2026)
-  Joo et al. "On Surprising Effectiveness of Masking Updates" (2026)
-  Amsel et al. "The Polar Express: Optimal Matrix Sign Methods" (2025)
-  Grishina et al. "Accelerating Newton-Schulz via Chebyshev-type Polynomials" (2025)
-  Д. Ковалёв "Understanding Gradient Orthogonalization" (теория Muon)

Приложение

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .

Замечания:

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.

Замечания:

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
3. Вычислить предобусловители $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$ (обратный матричный корень).

Замечания:

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
3. Вычислить предобусловители $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$ (обратный матричный корень).
4. Обновление: $W_{k+1} = W_k - \alpha P_L G_k P_R$.

Замечания:

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
3. Вычислить предобусловители $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$ (обратный матричный корень).
4. Обновление: $W_{k+1} = W_k - \alpha P_L G_k P_R$.

Замечания:

- Учитывает информацию о кривизне эффективнее методов первого порядка.

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
3. Вычислить предобусловители $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$ (обратный матричный корень).
4. Обновление: $W_{k+1} = W_k - \alpha P_L G_k P_R$.

Замечания:

- Учитывает информацию о кривизне эффективнее методов первого порядка.
- Вычислительно дороже Adam, но может сходиться быстрее по числу шагов.

Shampoo = **S**tochastic **H**essian-**A**pproximation **M**atrix **P**reconditioning for **O**ptimization **O**f deep networks — метод, вдохновлённый оптимизацией второго порядка.

Основная идея: Приближает полноматричный предобусловитель AdaGrad через произведения Кронекера.

Для матрицы весов $W \in \mathbb{R}^{m \times n}$:

1. Вычислить градиент G_k .
2. Обновить статистику $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
3. Вычислить предобусловители $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$ (обратный матричный корень).
4. Обновление: $W_{k+1} = W_k - \alpha P_L G_k P_R$.

Замечания:

- Учитывает информацию о кривизне эффективнее методов первого порядка.
- Вычислительно дороже Adam, но может сходиться быстрее по числу шагов.
- Требуется аккуратной реализации (эффективное вычисление обратных матричных корней).

²²  Gupta, Koren, Singer (2018). Shampoo: Preconditioned Stochastic Tensor Optimization. ICML.

Муон как упрощение Shampoo ²³

$$W_{t+1} = W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}}$$

Муон как упрощение Shampoo ²³

$$\begin{aligned} W_{t+1} &= W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}} \\ &= W_t - \eta (U S^2 U^\top)^{-1/4} (U S V^\top) (V S^2 V^\top)^{-1/4} \end{aligned}$$

Муон как упрощение Shampoo ²³

$$\begin{aligned} W_{t+1} &= W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}} \\ &= W_t - \eta (U S^2 U^\top)^{-1/4} (U S V^\top) (V S^2 V^\top)^{-1/4} \\ &= W_t - \eta (U S^{-1/2} U^\top) (U S V^\top) (V S^{-1/2} V^\top) \end{aligned}$$

Муон как упрощение Shampoo ²³

$$\begin{aligned} W_{t+1} &= W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}} \\ &= W_t - \eta (U S^2 U^\top)^{-1/4} (U S V^\top) (V S^2 V^\top)^{-1/4} \\ &= W_t - \eta (U S^{-1/2} U^\top) (U S V^\top) (V S^{-1/2} V^\top) \\ &= W_t - \eta U S^{-1/2} S S^{-1/2} V^\top \end{aligned}$$

Муон как упрощение Shampoo ²³

$$\begin{aligned} W_{t+1} &= W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}} \\ &= W_t - \eta (U S^2 U^\top)^{-1/4} (U S V^\top) (V S^2 V^\top)^{-1/4} \\ &= W_t - \eta (U S^{-1/2} U^\top) (U S V^\top) (V S^{-1/2} V^\top) \\ &= W_t - \eta U S^{-1/2} S S^{-1/2} V^\top \\ &= W_t - \eta U V^\top \end{aligned}$$

²³  J. Bernstein “Deriving Muon”

Муон как упрощение Shampoo ²³

$$\begin{aligned} W_{t+1} &= W_t - \eta \underbrace{(G_t G_t^\top)^{-1/4} G_t (G_t^\top G_t)^{-1/4}}_{\text{Shampoo}} \\ &= W_t - \eta (U S^2 U^\top)^{-1/4} (U S V^\top) (V S^2 V^\top)^{-1/4} \\ &= W_t - \eta (U S^{-1/2} U^\top) (U S V^\top) (V S^{-1/2} V^\top) \\ &= W_t - \eta U S^{-1/2} S S^{-1/2} V^\top \\ &= W_t - \eta U V^\top \end{aligned}$$

Ключевой инсайт: Shampoo с «идеальной» статистикой (один градиент вместо накопленных) — это просто ортогонализация градиента. Все сингулярные числа обновления равны 1.

²³  J. Bernstein “Deriving Muon”