




Синтез курса. Современные направления.

Даня Меркулов

ФКН ВШЭ

Итог: что мы изучили

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

**Три ключевых вопроса:**

1. **Существование:** есть ли решение?

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

**Три ключевых вопроса:**

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

**Три ключевых вопроса:**

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

**Три ключевых вопроса:**

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

# 18 лекций — один курс

**Цель курса:** научиться решать задачи вида  $\min_{x \in \mathcal{X}} f(x)$  для задач ML.

**Три ключевых вопроса:**

1. **Существование:** есть ли решение?
2. **Характеризация:** как описать оптимум (ККТ, субградиент)?
3. **Вычисление:** как его найти (алгоритм + гарантии скорости)?

Главная идея курса

Правильный алгоритм = правильное использование структуры задачи.



# Структура курса одним слайдом

| Блок                  | Лекции | Тема                                         |
|-----------------------|--------|----------------------------------------------|
| <b>Основы</b>         | 1–4    | Линал, выпуклость, условия оптимальности, GD |
| <b>Ускорение</b>      | 5–8    | Конъюгатные градиенты, AGD, Нестеров, FISTA  |
| <b>Стохастика</b>     | 9–10   | SGD, мини-батч, variance reduction           |
| <b>Специализация</b>  | 11–14  | CD, ADMM, PDHG, Frank-Wolfe                  |
| <b>Второй порядок</b> | 15     | Newton, BFGS, L-BFGS                         |
| <b>Расширения</b>     | 16–17  | Невыпуклость, PL, FedAvg, FL                 |
| <b>Синтез</b>         | 18     | Дерево выбора, frontier                      |

## Таксономия задач

# Три измерения любой задачи оптимизации

## Измерение 1 — Структура $f$ :

| Свойство                  | Параметр         | Что даёт                       |
|---------------------------|------------------|--------------------------------|
| $L$ -гладкость            | $L$              | Шаг $t \leq 1/L$ , GD работает |
| $\mu$ -сил. выпуклость    | $\mu$            | Линейная сходимость            |
| Сильно выпуклая + гладкая | $\kappa = L/\mu$ | Скорость $(1 - 1/\kappa)^k$    |
| Стохастический градиент   | $\sigma^2$       | Шумовой пол $O(\sigma^2/k)$    |

# Три измерения любой задачи оптимизации

## Измерение 1 — Структура $f$ :

| Свойство                  | Параметр         | Что даёт                       |
|---------------------------|------------------|--------------------------------|
| $L$ -гладкость            | $L$              | Шаг $t \leq 1/L$ , GD работает |
| $\mu$ -сил. выпуклость    | $\mu$            | Линейная сходимость            |
| Сильно выпуклая + гладкая | $\kappa = L/\mu$ | Скорость $(1 - 1/\kappa)^k$    |
| Стохастический градиент   | $\sigma^2$       | Шумовой пол $O(\sigma^2/k)$    |

**Измерение 2 — Ограничения:** нет /  $x \in C$  (проекция) /  $Ax = b$  / составная  $f + g$

**Измерение 3 — Масштаб:** размер  $n$ , размерность  $d$ , агентов  $N$

# Как выбрать алгоритм: дерево решений

Задача  $\min f(x)$ :

- $f$  негладкая? → субградиент / ISTA (если есть прокс)
- $f$  гладкая →
  - Составная  $f + g(Kx)$ ? → PDHG / ADMM [Л12-13]
  - Ограниченная  $C$ , LP дешёв? → Frank-Wolfe [Л14]
  - Маленький  $d$  ( $\leq 10$ )? → L-BFGS / Newton [Л15]
  - Большой  $n$ , стохастика →
    - Памяти много → SVRG / SAGA [Л10]
    - Памяти мало → SGD + cosine [Л9]
  - Распределённая →
    - IID → FedAvg [Л17]
    - non-IID → SCAFFOLD [Л17]
    - Приватность → DP-SGD [Л17]
  - Невыпуклая →
    - PL-условие → GD (линейная сходимость!) [Л16]
    - Сёдла → Perturbed GD [Л16]

## Мегатаблица методов

# Все алгоритмы курса — часть I

| Задача                          | Алгоритм       | Скорость                  |
|---------------------------------|----------------|---------------------------|
| $\min f$ , выпуклая, $L$ -гл.   | GD             | $O(1/k)$                  |
| $\min f$ , с.в., $L$ -гл.       | GD             | $O(e^{-k/\kappa})$        |
| $\min f$ , с.в., $L$ -гл.       | AGD (Нестеров) | $O(e^{-k/\sqrt{\kappa}})$ |
| $\min f + g$ , прокс $g$        | ISTA           | $O(1/k)$                  |
| $\min f + g$ , прокс $g$ , с.в. | FISTA          | $O(1/k^2)$                |
| Стохастический $\nabla f$       | SGD            | $O(\sigma/\sqrt{k})$      |
| Большой $n$ , с.в.              | SVRG / SAGA    | $O(e^{-k(1-1/n\kappa)})$  |

## Все алгоритмы курса — часть II

| Задача                    | Алгоритм    | Скорость                                |
|---------------------------|-------------|-----------------------------------------|
| Разрежённый $x$           | RCD         | $O(e^{-\mu k/dL})$                      |
| $\min f + g(Kx)$          | PDHG        | $O(1/k)$ при $\tau\sigma\ K\ ^2 \leq 1$ |
| $\min f + g$ (двойст.)    | ADMM        | $O(1/k)$                                |
| $x \in C$ , LP oracle     | Frank-Wolfe | $O(LD^2/k)$                             |
| Мал. $d$ , второй порядок | Newton      | Квадратичная                            |
| Мал. $d$ , памяти нет     | L-BFGS      | Суперлинейная                           |
| Невыпуклая                | GD          | $O(1/\sqrt{k})$ нормы $\nabla f$        |
| PL-условие                | GD          | $O(e^{-\mu k/L})$ к глоб. оптим.        |
| Распред., IID             | FedAvg      | $O(1/\sqrt{NK\tau})$                    |



## Нижние оценки: быстрее нельзя

**Теорема Немировского-Юдина (1983):** для гладкой выпуклой  $f$  любой алгоритм, использующий  $k$  градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

## Нижние оценки: быстрее нельзя

**Теорема Немировского-Юдина (1983):** для гладкой выпуклой  $f$  любой алгоритм, использующий  $k$  градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

**AGD = оптимален:** скорость  $O(1/k^2)$  достигается!

## Нижние оценки: быстрее нельзя

**Теорема Немировского-Юдина (1983):** для гладкой выпуклой  $f$  любой алгоритм, использующий  $k$  градиентов, имеет:

$$f(x_k) - f^* \geq \Omega\left(\frac{L\|x_0 - x^*\|^2}{k^2}\right)$$

**AGD = оптимален:** скорость  $O(1/k^2)$  достигается!

| Класс задач           | Нижняя оценка                  | Достигается |
|-----------------------|--------------------------------|-------------|
| Выпуклая, $L$ -гл.    | $\Omega(1/k^2)$                | AGD ☒       |
| С.в. $\mu$ , $L$ -гл. | $\Omega(e^{-k/\sqrt{\kappa}})$ | AGD ☒       |
| Стохастическая        | $\Omega(\sigma/\sqrt{k})$      | SGD ☒       |
| Конечная сумма        | $\Omega(e^{-k\mu/(L+n\mu)})$   | SVRG ☒      |

## Связь всего со всем

# Оператор расщепления — единый взгляд

**Ключевая идея:** большинство методов — это **численная дискретизация ODE** через оператор расщепления.

# Оператор расщепления — единый взгляд

**Ключевая идея:** большинство методов — это **численная дискретизация ODE** через оператор расщепления.

| Метод      | Расщепление                                                                                          |
|------------|------------------------------------------------------------------------------------------------------|
| GD         | Ли-Троттер: $e^{(A_f+A_R)h} \approx e^{A_f h} e^{A_R h}$                                             |
| ISTA       | Ли-Троттер: $\text{prox}_g \boxtimes \text{implicit } A_R + \nabla f \boxtimes \text{explicit } A_f$ |
| AGD        | Двойная ODE: Heavy Ball + Нестеровский момент                                                        |
| ADMM / DRS | Douglas-Rachford в двойственном пространстве                                                         |
| PDHG       | Прямо-двойственное расщепление                                                                       |
| FedAvg     | ADMM consensus = расщепление по агентам                                                              |

# Оператор расщепления — единый взгляд

**Ключевая идея:** большинство методов — это **численная дискретизация ODE** через оператор расщепления.

| Метод      | Расщепление                                                                                          |
|------------|------------------------------------------------------------------------------------------------------|
| GD         | Ли-Троттер: $e^{(A_f+A_R)h} \approx e^{A_f h} e^{A_R h}$                                             |
| ISTA       | Ли-Троттер: $\text{prox}_g \boxtimes \text{implicit } A_R + \nabla f \boxtimes \text{explicit } A_f$ |
| AGD        | Двойная ODE: Heavy Ball + Нестеровский момент                                                        |
| ADMM / DRS | Douglas-Rachford в двойственном пространстве                                                         |
| PDHG       | Прямо-двойственное расщепление                                                                       |
| FedAvg     | ADMM consensus = расщепление по агентам                                                              |

## Тема диссертации Даниила

Strang splitting (2-й порядок) для ISTA/Ridge регрессии: сходится в  $\sqrt{\kappa}$  раз быстрее Ли-Троттера. Подано в ЖВММФ.

## Связи между методами

**ADMM = DRS** (Douglas-Rachford Splitting):

ADMM для  $\min f(x) + g(z), Ax + Bz = c \iff$  DRS в двойственном пространстве



## Связи между методами

**ADMM = DRS** (Douglas-Rachford Splitting):

ADMM для  $\min f(x) + g(z), Ax + Bz = c \iff$  DRS в двойственном пространстве

**FISTA = AGD + Proximal:**

$$x_{k+1} = \text{prox}_{tg}(y_k - t\nabla f(y_k)), \quad y_{k+1} = x_{k+1} + \frac{k-1}{k+2}(x_{k+1} - x_k)$$

## Связи между методами

**ADMM = DRS** (Douglas-Rachford Splitting):

ADMM для  $\min f(x) + g(z), Ax + Bz = c \iff$  DRS в двойственном пространстве

**FISTA = AGD + Proximal:**

$$x_{k+1} = \text{prox}_{tg}(y_k - t\nabla f(y_k)), \quad y_{k+1} = x_{k+1} + \frac{k-1}{k+2}(x_{k+1} - x_k)$$

**FedAvg**  $\boxtimes$  **local SGD**  $\boxtimes$  **ADMM consensus:**

$$\min \frac{1}{N} \sum_{i=1}^N f_i(w) \iff \min \sum_i f_i(w_i) \text{ s.t. } w_i = w$$

## Современные направления

## Frontier: стохастические методы второго порядка

**Проблема:** Hessian  $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$  память,  $O(d^3)$  инверсия. Недопустимо для LLM ( $d \sim 10^9$ ).

## Frontier: стохастические методы второго порядка

**Проблема:** Hessian  $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$  память,  $O(d^3)$  инверсия. Недопустимо для LLM ( $d \sim 10^9$ ).

**Решения:**

| Метод   | Идея                              | Стоимость     |
|---------|-----------------------------------|---------------|
| L-BFGS  | $m$ последних градиентов          | $O(md)$       |
| K-FAC   | $H \approx A \otimes G$ (блочная) | $O(d^{1.5})$  |
| Shampoo | Блочный L-BFGS для тензоров       | $O(d^{1.5})$  |
| SOAP    | Shampoo + Adam в одном            | $O(d^{1.5})$  |
| Muon    | Nesterov + матричная форма        | $O(d \log d)$ |

## Frontier: стохастические методы второго порядка

**Проблема:** Hessian  $\nabla^2 f \in \mathbb{R}^{d \times d} \rightarrow O(d^2)$  память,  $O(d^3)$  инверсия. Недопустимо для LLM ( $d \sim 10^9$ ).

**Решения:**

| Метод   | Идея                              | Стоимость     |
|---------|-----------------------------------|---------------|
| L-BFGS  | $m$ последних градиентов          | $O(md)$       |
| K-FAC   | $H \approx A \otimes G$ (блочная) | $O(d^{1.5})$  |
| Shampoo | Блочный L-BFGS для тензоров       | $O(d^{1.5})$  |
| SOAP    | Shampoo + Adam в одном            | $O(d^{1.5})$  |
| Muon    | Nesterov + матричная форма        | $O(d \log d)$ |

Shampoo и K-FAC используются в продакшене (Google, Meta).

## Frontier: Adam и трансформеры

**Adam не имеет строгой теоремы** для невыпуклых стохастических задач (открытая проблема!).

## Frontier: Adam и трансформеры

**Adam не имеет строгой теоремы** для невыпуклых стохастических задач (открытая проблема!).

**Что известно:** - Adam с gradient clipping сходится (Zhang et al., 2020) - «Implicit bias» Adam  $\neq$  implicit bias GD  
→ разная генерализация - AdamW = Adam + weight decay (без decay на LayerNorm и biases)



# Frontier: Adam и трансформеры

**Adam не имеет строгой теоремы** для невыпуклых стохастических задач (открытая проблема!).

**Что известно:** - Adam с gradient clipping сходится (Zhang et al., 2020) - «Implicit bias» Adam  $\neq$  implicit bias GD  
→ разная генерализация - AdamW = Adam + weight decay (без decay на LayerNorm и biases)

**Muon** (Kosson & Brendan, 2025) — state-of-art для трансформеров:

$$G_t = \text{Nesterov}(\nabla \mathcal{L}_t), \quad \Delta W = \frac{G_t}{\|G_t\|_F}$$

Нормировка по фробениусовой норме = implicit matrix conditioning.

# Frontier: генеративные модели и оптимизация

**Diffusion models** = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

# Frontier: генеративные модели и оптимизация

**Diffusion models** = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

**RLHF** = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика  $\pi$ . Внутренняя: reward model  $r_\phi$ .

# Frontier: генеративные модели и оптимизация

**Diffusion models** = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

**RLHF** = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика  $\pi$ . Внутренняя: reward model  $r_\phi$ .

**GAN** = min-max (седловая задача):

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

# Frontier: генеративные модели и оптимизация

**Diffusion models** = оптимизация в пространстве функции score:

$$\nabla_x \log p(x) \approx s_\theta(x, t) \quad (\text{score function})$$

**RLHF** = двухуровневая (bi-level) оптимизация:

$$\max_{\pi} \mathbb{E}_{x \sim \pi} [r_\phi(x)] - \beta \text{KL}(\pi \| \pi_0)$$

Внешняя: политика  $\pi$ . Внутренняя: reward model  $r_\phi$ .

**GAN** = min-max (седловая задача):

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

**Открытые вопросы:** сходимость GAN (нет гарантий!), оптимальный schedule для RLHF, масштабирование Diffusion.

## Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.

# Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)

# Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?



# Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?
4. **Невыпуклость + PL:** когда PL выполняется для NN на практике? Связь с NTK?

# Открытые задачи связанные с курсом

1. **Adam: теорема для невыпуклых задач?** Строгих гарантий нет. Adam с AMSGrad частично решает, но практически хуже.
2. **High-order splitting для ML:** что такое «Strang-Adam»? Быстрее ли Strang-ISTA для Lasso? (Диссертация Даниила!)
3. **FL + LLM:** как делать FedAvg с LoRA-адаптацией? Convergence?
4. **Невыпуклость + PL:** когда PL выполняется для NN на практике? Связь с NTK?
5. **Privacy-utility-communication trilemma:** нет единого оптимального решения для FL.

## Подготовка к экзамену

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):**  $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):**  $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:**  $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):**  $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:**  $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL  $\rightarrow$  линейная сходимость:**  $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$



## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):**  $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:**  $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL  $\rightarrow$  линейная сходимость:**  $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$
6. **Frank-Wolfe:**  $f(x_k) - f^* \leq \frac{2LD^2}{k+2}$ , где  $D = \text{diam}(\mathcal{X})$

## 7 теорем, которые нужно знать

Обязательные:

1. **GD выпуклый:**  $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$
2. **GD сильно выпуклый:**  $\|x_k - x^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|x_0 - x^*\|^2$
3. **AGD (Нестеров):**  $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2}$
4. **SGD невыпуклый:**  $\min_k \|\nabla f(x_k)\|^2 \leq \frac{2L(f_0 - f^*)}{K} + \frac{L\sigma^2}{K}$
5. **PL  $\rightarrow$  линейная сходимость:**  $\|\nabla f\|^2 \geq 2\mu(f - f^*) \Rightarrow f(x_k) - f^* \leq (1 - \mu/L)^k (f_0 - f^*)$
6. **Frank-Wolfe:**  $f(x_k) - f^* \leq \frac{2LD^2}{k+2}$ , где  $D = \text{diam}(\mathcal{X})$
7. **PDHG:** сходится при  $\tau\sigma\|K\|^2 \leq 1$

# Типичные экзаменационные задачи

**Тип 1 — Доказательство:** - Докажите нижнюю оценку  $\Omega(1/k^2)$  для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

# Типичные экзаменационные задачи

**Тип 1 — Доказательство:** - Докажите нижнюю оценку  $\Omega(1/k^2)$  для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

**Тип 2 — Вычисление:** - Запишите двойственную задачу для LASSO / SVM - Вычислите  $\text{prox}_{\lambda\|x\|_1}(v)$  и  $\text{prox}_{\lambda\|x\|_2}(v)$  - Найдите оптимальный шаг для Ridge regression

# Типичные экзаменационные задачи

**Тип 1 — Доказательство:** - Докажите нижнюю оценку  $\Omega(1/k^2)$  для выпуклых задач - Покажите что ADMM = DRS для консенсусной задачи - Выведите условие шага для PDHG

**Тип 2 — Вычисление:** - Запишите двойственную задачу для LASSO / SVM - Вычислите  $\text{prox}_{\lambda\|x\|_1}(v)$  и  $\text{prox}_{\lambda\|x\|_2}(v)$  - Найдите оптимальный шаг для Ridge regression

**Тип 3 — Выбор алгоритма:** - «Дана задача  $X$  с параметрами  $Y$  — какой метод, какая скорость?» - «Сравните SGD и SVRG для задачи с  $n = 10^6$ ,  $\kappa = 100$ »

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity



# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

## Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

## Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

## Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

## Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

# Советы к экзамену

## Стратегия подготовки:

1. **Мегатаблица наизусть:** для каждого метода знать класс задачи + скорость + условия
2. **Доказательства по шагам:** GD + AGD + FISTA — три базовых доказательства
3. **Прокс-операторы:**  $\ell_1$ ,  $\ell_2$ , индикатор  $C$ , Moreau identity
4. **Числовые примеры:** уметь решать конкретные задачи с числами

## Самопроверка:

- Можете ли вы объяснить каждый метод из мегатаблицы за 30 секунд?
- Понимаете ли вы *почему* AGD быстрее GD (не только формулу)?
- Можете ли вы применить дерево решений к новой задаче?

## Главный совет

Найдите **\*\*условия\*\*** теорем, не только результаты. Экзаменатор проверит именно их.

## Заключение



## Что дальше после курса

**Для практиков (ML-инженеры):** - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

## Что дальше после курса

**Для практиков (ML-инженеры):** - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

**Для исследователей:** - Нижние оценки (Nesterov lower bound framework) - Operator splitting для составных задач - Stochastic variance reduction (SVRG, SARAH, SPIDER)

## Что дальше после курса

**Для практиков (ML-инженеры):** - Adam/AdamW + cosine LR schedule — стандарт для DL - L-BFGS — для малых задач и fine-tuning - SCAFFOLD / DP-SGD — если FL с конфиденциальностью

**Для исследователей:** - Нижние оценки (Nesterov lower bound framework) - Operator splitting для составных задач - Stochastic variance reduction (SVRG, SARAH, SPIDER)

**Для теоретиков:** - Convergence Adam — открытая задача - Non-convex optimization за пределами PL - Optimal FL communication complexity

# Оптимизация как профессия

**Журналы:** JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

# Оптимизация как профессия

**Журналы:** JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

**Конференции:** NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

# Оптимизация как профессия

**Журналы:** JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖВММФ (БАК)

**Конференции:** NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

**Ключевые исследовательские группы:** Nesterov (Louvain), Jordan (Berkeley), Sra (MIT), Richtárik (KAUST), Dvurechensky (Berlin), Меркулов (AI4Science Сбеа)

# Оптимизация как профессия

**Журналы:** JMLR, Mathematical Programming, SIAM Journal on Optimization, ЖБММФ (БАК)

**Конференции:** NeurIPS, ICML, ICLR (ML), SIAM OP, ISMP (чистая оптимизация)

**Ключевые исследовательские группы:** Nesterov (Louvain), Jordan (Berkeley), Sra (MIT), Richtárik (KAUST), Dvurechensky (Berlin), Меркулов (AI4Science Сбера)

Курс закончен — оптимизация продолжается!

Оптимизация = фундамент современного ML. Всё, что обучается, оптимизируется. Всё, что оптимизируется — требует теории.

# Спасибо за курс!

Удачи на экзамене!

Материалы курса: `hse26.fmin.xyz`

Вопросы после экзамена: Telegram @bratishk

*«An algorithm must be seen to be believed.»*

*— Donald Knuth*