

Условия оптимальности. Оптимизация с ограничениями. ККТ.

Семинар


ФКН ВШЭ

Условия оптимальности. Повторение основных понятий

$$f(x) \rightarrow \min_{x \in S}$$

Множество S обычно называется допустимым множеством.

- Точка x^* является глобальным минимумом, если $f(x^*) \leq f(x)$ для всех x .




Условия оптимальности. Повторение основных понятий

$$f(x) \rightarrow \min_{x \in S}$$

Множество S обычно называется допустимым множеством.

- Точка x^* является глобальным минимумом, если $f(x^*) \leq f(x)$ для всех x .
- Точка x^* является локальным минимумом, если существует окрестность N точки x^* такая, что $f(x^*) \leq f(x)$ для всех $x \in N$.




Условия оптимальности. Повторение основных понятий

$$f(x) \rightarrow \min_{x \in S}$$

Множество S обычно называется допустимым множеством.

- Точка x^* является глобальным минимумом, если $f(x^*) \leq f(x)$ для всех x .
- Точка x^* является локальным минимумом, если существует окрестность N точки x^* такая, что $f(x^*) \leq f(x)$ для всех $x \in N$.
- Точка x^* является строгим локальным минимумом (также называемым сильным локальным минимумом), если существует окрестность N точки x^* такая, что $f(x^*) < f(x)$ для всех $x \in N, x \neq x^*$.




Условия оптимальности. Повторение основных понятий

$$f(x) \rightarrow \min_{x \in S}$$

Множество S обычно называется допустимым множеством.

- Точка x^* является глобальным минимумом, если $f(x^*) \leq f(x)$ для всех x .
- Точка x^* является локальным минимумом, если существует окрестность N точки x^* такая, что $f(x^*) \leq f(x)$ для всех $x \in N$.
- Точка x^* является строгим локальным минимумом (также называемым сильным локальным минимумом), если существует окрестность N точки x^* такая, что $f(x^*) < f(x)$ для всех $x \in N, x \neq x^*$.
- Точку x^* называют стационарной точкой (или критической), если $\nabla f(x^*) = 0$. Любой локальный минимум обязательно является стационарной точкой.



Повторение: оптимизация без ограничений

💡 Необходимые условия первого порядка

Если x^* является локальным минимумом и f непрерывно дифференцируема в открытой окрестности, то

$$\nabla f(x^*) = 0 \quad (1)$$

💡 Достаточные условия второго порядка

Предположим, что $\nabla^2 f$ непрерывен в открытой окрестности точки x^* и выполняется

$$\nabla f(x^*) = 0 \quad \nabla^2 f(x^*) \succ 0. \quad (2)$$

Тогда x^* является строгим локальным минимумом f .

Оптимизация с ограничениями-равенствами

Рассмотрим простой, но практически важный случай ограничений в виде равенств:

$$f(x) \rightarrow \min_{x \in \mathbb{R}^n}$$

при $h_i(x) = 0, i = 1, \dots, p$

Повторение: множители Лагранжа

Основная идея метода Лагранжа состоит в переходе от условной оптимизации к безусловной путём увеличения размерности задачи:

$$L(x, \nu) = f(x) + \sum_{i=1}^p \nu_i h_i(x) = f(x) + \nu^T h(x) \rightarrow \min_{x \in \mathbb{R}^n, \nu \in \mathbb{R}^p}$$

Повторение: множители Лагранжа

Основная идея метода Лагранжа состоит в переходе от условной оптимизации к безусловной путём увеличения размерности задачи:

$$L(x, \nu) = f(x) + \sum_{i=1}^p \nu_i h_i(x) = f(x) + \nu^T h(x) \rightarrow \min_{x \in \mathbb{R}^n, \nu \in \mathbb{R}^p}$$

Необходимые условия:

$$\nabla_x L(x^*, \nu^*) = 0$$

$$\nabla_\nu L(x^*, \nu^*) = 0$$

Достаточные условия:

$$\langle y, \nabla_{xx}^2 L(x^*, \nu^*) y \rangle > 0,$$

$$\forall y \neq 0 \in \mathbb{R}^n : \nabla h_i(x^*)^T y = 0$$

Оптимизация с ограничениями-неравенствами

Рассмотрим простой, но практически важный случай ограничений в виде неравенств:

$$f(x) \rightarrow \min_{x \in \mathbb{R}^n}$$

при $g(x) \leq 0$

Оптимизация с ограничениями-неравенствами

Рассмотрим простой, но практически важный случай ограничений в виде неравенств:

$$f(x) \rightarrow \min_{x \in \mathbb{R}^n}$$

при $g(x) \leq 0$

$g(x) \leq 0$ **неактивно**. $g(x^*) < 0$:

$$\begin{aligned} g(x^*) &< 0 \\ \nabla f(x^*) &= 0 \\ \nabla^2 f(x^*) &> 0 \end{aligned}$$

$g(x) \leq 0$ **активно**. $g(x^*) = 0$:

$$\begin{aligned} g(x^*) &= 0 \\ -\nabla f(x^*) &= \lambda \nabla g(x^*), \lambda > 0 \\ \langle y, \nabla_{xx}^2 L(x^*, \lambda^*) y \rangle &> 0, \\ \forall y \neq 0 \in \mathbb{R}^n : \nabla g(x^*)^\top y &= 0 \end{aligned}$$

Общая постановка

Общая задача математического программирования:

$$\begin{aligned} f_0(x) &\rightarrow \min_{x \in \mathbb{R}^n} \\ \text{при } f_i(x) &\leq 0, \quad i = 1, \dots, m \\ h_i(x) &= 0, \quad i = 1, \dots, p \end{aligned}$$

Общая постановка

Общая задача математического программирования:

$$\begin{aligned} f_0(x) &\rightarrow \min_{x \in \mathbb{R}^n} \\ \text{при } f_i(x) &\leq 0, \quad i = 1, \dots, m \\ h_i(x) &= 0, \quad i = 1, \dots, p \end{aligned}$$

Решение предполагает построение функции Лагранжа:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

ККТ: необходимые условия

Пусть x^* , (λ^*, ν^*) является решением задачи математического программирования с нулевым зазором двойственности (оптимальное значение прямой задачи p^* равно оптимальному значению двойственной задачи d^*). Пусть также функции f_0, f_i, h_i дифференцируемы.

ККТ: необходимые условия

Пусть x^* , (λ^*, ν^*) является решением задачи математического программирования с нулевым зазором двойственности (оптимальное значение прямой задачи p^* равно оптимальному значению двойственной задачи d^*). Пусть также функции f_0, f_i, h_i дифференцируемы.

$$(1) \nabla_x L(x^*, \lambda^*, \nu^*) = 0$$

$$(2) \nabla_\nu L(x^*, \lambda^*, \nu^*) = 0$$

$$(3) \lambda_i^* \geq 0, i = 1, \dots, m$$

$$(4) \lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$$

$$(5) f_i(x^*) \leq 0, i = 1, \dots, m$$

ККТ: условия регулярности

Эти условия необходимы для того, чтобы решения ККТ являлись необходимыми условиями. Некоторые из них превращают необходимые условия в достаточные. Например, условие Слейтера:

ККТ: условия регулярности

Эти условия необходимы для того, чтобы решения ККТ являлись необходимыми условиями. Некоторые из них превращают необходимые условия в достаточные. Например, условие Слейтера:

Если для выпуклой задачи (т. е. при минимизации f_0, f_i выпуклы, а h_i аффинны) существует точка x такая, что $h(x) = 0$ и $f_i(x) < 0$ (существование строго допустимой точки), то зазор двойственности равен нулю, а условия ККТ становятся необходимыми и достаточными.

ККТ: достаточные условия

Для гладких нелинейных задач оптимизации достаточное условие второго порядка формулируется следующим образом. Решение x^*, λ^*, ν^* , удовлетворяющее условиям ККТ (выше), является условным локальным минимумом, если для функции Лагранжа

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

выполняются следующие условия:

$$\langle y, \nabla_{xx}^2 L(x^*, \lambda^*, \nu^*) y \rangle > 0$$

$$\forall y \neq 0 \in \mathbb{R}^n : \nabla h_i(x^*)^\top y = 0, \nabla f_0(x^*)^\top y \leq 0, \nabla f_j(x^*)^\top y = 0$$

$$i = 1, \dots, p \quad \forall j : f_j(x^*) = 0$$

Задача 1

i Question

Функция $f : E \rightarrow \mathbb{R}$ определена как

$$f(x) = \ln(-Q(x))$$

где $E = \{x \in \mathbb{R}^n : Q(x) < 0\}$ и

$$Q(x) = \frac{1}{2}x^\top Ax + b^\top x + c$$

с $A \in \mathbb{S}_{++}^n$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$.

Найдите максимум x^* функции f .

Задача 2

i Question

Дайте явное решение следующей задачи.

$$f(x, y) = x + y \rightarrow \min$$

при $x^2 + y^2 = 1$

где $x, y \in \mathbb{R}$.

Задача 3

i Question

Дайте явное решение следующей задачи.

$$\langle c, x \rangle + \sum_{i=1}^n x_i \log x_i \rightarrow \min_{x \in \mathbb{R}^n}$$

при $\sum_{i=1}^n x_i = 1,$

где $x \in \mathbb{R}_{++}^n, c \neq 0$.

Задача 4

Question

Пусть $A \in \mathbb{S}_{++}^n, b > 0$. Покажите, что:

$$\det(X) \rightarrow \max_{X \in \mathbb{S}_{++}^n} \text{ при } \langle A, X \rangle \leq b$$

имеет единственное решение, и найдите его.

Задача 5

i Question

Дано $y \in \{-1, 1\}$ и $X \in \mathbb{R}^{n \times p}$. Задача метода опорных векторов (SVM) имеет вид:

$$\frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \xi_i \rightarrow \min_{w, w_0, \xi_i}$$

при $\xi_i \geq 0, i = 1, \dots, n$

$$y_i(x_i^T w + w_0) \geq 1 - \xi_i, i = 1, \dots, n$$

Найдите условие стационарности ККТ.

Задача 6

i Question

Покажите, что следующая задача условной оптимизации имеет единственное решение, и найдите его.

$$\langle C^{-1}, X \rangle - \log \det(X) \rightarrow \min_{X \in \mathbb{S}_{++}^n} \text{ при } a^T X a \leq 1$$

$$C \in \mathbb{S}_{++}^n, a \neq 0$$

В ответе следует избегать явного обращения матрицы C .

Задача 7 (БОНУС)

Для некоторых $\Sigma, \Sigma_0 \in \mathbb{S}_{++}^n$ определим дивергенцию Кульбака-Лейблера между двумя гауссовскими распределениями как:

$$D(\Sigma, \Sigma_0) = \frac{1}{2}(\langle \Sigma_0^{-1}, \Sigma \rangle - \log \det(\Sigma_0^{-1} \Sigma) - n)$$

Пусть $H \in \mathbb{S}_{++}^n$ и $y, x \in \mathbb{R}^n : \langle y, s \rangle > 0$.

Требуется решить следующую задачу условной минимизации:

$$\min_{X \in \mathbb{S}_{++}^n} \{D(X^{-1}, H^{-1}) | Xy = s\}$$

Докажите, что она имеет единственное решение, равное:

$$(I_n - \frac{sy^T}{y^T s})H(I_n - \frac{ys^T}{y^T s}) + \frac{ss^T}{y^T s}$$

Задача 8 (БОНУС)

Question

Пусть $e_1, \dots, e_n$ — стандартный базис в $\mathbb{R}^n$. Покажите, что:

$$\max_{X \in \mathbb{S}_{++}^n} \det(X) : \|Xe_i\| \leq 1 \forall i \in 1, \dots, n$$

имеет единственное решение I_n , и выведите неравенство Адамара:

$$\det(X) \leq \prod_{i=1}^n \|Xe_i\| \forall X \in \mathbb{S}_{++}^n$$

Атаки состязательными примерами

Определение: атаки состязательными примерами — методы, используемые для обмана моделей глубокого обучения путём добавления малых возмущений к входным данным. Задачу атак состязательными примерами можно сформулировать как задачу условной оптимизации, где цель — минимизировать/максимизировать функцию потерь при ограничении на величину возмущения (ограничение на норму).

Метод быстрого знакового градиента (FGSM) — наиболее простой такой метод, генерирующий состязательные примеры путём добавления малого возмущения в направлении знака градиента функции потерь. Формально:

$$x' = x + \varepsilon \cdot \text{sgn}(\nabla_x L(x, y)), \text{ при } \|x - x'\| \leq \varepsilon$$

По существу, метод выполняет градиентный подъём по изображению (т. е. максимизирует потери по данному изображению).




Figure 2: Иллюстрация различных стационарных (критических) точек