

# Градиентный спуск и сходимость

Семинар

ФКН ВШЭ

# Градиентный спуск

Рассмотрим задачу минимизации гладкой функции  $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$f(x) \rightarrow \min_{x \in \mathbb{R}}$$

# Градиентный спуск

Рассмотрим задачу минимизации гладкой функции  $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$f(x) \rightarrow \min_{x \in \mathbb{R}}$$

Один из методов решения — **градиентный спуск**:

$$x_{k+1} = x_k - \eta_k \nabla f(x_k)$$

# Градиентный спуск

Рассмотрим задачу минимизации гладкой функции  $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$f(x) \rightarrow \min_{x \in \mathbb{R}}$$

Один из методов решения — **градиентный спуск**:

$$x_{k+1} = x_k - \eta_k \nabla f(x_k)$$

Узким местом (практически для всех градиентных методов) является выбор размера шага, который может кардинально влиять на поведение метода.

## Как выбирать размер шага

- Одно из теоретических предложений: выбирать размер шага обратно пропорционально константе Липшица градиента

$$\eta_k = \frac{1}{L}$$

## Как выбирать размер шага

- Одно из теоретических предложений: выбирать размер шага обратно пропорционально константе Липшица градиента

$$\eta_k = \frac{1}{L}$$

## Как выбирать размер шага

- Одно из теоретических предложений: выбрать размер шага обратно пропорционально константе Липшица градиента

$$\eta_k = \frac{1}{L}$$

- Поиск с возвратом.** Зафиксируем два параметра:  $0 < \beta < 1$  и  $0 < \alpha \leq 0.5$ . На каждой итерации начинаем с  $t = 1$ , и пока

$$f(x_k - t\nabla f(x_k)) > f(x_k) - \alpha t \|\nabla f(x_k)\|_2^2,$$

уменьшаем  $t = \beta t$ . Иначе выполняем шаг градиентного спуска  $x_{k+1} = x_k - t\nabla f(x_k)$ .

## Как выбирать размер шага

- Одно из теоретических предложений: выбрать размер шага обратно пропорционально константе Липшица градиента

$$\eta_k = \frac{1}{L}$$

- Поиск с возвратом.** Зафиксируем два параметра:  $0 < \beta < 1$  и  $0 < \alpha \leq 0.5$ . На каждой итерации начинаем с  $t = 1$ , и пока

$$f(x_k - t\nabla f(x_k)) > f(x_k) - \alpha t \|\nabla f(x_k)\|_2^2,$$

уменьшаем  $t = \beta t$ . Иначе выполняем шаг градиентного спуска  $x_{k+1} = x_k - t\nabla f(x_k)$ .



## Как выбирать размер шага

- Одно из теоретических предложений: выбрать размер шага обратно пропорционально константе Липшица градиента

$$\eta_k = \frac{1}{L}$$

- Поиск с возвратом.** Зафиксируем два параметра:  $0 < \beta < 1$  и  $0 < \alpha \leq 0.5$ . На каждой итерации начинаем с  $t = 1$ , и пока

$$f(x_k - t\nabla f(x_k)) > f(x_k) - \alpha t \|\nabla f(x_k)\|_2^2,$$

уменьшаем  $t = \beta t$ . Иначе выполняем шаг градиентного спуска  $x_{k+1} = x_k - t\nabla f(x_k)$ .

- Точный линейный поиск.**

$$\eta_k = \arg \min_{\eta \geq 0} f(x_k - \eta \nabla f(x_k))$$

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

Хотим, чтобы  $h$  было убывающим направлением:

$$f(x + \alpha h) < f(x)$$

$$f(x) + \alpha \langle f'(x), h \rangle + o(\alpha) < f(x)$$

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

Хотим, чтобы  $h$  было убывающим направлением:

$$f(x + \alpha h) < f(x)$$

$$f(x) + \alpha \langle f'(x), h \rangle + o(\alpha) < f(x)$$

и переходя к пределу при  $\alpha \rightarrow 0$ :

$$\langle f'(x), h \rangle \leq 0$$

## Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

Хотим, чтобы  $h$  было убывающим направлением:

$$f(x + \alpha h) < f(x)$$

$$f(x) + \alpha \langle f'(x), h \rangle + o(\alpha) < f(x)$$

и переходя к пределу при  $\alpha \rightarrow 0$ :

$$\langle f'(x), h \rangle \leq 0$$

Из неравенства Коши–Буняковского–Шварца:

$$\begin{aligned} |\langle f'(x), h \rangle| &\leq \|f'(x)\|_2 \|h\|_2 \\ \langle f'(x), h \rangle &\geq -\|f'(x)\|_2 \|h\|_2 = -\|f'(x)\|_2 \end{aligned}$$

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

Хотим, чтобы  $h$  было убывающим направлением:

$$f(x + \alpha h) < f(x)$$

$$f(x) + \alpha \langle f'(x), h \rangle + o(\alpha) < f(x)$$

и переходя к пределу при  $\alpha \rightarrow 0$ :

$$\langle f'(x), h \rangle \leq 0$$

Из неравенства Коши–Буняковского–Шварца:

$$\begin{aligned} |\langle f'(x), h \rangle| &\leq \|f'(x)\|_2 \|h\|_2 \\ \langle f'(x), h \rangle &\geq -\|f'(x)\|_2 \|h\|_2 = -\|f'(x)\|_2 \end{aligned}$$

Таким образом, направление антиградиента

$$h = -\frac{f'(x)}{\|f'(x)\|_2}$$

задаёт направление **наискорейшего локального убывания** функции  $f$ .

# Направление наискорейшего локального убывания

Рассмотрим линейное приближение дифференцируемой функции  $f$  вдоль некоторого направления  $h$ ,  $\|h\|_2 = 1$ :

$$f(x + \alpha h) = f(x) + \alpha \langle f'(x), h \rangle + o(\alpha)$$

Хотим, чтобы  $h$  было убывающим направлением:

$$f(x + \alpha h) < f(x)$$

$$f(x) + \alpha \langle f'(x), h \rangle + o(\alpha) < f(x)$$

и переходя к пределу при  $\alpha \rightarrow 0$ :

$$\langle f'(x), h \rangle \leq 0$$

Из неравенства Коши–Буняковского–Шварца:

$$\begin{aligned} |\langle f'(x), h \rangle| &\leq \|f'(x)\|_2 \|h\|_2 \\ \langle f'(x), h \rangle &\geq -\|f'(x)\|_2 \|h\|_2 = -\|f'(x)\|_2 \end{aligned}$$

Таким образом, направление антиградиента

$$h = -\frac{f'(x)}{\|f'(x)\|_2}$$

задаёт направление **наискорейшего локального убывания** функции  $f$ .

Результат применения этого метода:

$$x_{k+1} = x_k - \alpha f'(x_k)$$



## Минимизатор параболы Липшица

Если функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

## Минимизатор параболы Липшица

Если функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

что геометрически означает: если зафиксировать некоторую точку  $x_0 \in \mathbb{R}^n$  и определить две параболы:

$$\phi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2,$$

$$\phi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2.$$

## Минимизатор параболы Липшица

Если функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

что геометрически означает: если зафиксировать некоторую точку  $x_0 \in \mathbb{R}^n$  и определить две параболы:

$$\phi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2,$$

$$\phi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2.$$

Тогда

$$\phi_1(x) \leq f(x) \leq \phi_2(x) \quad \forall x \in \mathbb{R}^n.$$

## Минимизатор параболы Липшица

Если функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

что геометрически означает: если зафиксировать некоторую точку  $x_0 \in \mathbb{R}^n$  и определить две параболы:

$$\phi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2,$$

$$\phi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2.$$

Тогда

$$\phi_1(x) \leq f(x) \leq \phi_2(x) \quad \forall x \in \mathbb{R}^n.$$

Теперь, имея глобальную верхнюю оценку функции в виде параболы, можно попробовать перейти непосредственно к её минимуму.

## Минимизатор параболы Липшица

Если функция  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

что геометрически означает: если зафиксировать некоторую точку  $x_0 \in \mathbb{R}^n$  и определить две параболы:

$$\phi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2,$$

$$\phi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2.$$

Тогда

$$\phi_1(x) \leq f(x) \leq \phi_2(x) \quad \forall x \in \mathbb{R}^n.$$

Теперь, имея глобальную верхнюю оценку функции в виде параболы, можно попробовать перейти непосредственно к её минимуму.




Figure 1: Иллюстрация

## Минимизатор параболы Липшица

Если функция  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  непрерывно дифференцируема и её градиент удовлетворяет условию Липшица с константой  $L$ , то  $\forall x, y \in \mathbb{R}^n$ :

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2,$$

что геометрически означает: если зафиксировать некоторую точку  $x_0 \in \mathbb{R}^n$  и определить две параболы:

$$\phi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2,$$

$$\phi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2.$$

Тогда

$$\phi_1(x) \leq f(x) \leq \phi_2(x) \quad \forall x \in \mathbb{R}^n.$$

Теперь, имея глобальную верхнюю оценку функции в виде параболы, можно попробовать перейти непосредственно к её минимуму.




Figure 1: Иллюстрация

$$\nabla \phi_2(x) = 0$$

$$\nabla f(x_0) + L(x^* - x_0) = 0$$

$$x^* = x_0 - \frac{1}{L} \nabla f(x_0)$$

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$$

Этот путь приводит к выбору размера шага  $\frac{1}{L}$ . Однако константа  $L$  часто неизвестна.

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является RL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является RL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является PL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$f(x) - f(x^*) \leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 =$$



# Любая $\mu$ -сильно выпуклая дифференцируемая функция является RL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является RL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$\begin{aligned} f(x) - f(x^*) &\leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 = \\ &= \left( \nabla f(x)^T - \frac{\mu}{2}(x^* - x) \right)^T (x - x^*) = \end{aligned}$$

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является PL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$\begin{aligned} f(x) - f(x^*) &\leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 = \\ &= \left( \nabla f(x)^T - \frac{\mu}{2}(x^* - x) \right)^T (x - x^*) = \\ &= \frac{1}{2} \left( \frac{2}{\sqrt{\mu}} \nabla f(x)^T - \sqrt{\mu}(x^* - x) \right)^T \sqrt{\mu}(x - x^*) = \end{aligned}$$

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является PL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$\begin{aligned} f(x) - f(x^*) &\leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 = \\ &= \left( \nabla f(x)^T - \frac{\mu}{2}(x^* - x) \right)^T (x - x^*) = \\ &= \frac{1}{2} \left( \frac{2}{\sqrt{\mu}} \nabla f(x)^T - \sqrt{\mu}(x^* - x) \right)^T \sqrt{\mu}(x - x^*) = \end{aligned}$$

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является RL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является RL-функцией.

## Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$\begin{aligned} f(x) - f(x^*) &\leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 = \\ &= \left( \nabla f(x)^T - \frac{\mu}{2}(x^* - x) \right)^T (x - x^*) = \\ &= \frac{1}{2} \left( \frac{2}{\sqrt{\mu}} \nabla f(x)^T - \sqrt{\mu}(x^* - x) \right)^T \sqrt{\mu}(x - x^*) = \end{aligned}$$

Пусть  $a = \frac{1}{\sqrt{\mu}} \nabla f(x)$  и  
 $b = \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x)$

# Любая $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

## i Theorem

Если функция  $f(x)$  дифференцируема и  $\mu$ -сильно выпукла, то она является PL-функцией.

### Доказательство

По критерию сильной выпуклости первого порядка:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{\mu}{2}\|y - x\|_2^2$$

Подставляя  $y = x^*$ :

$$f(x^*) \geq f(x) + \nabla f(x)^T(x^* - x) + \frac{\mu}{2}\|x^* - x\|_2^2$$

$$\begin{aligned} f(x) - f(x^*) &\leq \nabla f(x)^T(x - x^*) - \frac{\mu}{2}\|x^* - x\|_2^2 = \\ &= \left( \nabla f(x)^T - \frac{\mu}{2}(x^* - x) \right)^T (x - x^*) = \\ &= \frac{1}{2} \left( \frac{2}{\sqrt{\mu}} \nabla f(x)^T - \sqrt{\mu}(x^* - x) \right)^T \sqrt{\mu}(x - x^*) = \end{aligned}$$

Пусть  $a = \frac{1}{\sqrt{\mu}} \nabla f(x)$  и

$$b = \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x)$$

Тогда  $a + b = \sqrt{\mu}(x - x^*)$  и

$$a - b = \frac{2}{\sqrt{\mu}} \nabla f(x) - \sqrt{\mu}(x - x^*)$$

Любая  $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

$$f(x) - f(x^*) \leq \frac{1}{2} \left( \frac{1}{\mu} \|\nabla f(x)\|_2^2 - \left\| \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x) \right\|_2^2 \right)$$

Любая  $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

$$f(x) - f(x^*) \leq \frac{1}{2} \left( \frac{1}{\mu} \|\nabla f(x)\|_2^2 - \left\| \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x) \right\|_2^2 \right)$$
$$f(x) - f(x^*) \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2,$$

Любая  $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

$$f(x) - f(x^*) \leq \frac{1}{2} \left( \frac{1}{\mu} \|\nabla f(x)\|_2^2 - \left\| \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x) \right\|_2^2 \right)$$
$$f(x) - f(x^*) \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2,$$



## Любая $\mu$ -сильно выпуклая дифференцируемая функция является PL-функцией

$$f(x) - f(x^*) \leq \frac{1}{2} \left( \frac{1}{\mu} \|\nabla f(x)\|_2^2 - \left\| \sqrt{\mu}(x - x^*) - \frac{1}{\sqrt{\mu}} \nabla f(x) \right\|_2^2 \right)$$
$$f(x) - f(x^*) \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2,$$

что в точности является условием Поляка-Лоясиевича (PL). Это означает, что у нас уже есть доказательство линейной сходимости для любой сильно выпуклой функции.

## Точный линейный поиск, он же метод наискорейшего спуска

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_{k+1}) = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Более теоретический, чем практический подход. Он также позволяет анализировать сходимость, однако точный линейный поиск зачастую затруднён, если вычисление функции занимает много времени или обходится дорого.

Интересное теоретическое свойство этого метода состоит в том, что каждая следующая итерация ортогональна предыдущей:

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Условия оптимальности:

$$\nabla f(x_{k+1})^\top \nabla f(x_k) = 0$$




Figure 2: Метод наискорейшего спуска

Открыть в Colab

## Анализ сходимости. Поиск с возвратом

Предположим, что  $f$  выпукла, дифференцируема и имеет Липшиц-непрерывный градиент с константой  $L > 0$ .

### Теорема

Градиентный спуск с фиксированным размером шага  $t \leq 1/L$  удовлетворяет условию

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}$$

## Анализ сходимости. Поиск с возвратом

Предположим, что  $f$  выпукла, дифференцируема и имеет Липшиц-непрерывный градиент с константой  $L > 0$ .

### Теорема

Градиентный спуск с фиксированным размером шага  $t \leq 1/L$  удовлетворяет условию

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}$$

Покажем, что скорость сходимости для поиска с возвратом не хуже  $O(1/k)$

## Анализ сходимости. Поиск с возвратом

Предположим, что  $f$  выпукла, дифференцируема и имеет Липшиц-непрерывный градиент с константой  $L > 0$ .

### Теорема

Градиентный спуск с фиксированным размером шага  $t \leq 1/L$  удовлетворяет условию

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}$$

Покажем, что скорость сходимости для поиска с возвратом не хуже  $O(1/k)$

Поскольку  $\nabla f$  Липшиц-непрерывен с константой  $L > 0$ , имеем

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2, \forall x, y$$

## Анализ сходимости. Поиск с возвратом

Предположим, что  $f$  выпукла, дифференцируема и имеет Липшиц-непрерывный градиент с константой  $L > 0$ .

### Теорема

Градиентный спуск с фиксированным размером шага  $t \leq 1/L$  удовлетворяет условию

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}$$

Покажем, что скорость сходимости для поиска с возвратом не хуже  $O(1/k)$

Поскольку  $\nabla f$  Липшиц-непрерывен с константой  $L > 0$ , имеем

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2, \forall x, y$$

Пусть  $y = x^+ = x - t\nabla f(x)$ , тогда:

$$f(x^+) \leq f(x) - \left(1 - \frac{Lt}{2}\right)t\|\nabla f(x)\|_2^2 \leq f(x) - \frac{1}{2L}\|\nabla f(x)\|_2^2$$

## Анализ сходимости. Поиск с возвратом

Предположим, что  $f$  выпукла, дифференцируема и имеет Липшиц-непрерывный градиент с константой  $L > 0$ .

### Теорема

Градиентный спуск с фиксированным размером шага  $t \leq 1/L$  удовлетворяет условию

$$f(x^{(k)}) - f^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2tk}$$

Покажем, что скорость сходимости для поиска с возвратом не хуже  $O(1/k)$

Поскольку  $\nabla f$  Липшиц-непрерывен с константой  $L > 0$ , имеем

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2, \forall x, y$$

Пусть  $y = x^+ = x - t\nabla f(x)$ , тогда:

$$f(x^+) \leq f(x) - \left(1 - \frac{Lt}{2}\right)t\|\nabla f(x)\|_2^2 \leq f(x) - \frac{1}{2L}\|\nabla f(x)\|_2^2$$

Это напоминает условие остановки в поиске с возвратом при  $\alpha = 0.5, t = \frac{1}{L}$ . Следовательно, поиск с возвратом при  $\alpha = 0.5$  совместно с условием Липшица на градиент гарантирует скорость сходимости  $O(1/k)$ .



## Задача

Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где  $f(x)$  выпукла и  $L$ -гладкая. Найдите скорость сходимости градиентного спуска с оптимальным теоретическим размером шага  $\eta_k = \frac{1}{L}$  для *средней точки* и для *наилучшей точки*. Другими словами, получите верхние оценки для

- $f(\bar{x}_N) - f^*$ , где  $\bar{x}_N = \frac{1}{N} \sum_{i=0}^{N-1} x_i$ ,

### Шаг градиентного спуска

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ \Psi_k(x) \equiv f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right\}$$



## Задача

Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где  $f(x)$  выпукла и  $L$ -гладкая. Найдите скорость сходимости градиентного спуска с оптимальным теоретическим размером шага  $\eta_k = \frac{1}{L}$  для *средней точки* и для *наилучшей точки*. Другими словами, получите верхние оценки для

- $f(\bar{x}_N) - f^*$ , где  $\bar{x}_N = \frac{1}{N} \sum_{i=0}^{N-1} x_i$ ,
- $\min_{0 \leq i \leq N-1} f(x_i) - f^*$ .

### Шаг градиентного спуска

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ \Psi_k(x) \equiv f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right\}$$

## Задача

Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где  $f(x)$  выпукла и  $L$ -гладкая. Найдите скорость сходимости градиентного спуска с оптимальным теоретическим размером шага  $\eta_k = \frac{1}{L}$  для *средней точки* и для *наилучшей точки*. Другими словами, получите верхние оценки для

- $f(\bar{x}_N) - f^*$ , где  $\bar{x}_N = \frac{1}{N} \sum_{i=0}^{N-1} x_i$ ,
- $\min_{0 \leq i \leq N-1} f(x_i) - f^*$ .

### i Шаг градиентного спуска

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ \Psi_k(x) \equiv f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right\}$$

# Задача

Рассмотрим задачу

$$\min_{x \in \mathbb{R}^n} f(x),$$

где  $f(x)$  выпукла и  $L$ -гладкая. Найдите скорость сходимости градиентного спуска с оптимальным теоретическим размером шага  $\eta_k = \frac{1}{L}$  для *средней точки* и для *наилучшей точки*. Другими словами, получите верхние оценки для

- $f(\bar{x}_N) - f^*$ , где  $\bar{x}_N = \frac{1}{N} \sum_{i=0}^{N-1} x_i$ ,
- $\min_{0 \leq i \leq N-1} f(x_i) - f^*$ .

## i Шаг градиентного спуска

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ \Psi_k(x) \equiv f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right\}$$

## 💡 Подсказка

Используйте тот факт, что  $\Psi_k(x)$  является  $L$ -сильно выпуклой благодаря квадратичному регуляризатору.

# Код

Примеры:  фрагмент кода.