

# Ускоренные градиентные методы

Семинар

ФКН ВШЭ

## ГС. Скорости сходимости

$$\min_{x \in \mathbb{R}^n} f(x) \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad \kappa = \frac{L}{\mu}$$

|                | гладкая и выпуклая                                         | гладкая и сильно выпуклая (или PL)                                                                      |
|----------------|------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| Верхняя оценка | $f(x_k) - f^* \approx \mathcal{O}\left(\frac{1}{k}\right)$ | $\ x_k - x^*\ ^2 \approx \mathcal{O}\left(\left(\frac{\kappa - 1}{\kappa + 1}\right)^k\right)$          |
| Нижняя оценка  | $f(x_k) - f^* \approx \Omega\left(\frac{1}{k^2}\right)$    | $\ x_k - x^*\ ^2 \approx \Omega\left(\left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k\right)$ |

# Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку  $x_k$  в направлении  $-\nabla f(x_k)$  на величину  $\alpha_k \|\nabla f(x_k)\|$ .

# Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку  $x_k$  в направлении  $-\nabla f(x_k)$  на величину  $\alpha_k \|\nabla f(x_k)\|$ .

# Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку  $x_k$  в направлении  $-\nabla f(x_k)$  на величину  $\alpha_k \|\nabla f(x_k)\|$ .

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- $x$  в направлении предыдущего шага на величину  $\beta_k \|x_k - x_{k-1}\|$ .

# Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку  $x_k$  в направлении  $-\nabla f(x_k)$  на величину  $\alpha_k \|\nabla f(x_k)\|$ .

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- $x$  в направлении предыдущего шага на величину  $\beta_k \|x_k - x_{k-1}\|$ .

# Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку  $x_k$  в направлении  $-\nabla f(x_k)$  на величину  $\alpha_k \|\nabla f(x_k)\|$ .

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- $x$  в направлении предыдущего шага на величину  $\beta_k \|x_k - x_{k-1}\|$ .

- Ускорение Нестерова

$$x_k - \alpha_k \nabla f(x_k + \beta_k (x_k - x_{k-1})) + \beta_k (x_k - x_{k-1})$$

Сдвинуть ещё-не-обновлённый- $x$  в направлении предыдущего шага на величину  $\beta_k \|x_k - x_{k-1}\|$ ,

выполнить шаг ГС на сдвинутом- $x$ , затем сдвинуть обновлённый- $x$  в направлении предыдущего шага на  $\beta_k \|x_k - x_{k-1}\|$ .

# Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$



# Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x^{k+1} &\in x^0 + \operatorname{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \operatorname{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

# Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

Для построения нижней оценки нам нужно найти функцию  $f$  из соответствующего класса такую, что любой метод из семейства 1 будет работать не быстрее нижней оценки.

## Гладкий случай

### Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

## Гладкий случай

### Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .

# Гладкий случай

## i Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключ к доказательству — явное построение специальной функции  $f$ .

## i Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключ к доказательству — явное построение специальной функции  $f$ .
- Заметим, что эта оценка  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не совпадает со скоростью градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Возможны два варианта:

# Гладкий случай

## i Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключ к доказательству — явное построение специальной функции  $f$ .
- Заметим, что эта оценка  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не совпадает со скоростью градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Возможны два варианта:
  - a. Нижняя оценка неточна.

# Гладкий случай

## i Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключ к доказательству — явное построение специальной функции  $f$ .
- Заметим, что эта оценка  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не совпадает со скоростью градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Возможны два варианта:
  - a. Нижняя оценка неточна.
  - b. Градиентный метод неоптимален для данной задачи.



# Гладкий случай

## i Theorem

Существует функция  $f$ , которая является  $L$ -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого  $k : 1 \leq k \leq \frac{n-1}{2}$ :

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция  $f$  такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как  $\mathcal{O}\left(\frac{1}{k^2}\right)$ .
- Ключ к доказательству — явное построение специальной функции  $f$ .
- Заметим, что эта оценка  $\mathcal{O}\left(\frac{1}{k^2}\right)$  не совпадает со скоростью градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$ . Возможны два варианта:
  - a. Нижняя оценка неточна.
  - b. **Градиентный метод неоптимален для данной задачи.**

# Метод тяжёлого шарика для квадратичной задачи

## Question

Какая стратегия выбора шага используется для ГС?




Figure 1: ГС против МТШ с фиксированным  $\beta$ .

**Наблюдение:** для “хорошей”  $f$  (со сферическими линиями уровня) ГС уже достаточно хорош и МТШ добавляет малый эффект. Однако для “плохой”  $f$  (с эллиптическими линиями уровня) МТШ лучше в ряде случаев.

## Метод тяжёлого шарика для квадратичной задачи




Figure 2: ГС с  $\alpha = \frac{1}{L}$  против МТШ с фиксированным  $\beta$ .

**Наблюдение:** аналогично. Если “хорошая”  $f$  (сферические линии уровня), ГС уже достаточен. Если “плохая”  $f$  (с эллиптическими линиями уровня), МТШ лучше в ряде случаев.

## УМН как метод с импульсом

- Начало:  $k = 0, a_0 = 1, x_{-1} = y_0, y_0$  — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}} (x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг:  $\alpha_k = \frac{1}{L} \forall k$ .

## УМН как метод с импульсом

- Начало:  $k = 0, a_0 = 1, x_{-1} = y_0, y_0$  — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}}(x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг:  $\alpha_k = \frac{1}{L} \forall k$ .

- Теорема.** Если  $f$  является  $L$ -гладкой и выпуклой, то последовательность  $\{f(x_k)\}_k$ , порождённая УМН, сходится к оптимальному значению  $f^*$  со скоростью  $\mathcal{O}(\frac{1}{k^2})$ :

$$f(x_k) - f^* \leq \frac{4L\|x_k - x^*\|^2}{(k+2)^2}$$

## УМН как метод с импульсом

- Начало:  $k = 0, a_0 = 1, x_{-1} = y_0, y_0$  — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}}(x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг:  $\alpha_k = \frac{1}{L} \forall k$ .

- Теорема.** Если  $f$  является  $L$ -гладкой и выпуклой, то последовательность  $\{f(x_k)\}_k$ , порождённая УМН, сходится к оптимальному значению  $f^*$  со скоростью  $\mathcal{O}(\frac{1}{k^2})$ :

$$f(x_k) - f^* \leq \frac{4L\|x_k - x^*\|^2}{(k+2)^2}$$

- Приведённое представление трудно воспринимается, поэтому перепишем эти уравнения в более наглядном виде.

## УМН как метод с импульсом

Если определить

$$v_k \equiv x_k - x_{k-1} \quad (5)$$

$$\beta_k \equiv \frac{a_k - 1}{a_{k+1}} \quad (6)$$

то комбинация Equation 4 и Equation 6 даёт:

$$y_k = x_{k-1} + \beta_{k-1} v_{k-1}$$

что позволяет переписать Equation 2 следующим образом при  $\alpha_k = \alpha_{k-1}$ :

$$x_k = x_{k-1} + \beta_{k-1} v_{k-1} - \alpha_{k-1} \nabla f(x_{k-1} + \beta_{k-1} v_{k-1}) \quad (7)$$

$$v_k = \beta_{k-1} v_{k-1} - \alpha_{k-1} \nabla f(x_{k-1} + \beta_{k-1} v_{k-1}) \quad (8)$$

где Equation 8 следует из Equation 5. Альтернативная запись:

$$v_{k+1} = \beta_k v_k - \alpha_k \nabla f(x_k + \beta_k v_k)$$

$$x_{k+1} = x_k + v_{k+1}$$

где  $\alpha_k > 0$  — скорость обучения,  $\beta_k$  — коэффициент импульса. Сравните МТШ с УМН.

# УМН для DL <sup>1</sup>

| task   | $0_{(SGD)}$ | 0.9N | 0.99N       | 0.995N | 0.999N       | 0.9M | 0.99M | 0.995M | 0.999M | SGD <sub>C</sub> |
|--------|-------------|------|-------------|--------|--------------|------|-------|--------|--------|------------------|
| Curves | 0.48        | 0.16 | 0.096       | 0.091  | <b>0.074</b> | 0.15 | 0.10  | 0.10   | 0.10   | 0.16             |
| Mnist  | 2.1         | 1.0  | <b>0.73</b> | 0.75   | 0.80         | 1.0  | 0.77  | 0.84   | 0.90   | 0.9              |
| Faces  | 36.4        | 14.2 | 8.5         | 7.8    | <b>7.7</b>   | 15.3 | 8.7   | 8.3    | 9.3    | NA               |

Figure 3: В таблице приведены среднеквадратичные ошибки на задачах для каждой комбинации  $\beta_{max}$  и типа импульса (УМН=N, МТШ=M). При  $\beta_{max} = 0$  выбор УМН или МТШ не имеет значения, поэтому ошибки обучения представлены в одном столбце. Для каждого  $\beta_{max}$  используется наилучшая скорость обучения. Столбец SGD<sub>C</sub> содержит результаты Chapelle & Erhan (2011), которые использовали 1.7M шагов SGD и tanh-сети.

---

<sup>1</sup>Ссылка



# Глобальная сходимость метода тяжёлого шарика<sup>2</sup>

## i Theorem

Предположим, что  $f$  является гладкой и выпуклой, и что

$$\beta \in [0, 1), \quad \alpha \in \left(0, \frac{2(1-\beta)}{L}\right).$$

Тогда последовательность  $\{x_k\}$ , порождённая итерацией метода тяжёлого шарика, удовлетворяет

$$f(\bar{x}_T) - f^* \leq \begin{cases} \frac{\|x_0 - x^*\|^2}{2(T+1)} \left( \frac{L\beta}{1-\beta} + \frac{1-\beta}{\alpha} \right), & \text{если } \alpha \in \left(0, \frac{1-\beta}{L}\right], \\ \frac{\|x_0 - x^*\|^2}{2(T+1)(2(1-\beta) - \alpha L)} \left( L\beta + \frac{(1-\beta)^2}{\alpha} \right), & \text{если } \alpha \in \left[\frac{1-\beta}{L}, \frac{2(1-\beta)}{L}\right), \end{cases}$$

где  $\bar{x}_T$  — среднее Чезаро итератов, т.е.

$$\bar{x}_T = \frac{1}{T+1} \sum_{k=0}^T x_k.$$

<sup>2</sup>Global convergence of the Heavy-ball method for convex optimization, Euhanna Ghadimi et.al.

# Глобальная сходимость метода тяжёлого шарика<sup>3</sup>

## i Theorem

Предположим, что  $f$  является гладкой и сильно выпуклой, и что

$$\alpha \in (0, \frac{2}{L}), \quad 0 \leq \beta < \frac{1}{2} \left( \frac{\mu\alpha}{2} + \sqrt{\frac{\mu^2\alpha^2}{4} + 4(1 - \frac{\alpha L}{2})} \right).$$

Тогда последовательность  $\{x_k\}$ , порождённая итерацией метода тяжёлого шарика, линейно сходится к единственной точке оптимума  $x^*$ . В частности,

$$f(x_k) - f^* \leq q^k (f(x_0) - f^*),$$

где  $q \in [0, 1)$ .

<sup>3</sup>Global convergence of the Heavy-ball method for convex optimization, Euhanna Ghadimi et.al.

# Глобальная сходимость УМН

## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является выпуклой и  $L$ -гладкой. Ускоренный метод Нестерова (УМН) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Шаг градиента:**  $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

**Экстраполяция:**  $x_{k+1} = (1 - \gamma_k)y_{k+1} + \gamma_k y_k$

**Вес экстраполяции:**  $\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$

**Вес экстраполяции:**  $\gamma_k = \frac{1 - \lambda_k}{\lambda_{k+1}}$

Последовательности  $\{f(y_k)\}_{k \in \mathbb{N}}$ , порождённые алгоритмом, сходятся к оптимальному значению  $f^*$  со скоростью  $\mathcal{O}\left(\frac{1}{k^2}\right)$ , а именно:

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}$$

# Глобальная сходимость УМН

## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является  $\mu$ -сильно выпуклой и  $L$ -гладкой. Ускоренный метод Нестерова (УМН) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Шаг градиента:**  $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

**Экстраполяция:**  $x_{k+1} = (1 + \gamma_k)y_{k+1} - \gamma_k y_k$

**Вес экстраполяции:**  $\gamma_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$

Последовательности  $\{f(y_k)\}_{k \in \mathbb{N}}$ , порождённые алгоритмом, сходятся к оптимальному значению  $f^*$  линейно:

$$f(y_k) - f^* \leq \frac{\mu + L}{2} \|x_0 - x^*\|_2^2 \exp\left(-\frac{k}{\sqrt{\kappa}}\right)$$

Программируем!  Colab

# Логистическая регрессия

Программируем!  Colab

# Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.

# Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.



# Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.
- Запустить код в Colab. Код взят из .

# Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.
- Запустить код в Colab. Код взят из .
- О важности инициализации и импульса в глубоком обучении. Ссылка.

## УМН для квадратичной задачи

Рассмотрим следующую задачу квадратичной оптимизации:

$$\min_{x \in \mathbb{R}^d} q(x) = \min_{x \in \mathbb{R}^d} \frac{1}{2} x^\top A x - b^\top x, \text{ где } A \in \mathbb{S}_{++}^d.$$

Каждая симметричная матрица  $A$  имеет разложение по собственным значениям

$$A = Q \text{diag}(\lambda_1, \dots, \lambda_n) Q^\top = Q \Lambda Q^\top, \quad Q = [q_1, \dots, q_n].$$

и, по соглашению, мы предполагаем, что  $\lambda_i$  упорядочены от наименьшего  $\lambda_1$  до наибольшего  $\lambda_n$ . Очевидно, что  $\lambda_i$  соответствуют **кривизне** вдоль соответствующих направлений собственных векторов.

Сделаем перепараметризацию  $q(x)$  матричным преобразованием  $Q$  и оптимизируем  $y = Qx$  с целевой функцией

$$p(y) \equiv q(x) = q(Q^\top y) = y^\top Q(Q^\top \Lambda Q) Q^\top y / 2 - b^\top Q^\top y = y^\top \Lambda y / 2 - c^\top y,$$

где  $c = Qb$ .

Далее перепишем  $p$  в виде

$$p(y) = \sum_{i=1}^n [p]_i([y]_i),$$

где  $[p]_i(t) = \lambda_i t^2 / 2 - [c]_i t$ .

## УМН для квадратичной задачи

💡 Теорема 2.1 из [1].

Пусть  $p(y) = \sum_{i=1}^n [p]_i([y]_i)$ , где  $[p]_i(t) = \lambda_i t^2/2 - [c]_i t$ . Пусть  $\alpha$  произвольно и фиксировано. Обозначим через  $\text{МТШ}_x(\beta, p, y, v)$  и  $\text{МТШ}_v(\beta, p, y, v)$  вектор параметров и вектор скорости соответственно, полученные одним шагом МТШ (т.е. ур. 1 и затем ур. 2) для функции  $p$  в точке  $y$ , со скоростью  $v$ , коэффициентом импульса  $\beta$  и скоростью обучения  $\alpha$ . Аналогично определим  $\text{УМН}_x$  и  $\text{УМН}_v$ . Тогда для  $z \in \{x, v\}$  выполняется:

$$\text{МТШ}_z(\beta, p, y, v) = \begin{bmatrix} \text{МТШ}_z(\beta, [p]_1, [y]_1, [v]_1) \\ \vdots \\ \text{МТШ}_z(\beta, [p]_n, [y]_n, [v]_n) \end{bmatrix}$$

$$\text{УМН}_z(\beta, p, y, v) = \begin{bmatrix} \text{МТШ}_z(\beta(1 - \alpha\lambda_1), [p]_1, [y]_1, [v]_1) \\ \vdots \\ \text{МТШ}_z(\beta(1 - \alpha\lambda_n), [p]_n, [y]_n, [v]_n) \end{bmatrix}$$

## УМН для квадратичной задачи. Доказательство (1/2)

Доказательство:

Нетрудно показать, что если

$$x_{i+1} = \text{MTШ}_x(\beta_i, [q]_i, [x]_i, [v]_i)$$

$$v_{i+1} = \text{MTШ}_v(\beta_i, [q]_i, [x]_i, [v]_i)$$

то для  $y_i = Qx_i, w_i = Qv_i$

$$y_{i+1} = \text{MTШ}_x(\beta_i, [p]_i, [y]_i, [w]_i)$$

$$w_{i+1} = \text{MTШ}_v(\beta_i, [p]_i, [y]_i, [w]_i)$$

. Далее рассмотрим один шаг  $\text{MTШ}_v$ :

$$\begin{aligned}\text{MTШ}_v(\beta, p, y, v) &= \beta v - \alpha \nabla p(y) \\ &= (\beta[v]_1 - \alpha \nabla_{[y]_1} p(y), \dots, \beta[v]_n - \alpha \nabla_{[y]_n} p(y)) \\ &= (\beta[v]_1 - \alpha \nabla[p]_1([y]_1), \dots, \beta[v]_n - \alpha \nabla[p]_n([y]_n)) \\ &= (\text{MTШ}_v(\beta_1, [p]_1, [y]_1, [v]_1), \dots, \text{MTШ}_v(\beta_i, [p]_i, [y]_i, [v]_i))\end{aligned}$$

Это показывает, что один шаг  $\text{MTШ}_v$  на  $p$  в точности эквивалентен  $n$  одновременным применениям  $\text{MTШ}_v$  к одномерным квадратикам  $[p]_i$  с одинаковыми  $\beta$  и  $\alpha$ . Аналогично для  $\text{MTШ}_x$ .

## УМН для квадратичной задачи. Доказательство (2/2)

Далее покажем, что УМН, применённый к одномерному квадратику с коэффициентом импульса  $\beta$ , эквивалентен МТШ, применённому к тому же квадратику с той же скоростью обучения, но с коэффициентом импульса  $\beta(1 - \alpha\lambda)$ . Покажем это, раскрыв  $\text{УМН}_v(\beta, [p]_i, y, v)$  (где  $y$  и  $v$  — скаляры):

$$\begin{aligned}\text{УМН}_v(\beta, [p]_i, y, v) &= \beta v - \alpha \nabla [p]_i (y + \beta v) \\ &= \beta v - \alpha (\lambda_i (y + \beta v) - c_i) \\ &= \beta v - \alpha \lambda_i \beta v - \alpha (\lambda_i y - c_i) \\ &= \beta (1 - \alpha \lambda_i) v - \alpha \nabla [p]_i (y) \\ &= \text{МТШ}_v(\beta(1 - \alpha \lambda_i), [p]_i, y, v).\end{aligned}$$

ЧТД.

**Наблюдения:**

- МТШ и УМН становятся **эквивалентными**, когда  $\alpha$  мало (когда  $\alpha\lambda \ll 1$  для каждого собственного значения  $\lambda$  матрицы  $A$ ), поэтому МТШ и УМН различаются лишь при достаточно большом  $\alpha$ .

## УМН для квадратичной задачи. Доказательство (2/2)

Далее покажем, что УМН, применённый к одномерному квадратику с коэффициентом импульса  $\beta$ , эквивалентен МТШ, применённому к тому же квадратику с той же скоростью обучения, но с коэффициентом импульса  $\beta(1 - \alpha\lambda)$ . Покажем это, раскрыв  $\text{УМН}_v(\beta, [p]_i, y, v)$  (где  $y$  и  $v$  — скаляры):

$$\begin{aligned}\text{УМН}_v(\beta, [p]_i, y, v) &= \beta v - \alpha \nabla [p]_i (y + \beta v) \\ &= \beta v - \alpha (\lambda_i (y + \beta v) - c_i) \\ &= \beta v - \alpha \lambda_i \beta v - \alpha (\lambda_i y - c_i) \\ &= \beta (1 - \alpha \lambda_i) v - \alpha \nabla [p]_i (y) \\ &= \text{МТШ}_v(\beta(1 - \alpha \lambda_i), [p]_i, y, v).\end{aligned}$$

ЧТД.

**Наблюдения:**

- МТШ и УМН становятся **эквивалентными**, когда  $\alpha$  мало (когда  $\alpha\lambda \ll 1$  для каждого собственного значения  $\lambda$  матрицы  $A$ ), поэтому МТШ и УМН различаются лишь при достаточно большом  $\alpha$ .
- При достаточно большом  $\alpha$  УМН использует меньший эффективный импульс для направлений высокой кривизны, что **предотвращает осцилляции** (или расходимость) и тем самым позволяет использовать бóльший  $\beta$ , чем возможно в МТШ при данном  $\alpha$ .