

Ускоренные градиентные методы

Семинар

ФКН ВШЭ

ГС. Скорости сходимости

$$\min_{x \in \mathbb{R}^n} f(x) \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad \kappa = \frac{L}{\mu}$$

	гладкая и выпуклая	гладкая и сильно выпуклая (или PL)
Верхняя оценка	$f(x_k) - f^* \approx \mathcal{O}\left(\frac{1}{k}\right)$	$\ x_k - x^*\ ^2 \approx \mathcal{O}\left(\left(\frac{\kappa - 1}{\kappa + 1}\right)^k\right)$
Нижняя оценка	$f(x_k) - f^* \approx \Omega\left(\frac{1}{k^2}\right)$	$\ x_k - x^*\ ^2 \approx \Omega\left(\left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k\right)$

Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку x_k в направлении $-\nabla f(x_k)$ на величину $\alpha_k \|\nabla f(x_k)\|$.

Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку x_k в направлении $-\nabla f(x_k)$ на величину $\alpha_k \|\nabla f(x_k)\|$.

Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку x_k в направлении $-\nabla f(x_k)$ на величину $\alpha_k \|\nabla f(x_k)\|$.

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- x в направлении предыдущего шага на величину $\beta_k \|x_k - x_{k-1}\|$.

Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку x_k в направлении $-\nabla f(x_k)$ на величину $\alpha_k \|\nabla f(x_k)\|$.

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- x в направлении предыдущего шага на величину $\beta_k \|x_k - x_{k-1}\|$.

Три схемы обновления

- Обычный градиент

$$x_k - \alpha_k \nabla f(x_k)$$

Сдвинуть точку x_k в направлении $-\nabla f(x_k)$ на величину $\alpha_k \|\nabla f(x_k)\|$.

- Метод тяжёлого шарика Поляка

$$x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

Выполнить шаг ГС,

сдвинуть обновлённый- x в направлении предыдущего шага на величину $\beta_k \|x_k - x_{k-1}\|$.

- Ускорение Нестерова

$$x_k - \alpha_k \nabla f(x_k + \beta_k (x_k - x_{k-1})) + \beta_k (x_k - x_{k-1})$$

Сдвинуть ещё-не-обновлённый- x в направлении предыдущего шага на величину $\beta_k \|x_k - x_{k-1}\|$,

выполнить шаг ГС на сдвинутом- x , затем сдвинуть обновлённый- x в направлении предыдущего шага на $\beta_k \|x_k - x_{k-1}\|$.

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

Итерация чёрного ящика

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, где

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{гладкая} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ где } g_i \in \partial f(x^i) && f - \text{негладкая}\end{aligned} \tag{1}$$

Для построения нижней оценки нам нужно найти функцию f из соответствующего класса такую, что любой метод из семейства 1 будет работать не быстрее нижней оценки.

Гладкий случай

Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

Гладкий случай

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.

Гладкий случай

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Заметим, что эта оценка $\mathcal{O}\left(\frac{1}{k^2}\right)$ не совпадает со скоростью градиентного спуска $\mathcal{O}\left(\frac{1}{k}\right)$. Возможны два варианта:

Гладкий случай

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Заметим, что эта оценка $\mathcal{O}\left(\frac{1}{k^2}\right)$ не совпадает со скоростью градиентного спуска $\mathcal{O}\left(\frac{1}{k}\right)$. Возможны два варианта:
 - a. Нижняя оценка неточна.

Гладкий случай

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Заметим, что эта оценка $\mathcal{O}\left(\frac{1}{k^2}\right)$ не совпадает со скоростью градиентного спуска $\mathcal{O}\left(\frac{1}{k}\right)$. Возможны два варианта:
 - a. Нижняя оценка неточна.
 - b. Градиентный метод неоптимален для данной задачи.

Гладкий случай

i Theorem

Существует функция f , которая является L -гладкой и выпуклой, такая что любой метод 1 удовлетворяет для любого $k : 1 \leq k \leq \frac{n-1}{2}$:

$$f(x^k) - f^* \geq \frac{3L\|x^0 - x^*\|_2^2}{32(k+1)^2}$$

- Каким бы градиентным методом вы ни воспользовались, всегда найдётся функция f такая, что при её минимизации вашим методом скорость сходимости ограничена снизу как $\mathcal{O}\left(\frac{1}{k^2}\right)$.
- Ключ к доказательству — явное построение специальной функции f .
- Заметим, что эта оценка $\mathcal{O}\left(\frac{1}{k^2}\right)$ не совпадает со скоростью градиентного спуска $\mathcal{O}\left(\frac{1}{k}\right)$. Возможны два варианта:
 - a. Нижняя оценка неточна.
 - b. **Градиентный метод неоптимален для данной задачи.**

Метод тяжёлого шарика для квадратичной задачи

Question

Какая стратегия выбора шага используется для ГС?




Figure 1: ГС против МТШ с фиксированным β .

Наблюдение: для “хорошей” f (со сферическими линиями уровня) ГС уже достаточно хорош и МТШ добавляет малый эффект. Однако для “плохой” f (с эллиптическими линиями уровня) МТШ лучше в ряде случаев.

Метод тяжёлого шарика для квадратичной задачи




Figure 2: ГС с $\alpha = \frac{1}{L}$ против МТШ с фиксированным β .

Наблюдение: аналогично. Если “хорошая” f (сферические линии уровня), ГС уже достаточен. Если “плохая” f (с эллиптическими линиями уровня), МТШ лучше в ряде случаев.

УМН как метод с импульсом

- Начало: $k = 0, a_0 = 1, x_{-1} = y_0$, y_0 — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}}(x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг: $\alpha_k = \frac{1}{L} \forall k$.

УМН как метод с импульсом

- Начало: $k = 0, a_0 = 1, x_{-1} = y_0, y_0$ — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}}(x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг: $\alpha_k = \frac{1}{L} \forall k$.

- Теорема.** Если f является L -гладкой и выпуклой, то последовательность $\{f(x_k)\}_k$, порождённая УМН, сходится к оптимальному значению f^* со скоростью $\mathcal{O}(\frac{1}{k^2})$:

$$f(x_k) - f^* \leq \frac{4L\|x_k - x^*\|^2}{(k+2)^2}$$

УМН как метод с импульсом

- Начало: $k = 0, a_0 = 1, x_{-1} = y_0, y_0$ — произвольная начальная точка, итерации:

$$\text{Шаг градиента } x_k = y_k - \alpha_k \nabla f(y_k) \quad (2)$$

$$\text{Вес экстраполяции } a_{k+1} = \frac{1 + \sqrt{1 + 4a_k^2}}{2} \quad (3)$$

$$\text{Экстраполяция } y_{k+1} = x_k + \frac{a_k - 1}{a_{k+1}}(x_k - x_{k-1}) \quad (4)$$

Заметим, что здесь используется фиксированный шаг: $\alpha_k = \frac{1}{L} \forall k$.

- Теорема.** Если f является L -гладкой и выпуклой, то последовательность $\{f(x_k)\}_k$, порождённая УМН, сходится к оптимальному значению f^* со скоростью $\mathcal{O}(\frac{1}{k^2})$:

$$f(x_k) - f^* \leq \frac{4L\|x_k - x^*\|^2}{(k+2)^2}$$

- Приведённое представление трудно воспринимается, поэтому перепишем эти уравнения в более наглядном виде.

УМН как метод с импульсом

Если определить

$$v_k \equiv x_k - x_{k-1} \quad (5)$$

$$\beta_k \equiv \frac{a_k - 1}{a_{k+1}} \quad (6)$$

то комбинация Equation 4 и Equation 6 даёт:

$$y_k = x_{k-1} + \beta_{k-1} v_{k-1}$$

что позволяет переписать Equation 2 следующим образом при $\alpha_k = \alpha_{k-1}$:

$$x_k = x_{k-1} + \beta_{k-1} v_{k-1} - \alpha_{k-1} \nabla f(x_{k-1} + \beta_{k-1} v_{k-1}) \quad (7)$$

$$v_k = \beta_{k-1} v_{k-1} - \alpha_{k-1} \nabla f(x_{k-1} + \beta_{k-1} v_{k-1}) \quad (8)$$

где Equation 8 следует из Equation 5. Альтернативная запись:

$$v_{k+1} = \beta_k v_k - \alpha_k \nabla f(x_k + \beta_k v_k)$$

$$x_{k+1} = x_k + v_{k+1}$$

где $\alpha_k > 0$ — скорость обучения, β_k — коэффициент импульса. Сравните МТШ с УМН.

УМН для DL ¹

task	$0_{(SGD)}$	0.9N	0.99N	0.995N	0.999N	0.9M	0.99M	0.995M	0.999M	SGD _C
Curves	0.48	0.16	0.096	0.091	0.074	0.15	0.10	0.10	0.10	0.16
Mnist	2.1	1.0	0.73	0.75	0.80	1.0	0.77	0.84	0.90	0.9
Faces	36.4	14.2	8.5	7.8	7.7	15.3	8.7	8.3	9.3	NA

Figure 3: В таблице приведены среднеквадратичные ошибки на задачах для каждой комбинации β_{max} и типа импульса (УМН=N, МТШ=M). При $\beta_{max} = 0$ выбор УМН или МТШ не имеет значения, поэтому ошибки обучения представлены в одном столбце. Для каждого β_{max} используется наилучшая скорость обучения. Столбец SGD_C содержит результаты Chapelle & Erhan (2011), которые использовали 1.7M шагов SGD и tanh-сети.

¹Ссылка

Глобальная сходимость метода тяжёлого шарика²

i Theorem

Предположим, что f является гладкой и выпуклой, и что

$$\beta \in [0, 1), \quad \alpha \in \left(0, \frac{2(1-\beta)}{L}\right).$$

Тогда последовательность $\{x_k\}$, порождённая итерацией метода тяжёлого шарика, удовлетворяет

$$f(\bar{x}_T) - f^* \leq \begin{cases} \frac{\|x_0 - x^*\|^2}{2(T+1)} \left(\frac{L\beta}{1-\beta} + \frac{1-\beta}{\alpha} \right), & \text{если } \alpha \in \left(0, \frac{1-\beta}{L}\right], \\ \frac{\|x_0 - x^*\|^2}{2(T+1)(2(1-\beta) - \alpha L)} \left(L\beta + \frac{(1-\beta)^2}{\alpha} \right), & \text{если } \alpha \in \left[\frac{1-\beta}{L}, \frac{2(1-\beta)}{L}\right), \end{cases}$$

где $\bar{x}_T$ — среднее Чезаро итератов, т.е.

$$\bar{x}_T = \frac{1}{T+1} \sum_{k=0}^T x_k.$$

²Global convergence of the Heavy-ball method for convex optimization, Euhanna Ghadimi et.al.

Глобальная сходимость метода тяжёлого шарика³

i Theorem

Предположим, что f является гладкой и сильно выпуклой, и что

$$\alpha \in (0, \frac{2}{L}), \quad 0 \leq \beta < \frac{1}{2} \left(\frac{\mu\alpha}{2} + \sqrt{\frac{\mu^2\alpha^2}{4} + 4(1 - \frac{\alpha L}{2})} \right).$$

Тогда последовательность $\{x_k\}$, порождённая итерацией метода тяжёлого шарика, линейно сходится к единственной точке оптимума x^* . В частности,

$$f(x_k) - f^* \leq q^k(f(x_0) - f^*),$$

где $q \in [0, 1)$.

³Global convergence of the Heavy-ball method for convex optimization, Euhanna Ghadimi et.al.

Глобальная сходимость УМН

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ является выпуклой и L -гладкой. Ускоренный метод Нестерова (УМН) предназначен для решения задачи минимизации, начиная с начальной точки $x_0 = y_0 \in \mathbb{R}^n$ и $\lambda_0 = 0$. Алгоритм выполняет следующие шаги:

Шаг градиента: $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

Экстраполяция: $x_{k+1} = (1 - \gamma_k)y_{k+1} + \gamma_k y_k$

Вес экстраполяции: $\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$

Вес экстраполяции: $\gamma_k = \frac{1 - \lambda_k}{\lambda_{k+1}}$

Последовательности $\{f(y_k)\}_{k \in \mathbb{N}}$, порождённые алгоритмом, сходятся к оптимальному значению f^* со скоростью $\mathcal{O}\left(\frac{1}{k^2}\right)$, а именно:

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}$$

Глобальная сходимость УМН

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ является μ -сильно выпуклой и L -гладкой. Ускоренный метод Нестерова (УМН) предназначен для решения задачи минимизации, начиная с начальной точки $x_0 = y_0 \in \mathbb{R}^n$ и $\lambda_0 = 0$. Алгоритм выполняет следующие шаги:

Шаг градиента: $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

Экстраполяция: $x_{k+1} = (1 + \gamma_k)y_{k+1} - \gamma_k y_k$

Вес экстраполяции: $\gamma_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$

Последовательности $\{f(y_k)\}_{k \in \mathbb{N}}$, порождённые алгоритмом, сходятся к оптимальному значению f^* линейно:

$$f(y_k) - f^* \leq \frac{\mu + L}{2} \|x_0 - x^*\|_2^2 \exp\left(-\frac{k}{\sqrt{\kappa}}\right)$$

Программируем!  Colab

Логистическая регрессия

Программируем!  Colab

Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.

Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.

Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.
- Запустить код в Colab. Код взят из .

Литература и примеры на Python

- Рисунки для МТШ взяты из презентации. Посетите сайт для дополнительных материалов.
- Почему импульс действительно работает. Ссылка.
- Запустить код в Colab. Код взят из .
- О важности инициализации и импульса в глубоком обучении. Ссылка.

УМН для квадратичной задачи

Рассмотрим следующую задачу квадратичной оптимизации:

$$\min_{x \in \mathbb{R}^d} q(x) = \min_{x \in \mathbb{R}^d} \frac{1}{2} x^\top A x - b^\top x, \text{ где } A \in \mathbb{S}_{++}^d.$$

Каждая симметричная матрица A имеет разложение по собственным значениям

$$A = Q \text{diag}(\lambda_1, \dots, \lambda_n) Q^\top = Q \Lambda Q^\top, \quad Q = [q_1, \dots, q_n].$$

и, по соглашению, мы предполагаем, что λ_i упорядочены от наименьшего λ_1 до наибольшего λ_n . Очевидно, что λ_i соответствуют **кривизне** вдоль соответствующих направлений собственных векторов.

Сделаем перепараметризацию $q(x)$ матричным преобразованием Q и оптимизируем $y = Qx$ с целевой функцией

$$p(y) \equiv q(x) = q(Q^\top y) = y^\top Q(Q^\top \Lambda Q) Q^\top y / 2 - b^\top Q^\top y = y^\top \Lambda y / 2 - c^\top y,$$

где $c = Qb$.

Далее перепишем p в виде

$$p(y) = \sum_{i=1}^n [p]_i([y]_i),$$

где $[p]_i(t) = \lambda_i t^2 / 2 - [c]_i t$.

УМН для квадратичной задачи

💡 Теорема 2.1 из [1].

Пусть $p(y) = \sum_{i=1}^n [p]_i([y]_i)$, где $[p]_i(t) = \lambda_i t^2/2 - [c]_i t$. Пусть α произвольно и фиксировано. Обозначим через $\text{МТШ}_x(\beta, p, y, v)$ и $\text{МТШ}_v(\beta, p, y, v)$ вектор параметров и вектор скорости соответственно, полученные одним шагом МТШ (т.е. ур. 1 и затем ур. 2) для функции p в точке y , со скоростью v , коэффициентом импульса β и скоростью обучения α . Аналогично определим УМН_x и УМН_v . Тогда для $z \in \{x, v\}$ выполняется:

$$\text{МТШ}_z(\beta, p, y, v) = \begin{bmatrix} \text{МТШ}_z(\beta, [p]_1, [y]_1, [v]_1) \\ \vdots \\ \text{МТШ}_z(\beta, [p]_n, [y]_n, [v]_n) \end{bmatrix}$$

$$\text{УМН}_z(\beta, p, y, v) = \begin{bmatrix} \text{МТШ}_z(\beta(1 - \alpha\lambda_1), [p]_1, [y]_1, [v]_1) \\ \vdots \\ \text{МТШ}_z(\beta(1 - \alpha\lambda_n), [p]_n, [y]_n, [v]_n) \end{bmatrix}$$

УМН для квадратичной задачи. Доказательство (1/2)

Доказательство:

Нетрудно показать, что если

$$x_{i+1} = \text{MTШ}_x(\beta_i, [q]_i, [x]_i, [v]_i)$$

$$v_{i+1} = \text{MTШ}_v(\beta_i, [q]_i, [x]_i, [v]_i)$$

то для $y_i = Qx_i, w_i = Qv_i$

$$y_{i+1} = \text{MTШ}_x(\beta_i, [p]_i, [y]_i, [w]_i)$$

$$w_{i+1} = \text{MTШ}_v(\beta_i, [p]_i, [y]_i, [w]_i)$$

. Далее рассмотрим один шаг MTШ_v :

$$\begin{aligned}\text{MTШ}_v(\beta, p, y, v) &= \beta v - \alpha \nabla p(y) \\ &= (\beta[v]_1 - \alpha \nabla_{[y]_1} p(y), \dots, \beta[v]_n - \alpha \nabla_{[y]_n} p(y)) \\ &= (\beta[v]_1 - \alpha \nabla[p]_1([y]_1), \dots, \beta[v]_n - \alpha \nabla[p]_n([y]_n)) \\ &= (\text{MTШ}_v(\beta_1, [p]_1, [y]_1, [v]_1), \dots, \text{MTШ}_v(\beta_i, [p]_i, [y]_i, [v]_i))\end{aligned}$$

Это показывает, что один шаг MTШ_v на p в точности эквивалентен n одновременным применениям MTШ_v к одномерным квадратикам $[p]_i$ с одинаковыми β и α . Аналогично для MTШ_x .

УМН для квадратичной задачи. Доказательство (2/2)

Далее покажем, что УМН, применённый к одномерному квадратику с коэффициентом импульса β , эквивалентен МТШ, применённому к тому же квадратику с той же скоростью обучения, но с коэффициентом импульса $\beta(1 - \alpha\lambda)$. Покажем это, раскрыв $\text{УМН}_v(\beta, [p]_i, y, v)$ (где y и v — скаляры):

$$\begin{aligned}\text{УМН}_v(\beta, [p]_i, y, v) &= \beta v - \alpha \nabla [p]_i (y + \beta v) \\ &= \beta v - \alpha (\lambda_i (y + \beta v) - c_i) \\ &= \beta v - \alpha \lambda_i \beta v - \alpha (\lambda_i y - c_i) \\ &= \beta (1 - \alpha \lambda_i) v - \alpha \nabla [p]_i (y) \\ &= \text{МТШ}_v(\beta(1 - \alpha \lambda_i), [p]_i, y, v).\end{aligned}$$

ЧТД.

Наблюдения:

- МТШ и УМН становятся **эквивалентными**, когда α мало (когда $\alpha\lambda \ll 1$ для каждого собственного значения λ матрицы A), поэтому МТШ и УМН различаются лишь при достаточно большом α .

УМН для квадратичной задачи. Доказательство (2/2)

Далее покажем, что УМН, применённый к одномерному квадратику с коэффициентом импульса β , эквивалентен МТШ, применённому к тому же квадратику с той же скоростью обучения, но с коэффициентом импульса $\beta(1 - \alpha\lambda)$. Покажем это, раскрыв $\text{УМН}_v(\beta, [p]_i, y, v)$ (где y и v — скаляры):

$$\begin{aligned}\text{УМН}_v(\beta, [p]_i, y, v) &= \beta v - \alpha \nabla [p]_i (y + \beta v) \\ &= \beta v - \alpha (\lambda_i (y + \beta v) - c_i) \\ &= \beta v - \alpha \lambda_i \beta v - \alpha (\lambda_i y - c_i) \\ &= \beta (1 - \alpha \lambda_i) v - \alpha \nabla [p]_i (y) \\ &= \text{МТШ}_v(\beta(1 - \alpha \lambda_i), [p]_i, y, v).\end{aligned}$$

ЧТД.

Наблюдения:

- МТШ и УМН становятся **эквивалентными**, когда α мало (когда $\alpha\lambda \ll 1$ для каждого собственного значения λ матрицы A), поэтому МТШ и УМН различаются лишь при достаточно большом α .
- При достаточно большом α УМН использует меньший эффективный импульс для направлений высокой кривизны, что **предотвращает осцилляции** (или расходимость) и тем самым позволяет использовать бóльший β , чем возможно в МТШ при данном α .