


# Метод Ньютона. Квазиньютоновские методы.

Семинар

ФКН ВШЭ

## Первая интерпретация метода Ньютона (решение линеаризованных уравнений)



Рассмотрим функцию  $\varphi(x) : \mathbb{R} \rightarrow \mathbb{R}$ . Нам нужно найти корень уравнения  $\varphi(x) = 0$ . Идея метода состоит в построении линейного приближения в точке  $x_k$  и нахождении его корня, который станет следующей точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

Получаем итерационную схему:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)}.$$

Если теперь рассмотреть  $\varphi(x) \equiv \nabla f(x)$ , это превратится в метод Ньютона для оптимизации:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

## Пример метода линеаризации Ньютона

### i Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

## Пример метода линеаризации Ньютона

### Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

## Пример метода линеаризации Ньютона

### Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

## Пример метода линеаризации Ньютона

### i Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

## Пример метода линеаризации Ньютона

### i Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

## Пример метода линеаризации Ньютона

### i Question

Примените метод Ньютона для нахождения корня  $\varphi(t) = 0$  и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

Легко видеть, что метод сходится только при  $|x_0| < 1$ , что подчёркивает **локальный** характер метода Ньютона.

## Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция  $f(x)$  и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции вблизи  $x_k$ :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

## Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция  $f(x)$  и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции вблизи  $x_k$ :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода состоит в нахождении точки  $x_{k+1}$ , минимизирующей функцию  $f_{x_k}^{II}(x)$ , то есть  $\nabla f_{x_k}^{II}(x_{k+1}) = 0$ .

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$

$$\nabla f_{x_k}^{II}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$

$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k)$$

$$[\nabla^2 f(x_k)]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

## Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция  $f(x)$  и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции вблизи  $x_k$ :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода состоит в нахождении точки  $x_{k+1}$ , минимизирующей функцию  $f_{x_k}^{II}(x)$ , то есть  $\nabla f_{x_k}^{II}(x_{k+1}) = 0$ .

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$

$$\nabla f_{x_k}^{II}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$


$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k)$$

$$[\nabla^2 f(x_k)]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$


$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Обратите внимание на ограничения, связанные с необходимостью невырожденности гессиана (для работы метода), а также его положительной определённости (для гарантии сходимости).


# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



# Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



# Метод Ньютона против градиентного спуска




Figure 7: Целевая функция изображена чёрным, приближение — красной пунктирной линией

Градиентный спуск  $\equiv$  линейное приближение

Метод Ньютона  $\equiv$  квадратичное приближение

## i Theorem

Пусть  $f(x)$  — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполнены неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Тогда метод Ньютона с постоянным шагом

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

локально сходится к решению задачи со сверхлинейной скоростью. Если, кроме того, гессиан является  $M$ -липшицевым, то метод сходится локально к  $x^*$  с квадратичной скоростью:

$$\|x_{k+1} - x^*\|_2 \leq \frac{M \|x_k - x^*\|_2^2}{2(\mu - M \|x_k - x^*\|_2)}$$

## i Theorem

Пусть  $f(x)$  — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполнены неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Тогда метод Ньютона с постоянным шагом

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

локально сходится к решению задачи со сверхлинейной скоростью. Если, кроме того, гессиан является  $M$ -липшицевым, то метод сходится локально к  $x^*$  с квадратичной скоростью:

$$\|x_{k+1} - x^*\|_2 \leq \frac{M \|x_k - x^*\|_2^2}{2(\mu - M \|x_k - x^*\|_2)}$$

“Сходится локально” означает, что описанная выше скорость сходимости гарантируется только при достаточной близости начальной точки к точке минимума, в частности  $\|x_0 - x^*\| < \frac{2\mu}{3M}$

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для  $g''(y_k), g'(y_k)$ :

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для  $g''(y_k), g'(y_k)$ :

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

# Аффинная инвариантность

## i Question

Рассмотрим функцию  $f(x)$  и преобразование с невырожденной матрицей  $A$ . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть  $x = Ay$  и  $g(y) = f(Ay)$ .
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для  $g''(y_k)$ ,  $g'(y_k)$ :

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

4. Таким образом, шаг метода преобразуется линейным преобразованием **так же**, как и координаты:

$$Ay_{k+1} = Ay_k - (f''(Ay_k))^{-1} f'(Ay_k) \quad x_{k+1} = x_k - (f''(x_k))^{-1} f'(x_k)$$

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- гессиан может быть вырожденным

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым  $\rightarrow$  направление  $-(f''(x))^{-1}f'(x)$  может не быть направлением убывания 

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым  $\rightarrow$  направление  $-(f''(x))^{-1}f'(x)$  может не быть направлением убывания 

# Итоги метода Ньютона

## Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

## Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым  $\rightarrow$  направление  $-(f''(x))^{-1}f'(x)$  может не быть направлением убывания 


Кубически регуляризованный метод Ньютона и квазиньютоновские методы частично решают эти проблемы!

Always has been.

$$x_{k+1} = \arg \min_x \left\{ \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x_k - x\|^3 \right\}$$

Wait, is it all wrong?

$$x_{k+1} = \arg \min_x \left\{ \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$



## Интуиция по улучшению метода Ньютона

💡 Повторение: градиентный спуск

Если  $f$  имеет  $L$ -липшицев градиент, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Таким образом, каждый шаг градиентного спуска для функции с  $L$ -липшицевым градиентом — это минимизация мажорирующего параболоида:

$$\begin{aligned} x_{k+1} &= \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|^2 \right\} \\ &= x_k - \frac{1}{L} \nabla f(x_k). \end{aligned}$$

## Интуиция по улучшению метода Ньютона

💡 Повторение: градиентный спуск

Если  $f$  имеет  $L$ -липшицев градиент, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Таким образом, каждый шаг градиентного спуска для функции с  $L$ -липшицевым градиентом — это минимизация мажорирующего параболоида:

$$\begin{aligned} x_{k+1} &= \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|^2 \right\} \\ &= x_k - \frac{1}{L} \nabla f(x_k). \end{aligned}$$

Но если функция  $f$  имеет  $M$ -липшицев гессиан, можно показать, что

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

**Что если применить ту же логику, что и в градиентном спуске, для функции с  $M$ -липшицевым гессианом?**

## Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

### Вопрос

Какие проблемы вы видите в (1)?

## Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

### ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.

## Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

### ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

## Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

### ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

# Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

## ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

## 💡 Решения

1. Можно использовать численные методы с быстрой сходимостью

# Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

## ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

## 💡 Решения

1. Можно использовать численные методы с быстрой сходимостью
2. Подзадача эквивалентна выпуклой одномерной задаче оптимизации. <sup>a</sup>

# Кубически регуляризованный метод Ньютона

Если  $f$  имеет  $M$ -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

## ! Сложности

1. Нельзя получить явное выражение для  $x_{k+1}$  (без  $\arg\min$ ) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

## 💡 Решения

1. Можно использовать численные методы с быстрой сходимостью
2. Подзадача эквивалентна выпуклой одномерной задаче оптимизации. <sup>a</sup>
3. Подзадача может быть сделана выпуклой при правильном выборе коэффициента регуляризации. <sup>b</sup>

## i Theorem

Пусть  $f(x)$  —  $\mu$ -сильно выпуклая функция с  $M$ -липшицевым гессианом. Тогда кубически регуляризованный метод Ньютона (1) сходится глобально сверхлинейно:

$$f(x_{k+1}) - f^* \leq \gamma_k (f(x_k) - f^*), \quad \gamma_k \rightarrow 0.$$

<sup>1</sup>Kamzolov, D., et al. (2024). Optami: Global superlinear convergence of high-order methods. Accepted to ICLR 2025.

# Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации  $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$  общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

# Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации  $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$  общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

# Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации  $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$  общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

то есть на каждой итерации необходимо **вычислять** гессиан и градиент и **решать** линейную систему.

# Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации  $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$  общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

то есть на каждой итерации необходимо **вычислять** гессиан и градиент и **решать** линейную систему.

Заметим, что если взять единичную матрицу  $B_k = I_n$  в качестве  $B_k$  на каждом шаге, мы получим в точности метод градиентного спуска.

Общая схема квазиньютоновских методов основана на выборе матрицы  $B_k$  так, чтобы она в некотором смысле стремилась при  $k \rightarrow \infty$  к истинному значению гессиана  $\nabla^2 f(x_k)$ .

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$

# Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

# Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование к  $B_{k+1}$**  (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование к  $B_{k+1}$**  (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- $B_{k+1}$  была симметричной

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование к  $B_{k+1}$**  (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- $B_{k+1}$  была симметричной
- $B_{k+1}$  была «близкой» к  $B_k$

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для  $k = 1, 2, 3, \dots$  повторять:

1. Найти  $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить  $B_{k+1}$  из  $B_k$

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование к  $B_{k+1}$**  (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- $B_{k+1}$  была симметричной
- $B_{k+1}$  была «близкой» к  $B_k$
- $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$

## Задача 1: Симметричное обновление ранга один (SR1)

Попробуем обновление с матрицей ранга один:

$$B_{k+1} = B_k + a u u^T$$

### Question

Как выбрать  $a$  и  $u$ ? Как будет выглядеть обновление  $B_{k+1}$ ?

## Задача 1: Симметричное обновление ранга один (SR1)

Попробуем обновление с матрицей ранга один:

$$B_{k+1} = B_k + a u u^T$$

### Question

Как выбрать  $a$  и  $u$ ? Как будет выглядеть обновление  $B_{k+1}$ ?

# Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

## i Theorem

Пусть

- $f$  дважды непрерывно дифференцируема, имеет единственную стационарную точку  $x^*$ ,

Тогда в SR1  $x_k \rightarrow x^*$  сверхлинейно.

# Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

## Theorem

Пусть

- $f$  дважды непрерывно дифференцируема, имеет единственную стационарную точку  $x^*$ ,
- $0 \succ \nabla^2 f(x^*)$ ,  $\nabla^2 f(x)$  липшицево непрерывно в окрестности  $x^*$ ,

Тогда в SR1  $x_k \rightarrow x^*$  сверхлинейно.

# Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

## Theorem

Пусть

- $f$  дважды непрерывно дифференцируема, имеет единственную стационарную точку  $x^*$ ,
- $0 \succ \nabla^2 f(x^*)$ ,  $\nabla^2 f(x)$  липшицево непрерывно в окрестности  $x^*$ ,
- последовательность матриц  $\{B_k\}$  ограничена по норме,

Тогда в SR1  $x_k \rightarrow x^*$  сверхлинейно.

# Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

## i Theorem

Пусть

- $f$  дважды непрерывно дифференцируема, имеет единственную стационарную точку  $x^*$ ,
- $0 \succ \nabla^2 f(x^*)$ ,  $\nabla^2 f(x)$  липшицево непрерывно в окрестности  $x^*$ ,
- последовательность матриц  $\{B_k\}$  ограничена по норме,
- $|(\Delta y_k - B_k d_k)^T d_k| \geq r \|d_k\| \|\Delta y_k - B_k d_k\|$ ,  $0 < r \ll 1$ .

Тогда в SR1  $x_k \rightarrow x^*$  сверхлинейно.

## SR1 с обновлением обратной матрицы

Как решить

$$B_{k+1}d_{k+1} = -\nabla f(x_{k+1}),$$

чтобы сделать следующий шаг? Помимо распространения  $B_k$  до  $B_{k+1}$ , будем распространять и обратные матрицы, то есть  $C_k = B_k^{-1}$  до  $C_{k+1} = (B_{k+1})^{-1}$ .

Формула Шермана-Моррисона:

Формула Шермана-Моррисона гласит:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}$$

## SR1 с обновлением обратной матрицы

Как решить

$$B_{k+1}d_{k+1} = -\nabla f(x_{k+1}),$$

чтобы сделать следующий шаг? Помимо распространения  $B_k$  до  $B_{k+1}$ , будем распространять и обратные матрицы, то есть  $C_k = B_k^{-1}$  до  $C_{k+1} = (B_{k+1})^{-1}$ .

Формула Шермана-Моррисона:

Формула Шермана-Моррисона гласит:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}$$

Таким образом, для обновления SR1 обратная матрица также легко обновляется:

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k)(d_k - C_k \Delta y_k)^T}{(d_k - C_k \Delta y_k)^T \Delta y_k}$$

В целом SR1 прост и дешёв, но имеет ключевой недостаток: не сохраняет положительную определённость.

## Задача 2: Обновление Бroyдена-Флетчера-Голдфарба-Шанно (BFGS)

Попробуем теперь обновление ранга два:

$$B_{k+1} = B_k + a u u^T + b v v^T.$$

### Question

Как выбрать  $a$ ,  $u$ ,  $b$  и  $v$ ? Как будет выглядеть обновление  $B_{k+1}$ ?

# Сходимость BFGS

$$B_{k+1} = B_k - \frac{B_k d_k d_k^T B_k}{d_k^T B_k d_k} + \frac{\Delta y_k \Delta y_k^T}{\Delta y_k^T \Delta y_k}$$

называется обновлением Бroyдена-Флетчера-Голдфарба-Шанно (BFGS).

## Theorem

Пусть  $f(x)$  дважды непрерывно дифференцируема, имеет липшицев гессиан в  $x^*$  и, кроме того,  $\sum_{k=1}^{\infty} \|x_k - x^*\| \leq \infty$ . Тогда в BFGS  $x_k \rightarrow x^*$  сверхлинейно.

# Обновление BFGS с обратной матрицей

## Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, имеет вид:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

# Обновление BFGS с обратной матрицей

## Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, имеет вид:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

Применяя к нашему случаю, получаем обновление ранга два для обратной матрицы  $C$ :

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k) d_k^T}{\Delta y_k^T d_k} + \frac{d_k (d_k - C_k \Delta y_k)^T}{\Delta y_k^T d_k} - \frac{(d_k - C_k \Delta y_k)^T \Delta y_k}{(\Delta y_k^T d_k)^2} d_k d_k^T$$

$$C_{k+1} = \left( I - \frac{d_k \Delta y_k^T}{\Delta y_k^T d_k} \right) C_k \left( I - \frac{\Delta y_k d_k^T}{\Delta y_k^T d_k} \right) + \frac{d_k d_k^T}{\Delta y_k^T d_k}$$

Данная формулировка гарантирует, что обновление BFGS, будучи комплексным, остаётся вычислительно эффективным и требует  $O(n^2)$  операций. Важно, что обновление BFGS сохраняет положительную определённость. Напомним, это означает  $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$ , или эквивалентно  $C_k \succ 0 \Rightarrow C_{k+1} \succ 0$ .

# Основная идея L-BFGS

- L-BFGS не хранит полную матрицу  $B_k$  ( $C_k$ ), вместо этого хранит две последовательности векторов длины  $m : m < n$

# Основная идея L-BFGS

- L-BFGS не хранит полную матрицу  $B_k$  ( $C_k$ ), вместо этого хранит две последовательности векторов длины  $m : m < n$
- память сокращается с  $O(n^2)$  до  $O(mn)$ , что делает метод более пригодным для задач высокой размерности

# Вычислительные эксперименты

- Вычислительные эксперименты для квазиньютоновских методов, CG и GD 

# Вычислительные эксперименты

- Вычислительные эксперименты для квазиньютоновских методов, CG и GD 
- Вычислительные эксперименты для метода Ньютона и квазиньютоновских методов .