


Метод Ньютона. Квазиньютоновские методы.

Семинар

ФКН ВШЭ

Первая интерпретация метода Ньютона (решение линеаризованных уравнений)



Рассмотрим функцию $\varphi(x) : \mathbb{R} \rightarrow \mathbb{R}$. Нам нужно найти корень уравнения $\varphi(x) = 0$. Идея метода состоит в построении линейного приближения в точке x_k и нахождении его корня, который станет следующей точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

Получаем итерационную схему:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)}.$$

Если теперь рассмотреть $\varphi(x) \equiv \nabla f(x)$, это превратится в метод Ньютона для оптимизации:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

Пример метода линеаризации Ньютона

i Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

Пример метода линеаризации Ньютона

Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

Пример метода линеаризации Ньютона

Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

Пример метода линеаризации Ньютона

i Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

Пример метода линеаризации Ньютона

i Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

Пример метода линеаризации Ньютона

i Question

Примените метод Ньютона для нахождения корня $\varphi(t) = 0$ и определите область сходимости:

$$\varphi(t) = \frac{t}{\sqrt{1+t^2}}$$

1. Найдём производную:

$$\varphi'(t) = -\frac{t^2}{(1+t^2)^{\frac{3}{2}}} + \frac{1}{\sqrt{1+t^2}}$$

2. Тогда итерация метода принимает вид:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)} = x_k - x_k(x_k^2 + 1) = -x_k^3$$

Легко видеть, что метод сходится только при $|x_0| < 1$, что подчёркивает **локальный** характер метода Ньютона.

Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция $f(x)$ и некоторая точка x_k . Рассмотрим квадратичное приближение этой функции вблизи x_k :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция $f(x)$ и некоторая точка x_k . Рассмотрим квадратичное приближение этой функции вблизи x_k :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода состоит в нахождении точки x_{k+1} , минимизирующей функцию $f_{x_k}^{II}(x)$, то есть $\nabla f_{x_k}^{II}(x_{k+1}) = 0$.

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$

$$\nabla f_{x_k}^{II}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$

$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k)$$

$$[\nabla^2 f(x_k)]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Вторая интерпретация метода Ньютона (минимизация локального квадратичного приближения Тейлора)

Пусть дана функция $f(x)$ и некоторая точка x_k . Рассмотрим квадратичное приближение этой функции вблизи x_k :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода состоит в нахождении точки x_{k+1} , минимизирующей функцию $f_{x_k}^{II}(x)$, то есть $\nabla f_{x_k}^{II}(x_{k+1}) = 0$.

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$

$$\nabla f_{x_k}^{II}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$


$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k)$$

$$[\nabla^2 f(x_k)]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$


$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Обратите внимание на ограничения, связанные с необходимостью невырожденности гессиана (для работы метода), а также его положительной определённости (для гарантии сходимости).


Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




Метод Ньютона как минимизатор локального квадратичного приближения Тейлора




Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



Метод Ньютона как минимизатор локального квадратичного приближения Тейлора



Метод Ньютона против градиентного спуска




Figure 7: Целевая функция изображена чёрным, приближение — красной пунктирной линией

Градиентный спуск $\equiv$ линейное приближение

Метод Ньютона $\equiv$ квадратичное приближение

i Theorem

Пусть $f(x)$ — сильно выпуклая дважды непрерывно дифференцируемая функция на $\mathbb{R}^n$, для второй производной которой выполнены неравенства: $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$. Тогда метод Ньютона с постоянным шагом

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

локально сходится к решению задачи со сверхлинейной скоростью. Если, кроме того, гессиан является M -липшицевым, то метод сходится локально к x^* с квадратичной скоростью:

$$\|x_{k+1} - x^*\|_2 \leq \frac{M \|x_k - x^*\|_2^2}{2(\mu - M \|x_k - x^*\|_2)}$$

i Theorem

Пусть $f(x)$ — сильно выпуклая дважды непрерывно дифференцируемая функция на $\mathbb{R}^n$, для второй производной которой выполнены неравенства: $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$. Тогда метод Ньютона с постоянным шагом

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

локально сходится к решению задачи со сверхлинейной скоростью. Если, кроме того, гессиан является M -липшицевым, то метод сходится локально к x^* с квадратичной скоростью:

$$\|x_{k+1} - x^*\|_2 \leq \frac{M \|x_k - x^*\|_2^2}{2(\mu - M \|x_k - x^*\|_2)}$$

“Сходится локально” означает, что описанная выше скорость сходимости гарантируется только при достаточной близости начальной точки к точке минимума, в частности $\|x_0 - x^*\| < \frac{2\mu}{3M}$

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для $g''(y_k)$, $g'(y_k)$:

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для $g''(y_k), g'(y_k)$:

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

Аффинная инвариантность

i Question

Рассмотрим функцию $f(x)$ и преобразование с невырожденной матрицей A . Выясним, как изменится шаг итерации метода Ньютона после применения этого преобразования.

1. Пусть $x = Ay$ и $g(y) = f(Ay)$.
2. Рассмотрим квадратичное приближение:

$$g(y + u) \approx g(y) + \langle g'(y), u \rangle + \frac{1}{2} u^\top g''(y) u \rightarrow \min_u$$
$$u^* = -(g''(y))^{-1} g'(y) \quad y_{k+1} = y_k - (g''(y_k))^{-1} g'(y_k)$$

3. Подставим явные выражения для $g''(y_k), g'(y_k)$:

$$y_{k+1} = y_k - (A^\top f''(Ay_k) A)^{-1} A^\top f'(Ay_k) = y_k - A^{-1} (f''(Ay_k))^{-1} f'(Ay_k)$$

4. Таким образом, шаг метода преобразуется линейным преобразованием **так же**, как и координаты:

$$Ay_{k+1} = Ay_k - (f''(Ay_k))^{-1} f'(Ay_k) \quad x_{k+1} = x_k - (f''(x_k))^{-1} f'(x_k)$$

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти
- необходимо решать линейные системы: $\mathcal{O}(n^3)$ операций

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти
- необходимо решать линейные системы: $\mathcal{O}(n^3)$ операций
- гессиан может быть вырожденным

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти
- необходимо решать линейные системы: $\mathcal{O}(n^3)$ операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым $\rightarrow$ направление $-(f''(x))^{-1}f'(x)$ может не быть направлением убывания 

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти
- необходимо решать линейные системы: $\mathcal{O}(n^3)$ операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым $\rightarrow$ направление $-(f''(x))^{-1}f'(x)$ может не быть направлением убывания 

Итоги метода Ньютона

Достоинства

- квадратичная сходимость вблизи решения
- высокая точность полученного решения
- аффинная инвариантность

Недостатки

- отсутствие глобальной сходимости
- необходимо хранить гессиан на каждой итерации: $\mathcal{O}(n^2)$ памяти
- необходимо решать линейные системы: $\mathcal{O}(n^3)$ операций
- гессиан может быть вырожденным
- гессиан может быть не положительно определённым $\rightarrow$ направление $-(f''(x))^{-1}f'(x)$ может не быть направлением убывания 

Кубически регуляризованный метод Ньютона и квазиньютоновские методы частично решают эти проблемы!


Небольшая предыстория.

Always has been.

$$x_{k+1} = \arg \min_x \left\{ \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x_k - x\|^3 \right\}$$

Wait, is it all wrong?

$$x_{k+1} = \arg \min_x \left\{ \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle \right\}$$



Интуиция по улучшению метода Ньютона

💡 Повторение: градиентный спуск

Если f имеет L -липшицев градиент, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Таким образом, каждый шаг градиентного спуска для функции с L -липшицевым градиентом — это минимизация мажорирующего параболоида:

$$\begin{aligned} x_{k+1} &= \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|^2 \right\} \\ &= x_k - \frac{1}{L} \nabla f(x_k). \end{aligned}$$

Интуиция по улучшению метода Ньютона

💡 Повторение: градиентный спуск

Если f имеет L -липшицев градиент, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Таким образом, каждый шаг градиентного спуска для функции с L -липшицевым градиентом — это минимизация мажорирующего параболоида:

$$\begin{aligned} x_{k+1} &= \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|^2 \right\} \\ &= x_k - \frac{1}{L} \nabla f(x_k). \end{aligned}$$

Но если функция f имеет M -липшицев гессиан, можно показать, что

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Что если применить ту же логику, что и в градиентном спуске, для функции с M -липшицевым гессианом?

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

Вопрос

Какие проблемы вы видите в (1)?

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

💡 Решения

1. Можно использовать численные методы с быстрой сходимостью

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

💡 Решения

1. Можно использовать численные методы с быстрой сходимостью
2. Подзадача эквивалентна выпуклой одномерной задаче оптимизации. ^a

Кубически регуляризованный метод Ньютона

Если f имеет M -липшицев гессиан, то

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|y - x\|^3.$$

Минимизируя правую часть этого неравенства, приходим к кубически регуляризованному методу Ньютона

$$x_{k+1} = \arg \min_x \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{M}{6} \|x - x_k\|^3 \right\}. \quad (1)$$

! Сложности

1. Нельзя получить явное выражение для x_{k+1} (без $\arg\min$) из (1), как это возможно в градиентном спуске.
2. Подзадача внутри (1) может быть невыпуклой.

💡 Решения

1. Можно использовать численные методы с быстрой сходимостью
2. Подзадача эквивалентна выпуклой одномерной задаче оптимизации. ^a
3. Подзадача может быть сделана выпуклой при правильном выборе коэффициента регуляризации. ^b

i Theorem

Пусть $f(x)$ — μ -сильно выпуклая функция с M -липшицевым гессианом. Тогда кубически регуляризованный метод Ньютона (1) сходится глобально сверхлинейно:

$$f(x_{k+1}) - f^* \leq \gamma_k (f(x_k) - f^*), \quad \gamma_k \rightarrow 0.$$

¹Kamzolov, D., et al. (2024). Optami: Global superlinear convergence of high-order methods. Accepted to ICLR 2025.

Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$ общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$ общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление d_k (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$ общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление d_k (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

то есть на каждой итерации необходимо **вычислять** гессиан и градиент и **решать** линейную систему.

Интуиция квазиньютоновских методов

Для классической задачи безусловной оптимизации $f(x) \rightarrow \min_{x \in \mathbb{R}^n}$ общая схема итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление d_k (направление Ньютона) задаётся решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

то есть на каждой итерации необходимо **вычислять** гессиан и градиент и **решать** линейную систему.

Заметим, что если взять единичную матрицу $B_k = I_n$ в качестве B_k на каждом шаге, мы получим в точности метод градиентного спуска.

Общая схема квазиньютоновских методов основана на выборе матрицы B_k так, чтобы она в некотором смысле стремилась при $k \rightarrow \infty$ к истинному значению гессиана $\nabla^2 f(x_k)$.

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Основная идея: Поскольку B_k уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования B_{k+1} .

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Основная идея: Поскольку B_k уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования B_{k+1} .

Разумное требование к B_{k+1} (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Основная идея: Поскольку B_k уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования B_{k+1} .

Разумное требование к B_{k+1} (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- B_{k+1} была симметричной

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Основная идея: Поскольку B_k уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования B_{k+1} .

Разумное требование к B_{k+1} (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- B_{k+1} была симметричной
- B_{k+1} была «близкой» к B_k

Шаблон квазиньютоновского метода

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$ повторять:

1. Найти $d_k : B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$
3. Вычислить B_{k+1} из B_k

Различные квазиньютоновские методы реализуют шаг 3 по-разному. Как мы увидим, обычно можно вычислить $(B_{k+1})^{-1}$ из $(B_k)^{-1}$.

Основная идея: Поскольку B_k уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования B_{k+1} .

Разумное требование к B_{k+1} (мотивировано методом секущих):

$$\begin{aligned}\nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}d_k\end{aligned}$$

Кроме уравнения секущих, мы хотим, чтобы:

- B_{k+1} была симметричной
- B_{k+1} была «близкой» к B_k
- $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$

Задача 1: Симметричное обновление ранга один (SR1)

Попробуем обновление с матрицей ранга один:

$$B_{k+1} = B_k + a u u^T$$

Question

Как выбрать a и u ? Как будет выглядеть обновление B_{k+1} ?

Задача 1: Симметричное обновление ранга один (SR1)

Попробуем обновление с матрицей ранга один:

$$B_{k+1} = B_k + a u u^T$$

Question

Как выбрать a и u ? Как будет выглядеть обновление B_{k+1} ?

Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

Theorem

Пусть

- f дважды непрерывно дифференцируема, имеет единственную стационарную точку x^* ,

Тогда в SR1 $x_k \rightarrow x^*$ сверхлинейно.

Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

Theorem

Пусть

- f дважды непрерывно дифференцируема, имеет единственную стационарную точку x^* ,
- $0 \succ \nabla^2 f(x^*)$, $\nabla^2 f(x)$ липшицево непрерывно в окрестности x^* ,

Тогда в SR1 $x_k \rightarrow x^*$ сверхлинейно.

Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

Theorem

Пусть

- f дважды непрерывно дифференцируема, имеет единственную стационарную точку x^* ,
- $0 \succ \nabla^2 f(x^*)$, $\nabla^2 f(x)$ липшицево непрерывно в окрестности x^* ,
- последовательность матриц $\{B_k\}$ ограничена по норме,

Тогда в SR1 $x_k \rightarrow x^*$ сверхлинейно.

Сходимость SR1

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

называется симметричным обновлением ранга один (SR1), или методом Бройдена.

i Theorem

Пусть

- f дважды непрерывно дифференцируема, имеет единственную стационарную точку x^* ,
- $0 \succ \nabla^2 f(x^*)$, $\nabla^2 f(x)$ липшицево непрерывно в окрестности x^* ,
- последовательность матриц $\{B_k\}$ ограничена по норме,
- $|(\Delta y_k - B_k d_k)^T d_k| \geq r \|d_k\| \|\Delta y_k - B_k d_k\|$, $0 < r \ll 1$.

Тогда в SR1 $x_k \rightarrow x^*$ сверхлинейно.

SR1 с обновлением обратной матрицы

Как решить

$$B_{k+1}d_{k+1} = -\nabla f(x_{k+1}),$$

чтобы сделать следующий шаг? Помимо распространения B_k до B_{k+1} , будем распространять и обратные матрицы, то есть $C_k = B_k^{-1}$ до $C_{k+1} = (B_{k+1})^{-1}$.

Формула Шермана-Моррисона:

Формула Шермана-Моррисона гласит:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}$$

SR1 с обновлением обратной матрицы

Как решить

$$B_{k+1}d_{k+1} = -\nabla f(x_{k+1}),$$

чтобы сделать следующий шаг? Помимо распространения B_k до B_{k+1} , будем распространять и обратные матрицы, то есть $C_k = B_k^{-1}$ до $C_{k+1} = (B_{k+1})^{-1}$.

Формула Шермана-Моррисона:

Формула Шермана-Моррисона гласит:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}$$

Таким образом, для обновления SR1 обратная матрица также легко обновляется:

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k)(d_k - C_k \Delta y_k)^T}{(d_k - C_k \Delta y_k)^T \Delta y_k}$$

В целом SR1 прост и дешёв, но имеет ключевой недостаток: не сохраняет положительную определённость.

Задача 2: Обновление Бroyдена-Флетчера-Голдфарба-Шанно (BFGS)

Попробуем теперь обновление ранга два:

$$B_{k+1} = B_k + a u u^T + b v v^T.$$

Question

Как выбрать a , u , b и v ? Как будет выглядеть обновление B_{k+1} ?

Сходимость BFGS

$$B_{k+1} = B_k - \frac{B_k d_k d_k^T B_k}{d_k^T B_k d_k} + \frac{\Delta y_k \Delta y_k^T}{\Delta y_k^T \Delta y_k}$$

называется обновлением Бroyдена-Флетчера-Голдфарба-Шанно (BFGS).

Theorem

Пусть $f(x)$ дважды непрерывно дифференцируема, имеет липшицев гессиан в x^* и, кроме того, $\sum_{k=1}^{\infty} \|x_k - x^*\| \leq \infty$. Тогда в BFGS $x_k \rightarrow x^*$ сверхлинейно.

Обновление BFGS с обратной матрицей

Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, имеет вид:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

Обновление BFGS с обратной матрицей

Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, имеет вид:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

Применяя к нашему случаю, получаем обновление ранга два для обратной матрицы C :

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k) d_k^T}{\Delta y_k^T d_k} + \frac{d_k (d_k - C_k \Delta y_k)^T}{\Delta y_k^T d_k} - \frac{(d_k - C_k \Delta y_k)^T \Delta y_k}{(\Delta y_k^T d_k)^2} d_k d_k^T$$

$$C_{k+1} = \left(I - \frac{d_k \Delta y_k^T}{\Delta y_k^T d_k} \right) C_k \left(I - \frac{\Delta y_k d_k^T}{\Delta y_k^T d_k} \right) + \frac{d_k d_k^T}{\Delta y_k^T d_k}$$

Данная формулировка гарантирует, что обновление BFGS, будучи комплексным, остаётся вычислительно эффективным и требует $O(n^2)$ операций. Важно, что обновление BFGS сохраняет положительную определённость. Напомним, это означает $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$, или эквивалентно $C_k \succ 0 \Rightarrow C_{k+1} \succ 0$.

Основная идея L-BFGS

- L-BFGS не хранит полную матрицу B_k (C_k), вместо этого хранит две последовательности векторов длины $m : m < n$

Основная идея L-BFGS

- L-BFGS не хранит полную матрицу B_k (C_k), вместо этого хранит две последовательности векторов длины $m : m < n$
- память сокращается с $O(n^2)$ до $O(mn)$, что делает метод более пригодным для задач высокой размерности

Вычислительные эксперименты

- Вычислительные эксперименты для квазиньютоновских методов, CG и GD 

Вычислительные эксперименты

- Вычислительные эксперименты для квазиньютоновских методов, CG и GD 
- Вычислительные эксперименты для метода Ньютона и квазиньютоновских методов .