

Методы условной оптимизации

Семинар

ФКН ВШЭ

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Рассмотрим **евклидову проекцию** (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \frac{1}{2} \underset{x \in S}{\text{argmin}} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Рассмотрим **евклидову проекцию** (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \frac{1}{2} \underset{x \in S}{\text{argmin}} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Рассмотрим **евклидову проекцию** (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \frac{1}{2} \underset{x \in S}{\text{argmin}} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне него, то её проекция на это множество не существует.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Рассмотрим **евклидову проекцию** (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \frac{1}{2} \underset{x \in S}{\text{argmin}} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне него, то её проекция на это множество не существует.
- Если точка принадлежит множеству, то её проекция — она сама.

Проекция

💡 Теорема о неравенстве Бурбаки–Чейни–Голдштейна

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

💡 Нерастягивающая функция

Функция f называется **нерастягивающей**, если f является L -Липшицевой при $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$,

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превышает расстояния между самими точками.




Figure 1: Угол для любой точки $x \in S$ должен быть тупым или прямым

Нерастягивающая функция становится сжимающей, если $L < 1$.

Задачи

i Question

Является ли оператор проекции нерастягивающим?

i Question

Найдите проекцию $\text{proj}_S(\mathbf{y})$ на S , где S :

- l_2 -шар с центром 0 и радиусом 1:

$$S = \{x \in \mathbb{R}^d \mid \|x\|_2^2 = \sum_{i=1}^d x_i^2 \leq 1\}$$

Задачи

i Question

Является ли оператор проекции нестягивающим?

i Question

Найдите проекцию $\text{proj}_S(\mathbf{y})$ на S , где S :

- l_2 -шар с центром 0 и радиусом 1:

$$S = \{x \in \mathbb{R}^d \mid \|x\|_2^2 = \sum_{i=1}^d x_i^2 \leq 1\}$$

- Куб в $\mathbb{R}^d$:

$$S = \{x \in \mathbb{R}^d \mid a_i \leq x_i \leq b_i\}$$

Задачи

i Question

Является ли оператор проекции нерастягивающим?

i Question

Найдите проекцию $\text{proj}_S(\mathbf{y})$ на S , где S :

- l_2 -шар с центром 0 и радиусом 1:

$$S = \{x \in \mathbb{R}^d \mid \|x\|_2^2 = \sum_{i=1}^d x_i^2 \leq 1\}$$

- Куб в $\mathbb{R}^d$:

$$S = \{x \in \mathbb{R}^d \mid a_i \leq x_i \leq b_i\}$$

- Аффинные ограничения:

$$S = \{x \in \mathbb{R}^d \mid Ax = b\}$$

Задача 1

Пусть $\mathcal{L}_L$ обозначает множество матриц, являющихся L -Липшицевыми:

$$\mathcal{L}_L = \{A \in \mathbb{R}^{m \times n} \mid \|Ax - Ay\|_2 \leq L\|x - y\|_2 \quad \forall x, y \in \mathbb{R}^n\}.$$

Задача проекции: Дана матрица $M \in \mathbb{R}^{m \times n}$. Найти матрицу $X \in \mathcal{L}_L$, ближайшую к M в некоторой норме:

$$\mathcal{P}_{(L, \zeta)} : \operatorname{argmin}_{X \in \mathcal{L}_L} \frac{1}{2} \|X - M\|_{\zeta}^2.$$

На самом деле, при $L = 1$ и $\zeta = F$ задача имеет простое решение: можете ли вы предложить идею решения в этом случае?

Задача 2

Пусть $\mathcal{S}$ — неотрицательный ортант. Найдите следующую проекцию:

$$\text{proj}_{\mathcal{S}}(\mathbf{y}) = \arg \min_{\mathbf{x} \geq 0} \|\mathbf{x} - \mathbf{y}\|_2$$

где $\mathbf{x} \geq 0$ означает, что $\mathbf{x}$ лежит в неотрицательном ортанте $\mathcal{S} = \{\mathbf{x} \mid x_i \geq 0 \ \forall i\}$.

Что изменится, если $\mathcal{S} = \{x \mid l \leq X \leq u\}$?

Задача 3

Спектраплекс — это спектраэдр, определяемый как множество

$$\mathcal{S} := \{X \in \mathbb{S}_+^n : \text{Tr } X = 1\},$$

Спектраплекс = «спектра» + «симплекс», то есть «собственные значения в симплексе». Спектраплекс — «полуопределённый» аналог симплекса.

Вопрос: дана матрица $Z \in \mathbb{R}^{n \times n}$. Что такое проекция Z на множество $\mathcal{S}$?


Другими словами, решите следующую задачу оптимизации:

$$\arg \min_{X \succeq 0, \text{Tr } X = 1} \frac{1}{2} \|X - Z\|_F^2.$$

Метод проекции градиента. Идея

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$

Ниже приведён пример применения этого метода для атаки нейронной сети: ♣️ Атаки состязательными примерами.



Метод Франка-Вульфа. Идея




Figure 3: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 4: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 5: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 6: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 7: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 8: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея




Figure 9: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Метод Франка-Вульфа. Идея

$$y_k = \arg \min_{x \in S} f^I_{x_k}(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$

$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$




Figure 10: Иллюстрация алгоритма Франка-Вульфа (условного градиента)

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и предположим, что существует минимизатор x^* функции f на S ; кроме того, предположим, что f гладкая на S с параметром L .

- Алгоритм **метода проекции градиента** с шагом $\frac{1}{L}$ обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}$$

Особенности метода Франка-Вульфа

Скорость сходимости для гладкого выпуклого случая

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и предположим, что существует минимизатор x^* функции f на S ; кроме того, предположим, что f гладкая на S с параметром L .

- Алгоритм **метода проекции градиента** с шагом $\frac{1}{L}$ обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

- Метод Франка-Вульфа** обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{k+1}$$

💡 Особенности метода Франка-Вульфа

Скорость сходимости для гладкого выпуклого случая

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и предположим, что существует минимизатор x^* функции f на S ; кроме того, предположим, что f гладкая на S с параметром L .

- Алгоритм **метода проекции градиента** с шагом $\frac{1}{L}$ обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

- Метод Франка-Вульфа** обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{k+1}$$

💡 Особенности метода Франка-Вульфа

- Скорость сходимости метода Франка-Вульфа для μ -сильно выпуклых функций равна $\mathcal{O}\left(\frac{1}{k}\right)$

Скорость сходимости для гладкого выпуклого случая

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и предположим, что существует минимизатор x^* функции f на S ; кроме того, предположим, что f гладкая на S с параметром L .

- Алгоритм **метода проекции градиента** с шагом $\frac{1}{L}$ обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

- Метод Франка-Вульфа** обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{k+1}$$

💡 Особенности метода Франка-Вульфа

- Скорость сходимости метода Франка-Вульфа для μ -сильно выпуклых функций равна $\mathcal{O}\left(\frac{1}{k}\right)$
- Метод Франка-Вульфа не работает для негладких функций. Однако его модификации работают.

Скорость сходимости для гладкого выпуклого случая

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и предположим, что существует минимизатор x^* функции f на S ; кроме того, предположим, что f гладкая на S с параметром L .

- Алгоритм **метода проекции градиента** с шагом $\frac{1}{L}$ обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

- Метод Франка-Вульфа** обеспечивает следующую скорость сходимости после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|_2^2}{k+1}$$

💡 Особенности метода Франка-Вульфа

- Скорость сходимости метода Франка-Вульфа для μ -сильно выпуклых функций равна $\mathcal{O}\left(\frac{1}{k}\right)$
- Метод Франка-Вульфа не работает для негладких функций. Однако его модификации работают.

Метод субградиента: линейное приближение + штраф за близость

Вспомним шаг метода субградиента с субградиентом g_k :

$$\begin{aligned} x_{k+1} = x_k - \alpha_k g_k &\Leftrightarrow x_{k+1} = \operatorname{argmin}_x \underbrace{f(x_k) + g_k^\top (x - x_k)}_{\text{линейное приближение } f} + \underbrace{\frac{1}{2\alpha} \|x - x_k\|_2^2}_{\text{штраф за близость}} \\ &= \operatorname{argmin}_x \alpha g_k^\top x + \frac{1}{2} \|x - x_k\|_2^2 \end{aligned}$$




Figure 11: $\|\cdot\|_1$ не является сферически симметричной

Пример. Плохая обусловленность

Рассмотрим $f(x_1, x_2) = x_1^2 \cdot \frac{1}{100} + x_2^2 \cdot 100$.




Figure 12: Плохо обусловленная задача в норме $\|\cdot\|_2$

Пример. Плохая обусловленность

Предположим, мы находимся в точке: $x_k = (-10 \quad -0.1)^\top$. Метод субградиента: $x_{k+1} = x_k - \alpha \nabla f(x_k)$

$$\nabla f(x_k) = \left(\frac{2x_1}{100} \quad 2x_2 \cdot 100 \right)^\top \Big|_{(-10 \quad -0.1)^\top} = \left(-\frac{1}{5} \quad -20 \right)^\top$$

Проблема: из-за вытянутости линий уровня направление движения $(x_{k+1} - x_k)$ приблизительно $\perp (x^* - x_k)$.

Решение: заменим штраф за близость

$$x_{k+1} = \operatorname{argmin}_x \underbrace{f(x_k) + g_k^\top(x - x_k)}_{\text{линейное приближение } f} + \underbrace{\frac{1}{2\alpha}(x - x_k)^\top I(x - x_k)}_{\text{штраф за близость}}$$

на другой

$$x_{k+1} = \operatorname{argmin}_x \underbrace{f(x_k) + g_k^\top(x - x_k)}_{\text{линейное приближение } f} + \underbrace{\frac{1}{2\alpha}(x - x_k)^\top Q(x - x_k)}_{\text{штраф за близость}},$$

где $Q = \begin{pmatrix} \frac{1}{50} & 0 \\ 0 & 200 \end{pmatrix}$ для данного примера. А в более общем случае — на другую функцию $B_\phi(x, y)$, измеряющую близость.

Пример. Плохая обусловленность

Найдём x_{k+1} для этого **нового** алгоритма

$$\alpha \nabla f(x_k) + \begin{pmatrix} \frac{1}{50} & 0 \\ 0 & 200 \end{pmatrix} (x - x_k) = 0.$$

Решая относительно x , получаем

$$x_{k+1} = x_k - \alpha \begin{pmatrix} 50 & 0 \\ 0 & \frac{1}{200} \end{pmatrix} \nabla f(x_k) = (-10 \ -0.1)^\top - \alpha(-10 \ -0.1)^\top$$

Наблюдение: меняя штраф за близость, мы **меняем направление** $x_{k+1} - x_k$. Иными словами, если мы измеряем расстояние таким **новым** способом, то также **меняем константу Липшица**.

Question

Какова константа Липшица функции f в точке $(1 \ 1)^\top$ для нормы:

$$\|z\|^2 = z^\top \begin{pmatrix} 50 & 0 \\ 0 & \frac{1}{200} \end{pmatrix} z?$$

Пример. Устойчивая регрессия

Квадратичная функция потерь $\|Ax - b\|_2^2$ очень чувствительна к выбросам.

Альтернатива: $\min \|Ax - b\|_1$. Эта задача также **выпуклая**.

Вычислим константу Липшица L для $f(x) = \|Ax - b\|_1$:

$$|\|Ax - b\|_1 - \|Ay - b\|_1| \leq L\|x - y\|_2.$$

Для упрощения вычислений: $A = I$, $b = 0$, т.е. $f(x) = \|x\|_1$.

Возьмём $x = \mathbf{1}_d$, $y = (1 + \varepsilon)\mathbf{1}_d$:

$$|n - (1 + \varepsilon)n| = \varepsilon n \leq L\|x - y\|_2 = \|\varepsilon\|_2 = \sqrt{n\varepsilon^2} = \varepsilon\sqrt{n}.$$

Итого получаем $L = \sqrt{n}$. Как видим, L **зависит от размерности**.

Question

Покажите, что если $\|\nabla f(x)\|_\infty \leq 1$, то $\|\nabla f(x)\|_2 \leq \sqrt{d}$.

Список литературы

Примеры для раздела о зеркальном спуске взяты из лекции .