

# Проксимальный градиентный метод

Семинар

ФКН ВШЭ


# Регуляризованные / составные целевые функции

Многие негладкие задачи имеют вид

$$\min_{x \in \mathbb{R}^n} \varphi(x) = f(x) + r(x)$$

- **Lasso, L1-LS, сжатые измерения**

$$f(x) = \frac{1}{2} \|Ax - b\|_2^2, r(x) = \lambda \|x\|_1$$



# Регуляризованные / составные целевые функции

Многие негладкие задачи имеют вид


$$\min_{x \in \mathbb{R}^n} \varphi(x) = f(x) + r(x)$$

- **Lasso, L1-LS, сжатые измерения**

$$f(x) = \frac{1}{2} \|Ax - b\|_2^2, r(x) = \lambda \|x\|_1$$

- **L1-логистическая регрессия, разреженная ЛР**

$$f(x) = -y \log h(x) - (1-y) \log(1-h(x)), r(x) = \lambda \|x\|_1$$



# Нижние оценки для выпуклой негладкой оптимизации

выпуклая (негладкая)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклая (негладкая)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

# Нижние оценки для выпуклой негладкой оптимизации

| выпуклая (негладкая)                                                                                                                | сильно выпуклая (негладкая)                                                                                                |
|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ |

- Метод субградиента является оптимальным для указанных задач.

## Нижние оценки для выпуклой негладкой оптимизации

| выпуклая (негладкая)                                                                                                                | сильно выпуклая (негладкая)                                                                                                |
|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ |

- Метод субградиента является оптимальным для указанных задач.
- Можно использовать метод зеркального спуска (обобщение метода субградиента на случай произвольного расстояния, не обязательно евклидова) с той же скоростью сходимости, чтобы лучше учитывать геометрию задачи.

## Нижние оценки для выпуклой негладкой оптимизации

| выпуклая (негладкая)                                                                                                                | сильно выпуклая (негладкая)                                                                                                |
|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$ $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ |

- Метод субградиента является оптимальным для указанных задач.
- Можно использовать метод зеркального спуска (обобщение метода субградиента на случай произвольного расстояния, не обязательно евклидова) с той же скоростью сходимости, чтобы лучше учитывать геометрию задачи.
- Однако можно достичь стандартной скорости сходимости градиентного спуска  $\mathcal{O}\left(\frac{1}{k}\right)$  (и даже ускоренной версии  $\mathcal{O}\left(\frac{1}{k^2}\right)$ ), если использовать структуру задачи.

# Проксимальный оператор

## **i** Проксимальный оператор

Для выпуклого множества  $E \in \mathbb{R}^n$  и выпуклой функции  $f : E \rightarrow \mathbb{R}$  оператор  $\text{prox}_f(x)$  такой, что

$$\text{prox}_f(x) = \underset{y \in E}{\operatorname{argmin}} \left[ f(y) + \frac{1}{2} \|y - x\|_2^2 \right]$$

называется **проксимальным оператором** функции  $f$  в точке  $x$



## От проекций к близости

Пусть  $\mathbb{I}_S$  — индикаторная функция замкнутого выпуклого множества  $S$ . Напомним ортогональную проекцию  $\pi_S(y)$

## От проекций к близости

Пусть  $\mathbb{I}_S$  — индикаторная функция замкнутого выпуклого множества  $S$ . Напомним ортогональную проекцию  $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

## От проекций к близости

Пусть  $\mathbb{I}_S$  — индикаторная функция замкнутого выпуклого множества  $S$ . Напомним ортогональную проекцию  $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

С учётом следующего определения индикаторной функции

$$\mathbb{I}_S(x) = \begin{cases} 0, & x \in S, \\ \infty, & x \notin S, \end{cases}$$

перепишем ортогональную проекцию  $\pi_S(y)$  в виде

$$\pi_S(y) := \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \|x - y\|^2 + \mathbb{I}_S(x).$$

## От проекций к близости

Пусть  $\mathbb{I}_S$  — индикаторная функция замкнутого выпуклого множества  $S$ . Напомним ортогональную проекцию  $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

С учётом следующего определения индикаторной функции

$$\mathbb{I}_S(x) = \begin{cases} 0, & x \in S, \\ \infty, & x \notin S, \end{cases}$$

перепишем ортогональную проекцию  $\pi_S(y)$  в виде

$$\pi_S(y) := \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \|x - y\|^2 + \mathbb{I}_S(x).$$

Близость: заменим  $\mathbb{I}_S$  произвольной выпуклой функцией!

$$\text{prox}_r(y) = \text{prox}_{r,1}(y) := \arg \min \frac{1}{2} \|x - y\|^2 + r(x)$$

# Проксимальный градиентный метод

## 💡 Теорема о проксимальном градиентном методе

Рассмотрим проксимальный градиентный метод

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

для критерия  $\phi(x) = f(x) + r(x)$  при условиях:

- $f$  — выпуклая, дифференцируемая функция с липшицевым градиентом;

Тогда проксимальный градиентный метод с фиксированным шагом  $\alpha = \frac{1}{L}$  сходится со скоростью  $O(\frac{1}{k})$

# Проксимальный градиентный метод

## 💡 Теорема о проксимальном градиентном методе

Рассмотрим проксимальный градиентный метод

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

для критерия  $\phi(x) = f(x) + r(x)$  при условиях:

- $f$  — выпуклая, дифференцируемая функция с липшицевым градиентом;
- $r$  — выпуклая функция, допускающая вычисление проксимального оператора.

Тогда проксимальный градиентный метод с фиксированным шагом  $\alpha = \frac{1}{L}$  сходится со скоростью  $O(\frac{1}{k})$

# Примеры проксимальных отображений

Квадратичная функция ( $A \geq 0$ )

$$f(x) = \frac{1}{2}x^T A x + b^T x + c,$$

# Примеры проксимальных отображений

Квадратичная функция ( $A \geq 0$ )

$$f(x) = \frac{1}{2}x^T Ax + b^T x + c,$$

$$\text{prox}_{tf}(x) = (I + tA)^{-1}(x - tb)$$

Евклидова норма

$$f(x) = \|x\|_2,$$



## Примеры проксимальных отображений

Квадратичная функция ( $A \geq 0$ )

$$f(x) = \frac{1}{2}x^T A x + b^T x + c,$$

$$\text{prox}_{tf}(x) = (I + tA)^{-1}(x - tb)$$

Евклидова норма

$$f(x) = \|x\|_2,$$

$$\text{prox}_{tf}(x) = \begin{cases} (1 - t/\|x\|_2)x & \text{если } \|x\|_2 \geq t \\ 0 & \text{иначе} \end{cases}$$

Логарифмический барьер

$$f(x) = -\sum_{i=1}^n \log x_i,$$

## Примеры проксимальных отображений

Квадратичная функция ( $A \geq 0$ )

$$f(x) = \frac{1}{2}x^T A x + b^T x + c,$$

$$\text{prox}_{tf}(x) = (I + tA)^{-1}(x - tb)$$

Евклидова норма

$$f(x) = \|x\|_2,$$

$$\text{prox}_{tf}(x) = \begin{cases} (1 - t/\|x\|_2)x & \text{если } \|x\|_2 \geq t \\ 0 & \text{иначе} \end{cases}$$

Логарифмический барьер

$$f(x) = -\sum_{i=1}^n \log x_i,$$

$$\text{prox}_{tf}(x)_i = \frac{x_i + \sqrt{x_i^2 + 4t}}{2}, \quad i = 1, \dots, n$$

# Простые правила вычисления проксимальных отображений

## Разделимая сумма

$$f\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = g(x) + h(y), \quad \text{prox}_f\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} \text{prox}_g(x) \\ \text{prox}_h(y) \end{bmatrix}$$

## Масштабирование и сдвиг аргумента (при $a \neq 0$ )

$$f(x) = g(ax + b), \quad \text{prox}_f(x) = \frac{1}{a} \left( \text{prox}_{a^2 g}(ax + b) - b \right)$$

## Правое умножение на скаляр (при $\lambda > 0$ )

$$f(x) = \lambda g(x/\lambda), \quad \text{prox}_f(x) = \lambda \text{prox}_{\lambda^{-1} g}(x/\lambda)$$

# ISTA и FISTA


Методы для решения задач с  $L1$ -регуляризацией (например, Lasso).

**ISTA** (Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(x_k - \alpha\nabla f(x_k))$$

**FISTA** (Fast Iterative Shrinkage-Thresholding Algorithm)



# ISTA и FISTA

Методы для решения задач с  $L1$ -регуляризацией (например, Lasso).


**ISTA** (Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(x_k - \alpha\nabla f(x_k))$$

- Скорость сходимости:  $O(\frac{1}{k})$

**FISTA** (Fast Iterative Shrinkage-Thresholding Algorithm)



# ISTA и FISTA


Методы для решения задач с  $L1$ -регуляризацией (например, Lasso).

**ISTA** (Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(x_k - \alpha\nabla f(x_k))$$

- Скорость сходимости:  $O(\frac{1}{k})$



**FISTA** (Fast Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(y_k - \alpha\nabla f(y_k)),$$

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2},$$

$$y_{k+1} = x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k)$$

# ISTA и FISTA


Методы для решения задач с  $L1$ -регуляризацией (например, Lasso).

**ISTA** (Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(x_k - \alpha\nabla f(x_k))$$

- Скорость сходимости:  $O(\frac{1}{k})$



**FISTA** (Fast Iterative Shrinkage-Thresholding Algorithm)

- Шаг:

$$x_{k+1} = \text{prox}_{\alpha\lambda\|\cdot\|_1}(y_k - \alpha\nabla f(y_k)),$$

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2},$$

$$y_{k+1} = x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k)$$

- Скорость сходимости:  $O(\frac{1}{k^2})$

## Задача 1. ReLU в проксимальном операторе

### Question

Найдите  $\text{prox}_f(x)$  для  $f(x) = \lambda \max(0, x)$ :

$$\text{prox}_{\lambda \max(0, \cdot)}(x) = \underset{y \in \mathbb{R}}{\operatorname{argmin}} \left[ \frac{1}{2} \|y - x\|^2 + \lambda \max(0, y) \right]$$



## Задача 2. Групповой $l_1$ -регуляризатор

### i Question

Найдите  $\text{prox}_f(x)$  для  $f(x) = \|x\|_{1/2} = \sum_{g=0}^G \|x_g\|_2$ , где  $x \in \mathbb{R}^n = [\underbrace{x_1, x_2, \dots}_{1}, \underbrace{\dots}_{g}, \dots, \underbrace{x_{n-2}, x_{n-1}, x_n}_G]$ :

$$\text{prox}_{\|x\|_{1/2}}(x) = \underset{y \in \mathbb{R}}{\operatorname{argmin}} \left[ \frac{1}{2} \|y - x\|_2^2 + \sum_{g=0}^G \|y_g\|_2 \right]$$

# Метод наименьших квадратов с $L_1$ -регуляризатором

Сравнение проксимальных методов для задачи наименьших квадратов с  $L_1$ -регуляризатором  Открыть в Colab.

# Шумоподавление изображений с помощью ISTA

**Задача:** Восстановить чистое изображение  $x_{\text{true}}$  из зашумлённого  $y = x_{\text{true}} + \mathbf{n}$

**Ключевая идея:** Чистые изображения имеют разреженные вейвлет-коэффициенты  $\alpha = Wx_{\text{true}}$  (большинство равны нулю), где  $W$  — оператор вейвлет-преобразования. Коэффициенты шума не являются разреженными.

**Оптимизационный подход:** Найти коэффициенты  $\alpha$ , минимизирующие составной критерий:

$$\min_{\alpha} \underbrace{\frac{1}{2} \|W^T \alpha - y\|_2^2}_{\text{Верность данным}} + \underbrace{\lambda \|\alpha\|_1}_{\text{Штраф за разреженность}}$$

где  $W^T$  — обратное вейвлет-преобразование, а  $\lambda$  балансирует слагаемые.

**Результат:** Очищенное от шума изображение получается из итоговых коэффициентов  $\alpha^*$ :

$$x_{\text{denoised}} = W^T \alpha^*$$

# Шумоподавление изображений с помощью ISTA

Открыть Git.



L1 - PSNR = 27.18  
SSIM = 0.91 - Time: 1.92s



TV - PSNR = 31.32  
SSIM = 0.96 - Time: 2.60s

