

# Методы редукции дисперсии


Семинар

ФКН ВШЭ

# Основная проблема SGD

$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex binary logistic regression.  $m=200$ ,  $n=10$ ,  $\mu=1$ .



## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$

**Применение к оценке градиента ?**

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$

**Применение к оценке градиента ?**

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка

**Применение к оценке градиента ?**

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка
  - Если  $\alpha < 1$ : возможное смещение (но уменьшенная дисперсия).

**Применение к оценке градиента ?**

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка
  - Если  $\alpha < 1$ : возможное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

**Применение к оценке градиента ?**

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка
  - Если  $\alpha < 1$ : возможное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

### Применение к оценке градиента ?

- SVRG: положим  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и сохранённом  $\tilde{x}$ .

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка
  - Если  $\alpha < 1$ : возможное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

### Применение к оценке градиента ?

- SVRG: положим  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и сохранённом  $\tilde{x}$ .
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$  — полный градиент в точке  $\tilde{x}$ ;

## Ключевая идея редукции дисперсии

**Принцип:** снижение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : несмещённая оценка
  - Если  $\alpha < 1$ : возможное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

### Применение к оценке градиента ?

- SVRG: положим  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и сохранённом  $\tilde{x}$ .
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$  — полный градиент в точке  $\tilde{x}$ ;
- $X - Y = \nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})$

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$

Замечания:

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{epoch} = 1$  до # эпох

Замечания:

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{epoch} = 1$  до # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$

Замечания:

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{epoch} = 1$  до # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$

Замечания:

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{epoch} = 1$  до # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длины эпохи ( $m$ )

Замечания:

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{epoch} = 1$  **до** # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длины эпохи ( $m$ )
    - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$

**Замечания:**

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{epoch} = 1$  **до** # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длины эпохи ( $m$ )
    - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
    - Обновить  $\tilde{x} = x_t$

**Замечания:**

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{epoch} = 1$  **до** # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длины эпохи ( $m$ )
    - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
    - Обновить  $\tilde{x} = x_t$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{epoch} = 1$  **до** # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длины эпохи ( $m$ )
    - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
    - Обновить  $\tilde{x} = x_t$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи и размер шага  $\gamma$ .

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

# SVRG (стохастический градиент с редукцией дисперсии) <sup>1</sup>

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{epoch} = 1$  до # эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длины эпохи ( $m$ )
    - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
    - Обновить  $\tilde{x} = x_t$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи и размер шага  $\gamma$ .
- Линейная скорость сходимости, простое доказательство.

---

<sup>1</sup>Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$

---

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$
- Инициализировать  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$

---

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$
- Инициализировать  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шагах  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. они остаются без изменений

---

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$
- Инициализировать  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шагах  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

---

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$
- Инициализировать  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шагах  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG больше не являются несмещёнными, однако их дисперсия значительно снижена

---

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

## SAG (стохастический усреднённый градиент) <sup>2</sup>

- Поддерживать таблицу, содержащую градиент  $g_i$  функции  $f_i$ ,  $i = 1, \dots, n$
- Инициализировать  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шагах  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG больше не являются несмещёнными, однако их дисперсия значительно снижена
- Не слишком ли дорого усреднять все эти градиенты? По существу, столь же эффективно, как SGD, если подойти к этому грамотно:

$$x^{(k)} = x^{(k-1)} - \alpha_k \underbrace{\left( \underbrace{\frac{1}{n} g_{i_k}^{(k)} - \frac{1}{n} g_{i_k}^{(k-1)}}_{\text{новое среднее по таблице}} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее по таблице}} \right)}_{\text{новое среднее по таблице}}$$

<sup>2</sup>Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

# Сходимость SAG

Предположим, что  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ , где каждая  $f_i$  дифференцируема, и  $\nabla f_i$  является липшицевым с константой  $L$ .

Обозначим  $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$  — среднее итерированных точек после  $k - 1$  шагов.

## i Theorem

SAG с фиксированным размером шага  $\alpha = \frac{1}{16L}$  и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

где математическое ожидание берётся по случайным выборам индексов.

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .
- Это скорость сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Для сравнения: скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  у GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  у SGD.

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .
- Это скорость сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Для сравнения: скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  у GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  у SGD.
- Но константы различаются! Оценки после  $k$  шагов:

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .
- Это скорость сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Для сравнения: скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  у GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  у SGD.
- Но константы различаются! Оценки после  $k$  шагов:
  - GD:  $\frac{L\|x^{(0)} - x^*\|^2}{2k}$

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .
- Это скорость сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Для сравнения: скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  у GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  у SGD.
- Но константы различаются! Оценки после  $k$  шагов:
  - GD:  $\frac{L\|x^{(0)}-x^*\|^2}{2k}$
  - SAG:  $\frac{48n[f(x^{(0)})-f^*]+128L\|x^{(0)}-x^*\|^2}{k}$

# Сходимость SAG

- Результат сформулирован для среднего итерируемого  $\bar{x}^{(k)}$ , но может быть также показан для наилучшего достигнутого итерируемого  $x_{best}^{(k)}$ .
- Это скорость сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Для сравнения: скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  у GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  у SGD.
- Но константы различаются! Оценки после  $k$  шагов:
  - GD:  $\frac{L\|x^{(0)} - x^*\|^2}{2k}$
  - SAG:  $\frac{48n[f(x^{(0)}) - f^*] + 128L\|x^{(0)} - x^*\|^2}{k}$
- Таким образом, первый член оценки SAG страдает от множителя  $n$ ; авторы предлагают более умную инициализацию, чтобы сделать  $f(x^{(0)}) - f^*$  малым (например, использовать результат  $n$  шагов SGD).

# Сходимость SAG

Предположим дополнительно, что каждая  $f_i$  является сильно выпуклой с параметром  $\mu$ .

## i Theorem

SAG с размером шага  $\alpha = \frac{1}{16L}$  и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2} (f(x^{(0)}) - f^*) + \frac{4L}{n} \|x^{(0)} - x^*\|^2\right)$$

## Замечания:

- Это линейная скорость сходимости  $\mathcal{O}(\gamma^k)$  для SAG. Для сравнения:  $\mathcal{O}(\gamma^k)$  у GD и лишь  $\mathcal{O}(\frac{1}{k})$  у SGD.

# Сходимость SAG

Предположим дополнительно, что каждая  $f_i$  является сильно выпуклой с параметром  $\mu$ .

## i Theorem

SAG с размером шага  $\alpha = \frac{1}{16L}$  и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2} (f(x^{(0)}) - f^*) + \frac{4L}{n} \|x^{(0)} - x^*\|^2\right)$$

## Замечания:

- Это линейная скорость сходимости  $\mathcal{O}(\gamma^k)$  для SAG. Для сравнения:  $\mathcal{O}(\gamma^k)$  у GD и лишь  $\mathcal{O}(\frac{1}{k})$  у SGD.
- Как и GD, говорят, что SAG адаптируется к сильной выпуклости.

# Сходимость SAG

Предположим дополнительно, что каждая  $f_i$  является сильно выпуклой с параметром  $\mu$ .

## i Theorem

SAG с размером шага  $\alpha = \frac{1}{16L}$  и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

## Замечания:

- Это линейная скорость сходимости  $\mathcal{O}(\gamma^k)$  для SAG. Для сравнения:  $\mathcal{O}(\gamma^k)$  у GD и лишь  $\mathcal{O}(\frac{1}{k})$  у SGD.
- Как и GD, говорят, что SAG адаптируется к сильной выпуклости.
- Доказательства этих результатов непросты: 15 страниц, с использованием вычислительных инструментов!

Название этого аниме?



SAG:

$$x^{k+1} = x^k - \gamma \left[ \frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$


SAGA:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости



<sup>3</sup>Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

## Vinland SAGA <sup>3</sup>

SAG:

$$x^{k+1} = x^k - \gamma \left[ \frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SAGA:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости
- имеет дисперсию в  $n^2$  раз больше



<sup>3</sup>Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

## Vinland SAGA <sup>3</sup>

SAG:

$$x^{k+1} = x^k - \gamma \left[ \frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SAGA:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[ f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости
- имеет дисперсию в  $n^2$  раз больше
- может быть расширен на составную оптимизацию с помощью проксимальных операторов



<sup>3</sup>Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

# Сходимость SAGA

Предположим, что  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ , где каждая  $f_i$  выпукла, дифференцируема, и  $\nabla f_i$  является липшицевым с константой  $L$ .

Обозначим  $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$  — среднее итерированных точек после  $k - 1$  шагов.

## i Theorem

SAGA с фиксированным размером шага  $\alpha = \frac{1}{3L}$  и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{4n}{k} [f(x^0) - f^*] + \frac{8L}{k} [\|x^0 - x^*\|^2].$$

где математическое ожидание берётся по случайным выборам индексов.

- Благодаря несмещённости обновления анализ значительно менее сложен, чем для SAG

## Методы редукции дисперсии для нейронных сетей <sup>4</sup>

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии

---

<sup>4</sup>Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

## Методы редукции дисперсии для нейронных сетей <sup>4</sup>

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти

---

<sup>4</sup>Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

## Методы редукции дисперсии для нейронных сетей <sup>4</sup>

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти
- результаты оказываются неудовлетворительными или даже приводят к расходимости

---

<sup>4</sup>Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

## Методы редукции дисперсии для нейронных сетей <sup>4</sup>

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти
- результаты оказываются неудовлетворительными или даже приводят к расходимости
- в итоге авторы предлагают использовать технику редукции дисперсии совместно с адаптивностью AdaGrad, ADAM и т.д.

---

<sup>4</sup>Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

# Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX .

# Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX .
- SVRG на JAX для VAE .

# Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX 🧠.
- SVRG на JAX для VAE 🧠.
- SVRG и SARAH на чистом Torch (MLP + RNN) 🧠