

Методы редукции дисперсии


Семинар

ФКН ВШЭ

Основная проблема SGD

$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex binary logistic regression. $m=200$, $n=10$, $\mu=1$.



Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$

Применение к оценке градиента ?

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$

Применение к оценке градиента ?

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка

Применение к оценке градиента ?

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка
 - Если $\alpha < 1$: возможное смещение (но уменьшенная дисперсия).

Применение к оценке градиента ?

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка
 - Если $\alpha < 1$: возможное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента ?

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка
 - Если $\alpha < 1$: возможное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента ?

- SVRG: положим $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и сохранённом $\tilde{x}$.

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка
 - Если $\alpha < 1$: возможное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента ?

- SVRG: положим $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и сохранённом $\tilde{x}$.
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$ — полный градиент в точке $\tilde{x}$;

Ключевая идея редукции дисперсии

Принцип: снижение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным математическим ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: несмещённая оценка
 - Если $\alpha < 1$: возможное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента ?

- SVRG: положим $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и сохранённом $\tilde{x}$.
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$ — полный градиент в точке $\tilde{x}$;
- $X - Y = \nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})$

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длины эпохи (m)

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- **Инициализация:** $\tilde{x} \in \mathbb{R}^d$
- **Для** $i_{epoch} = 1$ **до** # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - **Для** $t = 1$ **до** длины эпохи (m)
 - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длины эпохи (m)
 - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
 - Обновить $\tilde{x} = x_t$

Замечания:

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- **Инициализация:** $\tilde{x} \in \mathbb{R}^d$
- **Для** $i_{epoch} = 1$ **до** # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - **Для** $t = 1$ **до** длины эпохи (m)
 - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
 - Обновить $\tilde{x} = x_t$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- **Инициализация:** $\tilde{x} \in \mathbb{R}^d$
- **Для** $i_{epoch} = 1$ **до** # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - **Для** $t = 1$ **до** длины эпохи (m)
 - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
 - Обновить $\tilde{x} = x_t$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи и размер шага γ .

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SVRG (стохастический градиент с редукцией дисперсии) ¹

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{epoch} = 1$ до # эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длины эпохи (m)
 - $x_t = x_{t-1} - \alpha [\nabla f(\tilde{x}) + (\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}))]$
 - Обновить $\tilde{x} = x_t$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи и размер шага γ .
- Линейная скорость сходимости, простое доказательство.

¹Johnson, R., Zhang, T. (2013). Accelerating stochastic gradient descent using predictive variance reduction. Advances in neural information processing systems, 26.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$
- Инициализировать $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$
- Инициализировать $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шагах $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. они остаются без изменений

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$
- Инициализировать $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шагах $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$
- Инициализировать $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шагах $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG больше не являются несмещёнными, однако их дисперсия значительно снижена

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

SAG (стохастический усреднённый градиент) ²

- Поддерживать таблицу, содержащую градиент g_i функции f_i , $i = 1, \dots, n$
- Инициализировать $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шагах $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем положить

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{последний градиент } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. они остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG больше не являются несмещёнными, однако их дисперсия значительно снижена
- Не слишком ли дорого усреднять все эти градиенты? По существу, столь же эффективно, как SGD, если подойти к этому грамотно:

$$x^{(k)} = x^{(k-1)} - \alpha_k \underbrace{\left(\underbrace{\frac{1}{n} g_{i_k}^{(k)} - \frac{1}{n} g_{i_k}^{(k-1)}}_{\text{новое среднее по таблице}} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее по таблице}} \right)}_{\text{новое среднее по таблице}}$$

²Schmidt, M., Le Roux, N., Bach, F. (2017). Minimizing finite sums with the stochastic average gradient. Mathematical Programming, 162, 83-112.

Сходимость SAG

Предположим, что $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждая f_i дифференцируема, и ∇f_i является липшицевым с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднее итерированных точек после $k - 1$ шагов.

Theorem

SAG с фиксированным размером шага $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

где математическое ожидание берётся по случайным выборам индексов.

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.
- Это скорость сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Для сравнения: скорость $\mathcal{O}\left(\frac{1}{k}\right)$ у GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ у SGD.

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.
- Это скорость сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Для сравнения: скорость $\mathcal{O}\left(\frac{1}{k}\right)$ у GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ у SGD.
- Но константы различаются! Оценки после k шагов:

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.
- Это скорость сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Для сравнения: скорость $\mathcal{O}\left(\frac{1}{k}\right)$ у GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ у SGD.
- Но константы различаются! Оценки после k шагов:
 - GD: $\frac{L\|x^{(0)} - x^*\|^2}{2k}$

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.
- Это скорость сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Для сравнения: скорость $\mathcal{O}\left(\frac{1}{k}\right)$ у GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ у SGD.
- Но константы различаются! Оценки после k шагов:
 - GD: $\frac{L\|x^{(0)}-x^*\|^2}{2k}$
 - SAG: $\frac{48n[f(x^{(0)})-f^*]+128L\|x^{(0)}-x^*\|^2}{k}$

Сходимость SAG

- Результат сформулирован для среднего итерируемого $\bar{x}^{(k)}$, но может быть также показан для наилучшего достигнутого итерируемого $x_{best}^{(k)}$.
- Это скорость сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Для сравнения: скорость $\mathcal{O}\left(\frac{1}{k}\right)$ у GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ у SGD.
- Но константы различаются! Оценки после k шагов:
 - GD: $\frac{L\|x^{(0)} - x^*\|^2}{2k}$
 - SAG: $\frac{48n[f(x^{(0)}) - f^*] + 128L\|x^{(0)} - x^*\|^2}{k}$
- Таким образом, первый член оценки SAG страдает от множителя n ; авторы предлагают более умную инициализацию, чтобы сделать $f(x^{(0)}) - f^*$ малым (например, использовать результат n шагов SGD).

Сходимость SAG

Предположим дополнительно, что каждая f_i является сильно выпуклой с параметром μ .

i Theorem

SAG с размером шага $\alpha = \frac{1}{16L}$ и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2} (f(x^{(0)}) - f^*) + \frac{4L}{n} \|x^{(0)} - x^*\|^2\right)$$

Замечания:

- Это линейная скорость сходимости $\mathcal{O}(\gamma^k)$ для SAG. Для сравнения: $\mathcal{O}(\gamma^k)$ у GD и лишь $\mathcal{O}\left(\frac{1}{k}\right)$ у SGD.

Сходимость SAG

Предположим дополнительно, что каждая f_i является сильно выпуклой с параметром μ .

i Theorem

SAG с размером шага $\alpha = \frac{1}{16L}$ и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

Замечания:

- Это линейная скорость сходимости $\mathcal{O}(\gamma^k)$ для SAG. Для сравнения: $\mathcal{O}(\gamma^k)$ у GD и лишь $\mathcal{O}(\frac{1}{k})$ у SGD.
- Как и GD, говорят, что SAG адаптируется к сильной выпуклости.

Сходимость SAG

Предположим дополнительно, что каждая f_i является сильно выпуклой с параметром μ .

i Theorem

SAG с размером шага $\alpha = \frac{1}{16L}$ и той же инициализацией, что и выше, удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

Замечания:

- Это линейная скорость сходимости $\mathcal{O}(\gamma^k)$ для SAG. Для сравнения: $\mathcal{O}(\gamma^k)$ у GD и лишь $\mathcal{O}(\frac{1}{k})$ у SGD.
- Как и GD, говорят, что SAG адаптируется к сильной выпуклости.
- Доказательства этих результатов непросты: 15 страниц, с использованием вычислительных инструментов!

Название этого аниме?



Vinland SAGA ³

SAG:

$$x^{k+1} = x^k - \gamma \left[\frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SAGA:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости



³Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

Vinland SAGA³

SAG:

$$x^{k+1} = x^k - \gamma \left[\frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SAGA:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости
- имеет дисперсию в n^2 раз больше



³Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

Vinland SAGA ³

SAG:

$$x^{k+1} = x^k - \gamma \left[\frac{f'_j(x^k) - f'_j(\phi_j^k)}{n} + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SAGA:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\phi_j^k) + \frac{1}{n} \sum_{i=1}^n f'_i(\phi_i^k) \right]$$

SVRG:

$$x^{k+1} = x^k - \gamma \left[f'_j(x^k) - f'_j(\tilde{x}) + \frac{1}{n} \sum_{i=1}^n f'_i(\tilde{x}) \right]$$

- и SAGA, и SVRG являются несмещёнными в отличие от SAG, что улучшает их анализ и гарантии сходимости
- имеет дисперсию в n^2 раз больше
- может быть расширен на составную оптимизацию с помощью проксимальных операторов



³Defazio A. et. al. (2014). SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives.

Сходимость SAGA

Предположим, что $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждая f_i выпукла, дифференцируема, и ∇f_i является липшицевым с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднее итерированных точек после $k - 1$ шагов.

i Theorem

SAGA с фиксированным размером шага $\alpha = \frac{1}{3L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{4n}{k} [f(x^0) - f^*] + \frac{8L}{k} [\|x^0 - x^*\|^2].$$

где математическое ожидание берётся по случайным выборам индексов.

- Благодаря несмещённости обновления анализ значительно менее сложен, чем для SAG

Методы редукции дисперсии для нейронных сетей ⁴

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии

⁴Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

Методы редукции дисперсии для нейронных сетей ⁴

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти

⁴Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

Методы редукции дисперсии для нейронных сетей ⁴

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти
- результаты оказываются неудовлетворительными или даже приводят к расходимости

⁴Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

Методы редукции дисперсии для нейронных сетей ⁴

- обучение нейронных сетей нарушает большинство предположений, необходимых для работы методов редукции дисперсии
- авторы рассматривают SVRG, так как он не требует хранения полного градиента в памяти
- результаты оказываются неудовлетворительными или даже приводят к расходимости
- в итоге авторы предлагают использовать технику редукции дисперсии совместно с адаптивностью AdaGrad, ADAM и т.д.

⁴Defazio, A., Bottou, L. (2019). On the ineffectiveness of variance reduced optimization for deep learning. Advances in Neural Information Processing Systems, 32.

Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX .

Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX .
- SVRG на JAX для VAE .

Вычислительные эксперименты

Рассмотрим вычислительные эксперименты для

- SGD, SAG и SVRG на JAX 🧠.
- SVRG на JAX для VAE 🧠.
- SVRG и SARAH на чистом Torch (MLP + RNN) 🧠