

Обучение больших моделей

Семинар

ФКН ВШЭ

Accurate, Large Minibatch SGD. Мотивация

💡 Главные преимущества больших данных

Рост масштаба данных и моделей быстро улучшает качество

Accurate, Large Minibatch SGD. Мотивация

💡 Главные преимущества больших данных

Рост масштаба данных и моделей быстро улучшает качество

❗ Главные недостатки больших данных

По мере роста модели и данных растёт и время обучения

Accurate, Large Minibatch SGD. Мотивация

💡 Главные преимущества больших данных

Рост масштаба данных и моделей быстро улучшает качество

❗ Главные недостатки больших данных

По мере роста модели и данных растёт и время обучения

Решение: Использовать распределённый SGD с большим батчем для более **эффективных** итераций

Accurate, Large Minibatch SGD. Постановка задачи

Функция потерь

$$L(w) = \frac{1}{|X|} \sum_{x \in X} l(x, w)$$

Одна итерация Minibatch SGD (размер батча n)

$$w_{t+1} = w_t - \eta \frac{1}{n} \sum_{x \in \mathcal{B}} \nabla l(x, w_t)$$

k итераций Minibatch SGD (размер батча n)

$$w_{t+k} = w_t - \eta \frac{1}{n} \sum_{j < k} \sum_{x \in \mathcal{B}_j} \nabla l(x, w_{t+j})$$

Одна итерация Minibatch SGD с большим батчем (размер батча kn)

$$\hat{w}_{t+1} = w_t - \hat{\eta} \frac{1}{kn} \sum_{j < k} \sum_{x \in \mathcal{B}_j} \nabla l(x, w_t)$$

Желаемое свойство при обучении на нескольких GPU: $\hat{w}_{t+1} \sim w_{t+k}$

Accurate, Large Minibatch SGD. Основная идея

Желаемое свойство при обучении на нескольких GPU: $\hat{w}_{t+1} \sim w_{t+k}$

💡 Основное допущение статьи

Если допустить $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ при $j < k$, то установка $\hat{\eta} = k\eta$ даёт $\hat{w}_{t+1} \sim w_{t+k}$

Accurate, Large Minibatch SGD. Основная идея

Желаемое свойство при обучении на нескольких GPU: $\hat{w}_{t+1} \sim w_{t+k}$

💡 Основное допущение статьи

Если допустить $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ при $j < k$, то установка $\hat{\eta} = k\eta$ даёт $\hat{w}_{t+1} \sim w_{t+k}$

i Question

Когда условие $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ явно не выполняется?

Accurate, Large Minibatch SGD. Основная идея

Желаемое свойство при обучении на нескольких GPU: $\hat{w}_{t+1} \sim w_{t+k}$

💡 Основное допущение статьи

Если допустить $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ при $j < k$, то установка $\hat{\eta} = k\eta$ даёт $\hat{w}_{t+1} \sim w_{t+k}$

i Question

Когда условие $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ явно не выполняется?

1. Сеть быстро меняется в начале обучения

Accurate, Large Minibatch SGD. Основная идея

Желаемое свойство при обучении на нескольких GPU: $\hat{w}_{t+1} \sim w_{t+k}$

💡 Основное допущение статьи

Если допустить $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ при $j < k$, то установка $\hat{\eta} = k\eta$ даёт $\hat{w}_{t+1} \sim w_{t+k}$

i Question

Когда условие $\nabla l(x, w_t) \sim \nabla l(x, w_{t+j})$ явно не выполняется?

1. Сеть быстро меняется в начале обучения
2. Очень большое k порождает очень большое $\hat{\eta}$ и делает обучение нестабильным

Accurate, Large Minibatch SGD. Решение проблем допущения

Question

Как бороться с проблемами допущения?

Accurate, Large Minibatch SGD. Решение проблем допущения

i Question

Как бороться с проблемами допущения?

Постепенный разогрев. Итерационный линейный планировщик с начальным значением $\hat{\eta} = \eta$ и конечным значением $\hat{\eta} = k\eta$ примерно через ~ 5 эпох.

- позволяет избежать резкого увеличения скорости обучения

Постоянный размер выборки на воркер. При глобальном размере батча kn мы сохраняем *размер выборки на воркер* n постоянным при изменении числа воркеров k .

Accurate, Large Minibatch SGD. Решение проблем допущения

i Question

Как бороться с проблемами допущения?

Постепенный разогрев. Итерационный линейный планировщик с начальным значением $\hat{\eta} = \eta$ и конечным значением $\hat{\eta} = k\eta$ примерно через ~ 5 эпох.

- позволяет избежать резкого увеличения скорости обучения

Постоянный размер выборки на воркер. При глобальном размере батча kn мы сохраняем *размер выборки на воркер* n постоянным при изменении числа воркеров k .

Accurate, Large Minibatch SGD. Решение проблем допущения

i Question

Как бороться с проблемами допущения?

Постепенный разогрев. Итерационный линейный планировщик с начальным значением $\hat{\eta} = \eta$ и конечным значением $\hat{\eta} = k\eta$ примерно через ~ 5 эпох.


- позволяет избежать резкого увеличения скорости обучения

Постоянный размер выборки на воркер. При глобальном размере батча kn мы сохраняем *размер выборки на воркер* n постоянным при изменении числа воркеров k .


- крайне важно для Batch Normalization!

Accurate, Large Minibatch SGD. Результаты на ImageNet

Кривые обучения точно воспроизводят базовый вариант (за исключением периода разогрева) вплоть до $8k$ мини-батчей.



Accurate, Large Minibatch SGD. Результаты на ImageNet



Оба набора кривых хорошо совпадают после достаточного числа эпох обучения.

Обратите внимание, что статистики BN (только для инференса) вычисляются с помощью скользящего среднего, которое при большом мини-батче обновляется реже и поэтому более зашумлено в начале обучения (это объясняет больший разброс ошибки на валидации в ранних эпохах).

Снижение потребления памяти. Выгрузка на CPU

- Выгрузка весов на CPU и загрузка их на GPU только при выполнении прямого прохода

Снижение потребления памяти. Выгрузка на CPU

- Выгрузка весов на CPU и загрузка их на GPU только при выполнении прямого прохода
- Выгрузка на CPU работает с подмодулями, а не с целыми моделями.

Снижение потребления памяти. Выгрузка на CPU

- Выгрузка весов на CPU и загрузка их на GPU только при выполнении прямого прохода
- Выгрузка на CPU работает с подмодулями, а не с целыми моделями.
- Инференс значительно замедляется из-за итеративной загрузки и выгрузки.

Снижение потребления памяти. Выгрузка на CPU

- Выгрузка весов на CPU и загрузка их на GPU только при выполнении прямого прохода
- Выгрузка на CPU работает с подмодулями, а не с целыми моделями.
- Инференс значительно замедляется из-за итеративной загрузки и выгрузки.
- Пример в Colab  Open in Colab.

Снижение потребления памяти. Выгрузка модели

- Выгрузка на CPU замедляет инференс, поскольку *подмодули* по мере необходимости перемещаются на GPU и сразу возвращаются на CPU при запуске нового модуля.

Снижение потребления памяти. Выгрузка модели

- Выгрузка на CPU замедляет инференс, поскольку *подмодули* по мере необходимости перемещаются на GPU и сразу возвращаются на CPU при запуске нового модуля.
- Выгрузка полной модели — альтернатива, при которой целые модели перемещаются на GPU вместо обработки составляющих *подмодулей* каждой модели.

Снижение потребления памяти. Выгрузка модели

- Выгрузка на CPU замедляет инференс, поскольку *подмодули* по мере необходимости перемещаются на GPU и сразу возвращаются на CPU при запуске нового модуля.
- Выгрузка полной модели — альтернатива, при которой целые модели перемещаются на GPU вместо обработки составляющих *подмодулей* каждой модели.
- При выгрузке модели только один из основных компонентов пайплайна (как правило, текстовый энкодер, UNet или VAE) находится на GPU, пока остальные ожидают на CPU.

Снижение потребления памяти. Выгрузка модели

- Выгрузка на CPU замедляет инференс, поскольку *подмодули* по мере необходимости перемещаются на GPU и сразу возвращаются на CPU при запуске нового модуля.
- Выгрузка полной модели — альтернатива, при которой целые модели перемещаются на GPU вместо обработки составляющих *подмодулей* каждой модели.
- При выгрузке модели только один из основных компонентов пайплайна (как правило, текстовый энкодер, UNet или VAE) находится на GPU, пока остальные ожидают на CPU.
- Пример в Colab  Open in Colab.

Снижение потребления памяти. Квантизация

- Квантизация отображает значение с плавающей точкой $x \in [\alpha, \beta]$ в b -битное целое число $x_q \in [\alpha_q, \beta_q]$.

Снижение потребления памяти. Квантизация

- Квантизация отображает значение с плавающей точкой $x \in [\alpha, \beta]$ в b -битное целое число $x_q \in [\alpha_q, \beta_q]$.
- Процесс квантизации определяется как

$$x_q = \text{clip}\left(\text{round}\left(\frac{1}{s}x + z\right), \alpha_q, \beta_q\right)$$

А процесс деквантизации определяется как

$$x = s(x_q - z)$$

Значения масштаба s и точки нуля z равны

$$s = \frac{\beta - \alpha}{\beta_q - \alpha_q} \tag{1}$$

$$z = \text{round}\left(\frac{\beta\alpha_q - \alpha\beta_q}{\beta - \alpha}\right) \tag{2}$$

(3)

Заметим, что z — целое число, а s — положительное число с плавающей точкой.

Снижение потребления памяти. Квантизация

- Квантизация отображает значение с плавающей точкой $x \in [\alpha, \beta]$ в b -битное целое число $x_q \in [\alpha_q, \beta_q]$.
- Процесс квантизации определяется как

$$x_q = \text{clip}\left(\text{round}\left(\frac{1}{s}x + z\right), \alpha_q, \beta_q\right)$$

А процесс деквантизации определяется как

$$x = s(x_q - z)$$

Значения масштаба s и точки нуля z равны

$$s = \frac{\beta - \alpha}{\beta_q - \alpha_q} \tag{1}$$

$$z = \text{round}\left(\frac{\beta\alpha_q - \alpha\beta_q}{\beta - \alpha}\right) \tag{2}$$

(3)

Заметим, что z — целое число, а s — положительное число с плавающей точкой.

- Квантизация позволяет выполнять многие трудоёмкие операции глубокого обучения (например, матричное умножение) в целочисленном диапазоне с использованием эффективного целочисленного аппаратного обеспечения (NVIDIA Tensor Core или Tensor Core IMMA operations) и соответствующих алгоритмов.


Снижение потребления памяти. Квантизация

- Для изучения теории смотрите *Quantization for Neural Networks* , Lei Mao: **git**.

Снижение потребления памяти. Квантизация

- Для изучения теории смотрите *Quantization for Neural Networks* , Lei Mao: [git](#).
- Пример в Colab  Open in Colab.

Обучение со смешанной точностью (MPT)



Обучение со смешанной точностью — техника, при которой в процессе обучения нейронной сети используются как 16-битные (FP16), так и 32-битные (FP32) типы чисел с плавающей точкой. Такой подход ускоряет обучение и снижает потребление памяти без потери точности модели.

Почему МРТ выгодно?

- **Более быстрое обучение:** Использование FP16 позволяет ускорить вычисления, особенно на современных GPU с Tensor Cores, таких как архитектуры NVIDIA Volta, Turing и Ampere. Это может дать ускорение обучения в 2–3 раза.

Почему МРТ выгодно?

- **Более быстрое обучение:** Использование FP16 позволяет ускорить вычисления, особенно на современных GPU с Tensor Cores, таких как архитектуры NVIDIA Volta, Turing и Ampere. Это может дать ускорение обучения в 2–3 раза.
- **Снижение потребления памяти:** FP16 использует вдвое меньше памяти по сравнению с FP32, что позволяет обучать более крупные модели или использовать большие батчи.

Почему МРТ выгодно?

- **Более быстрое обучение:** Использование FP16 позволяет ускорить вычисления, особенно на современных GPU с Tensor Cores, таких как архитектуры NVIDIA Volta, Turing и Ampere. Это может дать ускорение обучения в 2–3 раза.
- **Снижение потребления памяти:** FP16 использует вдвое меньше памяти по сравнению с FP32, что позволяет обучать более крупные модели или использовать большие батчи.
- **Сохранение точности:** При правильной реализации обучение со смешанной точностью обеспечивает тот же уровень точности модели, что и обучение с полной точностью (FP32).

Как это работает?

1. **Автоматическое приведение типов:** Некоторые операции, например матричные умножения и свёртки, выполняются в FP16, тогда как другие, требующие более высокой точности, остаются в FP32. В таких фреймворках как PyTorch и TensorFlow это управляется автоматически.

Пример на PyTorch:

```
from torch.cuda.amp import autocast, GradScaler

scaler = GradScaler()

for data, target in dataloader:
    optimizer.zero_grad()
    with autocast():
        output = model(data)
        loss = loss_fn(output, target)
    scaler.scale(loss).backward()
    scaler.step(optimizer)
    scaler.update()
```

Как это работает?

1. **Автоматическое приведение типов:** Некоторые операции, например матричные умножения и свёртки, выполняются в FP16, тогда как другие, требующие более высокой точности, остаются в FP32. В таких фреймворках как PyTorch и TensorFlow это управляется автоматически.
2. **Масштабирование функции потерь:** Чтобы предотвратить исчезновение малых значений градиентов при использовании FP16, потери масштабируются вверх во время обратного распространения ошибки, а затем масштабируются вниз перед шагом оптимизатора.

Пример на PyTorch:

```
from torch.cuda.amp import autocast, GradScaler

scaler = GradScaler()

for data, target in dataloader:
    optimizer.zero_grad()
    with autocast():
        output = model(data)
        loss = loss_fn(output, target)
    scaler.scale(loss).backward()
    scaler.step(optimizer)
    scaler.update()
```

Когда использовать обучение со смешанной точностью?

- Обучение на современных GPU: Особенно эффективно на GPU с Tensor Cores (например, NVIDIA V100, A100).

Когда использовать обучение со смешанной точностью?

- Обучение на современных GPU: Особенно эффективно на GPU с Tensor Cores (например, NVIDIA V100, A100).
- Ограниченные вычислительные ресурсы: Снижает потребление памяти и ускоряет обучение, что полезно при нехватке вычислительных ресурсов.

Когда использовать обучение со смешанной точностью?

- Обучение на современных GPU: Особенно эффективно на GPU с Tensor Cores (например, NVIDIA V100, A100).
- Ограниченные вычислительные ресурсы: Снижает потребление памяти и ускоряет обучение, что полезно при нехватке вычислительных ресурсов.
- Смотрите также интересный пост в блоге по теме обучения со смешанной точностью 