


Двойственные методы и ADMM

Семинар

ФКН ВШЭ

Определение



Напомним, что для функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, определённая как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется её сопряжённой.

Свойства сопряжённой функции

Напомним, что для функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, определённая как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется её сопряжённой.

- Сопряжённые функции часто встречаются в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

Свойства сопряжённой функции

Напомним, что для функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, определённая как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется её сопряжённой.

- Сопряжённые функции часто встречаются в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

- Если f замкнута и выпукла, то $f^{**} = f$. Кроме того,

$$x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x) \Leftrightarrow x \in \arg \min_z [f(z) - y^T z]$$

Свойства сопряжённой функции

Напомним, что для функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, определённая как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется её сопряжённой.

- Сопряжённые функции часто встречаются в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

- Если f замкнута и выпукла, то $f^{**} = f$. Кроме того,



$$x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x) \Leftrightarrow x \in \arg \min_z [f(z) - y^T z]$$

- Если f строго выпукла, то

$$\nabla f^*(y) = \arg \min_z [f(z) - y^T z]$$

Наклоны f и f^*

Предположим, что f — замкнутая выпуклая функция. Тогда f является сильно выпуклой с параметром $\mu \Leftrightarrow \nabla f^*$ является липшицевым с параметром $1/\mu$.



Задача 1

i Question

Найдите сопряжённую функцию для

$$f_1(x) = a^T x + b$$

Задача 1

i Question

Найдите сопряжённую функцию для

$$f_1(x) = a^T x + b$$

$$f^*(s) = \sup_{x \in \mathbb{R}^n} (s^T x - a^T x - b) = \begin{cases} -b, & \text{if } s = a \\ \infty, & \text{else} \end{cases} = \delta([s = a]) - b$$

$$\text{dom } f^*(s) = \{a\}$$

Задача 1

i Question

Найдите сопряжённую функцию для

$$f_1(x) = a^T x + b$$

$$f^*(s) = \sup_{x \in \mathbb{R}^n} (s^T x - a^T x - b) = \begin{cases} -b, & \text{if } s = a \\ \infty, & \text{else} \end{cases} = \delta([s = a]) - b$$

$$\text{dom } f^*(s) = \{a\}$$

i Question

Найдите сопряжённую функцию для

$$f_2(s) = \delta([s = a]) - b$$

Задача 1

i Question

Найдите сопряжённую функцию для

$$f_1(x) = a^T x + b$$

$$f^*(s) = \sup_{x \in \mathbb{R}^n} (s^T x - a^T x - b) = \begin{cases} -b, & \text{if } s = a \\ \infty, & \text{else} \end{cases} = \delta([s = a]) - b$$

$$\text{dom } f^*(s) = \{a\}$$

i Question

Найдите сопряжённую функцию для

$$f_2(s) = \delta([s = a]) - b$$

$$(\delta([s = a]) - b)^* = \sup_{s \in \text{dom } f_2(s)} (y^T s - \delta([s = a]) + b) = a^T y + b$$

Задача 2

Question

Найдите сопряжённую функцию для

$$f(x) = \log(1 + \exp(x))$$

Задача 2

i Question

Найдите сопряжённую функцию для

$$f(x) = \log(1 + \exp(x))$$

$$f^*(s) = \sup_{x \in \mathbb{R}^n} (sx - \log(1 + \exp(x)))$$

Задача 2

i Question

Найдите сопряжённую функцию для

$$f(x) = \log(1 + \exp(x))$$

$$f^*(s) = \sup_{x \in \mathbb{R}^n} (sx - \log(1 + \exp(x)))$$

$$f^*(s) = \begin{cases} \infty, & \text{if } s < 0 \\ 0, & \text{if } s = 0 \\ 0, & \text{if } s = 1 \\ \infty, & \text{if } s > 1 \\ ?, & \text{if } 0 < s < 1 \end{cases}$$

Задача 2

i Question

Найдите сопряжённую функцию для

$$f(x) = \log(1 + \exp(x))$$

$s \in (0, 1)$:

$$s - \frac{\exp(x)}{1 + \exp(x)} = 0 \Leftrightarrow x_{opt} = \log \frac{s}{1 - s}$$

Задача 2

i Question

Найдите сопряжённую функцию для

$$f(x) = \log(1 + \exp(x))$$

$s \in (0, 1)$:

$$s - \frac{\exp(x)}{1 + \exp(x)} = 0 \Leftrightarrow x_{opt} = \log \frac{s}{1 - s}$$

Таким образом,

$$f^*(s) = \begin{cases} 0, & \text{if } s \in \{0, 1\} \\ s \log s + (1 - s) \log(1 - s), & \text{if } 0 < s < 1 \\ \infty, & \text{else} \end{cases}$$

$$\text{dom } f^*(s) = [0, 1]$$

Метод двойственного (суб)градиента

Даже если двойственную (сопряжённую) функцию нельзя выразить в замкнутой форме, можно использовать основанные на двойственности методы градиента или субградиента.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{subject to} \quad Ax = b$$

Метод двойственного (суб)градиента

Даже если двойственную (сопряжённую) функцию нельзя выразить в замкнутой форме, можно использовать основанные на двойственности методы градиента или субградиента.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{subject to} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая функция к f . Обозначим $g(u) = -f^*(-A^T u) - b^T u$. Заметим, что:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Метод двойственного (суб)градиента

Даже если двойственную (сопряжённую) функцию нельзя выразить в замкнутой форме, можно использовать основанные на двойственности методы градиента или субградиента.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{subject to} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая функция к f . Обозначим $g(u) = -f^*(-A^T u) - b^T u$. Заметим, что:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Используя свойства сопряжённых функций, получаем:

$$\partial g(u) = Ax - b \quad \text{where} \quad x \in \arg \min_z [f(z) + u^T Az]$$

Метод двойственного (суб)градиента

Даже если двойственную (сопряжённую) функцию нельзя выразить в замкнутой форме, можно использовать основанные на двойственности методы градиента или субградиента.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{subject to} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая функция к f . Обозначим $g(u) = -f^*(-A^T u) - b^T u$. Заметим, что:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Используя свойства сопряжённых функций, получаем:

$$\partial g(u) = Ax - b \quad \text{where} \quad x \in \arg \min_z [f(z) + u^T Az]$$

Метод двойственного подъёма для максимизации двойственной цели:

- Шаговые размеры α_k , $k = 1, 2, 3, \dots$, выбираются стандартными способами.

i

$$x_k \in \arg \min_x [f(x) + (u_{k-1})^T Ax]$$

$$u_k = u_{k-1} + \alpha_k (Ax_k - b)$$

$f \rightarrow \min_{x,y,z}$

Метод двойственного подъёма

Метод двойственного (суб)градиента

Даже если двойственную (сопряжённую) функцию нельзя выразить в замкнутой форме, можно использовать основанные на двойственности методы градиента или субградиента.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{subject to} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая функция к f . Обозначим $g(u) = -f^*(-A^T u) - b^T u$. Заметим, что:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Используя свойства сопряжённых функций, получаем:

$$\partial g(u) = Ax - b \quad \text{where} \quad x \in \arg \min_z [f(z) + u^T Az]$$

Метод двойственного подъёма для максимизации двойственной цели:

- Шаговые размеры α_k , $k = 1, 2, 3, \dots$, выбираются стандартными способами.
- Проксимальные градиенты и ускорение применяются так же, как обычно.

i

$$x_k \in \arg \min_x [f(x) + (u_{k-1})^T Ax]$$

$$u_k = u_{k-1} + \alpha_k (Ax_k - b)$$

$f \rightarrow \min_{x,y,z}$

Метод двойственного подъёма

Гарантии сходимости

Следующие результаты получаются из сочетания последнего факта с тем, что мы знаем о градиентном спуске:¹

- Если f сильно выпукла с параметром μ , то метод двойственного градиентного подъёма с постоянным шагом $\alpha_k = \mu$ сходится со сублинейной скоростью $O(\frac{1}{\epsilon})$.

Заметим, что здесь описывается сходимость по двойственной задаче. (Для сходимости по прямой задаче требуются дополнительные условия)

¹Это без учёта роли A , и таким образом отражает случай, когда сингулярные значения A близки к 1. Более точно, шаги должны быть: $\frac{\mu}{\sigma_{\max}(A)^2}$ (первый случай) и $\frac{2}{\frac{\sigma_{\max}(A)^2}{\mu} + \frac{\sigma_{\min}(A)^2}{L}}$ (второй случай).

Метод двойственного подъёма

Гарантии сходимости

Следующие результаты получаются из сочетания последнего факта с тем, что мы знаем о градиентном спуске:¹

- Если f сильно выпукла с параметром μ , то метод двойственного градиентного подъёма с постоянным шагом $\alpha_k = \mu$ сходится со сублинейной скоростью $O(\frac{1}{\epsilon})$.
- Если f сильно выпукла с параметром μ и ∇f липшицев с параметром L , то метод двойственного градиентного подъёма с шагом $\alpha_k = \frac{2}{\frac{1}{\mu} + \frac{1}{L}}$ сходится с линейной скоростью $O(\log(\frac{1}{\epsilon}))$.

Заметим, что здесь описывается сходимость по двойственной задаче. (Для сходимости по прямой задаче требуются дополнительные условия)

¹Это без учёта роли A , и таким образом отражает случай, когда сингулярные значения A близки к 1. Более точно, шаги должны быть: $\frac{\mu}{\sigma_{\min}^2(A)}$ (первый случай) и $\frac{2}{\frac{\sigma_{\max}^2(A)}{\mu} + \frac{\sigma_{\min}^2(A)}{L}}$ (второй случай).

Двойственная декомпозиция

Рассмотрим задачу:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, где каждый $x_i \in \mathbb{R}^{n_i}$. Матрицу A также разбиваем соответствующим образом:

$$A = [A_1 \dots A_B], \text{ где } A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но мощное наблюдение: при вычислении субградиента минимизация распадается на B отдельных задач:

$$\begin{aligned} x^{\text{new}} &\in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right) \\ \Rightarrow x_i^{\text{new}} &\in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B \end{aligned}$$

Двойственная декомпозиция

Рассмотрим задачу:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, где каждый $x_i \in \mathbb{R}^{n_i}$. Матрицу A также разбиваем соответствующим образом:

$$A = [A_1 \dots A_B], \text{ где } A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но мощное наблюдение: при вычислении субградиента минимизация распадается на B отдельных задач:

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right)$$

$$\Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B$$

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + (u^{k-1})^T A_i x_i), \quad i = 1, \dots, B$$

$$u_i^k = u_i^{k-1} + \alpha_k (A_i x_i^k - b_i), \quad i = 1, \dots, B$$

Эти шаги можно интерпретировать так:

- **Рассылка:** отправить u каждому из B процессоров, каждый параллельно оптимизирует и находит x_i .

Двойственная декомпозиция

Рассмотрим задачу:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, где каждый $x_i \in \mathbb{R}^{n_i}$. Матрицу A также разбиваем соответствующим образом:

$$A = [A_1 \dots A_B], \text{ где } A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но мощное наблюдение: при вычислении субградиента минимизация распадается на B отдельных задач:

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right)$$

$$\Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B$$

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + (u^{k-1})^T A_i x_i), \quad i = 1, \dots, B$$

$$u_i^k = u_i^{k-1} + \alpha_k (A_i x_i^k - b_i), \quad i = 1, \dots, B$$

Эти шаги можно интерпретировать так:

- **Рассылка:** отправить u каждому из B процессоров, каждый параллельно оптимизирует и находит x_i .
- **Сбор:** собрать $A_i x_i$ с каждого процессора, обновить глобальную двойственную переменную u .

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad \sum_{i=1}^B A_i x_i \leq b$$

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad \sum_{i=1}^B A_i x_i \leq b$$

Используя **двойственную декомпозицию**, а именно **метод проекции субградиента**, итерационные шаги записываются как:

- Шаг обновления прямой переменной:

$$x_i^k \in \arg \min_{x_i} \left[f_i(x_i) + (u^{k-1})^T A_i x_i \right], \quad i = 1, \dots, B$$

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{subject to} \quad \sum_{i=1}^B A_i x_i \leq b$$

Используя **двойственную декомпозицию**, а именно **метод проекции субградиента**, итерационные шаги записываются как:

- Шаг обновления прямой переменной:

$$x_i^k \in \arg \min_{x_i} \left[f_i(x_i) + (u^{k-1})^T A_i x_i \right], \quad i = 1, \dots, B$$

- Шаг обновления двойственной переменной:

$$u^k = \left(u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right) \right)_+$$

где $(u)_+$ обозначает положительную часть u , то есть $(u_+)_i = \max\{0, u_i\}$, для $i = 1, \dots, m$.

Метод расширенного лагранжиана (метод множителей)

Недостаток метода двойственного подъёма: для сходимости требуются жёсткие условия. Метод расширенного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

Метод расширенного лагранжиана (метод множителей)

Недостаток метода двойственного подъёма: для сходимости требуются жёсткие условия. Метод расширенного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта формулировка очевидно эквивалентна исходной задаче. Задача становится сильно выпуклой, если матрица A имеет полный ранг по столбцам.

Метод расширенного лагранжиана (метод множителей)

Недостаток метода двойственного подъёма: для сходимости требуются жёсткие условия. Метод расширенного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта формулировка очевидно эквивалентна исходной задаче. Задача становится сильно выпуклой, если матрица A имеет полный ранг по столбцам.

Метод двойственного градиентного подъёма: итерационные обновления определяются как:

$$\begin{aligned} x_k &= \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right] \\ u_k &= u_{k-1} + \rho(Ax_k - b) \end{aligned}$$

- **Преимущество:** расширенный лагранжиан обеспечивает лучшую сходимость.

Метод расширенного лагранжиана (метод множителей)

Недостаток метода двойственного подъёма: для сходимости требуются жёсткие условия. Метод расширенного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта формулировка очевидно эквивалентна исходной задаче. Задача становится сильно выпуклой, если матрица A имеет полный ранг по столбцам.

Метод двойственного градиентного подъёма: итерационные обновления определяются как:

$$\begin{aligned} x_k &= \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right] \\ u_k &= u_{k-1} + \rho(Ax_k - b) \end{aligned}$$

- **Преимущество:** расширенный лагранжиан обеспечивает лучшую сходимость.
- **Недостаток:** утрачивается декомпозируемость! (Разделимость нарушается)

Метод расширенного лагранжиана (метод множителей)

Недостаток метода двойственного подъёма: для сходимости требуются жёсткие условия. Метод расширенного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта формулировка очевидно эквивалентна исходной задаче. Задача становится сильно выпуклой, если матрица A имеет полный ранг по столбцам.

Метод двойственного градиентного подъёма: итерационные обновления определяются как:

$$\begin{aligned} x_k &= \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right] \\ u_k &= u_{k-1} + \rho(Ax_k - b) \end{aligned}$$

- **Преимущество:** расширенный лагранжиан обеспечивает лучшую сходимость.
- **Недостаток:** утрачивается декомпозируемость! (Разделимость нарушается)
- **Замечание:** шаговый размер $\alpha_k = \rho$ в двойственном алгоритме.

Пример в Colab

- Сравнение метода двойственного субградиента и метода расширенного лагранжиана  Open in Colab.

Метод переменных направлений множителей (ADMM)

ADMM (метод переменных направлений множителей) стремится совместить лучшие свойства обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Метод переменных направлений множителей (ADMM)

ADMM (метод переменных направлений множителей) стремится совместить лучшие свойства обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Дополняем целевую функцию штрафным слагаемым за нарушение ограничения:

$$\min_{x,z} f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

$$\text{s.t. } Ax + Bz = c$$

Метод переменных направлений множителей (ADMM)

ADMM (метод переменных направлений множителей) стремится совместить лучшие свойства обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Дополняем целевую функцию штрафным слагаемым за нарушение ограничения:

$$\min_{x,z} f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

$$\text{s.t. } Ax + Bz = c$$

где $\rho > 0$ — параметр. Расширенный лагранжиан для этой задачи определяется как:

$$L_{\rho}(x, z, u) = f(x) + g(z) + u^T(Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Метод переменных направлений множителей (ADMM)

ADMM выполняет следующие шаги, для $k = 1, 2, 3, \dots$:

1. Обновление x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

Метод переменных направлений множителей (ADMM)

ADMM выполняет следующие шаги, для $k = 1, 2, 3, \dots$:

1. Обновление x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновление z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

Метод переменных направлений множителей (ADMM)

ADMM выполняет следующие шаги, для $k = 1, 2, 3, \dots$:

1. Обновление x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновление z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновление u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Метод переменных направлений множителей (ADMM)

ADMM выполняет следующие шаги, для $k = 1, 2, 3, \dots$:

1. Обновление x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновление z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновление u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Метод переменных направлений множителей (ADMM)

ADMM выполняет следующие шаги, для $k = 1, 2, 3, \dots$:

1. Обновление x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновление z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновление u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Замечание: в обычном методе множителей первые два шага заменяются совместной минимизацией:

$$(x^{(k)}, z^{(k)}) = \arg \min_{x, z} L_\rho(x, z, u^{(k-1)})$$

Итоги по ADMM

- ADMM — один из ключевых и популярных современных методов оптимизации.

Итоги по ADMM

- ADMM — один из ключевых и популярных современных методов оптимизации.
- Он реализован во многих решателях и часто используется как метод по умолчанию.

Итоги по ADMM

- ADMM — один из ключевых и популярных современных методов оптимизации.
- Он реализован во многих решателях и часто используется как метод по умолчанию.
- Нестандартная формулировка задачи, для которой изобретён ADMM, охватывает многие важные частные случаи. «Нестандартная» переменная y зачастую играет роль вспомогательной переменной.

Итоги по ADMM

- ADMM — один из ключевых и популярных современных методов оптимизации.
- Он реализован во многих решателях и часто используется как метод по умолчанию.
- Нестандартная формулировка задачи, для которой изобретён ADMM, охватывает многие важные частные случаи. «Нестандартная» переменная y зачастую играет роль вспомогательной переменной.
- Штрафное слагаемое здесь — дополнительная модификация для стабилизации и ускорения сходимости. Нет необходимости делать ρ очень большим.